



中国研究生创新实践系列大赛
“华为杯”第二十一届中国研究生
数学建模竞赛

学 校 浙江工商大学

参赛队号 24103530117

1.陈蕊

队员姓名 2.邵雨欣

3.姚力琪

中国研究生创新实践系列大赛

“华为杯”第二十一届中国研究生

数学建模竞赛

题 目：风电场有功功率优化分配

摘 要：

随着我国大规模风电场的投入使用，风电产业面临着疲劳损伤加速和维护成本增加的挑战。本文基于此背景，针对风机关键部件疲劳损伤实时监测、受力估算以及有功功率优化调度搭建一系列时序预测、回归、优化模型，旨在优化有功功率分配、降低风机运行过程中的累积疲劳损伤，以减小其因疲劳导致可用寿命缩短的风险。

针对问题一：在复杂、随机载荷条件下，实时计算风机主轴和塔架的累积疲劳损伤具有低复杂度高实时性要求。为此，本问构建了实时预测疲劳损伤模型，首先通过自适应动态三阶段滑动窗口算法对时序数据分段，在子段内运用 AB 对抗 实现了窗口等参数高效搜索。其次，通过改进式雨流计数计算各窗口实时疲劳损失值，针对各子段进行并行计算预测风机主轴及塔架每秒累积疲劳损伤，并填入附件 5 中。最后进行数据对比，得出计算结果与附件 1 提供的参考数据所得结果增长情况一致。

针对问题二：针对传统受力分析方法在风速波动条件下难以准确估算受力，且风机主轴扭矩和塔架推力与风速和功率之间的复杂性。本问提出了基于物理理论与数据驱动相结合的非线性回归模型。首先通过多因素相关性分析，引入非线性项和交互项，提高模型泛化性。此外，提出三种分段拟合策略，同时运用网格搜索的方法，高效的捕捉了风速、功率、状态与风机结构受力之间的非线性关系。最后，根据附件 2 数据估算各个风机任意时刻的应力/扭矩值，与参考值对比拟合度为 0.8632。

针对问题三：风电场传统的有功平均分配策略由于无法应对高维度、多目标、实时性的需求，难以有效降低成本。本问通过 Pareto 前沿 分析将多目标有功功率分配优化模型转化为权重自适应的 MPC 优化模型。此外，根据风速波动特征对风电场进行区域划分，在各区间内进行滚动时域功率优化，得到每秒各风机功率分配值生成实时功率分配动图。最后，将功率分配结果和累积疲劳损失与参考值进行可视化分析，并评估模型。

针对问题四：在风电场实际运行中，随机噪声和通信延迟导致系统不稳定和优化效果下降。本问为提高模型的鲁棒性和稳定性，通过卡尔曼滤波器和延迟补偿机制分别对噪声影响和延迟作用进行处理，进一步引入鲁棒优化建立了基于问题三的全局协调的分区域 MPC 鲁棒优化模型。此外，建立对比模型，即基于粒子群算法的鲁棒优化模型。通过对比分析了后者在有功功率分配中效果较好，同时也减少了各元件累积疲劳损伤。最后，与无优化模型对比，验证了所提出的优化策略在实际环境中的有效性，成功应对了通信延迟和测量噪声带来的挑战。

关键词：有功功率优化、滑动窗口算法、非线性回归、MPC 模型、鲁棒优化、自适应

目录

1 前言	4
1.1 研究背景	4
1.2 问题重述	5
1.3 研究路线	5
2 理论基础	6
2.1 疲劳寿命	6
2.2 S-N 曲线	7
2.3 Palmgren-Miner 线性累积损伤理论	7
2.4 能量守恒原理	8
3 模型假设与符号说明	8
3.1 模型假设	8
3.2 符号说明	8
4 问题一 风机主轴及塔架疲劳损伤程度量化指标计算低复杂度模型	9
4.1 问题分析	9
4.2 求解思路图	10
4.3 模型建立	10
4.3.1 自适应动态三阶段滑动窗口算法	11
4.3.2 疲劳损伤模型	14
4.4 算法求解与结果分析	18
4.4.1 算法求解	18
4.4.2 结果分析	19
5 问题二 利用风速及功率估算塔架推力和主轴扭矩	24
5.1 问题分析	24
5.2 求解思路图	24
5.3 模型建立	25
5.3.1 数据预处理	25
5.3.2 相关性分析	25
5.3.3 多输入多输出的物理约束模型	28
5.3.4 分段拟合模型	29
5.4 算法求解与结果分析	32
5.4.1 模型求解	32
5.4.2 模型优化	34
5.4.3 结果分析	35
6 问题三 有功调度优化问题构建与实时求解	37
6.1 问题分析	37
6.2 求解思路图	38
6.3 模型建立	38
6.3.1 优化目标的设定	38
6.3.2 基于 Pareto 自适应权重调整	39
6.3.3 全局协调的分区域 MPC 优化模型	42
6.4 算法求解与结果分析	46
6.4.1 算法求解	46

6.4.2 结果分析	47
7 问题四 考虑通信延迟和测量噪声的有功功率优化与求解	50
7.1 问题分析	50
7.2 求解思路图	51
7.3 模型建立	51
7.3.1 基于动态数据滤波的缓解噪声影响策略	51
7.3.2 基于延迟补偿机制缓解延迟作用影响策略	52
7.3.3 基于粒子群算法的鲁棒优化模型	54
7.3.4 全局协调的分区域 MPC 鲁棒优化模型	56
7.4 算法求解与结果分析	58
7.4.1 算法求解	58
7.4.2 结果分析	59
8 模型总结与评价	62
8.1 模型优点与创新	62
8.2 模型缺点与不足	63
参考文献	64
附录 1: 附件文件及内容	65
附录 2: 部分代码	65
问题 1 关键代码	65
问题 2 关键代码:	67
问题 3 关键代码:	69
问题 4 关键代码:	71

1 前言

1.1 研究背景

近年来，我国风电快速发展，大型风机、大规模场站逐步投入运行。此趋势极大促进了可再生能源的利用与能源结构的转型，但同时也引出了新的技术挑战：随着风机额定功率的提升与机械结构的复杂化，其在多变风况下的柔性响应增强，导致疲劳损伤累积速率显著提升，极端情况甚至会加剧风机倒塌、叶片断裂等安全风险。目前，亟需通过优化手段，降低风机运行过程中的累积疲劳损伤，以减小其因疲劳导致可用寿命缩短的风险。

在风电场的实际运行过程中，电网调度指令由调度中心发出，并传递至风电场站的控制端。场站内的自动发电控制系统（AGC）作为核心调控组件，具备每秒一次的高频率采样能力，以实时响应电网调度指令。AGC 系统依据电网的调度需求，运用先进的算法模型，精确计算出风电场内各台风力发电机应承担的有功功率份额，此过程即为有功功率分配。分配结果以功率参考值的形式，通过通信链路发送给每一台风机。随后，各风机根据其接收到的功率参考值，通过调整机械参数（如叶片角度、发电机转速等），实现发电量对功率参考值的精确跟踪，从而确保风电场的整体输出功率与电网调度指令保持一致。

当前，风电领域亟待解决的关键问题之一在于，如何在维持高效发电的同时，有效控制并减缓风机运行中的疲劳损伤累积，以延长设备寿命并确保运行安全。传统上，功率分配策略多采用简单的平均分配方法，该方法未充分考虑风机个体间的运行状态差异及疲劳损伤累积的动态变化，致使部分风机长期处于高应力、高疲劳状态，加速了机械部件的退化。本研究致力于通过实时监测与数据分析，构建低复杂度疲劳损伤评估模型及考虑实际约束的有功调度优化算法，以实现风机功率分配的动态调整与精细化控制，旨在达成风机低疲劳、高效率的运行目标。




图 1-1 自动发电控制系统（AGC）运行流程图

1.2 问题重述

随着我国大规模风电场的投入使用，风电产业面临着疲劳损伤加速和维护成本增加的挑战。本文针对风机关键部件疲劳损伤实时监测、受力估算以及有功功率优化调度搭建适应性模型进行求解，提高了系统的运行效率和安全性。

针对问题一：在复杂、随机载荷条件下，实时计算风机主轴和塔架的累积疲劳损伤具有**低复杂度高实时性**要求。为此，本文设计了自适应动态三阶段滑动窗口算法，运用 **AB 对抗**实现了窗口等参数快速高效搜索，通过改进的雨流计数模型计算各窗口实时疲劳损失值，通过**并行计算**减少了模型运行时间，所建立的模型不仅降低了模型的计算复杂度，同时与参考值有较低的误差。通过在 Python 中编程，实现了在 1 秒内准确计算累积疲劳损伤的目标，解决了实时监测的技术难题。

针对问题二：针对传统受力分析方法在风速波动条件下难以准确估算受力，且风机主轴扭矩和塔架推力与风速和功率之间的复杂性。本文提出了基于**物理理论与数据驱动**相结合的非线性回归模型。模型引入**非线性项和交互项**，**提出三种分段拟合策略，同时运用网格搜索**的方法，快速高效的捕捉了风速、功率、状态与风机结构受力之间的复杂非线性关系。在 Python 环境中编程，实现了在风速波动和复杂工况下对主轴扭矩和塔架推力的准确实时估算。

针对问题三：风电场有功功率分配优化调度面临**高维度、多目标、实时性**要求。传统有功平均分配满足降低成本要求，本文运用了 Pareto 前沿分析和模型预测控制（MPC）理论，根据风速波动特征对风电场进行区域划分，构建了 **Pareto 权重自适应的 MPC 优化模型**。该模型将多目标之间进行权衡，分区域**调整权重**，实现了每秒实时求解高维优化问题。

针对问题四：在实际运行中，通信延迟和测量噪声对有功功率优化带来了新的挑战，导致系统不稳定和优化效果下降。本问为提高模型的鲁棒性和稳定性，引入了**鲁棒优化方法**，结合**卡尔曼滤波器**进行噪声处理，设计了**延迟补偿机制**，建立了基于问题三的**全局协调的分区域 MPC 鲁棒优化模型**，并建立对比模型，即**基于粒子群算法的鲁棒优化模型**。通过对比分析了**基于粒子群算法的鲁棒优化模型**在有功功率分配中效果最好，同时也减少了各元件疲劳损伤。同时与无优化模型对比，验证了所提出的优化策略在实际环境中的有效性，成功应对了通信延迟和测量噪声带来的挑战。

1.3 研究路线

本研究围绕**风电场风机疲劳损伤控制与有功功率优化分配**与展开，旨在通过构建和应
用实时性估计模型和优化策略，降低风机运行过程中的疲劳损伤，延长其可用寿命、提高
成本效益。全文的研究思路如图 1-1 所示。




图 1-1 全文求解思路图

2 理论基础

2.1 疲劳寿命

疲劳寿命是指材料在经历反复的应力或应变循环作用下，能够承受的最大循环次数，直到发生疲劳破坏（例如裂纹形成或断裂），它是衡量材料抗疲劳性能的一个关键指标。

当材料长时间受到反复载荷（如周期性应力或应变）时，即使这些载荷低于材料的屈服强度，它们也会逐渐积累损伤，最终导致材料失效。这个过程被称为**疲劳**，而导致失效所需的循环次数则称为**疲劳寿命**。

疲劳寿命通常通过 **S-N 曲线** 来表征。S-N 曲线（应力-寿命曲线）是一种实验得出的关系图，横轴表示载荷循环次数（ N ），纵轴表示应力幅值（ S ）。S-N 曲线表明应力幅值越大，材料的疲劳寿命越短。

$$N \propto \left(\frac{1}{S}\right)^m \quad (2-1)$$

其中， N 为疲劳寿命， S 为应力幅值， m 为材料的经验常数。

2.2 S-N 曲线

S-N 曲线（应力-寿命曲线，Stress-Number of cycles curve）是用于描述材料在疲劳载荷下的抗疲劳性能的曲线。它是通过实验得出的材料在不同应力幅值下，经历的载荷循环次数（ N ）与应力幅值（ S ）之间的关系。

S-N 曲线通常可以用以下经验公式来描述：

$$S = \frac{C}{N^m} \quad (2-2)$$

其中， S 表示应力幅值，即材料在每个载荷循环中所承受的应力大小； N 表示材料在特定应力幅值下能够承受的载荷循环次数，直到发生疲劳失效（如裂纹或断裂）。

2.3 Palmgren-Miner 线性累积损伤理论

Palmgren-Miner 线性累积损伤理论是用于计算材料在疲劳载荷作用下的累积损伤程度的经典理论。该理论提出：材料在经历不同应力循环后所产生的总疲劳损伤是这些应力循环损伤的线性叠加，当总损伤累积到 1 时，材料将会发生失效。

Palmgren-Miner 线性累积损伤理论认为，不同应力幅值下的疲劳损伤是独立的，每一次应力循环都会对材料的疲劳寿命产生一定的影响。材料的损伤程度可以通过累加这些独立损伤的总和来评估。

假设在某一应力幅值 F 下，材料的能够承受应力的循环次数极限为 N_F 次（ N_F 通过 S-N 曲线法获取）。实际已经经历了 n_F 次应力循环（根据定义人工计数），则其累积疲劳损伤值 D_F 可以表示为：

$$D_F = \frac{n_F}{N_F} \quad (2-3)$$

总损伤累积值 D 为各个应力水平（ $F_1, F_2, \dots, F_n$ ）下的累积损伤值之和：

$$D = D_{F_1} + D_{F_2} + \dots + D_{F_n}。 \quad (2-4)$$

2.4 能量守恒原理

能量守恒原理是物理学中的基本定律之一，指的是在一个孤立系统中，能量的总量是恒定的，既不会被创造，也不会被毁灭，而是可以从一种形式转化为另一种形式。

总能量不变：在没有外部作用力的情况下，系统的总能量始终保持不变。比如，一个风机在运行时，风能转化为电能，但风能的减少与电能的增加是相等的。

能量转化：能量可以在不同形式之间转化，例如动能、势能、热能和电能等。例如，风能转化为机械能（转动风轮），再转化为电能（发电）。

在风力发电中，风的动能被风机捕捉，转化为机械能，再转化为电能。整个过程遵循能量守恒的原则，即风能的减少等于风机所产生电能的增加。

能量守恒可以用以下等式表示：

$$E_{\text{总}} = E_{\text{动}} + E_{\text{势}} + E_{\text{其它}} = \text{常数} \quad (2-5)$$

其中， $E_{\text{总}}$ 是系统的总能量， $E_{\text{动}}$ 是动能， $E_{\text{势}}$ 是势能， $E_{\text{其它}}$ 是其他形式的能量（如热能）。

通过这个原理，后续在建模风机的推力和扭矩时，考虑风能、机械能和电能之间的转化关系。

3 模型假设与符号说明

3.1 模型假设

假设 1：所有风机主轴和塔架的初始疲劳损伤值为零，后续累积疲劳损伤计算只考虑当前时段的数据，不需要追溯之前的损伤积累。

假设 2：风机所承受的塔架推力和主轴扭矩是风速与功率之间非线性关系的结果，且风速超过额定风速（11.2m/s）时，风机不能完全吸收多余风能，这些能量会转化为对风机的额外机械应力。

假设 3：风电场内的所有风机具有相同的机械和结构特性，因此它们的塔架推力和主轴扭矩在相同条件下呈现相同的响应，区别仅在于风速和功率参考值。

假设 4：通过能量守恒的原则建立应力/扭矩的估算模型，多余的风能根据当前风速和功率参考值会作用于风机结构，形成主轴扭矩和塔架推力。

假设 5：各风机传感器测量的风速和功率数据存在 10%以内的测量噪声，噪声被认为是随机且不可消除的，需要通过模型处理来消减其影响。

假设 6：在存在通信延迟的情况下，模型可以基于历史数据或上一时刻的数据进行功率分配，并通过预测或时滞补偿技术来减小延迟对优化结果的影响。

3.2 符号说明

表 3-1 符号说明

符号	说明
P_t	电网调度指令
P_{ref}^i	第 i 台风机调度功率
W_t	风机数量
L_N	等效疲劳载荷
N_F	最大循环载荷次数
S	应力幅值
D_F	累计疲劳损伤值
D	总损伤累计值
T_s^i	风机轴系扭矩
F_t^i	风机塔顶推力
V_w^i	风机轮毂处等效风速
V	风速

4 问题一 风机主轴及塔架疲劳损伤程度量化指标计算低复杂度模型

4.1 问题分析

风机主轴和塔架是风电机组的核心结构部件，长期受到复杂载荷（如风速变化、气流不稳定等）的反复作用。随着时间推移，这些载荷会在材料中积累疲劳损伤，最终可能导致部件失效。因此，风机在长期运行中必须进行疲劳损伤监测，以评估其寿命和维护需求。

传统的疲劳损伤计算方法主要依赖于雨流计数法，但由于风机的**载荷数据通常表现出较强的随机性和不规则的周期性**，使得波峰和波谷难以识别，传统方法在实时计算中效率较低。同时，由于**载荷循环的周期较长，远远超过 1 秒的实时计算间隔**，现有方法无法实时计算累积疲劳损伤。

因此，问题一需要构建一个**计算复杂度较低且适合实时应用的疲劳损伤模型**，能够在不超过 1 秒的计算时间内，实时计算风机主轴和塔架的累积疲劳损伤。为了解决风机主轴和塔架疲劳损伤的实时计算问题，我们选择了**滑动窗口算法**作为核心方法设计**自适应动态三阶段滑动窗口算法**。滑动窗口算法的主要优势在于能够在处理随机且不规则的载荷数据时，将计算过程局部分割，从而降低计算复杂度并提高实时性。在这种算法中，我们将应

力时间序列划分为多个小窗口，每个窗口基于**改进的雨流实时计数模型**处理局部的应力数据，并逐步移动窗口，覆盖整个数据序列。通过这种方式，滑动窗口不仅能够捕捉载荷的局部变化，还能避免全局数据处理的高复杂度，适合实时计算场景。

通过使用滑动窗口算法，确保每秒内的计算时间小于 1 秒，满足实时性需求。同时对累积疲劳损伤评估，计算结果应能正确反映元件的累积疲劳损伤，并与**基于雨流计数法的参考结果进行对比**，验证其合理性。

4.2 求解思路图

本题的模型构建思路如图所示。




图 4-1 问题一求解思路图

4.3 模型建立

该模型为解决应力循环周期较长超过实时计算时间间隔（1 秒）难题，本文设计**自适应动态三阶段滑动窗口方法**。算法通过滑动窗口将长数据流分段处理，在每个窗口内逐步捕捉应力变化，并实时计算当前分段内的疲劳损伤。随着滑动窗口在时间序列上移动，算法能够累积多个小段内的损伤值，最终实现对整个应力循环的累积疲劳评估。针对**应力数**

据随机性强且波峰波谷不易辨识、随机性强等特征，模型应用改进式雨流实时计数模型。该模型能够在每个分段内自动识别出应力循环的峰谷值，解决了复杂应力数据中波峰波谷难以手动辨识的问题。通过结合 S-N 曲线和 Miner 疲劳累积准则计算每个循环的损伤贡献，模型能够准确捕捉应力循环的疲劳效应。最终，计算疲劳损伤增长趋势，并展示了代表性样本的累积损伤过程，确保实时性和计算效率。

4.3.1 自适应动态三阶段滑动窗口算法

在风机载荷数据分析中，我们面临数据量大、随机性强且对疲劳损伤评估精度要求高的挑战。针对时段载荷，直接应用雨流计数方法，其能够准确识别载荷循环，但其计算复杂度相对较高计算资源的消耗和时间成本均会显著增加，使得雨流计数在实际应用中面临效率瓶颈。另一方面，傅里叶变换作为频域分析的经典工具，对于揭示周期性或准周期性信号的内在规律具有独特优势。然而，风机载荷数据往往呈现出高度的随机性和非平稳性，这使得傅里叶变换在捕捉载荷数据的动态变化特征时，难以准确评估载荷循环对疲劳损伤的贡献。

相比之下，基于窗口滑动技术设计自适应动态三阶段滑动窗口算法，因其分段处理数据的能力、计算复杂度的降低以及对数据动态变化特征的捕捉，成为更优选择。它通过设置固定大小的初始窗口，并动态地滑动这些窗口来捕捉和分析数据的特征。算法的核心在于通过计算窗口之间的差值，并与设定的阈值进行比较，以判断数据是否在一个应力循环中，并据此决定是否舍弃某段数据或进行分段处理。在风机载荷数据分析的情境中，该算法能够精细地揭示每个时间段内载荷的变化规律及其对疲劳损伤的潜在影响。

(1) 算法流程

Step1: 初始窗口确定

滑动初始窗口确定，采用 AB 对抗法（Argumentative Backfire Effect）的思想进行优化。首先，设定基准窗口大小，如 20 个数据点。这个窗口大小将作为我们后续对比和验证的基准。按照基准窗口大小，我们将数据集从开始位置分割成多个窗口。进而，对每个窗口内的载荷数据进行特征值计算，以反映该窗口内数据的整体情况。

为构造“对抗”场景，我们通过调整窗口大小（如增加或减少几个数据点），形成不同的窗口划分方案。这些方案将与基准窗口进行对比。计算不同窗口划分方案下，每个窗口内载荷数据的特征值，并与基准窗口的特征值进行详细的对比和分析。根据特征值的稳定性和代表性，我们选择最优的窗口大小作为初始窗口。优化后得到最优窗口大小为 14，该窗口大小应该能够较好地覆盖数据集中的信息，并且具有较好的计算效率。具体流程见下图：




图 4-2 AB 对抗法思想优化初始窗口确定流程

Step2: 窗口内的累计损伤与差值计算

通过优化确定初始窗口大小为 14, 即 W1, 算法将窗口向右滑动一个步长(步长 S=1), 设置第二个窗口 W2。进一步, 计算两个相邻窗口(实际上是重叠的窗口, 即 W1 和 W3 中共同的部分 W2 与其后一个数据点 15)间特征值的差值。这里需要注意的是, 算法实际上是在比较窗口滑动前后, 窗口内数据累计损伤值的变化。

基于每个窗口内载荷-时间历程应用雨流计数法, 将其转化为系列的应力循环 $\{\sigma_1, \sigma_2$

$$W1 = \{x_1, x_2, \dots, x_{14}\} \quad (4-1)$$

$$W2 = \{x_2, x_3, \dots, x_{14}\} \quad (4-2)$$

$$W3 = \{x_2, x_3, \dots, x_{15}\} \quad (4-3)$$

, ..., σ_n 。计算循环的损伤。进一步, 根据 S-N 曲线和线性累积损伤理论, 计算每个循环造成的损伤。最后, 将窗口内所有循环造成的损伤进行累加, 得到该窗口内的累计损伤。

$$D_{total} = \sum_{i=1}^n D_{Fi} \quad (4-4)$$

Step3: 损伤差异与阈值比较

得到三个窗口间损伤差异与设定的阈值 T 进行比较。通过计算每个窗口内的累计损伤, 可以对不同窗口(即不同时间段)的疲劳损伤进行比较, 损伤差异值即为差点疲劳损伤。如果发现某个窗口的累计损伤显著大于其他窗口, 那么该窗口可能包含了导致疲劳损伤的主要载荷循环。

$$\Delta 1 = D_{total}(W1) - D_{total}(W2) > T \quad (4-5)$$

$$\Delta 2 = D_{total}(W3) - D_{total}(W2) > T \quad (4-6)$$




图 4-3 自适应动态三阶段窗口滑动示意图

Step4: 差异点定位

在比较过程中，如果发现相邻窗口的累计损伤存在显著差异，且这种差异超过了设定的阈值，那么可以认为在这两个窗口之间存在一个错开位置，可进行数据分段。这个错开位置即是导致疲劳损伤突然增加或减少的关键点。

Step5: 数据分段

最后，根据错开位置前后的累计损伤变化情况，可以评估该位置对疲劳损伤的影响程度。如果错开位置前后的累计损伤差异较大，且这种差异与风机的实际运行情况相符（如载荷突然增加、运行环境恶化等），那么可以认为该错开位置是导致疲劳损伤增加的主要原因。

Step6: 子段每秒损伤计算

进行判断，若 $\Delta i < T$ 、 $\Delta i + 1 > T$ 时，舍弃 x_1 从 x_{21} 处进行数据分段处理，即 $\{x_2, x_3, \dots, x_{21}\}$ ，在子段中通过滑动窗口差值计算每秒损伤差异。其中 $W_{current}$ 和 $W_{current}$ 分别是当前和前一个滑动窗口。具体操作见图：

$$\Delta D_{per_second} = D_{total}(W_{current}) - D_{total}(W_{current}) \quad (4-7)$$




图 4-4 字段分割每秒损伤求解示意图

Step7: 尾部受限数据逆向滑动求解

在滑动窗口法处理数据序列的过程中，序列末尾的部分数据由于窗口大小限制可能无法形成完整的应力循环。为解决这一问题，尾部数据可通过逆向滑动的方式进行求解。当滑动窗口到达数据末尾时，从最后一个数据点开始反向滑动，按照原有的应力循环识别规则重新进行分析。这样可以确保所有数据点都被充分处理，避免遗漏任何有效的疲劳循环，最终提升疲劳寿命预测的准确性和完整性。

4.3.2 疲劳损伤模型

(1) 雨流计数法选择

雨流计数法是一种基于时间历程数据的计数方法，后续将从三点式雨流计数法与改进的雨流实时计数模型展开，雨流计数法将应变随时间变化的曲线旋转 90 度，形成一个在坐标系中沿时间轴向下的雨流图，并根据雨流图的形状、频率和大小等特征进行统计和分析，雨流计数法整体技术规则如图 4- 所示。




图 4--5 雨流计数法示意图

三点式雨流计数法是一种常用于疲劳分析的简化雨流计数方法，它通过识别应力（或应变）时间序列中的峰值和谷值来确定应力循环。与传统雨流计数法相比，三点式方法简化了数据处理过程，但仍能准确捕捉疲劳循环。

三点式雨流计数法的核心思想是基于**应力时间序列**中的三个连续点（如峰值、谷值和下一个峰值），通过判断它们的相对大小来识别完整的应力循环。

具体步骤如下：

Step1 载荷数据预处理：

对原始的载荷-时间序列进行预处理，提取应力时间序列中的峰值和谷值。在预处理后的序列中，选择三个连续的点 S_1, S_2, S_3 ，其中：

- S_1 是前一个峰值或谷值；
- S_2 是当前的谷值或峰值；
- S_3 是下一个峰值或谷值。

Step2 应力循环识别：

计算两段应力变化量，

$$\Delta S_1 = |S_1 - S_2| \quad (4-8)$$

$$\Delta S_2 = |S_2 - S_3| \quad (4-9)$$

循环判断规则：当 $\Delta S_1 \leq \Delta S_2$ 时，认为 S_1 和 S_2 之间构成一个有效循环，进行计数。否则，不识别为有效循环，继续分析下一组点。

Step3 迭代处理：

每次成功识别并移除一个循环后，重新连接剩余的应力点，形成新的连续序列，继续对下一个三点组进行循环识别和计数，直到处理完整个序列中的所有有效点。




图 4-6 三点式雨流计数法流程图

改进的雨流实时计数模型相比传统方法,具实时性、内存优化、优化峰谷识别等优势。首先,它能够实时处理复杂的应力数据,动态识别疲劳循环,从而提升数据处理的效率,特别适用于长时间、连续监控的工业场景。其次,通过引入滑动窗口和阈值动态调整机制,该模型不仅能够准确捕捉不同幅值的应力循环,还能有效减少内存消耗和计算开销。同时,模型优化了峰谷识别算法,提升了应力循环识别的精度,保证疲劳寿命预测的准确性。具体算法流程见下:

Step1 载荷数据预处理:

对原始的载荷-时间序列进行预处理,提取应力时间序列中的峰值和谷值。在预处理后的序列中,选择三个连续的点 S_1, S_2, S_3 , 其中:

S_1 是前一个峰值或谷值;

S_2 是当前的谷值或峰值;

S_3 是下一个峰值或谷值。

Step2 应力循环识别:

计算两段应力变化量,

$$\Delta S_1 = |S_1 - S_2| \quad (4-10)$$

$$\Delta S_2 = |S_2 - S_3| \quad (4-11)$$

改进后的循环判断规则是基于应力幅值和实际的应力水平，并结合阈值 t 来判断是否构成有效应力循环。循环识别规则为：

循环判断规则：当 $\Delta S_1 \leq \Delta S_2$ 且 $\Delta S_2 \geq t$ ，则认为 S_1 和 S_2 之间构成一个有效循环，在改进的模型中，阈值 t 可以动态调整，以适应不同应力幅值的变化。

Step3 疲劳损伤累积：

对于每一个有效识别的应力循环，使用 Miner 法则累积疲劳损伤。根据雨流计数法中的循环幅值，计算疲劳损伤：

$$D = \sum_{j=1}^n \frac{1}{N_j(S_j)} \tag{4-12}$$

其中， $N_j(S_j)$ 是应力幅值 S_j 对应的疲劳寿命， n 是识别出的应力循环数量。通过这种方法可以逐步累积疲劳损伤，进而预测材料的疲劳寿命。

Step4 实时数据更新与内存优化：

与传统的三点式方法不同，改进的雨流实时计数模型通过每次输入新的数据点时，更新应力序列。内部滑动窗口机制，用于实时检测和更新峰谷点。

滑动窗口大小为 W ，每次输入新的应力数据 S_{new} ，计算当前窗口内的局部极值，实时更新并判别有效循环，节省内存，并且实时处理数据流。

Step5 迭代处理与循环识别：

每次成功识别并移除一个应力循环后，将剩余的应力点重新连接，生成新的应力序列。对新的序列继续应用步骤 2 和 3 进行疲劳循环识别和损伤累积，直到处理完整个数据序列。将剩余应力点连接进行循环识别，每次迭代计算后，自动更新应力序列，并进行下一个循环的判定。迭代公式见下：

$$S_{rem} = S_{j+k} \tag{4-13}$$

表 4-1 雨流计数法属性对比

属性	三点式雨流计数法	改进的实时雨流计数模型
数据处理方式	静态输入，序列整体处理	实时输入，逐步处理
应力循环识别	固定的三点式方法	基于实时滑动窗口 动态识别应力循环
阈值调整	使用固定阈值，不能调整	动态阈值，根据实时数据调整
存储与计算优化	需要完整保存序列数据	采用滑动窗口和 动态内存优化，减少存储需求
尾部数据处理	未特别处理尾部数据	通过逆向滑动窗口 处理尾部数据，避免遗漏
疲劳损伤累积	处理结束后累积疲劳损伤计算	实时累积疲劳损伤， 识别到循环即更新

基础的 S-N 曲线假设材料在平均载荷为 0 的情况下进行疲劳分析。但当平均载荷不为 0 时，需要对 S-N 曲线进行修正，通常使用 Goodman 修正。

Goodman 修正公式表示为：

其中， S_{ai} 是第 i 个循环的修正后幅值； S_i 是等效均值为 0 使得载荷幅值； S_{mi} 是第 i 个循

$$\frac{1}{S_{ai}} = \frac{1}{S_i} + \frac{S_{mi}}{\sigma_b} \quad (4-14)$$

环的均值； σ_b 为材料的极限拉伸强度（本题设为 50000000）。

（2）累积疲劳损伤评价指标构建

指标 1：等效疲劳载荷

$$L_N = \sqrt[m]{\frac{\sum L_i^m n_i}{N}} \quad (4-15)$$

其中， L_i 是经过 Goodman 修正的各级载荷幅值； n_i 为该级载荷的循环次数； m 为 S-N 曲线的 Wohler 指数（本题取 10）； N 取决于风电风机设计寿命（本题设为 42565440.4361）， L_N 为等效疲劳载荷。

指标 2：累计疲劳损伤值

使用 Palmgren-Miner 线性累积损伤理论，将所有疲劳循环的损伤累积起来。根据幂函数形式的 S-N 曲线：

$$S^m \times N = C \quad (4-16)$$

其中， S 为各个载荷幅值， N 为对应载荷的最大循环载荷次数， m 为 Wohler 指数（本题设为 10）， C 为常数（本题设为 9.77×10^{70} ）

累计损伤公式为：

$$D_F = \frac{n_F}{N_F} \quad (4-17)$$

其中， n_F 为实际的循环次数； N_F 为该幅值下的最大循环次数。
最终的累计疲劳损伤值通过所有疲劳循环的损伤累积求和。

4.4 算法求解与结果分析

4.4.1 算法求解

首先，基于自适应动态滑三阶段动窗口算法对塔架推力和扭矩数据进行分段处理。由于风机载荷数据存在随机性和不规则的周期特征，通过三阶段滑动窗口分析窗口内疲劳损伤差值，判断错位点进而对整段数据分割子段。窗口调整确保了应力循环在实时处理过程中被完整捕捉，并能适应数据变化的复杂性与不确定性，符合实时处理的要求。下图示例为 WT1、WT2、WT3、WT4、WT5 分段处理并行计算子段示例：




图 4-7 部分并行计算子段示例图

分段后的数据将被实时输入改进的雨流计数模型，进行**应力循环的识别与累积疲劳损伤的计算**。每个子段内的应力循环通过雨流计数法计算，其核心是捕捉应力幅值和计算疲劳损伤。模型通过结合 S-N 曲线（应力-寿命曲线），来判断每个应力幅值对材料疲劳寿命的影响。疲劳损伤的累积采用 Miner 疲劳累积准则，即在识别出有效的应力循环后，计算该循环对元件累积疲劳的贡献。每个子段的累积疲劳损伤值会实时更新，保证每秒的疲劳损伤计算能够反映当前的实际情况，达到实时累积的效果。具体操作时，模型通过计算每个应力循环对应的幅值与寿命关系，不断将疲劳损伤累加到总量中。

滑动窗口处理接近数据序列末端时，窗口大小可能不足以完全包含最后的应力循环数据，导致部分应力信息遗漏。为解决这个问题，模型采用**逆向滑动窗口技术**处理尾部数据。实际操作中，当滑动窗口到达数据序列末端时，模型会从最后一个数据点开始逆向滑动，并识别剩余数据中的应力循环。这种逆向滑动能够确保所有应力点都被充分分析，避免因窗口大小限制导致的数据遗漏。尾部数据的处理可以确保整个数据序列中每一个应力循环都能被完整识别，使得疲劳损伤计算结果更加准确。在实际求解过程中，通过**多线程或并行计算**将处理任务分配，以加速数据的处理和应力循环的识别。

4.4.2 结果分析

（1）计算结果与参考结果相似对比

基于所有 100 台风机的全部 200 件元件在 100s 时长时累计疲劳损伤值以及等效疲劳载荷。展示所计算结果与数据中提供的雨流计数法所得结果（即参考值）的相似程度，进而反应累积疲劳损伤程度增长情。分别对参考主轴扭矩累计疲劳损伤增长趋势，基于模型求解主轴扭矩累计疲劳损伤增长趋势对比；参考塔架推力累计疲劳损伤增长趋势，基于模型求解塔基累计疲劳损伤增长趋势对比；参考主轴扭矩累计等效疲劳载荷增长趋势，基于模型求解主轴扭矩等效疲劳载荷增长趋势对比；参考塔架推力等效疲劳载荷增长趋势，基于模型求解架推力等效疲劳载荷增长趋势对比。绘制折线图进行对比分析，具体见图：




图 4-8 主轴扭矩累计疲劳损伤对比图




图 4-9 塔架推力累计疲劳损伤对比图

对于主轴扭矩，参考值在 80 秒左右有显著增长，模型较好地捕捉到了这一变化，表明模型能够**准确处理应力波动**。而塔架推力的损伤增长表现出多次波动，尤其在前 40 秒和后 80 秒，模型与参考值一致，说明其对复杂应力变化的处理能力较强。




图 4-10 主轴扭矩累计等效疲劳载荷对比图




图 4-11 塔架推力等效疲劳载荷对比图

等效疲劳载荷的趋势同样显示了**多次波动**，特别是在主轴和塔架的载荷变化中，模型准确反映了**多个应力峰值**。整体而言，模型在多种元件和应力环境下的适用性和可靠性得到了验证，为风机元件的疲劳预测和维护提供了有效的支持。

(2) 元件累积疲劳损伤程度的增长过程

本文选取元件 WT1、WT20、WT31、WT51、WT82、WT87、展示从 0-100s 内累积疲劳损伤程度的增长过程。该样本集具有以下特性：**涵盖了多样的疲劳损伤表现**，既包括累积疲劳损伤增长较快的元件，也包括增长较为平缓的元件，从而展示了模型对不同损伤模式的处理能力。样本**来自不同的位置和结构**（如主轴和塔架），代表了风机不同部分的受力情况，证明了模型在多种结构和应力条件下的准确性。最后，样本覆盖了 100 台风机的典型**数据范围**，确保能够反映整体的运行状态，验证模型的广泛适用性和可靠性。样本原件 0-100s 内累积疲劳损伤程度的增长过程，具体见下图：




图 4-12 代表性原件累积疲劳损伤程度的增长图

WT1 组件在初期的累积疲劳损伤增长速度较快，并在 40 秒后趋于平稳，表明其在测试开始时承受了较大的应力，随后逐步趋于稳定。相比之下，WT20 组件的损伤增长则更加线性和平稳，表现出较为一致的应力分布，表明其在整个时间段内的应力负载较为均匀。同样的，WT31 和 WT87 组件的累积疲劳损伤也呈现出线性增长的趋势，说明它们在整个测试过程中受力变化较小，表现较为稳定。而 WT51 组件则表现出与 WT1 类似的特征，初期增长较快，后期逐渐稳定，这暗示其初期受到了较大应力的影响。

值得注意的是，WT82 组件的累积疲劳损伤增长最为缓慢，显示其受力较小突显了不同结构元件在相同时间段内所承受应力的差异，以及模型在处理这些复杂情况时的有效性。

通过这些元件的代表性数据，可以验证模型在多种风机结构和运行条件下的广泛适用性和可靠性。这些样本元件来源于不同的位置和结构（如主轴、塔架等），不仅证明了模型在多样化应力条件下的准确性，还确保了其在广泛应用场景中的稳定性和鲁棒性。

(3) 模型评估

在模型结果评估过程中，我们使用了均方误差（Mean Squared Error, MSE）、均方根误差（Root Mean Squared Error, RMSE）和 R²决定系数（Coefficient of Determination）三个指标来评估模型的预测性能。

表 4-2 评估结果对比表

	主轴扭矩		塔架推力	
	累计疲劳损伤	等效疲劳载荷	累计疲劳损伤	等效疲劳载荷
均方误差 (MSE)	5. 8700930467e-24	57. 36070086	1. 547601436e-28	43. 83594866
均方根误差 (RMSE)	2. 422065114e-12	7. 21542696845	1. 2440266575e-14	64. 3326614825
决定系数 R ²	0. 7286890278	0. 89176776185	0. 761349184931921	0. 87163705773

模型在主轴扭矩和塔架推力的累计疲劳损伤和等效疲劳载荷的计算中表现出较好的拟合效果。对于主轴扭矩的累计疲劳损伤，虽然存在一些误差（MSE 为 5.87e-24），但 R²达到 0.73，表明模型对数据变异的解释能力较强。在等效疲劳载荷预测方面，主轴扭矩和塔架推力的 R²分别为 0.89 和 0.87，表明模型能够很好地拟合数据，大部分变异被有效解释。尽管塔架推力的预测误差稍大（RMSE 为 64.33），但总体上，模型在捕捉疲劳损伤和载荷变化趋势方面表现出较高的准确性和可靠性，能够为后续的分析 and 决策提供有效支持。

部分主轴扭矩和塔架推力的 100s 累计疲劳损伤和等效疲劳载荷的计算时间表见下：

表 4-3 随机选取原件疲劳指标计算时间表

主轴	疲劳指标计算时（s）	塔架	疲劳指标计算时间（s）
WT15	0. 260563609	WT21	0. 339158124
WT23	0. 306519438	WT29	0. 374510416
WT36	0. 369270961	WT39	0. 373174561
WT45	0. 270368517	WT47	0. 296160745
WT58	0. 363287947	WT50	0. 206606644
WT62	0. 307202387	WT72	0. 262176339
WT79	0. 338077226	WT92	0. 296928743

5 问题二 利用风速及功率估算塔架推力和主轴扭矩

5.1 问题分析

本问题的核心在于通过建立**基于风速和功率参考值的实时计算模型**，精确估算风机**主轴的扭矩和塔架的推力**，从而实现累积疲劳损伤的动态监测和估算。风机的负载复杂且随机，且周期特征不标准，传统的受力分析难以在风速波动较大时提供准确的扭矩和推力估算。为了实现这一目标，本题提出了一种**基于物理理论和数据驱动相结合的非线性回归模型**。通过该模型能够有效分析风速、功率与风机结构受力之间的**非线性关系**，进而实时估算塔架推力和主轴扭矩。该**数据驱动**模型通过**多参数组合输入多策略分段拟合**进而提高风机主轴的扭矩和塔架的推力估算精度，能够适应风速波动和复杂工况下的受力变化，进而准确调控有效降低原件累积疲劳损伤。

5.2 求解思路图




图 5-1 问题二求解思路图

5.3 模型建立

本模型旨在根据风机的风速条件和功率参考值，准确估算塔架推力和主轴扭矩。模型的难点在于**多变量的复杂性、风速与桨距角等变量的非线性物理关系**，以及数据量有限的情况下如何确保模型的物理合理性与准确性。模型首先进行了数据预处理和相关性分析，以确定**关键变量**；随后基于物理约束建立了功率输出、主轴扭矩和塔架推力的**多输入多输出模型**，并采用**分段拟合策略**应对风速区间最终实现了在有限数据条件下的高效计算，保证了结果的物理合理性和实际应用价值。

5.3.1 数据预处理

在数据处理过程中，首先进行数据清洗，检查数据集是否存在缺失值，并使用适当的方法进行处理（如删除、插值或均值填补）进一步，识别并处理异常值，这些异常值可能来自极端风速或功率数据，使用 IQR 来检测并处理这些异常数据点。通过箱线图来可视化输入与输出变量的分布情况，以便快速识别异常值和数据分布，如下图所示。




图 5-2 风机输入与输出变量箱线图

接下来，为了估算和比较各风机在任意时刻的应力/扭矩值，我们基于附件 2 所提供的数据进行了进一步处理。附件 2 包含两个风电场（WF1 和 WF2）的数据，每个风电场包括 100 台风机，记录了 2000 秒的数据。为便于模型构建和计算，我们选取了 WF1 风电场的 100 台风机，在最后 100 秒的数据中进行分析与估算。通过截取这一时间段，我们能够计算各风机在特定时刻（例如第 100 秒）的应力/扭矩值，并通过统计估算值与参照值之间的误差平方和，展示模型计算结果与实际数据的对比情况，从而验证模型的准确性。

5.3.2 相关性分析

根据附件 2 中的数据，每台风机的数据集包括了时间（time），输入（inputs），输出（outputs）和状态（states）。输入包括该风机的功率调度指令（ P_{ref}^i ）与输入风速大小（ V_w^i ）；

输出包括主轴扭矩(T_{shaft})、塔架推力(F_t)以及风机实际输出功率(P_{out})；状态包括桨距角(pitch angle)、低速轴转速(ω_r)、高速轴转速(ω_f)。

在对风电场数据进行建模之前，相关性分析有助于揭示输入变量、状态变量与输出变量之间的关系，从而为后续模型的构建提供依据。通过对各变量的相关性进行评估，我们可以识别出高度相关的变量，分析其内在联系，并确定那些对模型贡献较大的变量。此外，负相关性和无明显相关性的变量也可以帮助我们了解系统的反向影响和不显著的关系。以下是各主要变量之间的相关性分析结果。




图 5-3 相关性检验热力图

首先，Output1（主轴扭矩）和 Output3（风机实际输出功率）之间的相关性非常高，相关系数接近 0.97。这表明这两个输出变量之间存在高度的线性关系，推测它们的变化趋势非常相似。根据能量守恒定律，风机的输出功率与主轴扭矩通过以下公式联系起来：

$$P_{out} = T_{shaft} \cdot \omega_r \quad (5-1)$$

其中， P_{out} 是风机的实际输出功率， T_{shaft} 是主轴扭矩， ω_r 是低速轴转速。主轴扭矩与风机的实际输出功率通常由相同的物理机制驱动，因此这种高相关性反映了它们共享共同的影响因素，如风机转速、风速等。

其次，Input2（风速）与 Output2（塔架推力）的相关性为 0.63，显示了较强的正相关性。这一结果符合风力发电的基本物理规律，风速是影响风机功率输出和推力的重要因素，风速与推力的关系可以通过以下公式表示：

$$F_t = 0.5 \cdot \rho \cdot A \cdot C_t \cdot V_\omega^2 \quad (5-2)$$

其中， F_t 是塔架推力， ρ 是空气密度， A 是风轮的扫掠面积， C_t 是推力系数。风速越大，风机受到的空气动能越多，塔架推力也随之增加。这种相关性说明了风速和塔架推力之间存在显著的关联性，表明风速对风机的结构应力有重要影响。

状态变量之间的相关性同样值得注意。State1（桨距角）和 State3（高速轴转速）之间的相关性为 0.75，而 State2（低速轴转速）与 State3 之间的相关性则更高，达到 0.87。这表明这些状态变量之间存在较强的关联性，可能是由于它们在风机运行中受相同的内部

控制系统或外部环境因素影响。例如，桨距角的变化可能会影响风机的转速控制，进而影响低速轴和高速轴的转速，具体公式为：

$$C_p = C_{p0} - \alpha \cdot \theta \quad (5-3)$$

其中， C_p 是功率系数， θ 是桨距角， α 是修正系数。功率系数的变化会进一步影响低速轴和高速轴的转速，通过这些状态变量之间的关联性分析，我们可以更好地理解风机各子系统之间的协同作用。

然而，并不是所有变量之间都存在显著的相关性。**Input1（功率调度指令）与其他变量的相关性较低，几乎接近于零**。这意味着在当前的数据集中，功率调度指令对风机的输出功率和状态变量影响不大。功率调度指令可以表示为目标功率 P_{ref} ，而风机的实际输出功率 P_{out} 受其他变量的影响，如风速、转速和桨距角。以下是功率输出的一般公式：

$$P_{out} = 0.5 \cdot \rho \cdot A \cdot C_p \cdot V_\omega^3 \quad (5-4)$$

因此，在特定条件下，风速和桨距角等外部因素对功率的影响可能超过功率调度指令的作用。

此外，**State2（低速轴转速）与 Output1 和 Output2 的相关性较低**，表明低速轴转速与输出功率和塔架推力之间的关系不显著。低速轴转速的变化通过影响主轴扭矩来间接影响输出功率，但其效果可能受其他因素的制约，如风速和桨距角的调整。

最后，某些变量之间的**负相关性**同样具有解释意义。以**State1（桨距角）与 Output1（主轴扭矩）之间的负相关性（-0.29）**为例，随着桨距角的增大，主轴扭矩反而会减小。这种现象可以通过风机的运行控制机制来解释：当风速增大时，风机通过增大桨距角来减少风轮吸收的风能，从而降低主轴上的负载和扭矩，具体的关系式为：

$$T_{shaft} = \frac{P_{out}}{\omega_r} \quad (5-5)$$

桨距角调节通过降低功率输出 P_{out} ，进一步减少主轴扭矩。

总的来说，相关性分析表明，某些变量之间存在显著的正相关性或负相关性，而其他变量之间的关系较弱。通过识别这些变量之间的关系，我们可以更好地理解风机的运行机制，并在后续的建模中聚焦于对输出影响最大的变量。

具体基于输入变量、状态变量与输出变量之间的相关关系，结合物理理论构建物理关系约束流程示意图见下图：




图 5-4 因素相关性分析物理约束构建示意图

5.3.3 多输入多输出的物理约束模型

在风机的运行过程中，风能的转化受多种物理因素的影响，包括风速、桨距角、轴系扭矩、风机转速和功率调度等变量。因此，构建风机的多输入多输出（MIMO）模型时，不仅要考虑各个变量之间的复杂关系，还需确保模型满足基本的物理约束条件，以保证模型的科学性和现实适用性。

1. 风机功率输出的物理原理

风力发电机的功率输出受空气密度、风轮扫掠面积、风速以及功率系数 C_p 的共同作用。功率输出公式基于风能转换的基本方程：

$$P = \frac{1}{2} \cdot \rho \cdot A \cdot C_p(\theta, v) \cdot V_\omega^3 \quad (5-6)$$

其中， P 为风机的输出功率； ρ 为空气密度（本题取 1.225kg/m^3 ）； A 为风轮扫掠面积（本题取 80m^2 ）； V_ω 为风速（Input2）；

C_p 为风能的功率系数，用于描述风机在不同运行条件下捕获风能的效率，在本题中 C_p 的变化由桨距角 $State1$ 和风速 $Input2$ 共同决定，公式为：

$$C_p = 0.22 \cdot \left(\frac{State1}{20} \right) + 0.5 \cdot \left(\frac{Input2}{12} \right) \quad (5-7)$$

功率输出公式反映了风机如何将风能转化为电能的过程。风速 V_ω 的变化是影响风机输出功率的主要外部因素，而桨距角 θ 则通过改变功率系数 C_p 来控制风轮吸收的风能，从而进一步调节输出功率。

2. 扭矩与功率的关系

在风机的动力传递系统中，输出功率与主轴扭矩之间存在着直接的关系。根据力学原理，输出功率与扭矩和转速之间的关系可以表示为：

$$P = T \cdot \omega \quad (5-8)$$

其中， P 为风机的输出功率； T 为主轴扭矩（Output1）； ω 为转速。

模型通过这个公式确保扭矩和功率之间的物理关系，进一步使得风机的扭矩、转速和输出功率彼此关联。低速轴转速（State2）和高速轴转速（State3）通过齿轮箱进行能量传递，转速的变化直接影响主轴扭矩，并进而影响输出功率。

3. 风速与推力的物理关系

风速不仅影响风机的输出功率，还决定了风机所承受的推力。塔架推力是由风推在风轮上产生的水平力，推力的大小直接受风速、风轮面积以及推力系数 C_t 的影响。推力的物理方程可以表示为：

$$F_t = \frac{1}{2} \cdot \rho \cdot A \cdot C_t \cdot V_\omega^2 \quad (5-9)$$

其中， F_t 为塔架推力（Output2）；

C_t 为推力系数描述了风轮受风推动时产生的水平推力，推力系数的大小随风速和桨距角变化而动态调整。本题中推力系数 C_t 的变化由以下公式决定：

$$C_t = 0.3 \cdot \left(\frac{State1}{15} \right) + 0.5 \cdot \left(\frac{Input2}{12} \right) \quad (5-10)$$

推力的物理公式表明，风速 V_ω 是影响塔架推力的主要因素，而推力系数 C_t 则与桨距角和风速的相互作用有关。推力的增加会给塔架和风轮带来额外的机械应力，长时间的高风速运行会增加设备的疲劳损伤。因此，桨距角 θ 的调节不仅影响输出功率，还通过推力系数 C_t 影响塔架推力，以确保风机在高风速下的安全性。

4. 多输入多输出非线性拟合

为了更好地捕捉输入变量（如风速和功率调度指令）与状态变量（如桨距角、轴系转速等）之间的复杂非线性关系，模型引入了高阶多项式项和交互项。这些项能够描述风机在不同运行状态下的非线性行为，确保模型能够适应风机的实际工况。公式如下：

$$Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \beta_3 X_1^2 + \beta_4 X_2^2 + \beta_5 X_1 X_2 + \dots + \epsilon \quad (5-11)$$

其中， Y 是输出变量（主轴扭矩、塔架推力或输出功率）； X_1, X_2 分别代表输入变量和状态变量（如风速、桨距角等）； $\beta_0, \beta_1, \beta_2, \dots$ 是待拟合的系数； ϵ 是误差项。

该非线性模型通过拟合高阶和交互项，能够更好地捕捉风机各个变量之间的复杂关系，特别是当风速超过额定值时，风机通过桨距角调整的非线性调节行为。

5.3.4 分段拟合模型

1. 分段拟合模型指标选取

在分段拟合模型构建过程中，选择合适的状态变量和控制变量对于拟合效果至关重要。以下是基于图表分析和风机运行条件，针对 State1、State2、State3 以及 Input1、Input2 的选择依据。

(1) 状态变量的选择

通过联合分布图 5-5 可以看出，State1 与 State2 和 State3 的相关性最为显著，尤其是与 State3 的关联更为强烈。同时，State1 作为风机的核心调节变量，能够直接反映风机在不同外部条件下的自我调节过程。因此，选择 State1 作为分段拟合的核心变量，可以捕捉风机在不同运行状态下的非线性行为，从而提高模型的拟合精度和解释性。




图 5-5 联合分布图

(2) 控制变量的选择

在输入变量的选择上，主要考虑 **Input1**（功率调度指令）和 **Input2**（风速）。根据问题背景和数据特点，我们选择 **Input1** 作为输入变量。

问题中给定的是一个 5MW 风机，其对应的额定风速为 11.2 m/s，这意味着风机在该风速下达到最佳运行状态。如果风速低于此值，风机无法充分输出其额定功率，而如果风速高于此值，风机则需要通过调节机制来减少风轮吸能。

但从数据分析中发现，**Input2**（风速）的值均超过了额定风速 11.2 m/s。这表明风机在大部分运行时间内处于高速环境，风速对输出功率的影响趋于平稳，调节作用不再显著。因此，风速的变化已不再是风机输出功率变化的主要驱动力，Input2 作为拟合变量的意义减弱。

2.分段拟合模型策略选取

模型通过分段式策略进行拟合，分别在不同的输入和状态变量下进行回归分析。分段拟合是为了解决多输入、多输出模型中的复杂非线性关系。每种策略下，模型都会引入多个高阶项和交互项，以捕捉风机运行过程中复杂的非线性关系具体过程见下图：




图 5-6 分段拟合模型示意图

在分段拟合策略中，采用了以下三种不同的分段方式来比较拟合效果：

(1) 基于 $Input1$ 控制策略的分段拟合：该策略通过对 $Input1$ （功率调度指令）进行分段，拟合其与风机的输出变量之间的关系。这个方法关注风机在不同调度指令下的响应，适用于基于外部调度的控制策略分析。公式如下：

$$Y = \beta_0 + \beta_1 \cdot Input1 + \beta_2 \cdot Input1^2 + \dots + \epsilon \quad (5-12)$$

该策略更多关注的是风机的控制策略，基于调度指令如何调整风机的输出。

(2) 基于 $States1$ 状态策略的分段拟合：使用 $State1$ （桨距角）进行分段拟合，关注风机的机械调节能力。桨距角反映了风机如何根据风速和功率需求进行自我调整，通过其分段拟合可以更好地解释风机的运行状态。公式如下：

$$Y = \beta_0 + \beta_1 \cdot State1 + \beta_2 \cdot State1^2 + \dots + \epsilon \quad (5-13)$$

(3) $Inputs1 + States1$ 联合拟合：该策略结合了 $Inputs1$ 和 $States1$ ，联合分析外部调度和机械状态对风机输出的影响。通过同时引入调度指令和桨距角的高阶项和交互项，可以更全面地捕捉复杂的风机运行机制。公式如下：

$$Y = \beta_0 + \beta_1 \cdot Input1 + \beta_2 \cdot State1 + \beta_3 \cdot Input1 \cdot State1 + \dots + \epsilon \quad (5-14)$$

这种联合策略虽然考虑了更多变量的影响，但在某些情况下，可能会增加模型的复杂性，导致拟合效果不如单一变量分段拟合稳定。

基于物理原理，并考虑到变量之间可能存在的非线性关系，本文通过引入非线性项和交互项，旨在捕捉风速、桨距角和转速等输入对扭矩、推力和功率输出的复杂影响。因此，数学公式如下：

主轴扭矩 (T_{shaft}) :

$$\begin{aligned} T_{\text{shaft}} = T(\text{state1}, \text{state2}, \text{state3}, V) = \\ a \cdot T_{\text{physical}} + b \cdot \text{state2} + c \cdot \ln V + d \cdot e^{-\text{state1}} + e \cdot V^2 + f \\ \cdot \ln(\text{state2}) + g \cdot e^{-\text{state3}} + h \cdot \text{state2} \cdot \text{state3} \end{aligned} \quad (5-15)$$

塔架推力 (F_t) :

$$\begin{aligned} F_t = F(\text{state1}, \text{state2}, \text{state3}, V) = \\ i \cdot C_t \cdot V^2 + j \cdot \text{state1} + k \cdot \text{state2} + l \cdot \ln \omega_r + \\ m \cdot e^{\text{state1}} + n \cdot e^{\text{state2}} + k \cdot \text{state1} \cdot \ln V \end{aligned} \quad (5-16)$$

实际输出功率 (P_{out}) :

$$\begin{aligned} P_{\text{out}} = T(\text{state1}, \text{state2}, \text{state3}, V, P_{\text{ref}}) = \\ a \cdot P_{\text{ref}} + b \cdot \text{state2} + c \cdot \ln V + d \cdot e^{-\omega_r} + e \cdot V^2 \\ + f \cdot \ln(\text{state3}) + g \cdot \text{state1} \cdot \ln(\text{state2}) + h \cdot e^{\text{state3}} \end{aligned} \quad (5-17)$$

其中 T_{physical} 表示物理扭矩，物理扭矩是功率与转速之间的桥梁，帮助更好地描述功率输出的细节。

5.4 算法求解与结果分析

5.4.1 模型求解

基于分段拟合模型，先将分段指标进行分段，三种分段策略均以指标的中位数作为分段阈值，使用中位数作为分段阈值可以有效避免极端值对数据划分的影响，确保数据的两部分更加均衡和具有代表性。基于物理理论及因素分析，具体分段如下：

- (1) 基于 Input1 控制策略的分段拟合：高功率调度指令与低功率调度指令
- (2) 基于 State1 状态策略的分段拟合：高桨距角与低桨距角
- (3) 基于 Input1+State1 联合拟合：高功率调度指令+低桨距角和低功率调度指令+高桨距角。

进一步，运用最小二乘法，最小化观测值与模型预测值之间的差异来估计模型参数，3 种策略运行拟合效果见下图：




图 5-7 input1 策略拟合效果




图 5-8 state1 策略拟合效果




图 5-9 input1+state1 策略拟合效果

图中展示三种策略的拟合效果都欠佳，通过对比表 5-1 数据，Input1 指标表现稍好，Thrust 拟合效果上较好（RMSE 较低）。其次是 Input1+State1 作为分段指标的方法，特别是在高功率调度+高桨距角区域，RMSE 比较低。最后 State1 作为分段指标效果较差，尤其是 Thrust 的 R^2 和 RMSE 表现最差。综上，选取基于 **Input1** 控制策略的分段拟合。

表 5-1 三种策略拟合效果

分段 指标	Input1		State1		Input1+State1	
	低功率	高功率	低桨距角	高桨距角	低功率+低桨距角	高功率+高桨距角
主轴 扭矩	1796771.5	1807249.89	1850228.05	1787596.89	1883883.27	1772173.75
塔架 推力	997047.14	989137.16	1067092.43	1029436.12	1059714.73	1025583.04

由于初步的拟合效果并不理想，因此引入**随机搜索作为超参数优化**的策略。这种方法可以有效探索参数空间，找到更优的参数组合，从而提高模型的预测性能。随机搜索通过在指定范围内随机选择参数值进行多次实验，相较于传统的网格搜索，它在计算效率上更具优势，能够更全面地探索不同参数的影响。此外，随机搜索可以避免陷入局部最优解，有助于发现更符合数据特征的模型配置，从而提升整体拟合效果。

5.4.2 模型优化

随机搜索通过在预设的参数范围内随机选择多个参数组合，并在每个组合下对模型进行拟合和评估。与系统地遍历所有可能参数组合的网格搜索不同，随机搜索并不依赖固定的步长或顺序，而是通过随机采样的方式快速探索参数空间中的不同区域。

这种方法的核心思想是，在高维参数空间中，随机选择比穷举法更能捕捉到有用的参数组合，因为某些参数对结果的影响可能不大，而其他参数则可能有显著作用。通过随机搜索，我们能够更迅速地找到那些对模型性能提升**关键的参数**。

随机搜索的优化过程可以表达为：

$$\theta^* = argmin_{\theta \in \Theta} L(f(X; \theta), y)$$

(5-18)

其中： θ 表示模型的参数向量， Θ 表示参数空间， $f(X; \theta)$ 表示模型的预测值， y 为实际观测值， $L(f(X; \theta), y)$ 为损失函数。本方法的损失函数为 $Total_RMSE = T_{shaft_RMSE} + F_t_RMSE + P_{out_RMSE}$ 。随机搜索会执行 50 次随机抽取参数，并通过最小化总 RMSE 来寻找最佳的初始猜测值。

表 5-2 参数优化方法对比

优化方法	优点	缺点
随机搜索	随机采样避免无效计算 在高维参数空间中灵活搜索	可能遗漏部分最优参数组合 结果受采样次数影响
网格搜索	逐一遍历所有参数组合 确保在低维空间找到最优解	计算量增加时，效率低 无效的参数组合计算
粒子群优化	全局搜索能力较强 适合多峰问题的优化	需要较多计算资源 容易陷入局部最优解
进化算法（如遗传算法）	能跳出局部最优解 自适应机制	算法复杂，调参困难 计算成本高迭代过程较长

随机搜索相较于网格搜索，显著提升了在高维参数空间中的搜索效率，通过避免遍历所有参数组合，大幅减少了无效计算，使得资源利用更为高效。与贝叶斯优化相比，随机搜索以其实现简单、资源需求低的优势，在资源有限的情况下能够迅速定位到有效的参数组合，无需构建复杂的优化模型。同时，与进化算法和粒子群优化等更复杂的优化策略相比，随机搜索方法更为直接，省去了繁琐的迭代过程和细致的参数调整，能够在较短时间内找到接近最优的解，且其计算资源需求较低，不易陷入局部最优，从而有效且快速地覆盖广泛的参数空间。

5.4.3 结果分析

通过附件 2 中的数据，估算 100 台风机在不同时间点的应力/扭矩值，并与提供的参考值进行对比，我们采用上文所提及的分段拟合的策略以及用随机搜索队参数进行优化的方法，估算出了每个台风机的主轴扭矩和塔架推力的值。通过模型分析，我们发现基于 Input1 控制变量的策略输出的效果最好，因此得出该策略下的参数值分别如下：

低功率调度指令的参数如下：

```
[ 3.44467935e+00  2.43406812e+06 -6.15227730e+04  1.59425370e+06
 4.05560605e+05 -1.29144743e+05 -1.03523361e+05  5.83835999e+03
 1.78597734e+05 -7.79647102e+05  3.80595509e+04 -4.50024375e+04
 5.87891024e+04  7.15696930e+05 -6.29575310e+05  1.41518579e+04
 -7.48306558e+03  2.38172870e+05 -2.12147622e+03  1.86019381e+03]
```

高功率调度指令参数如下：

```
[ 1.16998593e+01  1.97722924e+06 -6.60406065e+04  1.69997698e+06
 4.38740609e+05 -1.21114159e+05 -1.10297795e+05  3.56371300e+03
 2.18403613e+05 -5.60476414e+05  3.40677390e+04 -1.45945399e+04
 9.67799230e+04  6.75004957e+05 -8.69312762e+05  1.03480404e+04
 -8.37057005e+03  3.53229887e+05 -1.26646272e+02  5.65934744e+02]
```

分段拟合的策略以及用随机搜索队参数进行优化的方法与参考数据拟合效果见下图：




图 5-10 input1 策略拟合效果




图 5-11 部分台风机主轴扭矩与塔架推力预测值与参考值对比图

从图 5-11 可以得出多个风机的塔架推力与主轴扭矩的实际值与参考值对比结果表现出较好的拟合度，表明风机的实际运行情况与模型预测结果具有较高的吻合性。然而，局部的偏差提示我们在某些特殊工况（如风机启动、停止或外部风速快速变化时）下存在超出模型预测范围的运行特性，这些差异可能需要进一步的优化和分析以提升模型在这些场景下的适应性。

100 台风机在全部时刻的估算值与参照值之差的平方和对比效果如下图所示：




图 5-12 平方和对比图

从图中可以看到，左图的主轴扭矩（Output1）实际值与预测值基本保持一致，说明模型在整体趋势上的拟合效果较好。虽然两者的曲线在多数时刻高度重合，但在局部区域，如图中一些峰值处，实际值（蓝色线）稍低于预测值（橙色线），表明存在一些轻微的偏差。这些偏差通常是瞬时的，未持续影响整体的拟合效果。右图中的（塔架推力）Output2 实际值与预测值更为接近，几乎没有明显的差异，两条曲线完全重合，说明模型在预测 Output2 时表现更加理想。虽然仍有少数点位出现局部波动，但这些波动幅度较小，整体预测结果与实际值吻合度较高。

综上所述，模型在处理主轴扭矩（Output1）和（塔架推力）Output2 时均表现出较强的拟合能力。主轴扭矩（Output1）存在少量的局部偏差，显示出模型可能对一些特殊情况下的变化不够敏感；而（塔架推力）Output2 的预测结果几乎与实际值完全一致，展示了较高的预测精度。整体来看，该模型在预测这两组数据时具有良好的表现，尤其在（塔架推力）Output2 上的预测效果更为出色。

6 问题三 有功调度优化问题构建与实时求解

6.1 问题分析

本问题聚焦于大规模风电场的有功调度优化,风电场通常包括大量风机（如 100 台），导致高维度的优化问题，增加了计算复杂度。建模时需考虑优化多维目标（涉及主轴和塔架的疲劳损伤），并且保证算法低复杂性、实时性，要求每秒进行一次计算，为解决这些难点，本文通过 **Pareto 前沿** 分析来平衡主轴和塔架疲劳损伤的权重，确保各目标间的合理平衡。在约束条件方面，需保证风机有功参考值之和等于电网调度指令，并不超过各自的额定功率（5MW），这需要在建模时考虑风速变化对功率输出的影响，基于**区域划分**以及 **MPC（模型预测控制）** 框架建立优化模型确保了优化结果的可操作性和可实施性，有效降低了风电场的运维成本。

6.2 求解思路图




图 6-1 问题三求解思路图

6.3 模型建立

本模型旨在解决风电场有功功率调度中的多目标优化问题，确保实时性和功率分配的精准性。本问设计**基于 Pareto 权重自适应的 MPC 优化模型**，实现风机主轴和塔架疲劳损伤最小化的优化目标。通过 **Pareto 前沿分析**，模型在多个优化目标之间进行权重调整，形成 Pareto 最优解，**基于风速波动情况结合实际进行区域划分（权重分配异质化），区域内选择适当的权重组合来平衡主轴和塔架的疲劳损伤**。在区域内，**基于模型预测控制（MPC）框架**，模型通过预测风速和功率需求的变化，在每秒内动态调整风机的功率分配，确保实时优化与最优功率分配的执行。

6.3.1 优化目标的设定

在风电场的有功功率调度问题中，优化目标不仅是确保风机群的总功率输出满足电网的调度指令，还需同时关注风机运行过程中关键部件的疲劳损伤问题。具体而言，**主轴疲劳损伤和塔架疲劳损伤是两个核心的优化目标**。由于风机在运行过程中受到不同风速的影响，这些部件会承受长期的机械应力，进而影响风机的使用寿命和维护成本。

在本模型中选择**平均疲劳损伤**累计作为优化目标，主要是为了确保风电场中各台风机的疲劳损伤在整体上趋于**均衡**。通过优化平均疲劳损伤，可以避免个别风机因过度损伤而影响整个风电场的运行效率，从而实现**全局的损伤最小化**。选择平均值作为目标还能防止由于优化某些风机的疲劳损伤而导致其他风机承受过大负载的极端情况，确保所有风机的损伤水平相对一致。此外，平均损伤的优化有助于**平衡维护成本**，延长风机部件的使用寿命，减少频繁的维修需求。

目标 1：平均主轴疲劳损伤累计最小化

主轴是风机的重要组件，长期运行过程中会累积疲劳损伤，进而影响风机的可靠性。为了降低主轴的损伤，模型将各台风机的主轴累计疲劳损伤值进求和平均：

$$f_1 = \frac{1}{N_t} \sum_{i=1}^{N_t} D_{shaft}^i(k) \quad (6-1)$$

其中， $\frac{1}{N_t} \sum_{i=1}^{N_t} D_{shaft}^i$ 表示所有风机主轴疲劳损伤累计的平均值与功率输出 P_{ref}^i 和风速成非线性关系，反映了风速越高、功率输出越大的情况下，主轴承受的疲劳损伤增长更快。

目标 2：平均塔架累计疲劳损伤最小化

塔架承受风载荷，长期风速变化对塔架造成的应力会累积，形成疲劳损伤。因此，第二个优化目标是**最小化塔架的累积疲劳损伤均值**，具体公式为：

$$f_2 = \frac{1}{N_t} \sum_{i=1}^{N_t} D_{tower}^i(k) \quad (6-2)$$

其中， $\frac{1}{N_t} \sum_{i=1}^{N_t} D_{tower}^i$ 表示所有风机塔架疲劳损伤累计的平均值，疲劳损伤与功率输出 P_{ref}^i 和风速比值成非线性关系，反映了风速越高、功率输出越大的情况下，塔架承受的疲劳损伤增长更快。

通过这两个优化目标，模型在功率分配过程中，重点关注如何平衡风机关键部件的疲劳损伤。主轴和塔架的疲劳损伤分别取决于风速和功率，因此需要合理分配各风机的参考功率，以确保在降低损伤的同时满足电网调度的需求。

6.3.2 基于 Pareto 自适应权重调整

在风电场的有功功率调度问题中，模型的核心目标是同时优化主轴疲劳损伤累计和塔架疲劳损伤累计，为了实现这两个目标的**平衡优化**，本节先对主轴疲劳损伤累计和塔架疲劳损伤累计进行**相关影响分析**，进一步采用 Pareto 前沿分析来**确定不同目标之间的权重**，从而找到合适的优化解。基于 Pareto 自适应权重调整双重目标，确定目标函数流程见下图：




图 6-2 分区域目标函数流确立流程图

1. 主轴与塔架疲劳损伤相关性分析

对两目标进行权重设置将多目标问题转化为单一目标问题前，先考虑主轴与塔架疲劳损伤的相关性进而，理解这两个优化目标之间的关系。基于附件 2，100 台风机参考主轴扭矩、塔架推力求解疲劳损伤分析，绘制 KDE 密度图和热力图见下：




图 6-3 图轴与塔架疲劳损伤 KDE 密度图和热力图

从图中可知，主轴与塔架的疲劳损伤相关性较低，但这两个目标变量在特定区域内表现出集中趋势，表明在这些区域存在一定的权衡空间，分布信息为后续 Pareto 前沿的生成调整目标权重提供了重要分析基础。

2.Pareto 前沿生成

Pareto 前沿分析是一种常用于多目标优化的问题求解方法，能够帮助决策者在多目标之间进行权衡，生成一组 Pareto 最优解。通过 Pareto 前沿分析，模型在主轴疲劳损伤和塔架疲劳损伤两个独立目标之间实现平衡优化。

在模型中，我们采用加权求和法，通过对目标函数 f_1 和 f_2 赋予不同的权重 α_1 和 α_2 ，生成一组 Pareto 最优解。具体的目标函数形式如下：

$$F = \alpha_1 \frac{1}{N_t} \sum_{i=1}^{N_t} D_{shaft}^i(k) + \alpha_2 \frac{1}{N_t} \sum_{i=1}^{N_t} D_{tower}^i(k) \quad (6-3)$$

其中 f_1 为主轴疲劳损伤目标， f_2 为塔架疲劳损伤目标，权重 $\alpha_1 + \alpha_2 = 1$ ，且 $\alpha_1 \geq 0$ 、 $\alpha_2 \geq 0$ ，通过对不同的权重组合进行优化，可以生成对应的 Pareto 最优解集，称为 Pareto 前沿。每次优化的结果代表某种权重下的损伤折中效果。具体算法步骤见下：

Step1 初始单目标优化：

在 Pareto 前沿分析的第一步，我们首先对两个目标函数分别进行单目标优化，以明确这两个目标各自的最优状态：

(1)主轴疲劳损伤最小化：在不考虑塔架疲劳损伤的情况下，我们将权重 $\alpha_1=1$ ， $\alpha_2 = 0$ ，即完全优化主轴疲劳损伤 f_1 ，在此情况下，模型将得到一个针对主轴疲劳损伤的最小化解，但塔架疲劳损伤 f_2 将会受到一定影响。

(2)塔架疲劳损伤最小化：同样地，为了优化塔架疲劳损伤而忽略主轴损伤，将权重设定为 $\alpha_1=0$ ， $\alpha_2 = 1$ ，完全优化塔架疲劳损伤。

在此优化下，塔架疲劳损伤最小化，但主轴疲劳损伤 f_1 会受到一定影响。通过分别优化这两个目标，我们可以获得在每个目标单独最优时的解，为后续生成 Pareto 前沿奠定基础。

Step2 权重插值生成 Pareto 前沿：

为了在两个目标之间找到折中方案，采用加权求和法，对目标函数赋予不同的权重组合 α_1 和 α_2 ，进行多次优化求解，从而生成 Pareto 前沿。设定不同权重组合，在 α_1 和 α_2 之间进行插值，逐步改变权重组合。

表 6-1 部分权重差值设置表

α_1	α_2
0.1	0.9
0.2	0.8
0.5	0.5
0.7	0.3
0.8	0.2

根据设定的权重组合，逐次进行优化，得到不同权重下的最优解。每个优化结果都代表一个在当前权重组合下的最优方案。通过这种方式，可以生成一组 Pareto 最优解。

Pareto 前沿的形成：将每次优化得到的最优解绘制在二维平面上，以主轴疲劳损伤为 f_1 横轴，塔架疲劳损伤 f_2 纵轴。连接这些最优解的曲线即为 Pareto 前沿，它代表了不同权重下的最佳折中解，选定的权重组合 α_1^* 和 α_2^* 。Pareto 前沿上的解具有以下特性：无法在不恶化一个目标的情况下进一步优化另一个目标。

Step3 区域划分与权重应用策略：

在风电场的实际应用中，由于各风机所处的地理位置不同，其所受的风速和负载条件也会有所差异。为了更好地优化各台风机的功率分配，模型采用了区域划分与权重应用策略，即根据风速波动情况将风电场划分为多个区域，每个区域的风机根据其风速特性设置

不同的优化权重，能够在局部环境的基础上进行针对性优化。




图 6-4 图风机所处环境风速波动箱线图

对于风速波动较大的区域：主轴承承受的机械应力较大，主轴疲劳损伤成为主要优化目标。因此，针对这些区域的风机，该权重组合**优先考虑主轴疲劳损伤的最小化**，以延长主轴的使用寿命，确保系统的长期稳定性，基于 Pareto 前沿生成模型设定的权重组合为：

$$\alpha_1 = 0.14、\alpha_2 = 0.86$$

对于风速较稳定的区域：主轴和塔架的疲劳损伤累积较为均衡，使得系统能够同时兼顾主轴和塔架的疲劳损伤，确保两者的损伤均衡最小化，适应长期运行需求。针对该区域模型考虑平衡优化基于 Pareto 前沿设置权重组合：

$$\alpha_1 = 0.46、\alpha_2 = 0.54$$

这种方法可以根据风电场的实际情况进行调整，区域划分的依据不仅可以是风速波动，还可以结合其他环境或设备状况的变量，确保模型具有较高的可扩展性和适应性。

6.3.3 全局协调的分区域 MPC 优化模型

在实际的有功功率调度优化问题中，风电场中包含大量风机，每秒需要进行一次功率分配计算，因此求解方法不仅要具备**高精度**，还需要满足**实时计算**的要求。由于风电场中的风速分布特性不同，为了更好地优化风机的有功功率分配，可以将风电场划分为多个区域，并根据每个区域的特点分配不同的优化权重组合。基于实际场景，选择**模型预测控制（MPC, Model Predictive Control）**，考虑风速的变化、功率分配和疲劳损伤的累积效应建立动态模型。

MPC 能够自然处理**多目标和多约束优化问题**。与其他方法相比，线性规划（LP）和非线性规划（NLP）虽然可以用于求解优化问题，通常用于静态问题。元启发式算法（如遗传算法、粒子群优化等）擅长全局搜索，但求解时间较长。而动态规划（DP）在处理多阶段决策问题时，计算复杂度较高，综合实际需求选择 MPC 为模型外框架。

本文满足每秒优化的**高精度**要求设计了全局协调的分区域 MPC 优化模型，具体步骤见下：

Step1 全局功率区域分配设定:

在每个时间步 t ，系统首先根据电网调度的总功率要求 P_t ，为每个区域分配功率限额 $P_{region}^j(t)$ ，确保全局功率平衡：

$$\sum_{i=1}^{N_t^1} P_{ref}^i(t) + \sum_{i=1}^{N_t^2} P_{ref}^i(t) = P_t \quad (6-5)$$

其中， N_t^1 、 N_t^2 分别为区域 1、区域 2 的风机数量， $P_{ref}^i(t)$ 是第 i 台的参考功率，两区域分配功率之和为电网调度指令功率。

每个区域根据区域特点以及风机数量进行区域功率分配，高风速区域（区域 1）分配更多的功率以满足其高风速下的发电需求，两区域功率分配见下式：

$$P_{region}^1(t) = \frac{W_1}{W_1 + W_2} P_t \quad (6-6)$$

$$P_{region}^2(t) = \frac{W_2}{W_1 + W_2} P_t \quad (6-7)$$

其中 W_j 为区域 j 的功率权重，反映了该区域的功率需求（基于风速信息）。此时，每个区域 j 内的风机功率参考值应满足：

$$\sum_{i=1}^{N_t^j} P_{ref}^i(t) \leq P_{region}^j(t) \quad (6-8)$$

Step2 模型初始化（目标及约束确定）：

在初始时刻，系统首先获取风机的当前状态信息（风速 V_w^i ：第台风机的当前轮毂处风速，参考功率 P_{ref}^i ：第 i 台风机的初始功率参考值）。

目标函数：对于每个区域，基于不同的权重组合，目标函数 F 为各区域内部主轴疲劳损伤 f_1 和塔架疲劳损伤 f_2 的加权和：

$$\min_{\{P_{ref}^i(k)\}} F = \sum_{k=0}^{N_p} \left(\alpha_1 \frac{1}{N_t} \sum_{i=1}^{N_t} D_{shaft}^i(k) + \alpha_2 \frac{1}{N_t} \sum_{i=1}^{N_t} D_{tower}^i(k) \right) \quad (6-9)$$

其中， N_p 为 MPC 滚动时域窗口大小，具体，每个区域独立地求解优化问题，基于当前的风速预测和目标函数，进行功率分配优化。

约束条件：

动态约束：疲劳损伤累计模型（（Miner 法则））

$$D_{shaft}^i(k+1) = D_{shaft}^i(k) + \Delta D_{shaft}^i(k+1) \quad (6-10)$$

$$D_{tower}^i(k+1) = D_{tower}^i(k) + \Delta D_{tower}^i(k+1) \quad (6-11)$$

其中， $\Delta D_{shaft}^i(k+1)$ ， $\Delta D_{tower}^i(k+1)$ 为第 k+1 时刻疲劳损伤值

输入输出约束：

(1) **总功率平衡**：要保证所有风机有功参考值 P_{ref}^i 之和 $\sum P_{ref}^i$ 等于电网调度指令 P_t ，基于区域划分，两区域（共 100 台风机）所有风机有功参考值之和为 P_t 。

$$\sum_{i=1}^{N_t^1} P_{ref}^i(t) + \sum_{i=1}^{N_t^2} P_{ref}^i(t) = P_t \quad (6-12)$$

(2) **单台风机功率上限**

$$P_{min}^i \leq P_{ref}^i \leq P_{max}^i = 5MW \quad (6-13)$$

(3) **功率分配误差约束**

首先计算平均分配功率：

$$\bar{P}_{ref}^i = \frac{P_t}{N_t} \quad (6-14)$$

限制优化分配值与平均值的偏差不超过 1MW：

$$|P_{ref}^i - \bar{P}_{ref}^i| \leq 1MW \quad (6-15)$$

等价于：

$$\bar{P}_{ref}^i - 1 \leq P_{ref}^i \leq \bar{P}_{ref}^i + 1 \quad (6-16)$$

综合单台功率上下限，最终约束为：

$$\max(\bar{P}_{ref}^i - 1, 0) \leq P_{ref}^i \leq \min(5, \bar{P}_{ref}^i + 1) \quad (6-17)$$

(4) **功率变化率约束**

考虑风机的动态响应性能力设置每次功率变化量不大于 ΔP_{max} ：

$$|P_{ref}^i(k+1) - P_{ref}^i(k)| \leq \Delta P_{max} \quad (6-18)$$

其中， $\Delta P_{max}(3WM)$ 单次功率调整的最大允许变化量
具体见下：

$$\begin{aligned}
\min_{\{P_{ref}^i(k)\}} F &= \sum_{k=0}^{N_p-1} \left(\alpha_1 \frac{1}{N_t} \sum_{i=1}^{N_t} D_{shaft}^i(k) + \alpha_2 \frac{1}{N_t} \sum_{i=1}^{N_t} D_{tower}^i(k) \right) \\
\text{s.t.} &\begin{cases} \bar{P}_{ref}^i = \frac{P_t}{N_t} \\ \bar{P}_{ref}^i - 1 \leq P_{ref}^i \leq \bar{P}_{ref}^i + 1 \\ P_{min} \leq P_{ref}^i \leq P_{max} \\ |P_{ref}^i(k+1) - P_{ref}^i(k)| \leq \Delta P_{max} \end{cases} \quad (6-19)
\end{aligned}$$

Step3 并行优化求解:

每个区域独立地求解优化问题，基于当前的风速预测和目标函数，进行功率分配优化，基于风速波动进行区域划分：**区域 1（风速波动大的区域，主轴疲劳损伤优先）、区域 2（风速较稳定的区域，主轴与塔架均衡优化）**优化的目标是在未来时间窗口内最小化疲劳损伤，同时确保满足所有约束条件。每个区域都独立求解优化问题，确保时效性，并得到相应每台风机在每秒的最优功率分配 $P_{ref}^i(t+k)$ 。

Step4 风速预测模型:

预测是 MPC（模型预测控制）中核心的一部分，主要是为了帮助系统提前规划未来的操作，并确保在不确定的条件下进行优化。每个区域根据当前的风速数据，使用 LSTM 进行风速预测，预测未来时间窗口内的风速变化。

每个区域根据当前的风速数据 V_w^i ，进行风速预测，预测未来时间窗口内的风速变化。这是 MPC 的重要环节，依赖于风速时序数据的历史趋势来预测未来：

$$\hat{V}_w^i(t+k) = \text{forecast}(V_w^i(t)) \quad (6-20)$$

其中 $\hat{V}_w^i(t+k)$ 为未来第 $\hat{V}_w^i(t+k)$ 秒的风速预测值，每个区域基于风速预测，计算未来的疲劳损伤情况。

Step5 滚动时域功率优化:

基于未来风速预测，系统会基于这些风速数据为未来 10 秒的每台风机计算最优的功率分配策略。具体来说，系统会在时间窗口内优化每秒的功率分配，但由于未来风速存在不确定性，因此系统每秒更新并滚动应用，并应用于当前时刻的风机控制。

系统使用 MPC 模型，根据预测的未来风速数据，优化未来每秒的功率分配，即优化第 i 台风机在未来 10 秒内的功率分配，但仅确立当前时刻功率分配，确保计算复杂度同时考虑，未来时域变化，避免大浮动功率变化带来的疲劳损害。

时域内部，根据式（5-15）、（5-16）求得主轴扭矩以及塔架推力，基于自适应动态三阶段滑动窗口算法以及改进式雨流计数法求得疲劳损伤，通过有功优化分配策略，确保疲劳损伤的最小化。

Step6 全局验证与反馈调整:

每个区域完成局部优化后，系统在全局层面进行验证，检查所有区域的功率分配是否满足全局功率限制，首先进行全局功率平衡验证：

$$\sum_{i=1}^{N_t^1} P_{ref}^i(t+k) + \sum_{i=1}^{N_t^2} P_{ref}^i(t+k) = P_{t+k} \quad (6-21)$$

如果某一区域功率分配超出其分配限额 $P_{region}^j(t)$ ，则全局反馈机制会调整该区域的功率分配，确保其功率分配在全局范围内。例如，如果高风速区域的功率超出全局限制，则通过反馈机制调整其权重组合，减少该区域的功率分配：

$$P_{ref}^i(t+k) \rightarrow P_{ref}^i(t+k) - \Delta P \quad (6-22)$$

其中， ΔP 是超出的功率调整量。

6.4 算法求解与结果分析

6.4.1 算法求解

在问题三的 MPC 框架内部滚动时域优化求解是采用优化求解调用 SLSQP（顺序最小二乘法）算法进行风电场有功功率的优化求解，此过程旨在通过调整风机的功率分配，最大限度地降低疲劳损伤，以实现更高的运行效率和更低的运维成本。

首先初始化各参数，基于模型建立中目标函数及约束使用 Pareto 权重自适应的 MPC 优化模型求解，在进行优化之前，为每台风机的有功功率分配初始值。

初始值 P_{ref}^i 是基于电网调度指令 P_t 的均分计算得出的：

$$P_{ref}^i = P_t / W_t \quad (6-23)$$

为了增强优化过程的灵活性，防止算法陷入局部最优解，我们在初始值中加入**小幅随机扰动**。具体，扰动值 ϵ 是在一个小范围内的随机值，其范围设定为 $[-0.1 \text{ MW}, 0.1 \text{ MW}]$ ：

$$P_{ref}^i += \epsilon \quad (6-24)$$

加入随机扰动能够**避免局部最优解**，通过随机扰动打破当前解的稳定性，使得算法在解空间中进行更广泛的探索，在实际风电场运行中，电网调度和风速等参数常常具有一定的不确定性。通过引入随机扰动，优化求解器能更好地适应这些变化，从而提高模型在实际应用中的鲁棒性和灵活性。

在设置好初始平均功率和约束条件后，我们调用优化求解器进行优化求解。该求解器通过迭代方式逐步调整功率分配 P_{ref}^i ，以寻找能够最小化目标函数的最优解。

首先，算法计算当前功率分配下的目标函数值，并检查所有约束条件是否得到满足。若满足条件，则通过优化算法的更新规则调整功率分配，继续寻找新的解，直到满足收敛条件（如目标函数变化小于设定阈值或达到最大迭代次数）。具体过程如下图 6-6 所示。




图 6-6 优化算法求解流程图

完成优化后，我们可以从优化求解器的输出中提取最优功率分配结果 P_{ref}^i ，该结果为每台风机在当前电网调度条件下的最佳功率分配方案。通过这些步骤，我们不仅实现了风电场的有功功率动态优化，也为后续的疲劳损伤分析和性能评估提供了基础，确保在满足电网调度要求的同时，最大程度降低风机的疲劳损伤。

6.4.2 结果分析

1. 计算结果分析

下图展示了前 50 秒对 100 台风机进行有功功率优化分配的实时计算时间。由于大规模风电场的优化问题维度较高（此例中风机总数量为 100），我们在建模阶段兼顾了模型的复杂度和精度。从折线图可以看出，所采用的模型和求解方法能够将计算时间稳定控制在 1 秒以内，确保快速响应，并为每台风机提供最优的功率分配。为展示系统的实时性，还生成了带有计时器的动图（GIF），以动态形式体现计算结果的实时性，将在附件中提交展示。




图 6-7 每秒功率分配方案实时计算时间

2. 优化前后风机间参考功率方差值

为了展示模型的优化结果，我们对风机间参考功率方差值进行了对比，从图中可以看到，优化前（橙色曲线）和优化后（蓝色曲线）的功率方差在整个时间段内均存在较大的波动。然而，两者的波动幅度和变化趋势有所不同，尤其是在局部时段，优化后的方差变化更加平稳。

优化后的功率方差整体呈现出更为集中的波动，峰值有所减小。例如，在 20 秒和 50 秒左右，优化后的方差明显低于优化前的方差，这表明通过优化，风机之间的功率分配更加均衡，风机功率之间的差异有所减小。

在一些时间点上，优化后的方差甚至略高于优化前的方差，说明在某些时刻，优化过程可能会为了满足约束条件而造成局部的功率分配差异增大。但总体来看，优化后的方差曲线呈现出更为平滑的趋势，降低了极端波动。

综合来看，优化后的功率分配在绝大多数时间段内方差更小，这说明优化方案有效地减少了风机功率的分配不均，有助于降低风机的疲劳损伤，并使风场整体运行更加稳定。




图 6-8 优化前后功率方差变化对比图

3. 实时分配结果部分展示

每秒进行一次功率分配，生成的供含有计时器的动图已放入作品附件，随机截取动图展示部分实时分配结果图见下图：




图 6-9 部分时刻实时分配展示图

4.单台风机功率分配结果分析

从图中可以看到，我们随机选取了 6 台风机的功率分配情况，这些风机的编号分别为 WT_26、WT_32、WT_56、WT_58、WT_71 和 WT_86。图中展示了它们在 100 秒内的功率输出情况。曲线显示，每台风机的功率分配在整个时间段内存在一定的波动，但总体上保持在合理的范围内。




图 6-10 功率分配波动图

根据图中的数据信息和我们设定的约束条件，在时间限制内计算出每秒 100 台功率分配情况，**优化结果具有平滑性**：反映了每台风机的功率输出较为平滑，说明优化算法在调整功率分配时避免了剧烈的波动，这有助于维持风机运行的稳定性。此外，功率分配与各风机的平均分配偏差均在 1MW 的约束范围内（结合代码中的约束条件设定）。**波动合理**：各风机的功率输出在不同时间点存在波动，但这些波动与风速变化和电网调度指令的动态变化相一致。**功率变化率约束** $|P_{\text{ref}}^i(k+1) - P_{\text{ref}}^i(k)| \leq \Delta P_{\text{max}}$ 这种波动确保了风电场的功率输出能够及时响应外部条件的变化，并且通过算法求解保证了功率分配在可接受的范围内。

7 问题四 考虑通信延迟和测量噪声的有功功率优化与求解

7.1 问题分析

在实际风力发电中，AGC 系统依赖多个传感器采集信号并通过高速光纤环网传输至集控中心。传感器数据受到随机测量噪声的干扰，通信过程中的传输拥堵可能导致最大 10 秒的随机延迟，这限制了优化的实时性和效果，因此需要对现有的优化方案进行完善。本问将通过**卡尔曼滤波器**处理测量噪声，结合多传感器数据融合提升观测数据的准确性，确保模型输入数据的鲁棒性。针对通信延迟，引入**延迟补偿机制**，通过历史数据的权重和状态预测对功率进行动态调整，基于第三问中提出的**Pareto 权重自适应模型预测控制(MPC)优化模型**，结合鲁棒优化，以提升系统的鲁棒性和稳定性。同时，将探讨**改进的粒子群算法与鲁棒优化相结合**进行模型调整，并对比噪声和延迟作用下两种模型分配策略对各元件疲劳损伤累计的影响。

7.2 求解思路图




图 7-1 问题四求解思路图

7.3 模型建立

7.3.1 基于动态数据滤波的缓解噪声影响策略

测量噪声主要来源于传感器的随机干扰，导致数据精度降低，使风机调度决策基于不准确的信息。此外，噪声影响疲劳损伤的评估，可能导致未能准确反映实际损伤情况，增加系统的不确定性。为有效应对测量噪声的影响，可以引入卡尔曼滤波器对风速感测和功率指令进行动态处理。通过构建状态空间模型，滤波器将历史真实状态（风速感测和功率指令）与测量值（存在噪声测量值）进行融合，结合历史数据和模型预测。

结合实际模型其具体步骤见下：

Step1 定义状态与观测变量:

系统的状态变量可以定义为估计的风速和功率指令，记为 $\mathbf{x}_k$ ，而观测变量则是传感器测得的带有噪声的风速和功率数据，记为 $\mathbf{z}_k$ 。卡尔曼滤波器通过预测与校正相结合的方式逼近系统的真实状态。

状态转移方程:

$$\mathbf{x}_k = \mathbf{A}\mathbf{x}_{k-1} + \mathbf{B}\mathbf{u}_{k-1} + \boldsymbol{\omega}_k \quad (7-1)$$

其中， $\mathbf{A}$ 是状态转移矩阵，用于表示状态随时间的变化。， $\mathbf{B}\mathbf{u}_{k-1}$ 是控制输入，反映前一时刻的功率调度决策。 $\boldsymbol{\omega}_k$ 是过程噪声，反映系统内部的不确定性。

观测方程:

$$\mathbf{z}_k = \mathbf{H}\mathbf{x}_k + \mathbf{v}_k \quad (7-2)$$

$\mathbf{z}_k$ 是当前时刻的测量值（传感器测得的风速或功率）。 $\mathbf{H}$ 是观测矩阵，将状态变量映射到测量空间。 $\mathbf{v}_k$ 是测量噪声，本题假设服从正态分布。

Step2 滤波过程:

卡尔曼滤波的工作流程分为两个主要步骤：预测和校正。

预测步骤：根据上一时刻的状态估计 $\mathbf{x}_{k-1}$ ，预测当前时刻的状态 $\mathbf{x}_k$ ，

$$\bar{\mathbf{x}}_k = \mathbf{A}\bar{\mathbf{x}}_{k-1} + \mathbf{B}\mathbf{u}_{k-1} \quad (7-3)$$

同时预测协方差矩阵:

$$\mathbf{P}_k = \mathbf{A}\mathbf{P}_{k-1}\mathbf{A}^T + \mathbf{Q} \quad (7-4)$$

$\mathbf{P}_k$ 是当前的状态协方差， $\mathbf{Q}$ 是过程噪声的协方差矩阵。

校正步骤：根据当前时刻的测量值 $\mathbf{z}_k$ ，计算卡尔曼增益 $\mathbf{K}$ ：

$$\mathbf{K}_k = \mathbf{P}_k\mathbf{H}^T(\mathbf{H}\mathbf{P}_k\mathbf{H}^T + \mathbf{R})^{-1} \quad (7-5)$$

$\mathbf{R}$ 是测量噪声的协方差矩阵。

利用卡尔曼增益修正状态估计:

$$\bar{\mathbf{x}}_k = \bar{\mathbf{x}}_k + \mathbf{K}_k(\mathbf{z}_k - \mathbf{H}\bar{\mathbf{x}}_k) \quad (7-6)$$

同时更新协方差矩阵:

$$\mathbf{P}_k = (\mathbf{I} - \mathbf{K}_k\mathbf{H}) \mathbf{P}_k \quad (7-7)$$

通过这一过程，滤波器能够根据实时测得的观测值对状态进行修正，将随机噪声的影响最小化。这样，尽管系统没有直接的真实状态，但通过滤波器的反复迭代，模型能够获得逐渐逼近真实的风速和功率指令估计，从而提高功率调度的准确性。

7.3.2 基于延迟补偿机制缓解延迟作用影响策略

通信延迟会导致风机无法及时接收功率指令，调度决策基于过时的信息，从而降低调度的灵活性和实时调整能力。这使得风机的功率分配无法快速适应环境变化，进而影响功

率输出的效率。针对风电场的有功功率调度问题，通信延迟会导致数据的滞后，从而影响调度决策的及时性和准确性。为了减轻通信延迟的影响，可以通过**调整模型预测控制(MPC)的调度策略**(根据延迟长调整滚动时域窗口大小)，并引入**延迟补偿**机制，确保在数据延迟情况下依然能够做出高效的调度决策。

1. 优化调度策略

优化调度策略的核心是调整 MPC 的调度时间步长，并根据风电场的实际运行需求，确保在延迟情况下依然能够实现高效的调度。

Step1 调整 MPC 时间步长：

在面对通信延迟时，可以通过缩短 MPC 的调度时间步长来提高系统的反应速度。调度传输通信延迟最大为 10 秒，本模型将 MPC 的时间步长设为 5 秒，保证每 5 秒进行一次调度更新，确保即使在 10 秒的延迟范围内，**系统仍能进行两次调度调整**，从而有效应对数据传输滞后的问题。

MPC 的核心目标是在每个时间步优化功率分配，假设当前时刻 k 时的状态为 x_k ，观测值为 z_k ，则 MPC 的控制输入 u_k 为：

$$u_k = MPC(x_k, z_k) \quad (7-8)$$

其中， u_k 是当前时刻的功率分配方案， x_k 是系统状态（如风机的当前运行状态）， z_k 是传感器测得的风速或功率数据。

Step2 引入历史数据的权重：

为了应对通信延迟导致的数据滞后问题，调度策略中可以引入历史数据的权重，使得即使当前数据滞后，模型也能够基于最近的历史数据进行合理的调度决策。假设延迟时长为 d 秒($d \leq 10$)，模型通过加权平均过去的观测值 $z_{k-d}, z_{k-d-1}, \dots, z_k$ ，来估计当前状态：

$$u_k = MPC(x_k, \bar{z}_k) \quad (7-9)$$

其中， w_i 为历史数据的权重，加权后的观测值 $\bar{z}_k$ 作为新的输入，用于 MPC 的调度更新：

$$u_k = MPC(x_k, \bar{z}_k) \quad (7-10)$$

通过这种方式，即使数据延迟，系统仍能基于历史观测进行调度，确保功率分配优化。

2. 延迟补偿机制

为了进一步增强 MPC 的实时性，延迟补偿机制可以通过预测未来的状态和控制输入，在延迟的情况下提前做出合理的调度决策。

Step1 延迟预测补偿：

当数据延迟时，模型可以基于历史状态和控制输入来预测当前时刻的状态。当前时刻的状态 x_k 可以基于上一时刻 $k-d$ 时的状态 x_{k-d} 和控制输入 u_{k-d} 进行预测：

$$\hat{x}_k = A^d x_{k-d} + B \sum_{i=0}^{d-1} A^i u_{k-i} \quad (7-11)$$

其中， A 是状态转移矩阵， B 是输入矩阵。通过预测 $\hat{x}_k$ ，系统可以补偿当前时刻的数据延迟，生成一个近似的状态估计，用于调度决策。

Step2 基于延迟的调度更新：

在有延迟的情况下，系统的控制输入 u_k 也可以根据预测状态来进行调度更新：

$$u_k = MPC(\hat{x}_k, \bar{z}_k) \quad (7-12)$$

其中， $\hat{z}_k$ 为预测的观测值，基于历史数据和延迟补偿机制进行估计。通过这种延迟补偿，系统能够在数据滞后的情况下仍然保持较好的响应能力。

Step3 实时反馈调整：

为了进一步提升调度策略的准确性，可以通过反馈调整机制对调度结果进行实时校正。反馈调整的核心是根据当前的误差 e_k 对调度进行修正：

$$e_k = z_k - \hat{z}_k \quad (7-13)$$

其中， z_k 为实际测得的观测值， $\hat{z}_k$ 为预测的观测值。可以调整控制输入：

$$u_{k-1} = u_k + K e_k \quad (7-14)$$

这里， K 是增益系数，用于调节系统对误差的响应速度。这种反馈机制确保调度结果更加精确，进一步提高系统在通信延迟条件下的调度效果。

通过优化调度策略（调整时间步长、引入历史数据权重）和延迟补偿机制（状态预测、反馈调整），MPC 模型能够有效应对通信延迟的影响。这种设计确保即使在数据延迟和不确定性影响下，系统依然能够进行高效、准确的功率调度，确保风电场的稳定运行和电网需求的实时响应。

7.3.3 基于粒子群算法的鲁棒优化模型

在实际风电场中，AGC 系统的信号通过多个传感器采集，数据传输受到噪声和延迟的影响，导致优化过程面临不确定性。粒子群算法（Particle Swarm Optimization, PSO）是一种群体智能优化技术，由 Kennedy 和 Eberhart 于 1995 年提出。该算法受鸟群觅食行为的启发，模拟粒子（个体）在解空间中的动态飞行，以寻找最优解。

其具有**高效性**，PSO 算法能够快速收敛，适合大规模优化问题，能够在较短时间内找到接近全局最优解。在面对不确定性时，PSO 通过粒子间的信息共享，**动态调整**搜索策略，适应环境变化。同时该算法参数相对较少，易于实现，适合**工程应用**。

PSO 的基本原理和流程如下：

Step1 粒子的表示：

每个粒子代表一个潜在的解决方案，其位置和速度在多维空间中变化。粒子的位置向量表示为：

$$x_i = [x_{i1}, x_{i2}, \dots, x_{id}]^T \quad (7-15)$$

其中， d 是问题的维度， i 是粒子的索引。

Step2 速度更新：

粒子的速度决定了其在解空间中的移动，更新公式为：

$$V_i(t+1) = \omega \cdot V_i(t) + c_1 \cdot r_1 \cdot (p_i - x_i(t)) + c_2 \cdot r_2 \cdot (g - x_i(t)) \quad (7-16)$$

其中， ω 是惯性权重，控制粒子前进的速度； c_1 和 c_2 是学习因子，影响粒子向个体最佳位置(p_i)和全局最佳位置的趋向， r_1 和 r_2 是 $[0,1]$ 之间的随机数，增加搜索的随机性。

Step3 位置更新：

粒子的当前位置根据其速度进行更新：

$$x_i(t+1) = x_i(t) + V_i(t+1) \quad (7-17)$$

Step4 适应度评估:

每次更新后，计算粒子的适应度值，更新个体最佳位置和全局最佳位置。

Step5 迭代过程:

算法持续迭代，直到达到预设的终止条件（如最大迭代次数或适应度阈值）




图 7-2 粒子群 PSO 算法流程图

鲁棒优化的目标是确保优化解在面对不确定性时仍具备良好的性能。在风电场的背景下，主要考虑两种不确定性因素：**测量噪声（如风速和功率指令的随机干扰）**和**通信延迟（信号传输的时延）**。为此，模型需处理不同情况下的损伤值，确保所选的功率调度指令在这些扰动下依然有效。

在本题中，我们的优化目标是**最小化风机系统的疲劳损伤**，包括主轴和塔架的损伤。目标函数定义如下：

$$\min_{\{P_{ref}^i(k)\}} F = \sum_{k=0}^{N_p-1} \left(\alpha_1 \frac{1}{N_t} \sum_{i=1}^{N_t} D_{shaft}^i(k) + \alpha_2 \frac{1}{N_t} \sum_{i=1}^{N_t} D_{tower}^i(k) \right) \quad (7-18)$$

在本模型中，PSO 被用来优化功率调度指令 P_{ref} 的选择。具体的步骤如下：

Step1 初始化粒子群:

随机生成一定数量的粒子，每个粒子的位置表示一种可能的功率调度方案，而速度则决定粒子在解空间中的移动方向和距离。

Step2 适应度评估:

对于每个粒子，根据鲁棒优化的目标函数计算其适应度，具体过程如下：

$$F(P_{ref}) = \left[\sum_{k=0}^{N_p-1} \left(\alpha_1 \frac{1}{N_t} \sum_{i=1}^{N_t} D_{shaft}^i(k) + \alpha_2 \frac{1}{N_t} \sum_{i=1}^{N_t} D_{tower}^i(k) \right) \right] \quad (7-19)$$

其中，E表示对随机扰动进行期望计算，确保粒子适应度评估充分考虑不确定性。

Step3 更新粒子位置与速度:

根据适应度评估结果，更新每个粒子的速度和位置。

Step4 迭代优化:

算法持续迭代，直到达到预设的终止条件，如最大迭代次数或适应度不再显著改善。

7.3.4 全局协调的分区域 MPC 鲁棒优化模型

随着风能的广泛应用，风电场的运行管理面临着多种挑战，包括通信延迟和测量噪声的影响。这些不确定性因素可能导致传统优化方法难以保证风电场有功功率的稳定输出。为了提高系统在复杂环境下的适应能力，本文提出了一种基于 Pareto 权重自适应的模型预测控制（MPC）鲁棒优化模型，旨在增强模型对不确定性因素的鲁棒性，并实现更优的控制效果。

1. Pareto 权重自适应 MPC 模型

在原有的基于 Pareto 权重自适应的 MPC 模型中，优化过程旨在平衡多目标，包括风电场的运行成本与输出功率的偏差。模型的目标函数可以表示为：

$$\min_{\{P_{ref}^i(k)\}} F = \sum_{k=0}^{N_p-1} \left(\alpha_1 \frac{1}{N_t} \sum_{i=1}^{N_t} D_{shaft}^i(k) + \alpha_2 \frac{1}{N_t} \sum_{i=1}^{N_t} D_{tower}^i(k) \right) \quad (7-20)$$

但是，在风电场的实际运营中，测量噪声和通信延迟可能导致数据失真和控制信号的滞后，从而影响优化效果。具体原因如下：

测量噪声：传感器在采集数据时常受到随机噪声的干扰，通常噪声范围为真实值的正负 10%。这种不确定性会导致优化决策的不可靠性。

通信延迟：在高速光纤环网中，数据传输可能受到网络拥塞的影响，导致最大延迟可达 10 秒。此时，控制策略仅能基于上一个正常通信时刻的数据进行优化，无法实时响应环境变化。

因此，引入鲁棒优化以应对这些不确定性显得尤为重要。

2. 鲁棒优化模型构建

鲁棒优化是一种针对不确定性决策问题的优化方法，旨在在面对各种扰动和不确定性条件下，确保解决方案的有效性和可靠性。其核心思想是通过考虑系统中存在的不确定性，优化设计和决策，使其在最坏情况下仍能满足性能要求。

不确定性建模

鲁棒优化的核心在于识别和描述模型中存在的不确定性。这些不确定性可以通过集合或区间来表示。设 x 为优化变量， d 为不确定参数，则可以用集合 D 表示不确定性：

$$d \in D$$

例如，假设测量误差可能在一个范围内波动：

$$d \in [d_{min}, d_{max}] \quad (7-21)$$

优化目标

鲁棒优化的目标是最小化最坏情况下的成本或风险。通常，目标函数表示为：

$$\max_x \max_{d \in D} f(x, d) \quad (7-22)$$

其中， $f(x, d)$ 是目标函数，反映了在不同不确定性情况下的性能。通过这一结构，鲁棒优化确保所选择的解在各种可能的扰动下均表现良好。

约束条件

在鲁棒优化中，约束条件需要保证在所有可能的扰动情况下都能满足。一般形式为：

$$g(x, d) \leq 0, \forall d \in D \quad (7-23)$$

这意味着约束条件不仅需要在确定性情况下成立，还需要在不确定性范围内也成立。

基于以上问题，我们在 Pareto 权重自适应的 MPC 模型基础上，引入鲁棒优化。新的模型结构如下：

$$\min J_{robust} = \max_{\epsilon \in \epsilon} \{F(\epsilon)\} \quad (7-24)$$

其中， ϵ 表示测量噪声，范围设定为 $|\epsilon| \leq 0.1|x(t)|$ ； ϵ 为噪声的可能取值集合，题目中取 $\pm 10\%$ 。

同时，为了并确保鲁棒优化模型的有效性，需添加以下约束条件：

(1) 功率分配误差约束

$$|P_{ref}^i - \bar{P}_{ref}^i| \leq 1MW + \epsilon_{error} \quad (7-25)$$

其中， ϵ_{error} 表示由于噪声引起的额外误差。

(2) 功率变化率约束

功率变化率约束也需要考虑鲁棒性，表示为：

$$|P_{ref}^i(k+1) - P_{ref}^i(k)| \leq \Delta P_{max} + \epsilon_{change} \quad (7-26)$$

其中， ϵ_{change} 是由外部因素引起的允许变化量。

表 7-1 MPC 鲁棒优化模型伪代码

MPC 鲁棒优化模型伪代码
#初始化参数
While true do
获取当前风速预测和测量数据
初始化疲劳损伤 D_{shaft}^i 和 D_{tower}^i
for k=0 to N_p-1 do
#计算平均功率参考值
$P_{avg} = P_t / N_t$

MPC 鲁棒优化模型伪代码

```
#计算参考功率范围
for i=1 to N_t do
    P_ref^i = P_avg + 随机噪声（例如±1 MW）
    确保 P_min^i ≤ P_ref^i ≤ P_max^i

#动态更新疲劳损伤
for i = 1 to N_t do
    ΔD_shaft^i(k+1) = 计算主轴疲劳损伤增量
    ΔD_tower^i(k+1) = 计算塔架疲劳损伤增量

    D_shaft^i(k+1) = D_shaft^i(k) + ΔD_shaft^i(k+1) + 随机噪声
    D_tower^i(k+1) = D_tower^i(k) + ΔD_tower^i(k+1) + 随机噪声

#计算目标函数 F
F = 0
for i = 1 to N_t do
    F += (α 1 * (D_shaft^i(k) + 随机噪声) + α 2 * (D_tower^i(k) +
随机噪声)) / N_t

#优化目标
min J_robust = max(ε ∈ E) { F }

#检查约束条件
确保 Σ P_ref^i(t) = P_t
确保 |P_ref^i(k+1) - P_ref^i(k)| ≤ Δ P_max

#更新控制指令
应用优化后的功率参考值 P_ref^i
end for

#反馈并调整
进行性能评估与鲁棒性验证

end while
```

7.4 算法求解与结果分析

7.4.1 算法求解

在风电场的 AGC 系统中，传感器数据的准确性对调度效率至关重要。然而，实际应用中，这些数据常受到随机噪声和通信延迟的影响，导致测量误差和调度决策的不准确性。测量噪声通常在正负 10% 的范围内，而最大传输延迟可达 10 秒。这使得在理想条件下建立的优化模型难以满足实际需求。

为了解决这一问题，我们构建了两个鲁棒优化模型，均结合了延迟补偿机制和卡尔曼滤波器。具体求解步骤如下：

Step 1 数据加载：

本题使用的数据均来源于附件 4，该数据文件为额外的十台风机的 300 秒测量数据（仅提供添加噪声以及延迟后的数据）。在两个模型中，首先通过 pandas 加载训练集和测试集的数据，分别提取功率调度指令、风速以及输出功率等信息。

Step 2 定义延迟补偿策略：

在模型中，延迟补偿策略通过结合历史数据和当前可用信息，动态调整优化参数，确保调度决策在通信延迟的情况下仍然有效。此策略能够减轻因数据传输延迟导致的调度误差。

Step 3 卡尔曼滤波去噪：

在两个模型中都引入卡尔曼滤波器，以降低传感器数据中的随机噪声影响。卡尔曼滤波通过对测量值进行加权估计，提高风速和功率的准确性，从而为后续的优化决策提供更可靠的输入。

Step 4 鲁棒优化目标函数：

在目标函数中，通过引入随机扰动模拟不确定性，并计算基于功率误差的损失值。该损失值为优化目标，多个试验的平均损失确保了模型在面对不同扰动时的鲁棒性。全局协调的分区域 MPC 和 PSO 模型均使用此目标函数进行求解。


Step 5 两种模型运行与比较：

最后，分别运行全局协调的分区域 MPC 鲁棒优化模型和基于粒子群算法的鲁棒优化模型。通过对比两种模型在相同测试数据下的优化效果，评估其在处理噪声和延迟方面的鲁棒性，进而得出更为有效的调度策略。

7.4.2 结果分析

1. 算法优化对比

下图展示了通过 PSO（粒子群优化）结合鲁棒优模型，优化后的功率输出（ P_{opt} ）在参考功率（ P_{ref} ）附近波动较小，优化明显减少了功率波动范围，功率输出更加接近目标值。PSO 和鲁棒优化显著提升了系统的稳定性和鲁棒性，有效减少了功率输出中的不稳定因素，特别是在训练集上的表现尤为突出，在测试集中依然能够很好地保持较高的性能，说明该优化策略成功提高了风机功率调度的精度和一致性。



下图展示了通过 MPC（模型控制预测）结合鲁棒优模型对风机功率输出进行优化的结果，优化后的功率输出（ P_{opt} ）在参考功率（ P_{ref} ）附近相比 PSO（粒子群优化）结合鲁棒优模型波动较大，功率输出较差。




图 7-4 MPC 功率输出波动图

2.所有风机的累积疲劳损伤总和优化前后对比




图 7-5 风机的累积疲劳损伤总和优化前后对比图

(1) 训练集塔架推力损伤对比（左上图）：

蓝色曲线表示“优化后的塔架推力损伤”，红色虚线表示“未优化的塔架推力损伤”。这两条曲线的累积损伤趋势非常接近，几乎完全重合。表明无论是优化还是未优化，塔架推力的损伤在训练集上的结果差别并不大。可推测，塔架的损伤在原始情况下就已经非常接近最优解，优化对其的改善可能有限，或者塔架推力的损伤对模型的敏感度较低。

(2) 测试集塔架推力损伤对比（右上图）：

绿色曲线表示“优化后的塔架推力损伤”，橙色虚线表示“未优化的塔架推力损伤”。在测试集上，这两条曲线也几乎完全重合，且曲线总体趋势是阶梯形状的。和训练集类似，

测试集中，优化和未优化的塔架推力损伤结果差别较小，阶梯形趋势可能反映了特定时间段内的损伤突然增加，表明可能在该时刻存在较大的外部力作用。

(3) 训练集主轴扭矩损伤对比（左下图）：

描述：蓝色曲线表示“优化后的主轴损伤”，红色虚线表示“未优化的主轴损伤”。未优化的损伤明显高于优化后的损伤，且红色曲线的上升速度比蓝色曲线快得多。表明：对于主轴扭矩的损伤，优化过程起到了显著作用。**未优化的主轴扭矩损伤快速累积**，表明在原始模型中，主轴受到了较大的损伤，而通过优化后，**损伤的累积速度显著减缓**，这表明优化在保护主轴方面有效。

(4) 测试集主轴扭矩损伤对比（右下图）：

绿色曲线表示“优化后的主轴损伤”，橙色虚线表示“未优化的主轴损伤”。未优化的损伤曲线高于优化后的损伤曲线，且两者的上升速度在一定时间后保持较稳定的趋势。在测试集上，主轴扭矩的损伤同样得到了一定程度的优化。虽然未优化曲线在早期损伤快速累积，但优化后的模型能有效减少主轴扭矩损伤的累积，特别是在初始阶段损伤减少明显。

优化在主轴扭矩方面有明显的效果，而塔架推力的优化效果并不显著。这也可能是由于塔架推力的损伤本来较小，优化空间较为有限。

3.优化前后各个风机的累积疲劳损伤程度

从塔架累积疲劳损伤的对比图 7-6 可以看出，优化策略对于减少风机塔架的疲劳损伤起到了限制作用。大多数风机在优化后，累积疲劳损伤曲线保持平稳没有明显上升的趋势，尤其是**未优化的风机 4**，累积疲劳损伤在 80 时间单位时出现了显著增加，说明在未进行优化的情况下，塔架的疲劳损伤累积会加剧，优化后的风机 4 表现出良好的疲劳损伤控制，证明**优化策略能够有效延缓累积疲劳损伤的增长**。




图 7-6 优化前后各个风机的塔架累积疲劳损伤对比图

主轴累积疲劳损伤对比图进一步验证了优化策略的有效性。图 7-7 中显示，优化后的风机主轴疲劳损伤保持在较低的水平。相比之下，未优化的风机（如风机 3 和风机 5）主轴疲劳损伤出现了一定的波动，损伤水平明显高于优化后的风机。未优化情况下的风机 5 表现尤为突出，其累积疲劳损伤在较早的时间段内就已经显现出较高的水平，说明主轴在未优化的情况下承受了更大的负荷和疲劳风险，优化后的风机能够维持较低的损伤水平，能够有效延长主轴的使用寿命。




图 7-7 优化前后各个风机的主轴累积疲劳损伤对比图

8 模型总结与评价

8.1 模型优点与创新

1.问题 1 模型优点与创新

实时性强：该模型采用了自适应动态三阶段滑动窗口算法，能够在 1 秒内完成风机主轴和塔架累积疲劳损伤的计算，满足了风电场实时监测的严格需求。这确保了系统能够即时响应风机运行状态的变化，提供及时的疲劳损伤评估。

提高计算效率：通过将应力时间序列分段处理，滑动窗口算法显著降低了计算负担，使得处理大量随机载荷数据变得更加高效。这种分段处理方法有效提升了整体计算速度，适应了高频率的数据输入需求。

提高准确性：结合改进的雨流实时计数模型，该方法能够准确捕捉应力循环中的峰谷值，提高了疲劳损伤计算的精度。精准的损伤累积评估有助于更好地预测风机部件的寿命，预防潜在的故障风险。

适应性强：自适应滑动窗口的设计使模型能够动态调整窗口大小，灵活应对不同载荷特征和变化的工况条件。这种适应性确保了模型在多种复杂运行环境下的稳定性和可靠性。

2.问题 2：模型优点与创新

高精度估算：模型采用了基于物理理论与数据驱动相结合的非线性回归模型，能够有效捕捉风速、功率与风机结构受力之间的复杂非线性关系，显著提升了受力估算的准确性。这为风机运行状态的监测和维护提供了更加可靠的科学依据。

适应复杂工况：通过多参数组合输入和分段拟合的方法，模型具备良好的适应性，能

够应对风速波动和复杂工况下的受力变化，广泛适用于不同类型和运行环境的风机。

3.问题 3：模型优点与创新

多目标优化能力强：该模型结合了 Pareto 前沿分析和模型预测控制（MPC）理论，能够同时优化多个目标，如降低疲劳损伤和满足电网调度指令，实现了各优化目标之间的有效权衡，提升了整体优化效果。

实时性满足：模型设计满足每秒实时计算的要求，能够在高维度优化问题中快速求解，适用于大规模风电场的实时调度需求，确保了系统的高效运行。

区域划分策略：根据风速波动特征进行区域划分，简化了复杂问题的求解过程，提高了优化效率和模型精度，确保了优化结果的科学性和实用性。

4.问题 4：模型优点与创新

增强系统鲁棒性：该模型引入了鲁棒优化方法，有效提升了模型在面对测量噪声和通信延迟等不确定条件下的稳定性和可靠性，确保了系统在复杂环境中的稳定运行。

有效处理噪声：采用卡尔曼滤波器对测量噪声进行处理，提升了观测数据的准确性，确保了模型输入数据的可靠性，从而提高了优化结果的精度和可信度。

延迟补偿机制：设计了专门的延迟补偿策略，减小了通信延迟对优化效果的影响，确保了系统的实时性和稳定性，使优化过程能够在存在延迟的情况下依然高效运行。

优化算法改进：结合改进的粒子群算法对模型参数进行优化，提高了优化求解的效率和精度，增强了模型在动态环境中的适应性和响应能力。

8.2 模型缺点与不足

针对问题 1：滑动窗口的大小和自适应策略的参数设置需要根据不同的运行环境和载荷特征进行优化调整。这增加了模型在实际应用中的**前期配置工作量**，需确保参数选择的准确性以维持模型性能。

针对问题 2：模型训练需要大量**高质量的历史数据**，数据的获取和质量控制可能存在一定的挑战，影响模型的训练效果和估算精度。这在数据收集和处理阶段可能增加工作量。若训练数据不足或不够全面，模型在面对未见过的极端工况时的估算精度可能下降，需要持续进行模型的更新和优化，以保持其泛化能力。

针对问题 3：模型在实际应用中需要**准确的风速预测数据**，若风速预测存在偏差，可能会影响优化调度的效果，降低整体优化的可靠性和准确性。模型的**参数设置和权重调整**需要根据具体风电场的运营情况进行细致调节，以确保优化结果的有效性和可靠性。这增加了模型在实际应用中的配置和维护工作量。

针对问题 4：在**极端通信环境**下，**延迟补偿机制**的效果可能受到限制，需进一步优化以适应更复杂的网络状况，确保模型在所有运行条件下的稳定性和可靠性。卡尔曼滤波器的参数设置需要根据具体应用场景进行**参数精确调整**，以确保噪声处理的有效性和优化结果的准确性。这在实际应用中可能需要更多的实验和验证工作。

参考文献

- [1] Cooley J W, Tukey J W. An algorithm for the machine calculation of complex Fourier series[J]. Mathematics of Computation, 1965, 19(90): 297–301.
- [2] Zhao J ,Zhang T ,Tang S , et al.Optimal Scheduling Strategy of Wind Farm Active Power Based on Distributed Model Predictive Control[J].Processes,2023,11(11):
- [3] Lin Z ,Chen Z ,Qu C , et al.A hierarchical clustering-based optimization strategy for active power dispatch of large-scale wind farm[J].International Journal of Electrical Power and Energy Systems,2020,121
- [4] Energy - Wind Farms; China Agricultural University Reports Findings in Wind Farms (Hierarchical Model Predictive Control Strategy Based On Dynamic Active Power Dispatch for Wind Power Cluster Integration)[J].Energy Weekly News,2020,
- [5] Fu B ,Zhao J ,Li B , et al.Fatigue reliability analysis of wind turbine tower under random wind load[J].Structural Safety,2020,87
- [6] Hussain A ,Sher A H ,Murtaza F A , et al.Improved Restricted Control Set Model Predictive Control (iRCS-MPC) Based Maximum Power Point Tracking of Photovoltaic Module.[J].IEEE Access,2019,7149422-149432.
- [7] M. Musallam and C. M. Johnson, “An Efficient Implementation of the Rainflow Counting Algorithm for Life Consumption Estimation,” IEEE Trans. Rel., vol. 61, no. 4, pp. 978–986, Dec. 2012.
- [8] J. Barradas-Berglind, R. Wisniewski, and B. Jayawardhana, “Model Predictive Control with Fatigue-Damage Minimization Through the Dissipativity Property of Hysteresis Operators,” European Journal of Control, vol. 54, pp. 140–151, Jul. 2020.
- [9] 董乐义, 罗俊. 雨流计数法及其在程序中的具体实现[J]. 计算机技术与应用,2004,24(3):38-40.
- [10] 王宏伟.雨流计数法及其在疲劳寿命估算中的应用[J].矿山机械, 2006, 34 (3) :95-97.
- [11] 景少伟,任子旭,魏书荣.考虑风机疲劳载荷分布的海上风电场有功功率优化调度[J/OL],1-12[2024-09-24].<http://kns.cnki.net/kcms/detail/12.1420.TM.20240130.1742.006.html>.
- [12] 杨伟峰,文云峰,李立,等.考虑疲劳载荷的风电场分散式频率响应策略[J].电力自动化设备,2022,42(04):55-62.DOI:10.16081/j.epae.202201003.
- [13] 路朋,叶林,汤涌,等.基于模型预测控制的风电集群多时间尺度有功功率优化调度策略研究[J],2019,39(22):6572-6583.DOI:10.13334/j.0258-8013.pcsee.190188.
- [14] 叶林,任成,李智,等.风电场有功功率多目标分层递阶预测控制策略[J].中国电机工程学报,2016,36(23):6327-6336+6597.DOI:10.13334/j.0258-8013.pcsee.152794.

附录 1：附件文件及内容

附件	命名
附件 1	问题一代码
附件 2	问题二代码
附件 3	问题三代码
附件 4	问题四代码
附件 5	附件 5-问题一答案表
附件 6	附件 6-问题二答案表
附件 7	问题三功率分配动图（含有计时器）

附录 2：部分代码

问题 1 关键代码

```
# 滑动窗口并行处理代码
import numpy as np
import pandas as pd
import time
from concurrent.futures import ProcessPoolExecutor
from three_point import rainflow_counting

# 固定的 S-N 曲线参数
C = 9.77e+70 # 固定 C 值
k = 10 # 固定 Wohler 指数 m = 10
N_design = 42565440.4361 # 设计寿命 N 值

# 单个滑动窗口计算函数 (含 Goodman 修正)
def compute_window_fatigue(window_data, Su=500000000):
    ranges, means, cycle_counts = rainflow_counting(window_data)
    goodman_amplitudes = ranges / (1 - means / Su)
    window_damage = 0
    for i in range(len(goodman_amplitudes)):
        N_F = C / (goodman_amplitudes[i] ** k)
        D_F = cycle_counts[i] / N_F
        window_damage += D_F
    return window_damage, goodman_amplitudes, cycle_counts
```

```

# 并行处理滑动窗口疲劳损伤
def sliding_window_fatigue_parallel(signal, window_size, step_size, max_workers=4,
Su=50000000):
    num_points = len(signal)
    total_damage = []

    tasks = []
    with ProcessPoolExecutor(max_workers=max_workers) as executor:
        for start in range(0, num_points - window_size + 1, step_size):
            end = start + window_size
            window_data = signal[start:end]
            tasks.append(executor.submit(compute_window_fatigue, window_data, Su))

    for task in tasks:
        window_damage, _, _ = task.result()
        total_damage.append(window_damage)

    return total_damage

# 计算每秒的疲劳损伤值
def calculate_fatigue_per_second(total_damage):
    fatigue_per_second = np.diff(total_damage) # 计算相邻窗口的差值
    return fatigue_per_second

# 计算每个风机的累积疲劳损伤值，并计算每秒的疲劳损伤值
def calculate_fatigue_with_fixed_params_parallel(force_data, window_size=14,
step_size=1, max_workers=4):
    total_damage = sliding_window_fatigue_parallel(force_data, window_size, step_size,
max_workers)

    # 计算每秒的疲劳损伤值
    fatigue_per_second = calculate_fatigue_per_second(total_damage)

    return fatigue_per_second

# 批量处理每个风机的数据并行
def process_all_turbines_parallel(dataframe, max_workers=4):
    results = {}
    window_size = 10 # 调整窗口大小以获取更多秒数

```

```

step_size = 1 # 保持步长为 1，以最大化秒数

for turbine in dataframe.columns[1:]: # 跳过时间列
    force_data = dataframe[turbine].values
    fatigue_per_second = calculate_fatigue_with_fixed_params_parallel(
        force_data, window_size, step_size, max_workers)

    # 将每台风机的每秒疲劳损伤保存到结果字典中
    results[turbine] = fatigue_per_second

return results

```

问题 2 关键代码:

```

#基于 Input1 分段拟合代码
import numpy as np
import pandas as pd
import matplotlib.pyplot as plt
from scipy.optimize import least_squares
from sklearn.preprocessing import StandardScaler
from sklearn.metrics import mean_squared_error, r2_score
import matplotlib

font = {'family': 'MicroSoft YaHei',
        'weight': 'normal',
        'size': '10'}
matplotlib.rc("font", **font)

# 定义多输入、多输出的物理约束模型
def multi_output_model_with_physical_constraints(X, params):
    Input1 = X[:, 0]
    Input2 = X[:, 1] # 风速
    State1 = X[:, 2] # 桨距角
    State2 = X[:, 3] # 低速轴转速
    State3 = X[:, 4] # 高速轴转速

    # 提取参数，确保数量为 35（增加了非线性项的参数）
    a, b, c, d, e, f, g, h, i, j, k, l, m, n, o, p, q, r, s, t, u, v, w, x, y, z, aa, bb, cc, dd, ee, ff, gg,
    hh, ii = params

    # 物理约束部分

```

```

rho = 1.225 # 空气密度 (kg/m^3)
A = 80 # 扫风面积, 假设叶片长度为 62.5 米
Cp = 0.4 # 功率系数的典型值

# 功率方程  $P = 0.5 * \rho * A * v^3 * C_p$ 
power_output_physical = 0.5 * rho * A * Input2 ** 3 * Cp

# 扭矩与转速关系  $P = T * \omega$  (功率等于扭矩乘以转速)
torque_physical = power_output_physical / (State2 + 1e-6)

# 确保 log 函数中的参数大于零
Input2 = np.where(Input2 <= 0, 1e-6, Input2)
Input1 = np.where(Input1 <= 0, 1e-6, Input1)

# 扭矩 (Torque): 增加更多的非线性项
torque = (a * Input1 + b * Input2 + c * State1 + d * State2 + e * State3
          + f * Input1 * State1 + g * Input2 * State2 + h * Input2 ** 2
          + i * Input1 ** 2 + j * Input1 ** 3 + k * State1 * State2 + l *
np.log(Input1 + 1)
          + m * np.log(Input2 + 1) + n * State1 ** 3 + o * Input1 ** 4 + p * State1
* State3
          + q * np.exp(Input1) + r * np.exp(Input2) + torque_physical)

# 推力 (Thrust): 增加更多的交互项和高阶项, 加入非线性函数
thrust = (t * Input1 + u * Input2 + v * State1 + w * State2 + x * State3
          + y * Input1 ** 2 + z * Input2 ** 2 + aa * State1 ** 3 + bb * Input1 *
State2
          + cc * Input2 * State1 + dd * State2 ** 2 + ee * Input1 ** 3 + ff * State1 *
State3
          + gg * np.log(Input1 + 1) + hh * np.exp(State2) + ii * Input1 * Input2 *
State2)

# 实际功率输出 (Power Output): 单独增加更多的高阶和交互项
power_output = (a * Input2 ** 3 + (1 - a) * (Input1 + State1 + State2 + State3)
                + f * Input1 * Input2 + g * State1 * State2 + h * Input1 ** 2
                + k * Input2 ** 4 + l * State2 ** 3 + m * Input1 * State1 * State2
                + n * Input2 ** 3 * State1 + t * Input1 * Input2 ** 2 + dd * Input2
** 5
                + bb * Input1 * Input2 * State2 + power_output_physical)

return torque, thrust, power_output

# 对低功率调度区间进行拟合
initial_guess = np.ones(35) # 假设有 18 个拟合参数

```

```
low_result, low_X_scaled, low_Y_combined = preprocess_and_fit(low_input1_data,
initial_guess)
```

```
# 对高功率调度区间进行拟合
high_result, high_X_scaled, high_Y_combined = preprocess_and_fit(high_input1_data,
initial_guess)
```

```
# 获取预测结果
def get_predictions(result, X_scaled):
    torque_pred, thrust_pred, power_output_pred =
multi_output_model_with_physical_constraints(X_scaled, result.x)
    return torque_pred, thrust_pred, power_output_pred
```

问题 3 关键代码:

```
import numpy as np
from scipy.optimize import minimize
import pandas as pd

# 加载电网调度指令和风速数据
grid_dispatch_data = pd.read_excel('电网调度指令.xlsx')
wind_speed_data = pd.read_excel('风速数据.xlsx')

# 取出电网调度指令和风速数据
P_t = grid_dispatch_data['电网调度指令'].values # 取出电网调度指令
wind_speeds = wind_speed_data.drop(columns=['Time']).values # 取出风速数据

# 固定的 S-N 曲线参数
C = 9.77e+70 # 固定 C 值
k = 10 # 固定 Wohler 指数

# 目标函数 (MPC 中最小化的目标函数)
def objective(P_ref):
    total_shaft_damage = 0
    total_tower_damage = 0

    # 对每台风机进行主轴和塔架的疲劳损伤计算
    for i in range(N_t):
        shaft_damage = rainflow_counting_and_fatigue(P_ref) # 主轴疲劳损伤
        tower_damage = rainflow_counting_and_fatigue(5 - P_ref) # 塔架疲劳损伤

        total_shaft_damage += w_shaft * shaft_damage
```

```

        total_tower_damage += w_tower * tower_damage

    return total_shaft_damage + total_tower_damage

# 约束条件：总功率等于电网调度指令，并限制功率上下界和分配偏差
def constraint_eq(P_ref, P_t):
    # 约束 1：所有风机的有功功率之和等于电网调度指令 P_t
    return np.sum(P_ref) - P_t

def constraint_ineq(P_ref, P_t):
    # 约束 2：风机的功率不能超过其额定值 5MW，且不能小于 0
    ineq1 = P_ref - P_min # P_ref >= P_min
    ineq2 = P_max - P_ref # P_ref <= P_max

    # 约束 3：各风机分配值与平均分配的偏差不能超过 1MW
    avg_P_ref = P_t / N_t # 平均分配功率
    ineq3 = np.abs(P_ref - avg_P_ref) - 1e6 # |P_ref - avg_P_ref| <= 1MW

    return np.concatenate((ineq1, ineq2, ineq3))

# 风机参数
N_t = 100 # 风机数量
P_max = 5e6 # 单台风机最大功率（5 MW 转换为瓦特 5,000,000 W）
P_min = 0 # 单台风机最小功率
w_shaft = 0.5 # 主轴疲劳损伤权重
w_tower = 0.5 # 塔架疲劳损伤权重

# 主控制循环（MPC 框架，每秒钟优化一次）
for t in range(len(P_t)):
    # 使用初始调度指令的平均值作为功率参考初始值，并加入较小的扰动
    P_ref_initial = np.full(N_t, P_t[t] / N_t) # 初始均分
    P_ref_initial += np.random.uniform(-0.1e6, 0.1e6, N_t) # 添加较小的扰动，保持平
滑度

    # 优化设置
    constraints = [{'type': 'eq', 'fun': lambda P_ref: constraint_eq(P_ref, P_t[t])}, # 对应
当前秒的调度指令
                    {'type': 'ineq', 'fun': lambda P_ref: constraint_ineq(P_ref, P_t[t])}]

    # 执行优化
    res = minimize(objective, P_ref_initial, constraints=constraints, tol=1e-4,

```

```
options={'maxiter': 50})
```

```
# 计算得到的最优功率分配
P_ref_optimal = res.x

# 更新初始参考值为优化后的结果，作为下一秒的初始功率分配
P_ref_initial = P_ref_optimal

# 打印当前时刻的优化结果
print(f'Time {t}: Optimal Power Distribution {P_ref_optimal}')
```

问题 4 关键代码:

```
#MPC+鲁棒模型:
import numpy as np
import matplotlib.pyplot as plt
import pandas as pd

# 1. 加载数据
file_path_train = 'D:/24 数模/A 题/附件 3 提取数据_last_100_seconds.xlsx'
file_path_test = 'D:/24 数模/A 题/附件 4-噪声和延迟作用下的采集数据.xlsx'

train_data = pd.read_excel(file_path_train, sheet_name=0, header=0)
Pref_train = train_data['Input1'].values
Vwin_train = train_data['Input2'].values
Pout_train = train_data['Output3'].values

Vwin_test = pd.read_excel(file_path_test, sheet_name='Vwin',
header=None).values.flatten()
Pref_test = pd.read_excel(file_path_test, sheet_name='Pref', header=None).values.flatten()
Pout_test = pd.read_excel(file_path_test, sheet_name='Pout', header=None).values.flatten()

# 2. 鲁棒优化目标函数，加入扰动和不确定性
def robust_objective(P_ref, Vwin, uncertainty_level=0.1, num_trials=10):
    total_loss = 0
    for _ in range(num_trials):
        wind_speed_perturbed = Vwin * (1 + np.random.uniform(-uncertainty_level,
uncertainty_level, Vwin.shape))
        # 假设简单的功率误差损失为目标，当然你可以根据需求替换为其他目标
        loss = np.sum((P_ref - wind_speed_perturbed) ** 2)
```

```

        total_loss += loss
    return total_loss / num_trials

# 3. MPC 控制器，结合鲁棒优化
def mpc_robust_control(Pref, Vwin, P_init, Np=10, uncertainty_level=0.1):
    P_ref_optimal = np.copy(P_init)
    for t in range(len(Pref) - Np):
        P_current = P_ref_optimal[t]
        P_pred = np.zeros(Np)

        for k in range(Np):
            wind_speed_perturbed = Vwin[t + k] * (1 +
np.random.uniform(-uncertainty_level, uncertainty_level))
            P_pred[k] = P_current # 简化预测，这里可以替换为更复杂的预测模型

            # 鲁棒性优化，通过控制误差和约束
            P_ref_error = np.abs(P_pred[k] - Pref[t + k])
            if P_ref_error > 1e6: # 假设最大允许误差为 1MW
                P_pred[k] = Pref[t + k]

            if k > 0:
                delta_P = np.abs(P_pred[k] - P_pred[k - 1])
                if delta_P > 1e6: # 假设最大功率变化率为 1MW
                    P_pred[k] = P_pred[k - 1] + np.sign(P_pred[k] - P_pred[k - 1]) *
1e6

        # 对每一时刻使用鲁棒优化目标
        P_ref_optimal[t:t + Np] = P_pred
    return P_ref_optimal

```