



中国研究生创新实践系列大赛
“华为杯”第二十一届中国研究生
数学建模竞赛

学 校 西北农林科技大学

参赛队号 24107120016

1.杨磊

队员姓名 2.林炅

3.刘冠麟

中国研究生创新实践系列大赛

“华为杯”第二十一届中国研究生

数学建模竞赛

题 目： 风电场有功功率分配优化模型

摘 要：

在风电场中，风机有功功率的分配将会影响其疲劳损伤的累计，这与风机的运维成本、发电效率和安全风险息息相关。因此，设计出一种有效的风电场有功功率分配优化模型，减少风机的疲劳损失具有重要的现实意义。

基于题目中有功功率分配和疲劳损伤的理论以及附件中实际数据，本文设计了一种基于风机主轴和塔架疲劳损伤的有功功率分配优化模型。首先，本文通过分析雨流计数法实时性的不足，提出了一种基于滑动窗口的疲劳损伤量化模型，通过对局部荷载的分析有效计算了实时疲劳损伤。其次，本文根据能量守恒和空气动力学原理，提出了一种更符合现实情况的主轴扭矩和塔架推力的估计模型，实现了从风速和有功功率到荷载的转化。基于此，本文根据实时的风速条件构建了基于风电场总体疲劳损失的最小化单目标优化模型，以规划有功功率的分配方式。同时，本文设计了一种具有繁殖约束的遗传算法用于求解上述优化模型，并获得了良好的效果。此外，考虑到现实场景中的噪声与通信延迟问题，本文提出了一种基于卡尔曼滤波的风速去噪模型和基于长短期记忆（LSTM）网络的传输延迟预测模型，提升了有功功率分配优化模型的鲁棒性和抗干扰性。

针对问题一，要求建立能够实时计算风机的主轴和塔架任意时段累积疲劳损伤程度的数学模型；计算给定时间段的累积疲劳损伤并分析其与雨流计数法所得结果的相似程度。本文首先通过滑动窗口识别应力，然后基于 Goodman 修正公式和 Palmgren-Miner 理论对应力幅值和均值进行处理，得到累计疲劳损伤。其次，本文采用了滑动窗口和向量化计算的方式，极大地降低了疲劳损伤的计算复杂度。最后，本文计算了 100 台风机的最大扭矩和塔架的累计疲劳损伤并与雨流计数法所得结果进行了比较，验证了算法的有效性和实时性。

针对问题二，要求建立能够根据风机所处位置的风速条件和功率参考值估计当前风机所承受的推力和扭矩；估算给定风机任意时刻的推力和扭矩值并与参考值进行对比。首先，本文调研了符合题目描述的风机型号，确定了关键参数的设计和取值范围。其次，本文通过对风机状态和受力的分析，构建了塔架推力和最大扭矩的估计模型。通过比较估计值与参考值的均值与幅值差异，发现估计模型在时间维度上的错峰现象和尺度异常。基于此，本文引入时滞补偿机制和尺度变化因子优化了上述估计模型，实现了良好的效果。最后，本文计算了附件中风机塔架推力和最大扭矩，并基于误差平方和（SSE）与参考值进行了比较。

针对问题三，要求构造基于主轴和塔架的疲劳损伤的最小化目标函数；要求构建低复杂度的有功功率分配的优化模型，并展示其实时性；要求计算满足约束条件的优化结果并与优化前（平均分配功率）的结果进行对比。首先，本文结合问题一和问题二的分析过程，建立了表示主轴和塔架疲劳损伤的**目标函数**，并在此基础上设计了代表单台风机和所有风机总体疲劳损伤的**最小化目标**。随后，本文建模了题目中给定的**约束条件**并且将有用功率的分配转化为了**权重系数**的划分。在此基础上，本文设计了一个带有约束的**有功功率分配优化模型**并且提出了一种具有**繁殖约束的遗传算法**用于实时求解该模型。此外，本文基于疲劳损伤和有功功率的方差设计了五个指标来评估优化结果的性能。最后，本文展示了求解优化模型的**时间**和**实时性**，并且比较了附件二中的原始数据、平均分配功率和优化后分配功率的 CD^i , ACD , PV_j , R , APV 值，验证了模型和算法的**有效性和低复杂度**。

针对问题四，要求考虑随机测量噪声和通信延迟对于模型精度和优化问题最优性的影响，完善问题三中的优化方案；要求以附件中的数据作为测试集验证模型的鲁棒性；要求展示比对优化效果以及所建模型对噪声和延迟的抑制能力。首先，本文结合问题中的描述分析了噪声数据和通信延迟的来源与特性。对于噪声，本文构造了基于**滑动平均滤波**、**Savitzky-Golay 滤波**和**卡尔曼滤波**的去噪模型。对于通信延迟，本文设计了一种基于**变化率的传输延迟检测模型**来识别延迟。此外，本文将延迟信号的预测建模为了**时间序列预测任务**，采用了**简单移动平均预测模型**、**差分自回归移动平均（ARIMA）预测模型**和**LSTM 预测模型**根据已有数据来预测延迟的信号。基于此，本文优化了问题三中有功功率的分配优化方案，对附件四中的数据去噪和延迟预测后进行分配优化。为验证所提出的模型的鲁棒性，本文基于附件四中的数据构造了五种有功功率的分配方式，通过计算五种方式的 CD^i , ACD , PV_j , R , APV 值，展示了优化效果以及所建模型对噪声和延迟的抑制能力。

关键词：滑动窗口，局部荷载，Goodman 修正公式，Palmgren-Miner 理论，时滞补偿机制，具有繁殖约束的遗传算法，卡尔曼滤波，LSTM

目录

一：问题重述	5
1.1 问题背景	5
1.2 问题重述	5
二：模型假设	7
三：关键性符号说明	8
四：问题一的模型建立与求解	9
4.1 问题的描述与分析	9
4.2 模型假设	10
4.3 详细符号说明	10
4.4 数学模型的建立	10
4.4.1 数据获取与预处理	10
4.4.2 滑动窗口法应力识别	11
4.4.3 累计疲劳损伤计算	12
4.4.4 实时计算优化	13
4.5 模型求解与分析	13
4.5.1 模型求解流程	13
4.5.2 模型结果分析	14
五：模型二的模型建立与求解	16
5.1 问题描述与分析	16
5.2 模型假设	16
5.3 详细符号说明	17
5.4 数学模型的建立	17
5.4.1 风机参数	17
5.4.2 风机状态与受力分析	19
5.4.3 主轴扭矩与塔架推力估算	19
5.5 模型求解与分析	20
5.5.1 模型求解流程	20
5.5.2 模型结果与分析	20
六：问题三的模型建立与求解	27
6.1 问题的描述与分析	27
6.2 模型假设	28
6.3 详细符号说明	28
6.4 数据来源与预处理	29
6.5 数学模型的建立	29
6.5.1 单台风机的疲劳损伤	29
6.5.2 所有风机的总体疲劳损伤程度	29
6.5.3 有功功率的约束条件	29
6.5.4 有功功率分配方式	30
6.5.5 有功功率分配模型	30
6.6 模型的求解及分析	31
6.6.1 具有繁殖约束的启发式遗传算法	31
6.6.2 评估指标的设计	32

6.6.3 问题的求解	33
七：问题四的模型建立与求解	38
7.1 问题描述与分析	38
7.2 模型假设	39
7.3 详细符号说明	40
7.4 问题四的模型建立	40
7.4.1 风速去噪模型	40
7.4.2 传输延迟预测模型	42
7.5 模型求解与回答	43
7.5.1 风速去噪：	44
7.5.2 传输延迟预测	44
7.5.3 风机有功功率的优化分配	47
7.6 问题的求解与优化效果	47
7.6.1 风速去噪效果	47
7.6.2 传输延迟预测效果	48
7.6.3 有功功率分配效果	49
八：模型评价	51
8.1 模型的优点	51
8.2 模型的缺点	51
8.3 展望	51
九：参考文献	52
十：附录	53

一：问题重述

1.1 问题背景

大型风机、大规模场站的投入促使我国风电快速发展，然而高容量的大型风机因机械部件柔性较高，容易在运行过程中加速累积疲劳损伤，导致维护成本增加，发电效率降低，甚至会引发风机倒塌、叶片断裂等安全事故。目前，风电场主要依赖电网调度指令对风机进行功率分配，降低风机运行过程中累积疲劳损伤的方式多采用平均分配方式，根据风电场风机数量平均分配发电任务。然而，这种方法未能考虑到各风机运行状态与疲劳损伤的关系，导致部分风机长时间处于高负荷运行状态，加速机械部件的疲劳损伤。虽然已有风电场基于风机健康状态来改进功率分配策略，但仍然存在一定的局限性。因此，建立更加合理的功率分配方案，降低风机疲劳损伤，显得尤为重要。这不仅有助于提高风电场的发电效率、降低其维护成本，更符合可持续发展的要求，为我国风电产业的长期健康发展提供有力支持。




图 1.1 风电场信号传输示意图

1.2 问题重述

基于上述研究背景，本文需研究和解决如下问题：

问题一：风机主轴及塔架疲劳损伤程度量化指标计算低复杂度模型

在实际风电场应用中，风机主轴扭矩和塔架推力的载荷数据随机性强，周期不规则。

虽然目前常用的雨流计数法可以统计不同幅值载荷循环次数，但无法实现在线实时求解，无法保证数据的时效性。因此，实现对风机主轴和塔架在任意时段内累积疲劳损伤的实时计算十分重要。本题根据 100 个风机在 100 秒内的主轴扭矩和塔架推力数据以及雨流计数法计算结果，建立一个数学模型，在 1.00 秒内反映当前条件下累积疲劳损伤程度，并将结果与雨流计数法进行对比验证，确保方法的正确性。

问题二：利用风速及功率估算塔架推力和主轴扭矩

在实际应用中，疲劳损伤主要是由主轴扭矩和塔架推力产生的，而风速与风机发电功率呈正相关关系，当风速相对于发电功率过高时，风机会承受多余的风能，导致主轴扭矩和塔架推力增加，从而加剧累积疲劳损伤。因此，利用实时的风速和功率数据估算主轴扭矩与塔架推力是十分重要的。本题以 2 个风场内共计 200 个风机在 2000s 内的实时数据作为参考，利用受力分析与能量守恒建立数学模型，计算实时主轴扭矩与塔架推力，并与参考值进行对比，确保模型的有效性。

问题三：有功调度优化问题构建与实时求解

有功功率的优化分配在风电场运行中至关重要，尤其是当风电场规模达较大时，优化计算必须每秒进行一次，以确保实时性和响应能力。根据实际工程中的一般经验，风电场内的风机通常型号相同，模型参数一致，主要差异体现在轮毂处的风速条件和调度功率。从本质上来看，为了降低运维成本，基于不同风机所处位置的风速条件，我们需要让每种元件的疲劳损伤平均值最小、或疲劳损伤最严重的元件的疲劳值最小，从而使得主轴和塔架的两种元件的疲劳损伤程度最小化，同时满足电网调度指令不超过 1MW。本题根据附件 2 中的功调度指令的时序数据及实测风速数据建立合理的数学模型，以给出合理的有功功率分配策略，同时将优化前后的结果进行对比，验证模型的准确性。

问题四：考虑通信延迟和测量噪声的有功功率优化与求解

在实际风电场中，AGC 系统依赖多种传感器收集信号，并通过高速光纤环网将数据传输至集控中心。然而，风电场内传感器所接收或传输的数据常受到噪声干扰，同时，通信过程中的协议层和物理层也可能因传输拥塞而引起随机延迟，造成部分时间段内数据无法及时获取。本题中，我们需要改进问题三中的优化方案，利用附件 2，附件 3 中的数据建立去噪模型，利用附件 2，附件 4 中的数据建立预测模型，最后先后利用两个模型完成对实际值的预测，并进行优化前后数据质量的对比。

二：模型假设

- (1) 假设附件中提供的模拟数据是可靠的。
- (2) 假设环境参数温度与气压保持稳定。
- (3) 假设材料疲劳特性在整个运行过程中保持不变。
- (4) 假设风机主轴和塔架受载荷数据在短时间内的变换可视为线性，即在短时间内应力幅值和均值变换较小。
- (5) 假设空气流动没有湍流影响，风在叶片上的扫风面积均匀一致。
- (6) 假设风机相邻时刻之间疲劳损伤不存在时间依赖性。

三：关键性符号说明

关键性符号说明见表 3-1：

表 3-1 符号说明


符号	说明
P_t	电网调度指令
P_{ref}^i	每台风机的功率指令
W_t	场内所有风机数量
N_F	最大循环次数
S	材料受到的应力幅值
n_F	实际应力循环次数
D_F	累积疲劳损伤值
V_w^i	各风机轮毂处等效风速
T_s^i	风机轴系扭矩
F_t^i	风机塔顶推力
N_t	风机总数量
t	时间
P_{out}^i	每台风机的产出的实际功率
β	桨距角
ω_r	低速轴转速
ω_{fs}	高速轴转速

四：问题一的模型建立与求解

4.1 问题的描述与分析

风机的核心结构主要包括主轴、叶片和塔架等关键部件，这些部件在运行过程中长期承受着风载荷、重力、离心力等多种力的作用，尤其在多变的风况和环境下，承受的载荷具有强烈的随机性和非线性特征。这些载荷会对风机的主轴和塔架造成持续的疲劳累积，最终导致材料性能的退化甚至断裂。准确评估风机主轴和塔架的疲劳损伤情况，对于延长风机寿命、减少维护成本以及保障风机运行安全具有重要意义。

风机主轴和塔架的疲劳损伤是一个典型的多轴随机载荷作用下的疲劳问题。疲劳损伤评估的本质核心在于对载荷循环次数和幅值的准确统计。常用的疲劳损伤评估方法包括雨流计数法^{[1][2]}、线性累积损伤理论等。其中，传统雨流计数法^[10]是一种常见的应力分析方法，广泛用于风机疲劳寿命预测中，能够有效识别载荷信号中的循环信息。然而，在风机运行过程中，主轴扭矩和塔架推力的载荷数据表现出明显的随机性和非标准周期性，雨流计数法难以辨识波峰和波谷由于其计算复杂度高，且载荷循环的周期时长远远超过了实时计算的时间间隔（1s），使得在线实时计算疲劳损伤成为一大挑战。因此，需要一种能不在依赖完整载荷循环的情况下，利用滑动窗口技术来对实时载荷进行计算的模型。



4.2 模型假设

- (1) 材料疲劳特性在整个运行过程中保持不变。
- (2) 风机主轴和塔架受载荷数据在短时间内（滑动窗口内）的变换可视为线性，也即是在短时间内应力幅值和均值变换较小。
- (3) 累积损伤遵循 Palmgren-Miner 线性累积损伤理论，疲劳损伤是可以直接相加的。
- (4) 使用 Goodman 修正方法，将应力幅值转换为等效幅值时，材料的拉伸强度极限是已知且固定的。

4.3 详细符号说明

表 4-1 符号说明

符号	说明
S_{ai}	第一步中计算的第 i 个窗口的荷载幅值
S_i	等效均值为 0 时第 i 个窗口的载荷幅值
S_{mi}	第一步中计算的第 i 个窗口的均值
σ_b	材料在拉伸断裂时的最大载荷值 (本题中两种元件均为 50000000)
C	常数 (本题取 9.77×10^{70})
N_i	第 i 个窗口等效载荷对应的最大循环载荷次数
m	Wohler 指数 (本题取 10)
D_{Fi}	第 i 个窗口的损伤增量
D_i	第 i 时刻下的累积疲劳损伤程度

4.4 数学模型的建立

在本研究中，为了建立一个低复杂度的模型用于评估风机主轴及塔架的疲劳损伤^[5]程度，我们结合了雨流计数法、Goodman 修正公式以及 Palmgren-Miner 线性累积损伤理论，采用滑动窗口法处理实时载荷数据，从而实现疲劳损伤的实时评估。具体步骤如下。

4.4.1 数据获取与预处理

在模型建立的第一步，首先需要从已有的表格中对表格数据进行清洗，获取进行处理和分析所需要的数据，从中分别提取风机主轴扭矩和塔架推力在 100 秒时间内的实时载荷数据。这些数据通常以时间序列的形式存储在 excel 文件或数据库中，将数据转换为适合处理的格式，以便后续分析，图 4.2 是在 100 秒时间下一号风机的主轴扭矩和塔架推力的载荷数据，容易观察到，所提取的数据随机性强，周期不标准，难总结出客观规律。




图 4.2 获取的 100 秒内主轴扭矩和塔架推力的实时荷载数据


4.4.2 滑动窗口法应力识别

滑动窗口法是本模型的核心部分，通过设定的固定大小的滑动窗口在数据序列中逐步滑动以捕捉局部的应力的变换，并通过计算每个窗口范围内的应力幅值、应力均值和应力循环次数，我们能够进一步计算该窗口范围内的疲劳损伤。滑动窗口的大小设置至关重要：窗口过小可能导致对瞬时信息的捕捉不足，而窗口过大则可能丢失重要的应力特征变化。经过多次实验与调整，我们确定最佳的滑动窗口大小 T 为 10 秒，能充分捕获应力的特征变化。


然而，滑动窗口法在数据序列的起始几秒钟存在一定的缺陷，因为在这段时间内，数据量不足以有效捕捉应力的变化。因此，我们提出了使用三角函数对应力序列进行简单拟合预测的方法。三角函数能够更好地模拟周期性变化，适用于具有明显周期性特征的应力数据。采用三角函数拟合模型，我们可以表示应力序列如公式 (4.1)。

$$f(x) = a_n \cos nx + b_n \sin nx \quad (4.1)$$

图 4.3 是对风机 1 的主轴扭矩和塔架推力的前 T 个数据进行拟合，并向前预测 T 个数据，用于初始的窗口计算。



(a) 风机 1 的主轴扭矩数据预测结果



(b) 风机 1 的塔架推力数据预测结果

图 4.3 对 1 秒前的荷载数据进行拟合预测

在滑动窗口法中，我们希望获得每一秒瞬时的疲劳损伤，这需要对每一时刻窗口内的应力数据进行分析。在这个过程中，窗口会覆盖当前时刻及其前后一定范围内的应力数据，从而捕捉到该时刻的应力变化特征。流程示意图如图 4.4。




图 4.4 窗口移动法示意图

设定一个窗口大小为 T ，窗口内的数据序列为 $\sigma(t_i)$ ，我们便能通过计算得到该窗口内的荷载幅值以及荷载均值，如公式（4.2），（4.3）：

$$S_{ai} = (\max(\sigma(t_i)) - \min(\sigma(t_i)))/2 \quad (4.2)$$

$$S_{mi} = \frac{1}{T} \sum_{i=1}^N \sigma(t_i) \quad (4.3)$$

4.4.3 累计疲劳损伤计算

在识别出每个窗口的应力幅值、应力均值后，我们可以基于 Goodman 修正公式和 Palmgren-Miner 理论进行累计疲劳损伤的计算。具体步骤包括：

(1) Goodman 修正。

Goodman 曲线修正考虑平均载荷对疲劳^[6]寿命的影响。传统的 S-N 曲线通常假设平均载荷为零的情况，但在实际工程中，例如本模型中所评估的风车主轴和塔架，在发电期间会受到非零平均载荷的作用。为了更准确地评估在这种情况下的疲劳寿命，必须对原有的 S-N 曲线进行修正。常用的方法便是 Goodman 曲线修正，其修正公式如公式（4.4）所示。

$$S_i = S_{ai} / (1 - \frac{S_{mi}}{\sigma_b}) \quad (4.4)$$

(2) 确定应力幅值对应的疲劳循环次数。

在经过修正后，我们在使用 S-N 曲线，来求得窗口应力幅值对应的疲劳循环次数，将第二步中的经过 Goodman 修正的各级载荷幅值代入 S-N 曲线公式（4.5），可得对应的最大循环载荷次数。

$$N_i = C / S_i^m \quad (4.5)$$

(3) 瞬时疲劳损伤计算。

使用 Palmgren-Miner 法则计算每个窗口的损伤增量。根据 S-N 曲线确定每个窗口应

力幅值对应的疲劳循环次数 N_i ，然后计算该窗口的损伤增量 D_{Fi} ，如公式（4.6）。

$$D_{Fi} = \frac{n_{Fi}}{N_i} \quad (4.6)$$

(4) 累积损伤。将每个窗口的损伤增量累加求和，得到当前时刻的累计疲劳损伤值，如公式（4.7）。 i 时刻的总损伤累积值 D_i 为各个应力水平（ $F_1, F_2, \dots, F_i$ ）下的累积损伤值之和，当总损伤累积值 D_i 达到 1 时，材料即发生疲劳失效。

$$D_i = \sum_{t=1}^i D_{Ft} = D_{F1} + D_{F2} + \dots + D_{Fi} \quad (4.7)$$

4.4.4 实时计算优化

为了简化计算，提高模型的实时计算性能，我们对所建立的模型的计算过程进行优化，具体措施如下：

1. 向量化计算。在 MATLAB 中对应力幅值、应力均值、Goodman 修正后的幅值计算和损伤增量等步骤进行了向量化处理。通过使用向量化操作，如 $\max()$, $\min()$, $\text{mean}()$, 和 $./$ ，可以一次性处理整个数据集，而不是逐个循环处理每个数据点，极大地提高了计算效率

2. 滑动窗口法。通过在循环中使用固定长度的滑动窗口（ T ）来处理塔架推力和主轴扭矩数据，每次只处理最新的载荷数据，避免了对全局数据的重复计算。这种方法有效地减少了计算量，使得每个时间步的计算更加高效。

3. 避免重复计算。在累积损伤计算过程中，直接使用前一时刻累积的结果，并将当前增量累加上去，避免了重复计算已有数据。这使得算法更加高效，并能实时更新疲劳损伤值。

这些优化措施结合起来，显著提高了代码的执行效率，使得模型能够在每秒时间步内快速完成对 100 台风机的 200 个元件的实时疲劳损伤计算，确保计算时间远小于 1 秒，满足了实时计算的要求。

4.5 模型求解与分析

为了清晰地阐述风机主轴及塔架疲劳损伤程度量化指标的实时计算过程，本部分将通过流程图和详细的描述来展示模型求解的步骤和分析结果。

4.5.1 模型求解流程

在本节中，我们详细描述了模型的求解流程，整个过程概括为数据预处理，荷载序列三角拟合-预测，以及滑动窗口法计算累计疲劳损伤三个主要步骤，流程图如图 4.5 所示。




图 4.5 模型求解流程图

首先我们从 excel 表格中读取 100 台风机的 100 秒时间序列及其对应的主轴扭矩和塔架推力数据，初始化瞬时疲劳损伤矩阵和累积疲劳损伤矩阵，利用三角函数来拟合两个荷

载序列，用于预测计算开始前的序列波形用于窗口滑动法的初始窗口数据。

接着，采用滑动窗口法对数据进行处理，以模拟实际环境中应力的变化过程。在每一个时间点，滑动窗口提取当前数据序列，计算窗口内的应力幅值和均值，并根据 Goodman 公式进行修正，并结合 Palmgren-Miner 法则，求得该时刻的损伤增量。随着时间的推移，累积疲劳损伤值逐渐增加，记录到累积损伤矩阵中，算法 4.1 给出了基于滑动窗口法的风机元件累计疲劳损伤程度实时计算算法伪代码。

算法 4.1: 基于滑动窗口法的风机元件累计疲劳损伤程度实时计算

输入: 主轴扭矩,塔架推力, 时间, 窗口大小 T , 风机数量等参数

输出: 荷载的累计疲劳损伤

```
1: 初始化瞬时疲劳损伤矩阵, 累积疲劳损伤矩阵
2: for 每台风机 do
3:   反转主轴扭矩和塔架推力两个荷载序列
4:   用公式 (4.1) 拟合两个荷载序列, 并预测窗口大小  $T$  个数据
5:   再次反转两个荷载序列, 作为滑动窗口法的输入
6:   for 每个窗口 do
7:     根据公式 (4.2) (4.3) 计算窗口应力幅值, 应力均值
8:     根据公式 (4.5) 进行 Goodman 修正,
9:     根据公式 (4.6) 计算增量疲劳损伤, 并根据公式 (4.7) 更新累计疲劳损伤
10:  end for
11: end for
```

4.5.2 模型结果分析

(1) 风机主要元件累积疲劳损伤程度与传统雨流计数法对比

通过对 100 台风机的 主轴扭矩和塔架推力进行 累计疲劳损伤分析，我们采用了对数坐标图来展示结果，这种方法有效地证明了模型的可靠性。如图 4.6 所示，在对数尺度下，累积疲劳损伤值的增长趋势变得更加明显，尤其适合于处理不同风机损伤值差异较大的情况。此外，我们将这些结果与传统的雨流计数法进行了对比分析，发现虽然两者的结果并不完全相同，但增长趋势是一致的。这表明我们提出的模型能够准确捕捉风机疲劳损伤的变化趋势。

该模型在横向对比风机时，能够准确地反映累计疲劳损伤程度的变化，这为风电场的运维和风机健康状态的评估提供了一个更为精确的工具。总体而言，模型显示出了较高的准确性和解释力，能够有效地监测风机在长期运行过程中的疲劳损伤，为风电行业的维护和评估提供了重要的参考。




图 4.6 100 台风机各元件累计疲劳损伤结果与数据中提供的雨流计数法所得结果的相似程度对比

（2）风机主要元件累积疲劳损伤程度的增长过程

我们选取了 6 个具有代表性的风机样本，并对它们在 0-100s 时间段内的主要元件（主轴扭矩和塔架推力）的累积疲劳损伤程度进行了详细跟踪与展示。如图 4.7 所示，这些样本代表了风机运行状态的不同情形，包括疲劳损伤增长较快的样本、增长平稳的样本以及在运行过程中发生明显波动的样本。




图 4.7 代表性风机主要元件 0-100 秒内的累计疲劳损伤程度增长过程

通过曲线图，展示了每个代表性样本在 0-100s 时间范围内累积疲劳损伤程度的增长趋势。曲线的纵轴表示累积疲劳损伤值，横轴表示时间（秒）。这些曲线清晰地反映了疲劳损伤的增长速率及变化规律。观察发现，所有样本的疲劳损伤程度均呈现累积增长的趋势，验证了模型对疲劳损伤累积过程的有效捕捉。例如，风机 9 和风机 19 的累计损伤增长较为迅速，说明它们在该时间段内经历了较大的应力循环；风机 89 和风机 100 的累计损伤呈阶梯状，说明他们在周期性的经历应力循环；而风机 39 和风机 69 的累计损伤较为平稳，代表了正常运行状态。

（3）算法运行时间和有效性分析

在对 100 台风机主轴扭矩和塔架推力进行累计疲劳损伤的分析中，算法的运行时间主要耗费在三角拟合部分。具体而言，在 100 台风机、100 秒数据的情况下：三角拟合共耗时约 12 秒。然而，由于三角拟合只需要在算法的初始阶段执行一次，它不会成为实时性瓶颈。初始拟合完成后，后续数据处理将无需再次执行此高复杂度操作。滑动窗口法运行时间仅为 0.7 秒，体现了该方法在应力幅值和均值捕捉方面的高效性。由于三角拟合仅在初始时刻进行，后续的数据处理完全满足实时要求，整个算法在每秒内能够快速完成对新数据的处理，确保了计算时间小于 1.00 秒。

通过对 5 个代表性样本的分析，我们可以进一步说明所提出的建模方法在所有样本中都能有效地捕捉到风机的疲劳损伤增长过程。经过对 100 台风机的全面数据分析，发现该模型在各样本中均展现出稳定的拟合效果，说明模型不仅能适应多台风机的疲劳损伤特性，而且具备广泛的适用性。

五：模型二的模型建立与求解

5.1 问题描述与分析

在实际的风力发电过程中，风能的转化效率受到多种因素的影响，无法完全转化为电能。当实际风速超过额定风速时，无法被风机消化的风能会对风机施加额外的塔架推力和主轴扭矩，造成风机部件的损伤，增加设备的维护成本。因此，基于每个风机所在位置的实际风速条件和参考功率，精准地估算风机在不同条件下所承受的推力与扭矩，可以精确推算出荷载对风机主轴和塔架的疲劳影响，为风电场的功率调度策略提供数据支持和科学依据，保证风电场的稳定运行。基于上述条件，首先需要明确各个参数之间的关系，以建立完整的数学模型。具体而言，风机所受的推力与扭矩主要由风速影响，同时桨距角和低速轴转速等状态参数也会对风能的转换效率产生重要影响。之后，通过进行合理的受力分析并引入能量守恒定律，构建综合考虑各参数的塔架推力和主轴扭矩的预测模型。




图 5.1 问题二思路流程图

5.2 模型假设

- (1) 假设风电场所处气温气压条件稳定保持 20 摄氏度，1 标准大气压，且不受风速影响。
- (2) 假设空气流动没有湍流影响，风在叶片上的扫风面积均匀一致。

(3) 假设风机叶片具有理想的刚性，在单一时刻下不会发生变形，且叶片的阻力系数不随风速变化。

(4) 假设在计算时刻，所有测量数据（如风速、桨距角、转速等）都是准确的，不受测量仪器误差或外界噪声的干扰。

5.3 详细符号说明

表 5-1 符号说明

符号	说明
ρ	空气密度（20 摄氏度，1 标准大气压）
S, D, R	扫掠面积，转子直径，叶片半径
V	风速
t_0	时间
E_{wind}	风能
$E_{machine}$	机械能
$W_{machine}, P_{machine}$	机械能转移为系统内做的功和一定时间内的功率
C_p	功率系数
C_t	推力系数
M	空气质量
v_{in}, v_{out}	进入和离开风机时的风速
P_{in}, P_{out}	进入和离开风机时，风所做功的功率
P_0, P	标准大气压，实际大气压
T, t	绝对温度，摄氏温度
β	桨距角
ω	低速轴转速
λ	叶尖速比
λ_i	基于叶尖速比和桨距角的修正值
T_{shaft}	主轴扭矩
F_t	塔架推力
P_{ref}	有功功率参考值
η_P	功率因子
η_F	有效力因子
N	风机叶片数量
α	分布优化系数

5.4 数学模型的建立

针对“估算风机所承受的应力/扭矩”问题，寻找参数之间的关系，构建数学模型。

5.4.1 风机参数

(1) 常见 5MW 风机型号及参数

为了找到符合题目描述的风机型号，我们需要确定该风机的几个关键参数：额定功率 5MW，额定风速 11.2 m/s，表 5-2 展示了一些知名的风机型号及其参数。

表 5-2 常见风机的关键参数

型号	SG 5.0-132		SG 5.0-145	
	参数	单位	参数	单位
额定功率	5.0	(MW)	5.0	(MW)
转子直径	132.0	(m)	145.0	(m)
叶片半径	64.5	(m)	71.0	(m)

扫掠面积	13685.0	(m ²)	16513.0	(m ²)
功率因子	≥0.9	\	≥0.9	\

(2) 常规参数的确定与风机的选择

为进一步确定风机参数，使计算结果更加精准，我们参考了空气动力学中的风能公式（5.1）与风能向机械能的转化（5.2），结合系统内“能量-功”的关系（5.3），功率计算公式（5.4）得到公式（5.5），可以直观地反映出风机输出功率与空气密度，扫掠面积，风速以及功率转换率之间的关系。

$$E_{wind} = \frac{1}{2} \rho S V^3 t_0 \quad (5.1)$$

$$E_{machine} = E_{wind} C_p \quad (5.2)$$

$$W_{machine} = E_{machine} \quad (5.3)$$

$$P_{machine} = \frac{W_{machine}}{t} \quad (5.4)$$

$$P_{machine} = \frac{1}{2} \rho S V^3 C_p \quad (5.5)$$

基于 5.2 小节中提到的假设环境，我们利用风机的额定功率与额定风速进行计算。目前，我们已知的参数如下：风机工作的额定风速为 11.2 m/s；根据 Betz 定律的理论极限，公式如（5.6）-（5.9），当进入风速 v_{in} 与残余风速 v_{out} 的比值为 3:1 时，风力发电机能从风中提取的最大能量效率是 59.3%（即 $C_p=0.593$ ）；根据空气密度的计算公式，在 20 摄氏度，1 标准大气压的条件下，空气密度（5.10）约等于 1.205 kg/m³（即 $\rho=1.205$ ）。

$$M = \frac{1}{2} \rho S (v_{in} + v_{out}) \quad (5.6)$$

$$P_{in} = \frac{1}{2} \rho S v_{in}^3 \quad (5.7)$$

$$P_{out} = \frac{1}{2} M (v_{in}^2 - v_{out}^2) \quad (5.8)$$

$$\frac{P_{out}}{P_{in}} = \frac{1}{2} \left(1 - \frac{v_{out}^2}{v_{in}^2}\right) \left(1 + \frac{v_{out}}{v_{in}}\right) \quad (5.9)$$

$$\rho = 1.293 * \frac{P}{P_0} * \frac{273.15}{T} \quad (T = t + 273.15) \quad (5.10)$$

基于上述公式，由于能量效率无法超过 59.3%，但在额定条件下仍会保持一个较高的能量效率，因此我们假设额定条件下的功率系数为 0.45。之后，我们根据额定风速下风机的状态计算风机的扫掠面积约为 13126 m²，与型号为“SG 5.0-132”的风机参数更为相近。

因此，我们选择型号为“SG 5.0-132”的风机作为我们的参考模型，其精确的扫掠面积为 13685 m^2 ，叶片半径为 64.5 m 。

5.4.2 风机状态与受力分析

对于已选定的风机模型，结合 5.4.1 小节中的相关公式，如图 5.2 所示，我们绘制了简易的风机模型，并对风机的状态和受力进行分析。




图 5.2 简易风车模型，包含正视图及侧视图

(1) 风机状态:

对风机的状态分析主要涉及到风机参数的确定与系统内能量的转换。对风机的状态参数进行分析，扫掠面积 S 为风能捕获的能力 E_{wind} 和塔架推力 F_t 呈正相关，但是如图 5.2 正视图所示，扫掠面积对应的半径并不等于叶片的实际半径 R ，而叶片半径 R 是决定叶尖速比的关键参数，会间接影响到塔架推力 F_t 的计算。图 5.2 侧视图中的桨距角 β 和转速 ω 是直接测得的量，也会参与到功率系数的计算之中；对“环境-风机”系统的能量进行分析，如图 5.2 侧视图所示，风能在经过风机时对风机叶片做功，一部分风能转化为机械能，一部分风能流失。转化得到的机械能将进一步转化为电能。

(2) 受力分析:

对风机的受力分析主要涉及到主轴上的受力与塔架上的推力。当风机处于工作状态时，风力作用于叶片，带动风机主轴产生旋转。如图 5.2 侧视图所示，主轴顺时针旋转，将机械能转换为电能；塔架推力是风力作用在叶片产生的力，这个力通过叶片传递到整个塔架。因为这个力是沿着风向作用的，风力的一部分分力使叶片旋转，多余的分力则由塔架承受。

5.4.3 主轴扭矩与塔架推力估算

(1) 功率系数:

除了 Betz 定律之外，我们还可以利用叶尖速比 λ (5.11) 以及桨距角 β 计算任意条件下的功率系数。公式如 (5.12)，(5.13)。其中 λ_i 是一个基于 λ 和 β 的修正值。

$$\lambda = \frac{\omega R}{V} \quad (5.11)$$

$$C_p(\lambda, \beta) = 0.5176 \left(\frac{116}{\lambda_i} - 0.4\beta - 5 \right) e^{-\frac{21}{\lambda_i}} + 0.0068\lambda \quad (5.12)$$

$$\frac{1}{\lambda_i} = \frac{1}{\lambda + 0.08\beta} - \frac{0.035}{\beta^3 + 1} \quad (5.13)$$

(2) 主轴扭矩估算：

风力发电的基本原理是将风的动能转化为机械能，然后通过发电机将机械能转化为电能。具体来说，风机发电的两个关键步骤是：风力推动风轮转动，产生机械能；风轮的转动通过主轴将机械能传递到发电机，转化为电能。主轴扭矩 T_{shaft} 是风轮将机械功率传递给发电机的力矩。主轴扭矩与机械功率和风轮的角速度之间存在如下关系，公式如 (5.14)：

$$T_{shaft} = \frac{P_{machine}}{\omega} \quad (5.14)$$

(3) 塔架推力估算：

塔架推力 F_t 是指风力对风机塔架顶部施加的水平方向的力，它对风力发电机的稳定性和结构强度有重要影响。具体来说，风机的塔架推力可以用一个推力系数 C_t 来表示风能转化为推力的效率， C_t 一般来说与 C_p 呈正相关，且比值 $k \approx 1.5$ (5.15)。推力 F_t 的计算公式如公式 (5.16)。

$$C_t = 1.5 * C_p \quad (5.15)$$

$$F_t = \frac{1}{2} \rho S V^2 C_t \quad (5.16)$$

5.5 模型求解与分析

5.5.1 模型求解流程

在本节中，我们详细描述了模型的求解流程，整个过程概括为风机模型参数的确定，系统能量传递分析与风机叶片受力分析，主轴扭矩与塔架推力估算三个主要步骤，具体步骤如表 5-3。

表 5-3 模型求解流程

Step1: 搜索常见的 5MW 风机模型
Step2: 根据空气动力学与能量守恒寻找已知参数之间的关系
Step3: 根据额定参数估算风机模型的常量参数，选择合适的风机模型
Step4: 对风机系统的能量传递和风机叶片的受力进行分析
Step5: 建立数学模型，估算主轴扭矩与塔架推力
Step6: 对比估算值与参考值，展示实验结果。

5.5.2 模型结果与分析

(1) 主轴扭矩估算:

通过构建主轴推力的数学模型，根据风速及有功功率^[3]估算风机在 2000s 内任意时刻的主轴扭矩的估计值，将所得结果与主轴扭矩参考值进行比较，我们发现我们构建的模型根据已有条件估算出的主轴扭矩在时间线上与参考值的变化趋势大致相同，但是整体相较参考值偏低，如图 5.3，图 5.4 所示。




图 5.3 在 2000s 内每间隔 20s 取一个关键帧，绘制出主轴扭矩参考值（红色）与估计值（蓝色）




图 5.4 在后 100s 单位时间内的主轴扭矩参考值（红色）与估计值（蓝色）

由图可知，我们构建的模型具备一定的准确性，即主轴扭矩主要与有功功率呈正相关。然而，估计值与参考值之间存在的差异也表明了我们在分析实际问题时存在未考虑的因素，例如风机在实际运行过程中可能受到更加复杂的影响，或是我们未充分挖掘其他变量与主轴扭矩之间的关系。此外，风能-机械能-电能的转换损失以及风电场调控系统的响应特性也可能未被充分考虑。

(2) 主轴扭矩优化:

基于上述实验结果，我们再次分析了风机系统的能量转化问题并重点关注了风机的基础参数。我们发现了一个被忽略的重要参数——功率因子。功率因子是电力系统中一个重要的参数，表示电功率与视在功率之间的比率，而在风电机组的应用环境中，功率因子反映了风电机组将风能转换为电能的效率。所以，我们在之前的实验中存在如下几个错误：未考虑机械能转换为电能时的能量损耗；未理解实际的输出功率与有功功率参考值的含义。

因此，我们重新梳理了主轴扭矩与功率的关系，如公式（5.17）。式中， η_p 为功率因子，该公式的物理意义为总机械功率乘以一个功率因子 η_p 可以得到有功功率^[4]。根据公式（5.17），我们得到了新的主轴扭矩计算公式（5.18）

$$P_{ref} = T_{shaft} \omega \eta_p \quad (5.17)$$

$$T_{shaft} = \frac{P_{machine}}{\omega \eta_p} \quad (5.18)$$

关于功率因子 η_p 的具体取值，SG 5.0-132 型号的风机所在官网技术规格中给出的参考范围为 0.9 CAP-0.9 IND。通过查阅资料可知，CAP 和 IND 分别对应容性和感性，指的是电器负载或电路对电能的影响状态，容性状态时电流超前于电压，感性状态时电流滞后于电压。0.9CAP 表示功率因子为 0.9 且负载是容性的，0.9IND 表示功率因子为 0.9 且负载是感性的。因此，综合考虑状态的交替，功率因子的具体取值范围应为 0.9 CAP-1-0.9 IND，表示功率因子从 0.9 到 1 再到 0.9。为方便计算，考虑到风机的风能难以完全转换为电能，我们设定功率因子的范围为(0.9, 0.99)，最终取功率因子在范围内的平均值 0.945 进行计算，同时用有功功率参考值替换原来的实际输出功率。

此外，我们还充分考虑了风电场调控系统的响应时间这一关键因素。在实际运行中，风电场的功率分配和调度需要一定的时间来完成状态调整和反馈。因此，为更准确地模拟这一特性，我们在时间轴上引入了一个时滞补偿机制：沿时间轴上时间增加的方向平移一个单位。这意味着第 1 秒的有功功率参考值将由第 2 秒的状态响应，第 2 秒的有功功率参考值则对应第 3 秒的状态，以此类推。

通过优化主轴扭矩计算公式并添加了时滞补偿机制，我们所估算的主轴扭矩值如图 5.5，图 5.6 所示。




图 5.5 优化后的 2000s 内关键帧，绘制主轴扭矩参考值（红色）与估计值（蓝色）




图 5.6 优化后的后 100s 单位时间内的主轴扭矩参考值（红色）与估计值（蓝色）

为了定性定量的分析优化前后主轴扭矩估算值的实验结果，我们统计了两种实验数据中单个风机的估算值与参照值的误差平方和。统计结果如表 5-4 所示。

表 5-4 主轴扭矩误差分析

	后 100s 数据	每隔 100s 数据	全 2000s 数据
优化前	4.3077e+12	4.1495e+12	8.2854e+13
优化后	5.3693e+11	4.2388e+11	9.9011e+12

(3) 塔架推力估算：

通过构建塔架推力的数学模型，根据风速及有功功率估算风机在 2000s 内任意时刻所受的塔架推力后，将所得结果与塔架推力参考值进行比较，我们发现我们构建的模型根据已有条件估算出的塔架推力在时间线上与参考值的变化趋势大致相同，但是估计值显著大于参考值且幅值变化显著小于参考值，如图 5.7，图 5.8 所示。




图 5.7 在 2000s 内每间隔 20s 取一个关键帧，绘制出塔架推力参考值（红色）与估计值（蓝色）




图 5.8 在后 100s 单位时间内的主轴扭矩参考值（红色）与估计值（蓝色）

由图可知，在我们构建的模型中，估计值与参考值之间存在显著差异，尤其是均值与幅值的显著偏差。然而，我们估算的连续时间下塔架推力的变化趋势与参考值的变化趋势较为贴近，证明了在我们推导的公式中，塔架推力与风速的平方呈正相关。因此，基于塔架推力与风速平方的正比例关系，我们需要进一步探寻结果均值与幅值的影响因素。

（4）塔架推力优化：

基于上述实验结果，结合图 5.2，我们再次对风机叶片上的受力情况进行了细致的分析。首先，我们对塔架推力幅值进行优化。假定一个风机的叶片数量 $N = 1$ ，带入公式(5.16)得到塔架推力 F_t ，如图 5.2 正视图所示，当叶片数量 $N = 3$ 时，带入公式(5.16)得到的塔架推力仍为 F_t ，存在不合理性。此外，结合图 5.1 侧视图中的桨距角数据，当风力作用于任一叶片上时，由于桨距角 β 的存在，风力无法完全转换为推力。因此，根据图 5.9 所示，我们将风力沿平行扇面和垂直扇面的方向进行分解，求得在风力作用过程中转化为实际有效力的有效力因子 η_F ，如公式(5.19)。综上所述，我们认为应该在公式(5.16)的基础上引入两个变量对公式进行优化，第一个变量是叶片数量 N ，代表塔架推力是由作用每个叶片上的分力聚合得到的，第二个变量是桨距角 β ，用于计算风力中的有效部分。最终得到的关于塔架推力的幅值修正公式如公式(5.20)。




图 5.9 风力分解示意图

基于幅值优化，塔架推力估计值随时间的变化规律与变化幅度与塔架推力参考值近似。为进一步拟合得到更贴近塔架推力的估计值，我们引入了一个分布优化系数 α ，我们以误差平方和 SSE 作为损失函数，当误差平方和最小时，确定最佳的分布优化系数 $\alpha = 978700$ 。

综上所述，综合考虑对塔架推力公式的幅值优化和均值优化，我们得到了优化后的塔架推力公式 (5.21)

$$\eta_F = 1 - \sin(\beta) \quad (5.19)$$

$$F_t = \frac{1}{2} N \rho S V^2 C_t \eta_F \quad (5.20)$$

$$F_t = \frac{1}{2} N \rho S V^2 C_t \eta_F - \alpha \quad (5.21)$$

通过优化塔架推力计算公式，我们所估算的塔架推力值如图 5.10，图 5.11 所示。




图 5.10 优化后的后 100s 单位时间内的塔架推力参考值（红色）与估计值（蓝色）




图 5.11 优化后的后 100s 单位时间内的塔架推力参考值（红色）与估计值（蓝色）

为了定性定量的分析优化前后塔架推力估算值的实验结果，我们统计了两种实验数据中单个风机的估算值与参照值的误差平方和。统计结果如表 5-5 所示。

表 5-5 塔架推力误差分析

	后 100s 数据	每隔 100s 数据	全 2000s 数据
优化前	4.4115e+12	4.7202e+12	9.6753e+13
优化后	1.3940e+11	1.1607e+11	4.5409e+12

(5) 实验结果展示:

基于上述实验内容分析，我们计算了两个风电场 $WT1$, $WT2$ 内各 100 台风机，在全 2000s 时间内的主轴扭矩与塔架推力的估算值与参照值的误差平方和。统计结果如表 5-6 所示。

表 5-6 全部风机的主轴扭矩与塔架推力误差分析

	$WT1$	$WT2$	$WT1 + WT2$
主轴扭矩	9.6392e+14	9.6868e+14	1.9326e+15
塔架推力	3.6766e+14	3.6670e+14	7.3436e+14

六：问题三的建立与求解

6.1 问题的描述与分析

风机机械部件的疲劳损伤会增加风机维护成本，降低风力发电效率，在极端情况甚至会造成风机倒塌、叶片断裂等安全风险。为了降低风电场运维成本，需尽可能降低场站所有风机总体疲劳损伤程度。风机总体疲劳损伤程度主要由主轴和塔架的两种元件的疲劳损伤程度决定。由问题一的分析可知，主轴和塔架的疲劳损伤程度与风机所承受的载荷（指主轴扭矩和塔架推力）相关。由问题二的分析可知，主轴扭矩和塔架推力与风机所处位置的风速条件和有功功率相关。从本质上来看，问题三需要基于不同风机所处位置的风速条件，给出合理的有功功率分配策略，从而使得主轴和塔架的两种元件的疲劳损伤程度最小化，同时满足电网调度指令 P_t 。因此，本文首先建立了从风速条件和风机有功功率到主轴和塔架的疲劳损伤程度的数学模型。在此基础上，本文构建了代表场站所有风机总体疲劳损伤程度目标函数。通过对功率分配方式的分析，本文将功率分配转化为了各风机分配权重的优化问题并构建了最小化优化模型。随后，本文设计了一种具有繁殖约束的遗传算法求解该优化问题。最后，本文对所提出的遗传算法的有效性和实时性进行了验证，并对优化前后的分配结果进行了对比与分析。




图 6.1 问题三思路流程图

6.2 模型假设

- (1) 假设风机的总体疲劳损伤程度仅与主轴及塔架疲劳损伤程度相关；
- (2) 假设风机的主轴及塔架疲劳损伤可以由有功功率值和所处位置的风速直接计算得出；
- (3) 假设风机相邻时刻之间疲劳损伤不存在时间依赖性。

6.3 详细符号说明

表 6-1 符号说明

符号	说明
P_t	电网调度指令
D_s^i	第 i 台风机主轴的疲劳损伤
α	主轴损伤系数，本文中被设置为 1
P_{ref}^i	第 i 台风机有功功率的参考值
V_w^i	第 i 台风机所处位置的风速
β	塔架损伤系数，本文中被设置为 1
ω_s	所有风机主轴损伤权重，本文中为 0.5
ω_t	所有风机塔架损伤权重，本文中为 0.5
f_s	所有风机主轴损伤程度
f_t	所有风机塔架损伤程度
N_t	风电场中的风机数量
P_r	风机有功功率额定值, 本文中为 5MW
P_d	与平均分配结果的最大差值，本文中为 1MW
$\bar{P}_{ref}$	平均分配的有功功率
λ^i	第 i 台风机有功功率分配的权重
$Pop1, Pop2$	种群进化过程中产生的亚种群
N	种群的大小
G	遗传算法的最大演化代数
g	遗传算法的当前演化代数
$MatPool$	锦标赛选择方法构造出的交配池
Pop	遗传算法中的主种群
$Offspring$	遗传算法中产生的子代
T	附件二中风电场发电的总体时间，值为 2000
D_s^{ij}	第 i 台风机在第 j 时刻的主轴损伤
D_t^{ij}	第 i 台风机在第 j 时刻的塔架损伤
ACD	所有风机的累积疲劳损伤总和
PV_j	第 j 时刻风机间有功功率方差值
P_{ref}^{ij}	第 i 台风机在第 j 时刻有功功率
n	优化前后更具有优势的风机数量
R	风机累积疲劳损伤程度优势
APV	风机间有功功率方差值累计值
$WF1, WF2$	附件二中的风电场一和风电场二

S	同一时刻下的所有风机的分配权重会被求和
$maxw$	同一时刻下所有风机的分配权重 λ^i 的最大值
$minw$	同一时刻下所有风机的分配权重 λ^i 的最小值
xu, xl	分配权重取值范围的上界和下界

6.4 数据来源与预处理

问题三要求对电网调度指令 P_t 进行分配优化，并将优化后的结果与优化前（平均分配功率）的结果进行对比。附件二中给出了两个分别含有 100 个风机的风电场在 2000 秒内的每个风机的有功功率值和所处位置的风速。在同一风电场，我们需要对相同时间下的所有风机的有功功率值求和得到对应时刻下电网有功调度指令 P_t ，以完成后续分配优化过程。

此外，需要结合 P_t 和风电场中的风机数量，来确定平均分配功率的大小 $\bar{P}_{ref}$ 。

6.5 数学模型的建立

6.5.1 单台风机的疲劳损伤

由问题一和二的分析可知，风机的主轴疲劳损伤与有功功率呈线性关系，与所处位置的风速呈现非线性关系。故定义主轴的疲劳损伤如公式（6.1）所示。同理，定义塔架疲劳损伤如公式（6.2）所示。

$$D_s^i = \alpha \cdot P_{ref}^i \cdot (V_w^i)^2 \quad (6.1)$$

$$D_t^i = \beta \cdot P_{ref}^i \cdot (V_w^i)^2 \quad (6.2)$$

6.5.2 所有风机的总体疲劳损伤程度

为降低风电场运维成本，需尽可能降低场站所有风机总体疲劳损伤程度。结合单台风机的疲劳损伤，风电场中所有风机平均主轴疲劳损伤和平均塔架疲劳损伤共同构成了总体疲劳损伤程度，如公式（6.3）所示。此外，权重 ω_s 和 ω_t 被引入用于控制主轴损伤和塔架损伤比例，在本文中均被设置为 0.5，表示主轴损伤和塔架损伤对总体疲劳损伤程度影响相同。

$$F = \omega_s \cdot f_s + \omega_t \cdot f_t \quad (6.3)$$

$$f_s = \frac{1}{N_t} \cdot \sum_{i=1}^{N_t} D_s^i \quad (6.4)$$

$$f_t = \frac{1}{N_t} \cdot \sum_{i=1}^{N_t} D_t^i \quad (6.5)$$

6.5.3 有功功率的约束条件

(1) 所有风机有功功率值之和等于电网调度指令 P_t

$$\sum_{i=1}^{N_t} P_{ref}^i = P_t \quad (6.6)$$

(2) 各风机有功功率值不大于风机有功功率额定值

$$0 \leq P_{ref}^i \leq P_r \quad (6.7)$$

(3) 有功功率分配值与平均分配方法结果差值不超过 P_d

$$\bar{P}_{ref} = \frac{P_t}{N_t} \quad (6.8)$$

$$|P_{ref}^i - \bar{P}_{ref}| \leq P_d \quad (6.9)$$

6.5.4 有功功率分配方式

由公式 (6.3), (6.6), (6.7) 和 (6.9) 可知, 问题三是一个带有等式和不等式约束的单目标优化问题。该优化问题的输入就是电网有功调度指令 P_t 的分配方式。为了便于计算和求解, 本文将该分配方式转化为对各个风机的权重系数的划分。本文为所有风机分配的一个权重系数, 权重系数与电网有功调度指令 P_t 的乘积就是分配给对应风机的有功功率, 如公式 6.10 所示。因此, 约束 (6.6), (6.7) 和 (6.9) 可以转化为 (6.11), (6.12) 和 (6.13)。综合约束 (6.12) 和 (6.13), 可以得到 (6.14)。

$$P_{ref}^i = \lambda^i \cdot P_t \quad (6.10)$$

$$\sum_{i=1}^{N_t} \lambda^i = 1 \quad (6.11)$$

$$0 \leq \lambda^i \leq \frac{P_r}{P_t} \quad (6.12)$$

$$\frac{1}{N_t} - \frac{P_d}{P_t} \leq \lambda^i \leq \frac{1}{N_t} + \frac{P_d}{P_t} \quad (6.13)$$

$$\max \left\{ 0, \frac{1}{N_t} - \frac{P_d}{P_t} \right\} \leq \lambda^i \leq \min \left\{ \frac{P_r}{P_t}, \frac{1}{N_t} + \frac{P_d}{P_t} \right\} \quad (6.14)$$

6.5.5 有功功率分配模型

(1) **模型的输入:** 结合上述分析可知, 在某一时刻下, 优化模型的输入应该包含代表分配权重的向量和代表风速的向量, 它们的维度均为 $1 \times N_t$ 。

(2) **模型的约束:** 对于约束 (6.11) 而言, 可以在生成解向量时, 通过归一化操作实现。约束 (6.14) 可以转化成解向量取值范围即上下界。

(3) **模型的优化目标:** 场站所有风机总体疲劳损伤程度, 由权重 ω_s 和 ω_t 控制的主轴损伤和塔架损伤共同构成, 如公式 (6.3) 所示。

综上所述, 可以构建一个用于分配风机有功功率的单目标优化模型, 如下所示:

$$\min \left\{ F = \frac{\omega_s}{N_t} \cdot \sum_{i=1}^{N_t} \alpha \cdot (\lambda^i \cdot P_t) \cdot (V_w^i)^2 + \frac{\omega_t}{N_t} \cdot \sum_{i=1}^{N_t} \beta \cdot (\lambda^i \cdot P_t) \cdot (V_w^i)^2 \right\}$$

$$s.t. \left\{ \begin{array}{l} \sum_{i=1}^{N_t} \lambda^i = 1, \\ \max \left\{ 0, \frac{1}{N_t} - \frac{P_d}{P_t} \right\} \leq \lambda^i \leq \min \left\{ \frac{P_r}{P_t}, \frac{1}{N_t} + \frac{P_d}{P_t} \right\} \\ i = 1, 2, \dots, N_t. \end{array} \right\} \quad (6.15)$$

6.6 模型的求解及分析

6.6.1 具有繁殖约束的启发式遗传算法

为求解上述问题，本文设计了一种综合考虑繁殖约束的启发式遗传算法^[7]，算法流程如算法 6.1 所示。电网的调度指令，风电场中各个风机所处位置的风速被输入用于计算目标函数和。此外，关于演化算法的初始化超参数，种群大小，最大演化代数等也需要被给定控制种群的演化。在求解优化问题的过程中，遗传算法会随机初始化一个种群，通过选择机制和评估机制的共同作用引导种群中的个体不断向着优化目标演化，最终获取到满足优化条件的个体。在此问题中，种群中的每个个体代表了一种有功功率的分配方式，个体的决策向量就是代表有功功率分配权重的向量。首先，遗传算法^{[11][12]}会初始化个体在取值范围内的种群，来保证个体的决策变量满足约束（6.14）。这些个体的决策向量将会被归一化以满足约束（6.11），公式如下所示。

$$\lambda^i = \frac{\lambda^i}{\sum_{i=1}^{N_t} \lambda^i}, i = 1, 2, \dots, N_t \quad (6.16)$$

随后，种群开始演化过程。在演化的每一代中，锦标赛选择方法被用于构造交配池。具体来讲，锦标赛选择方法会随机的从种群中抽取成对的数据，并选择出这些数据中目标值最小的个体放入交配池。锦标赛选择方法会持续上述过程直到交配池大小达到一定程度。根据交配池中的元素，算法会生成两个亚种群 *Pop1* 和 *Pop2*，并基于模拟二进制交叉算子对这两个亚种群中个体决策变量进行交叉繁殖出子代。此外，多项式突变算子被引用用于子代的突变。为了保证满足约束，子代会被归一化通过公式（6.16），并且决策向量超出（6.11）取值范围的个体会被直接删除。满足约束的子代会根据数学模型（6.15），得到其优化的目标函数值。子代将会与原始种群合并得到新的种群，它将会根据所有个体的目标值的大小对个体进行排序和选择，实现种群的更新。上述演化过程会持续进行，直到达到最大的演化代数。

算法 6.1：具有繁殖约束的遗传算法

输入： 电网调度指令 P_t ，各个风机所处位置的风速 V_w^i ，种群大小 N ，最大演化代数 G 等

输出： 有功功率分配权重 λ^i

1: 根据公式（6.14）确定决策向量的取值范围；

2: 初始化大小为 N 的种群，并对其中的每个个体的决策向量做归一化，满足约束（6.11）

3: **while** $g < G$ **do**

4: $MatPool \leftarrow$ 采用锦标赛选择法构造交配池；

- 5: $Pop1, Pop2 \leftarrow$ 根据交配池生成两个亚种群;
- 6: $Offspring \leftarrow$ 采用模拟二进制交叉算子, 对 $Pop1$ 和 $Pop2$ 进行交叉;
- 7: $Offspring \leftarrow$ 采用多项式突变算子对子代进行突变;
- 8: $Offspring \leftarrow$ 对子代进行归一化, 使其满足满足约束 (6.11);
- 9: $Offspring \leftarrow$ 删除子代中超出 (6.11) 取值范围的个体;
- 10: $Offspring \leftarrow$ 根据公式 (6.15) 计算子代的目标值;
- 11: $Pop \leftarrow$ 将子代与原始种群合并;
- 12: $Pop \leftarrow$ 根据种群中个体的目标值, 对种群中的个体排序;
- 13: $Pop \leftarrow$ 选择种群中的前 N 个个体, 实现种群的更新;
- 14: $g \leftarrow g+1$;
- 15: **end while**




图 6.2 具有繁殖约束的遗传算法流程

图 6.2 展示了算法 1 的流程, 与常规的遗传算法^[8]相比, 本文提出的遗传算法考虑了优化问题中的等式与不等式约束。对于不等式约束, 本文将其转化为决策向量的取值范围。对于等式约束, 本文通过归一化技术实现了其对决策向量的限制。通过上述处理方式, 问题三中的优化分配问题变成了一个可行域内求解最小目标的优化问题, 降低了求解的难度。此外, 构造交配池和种群更新过程中, 个体的最小化目标值被作为了选择标准和依据, 保证了种群进化的方向。最终, 所提出的算法在求解数学模型 (6.15) 上表现出了良好的时间性能与优化性能, 这将在下一节中展开讨论。

6.6.2 评估指标的设计

为了验证所构建的数学模型的有效性, 需要将优化后与优化前 (平均分配功率) 的结果进行对比。因此, 本文设计了几个相关的评估指标, 以衡量不同功率分配策略的优劣。

(1) 各个风机的累积疲劳损伤程度: 这个指标用于衡量单个在给定时间段内累积疲劳损伤程度之和, 计算公式如 (6.17) 所示。

$$CD^i = \sum_{j=1}^T (D_s^{ij} + D_t^{ij}) \quad (6.17)$$

(2) **所有风机的累积疲劳损伤总和**: 这个指标用于衡量风电场内所有风机的累积疲劳损伤总和, 计算公式如 (6.18) 所示。

$$ACD = \sum_{i=1}^{N_t} (CD^i) \quad (6.18)$$

(3) **风机间有功功率方差值**: 这个指标衡量了某一时刻下不同的风机有功功率与均值的差异大小, 反映了为不同风机分配有功功率的有效性。

$$PV_j = \frac{1}{N_t} \sum_{i=1}^{N_t} (P_{ref}^{ij} - \frac{P_t}{N_t})^2 \quad (6.19)$$

(4) **风机累积疲劳损伤程度优势**: 问题三要求对优化后与优化前 (平均分配功率) 的结果进行对比, 由于风电场存在多个风机, 在每个风机上进行累积疲劳损伤程度的数值比较较为繁琐。对此, 一种用于反映不同分配策略的造成的累计疲劳损伤程度优势比的指标 R 被提出。具体来讲, 对于同一台风机, 我们对不同分配方式的得到累计疲劳损伤进行排名, 并求得所有风机上排名的均值。这反映了不同分配方式所得到的累计疲劳损伤的差距。 R 值越小, 说明对应分配策略越好。

$$R = \frac{\sum_{i=1}^{N_t} Rank(CD^i)}{N_t} \quad (6.20)$$

(5) **风机间有功功率方差值累计值**: 在优化之后分配策略中, 每个时刻下所有风机都会被分配新的有功功率。为了衡量一段时间内风机间有功功率方差值, 本文提出了一种风机间有功功率方差值累计值 APV 即各个时刻风机间有功功率方差值之和。 APV 值越大表明一段时间内风机有功功率的分配的有效性越好。

$$APV = \sum_{j=1}^T PV_j \quad (6.21)$$

6.6.3 问题的求解

(1) 具有繁殖约束的遗传算法有效性验证






图 6.3 遗传算法演化轨迹图

为验证具有繁殖约束的遗传算法求解数学模型 (6.15) 的有效性。我们获取了该算法优化附件二中风电场 $WF1$ 的前三个时刻分配有功功率的轨迹, 如图 6.3 所示。在求解过程中, 种群大小, 最大演化代数分别被设置为 10 和 50。图中的纵轴表示了 (6.15) 所要优化的目标, 横轴代表了演化代数。因为种群的大小为 10, 所以在搜索最优解的过程中有 10 个体同时优化。可以观察到, 随着演化代数的增加, 目标函数不断降低, 这表明了具有繁殖约束的遗传算法能够有效地求解数学模型 (6.15)。


(2) 计算结果的实时性展示



(a) 遗传算法优化功率分配的时间



(b) $WF1$ 中前 5 个时刻功率分配调度



(c) $WF2$ 中前 5 个时刻功率分配调度

图 6.4 功率分配的实时性可视化结果

问题三要求每秒对电网调度指令 P_t 进行一次分配，因此在单一时刻下求解数学模型 (6.15) 时间要小于 1 秒。本文所提出的具有繁殖约束的遗传算法的时间复杂度主要由锦标赛选择和种群更新过程中的排序决定，最坏情况下为 $O(GN^2)$ 。此外，图 6.4 (a) 展示了本文所提出的遗传算法在风电场 $WF1$ 和 $WF2$ 中 2000 次分配功率的时间。可以看出，本文所提出的优化算法具有良好的时间性能，所有分配功率的时间均小于 1 秒。这为实时地分配风机有功功率提供了条件。为了进一步展示算法分配有功功率和计时器的运行调度过程，我们选取了风电场 $WF1$ 和 $WF2$ 前 5 秒的数据，绘制了图 6.4 (b) 和 (c)。随着计时器记录，每隔一秒钟，遗传算法就会被调动用于分配该时刻下的有功功率。由于算法运行的时间小于 1 秒，在下一次电网调度指令 P_t 到来之前，所有风机有功功率的分配就会被优化完成。

(3) 约束条件的满足情况

为验证遗传算法优化结果是否满足问题三给定的约束条件 (6.11) 和 (6.14)。我们设计了测试约束条件的算法对优化结果进行验证，步骤如算法 6.2 所示。首先，同一时刻下的所有风机的分配权重会被求和，得到 S 。当 S 不等于 1 时，这表明所得的结果违反了约束 (6.11)，算法返回否。当 S 等于 1 时，算法会对解的第二个约束进行判断。通过判断分配权重 λ_i 的最大值和最小值与分配权重取值范围的上界和下界之间的关系，算法会给出第二个约束的结果，若满足返回是，反之返回否。经过算法 6.2 验证，由遗传算法所求的有功功率的分配结果均满足上述约束条件。

算法 6.2: 约束条件的满足情况

输入: 电网调度指令 P_t , 有功功率分配权重 λ^i , 有功功率额定值 P_r , 功率差值 P_d 等

输出: 是或否


```
1:  $S \leftarrow$  对同一时刻下所有风机的分配权重  $\lambda^i$  求和;  
2: if  $S=1$  then  
3:    $maxw \leftarrow$  获取同一时刻下所有风机的分配权重  $\lambda^i$  的最大值;  
4:    $minw \leftarrow$  获取同一时刻下所有风机的分配权重  $\lambda^i$  的最小值;  
5:    $xu, xl \leftarrow$  根据公式 (6.14) 计算分配权重取值范围的上界和下界;  
6:   if  $maxw \leq xu$  and  $minw \geq xl$  then  
7:     return 是;  
8:   else  
9:     return 否;  
10:  end if  
11: else  
12:   return 否;  
13: end if
```

(4) 优化后与优化前的结果对比


为了对比分配策略优化前后所得结果的区别, 本文采用了五个指标对附件二中的原始数据, 平均分配方式以及采用遗传算法优化分配的结果进行评估和比较: 各个风机的累积疲劳损伤程度 CD^i , 所有风机的累积疲劳损伤总和 ACD , 风机间有功功率方差值 PV_j , 风机累积疲劳损伤程度优势 R , 和风机间有功功率方差值累计值 APV 。为了获得在不同时刻下电网调度指令 P_t , 本文对附件二中所有风机的有功功率求和, 将其作为不同时刻下的 P_t 值, 如图 6.5 所示。此外, 优化分配策略之前, 平均分配方式被采用, 因此可以利用公式 (6.8) 计算平均有功功率, 如表 6.2 所示。

表 6.2 风电场 WF1 和 WF2 的平均有功功率

风电场	$\bar{P}_{ref}$
WF1	3.8940e+06
WF2	3.8945e+06




(a) 风电场 WF1 2000 秒内的 P_t



(b) 风电场 $WF2$ 2000 秒内的 P_t

图 6.5 风电场 $WF1$ 和 $WF2$ 的 P_t




(a) $WF1$


(b) $WF2$

图 6.6 风电场 $WF1$ 和 $WF2$ 中优化前后 CD^i 箱线图

附件二提供的是两个风电场内 2000 秒内 100 台风机的数据，因此在对一个风电场分配结果评估时，各个风机的累积疲劳损伤程度 CD^i 包含 100 个值，风机间有功功率方差值 PV_j 包含 2000 个值。为了便于展示优化前后 CD^i 和 PV_j 的差异，我们箱线图的形式呈现结果，如图 6.6 和 6.7 所示。由图 6.6 可知，相比于附件二中的原始数据和平均分配的结果，优化分配后，各个风机的累积疲劳损伤程度都得到了减少，表明了优化模型的有效性。对于平均分配有功功率的方式而言，其风机间有功功率方差值 PV_j 为 0。原始数据和优化分配后风机间有功功率方差值 PV_j 如图 6.7 所示。与原始数据相比，优化后有功功率的分配与风机所处位置的风速条件相关，风机间有功功率方差值变大。此外，三种分配方式下所有风机的累积疲劳损伤总和 ACD ，风机累积疲劳损伤程度优势 R 和风机间有功功率方差值累计值 APV 被展示在表 6.3 中。由 ACD 和 R 知，本文所构造的数学模型和优化算法能够合理地分配有功功率，降低风机的疲劳损伤程度。平均分配方式的风机间有功功率方差值 PV_j 均为 0，因此其 APV 值也为 0。由 APV 可知，风机间有功功率分配差异性较为明显。综上，本文所构造的数学模型和所提出的优化算法能够有效地解决有功功率的分配优化问题，并具有良好的时间性能。



(a) $WF1$



(b) $WF2$

图 6.7 风电场 $WF1$ 和 $WF2$ 中优化后有功功率方差值 PV_j

表 6.3 优化前后 ACD , R 和 APV 的对比

$WF1$			
有功功率分配方式	ACD	R	APV
原始数据	3.2899e+14	2.4600e+01	5.3405e+14
平均分配	3.2901e+14	2.4300e+01	0.0000e+00
优化分配	3.2684e+14	1.1100e+01	6.7910e+14
$WF2$			
原始数据	3.2917e+14	2.4300e+01	5.3436e+14
平均分配	3.2917e+14	2.4800e+01	0.0000e+00
优化分配	3.2701e+14	1.0900e+01	6.7874e+14

七：问题四的模型建立与求解

7.1 问题描述与分析

在实际风电场运行中，AGC（自动发电控制）系统需要采集大量的实时数据来进行有功功率的优化和调度，这些数据通常由风机上的传感器通过高速光纤环传输至集控中心。然而，这一过程中，数据的采集和传输往往会受到多方面因素的影响，导致数据的准确性和实时性下降，主要表现为以下两个问题：

（1）测量噪声：现场传感器会由于各种环境因素和自身精度限制，采集到的数据会受到随机噪声的干扰。在实际工程中，这种噪声一般表示为测量值与真实值之间存在 10% 以内的相对误差。这种噪声干扰将会导致风机得到的输入值与实际真实值不一致，进而影响有功功率的优化分配和调度。


（2）通信延迟：在信号传输过程中，数据在协议层和物理层均可能受到传输拥塞影响，会出现随机的传输延迟问题，导致部分时间段内的数据无法及时采集，进而影响有功功率的优化分配和调度。

上述噪声与延迟问题会导致传统的优化模型难以满足实际工程需求。因此，为确保风电场有功功率调度的准确性与实时性，需要考虑随机测量噪声与通信延迟对模型的影响，进一步改进问题三中的优化方案，构建一个对噪声和延迟具有鲁棒性的优化模型。

为了在实际环境下能更好的优化风电场的有功功率分配，我们需要针对测量噪声和延迟问题进行深入分析和处理。本题中，我们的有功功率优化算法需要实时接收风机的风速数据以及整体的调度信息。在实际风电场运行中，噪声主要来自于风机实时风速的测量，受限于现场传感器精度和外部环境的干扰，风速测量数据往往带有一定的随机波动。此外，通信延迟则更为复杂，通信过程在协议层和物理层均可能受到传输拥塞影响，存在随机传输延迟问题，导致部分时间段数据无法及时采集。物理层的延迟发生在风速数据从风机传输到中央控制系统的过程中，协议层的延迟发生在各风机的参考有功功率信号传递过程中。

因此，该问题的核心在于两个方面：首先是对风速时间序列进行去噪处理，尽量减小测量噪声的影响，以确保风速数据能够更加准确地反映实际的风况变化；其次是设计一套延迟监测机制，能够实时监测到数据传输的延迟情况。当延迟发生时，我们需要对丢失的风速数据进行拟合预测，确保在数据缺失的情况下，优化算法仍然能够基于合理的数据进行有功功率的分配。

针对风速时间序列的去噪，可以采用卡尔曼滤波、低通滤波等方法，这些方法能够有效减小随机噪声的干扰，提高数据的准确性。而对于延迟的处理，则需要建立一个实时监测系统，通过对数据传输时间的记录 and 对比，判断是否出现延迟。一旦检测到延迟，我们可以利用历史数据序列建立预测模型以保证算法在延迟情况下依然能够维持稳定运行。通过对测量噪声和延迟问题的全面分析和应对，优化算法能够在实际环境中更具鲁棒性，提高风电场有功功率分配的精度与效率。



(4) 假设附件二中风机有功功率参考值和风速波动变化规律与附件四中的风机一致。

7.3 详细符号说明

表 7-1 符号说明

符号	说明
M	窗口大小
N	总时间
b_k	Savitzky-Golay 滤波器系数
$\hat{x}_{k k-1}$	时刻 k 的状态预测值
u_{k-1}	时刻 k 的控制量
$P_{k k-1}$	时刻 k 的预测协方差矩阵
A	状态转移矩阵
B	控制输入矩阵
Q	过程噪声协方差矩阵
R	测量噪声协方差矩阵
K_k	卡尔曼增益
H	观测矩阵
z_k	观测值
$delay$	延迟区域标志矩阵
V	时序数据
V_μ	时序数据均值
V_σ	时序数据方差
V_{pred}	时序数据预测值
V_{scaled}	归一化后的时序数据
V_{true}	时序数据真实值

7.4 问题四的模型建立

7.4.1 风速去噪模型

完成了数据获取与预处理，我们需要对传感器所采集的存在随机噪声的风机的风速数据进行滤波去噪处理。我们采用了滑动平均滤波、Savitzky-Golay 滤波和卡尔曼滤波对带有噪声的风机风速数据进行去噪。

(1) **滑动平均滤波**：滑动平均滤波是一种常用的滤波算法，通过对数据点进行局部平均来实现滤波，通过不断滑动窗口来实现滤波，一定程度上能减少数据的随机波动，滤波公式如下：

$$x[n] = \frac{1}{M} \sum_{k=0}^{M-1} x[n-k] \quad (7.1)$$

(2) **Savitzky-Golay 滤波**：Savitzky-Golay 滤波是一种用于平滑和微分数据的滤波器，在滑动平均滤波的基础上，不仅能减少随机噪声，还能有效的保留信号的特征，公式如下：

$$x[n] = \sum_{k=-\frac{M-1}{2}}^{\frac{M-1}{2}} b_k x[n+k] \quad (7.2)$$

(3) **卡尔曼滤波**：卡尔曼滤波是一种用于线性动态系统的最优递归数据处理算法，它通过建立系统状态的预测和更新方程，利用测量值与系统模型之间的误差反馈来动态调整对

系统状态的估计。在动态系统中能实时地根据观测数据和系统模型对状态进行更新，能很好的处理系统状态变化和测量噪声的变换。预测状态方程，预测协方差矩阵，卡尔曼增益，状态更新方程和更新误差协方差矩阵如公式（7.3），（7.4），（7.5），（7.6）和（7.7）所示。

$$\hat{x}_{k|k-1} = A\hat{x}_{k-1|k-1} + Bu_{k-1} \quad (7.3)$$

$$P_{k|k-1} = AP_{k-1|k-1}A^T + Q \quad (7.4)$$

$$K_k = P_{k|k-1}H^T(HP_{k|k-1}H^T + R)^{-1} \quad (7.5)$$

$$\hat{x}_{k|k} = \hat{x}_{k|k-1} + K_k(z_k - H\hat{x}_{k|k-1}) \quad (7.6)$$

$$P_{k|k} = (I - K_kH)P_{k|k-1} \quad (7.7)$$

算法 7.1 展示了基于卡尔曼滤波的伪代码。通过算法 7.1 的算法流程，测量噪声与真实信号逐步被区分开，以提供对系统状态的最优估计。

算法 7.1： 基于卡尔曼滤波的风速去噪

输入： 风机数量，风速序列

输出： 去噪后的风速序列

```

1: for 每台风机 do
2:   初始化状态转移矩阵  $A$ ，控制输入矩阵  $B$ ，确定  $R$ ， $Q$ 
3:   for 每个时刻 do
4:     根据公式（7.1）预测状态  $\hat{x}_{k|k-1}$ 
5:     根据公式（7.2）预测误差协方差  $P_{k|k-1}$ 
6:     根据公式（7.3）确定卡尔曼增益  $K_k$ 
7:     根据公式（7.4）更新状态
8:     根据公式（4.5）更新误差协方差
9:   end for
10: end for

```

为了进一步优化卡尔曼滤波的性能并适应风电场中风速的噪声的特性，我们设计了一个专门的调参模型，以均方误差（MSE）作为优化指标，最小化滤波后的数据与原始真实数据之间的误差。

$$MSE = (Kalman(V_{noise}) - V_{ori})^2 / N \quad (7.8)$$

通过优化过程，调整卡尔曼滤波器的 Q 和 R 参数，使其更加符合风速数据的实际波动特性，达到最优的去噪效果。这一调参过程的目标是确保滤波后的数据不仅能有效抑制噪声，而且能尽可能保持原始数据的动态特性，实现对风速数据的精准去噪处理，图 7.2 展示了调优策略的流程。

在调优策略中，我们遍历所有可能的噪声协方差参数 Q 和 R ，并且使用卡尔曼滤波对噪声数据进行处理。通过计算每一组参数下的 MSE ，可以评估滤波效果的优劣，如图 7.3 所示。经过分析， MSE 最小的参数组合 $R = 0.029764, Q = 0.029764$ 被作为最优值。




图 7.2 卡尔曼滤波参数调优策略流程图




图 7.3 MSE 随着 Q 、 R 变化情况

7.4.2 传输延迟预测模型

(1) 传输延迟检测模型:

在实际风电场中，数据传输过程中可能会出现延迟，导致采集到的风速数据和功率调度数据在某些时间段内保持不变。为了有效识别这些延迟，我们首先采用一种基于变化率的检测方法，通过分析每个风机在不同时间点的风速变化，识别出现延迟的部分。具体步骤包括设定一个阈值，当数据变化率小于该阈值时，标记为延迟。这样，我们可以得到一个延迟区域的标志矩阵，便于后续分析和处理。

$$\text{delay} = \begin{cases} 1 & \text{if } |V(t) - V(t-1)| < 1e4 \\ 0 & \text{otherwise} \end{cases} \quad (7.9)$$

(2) 传输延迟预测模型:

我们分别使用简单移动平均预测模型、差分自回归移动平均（ARIMA）预测模型和长短期记忆网络^[9]（LSTM）预测模型进行时间序列预测来处理传输延迟。简单移动平均预测模型：是一种常用的时间序列预测方法，主要适用于平稳时间序列，主要基本思想是通过取最近 n 个数据的平均值来预测下一个数据点，公式如下：

$$x_t = \frac{1}{n} \sum_{i=0}^{n-1} x_{t-i} \quad (7.10)$$

差分自回归移动平均模型：是一种适用于非平稳时间序列预测的统计模型。ARIMA 模型结合了自回归（AR）、差分（I）和滑动平均（MA）三种成分，以便捕捉时间序列中的趋势和季节性，如下为 ARIMA 模型主要公式，其中 ϕ_0 为常数项， ϕ_i 为自回归系数，而 ϵ_t 为白噪声误差项：

$$x_t = AR_t + MA_t \quad (7.11)$$

$$AR_t = \phi_0 + \phi_1 x_{t-1} + \dots + \phi_p x_{t-p} + \epsilon_t \quad (7.12)$$

$$MA_t = \theta_1 \epsilon_{t-1} + \theta_2 \epsilon_{t-2} \dots + \theta_q \epsilon_{t-q} + \epsilon_t \quad (7.13)$$

通过对附件中的数据波动规律的分析可知，有功功率分配过程中风速和功率参考值变化较为复杂。常规的时间序列预测方法在面临着这种复杂变化的数据时表征能力不足。LSTM^{[13][14]}能够通过门控机制和细胞状态捕捉数据中的长期依赖关系，从而适应数据的复杂变换。为此，我们设计了一种基于 LSTM 的时间序列预测模型来对延时数据进行预测，如公式（7.14）所示。本文采用的 LSTM 模型结构如图 7.4 所示。该模型主要由三部分构成，分别是输入层，LSTM^[15]层，输出层。输入层和输出层均为包含 200 个神经元的全连接层，LSTM 层由 200 个 LSTM 单元组件串联而成。

$$V_{\text{pred}}(t) = \text{LSTM}(V(t-1), V(t-2), \dots) \quad (7.14)$$




图 7.4 模型结构

7.5 模型求解与回答

在本节中，我们详细描述了我们的模型的求解流程，以下是算法的总求解流程图：




图 7.5 算法总求解流程图

7.5.1 风速去噪：

滑动平均滤波、Savitzky-Golay 滤波、卡尔曼滤波被用于对各风机得到的风速时间序列去噪。在进行卡尔曼滤波时，由于不同的参数可能导致不同的结果，通过调优策略（如图 7.2 所示），我们在一系列可能的卡尔曼滤波参数中寻找最优的 Q 和 R 值，以最小化均方误差见公式(7.8)。

7.5.2 传输延迟预测

该部分复杂对模型中存在的延迟进行检测与预测，总体分为延迟检测、时间序列预测、延迟预测三个部分，图 7.6 展示了该部分主要求解流程。




图 7.6 传输延迟预测部分主要求解流程

(1) **基于变化率的延迟检测方法：**首先，我们提出了一种基于变化率的延迟检测方法，通过分析每个风机在不同时间点的序列变化，识别出现延迟的部分。接着，我们部署了 LSTM 模型^[16]并分别对风速和功率调度序列进行训练。我们采用了附件二中提供的完整、真实且无噪声延迟的数据。


(2) **数据预处理：**附件二中提供的数据以 8.5: 1.5 的比例被划分为训练集和验证集，并进行归一化处理，如公式 (7.15) 所示。

$$V_{\text{scaled}} = \frac{V - V_{\mu}}{V_{\sigma}} \quad (7.15)$$


(3) **模型架构设计与训练：**我们对 7.4.3 节中构造的 LSTM 模型进行了训练，并且采用均方根误差 (RMSE) 作为损失函数，通过反向传播算法优化模型参数。

$$\text{RMSE} = \sqrt{\frac{1}{N} \sum_{i=1}^N (V_{\text{pred}}(i) - V_{\text{true}}(i))^2} \quad (7.16)$$

有功功率和风速的训练过程被展示在图 7.7 中。随着训练进程，均方根误差显著下降。在训练过程中，学习率被设置为 0.01，并进行了 1000 次训练迭代，以确保模型能够被充分训练。通过多次迭代训练，两个鲁棒的预测模型被得到，可以有效捕捉数据序列的波动特征。预测模型在验证集上的预测结果如图 7.8 所示。




(a) 有功功率序列训练过程




(b) 风速序列训练过程

图 7.7 预测模型训练过程损失展示



(a) 有功功率验证集结果



(b) 风速验证集结果

图 7.8 预测模型在验证集上的结果


7.5.3 风机有功功率的优化分配


经过上述的风速去噪和传输延迟预测，不同时刻下各个风机所对应的有功功率的参考值和所处位置的风速条件被获得。为了降低所有风机总体疲劳损伤程度，我们采用了问题三中构造的有功功率分配模型来优化功率的分配方式。首先，我们对同一时刻下各个风机有功功率的参考值求和，得到电网调度指令 P_t 。随后， P_t 和各个风机所处位置的风速条件被输入具有繁殖约束的遗传算法中，优化各个风机的功率分配的权重系数，具体步骤如算法 6.1 所示。最终，得到优化之后的权重系数并计算出对应风机的有功功率的参考值，实现对有功功率的合理分配。

7.6 问题的求解与优化效果


7.6.1 风速去噪效果

为了分析风速去噪算法的有效性，我们将其分别从滤波效果和 MSE 指标两个方面，对不同去噪方式的滤波效果进行直观的对比。图 7.9 给出了卡尔曼滤波，滑动平均滤波和 Savitzky-Golay 的滤波结果，其中红色为具有噪声的结果，蓝色为滤波后的结果，并且绿色虚线则表示原始未加入噪声的真值。经过与其他两种去噪方式对比，我们提出的优化后的卡尔曼滤波能在很好的保留数据的变化规律的基础上，有效的削弱相对误差 10%范围内的噪声。随后，定量分析被展开，我们将滤波后的结果与原始未加入噪声的数据计算均方误差 MSE，如表 7-2 所示。经分析，发现基于优化的卡尔曼滤波相较于其他滤波算法有最低的均方误差，经过滤波后的结果最逼近真实值，能更好的实现风速去噪。





(b) 滑动平均滤波结果



(c) Savitzky-Golay 滤波结果

图 7.9 不同滤波算法对噪声数据的处理结果展示

表 7-2 不同滤波算法 MSE 结果定量对比

滤波算法	MSE
优化后的卡尔曼滤波	4.8101e-01
滑动平均滤波	7.6918e-01
Savitzky-Golay 滤波	7.3910e-01

7.6.2 传输延迟预测效果

图 7.10 展示了 LSTM 时间序列预测模型, Arima 预测模型和简单移动平均预测模型在功率调度的延迟区域的预测结果。可以看到, 在延迟区域, 所提出的基于 LSTM 的时间序列模型能很好的预测延迟区域的趋势, 而其他的时间序列预测模型表现较差。结果证明了

所提出的 LSTM 模型在处理复杂时间序列数据时的优势，并在处理传输延迟问题时表现出了良好的性能。




图 7.10 多种时间序列预测模型在延迟区域的预测结果对比

7.6.3 有功功率分配效果

为验证所建立的风速去噪模型和传输延迟预测模型的有效性，本文结合附件四的数据，构造了五类不同的有功功率分配方式，并且通过计算疲劳损伤程度对其性能进行分析。五类有功功率分配方式如表 7-3 所示。本文采用了五个指标对上述方式的结果进行评估比较，分别是各个风机的累积疲劳损伤程度 CD^i ，所有风机的累积疲劳损伤总和 ACD ，风机间有功功率方差值 PV_j ，风机累积疲劳损伤程度优势 R ，和风机间有功功率方差值累计值 APV 。

表 7-3 五类不同的有功功率分配方式及含义

有功功率分配方式	含义
方式 1	附件四中的原始数据
方式 2	附件四中数据传输延迟处理后的结果
方式 3	附件四中数据风速去噪后的结果
方式 4	附件四中数据传输延迟处理和风速去噪后的结果
方式 5	方式 4 中数据采用遗传算法进行优化后的结果

附件四的原始数据中包含了 10 台风机在 300 秒内的有功功率的参考值和所处位置的风速。我们采用问题三中所构建的疲劳损伤的数学模型。经过计算，各个风机的累积疲劳损伤程度 CD^i 和风机间有功功率方差值 PV_j 分别是包含 10 和 300 个数组形式。为了便于观察不同分配方式之间的差异，本文以可视化方式对其进行展示，如图 7.11 所示。对于 CD^i ，方式 3 由于仅仅去除了风速中的噪声，因此其各个风机的累积疲劳损伤平均水平并不大。方式 3 和方式 4 处理了原始数据中存在的信号传输延迟问题，因此降低了风机的累积疲劳损伤。对于 PV_j ，方式 3 数据中的噪声，因此风机间有功功率方差值较小。方式 3 和方式 4 将原始数据中的保持不变的延迟信号转化为了波动的预测信号，因此增大了风机间有功功率方差值。此外，方式 5 通过遗传算法优化了有功功率的分配，在 CD^i 和 PV_j 都胜过了其他方式。

表 7-4 展示了五种分配方式的 ACD ， R 和 APV 。对于 ACD 而言，由于方式 3 仅需要对风速水平去噪，而在影响疲劳损伤的两个因素中，有功功率比风速具有更大的数量级和影响。因此，方式 3 的 ACD 和方式 1 的较为接近。同理，处理了风速和有功功率信号延迟的方式 2 和 4 具有更小的 ACD 。结合 CD^i 的可视化结果，方式 3 的 CD^i 数据上下界范围更大，方式 2 的 CD^i 数据则集中在均值附近。因此，对于 R ，方式 2 具有更好的性能。五

种方式的 APV 展现出了与 PV_j 相近的趋势，方式 2 和 4 通过预测值的加入提升了原始数据整体的波动性，因此其方差值更大。

结合五种方式在五个指标上的性能，可以得出以下结论：

(1) 本文构建出的风速去噪模型和传输延迟预测模型具有良好的性能。相较于含有噪声和传输延迟的原始数据，经过去噪（方式 2）和传输延迟预测（方式 3）的结果具有更小的疲劳损伤和更大的功率方差。此外，传输延迟预测相比于去噪对最终结果的影响更大。

(2) 通过风速去噪和传输延迟预测的综合处理可以使 AGC 系统更好的应对实际风电场中的风险。相较于含有原始数据（方式 1），去噪结果（方式 2）和传输延迟预测结果（方式 3），综合处理结果（方式 4）具有更优的性能。

(3) 本文构建的具有繁殖约束的演化算法对于优化有功功率的分配具有良好的性能。与其他所有的方式相比，该算法优化后的功率分配都具有显著的优势。




图 7.11 CD^i 和 PV_j 的可视化结果

表 7-4 五种分配方式的 ACD , R 和 APV

有功功率分配方式	ACD	R	APV
方式 1	5.4492e+12	3.8000e+00	1.5899e+13
方式 2	5.3707e+12	3.1000e+00	7.7259e+13
方式 3	5.4262e+12	2.8000e+00	1.5899e+13
方式 4	5.3311e+12	2.7000e+00	8.7474e+13
方式 5	5.2748e+12	2.6000e+00	1.7130e+14

八：模型评价

8.1 模型的优点

本文提出一种针对风机功率分配的优化模型，其具有以下优点：

疲劳损伤程度量化更合理、复杂度更低——本模型设计了一种滑动窗口法和荷载数据预测方法来对荷载进行实时计算，达到快速计算累计疲劳损伤的要求，解决了传统雨流计数法依赖完整荷载循环并且无法实现实时计算疲劳损伤的问题。

塔架推力和主轴扭矩估计更精准——本模型设计了更有效的荷载估计，结合合理的受力分析通过实时风速和功率参考值有效地估计风机在不同条件下的塔架推力和主轴扭矩。

有功功率的调度优化更高效、更快速——本模型设计了一种基于主轴和塔架疲劳损伤的最小化目标函数，并且提出了一种具有繁殖约束的遗传算法优化该目标，实现了更实时更高效的功率分配。

能够应对实际场景中噪声和通信延迟问题——本模型设计了一种卡尔曼滤波去噪方法和基于 LSTM 的延迟信号预测方法，用于解决实际风电场中常见的传感器噪声和通信传输延迟问题，提升了模型的实际应用价值和鲁棒性。

综上，本文通过改进疲劳损伤量化，荷载估计，功率的调度优化和环境适应性，有效地提高了功率分配效率和鲁棒性，确保风力系统能根据实时数据做出快速响应，为风力发电提供良好的功率分配方案。

8.2 模型的缺点

结合模型整体的特征与运行流程，以下几个方面值得进一步改进和优化：

(1) 疲劳损伤程度量化：缺少全局推力和扭矩对疲劳损伤的影响的考虑，造成了估计的不准确。

(2) 塔架推力和主轴扭矩估计：对于影响塔架推力和主轴扭矩现实因素的考虑不够全面，并且相关参数的取值具有挑战性。

(3) 有功调度优化模型：疲劳损伤建模过程较为简单，对相邻时间的功率与风速变化的依赖性以及主轴与塔架的疲劳损伤的差异性考虑不足。

(4) 基于 LSTM 的传输延迟预测：传输延迟预测结果对训练数据较为敏感，容易受到噪声数据的波动影响。

8.3 展望

随着全球对不可再生资源的消耗日益加剧，风能作为一种可再生资源，愈加重要。开发和利用风能不仅有助于减少对环境的影响，也是实现能源结构转型的关键。因此，构建高效、鲁棒性强的风机功率分配优化模型，在最大化风能利用率的同时最小化疲劳损伤，具有重要的现实意义。在未来，本文提出的模型将不断地完善和发展，以提供更高效的功率分配，从以下方向进行展望：

(1) 传输延迟预测：更先进的数据分析技术和机器学习算法将会被引入以提升模型对风速变化和功率的预测精度。

(2) 算法运行效率：在确保预测准确性的基础上，算法的计算效率将被进一步提升，以满足实时数据处理和快速决策的需求。

(3) 环境适应性：风能资源丰富的地区往往地理位置偏远，环境条件极端。更先进的异常处理技术将被开发，以应对复杂多变的现实情境。

(4) 实时监控与维护：实时监控系統将被设计，对风机的运行状态和疲劳损伤进行持续跟踪并及时预警潜在的风险，以实现预防性维护。

九：参考文献

- [1] 董乐义, 罗俊. 雨流计数法及其在程序中的具体实现[J]. 计算机技术与应用, 2004, 24(3): 38-40.
- [2] 王宏伟. 雨流计数法及其在疲劳寿命估算中的应用[J]. 矿山机械, 2006, 34(3): 95-97.
- [3] 王鑫. 考虑疲劳载荷的风电场有功功率分配策略研究[D]. 西安理工大学, 2022. DOI: 10.27398/d.cnki.gxalu.2022.000373.
- [4] 赵永兵. 风电场有功分配及无功优化研究[D]. 沈阳工业大学, 2016.
- [5] 武晓冬, 席鹏辉, 赵锬, 等. 基于疲劳分布的风电场有功优化调度策略[J]. 科学技术与工程, 2024, 24(22): 9400-9407.
- [6] 潘沈恺, 高丙团, 毛永恒, 等. 考虑机组疲劳载荷的风电场快速有功功率分配方法[J]. 电力系统自动化, 2024, 48(15): 112-121.
- [7] 丛雨, 李秀芬, 原帅, 等. 基于改进遗传算法的风电场多时段有功功率优化分配[J]. 电网与清洁能源, 2022, 38(12): 107-114.
- [8] 常晟, 万宇宾, 蒋韬. 基于自适应遗传算法的风电机组变桨控制参数自寻优方法[J]. 控制与信息技术, 2024, (02): 40-48. DOI: 10.13889/j.issn.2096-5427.2024.02.006.
- [9] 任鹏, 付文杰, 申洪涛, 等. 基于竞争学习机制的 LSTM 风电多目标区间预测[J]. 计算机应用与软件, 2024, 41(06): 305-311+349.
- [10] M. Musallam and C. M. Johnson, "An Efficient Implementation of the Rainflow Counting Algorithm for Life Consumption Estimation," IEEE Trans. Rel., vol. 61, no. 4, pp. 978-986, Dec. 2012.
- [11] Albadr M A, Tiun S, Ayob M, et al. Genetic algorithm based on natural selection theory for optimization problems[J]. Symmetry, 2020, 12(11): 1758.
- [12] Gozali A A. Modified genetic algorithm to solve worker assignment problem with time windows[J]. Industrial Artificial Intelligence, 2024, 2(1): 1.
- [13] Yu Y, Si X, Hu C, et al. A review of recurrent neural networks: LSTM cells and network architectures[J]. Neural computation, 2019, 31(7): 1235-1270.
- [14] Zhao Z, Chen W, Wu X, et al. LSTM network: a deep learning approach for short-term traffic forecast[J]. IeT intelligent transport systems, 2017, 11(2): 68-75.
- [15] Gers F A, Schmidhuber J, Cummins F. Learning to forget: Continual prediction with LSTM[J]. Neural computation, 2000, 12(10): 2451-2471.
- [16] py 学习小白, LSTM 进行时间序列预测——训练, 验证, 测试, https://blog.csdn.net/m0_58327216/article/details/127820677.

十：附录

10.1 第一题答案（主轴扭矩、前 5 台风机、前 30 条）

时间	WT1	WT2	WT3	WT4	WT5
1	1.4821e-22	4.4724e-22	5.7613e-22	1.9548e-21	3.3825e-26
2	2.9645e-22	8.9527e-22	1.1511e-21	3.9071e-21	6.7648e-26
3	4.4487e-22	1.3438e-21	1.7254e-21	5.7402e-21	1.0358e-24
4	5.4464e-22	1.7922e-21	2.3001e-21	1.3030e-20	5.0066e-24
5	6.4438e-22	2.2396e-21	2.8755e-21	2.0335e-20	8.9729e-24
6	7.7979e-22	2.6863e-21	3.4516e-21	2.7657e-20	9.5649e-24
7	8.2140e-22	3.1333e-21	4.0278e-21	3.4986e-20	3.5607e-23
8	8.4271e-22	3.5812e-21	4.6042e-21	4.2305e-20	8.8463e-23
9	1.5276e-21	3.7936e-21	5.2319e-21	4.9601e-20	1.4141e-22
10	2.2148e-21	4.1829e-21	5.8595e-21	5.6876e-20	1.9441e-22
11	2.9034e-21	4.5716e-21	6.4870e-21	6.4140e-20	2.4741e-22
12	3.5913e-21	4.6268e-21	6.5003e-21	6.5896e-20	3.0045e-22
13	4.2782e-21	4.6819e-21	6.5006e-21	6.7652e-20	3.5353e-22
14	4.9641e-21	4.7370e-21	6.5009e-21	6.9408e-20	4.0666e-22
15	5.6495e-21	4.7922e-21	6.5011e-21	7.0893e-20	4.0929e-22
16	6.3354e-21	4.8476e-21	6.5014e-21	7.0918e-20	4.0952e-22
17	6.5470e-21	4.9029e-21	6.5017e-21	7.0921e-20	4.0975e-22
18	6.7588e-21	4.9396e-21	6.5019e-21	7.0925e-20	4.1010e-22
19	6.9706e-21	4.9471e-21	6.5533e-21	7.0928e-20	4.1018e-22
20	7.1020e-21	4.9546e-21	7.9026e-21	7.0930e-20	4.1041e-22
21	7.1040e-21	4.9665e-21	9.2482e-21	7.0931e-20	4.1939e-22
22	7.1059e-21	4.9721e-21	1.0592e-20	7.0936e-20	4.2837e-22
23	7.1242e-21	4.9765e-21	1.1935e-20	7.0943e-20	4.2941e-22
24	7.1426e-21	4.9805e-21	1.3215e-20	7.0950e-20	4.3045e-22
25	7.1609e-21	4.9845e-21	1.4496e-20	7.0957e-20	4.3148e-22
26	7.1792e-21	4.9886e-21	1.5777e-20	7.0957e-20	4.3251e-22
27	7.1976e-21	4.9926e-21	1.7057e-20	7.0964e-20	4.3354e-22
28	7.2160e-21	4.9966e-21	1.8336e-20	7.1014e-20	4.3458e-22
29	7.2344e-21	4.9991e-21	1.9614e-20	7.1119e-20	4.3561e-22
30	7.2401e-21	4.9992e-21	2.1995e-20	7.1224e-20	4.3647e-22

10.2 第一题部分代码

滑动窗口法建立累计疲劳损伤

```
1. % 向量化处理
2. for t = 1:length(Time)
3.     % 滑动窗口数据
4.     window_data_thrust = entend_thrust_data((t):window_size+t, :);
5.     window_data_torque = entend_torque_data((t):window_size+t, :);
6.
7.     % 计算应力幅值（最大值 - 最小值）
```

```

8.     delta_S_thrust = (max(window_data_thrust) - min(window_data_thrust))/2;
9.     delta_S_torque = (max(window_data_torque) - min(window_data_torque))/2;
10.
11.    % 计算应力均值
12.    mean_stress_thrust = mean(window_data_thrust);
13.    mean_stress_torque = mean(window_data_torque);
14.
15.    % Goodman 修正后的幅值计算
16.    L_thrust = delta_S_thrust ./ (1 - mean_stress_thrust / sigma_b);
17.    L_torque = delta_S_torque ./ (1 - mean_stress_torque / sigma_b);
18.
19.    % 损伤增量计算
20.    N_F_thrust = C ./ (L_thrust .^ m);
21.    N_F_torque = C ./ (L_torque .^ m);
22.
23.    D_increment_thrust = 1 ./ N_F_thrust;
24.    D_increment_torque = 1 ./ N_F_torque;
25.
26.    % 累积损伤
27.    damage_cumulative_thrust_second(:, t) = D_increment_thrust;
28.    damage_cumulative_torque_second(:, t) = D_increment_torque;
29.    if t==1
30.        damage_cumulative_thrust(:, t) =D_increment_thrust';
31.        damage_cumulative_torque(:, t) =D_increment_torque';
32.        continue;
33.    end
34.    damage_cumulative_thrust(:, t) = damage_cumulative_thrust(:, t-1) + D_increment_thrust';
35.    damage_cumulative_torque(:, t) = damage_cumulative_torque(:, t-1) + D_increment_torque';
36.
37. end

```

10.3 第二题答案（主轴扭矩、前 5 台风机、前 30 条）

时间	WT1	WT2	WT3	WT4	WT5
1	3.8178e+06	3.4083e+06	3.5439e+06	2.6125e+06	3.8868e+06
2	2.9116e+06	3.9336e+06	3.7974e+06	3.0931e+06	3.9606e+06
3	3.3835e+06	4.0579e+06	3.2857e+06	2.8017e+06	3.6495e+06
4	3.1602e+06	3.4999e+06	3.8490e+06	2.8263e+06	3.1979e+06
5	3.9713e+06	2.5771e+06	3.8323e+06	2.9386e+06	3.7722e+06
6	2.5726e+06	2.6532e+06	3.0177e+06	3.1098e+06	2.4979e+06
7	3.0212e+06	2.9931e+06	3.6242e+06	3.7452e+06	2.4941e+06
8	3.2813e+06	2.7824e+06	2.7124e+06	3.9363e+06	2.6498e+06
9	2.6047e+06	3.8931e+06	4.0033e+06	2.7495e+06	3.1348e+06

10	3.3222e+06	2.8663e+06	3.1414e+06	3.0013e+06	3.3448e+06
11	3.2095e+06	2.6892e+06	3.1610e+06	2.9689e+06	3.1562e+06
12	3.4753e+06	3.5690e+06	3.0238e+06	3.0231e+06	3.2996e+06
13	2.8515e+06	3.5344e+06	3.2572e+06	3.6340e+06	3.2413e+06
14	3.6657e+06	2.9648e+06	3.9868e+06	3.0972e+06	3.0871e+06
15	2.7211e+06	3.1377e+06	3.3809e+06	3.9388e+06	3.7507e+06
16	3.3225e+06	3.5862e+06	2.5529e+06	3.8049e+06	2.8416e+06
17	2.8984e+06	3.6146e+06	3.8466e+06	3.5406e+06	3.1567e+06
18	3.3162e+06	3.0613e+06	3.4411e+06	3.4738e+06	3.8533e+06
19	2.8994e+06	2.5507e+06	2.8707e+06	2.8324e+06	3.4627e+06
20	2.9593e+06	2.6334e+06	3.8692e+06	2.8199e+06	3.6762e+06
21	3.7647e+06	3.0571e+06	3.2019e+06	3.5588e+06	2.7609e+06
22	3.8774e+06	3.6682e+06	3.7065e+06	3.4301e+06	3.8407e+06
23	3.5083e+06	2.7137e+06	3.9475e+06	2.6350e+06	3.4432e+06
24	3.7816e+06	3.0264e+06	3.7412e+06	3.1729e+06	3.3038e+06
25	3.4872e+06	3.8498e+06	3.3016e+06	2.7870e+06	3.3311e+06
26	3.0314e+06	3.4991e+06	3.8651e+06	3.3182e+06	2.7076e+06
27	2.5774e+06	3.8225e+06	3.7875e+06	3.0963e+06	3.9623e+06
28	2.9299e+06	2.6185e+06	3.3857e+06	2.6783e+06	2.5380e+06
29	2.7976e+06	3.0887e+06	2.5682e+06	3.5538e+06	3.0218e+06
30	3.9209e+06	3.2125e+06	3.1549e+06	2.6014e+06	3.2739e+06

10.4 第二题部分代码

根据风速和功率估算主轴扭矩和塔架推力

```

1. % 设定常数
2. rho = 1.205; % 空气密度 kg/m^3
3. R = 64.5; % 叶片半径, 假设为 50m
4. A = 13685; % 风机扫风面积
5.
6. % 功率系数 Cp 的计算公式
7. calculate_Cp = @(lamdaR, beta) ...
8.     0.5176 * (116 ./ (1 ./ (1 ./ (lamdaR + 0.08 .* beta) - 0.035 ./ (beta.^3 + 1)))) - 0.4 * beta -
9.     5) .* ...
10.     exp(-21 ./ (1 ./ (1 ./ (lamdaR + 0.08 .* beta) - 0.035 ./ (beta.^3 + 1)))) + 0.0068 .* lamdaR;
11.
12. % 叶尖速比 lamda 的计算公式
13. calculate_lamda = @(omegaR, R, windSpeed) (omegaR .* R) ./ windSpeed;
14.
15. % 主轴扭矩 Tshaft 的计算公式
16. calculate_Tshaft = @(Pref, omegaR) Pref ./ omegaR ./ 0.945;
17.
18. % 塔架推力 Ft 的计算公式

```

```

18. calculate_Ft = @(windSpeed, Cp, pitch) 3 * 0.5 * rho * A * Cp * 1.5 .* windSpeed .* windSpeed .* (
    1 - sin(pitch * pi / 180)) - 978700;
19.
20. % 遍历所有时间点，计算 Cp，主轴扭矩 Tshaft，塔架推力 Ft
21. df.lamdaR = calculate_lamda(df.omegaR, R, df.windSpeed);
22. df.Cp = calculate_Cp(df.lamdaR, df.pitch);
23. df.Tshaft_estimated = calculate_Tshaft(df.Pref, df.omegaR);
24. df.Ft_estimated = calculate_Ft(df.windSpeed, df.Cp, df.pitch);
25.
26. % 提取 Tshaft_estimated 和 Tshaft 的数据
27. estimated_values = df.Ft_estimated(1:2000);
28. reference_values = df.Ft(1:2000);
29.
30. % 计算误差
31. errors = estimated_values - reference_values;
32.
33. % 计算误差平方和
34. squared_error_sum = sum(errors.^2);

```

10.5 第三题部分代码

遗传算法

```

1. function [Population, his_objs] = GeneticAlgorithm(N, D, G, P, V)
2.     MaxFex = G*N; %最大评价次数
3.     Fex=0; %当前评价次数
4.     upper=min((5*1e6)/P, (1e6/P)+(1/D));
5.     lower=max(0, (1/D)-(1e6/P));
6.     Population = Initialization(N,D,Fex,lower,upper,P,V);
7.     his_objs=[];
8.     while (Fex<MaxFex)
9.         %Fex
10.        MatingPool=TournamentSelection(2,N,Population.objs);
11.        Parentpool.decs=Population.decs(MatingPool,:);
12.        Parentpool.objs=Population.objs(MatingPool,:);
13.        %生成子代
14.        OffDec=OperatorGA(Parentpool,lower,upper);
15.        Offspring.decs=OffDec;
16.        %评价
17.        Offspring=evaluation(Offspring, P, V, D);
18.        Fex=Fex+N;
19.        Population=enviornmentalSelection(Population,Offspring);
20.        his_objs=[his_objs,Population.objs];
21.    end
22. end

```

目标函数

```
1. function [Population, his_objs] = GeneticAlgorithm(N, D, G, P, V)
2.     MaxFex = G*N; %最大评价次数
3.     Fex=0; %当前评价次数
4.     upper=min((5*1e6)/P, (1e6/P)+(1/D));
5.     lower=max(0, (1/D)-(1e6/P));
6.     Population = Initialization(N,D,Fex,lower,upper,P,V);
7.     his_objs=[];
8.     while (Fex<MaxFex)
9.         %Fex
10.        MatingPool=TournamentSelection(2,N,Population.objs);
11.        Parentpool.decs=Population.decs(MatingPool,:);
12.        Parentpool.objs=Population.objs(MatingPool,:);
13.        %生成子代
14.        OffDec=OperatorGA(Parentpool,lower,upper);
15.        Offspring.decs=OffDec;
16.        %评价
17.        Offspring=evaluation(Offspring, P, V, D);
18.        Fex=Fex+N;
19.        Population=enviornmentalSelection(Population,Offspring);
20.        his_objs=[his_objs,Population.objs];
21.    end
22. end
```

10.6 第四题部分代码

卡尔曼滤波

```
1. function V_filtered = KalmanFilter(V_noise, Q, R)
2.     % 获取数据尺寸
3.     [n_samples, n_turbines] = size(V_noise);
4.
5.     % 预分配存储滤波后的数据
6.     V_filtered = zeros(n_samples, n_turbines);
7.
8.     % 卡尔曼滤波参数初始化
9.     A = 1; % 状态转移矩阵
10.    H = 1; % 测量矩阵
11.    P = 1; % 初始状态协方差
12.    x_est = 0; % 初始状态估计
13.
14.    % 对每个风机进行卡尔曼滤波
15.    for turbine = 1:n_turbines
16.        for t = 1:n_samples
17.            % 预测阶段
```

```

18.         x_pred = A * x_est;
19.         P_pred = A * P * A' + Q;
20.
21.         % 更新阶段
22.         K = P_pred * H' / (H * P_pred * H' + R);
23.         x_est = x_pred + K * (V_noise(t, turbine) - H * x_pred);
24.         P = (1 - K * H) * P_pred;
25.
26.         % 保存滤波后的结果
27.         V_filtered(t, turbine) = x_est;
28.     end
29. end
30. end

```