



中国研究生创新实践系列大赛
“华为杯”第二十一届中国研究生
数学建模竞赛

学 校	福州大学	
参赛队号	24103860012	
队员姓名	1.	欧成光
	2.	詹鹏翔
	3.	余佳硕

中国研究生创新实践系列大赛
“华为杯”第二十一届中国研究生
数学建模竞赛

题 目： 数据驱动下磁性元件的磁芯损耗建模

摘 要：

磁性元件（如变压器、电感）是功率变换器中不可或缺的核心器件，广泛应用于轨道交通、电动汽车、信息通讯等领域。在设计磁性元件时，除了电气参数需要符合要求外，还要求磁性材料在高频交变磁通下的磁芯损耗较低。然而，目前尚无一种高精度且通用的损耗预测模型能够满足实际应用需求。为此，本文构建了一种基于数据驱动的磁芯损耗模型，并进一步探索磁性元件损耗特性。

针对问题一，为提取反映磁通量密度分布的波形形状特征，我们从两个角度进行特征提取。首先，通过**统计特征分析**，选取波形的峰度、偏度等 **8 种统计特征**；其次，通过几何特征分析，利用可视化探索几何分布，并筛选出 **11 种数学表征的几何特征**。接着，基于决策树和随机森林算法计算特征的重要性，最终选取**峰度、幅度前 k 大的频率和幅度**为有效特征，并进行**相关性分析**。为提高模型预测的健壮性，选择**决策树、随机森林和逻辑回归模型**，分别对全部特征和筛选特征进行训练与测试，最终通过投票法确定分类结果，并对附件二中的数据进行预测。

针对问题二，题目要求对原始斯坦麦茨方程进行修正，构造可适用于不同温度下的磁芯损耗预测方程。对此，我们首先分析原始斯坦麦茨方程，经过**对数变换**后通过**最小二乘法**求解参数。我们结合**统计误差分析**和**可视化数据分析**，提出温度对磁芯损耗的**线性/非线性影响假设**。我们将温度作为**线性项/对数变换项**对斯坦麦茨方程进行修正，提出了 **6 种修正方程假设**。经过模型参数求解和测试后，我们找出了拟合效果最好的修正方程，并对其在材料 1、正弦波下与原始斯坦麦茨方程的预测效果进行比较和分析。修正方程的误差相比原始斯坦麦茨方程显著减少，降低近 **4 倍**， R^2 从 0.929979 提升至 0.985661。

针对问题三，要求分析温度、励磁波形、磁芯材料三种离散因素对磁芯损耗的影响。为满足方差齐性和正态性假设，我们对损耗数据进行了对数变换，使其更接近正态分布。对于三种因素下的 48 种组合方案，我们按频率排序，并采用分层随机抽样法随机抽取 50 条数据。然后，通过单因素和双因素方差分析，评估各因素及其两两交互对磁芯损耗的影响。利用热力图和数据可视化分析，在低频条件下，材料 4、正弦波、90℃的组合表现出最低损耗；而在高频条件下，材料 4、正弦波、70℃为最优组合。

针对问题四，为设计通用的磁芯损耗预测模型，我们首先基于问题二中的修正斯坦茨方程，引入 one-hot 编码和等效正弦波频率对其进一步改进。尽管验证结果未取得理想效果，但为后续改进提供了重要思路。鉴于特征间存在复杂的非线性关系，我们采用了机器学习方法，构建了 9 种不同的机器学习模型，对温度、频率、波形、材料和磁通密度峰值五个主要特征进行训练，验证结果显示效果良好。为了进一步提升模型性能，我们增加了问题一中提取的峰值特征来描述磁通密度分布，验证表明模型拟合效果得到了进一步改进。随后，我们引入了基于磁通密度变化率($dB(t)/dt$)的 IGSE 预测模型，并通过模型堆叠的方式，将 IGSE 计算结果作为先验知识进行训练。此方法结合了可解释性与非线性学习能力，最终 CatBoost 模型在此特征组合上取得了最佳预测效果，取得平均相对误差 0.03542。

针对问题五，为解决在实现最小磁芯损耗的同时最大化传输磁能（频率与磁通密度峰值的乘积）的双目标优化问题，我们结合问题三中的分析结果，设定最低磁芯损耗条件：材料 4、正弦波、70℃或 90℃。我们采用遗传算法、粒子群优化算法和灰狼优化算法，结合问题四中基于五种基本特征训练的 CatBoost 模型进行优化求解。结果表明，在频率约 188,000 Hz、温度 90℃、正弦波、磁通密度峰值为 0.012、材料四的条件下，灰狼优化算法表现出最优解。为确保结果的严谨性，我们进一步使用灰狼优化算法对 48 种离散变量组合进行了优化实验，验证了其稳健性和效果。

关键词：特征重要性分析、多元线性回归、方差分析、模型堆叠、灰狼优化算法

目录

一、问题重述	5
1.1 问题背景	5
1.2 问题的提出	6
二、总体技术路线图	8
三、基本假设与符号说明	9
3.1 基本假设	9
3.2 符号说明	9
四、数据预处理	10
五、问题一模型建立与求解分析	12
5.1 问题一分析与思路	12
5.2 特征提取	13
5.3 分类模型的建立与求解	15
5.4 模型总结	22
5.5 最终分类模型的建立与预测	24
六、问题二模型建立与求解分析	27
6.1 问题二的分析与思路	27
6.2 数据处理与分析	27
6.3 斯坦麦茨方程分析与求解	28
6.4 数据可视化与分析	29
6.4 修正斯坦麦茨方程设计思路和验证	31
6.5 总结与分析	36
七、问题三 磁芯损耗因素分析	38
7.1 问题分析	38
7.2 数据准备	39
7.3 单因素方差分析	41
7.3.1 温度	41
7.3.2 励磁波形	41
7.3.3 磁芯材料	42
7.4 双因素方差分析	42
7.4.1 励磁波形+温度	42
7.4.2 温度+磁芯材料	43
7.4.3 磁芯材料+励磁波形	44
7.5 结论	46
八、问题四模型建立与求解分析	49
8.1 问题四的分析与思路	49

8.2 特征提取	50
8.3 回归模型的建立和求解	51
8.3.1 改进斯坦麦茨方程	51
8.3.2 机器学习方法模型介绍	52
8.4 预测与模型总结	58
九、问题五模型建立与求解分析	61
9.1 分析与思路	61
9.2 模型的建立、求解	62
9.2.1 优化算法	62
9.2.2 特征向量	65
9.3 预测与模型总结	65
十、模型评价和改进	68
10.1 模型优点	68
10.2 模型缺点	68
10.3 模型的改进和推广	69
参考文献	70
附录	71

一、问题重述

1.1 问题背景

磁性元件（如变压器、电感等）在现代电力电子技术中发挥着不可或缺的作用，负责磁能的传递、存储和滤波等功能。其器件参数对于功率变换器在电力传输中的体积、重量、损耗及成本等方面具有至关重要的影响。因此，提升磁性元件的性能指标、研发新型磁性材料，以及探索磁性材料的最佳运行条件，对促进国民经济发展和社会进步起到关键推动作用。这不仅能够推动我国新能源和通信领域的技术进步，还将提升我国在这些领域的国际竞争力。

为了获得高效率和高功率密度的设计，除了满足磁性元件电气参数的可行性设计外，还要求其各项损耗最小化。因此，必须详细研究和分析磁性元件的损耗特性，磁性元件的损耗包括绕组损耗和磁芯损耗。其中损耗可以通过电磁场有限元仿真技术准确获得，然而磁芯损耗是磁性材料在高频交变磁通作用下产生的功率损耗。由于高频磁性材料微观结构复杂，且其损耗与工作频率、磁通密度、励磁波形、工作温度、磁芯材料等诸多因素有关，并呈现复杂的非线性和相互关联性。现有的磁芯材料损耗模型与实际应用的需求有较大差异。

目前，磁芯损耗模型主要分为两大类：损耗分离模型和经验计算模型。

（1）磁芯损耗分离模型：将磁芯损耗分成 3 个部分：磁滞损耗、涡流损耗和剩余损耗^[1]。其计算公式如下：

$$P_{core} = P_h + P_{cl} + P_e$$

其中： P_{core} 为总的磁芯损耗密度； P_h 为磁滞损耗； P_{cl} 为涡流损耗； P_e 为剩余损耗。

（2）磁芯损耗经验计算模型：经验计算模型较为简便，它基于实验数据或理论推导得出的经验公式来估算磁芯损耗。斯坦麦茨方程（Steinmetz-equation, SE）是最著名的经验计算模型之一。在正弦波励磁下，磁芯损耗计算公式如下：

$$P = k_1 \cdot f^{\alpha_1} \cdot B_m^{\beta_1}$$

其中： P 为磁芯损耗； f 是频率； B_m 是磁通密度的峰值； k_1 、 α_1 、 β_1 是根据实验数据拟合的系数，一般 $1 < \alpha_1 < 3$ ， $2 < \beta_1 < 3$ 。目前已经观察到磁芯损耗同时与温度、材料、频率、磁通密度的峰值存在复杂的线性和非线性关系。尽管后续提出了修正斯坦麦茨方程

^[2] (Modified SE, MSE) 和 IGSE (Improved Generalized SE) 修正了不同波型对于磁芯损耗的影响。但影响磁芯损耗的因素较多, 现阶段还没有一个普遍适用并能实现较高精度的模型, 这使得业内在使用磁性元件时无法对磁芯损耗做出精确的评估, 进而影响到对功率变换器效率的评估。因此, 希望基于数据驱动, 建立一个高精度并且普遍适用于各种工况的磁芯损耗模型成为亟待解决的问题。

1.2 问题的提出

针对磁芯损耗估计, 题目中共给出了 4 组附件数据。其中附件一为训练集, 包含针对 4 种不同磁芯材料在不同温度、频率、波形等工况下的测试数据。附件二、附件三均为测试集, 分别隐去了部分列, 要求我们建立不同的模型解决以下五个问题, 并根据所建模型预测隐去的部分列, 并将数据结果填入附件四中。

问题一：励磁波形分类

分析附件一中磁通密度分布特征及不同波形的形状特征, 提取出反映磁通密度波形的形状特征变量, 建立分类模型, 用于识别三种励磁波形, 并分析分类模型的合理性及有效性, 最后利用模型对附件二中的样本进行识别, 将分类结果填入附件四中。

问题二：斯坦麦茨方程修正

分析斯坦麦茨方程在同一种磁芯材料、正弦波形下, 对不同温度变化下磁芯损耗预测效果差异, 并在原有斯坦麦茨方程基础上增加温度因素, 构造一种可适用于不同温度变化的修正方程。并以附件一材料 1 的正弦波形数据为例, 分析优化预测结果。

问题三：磁芯损耗因素分析

温度、励磁波形以及磁芯材料是最常见的三大影响要素。题目要求依托实验数据, 剖析三者对磁芯损耗的独立或协同作用, 分析并给出实现最低磁芯损耗的最优条件。

问题四：基于数据驱动的磁芯损耗预测模型

利用附件一中的实验数据, 通过数据分析与建模技术, 构建磁芯损耗预测模型, 分析模型的预测精度、泛化能力, 以及对业界的各种指导意义。同时对附件三中样本的磁芯损耗进行预测, 把预测结果填入附件四中。

问题五：磁性元件的最优化条件

为了实现磁性元件整体性能的卓越与最优化, 需要综合考虑传输磁能和磁芯损耗评价指标。题目要求以问题四构建的磁芯损耗预测模型为目标函数, 同时考虑传输磁能 (以频

率与磁通密度峰值的乘积 $f \times B_m$ 来衡量传输磁能大小），利用附件一中的实验数据，建立优化模型，分析温度、频率、波形、磁通密度峰值及磁芯材料满足何种条件下，能达到最小的磁芯损耗以及具有最大的传输磁能。

二、总体技术路线图

本文的技术路线如下：




图 2-1 全文技术路线图

三、基本假设与符号说明

3.1 基本假设

在分析与建模过程中，根据提供的训练数据做出以下假设：假设 1：本题附件中提供的所有关于磁芯损耗相关数据全部真实有效；假设 2：本题附件中的所有数据不存在异常值和缺失值，并且定类数据标注无误。假设 3：在一定的温度条件下，实验所用材料的内部结构与外部形态不会发生变化假设 4：本题附件中不同样本表示不同工况下的数据结果，样本之间都相互独立。

3.2 符号说明

表 3-1 本文符号表说明

符号	符号说明
$a_1, a_2, a_3 \dots$	波形的斜率
$f_1, f_2, f_3 \dots$	励磁波形傅立叶变换后对应的频率
$s_1, s_2, s_3 \dots$	励磁波形傅里叶变换频率对应的幅度
k_1	斯坦麦茨方程与其修正方程中的参数
n_t	决策树中节点 t 的重要性
n	数据的数量
p_i^2	类别 i 在数据集 D 中的概率
B_m	磁通密度的峰值
ΔB	磁通密度在一个周期内的峰峰值
C	决策树中类别总数
E	期望值
F	方差分析中统计量，用于比较两个方差之间的比率
$F1$	F1 召回率
G_t, G_r, G_l	决策树中节点 t 以及其右节点、左节点的不纯度
P	磁芯损耗 或者 在统计测试中， P 值用于决定是否拒绝原假设
R^2	决定系数，用于衡量回归模型对观测数据的拟合程度
X	波形信号的样本值
f	频率
$\alpha_1, \beta_1, \gamma_1, \eta_1, \theta_1$	磁芯损耗修正方程中的参数
ρ	斯皮尔曼相关系数
μ	均值
σ	标准差与逻辑函数 $\sigma(x)$ 的符号表示

四、数据预处理

题目中共给出了 4 组附件数据。附件一为训练集，有 4 个数据表，分别表示来自 4 种不同磁芯材料所测的数据。每一行的特征包括温度、频率、磁芯损耗、励磁波形类型、以及 1024 个磁通密度采样所得到的值。每一行表示磁芯在一种工况下的实验结果，不同行表示不同的工况。其中由于磁芯材料的复杂性，我们仅用材料 1、材料 2、材料 3、材料 4 来表示不同材料，附件一中包含有 3400 个关于材料一的工况，有 3000 个关于材料二的工况，有 3200 个关于材料三的工况，有 2800 个关于材料四的工况。（这边可以画个柱状图）。

附件二、附件三均为测试集，其中附件二的前 4 列分别是样本序号、温度、频率、磁芯材料，第 5—1029 列是磁通密度。附件三第 1 列是样本序号，其他除磁芯损耗改为磁芯材料外，与附件一中相应的结构、格式、含义相同。附件四为答案文件，需要通过模型构建及计算得到。

我们对附件一中的各项数据进行频数分析，研究波形、温度、频率、材料及峰值的变量分布情况，并进行了如下描述：首先，波形的分布显示，三角波是最常用的波形，频数为 4948，占比 39.903%；其次是正弦波，频数为 4054，占比 32.694%；梯形波的频数较低，为 3398，占比 27.403%。这一结果表明，三角波在实验中使用频率较高，而正弦波和梯形波的使用相对均衡。温度的分布较为均匀，25.0° C 的频数为 3244，占比 26.161%；50.0° C 的频数为 3070，占比 24.758%；70.0° C 的频数为 3030，占比 24.435%；90.0° C 的频数为 3056，占比 24.645%。这表明实验数据中，四个温度条件的分布非常接近，各温度段在实验中均得到了充分代表。频率的分布结果显示，频率范围[49990.0, 162787.5)的频数为 6800，占比 54.839%，为主要频段；频率范围[162787.5, 275585.0)的频数为 2649，占比 21.363%；频率范围[275585.0, 388382.5)的频数为 1356，占比 10.935%；而频率范围[388382.5, 501180.0]的频数为 1595，占比 12.863%。数据表明，大多数实验条件下的频率集中在较低的区间。材料的分布显示，材料 1 的频数最高，为 3400，占比 27.419%；其次是材料 3，频数为 3200，占比 25.806%；材料 2 和材料 4 的频数相对较低，分别为 3000（占比 24.194%）和 2800（占比 22.581%）。该结果显示材料的使用存在一定的差异，材料 1 的使用相对较多。

峰值的分布分析结果显示，大部分数据集中在区间[0.01, 0.086)，其频数为 8362，占比 67.435%；峰值范围[0.086, 0.161)的频数为 2586，占比 20.855%；而峰值在更高区间（[0.161, 0.237)、[0.237, 0.313]）的频数明显减少，分别为 802（占比 6.468%）和 650（占比 5.242%）。这表明在实验条件中，较小的峰值占据了大部分样本数据。




图 4-1 变量分布图

综上所述，本次频数分析揭示了波形、温度、频率、材料和峰值在实验中的使用及分布情况，各变量的多样性为后续的分析提供了广泛的代表性。

五、问题一模型建立与求解分析

5.1 问题一分析与思路

根据问题一的要求，需要深入理解磁通密度的分布特征和不同波型的形状特征提取出能够反映磁通密度分布和波型形状特征的变量，建立模型准确识别出励磁波型类型。观察附件一中的训练数据，每个样本磁通密度分布通过一组数量为 1024 的浮点类型数据进行表示，并且每个样本均标明所属的波型类型。因此，我们解决该问题的思路按照如下步骤进行，其流程图如图 5-1 所示。




图 5-1 问题一思路流程图

首先，我们从两个角度选取反映磁通密度分布和波型形状的特征：

- 1) **统计特征提取**：通过计算一组数据的基本统计量，如最大值、最小值、均值、方差、偏度和峰度等，来描述数据的集中趋势和离散程度。
- 2) **几何特征分析**：通过可视化方法来探索数据的分布形态特征，通过观察图形的形状、对称性和集中程度，识别潜在的特征。

汇总以上两个角度选取的特征，整合样本波型类型作为标签，利用五折交叉验证方法将附件一中的全部样本划分为训练集和测试集，作为后续训练和测试分类模型的输入。为了更好的选取合适的特征，我们使用决策树模型和随机森林模型对特征重要性进行评价，判断挑选的特征对决策的影响。最后，根据题目要求我们对选取的有效特征尝试进行机理分析，总结经验并填写题目要求的相应结果表格。

5.2 特征提取

针对三种励磁波形，我们对其在不同材料下的形状特点进行可视化，通过随机选取不同材料下的三种波型类型，绘制波形曲线如图 5-2 所示，可以发现波形的形状特征在不同材料下没有显著变化。同时图 5-2 的可视化结果帮助我们对波形特征有着更深刻的认识。接下来，我们分别进行统计特征提取和几何特征分析。




图 5-2 不同材料下波形可视化

(1) 统计特征提取

针对波形数据，常见的统计学特征包括：均值、中位数、方差、偏度、最小值/最大值、四分位数、峰度，每种特征的含义如表 X 所示：

表 5-1 选取的统计特征及含义

特征	含义
均值	数据的算术平均值，反映数据的集中趋势。
中位数	将数据按大小排序后位于中间位置的值，表示数据的中间值。
方差	衡量数据与均值之间的离散程度，数值越大表示数据分散越广。
偏度	衡量数据分布的对称性，偏度为零表示对称，正值表示右偏。
最小值/最大值	数据集中最小的值/数据集中最大的值。
四分位数	将数据分成四个部分的值，第一四分位数(Q1)为下 25%，中位数(Q2)为 50%，第三四分位数(Q3)为 75%。
峰度	描述数据分布的尖锐程度，峰度高表示数据集中在均值附近。

(2) 几何特征分析

基于图 5-2 的可视化结果，我们分别针对正弦波、三角波和梯形波的形状特征进行分析，并尝试通过数学方法进行表征：

正弦波：波形形状是一个平滑的曲线，无拐点。

三角波：波形形状类似锯齿，上升部分和下降部分斜率无明显变化，拐点数量为 2，并且拐点处即为波形的峰值所在处。

梯形波：波形形状与三角波类似，但是在上升部分包含两个额外的拐点，下降部分斜率无明显变化，总拐点数量为 4；此外，在上升部分的 3 段斜率 a_1 ， a_2 和 a_3 之间的关系为 $a_2 > a_1 \approx a_3$ 。

通过上述观察，我们设计了 **2 种**特征计算方法对观察到的波形特点进行表征：

1.幅度前 k 大信号频率和幅度：研究波形的主要信号组成是区分波形形状特征的主要方法之一。在信号处理中，每种模型都可以通过不同频率下的正弦波组合叠加得到，快速傅立叶变换（FFT）算法高效的实现了这一过程。通过傅立叶变换，我们可以解析出信号中不同频率成分的强度和相位，从而识别波形特征。由于波形在大部分频率上的振幅接近 0，因此我们选择幅度前 k 大的信号频率作为表征波形的几何特征。图 5-3 展示了三种波形在快速傅立叶变换的频域信号分布（图中取幅度排行前 10 的信号进行展示且频域分布的 y 轴经过归一化处理），其中正弦波由于直接由正弦信号组成，因此仅包含 1 个频率信号，而三角波和梯形波在快速傅立叶变换后可以观察到主要频率信号的分布存在明显差异。




图 5-3 三种波形快速傅立叶变换示例

2. 二阶导数非 0 值数量：二阶导数非零值是用于识别波形拐点的重要方法之一，由于拐点处左右斜率不同，因此在拐点处取三个点可以计算得到二阶导数非 0。而在斜率不变情况下，计算二阶导数则值为 0。考虑到本题数据通过精确的信号采样获得，因此我们设定一个极小的阈值用于判断二阶导数是否为 0。

特征选择：对于综合上述两个角度获取的特征，我们根据观察和经验进行初步的特征选择，特别是对于统计特征，经过分析我们决定丢弃均值、中位数，由于三种波形在正区间和负区间上的面积基本一致，因此均值和中位数均接近 0，与波形类型不存在相关性。针对幅度前 k 大信号频率和幅度特征，我们观察到三角波和梯形波大多仅仅具有 5 个显著组成频率信号，因此我们对取值为 5。对于剩下的特征，我们全部选取并通过五折交叉验证将数据集划分为训练集和测试集。这种方法确保每个数据子集都能作为测试集，从而提供更全面的模型评估。通过这种系统的特征选择和数据划分策略，我们能够有效降低过拟合的风险，并提高模型在实际应用中的预测能力。

5.3 分类模型的建立与求解

经过特征挑选，我们共选择了 19 个特征作为模型训练的输入：方差、偏度、最小值、最大值、四分位数（Q1、Q2、Q3）、峰度、幅度前 k 大信号频率和幅度（f1、f2、f3、f4、

f5、s1、s2、s3、s4、s5)、二阶导数非 0 值数量。我们选择三个传统的机器学习分类模型对输入特征进行训练，并分析预测准确率和选择特征的相关度。

(1) 决策树模型

决策树模型是一种基于树形结构的监督学习算法，广泛应用于分类和回归任务。它通过将数据集分割成更小的子集，形成树形结构的节点，每个内部节点表示对某个特征的测试，而每个叶子节点则表示最终的决策结果。决策树的优点包括易于理解和解释，能够处理非线性关系，并且不需要对数据进行特定的预处理。它适用于各种数据类型，包括数值型和类别型数据。

模型训练：决策树算法的训练过程可以概括为以下几个步骤：1. 将当前样本作为根节点，开始特征选择，从所有特征中使用基尼指数（Gini Index）选择一个最佳特征。基尼指数用于衡量数据的不纯度，其计算公式为：

$$Gini(D) = 1 - \sum_{i=1}^C p_i^2$$

其中， p_i^2 是类别*i*在数据集 *D* 中的概率，*C* 是类别总数。基尼指数越小，数据的不纯度越低，说明该特征越有效；2. 数据分割：根据选定的特征，将数据集分割成多个子集，每个子集对应于特征的不同取值，形成树的分支；3 递归构建：对每个子集重复步骤 1 和 2，继续选择最佳特征并分割数据，直到满足停止条件：达到预定的树深度、子集中的样本数量小于某个阈值、子集内的标签完全一致；4. 创建叶子节点：当满足停止条件时，生成叶子节点，并将其标记为相应的类别，叶子节点的标签通常是子集中样本的多数类别。

决策树算法可以在分类的基础上反过来对特征进行回归分析，通过**将样本分类的结果进行一定的运算可以获得各个特征重要性特征的重要性**，从而可以表示特征对预测结果的重要性，某一特征重要性越大，表明该特征对预测结果的贡献度越大，重要性越小，表明该特征对预测结果的贡献度越小。在决策树中，计算某一个节点 *t* 的重要性：

$$n_t = \omega_t^* G_t - \omega_r^* G_r - \omega_l^* G_l$$

其中， $\omega_t, \omega_r, \omega_l$ 分别为节点 *t* 以及其右节点、左节点中训练样本与总训练样本数目的比例， G_t, G_r, G_l 分别为节点 *t* 以及其右节点、左节点的不纯度。知道每一个节点的重要性之后，即通过公式的得出某一特征的重要性。

$$f = \frac{\sum_{t \in \text{nodes split on feature } i} n_t}{\sum_{t \in \text{all nodes}} n_t}$$

训练结果：参数设置如表 5-2 所示我们对训练后的决策树进行可视化，如图 5-4 所示。在决策树分类模型的特征重要性评估中，结果显示出显著的不均衡性，其中峰度(Kurtosis)和 s4 特征占据了主导地位，分别贡献了 55.70%和 44.30%的重要性，而其余特征包括方差、偏度、最大值、最小值、二阶导非 0 值、各四分位数 (Q1、Q2、Q3)、以及 f 系列和 s 系列中的其他特征 (除 s4 外)，其重要性均为 0%。

表 5-2 决策树模型参数配置

参数名	参数值
节点分裂评价准则	gini
内部节点分裂的最小样本数	2
叶子节点的最小样本数	1
叶子节点中样本的最小权重	0
叶子节点的最大数量	50
树的最大深度	10
节点划分不纯度的阈值	0




图 5-4 决策树可视化

峰度对于分类决策具有显著影响，幅度特征 s4 同样对于分类决策有着一定的影响。相比之下，方差、偏度等常规统计量以及四分位数等描述性统计指标在此模型中的贡献几乎可以忽略不计。

模型精确度：为评估决策树模型的性能，我们通过四个常用指标——**准确率**（Accuracy）、**召回率**（Recall）、**精确率**（Precision）、以及 **F1 分数**（F1 Score），对训练集、交叉验证集和测试集进行了详细的分析。模型在所有数据集上的性能如表 5-3 所示。从结果中可以看出，决策树模型在训练、交叉验证和测试集上都达到了 100% 的准确率，意味着模型对所有样本进行了完全正确的分类。尽管模型在所有数据集上的性能都达到了完美状态，但这种情况在实际问题中通常较为罕见。这可能是因为数据集的样本数量较小、样本分布较为简单，或者特征高度可分，模型较易在训练和测试时获得完美的分类性能。

表 5-3 决策树模型精确度

	准确率	召回率	精确率	F1
训练集	1	1	1	1
交叉验证集	1	1	1	1
测试集	1	1	1	1

（2）随机森林模型

随机森林（Random Forest，简称 RF）是一种由美国科学家 Leo Breiman 在 2001 年提出的机器学习方法。作为一种灵活且新兴的算法，随机森林在多个分类和回归问题中展现出优异的准确性，并具备广泛的应用潜力。此外，随机森林还具备内置的特征选择功能，能够有效评估各特征在特定任务中的重要性。

模型训练：随机森林的训练过程包含以下几个步骤：1. 数据抽样：从原始样本集中使用自助采样法（Bootstrap）随机抽取多个样本集，通常每个样本集大小与原始数据集相同。2. 构建决策树：对于每个样本集，构建一棵决策树。在树的每个节点进行分裂时，从所有特征中随机选择一个特征子集。常用的分裂标准包括基尼指数和信息增益。3. 递归分裂：继续对每个子集进行分裂，直到达到停止条件，如最大树深度、叶子节点样本数

量少于某个阈值，或不再能够减少不纯度。4. 生成森林：重复上述步骤，训练多棵独立的决策树，形成一个随机森林模型。

随机森林在决策树的基础上增加了集成学习的能力，通过结合多棵决策树的预测结果来提高模型的准确性和稳定性。此外，随机森林引入了随机特征选择和自助采样法，这使得每棵树都基于不同的训练数据和特征组合，增强了模型的鲁棒性，并能够有效评估特征的重要性，从而更好地处理高维数据。经由多棵决策树结构，随机森林能够将各棵树的特征重要性综合，提供了可靠的特征重要性评分，帮助理解特征在特定任务中的贡献。我们对随机森林模型进行训练，相关配置参数如表 5-4 所示。

表 5-4 随机森林模型参数配置

参数名	参数值
节点分裂评价准则	gini
决策树数量	100
内部节点分裂的最小样本数	2
叶子节点的最小样本数	1
叶子节点中样本的最小权重	0
树的最大深度	10
叶子节点的最大数量	50
节点划分不纯度的阈值	0

结果分析：通过特征重要性进行判断，我们统计了 19 个结果对于分类任务的重要性，排序后的柱状图如图 5-5 所示。其中 s4 特征的重要性高达 22.40%，位居首位，表明该特征在分类决策中发挥了关键作用。紧随其后的是峰度和 s5，重要性分别为 19.50%和 16.40%。s2 和 s3 特征的重要性分别为 13.80%和 10.00%，显示出这些特征在提升模型分类性能方面的重要性不容忽视。虽然二阶导非零值、Q2、f4 等特征的重要性较低，介于 4.00%至 5.00%之间，但它们仍对模型的预测能力产生积极影响。另一方面，方差、最大值、最小值、Q1、Q3、f1、f2、f、s1 等特征的重要性极低，甚至为 0%，表明这些特征在当前数据集和模型构建中可能不包含有用信息，或者其信息已被其他显著特征所覆盖。




图 5-5 随机森林特征重要性分析结果

模型精确度：为了评估随机森林模型的性能，我们采用了准确率（Accuracy）、召回率（Recall）、精确率（Precision）、以及 F1 分数（F1 Score）作为评估指标，对训练集、交叉验证集和测试集进行了全面分析。尽管随机森林模型在训练集和测试集上的各项指标均为 1，显示出完美的分类能力，但在交叉验证集上稍微下降的性能表明，模型可能存在轻微的过拟合情况。特别是在交叉验证中的性能指标为 0.997，表明模型的泛化能力虽然很强，但在应对未见数据时仍可能存在少量误分类的可能性。总的来说，随机森林模型在当前的数据集上展示了非常强的学习和泛化能力。

表 5-5 随机森林模型精确度

	准确率	召回率	精确率	F1
训练集	1	1	1	1
交叉验证集	0.997	0.997	0.997	0.997
测试集	1	1	1	1

（3）逻辑回归模型

逻辑回归是一种广泛应用的分类算法，它通过建立特征与目标变量之间的关系，利用逻辑函数：

$$\sigma(x) = \frac{1}{1 + e^{-x}}$$

将线性组合的结果映射到 0 到 1 之间的概率值。模型的输出可以表示为某个类别的概率，从而进行分类决策。在实现三分类任务时，通常采用一对多（One-vs-Rest）策略，该方法为每个类别训练一个独立的逻辑回归模型，将该类别视为正类，其他类别视为负类。通过这种方式，每个模型输出一个概率值，表示输入样本属于该类别的可能性。在预测阶段，最终选择具有最高概率的类别作为样本的预测结果。我们通过梯度下降法训练逻辑回归模型，迭代训练 1000 次，收敛后完成模型训练。模型的相关参数配置如表 5-6 所示：

表 5-6 逻辑回归模型参数设置

参数名	参数值
设置常数项	true
误差收敛条件	0.001
最大迭代次数	1000

模型精确度：逻辑回归模型在训练集、交叉验证集和测试集上的各项指标都达到了 1，显示了极强的分类能力，但这同样可能是因为当前数据集可能具有较强的特征分离能力，或者类别分布较为简单。

表 5-7 逻辑回归模型精确度

	准确率	召回率	精确率	F1
训练集	1	1	1	1
交叉验证集	1	1	1	1
测试集	1	1	1	1

5.4 模型总结

根据 4.3 中选择的决策树模型和随机森林模型对各个特征在分类任务下的评价，因此我们观察到影响波形分类的主要因素包括统计特征中的**峰度**以及几何特征中的**幅度前 k 大信号频率和幅度**，接下来我们将重点关注上述两个重要特征，对其进一步的分析和判断。

(1) 峰度

峰度是用来描述波形信号分布特性的一个重要统计量，它反映了波形的尖锐程度以及尾部的厚度。对于波形数据，峰度的计算与一般数据相同，通常使用以下公式：

$$\text{Kurtosis} = \frac{E[(X - \mu)^4]}{\sigma^4} - 3$$

其中 E 是期望值， X 是波形信号的样本值， μ 是波形信号的均值， σ 是波形信号的标准差。峰度的大小实际上反映了信号中存在极端值的数量（如尖峰），通常当峰度大于 0 时，表明信号在瞬态响应或冲击波形中；当峰度小于 0 时，表示信号的分布相对平坦，数据集中没有显著的尖峰。需要注意的是，当峰度值为 0 时，信号恰好满足正态分布。

基于三种波形的形状背景下，我们可以对峰度进行进一步的拓展解释。对于正弦波，由于它是平滑曲线，因此峰度值处于一个最小的区间。对于三角波，由于其包含两个拐点，在拐点处产生类似尖峰的形状，导致峰度值位于一个较高的区间。对于梯形波，尽管其图像包含 4 个拐点，但是由于其上升过程中斜率 a_1 ， a_2 和 a_3 满足 $a_2 > a_1 \approx a_3$ 的关系，一定程度上缓解了最高值和最低值处“尖峰”产生的影响，因此梯形波的峰度值位于中间区间。为了验证上述猜想，我们将附件一中的全部数据进行峰度值的计算，并以箱型图的形式绘制，如图 5-6 所示。让我们感到意外的是，我们发现三种波形的峰度值范围均不互相重叠，因此可以直接通过设置阈值（ $\tau_1 = -1.25$ ， $\tau_2 = -1.45$ ）的方式，通过计算峰度值直接完成励磁波型的分类。




图 5-6 三种波形的峰度值

(2) 幅度前 k 大的频率和幅度

在 4.2 特征选择中我们简单介绍了将时域波形图经由快速傅立叶变换后得到的频域分布的优点，在这里我们将对其内在机理进行进一步的分析。通过决策树和随机森林的训练结果可以发现，特征重要性大于 10% 的特征中包含了幅度 s4(22.4%)、s5(16.4%)、s2(13.8%)、s3(10.0%)，而对应的频率 f 的重要性普遍不高，因此可以看出信号的幅度分布是影响波形特征的主要决定因素。深入到三种励磁波形，参考图 5-3 可以发现正弦波仅含有一个最大幅度信号，因此其在幅度 s4、s5、s2、s3 上的幅度值将近为 0，可以直接进行区分。此外，可以发现梯形波在 s5 上的幅度将近为 0，而三角波一直到第 7-8 个幅度才降低到将近为 0。考虑这一特性，我们重新构造决策树模型，仅采用 s5 作为评价特征，构造出来的决策树模型如图 5-7 所示，可以看到特征 s5 能够完成三种励磁波形的分类，并且达到 100% 的预测精度。




图 5-7 基于 s5 和 s4 构建决策树模型

(3) 特征相关性分析

本研究采用斯皮尔曼(Spearman)等级相关系数分析了变量 s5、s4 与峰关联性。斯皮尔曼相关系数:又称斯皮尔曼秩相关系数,是秩相关系数的一种。公式为:

$$\rho = 1 - \frac{6\sum d_i^2}{n(n^2 - 1)}$$

分析结果如图 5-8 所示,结果显示三者之间均存在极为显著的正相关关系 ($p < 0.001$, 标记为***)。具体而言, s5 与 s4 之间的相关系数高达 0.961, 表明两者之间存在极强的正向关联性呈直线型相关,且这种关联在统计上极其显著。同样, s5 与峰度、s4 与峰度之间的相关系数分别为 0.909 和 0.907, 亦表明它们之间的正相关关系极为紧密,尽管略低于 s5 与 s4 之间的关联强度,但同样在统计上具有极高的显著性。此分析结果强烈支持了变量间相互影响的假设,即 s5、s4 的增加伴随着峰度的同步上升,反之亦然。




图 5-8 特征相关性热力图

5.5 最终分类模型的建立与预测

(1) 最终分类模型的建立与预测

经过之前的步骤,我们有以下结论:

1. 我们选取了影响波形分类的最主要因素，即统计特征中的峰度以及几何特征中的幅度前 k 大信号频率和幅度，并验证了这两个特征对模型分类的有效性。为了模型能够实现更加正确的分类，考虑选择更多特征数量可能潜在的影响分类结果，因此我们不局限于选择这两个最重要特征。
2. 从 4.4 小节从实验结果得知，使用决策树模型、随机森林模型、逻辑回归模型可以实现励磁波形的正确分类，体现了分类模型的合理性与有效性。因此我们在最终预测也选择上述 3 种模型。
3. 为了实验结果更加的正确，不再把 4.4 小节中把附件一中的数据划分成训练集与测试集，改为把附件一中全部的数据作为训练集，即增加了分类模型输入的样本。在模型训练完后，完成对附件二中的数据进行励磁波形的预测。

综上所述：尽管 4.4 小节的模型已经可以达到对训练集接近 100%的准确率，但为了预测结果更加健壮，我们利用峰度和幅度前 k 大信号频率和幅度作为特征训练出 3 个模型，以及用之前 19 个特征训练出 3 个模型，训练集为附件一的全部数据。通过 6 个模型，对附件二进行预测，然后使用投票法得出最终结果。

表 5-8 问题一预测模型配置

特征选择	峰度、幅度前 k 大信号频率和幅度等等
训练集	附件一中全部数据（12400 条）
测试集	附件二中待预测数据（80 条）
模型选择	决策树模型、随机森林模型、逻辑回归模型
最终预测结果	投票汇总出结果

（2）附件二中三种波形数量：

励磁波形	数量
正弦波	20
三角波	44
梯形波	16

（3）附件二中部分样本预测结果展示：

样本序号	分类结果
1	2
5	2
15	1
25	2
35	3
45	3
55	2
65	2
75	2
80	1

六、问题二模型建立与求解分析

6.1 问题二的分析与思路

根据题目要求，我们需要对现有的斯坦麦茨方程进行分析，探究不同温度下对方程预测效果的影响。题目明确告知以下信息：1. 斯坦麦茨方程主要针对正弦波形设计；2. 对于不同种类的磁芯材料及工作温度的变化，斯坦麦茨方程会造成较大的误差。因此我们解决本题的思路是：1. 数据分析和预处理；2. 首先分析目前斯坦麦茨方程，尝试理解并根据数据集求解参数；3. 对数据进行可视化，不同材料下温度对斯坦麦茨方程的影响，提出改进方程的可行方式假设；4. 不断对假设进行验证，分析改进方程对数据的拟合情况并提出新的假设，往复尝试并验证结果；5. 对不同改进方法的预测效果进行综合分析，总结经验为后续问题服务。整体思路如图 6-1 所示。

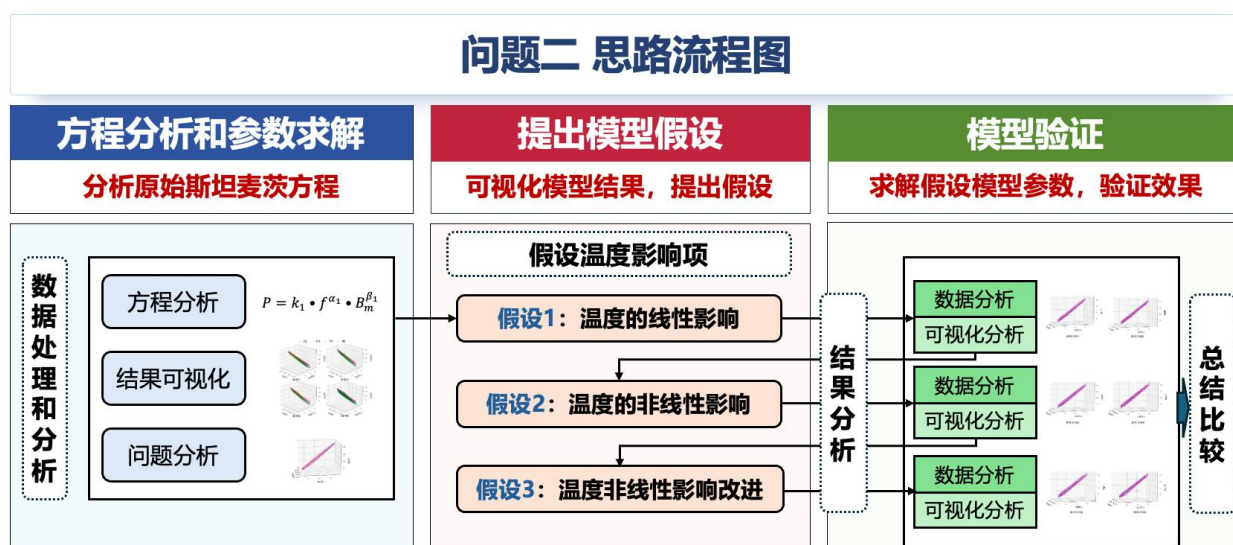


图 6-1 问题二思路流程图

6.2 数据处理与分析

附件一中包含四种材料在三种波形和不同温度条件下的磁芯损耗值。根据题目提示斯坦麦茨方程针对正弦波设计，因此我们首先对数据进行处理，去掉其它波形的数据。接着，

通过观察发现磁芯损耗值 P 的分布范围较大，最大值和最小值之间相差了多个数量级，例如在材料一中，最大的磁芯损耗 P 为 415.61，最小的磁芯损耗为 3616132.54。同时，题目给出工况条件设置的频率范围在 50000–500000Hz 内波动，因此需要考虑可能的数据归一化操作或对数变换操作。此外，部分频率值可能超过题目给定的频率范围（49990、501180、……），在数据处理过程中需要留意，避免数据污染或损失。

6.3 斯坦麦茨方程分析与求解

（1）斯坦麦茨方程分析

斯坦麦茨方程呈现了在正弦波励磁下，磁芯损耗计算公式如下：

$$P = k_1 \cdot f^{\alpha_1} \cdot B_m^{\beta_1}$$

其中： P 为磁芯损耗； f 是频率； B_m 是磁通密度的峰值； $k_1 \neq \alpha_1 \neq \beta_1$ 是根据实验数据拟合的系数，一般 $1 < \alpha_1 < 3$ ， $2 < \beta_1 < 3$ 。观察公式发现，对于预测值 P ，其值由 f 、 B_m 和参数 k_1 连乘得到，因此我们可以尝试对公式进行对数变换，从而把指数方程变成线性方程，转换为线性关系后能够通过回归算法计算参数：

$$\log P = \log (k_1 \cdot f^{\alpha_1} \cdot B_m^{\beta_1}) = \alpha_1 \log f + \beta_1 \log B_m + \log k_1$$

变换后可以很容易看出斯坦麦茨方程考虑的影响磁芯损耗 P 的因素是频率和磁芯损耗峰值，参数 α_1 和 β_1 分别自变量系数， $\log k_1$ 为截距，我们可以通过最小二乘法计算参数。针对给定的两个自变量和一个因变量，构建均方误差损失函数，通过求导得到损失函数相对于各回归系数的偏导数，将这些偏导数设为零并解出方程组，从而获得线性方程的最佳系数，使模型对数据的拟合误差最小。我们以附件 1 中的四种材料数据作为训练数据，计算得到四种材料下的参数 α_1 、 β_1 和 $\log k_1$ 值，并通过均方误差*MSE loss*和 R^2 作为拟合程度的评估指标，结果如表 6-1 所示：

表 6-1 材料 1 斯坦麦茨方程拟合结果

	$\alpha_1[1,3]$	$\beta_1[2,3]$	$\log k_1$	<i>MSE loss</i>	R^2
材料 1	1.610115	2.497115	-1.738202	1795301477.4	0.929979
材料 2	1.720977	2.508885	-2.670748	1459640271.3	0.936203
材料 3	1.615812	2.518966	-1.263155	1420036251.9	0.948437

6.4 数据可视化与分析

拟合数据后的方程在几何意义上可以表示为一个三维空间中的超平面，因此一定程度上暗示了数据分布。因此，我们根据题目要求，分别针对不同种的磁芯材料，在正弦波形下绘制磁芯损耗 P 值随频率和磁通量最大值变换的 3 维散点分布图，为了探究温度对磁通量的影响，我们将数据集给定的四种温度按照不同的颜色绘制散点，方便观察变化规律。

绘制的三维散点图如图 6-2 所示，可以看到散点大致在三维平面中分布在一个“超平面”上，因此可以初步假设斯坦麦茨方程的预测框架大致合理。进一步观察可视化散点图可以看出，材料 1 中不同温度下的散点有明显不同的分布趋势，然而由于视角限制我们难以观察到更加具体的特征。




图 6-2 三维视角下的数据分布

对此，我们尝试变换观察三维空间的角度，从垂直于超平面的方向观察不同温度散点的分布，结果如图 6-3 所示。可以观察到随着数据的温度的变化，“超平面”出现了明显的“颜色分层”现象，这个现象表明，原先建模时基于固定超平面的假设不再成立。这表

明温度并非仅作为一个附加变量，而是与其他特征变量产生了复杂的交互作用。因此，可以推断原先的斯坦麦茨模型假设过于简化，未能考虑温度的影响，导致模型在全局上难以准确拟合所有数据。在不同温度条件下，数据分布发生了明显的偏移，因此统一使用一个固定超平面来解释所有数据将无法反映这些复杂的变化趋势。如图 6-3 所示，其中蓝色点表示预测值，红色点表示真实值，单一“超平面”难以拟合所有数据。而对数变换的线性方程在指数变换后，P 值的误差将会以指数级别放大。




图 6-3 变换视角的三维散点分布




图 6-4 斯坦麦茨方程预测值和真实值的比较

基于此观察，我们需要重新构建模型结构，考虑温度作为一个调节因素，将温度引入斯坦麦茨方程，并作为交互项。这样可以更好地捕捉温度对其他变量和整体数据结构的影响，从而解决模型未能考虑数据分层的问题。

6.4 修正斯坦麦茨方程设计思路和验证

(1) 多层超平面模型假设

考虑温度是影响数据分布的线性因素，因此我们作出假设：数据在不同的温度区间下呈现多个超平面，并且超平面之间相互平行。因此，我们考虑温度作为线性项，加入对数变换后的斯坦麦茨方程。我们将温度值将温度分别作为线性项和对数变换项构造两个预测方程如下：

修正方程 1: $\log P = \log k_1 + \alpha_1 \log f + \beta_1 \log B_m + \gamma_1 \log T$

修正方程 2: $\log P = \log k_1 + \alpha_1 \log f + \beta_1 \log B_m + \gamma_1 T$

相同的，我们采用最小二乘法，采用在四种材料数据下对上述两个预测方程进行拟合，我们以材料 1 为例，计算得到参数如表 6-2 所示，针对四种材料的拟合效果如表 6-3 所示：

表 6-2 多层超平面模型假设下材料 1 拟合参数

参数/结果	修正方程 1	修正方程 2
$\log(k_1)$	0.286886	-1.426102
α_1	1.646219	1.647745
β_1	2.514083	2.516413
γ_1	-0.604244	-0.011840

表 6-3 修正方程 1 和 2 四种材料下的拟合效果

材料	修正方程 1		修正方程 2	
	<i>MSE Loss</i>	R^2	<i>MSE Loss</i>	R^2
材料 1	655752896.0	0.979593	599557883.6	0.981191
材料 2	757929049.8	0.972573	719831174.4	0.972856
材料 3	1129777222.1	0.967135	1058483106.8	0.967177
材料 4	74481068.3	0.983102	81063098.5	0.981358

可以看到将温度作为线性项/对数变换项加入原斯坦麦茨方程后，预测拟合程度获得明显提升。在材料 1、2 和 3 上，**修正方程 2** 相比**修正方程 1**，模型的 *MSE Loss* 有所下降，例如材料 1 中从 655752896.0 下降到 599557883.6，表明**修正方程 2** 在拟合数据时的误差有所减少。同时，在材料 1 下**修正方程 2** 的 R^2 值从 0.979593 提升到了 0.981191，意味着**修正方程 2** 更好地解释了数据的方差，拟合效果更加准确。但是针对材料 4，**修正方程 1** 的拟合效果好于**修正方程 2**，我们猜测这是材料特性的影响，表明针对不同材料，温度的影响力不同。参数 α_1 和 β_1 在两个模型中变化较小，说明频率 f 和磁感应强度 B_m 对预测变量 P 的影响是稳定的，两个模型都能较好地捕捉这些特征的关系。

重复 5.3 中步骤，我们将模型在材料 1 下的的预测值和真实值通过不同颜色的散点，在三维空间中进行可视化绘制，以验证多层超平面模型假设，绘制结果如图 6-5 所示：




图 6-5 多层超平面方程预测结果

两个方程的预测结果在三维空间中都展示了与实际数据较为接近的分布。散点基本沿着一个斜率较为固定的超平面排列，表明修正方程 1 和修正方程 2 都能够捕捉到 f 、 B_m 和 P 之间的关系。从视觉上看，修正方程 2 的拟合效果更好，散点更为集中，说明其误差更小。通过引入线性温度项，模型更好地捕捉了温度对目标变量的影响，减弱了温度分层对数据拟合的影响，提升了模型的表现。

但是进一步的观察，我们发现修正方程 1 和修正方程 2 的多个超平面在上半部分拟合效果较好，但是在下半部分真实数据出现明显的偏差，呈现非线性的分布。留有进一步改进的空间。

(2) 多层非线性曲面假设

基于上述假设的结果，我们假设温度与其他特征变量之间存在非线性交互作用，需要进一步改进模型，通过引入温度与其他自变量的交互项（如多元线性回归中的交互项）来调整模型，使其能够捕捉温度在不同层次上的作用。因此我们进一步的分别将温度作为线性项和对数项，更新原始斯坦麦茨方程：

$$\text{修正方程 3: } \log P = \log k_1 + \alpha_1 \log f + \beta_1 \log B_m + \gamma_1 \log T + \kappa_1 \log f * \log T + \eta_1 \log B_m * \log T$$

$$\text{修正方程 4: } \log P = \log k_1 + \alpha_1 \log f + \beta_1 \log B_m + \gamma_1 * T + \kappa_1 \log f * T + \eta_1 \log B_m * T$$

采用最小二乘法拟合后的方程参数和预测结果如表 6-4 和表 6-5 所示：

通过对两种多层非线性曲面模型的拟合结果进行分析，可以看出引入温度与其他特征变量之间的非线性交互项显著改善了模型的表现。相比修正方程 1 和 2，修正方程 3 和 4 在部分材料 1、3、4 上取得了更高的 R^2 值，这表明引入温度与自变量的非线性交互项能够发挥作用，使得拟合结果在整体上更加精准。并且修正方程 4 对材料 1 和材料 2 的拟合效

果更好，修正方程 3 对材料 3 和材料 4 的拟合效果更加突出。我们继续采用可视化方法对修正方程 3 和修正方程 4 在材料 1 上的预测结果进行 3 维散点图绘制，如下图所示：

表 6-4 多层超平面模型假设下拟合结果

参数/结果	修正方程 3	修正方程 4
$\log(k_1)$	22.327445	5.460823
α_1	-0.321090	-0.321090
β_1	2.173243	2.410708
γ_1	-6.133563	-0.127164
κ_1	0.493632	0.010302
η_1	0.086479	0.001858

表 6-5 修正方程 3 和 4 四种材料下的拟合效果

材料	修正方程 3		修正方程 4	
	$MSE\ Loss$	R^2	$MSE\ Loss$	R^2
材料 1	476265740.6	0.984922	447692389.5	0.985661
材料 2	814711300.4	0.969192	747282590.1	0.9705848
材料 3	811679411.5	0.974265	828720886.8	0.9727038
材料 4	72028043.0	0.982512	88929855.8	0.978324




图 6-6 多层非线性曲面预测结果

可视化结果可以清晰的看到，在图 6-5 中修正方程 1 和 2 无法拟合的下部数据，修正方程 3 和 4 能够有效拟合，取得可非常好的效果。

(3) 多层非线性曲面预测改进尝试

在修正方程 3 和 4 的基础上,我们进一步探究温度对其他自变量同时产生影响的假设。具体而言，我们在修正方程 3 和 4 的基础上，再添加温度同时与频率 f 和磁通量最大值 B_m 的交互项。同样的，我们将温度 T 分别作为线性项和对数变换项加入，如下所示：

修正方程 5: $\log P = \log k_1 + \alpha_1 \log f + \beta_1 \log B_m + \gamma_1 \log T + \kappa_1 \log f * \log T + \eta_1 \log B_m * \log T + \delta_1 \log f * \log B_m * \log T$

修正方程 6: $\log P = \log k_1 + \alpha_1 \log f + \beta_1 \log B_m + \gamma_1 * T + \kappa_1 \log f * T + \eta_1 \log B_m * T + \delta_1 \log f * \log B_m * T$

其参数求解结果和预测误差图表 6-6 和表 6-7 所示，可视化结果如图 6-7 所示：

表 6-6 多层超平面模型改进假设下拟合结果

参数/结果	预测方程 5	预测方程 6
$\log(k_1)$	22.900900	5.704712
α_1	-0.387753	1.0080812
β_1	2.094843	2.390627
γ_1	-4.556247	0.002806
κ_1	0.362884	-0.000751
η_1	0.703069	0.048923
δ_1	-0.050885	-0.003978

表 6-7 修正方程 5 和 6 四种材料下的拟合效果

材料	修正方程 5		修正方程 6	
	$MSE Loss$	R^2	$MSE Loss$	R^2
材料 1	660555681.5	0.978576	480261540.4	0.983999
材料 2	985842432.8	0.963690	785825388.1	0.970201
材料 3	926188235.1	0.972187	830655008.0	0.974231
材料 4	72394853.3	0.982238	79276816.4	0.980701




图 6-7 多层非线性曲面预测改进尝试

分析预测结果发现，修正方程 5 和 6 的精确度没有明显提升，部分 R^2 值甚至小于修正方程 1 和 2 的结果。因此可以推翻先前假设，说明温度变量不存在同时和频率 f 与磁通量最大值 B_m 产生非线性交互影响，因此引入该交互变量反而对预测结果拟合度产生负影响。

6.5 总结与分析

我们对 5.4 中进行的各种假设和验证产生的预测方程进行总结，在表 6-8 中展示了修正方程 1-6 经过逆对数变换后的公式结果以及其在材料 1 正弦波上磁芯损耗的预测准确率（通过 $MSE Loss$ 和以 R^2 表示）：

表 6-8 修正方程总结

	修正方程	$MSE Loss$	R^2
	原始斯坦麦茨方程： $P = k_1 f^{\alpha_1} B_m^{\beta_1}$	1795301477.4	0.929979
1	$P = k_1 f^{\alpha_1} B_m^{\beta_1} T^{\gamma_1}$	655752896.0	0.979593
2	$P = k_1 f^{\alpha_1} B_m^{\beta_1} \exp(\gamma_1 T)$	599557883.6	0.981191
3	$P = k_1 f^{\alpha_1} B_m^{\beta_1} T^{\gamma_1 + \kappa_1 \log f + \eta_1 \log B_m}$	476265740.6	0.984922
4	$P = k_1 f^{\alpha_1} B_m^{\beta_1} \exp(\gamma_1 T) f^{\kappa_1 T} B_m^{\eta_1 T}$	447692389.5	0.985661
5	$P = k_1 f^{\alpha_1} B_m^{\beta_1} T^{\gamma_1 + \kappa_1 \log f + \eta_1 \log B_m + \delta_1 \log f \log B_m}$	660555681.5	0.978576
6	$P = k_1 f^{\alpha_1} B_m^{\beta_1} \exp(\gamma_1 T) f^{\kappa_1 T} B_m^{\eta_1 T} \exp(\delta_1 \log f * \log B_m * T)$	480261540.4	0.983999

根据 R^2 结果，我们选择**修正方程 4** 作为最终的修正方程，与初始斯坦麦茨方程相比，**修正方程 4** 的 R^2 值为 0.985661，远超初始方程的 R^2 值 0.929979。证明引入温度作为交互项能够提升模型的预测效果。

七、问题三 磁芯损耗因素分析

7.1 问题分析

磁芯损耗是磁性元件设计与优化中的关键指标，直接影响设备的效率和稳定性。温度、励磁波形及磁芯材料是影响磁芯损耗的三大主要因素。本题旨在分析这三者对磁芯损耗的独立及协同影响，特别是探讨两两因素之间的交互作用，并找到在什么条件下磁芯损耗可能最小。通过对实验数据进行统计分析和建模，可以得到以下主要问题：

1. 温度、励磁波形和磁芯材料各自对磁芯损耗的影响程度如何？
2. 两两因素之间是否存在协同作用？如果有，这些交互作用如何影响磁芯损耗？
3. 在什么组合条件下，磁芯损耗可能达到最小？

本研究拟采用以下方法对数据进行分析：

1. 单因素方差分析：用于评估每个因素（温度、励磁波形、磁芯材料）对磁芯损耗的独立影响。通过比较不同水平的均值，判断该因素的影响显著性。
2. 双因素方差分析：用于评估两两因素之间的交互作用（例如温度与励磁波形、温度与磁芯材料、励磁波形与磁芯材料）。通过交互项的显著性分析来判断协同效应是否显著。

综上所述，我们对本题的技术路线如图 7-1 所示：



图 7-1 问题三思路流程图

7.2 数据准备

实验数据（见附件一）涵盖了四个温度水平：25° C、50° C、70° C 和 90° C，以及三种励磁波形：正弦波、三角波和梯形波。此外，数据还包含四种不同的磁芯材料（标记为材料 1、材料 2、材料 3 和材料 4）。温度的变化可能会显著影响磁性材料的电阻和磁性能，从而改变其损耗特性。同时，不同的励磁波形和材料类型对磁芯损耗的影响也各不相同，这为后续分析提供了丰富的变量组合。理论上，温度、波形和材料的组合共计 48 种。

在数据预处理阶段，我们对每种组合的数据进行频率排序，并在此基础上随机抽取 50 条数据进行多次抽样测试。这种有针对性的抽样方法旨在抵消频率差异对分析结果的潜在影响，确保数据的代表性和足够的统计效力。为了满足方差分析的假设条件，我们对磁芯损耗数据进行了对数变换，以使其分布更接近正态分布。

根据图 7-2 的正态性检验直方图和 P-P 图，可以观察到对数变换后磁芯损耗数据的正态性检验结果。直方图显示，数据分布呈现出典型的钟形特征（中间高，两端低），这表明数据虽然不完全符合正态分布，但可以基本接受为正态分布。此外，P-P 图展示了对数变换后磁芯损耗观测值的累计概率与正态分布的累计概率的拟合情况，拟合程度较高，说明数据逐渐趋近于正态分布。我们还对 48 种组合的实验数据进行了逐一的正态性检验，结果进一步验证了处理后的数据满足使用方差分析法的前提条件。这些分析为后续的统计推断奠定了坚实基础。




图 7-2 正态性检验直方图和 P-P 图




图 7-3 48 种组合的实验数据正态性检验图

7.3 单因素方差分析

7.3.1 温度

单因素方差分析用于比较不同温度下磁芯损耗的均值，具体结果如表 7-1 所示：

表 7-1 温度-方差分析结果表

变量值	平均值	标准差	<i>F</i>	<i>P</i>
25.0	10.986	1.874	9.315	0.001
50.0	10.792	1.902		
70.0	10.516	1.897		
90.0	10.493	1.902		
总计	10.697	1.904		

方差分析的结果显示，*F* 检验值为 9.315，*P* 值为 0.001，显著性水平小于 0.05。这意味着我们可以拒绝原假设，表明不同温度下的磁芯损耗均值之间存在显著性差异。进一步的效应量化分析表明，偏 Eta 方 (η^2) 为 0.012，Cohen's *f* 值为 0.108。这表明，尽管温度对磁芯损耗的影响显著，但其效应量较小，暗示温度变化对磁芯损耗的总体影响程度为小效应。

总结来看，虽然温度对磁芯损耗有统计上的显著影响，但其实际效应量较小，这意味着温度的变化对磁芯损耗的影响相对较微弱，可能需要结合其他因素进行综合考虑。

7.3.2 励磁波形

励磁波形的单因素方差分析结果见表 7-2：

表 7-2 励磁波形-单因素方差分析结果表

变量值	平均值	标准差	<i>F</i>	<i>P</i>
三角波	11.158	1.71	97.114	0.001
梯形波	10.964	1.908		
正弦波	9.968	1.872		
总计	10.697	1.904		

方差分析结果显示，由于数据未满足方差齐性假设（Levene 检验 $P=0.001$ ），因此采用 Welch's 方差检验。结果 *P* 值为 0.001，远小于 0.05，表明不同励磁波形在磁芯损耗上

存在显著差异。效应量化分析结果显示，偏 Eta 方 (η^2) 为 0.075，意味着 7.5%的总差异可归因于励磁波形之间的差异，而 Cohen’ s f 值为 0.285，表明励磁波形对磁芯损耗的影响程度为中等效应。

具体来看，正弦波的磁芯损耗最低（9.968），而三角波的损耗最高（11.158），这表明励磁波形的选择对磁芯损耗具有显著影响。选择合适的波形，例如正弦波，可以显著降低磁芯损耗，从而提高系统的整体效率。

7.3.3 磁芯材料

表 7-3 磁芯材料-单因素方差分析结果表

变量值	平均值	标准差	F	P
材料 1	10.646	1.895	20.03	0.001
材料 2	10.874	1.948		
材料 3	11.029	1.897		
材料 4	10.238	1.782		
总计	10.697	1.904		

方差分析结果显示，P 值为 0.001（ $P \leq 0.05$ ），表明不同材料对磁芯损耗的影响存在显著性差异。此外，Levene 检验的 P 值为 0.054，符合方差齐性假设。

效应量化分析结果表明，偏 Eta 方 (η^2) 为 0.024，说明材料对磁芯损耗的差异性影响占总差异的 2.4%。Cohen’ s f 值为 0.158，表明材料对磁芯损耗的影响为小效应。

综上所述，不同磁芯材料对损耗的影响显著，其中材料 3 的损耗最高，而材料 4 的损耗最低。这提示在磁芯材料的选择上，不同材料的特性可能会显著影响损耗表现，选择合适的材料能够在一定程度上优化磁芯的性能表现。

7.4 双因素方差分析

7.4.1 励磁波形+温度

为了进一步研究励磁波形和温度对磁芯损耗的综合影响，本文进行了双因素方差分析。结果表明：

- 励磁波形：励磁波形的主效应显著，F 值为 98.516，P 值为 0.001（ $P \leq 0.05$ ），表明不同励磁波形对磁芯损耗的影响显著。这与单因素方差分析的结果一致。
- 温度：温度的主效应同样显著，F 值为 10.102，P 值为 0.001（ $P \leq 0.05$ ），说明温度对磁芯损耗的影响在统计上显著。
- 励磁波形与温度的交互作用：交互项的 F 值为 2.218，P 值为 0.039，这表明波形和温度之间的交互作用对磁芯损耗存在显著性影响。尽管交互作用效应较弱，但依然可以推测某些波形和温度组合对磁芯损耗的影响可能更为明显。

表 7-4 励磁波形+温度-双因素方差分析结果

项	平方和	自由度	均方	<i>F</i>	<i>P</i>	<i>R</i> ²	调整 <i>R</i> ²
励磁波形	651.667	2	325.834	98.516	0.001		
温度	100.234	3	33.411	10.102	0.001	0.092	0.087
励磁波形 * 温度	44.023	6	7.337	2.218	0.039		




图 7-4 励磁波形+温度-均值对比图

7.4.2 温度+磁芯材料

在本文的双因素方差分析中，温度和材料作为自变量对磁芯损耗的影响进行了评估。以下是主要的结果和分析：

• 温度：温度的主效应显著，F 值为 9.515，P 值为 0.001 ($P \leq 0.05$)，表明不同温度条件下，磁芯损耗存在显著差异。这与之前的单因素分析结果一致，进一步验证了温度在影响磁芯损耗上的重要性。

• 材料：材料的主效应同样显著，F 值为 20.191，P 值为 0.001 ($P \leq 0.05$)，显示不同材料对磁芯损耗的影响显著。材料在损耗方面的差异反映了不同磁性材料的特性对损耗的影响。

• 温度与材料的交互作用：交互项的 F 值为 0.304，P 值为 0.974，远大于 0.05，表明温度与材料之间不存在显著的交互作用。也就是说，温度和材料对磁芯损耗的影响是独立的，两者的组合并没有产生额外的影响。

• 本次双因素方差分析的 R^2 为 0.037，调整 R^2 为 0.031，尽管解释力较低，但显示出温度和材料均对磁芯损耗有显著的独立影响，而两者之间不存在显著的交互作用。这表明在不同的温度条件下，选择合适的材料可以有效减少磁芯损耗，但两者的影响是分离的。

表 7-5 温度+磁芯材料-双因素方差分析结果

项	平方和	自由度	均方	<i>F</i>	<i>P</i>	R^2	调整 R^2
温度	100.234	3	33.411	9.515	0.001		
磁芯材料	212.709	3	70.903	20.191	0.001	0.037	0.031
温度 * 磁芯材料	9.621	9	1.069	0.304	0.974		



图 7-5 温度+磁芯材料-均值对比图

7.4.3 磁芯材料+励磁波形

双因素方差分析的主效应结果显示，材料和励磁波形对磁芯损耗的影响均具有统计学上的显著性：

- 材料的 F 检验结果为 21.721，P 值为 0.001 ($P \leq 0.05$)，表明不同材料之间对磁芯损耗的影响存在显著差异。

- 励磁波形的 F 检验结果为 99.819，P 值为 0.001 ($P \leq 0.05$)，同样显示不同波形在磁芯损耗上具有显著影响。

这表明，材料和励磁波形均显著影响磁芯损耗，且应分别考虑其在磁芯设计中的作用。然而，对于材料和励磁波形的交互效应，F 检验结果为 1.768，P 值为 0.102，未达到显著性水平 ($P > 0.05$)。这意味着，材料与励磁波形之间的交互作用对磁芯损耗没有显著影响。换句话说，不同材料与励磁波形组合下的磁芯损耗没有产生显著的协同效应。

通过本次双因素方差分析可以看出，虽然材料和励磁波形各自对磁芯损耗具有显著影响，但二者之间的交互效应并不显著。这表明，在磁芯设计中，可以分别优化材料和励磁波形来减少损耗，而无需特别关注它们的组合对损耗的协同作用。

表 7-6 磁芯材料+励磁波形-双因素方差分析结果

项	平方和	自由度	均方	F	P	R ²	调整 R ²
磁芯材料	212.709	3	70.903	21.721	0.001		
励磁波形	651.667	2	325.834	99.819	0.001	0.103	0.099
磁芯材料 * 励磁波形	34.623	6	5.77	1.768	0.102		




图 7-6 磁芯材料+励磁波形-均值对比图

7.5 结论

通过对温度、励磁波形和磁芯材料的单因素及双因素方差分析，本文得出了以下关键结论：

1. 温度的影响：研究结果显示，温度对磁芯损耗具有显著影响（ $P < 0.05$ ），但其实际效应较小。尽管在温度升高时，损耗略有下降，但这一变化并不显著，说明温度对磁芯损耗的调控能力有限。
2. 励磁波形的影响：励磁波形对磁芯损耗的影响显著（ $P < 0.05$ ），其中正弦波的损耗最低，而三角波的损耗最高。这表明选择合适的波形（如正弦波）可以有效地降低损耗，从而在磁性元件设计中具有重要的实用价值。
3. 磁芯材料的影响：不同材料对磁芯损耗的影响同样显著（ $P < 0.05$ ）。实验结果显示，材料 4 的损耗最低，而材料 3 的损耗最高。这提示合理选择磁芯材料是减少损耗的重要策略，对于提升磁性元件的整体性能至关重要。
4. 交互效应分析：温度与励磁波形之间存在显著的交互效应（ $P = 0.039$ ），这表明优化这两者的组合可以进一步降低磁芯损耗。这意味着在设计过程中，考虑温度与波形的联合影响将有助于实现更优的性能表现。

5. 独立考虑的因素：然而，温度与材料之间以及材料与波形之间的交互效应并不显著，表明这些因素可以独立考虑。这为优化设计提供了灵活性，设计者可以单独优化每个参数，而不必担心它们之间的复杂交互。

优化磁芯损耗的建议如下：为优化磁芯损耗，建议在设计中选择较高的温度（如 90° C）、采用正弦波励磁波形，并优先使用材料 4。在这些条件下，磁芯损耗可以显著降低，从而提高磁性元件的性能。最后，图 7-1 通过热力图展示了 48 种变量组合的实验结果，我们发现实现磁芯损耗的最佳条件出现在材料 4 的正弦波下，但是经过多次抽样后，发现最佳温度条件具有不确定性，即当温度条件 90° C 和 70° C 时往复出现最低的磁芯损耗。对此，我们进行进一步的分析。




图 7-7 磁芯损耗均值热力图

借助可视化技术，我们将正弦波、材料 4 下的所有数据进行散点图绘制，如图 7-8 所示。其中蓝色点表示 70° C 条件下的磁芯损耗数据，黑色点表示 90° C 条件下的磁芯损耗数据，可以看到在低频区间上，温度为 90° C 时的磁芯损耗低于 70° C 条件下的磁芯损耗，当频率升高后，温度为 90° C 时的磁芯损耗则高于温度为 70° C 条件下的磁芯损耗。这一结果反映在上述热力图预测结果上则得到了很好的解释：由于我们采用抽样方式对数据进行分析，当采样高频区间的数据更多时，热力图反映了温度为 70° C 条件下取得更低的磁芯损耗。而当采样得到低频区间的数据更多时，热力图反映了温度为 90° C 条件下的磁芯损耗更低。




图 7-8 不同温度下磁芯损耗分析

综上所述，由于处于相对较高频段时温度为 70°C 具有更低磁芯损耗，但是在大部分频率区间上， 90°C 、正弦波和材料 4 的组合是实现最低磁芯损耗的最佳条件。综合考虑该组合因素，将有助于推动相关领域的技术进步和应用优化。

八、问题四模型建立与求解分析

8.1 问题四的分析与思路

在磁芯损耗研究中，虽然已有众多传统模型存在，但它们往往在精度和适用范围上面临挑战，限制了对磁性元件设计中损耗的精确评估。因此，本题的核心要求旨在构建一个基于数据驱动的通用预测方法，构建能够在不同材料类型和工况条件下进行有效预测的磁芯损耗模型。这一模型的建立将有助于提高磁性元件设计的精确性与效率，进一步推动电力电子技术的发展。

对此，结合问题一、二、三的分析结果和见解我们按照如下思路设计构建通用模型，其流程图如图 8-1 所示：

1. 我们基于问题一实现过程中的观察结论从附件一中的实验数据中提取相关特征，选择对磁芯损耗影响较大的自变量，包括温度、波形、材料、频率和磁通密度峰值等，并进行一定的变换预处理。
2. 我们将数据划分为训练集和测试集，我们首先基于问题二研究的结合温度因素的修正模型进行进一步改进，并验证效果。
3. 我们对 2 中的拟合结果进行分析，运用多种机器学习模型（线性回归、随机森林、梯度提升树等）并尝试调整特征的选取策略，构建磁芯损耗预测模型进行训练，评估不同模型在不同特征选取策略下的预测精度和泛化能力。
4. 最后，我们对附件三中的样本进行磁芯损耗预测，将结果填入附件四表格中，并在根据要求提取部分数据展示在本节末尾。

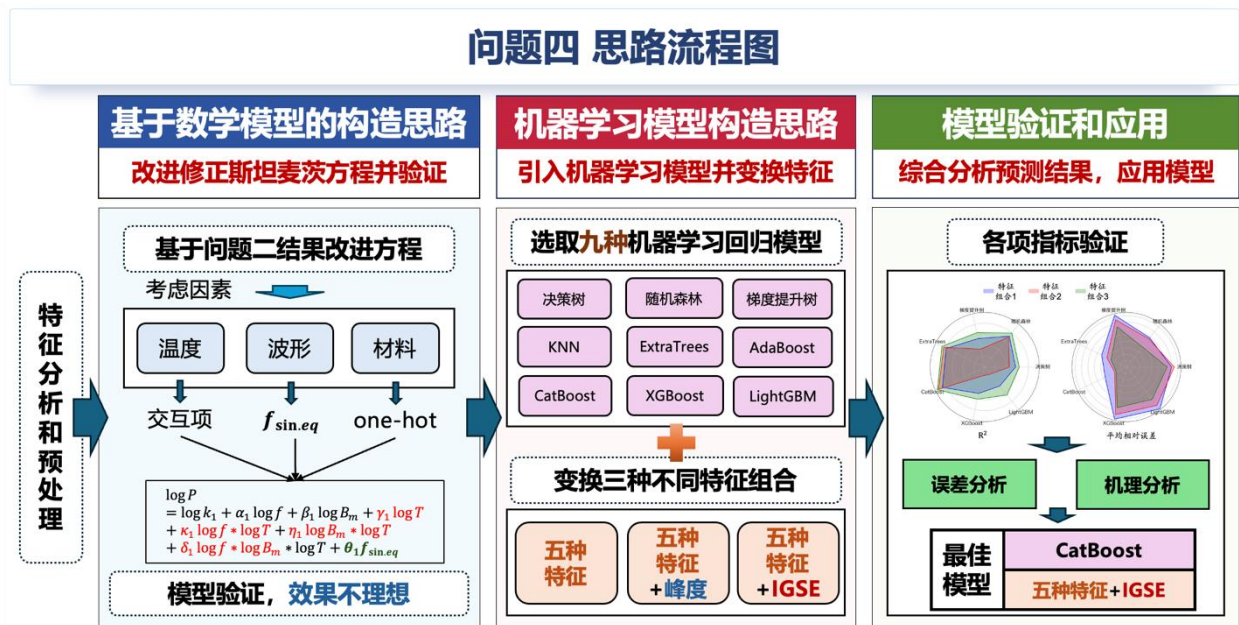


图 8-1 问题四思路流程图

8.2 特征提取

在建立磁芯损耗的预测模型时，特征提取是关键步骤。本研究将温度、频率、励磁波形、磁通密度峰值和磁芯材料作为主要变量进行分析。其中励磁波形和磁芯材料为离散变量，我们采用 one-hot 编码对其进行处理。one-hot 编码方法能够将每个离散特征转换为二进制向量，进而保留其信息。




图 8-2 频率和磁通量最大值的可视化结果




图 8-3 对数变换后的频率和磁通量最大值可视化结果

对于连续变量，频率和磁通密度峰值，我们首先进行数据可视化，以了解这两个特征的分布情况。频率的最小值和最大值分别为 49990 和 501180，而磁通密度峰值的最小值和最大值分别为 0.00963815 和 0.313284469。可以明显看出，频率与磁通密度峰值之间存在数量级的显著差异，为确保模型训练的有效性，必须统一这两个特征的量纲。为此，我们尝试了两种标准化方法：对数变换和最大最小归一化。如图 8-3 可视化结果显示，对数变换使得数据量纲提升到同一数量级，并且更接近正态分布，因此我们选择对数变换来处理频率和磁通密度峰值。此外，我们同样对温度以及预测的磁芯损耗进行对数变换，以保持特征一致性。

在特征提取完成后，针对附件一中的每一行数据（即每一个工况），我们将获得一个特征向量。这些特征向量将作为输入，用于后续回归模型的训练、验证与预测，确保模型在不同工况下都能有效运作。

8.3 回归模型的建立和求解

8.3.1 改进斯坦麦茨方程

问题二中给定了修正斯坦麦茨方程的要求，经过提出假设到验证的过程，我们首先尝试对已有的斯坦麦茨方程进行进一步的改进，增加其通用性。我们选取问题 2 中在四种材料上均取得优异表现的**修正方程 5**，进行进一步改造。

针对题目提出的通用性前提，我们在已知所有因素上还需要进一步考虑材料和波形的影响。首先针对材料参数，由于其为一个高度离散的变量，并且题目并没有给出使用材料的任何相关信息，因此我们采用先前的 one-hot 编码进行处理。具体而言，我们将针对每一种材料计算出模型参数，并在回归时根据材料类型进行相应计算。其次，针对波形类型，

原始的斯坦麦茨方程针对正弦波进行设计，因此无需考虑波形特征。幸运的是，已有工作^[3]已经针对其他波形提出了任意波形励磁下的等效正弦波频率计算方法：

$$f_{\sin.eq} = \frac{2}{\Delta B^2 \cdot \pi^2} \int_0^T \left(\frac{dB}{dt}\right)^2 dt$$

因此我们将 $f_{\sin.eq}$ 作为修正参数，以线性项的方式加入修正方程 5，最终对数变换后修正方程 5 的推导方程如下所示：

$$\log P = \log k_1 + \alpha_1 \log f + \beta_1 \log B_m + \gamma_1 \log T + \kappa_1 \log f * \log T + \eta_1 \log B_m * \log T + \delta_1 \log f * \log B_m * \log T + \theta_1 f_{\sin.eq}$$

我们同样通过最小二乘法，根据材料 1 中数据计算参数，其结果如表 8-1 所示：

表 8-1 参数效果和拟合结果

参数/结果	材料 1	材料 2	材料 3	材料 4
$\log(k_1)$	44.122312	49.734704	45.708186	45.027698
α_1	0.26034	-0.069333	0.125279	0.144609
β_1	2.309555	2.204157	2.089649	2.349777
γ_1	-2.790572	-3.684475	-2.804102	-3.111231
κ_1	0.202491	0.28268	0.219401	0.234231
η_1	0.859066	0.83018	0.845469	0.700954
δ_1	-0.070027	-0.063888	-0.062423	-0.056723
θ_1	1.02952	1.082692	1.03305	1.000063
对数变换下 R^2	0.991743	0.991883	0.991775	0.986086
R^2	0.929084	0.959417	0.961276	0.942052

分析结果我们发现，尽管在对数变换下，我们的模型精确度（ R^2 表示）取得了较高的数值，但是在逆对数变换后的预测过程中，其结果 R^2 则出现大幅下降，我们考虑可能的潜在原因是逆对数变换后，部分没有很好拟合的样本数据误差经过指数级放大后导致误差极大下降。对此，我们考虑进一步的采用机器学习回归方法，通过引入具有更强非线性建模能力、高维数据拟合能力以及自动特征选取能力，弥补传统数学模型的缺点。由此构建出一个满足题目要求的预测能力更强的通用模型。

8.3.2 机器学习方法模型介绍

在本研究中，我们选择了多种回归预测模型以构建磁芯损耗预测模型，旨在分析和比较这些模型的预测精度和泛化能力。我们首先对采用的机器学习模型进行详细的介绍：

(1) 决策树模型^[6]：决策树模型在回归问题中通过将特征空间划分成多个区域，并为每个区域分配一个预测值进行建模。决策树的核心思想是不断地根据特征的某个阈值将数据划分为更小的区域，并在这些区域中使用均值或中位数等统计值作为最终的预测结果。其优势在于它能够自动处理非线性关系、特征交互和不同的特征类型，且不需要对数据进行标准化。决策树的训练过程包括以下步骤：1. 从根节点开始，选择一个特征并确定一个分裂点，将数据集划分为两部分。这个分裂点的选择基于设置的损失函数选择能够最大程度降低分裂后节点中数据误差的分裂点；2. 对每个子节点重复这一过程，继续选择特征和分裂点，不断划分数据，直到达到停止条件（如树的最大深度或叶子节点中的最小样本数）；3. 每个叶子节点最终对应一个区域的预测值，通常是该区域内目标变量的均值。最后，在预测时，新数据通过树的结构从根节点逐级下行，直到到达某个叶子节点，叶子节点中的值即为最终的回归预测结果。

(2) 随机森林模型^[7]：通过集成多棵回归决策树，随机森林有效提升预测精度和泛化能力。与单棵决策树相比，随机森林通过随机化构建多个不同的决策树模型，每棵树都是在不同的数据子集和特征子集上训练的。最终的预测结果是通过对所有决策树的预测进行平均来获取。这种“集成”的方式能够有效减少单棵树容易出现的过拟合现象，同时提升模型的稳定性和对数据的泛化能力，在处理高维数据或复杂非线性问题时表现良好。随机森林训练过程包括：1. 有放回地从原始训练数据集中随机抽取若干样本，构建多个训练集，每个训练集用于训练一棵决策树；2. 按照决策树（1）中决策树构建方法训练每棵决策树。

(3) 梯度提升决策树^[8]（GBDT, Gradient Boosting Decision Tree）：GBDT 是一种常用的集成学习方法，它通过迭代地构建一系列决策树来提升模型的性能。GBDT 的核心思想是：每个新树的构建目标是弥补前一轮所有决策树在预测中的误差，即通过优化损失函数的负梯度方向来逐步改进模型的拟合能力。其训练过程包括：1. 初始化模型，通常使用所有样本的均值或中位数作为初始预测值；2. 计算每个样本的残差，即真实值与当前预测值的差异，这些残差用作新一轮决策树的目标值；3. 训练一棵新的决策树来拟合这些残差，以修正模型的误差，然后将这棵新树加入到模型中；4. 不断迭代上述过程，直到达到预设的树的数量或者模型的误差收敛。最终的 GBDT 模型是所有树的加权和，每棵

树都为模型的预测贡献一部分，这种方法能够逐步减少误差，适应复杂的非线性数据，并且具有良好的泛化能力。

(4) K 近邻算法^[9] (KNN)：KNN 的核心思想是基于输入样本的邻近性来进行预测。KNN 是一个非参模型，不依赖于任何假设或训练阶段，而是直接使用整个训练数据集进行预测。在回归任务中，KNN 通过找到距离输入样本最近的 K 个邻居（如欧式距离），然后根据这些邻居的目标值的平均值来进行预测。KNN 的优势在于不需要训练过程，因此在处理小规模数据集或局部特征模式时表现良好。虽然 KNN 简单易用，但它在高维数据中可能表现不佳，且需要对距离度量和 K 的选择进行适当调节。此外，因为每次预测都需要计算到所有训练样本的距离，KNN 的计算复杂度较高。

(5) Extra Trees^[10] (Extremely Randomized Trees)：Extra Trees 是一种基于决策树的集成学习方法，与随机森林类似，但通过引入更多的随机性来增强模型的泛化能力。与随机森林不同，Extra Trees 在构建每棵树时，不仅对数据进行随机抽样，还在每个节点分裂时随机选择特征和分裂点，而不是选择最优分裂点。由于这种极端的随机性，Extra Trees 在回归问题中能够更好地避免过拟合，尤其在处理复杂和高维数据时表现良好。Extra Trees 的训练过程与随机森林相似，但有一些关键区别：1. Extra Trees 不会进行有放回的样本抽样，而是使用整个数据集；2. 对于每棵树的每个节点，在分裂时，Extra Trees 会随机选择一个特征子集，并在这些特征中随机选择一个分裂点，而不是基于某种分裂准则（如均方误差）选择最佳分裂点。

(6) Adaboost 模型^[11]：Adaboost 是一种基于加权集成的方法，它迭代地构建多个弱学习器（通常是简单的决策树），并将这些弱学习器组合成一个强大的预测模型。在每一轮训练中，Adaboost 重点关注前一轮中预测错误的样本，通过调整样本权重，使得后续学习器更关注难以预测的数据。在回归任务中，Adaboost 能够通过加权组合弱回归模型来提升整体的预测性能。相比其他回归模型，Adaboost 在应对复杂、非线性数据时表现出更强的灵活性和鲁棒性，同时不需要对数据的分布和特征进行过多假设。此外，Adaboost 能够自动聚焦于难以预测的样本，减少偏差和方差，从而提供更准确的回归预测结果。其模型的训练过程包括：1. 为所有样本初始化一个权重，每个样本的权重相等；2. 训练一个弱分类器，并计算分类错误率；3. 根据错误率调整样本权重，错误分类的样本权重增加；4. 重复步骤 2 和 3，直到达到预设的分类器数量或误差足够小；5. 最终模型是多个弱分类器的加权组合，权重与各自的分类性能相关。

(7) CatBoost 模型^[12]：CatBoost 是一种基于梯度提升决策树（GBDT）的机器学习模型，专为处理具有分类特征的数据而优化。CatBoost 在回归任务中相比其他模型具有几个独特的优势。首先，它在处理数据集中的分类特征时表现尤为出色，能够自动处理类别数据，减少了特征预处理的复杂度。其次，CatBoost 通过创新的随机森林方法降低了过拟合的风险。整体上，CatBoost 在回归任务中提供了良好的性能、易用性和高效的特征处理能力。其训练过程与 GBDT 大致相同，但是额外的核心改进是引入对称决策树构建方法和处理分类特征时通过“有序目标编码”来避免目标泄露问题。通过随机打乱数据并对不同数据块进行独立编码，保证分类特征不会影响模型的预测准确性。此外 CatBoost 还通过引入内置的 L2 正则化来防止过拟合。

(8) XGBoost 模型^[13]（Extreme Gradient Boosting）：XGBoost 是一种基于梯度提升决策树（GBDT）的增强版算法，专门针对性能和速度进行了优化，尤其在处理大规模数据时表现卓越。与普通的 GBDT 相比，XGBoost 对损失函数的二阶导数进行优化，引入更高效的正则化处理、自动化的特征选择以及对缺失值的原生支持。在回归问题中的 XGBoost 训练过程基于梯度提升框架，其训练过程包括：1. 与 GBDT 一样，通过迭代训练多棵决策树，每棵树在之前所有树的基础上进一步拟合残差；2. XGBoost 使用一阶导数来更新模型，并使用损失函数的二阶导数（Hessian 矩阵）来更准确地评估每次分裂的方向和步幅；3. XGBoost 引入 L1（Lasso）和 L2（Ridge）正则化来控制模型复杂度，减少过拟合的风险。4. XGBoost 通过分裂查找时的“近似算法”来加速训练过程，采用块结构和并行计算使得训练速度大幅提升；5. XGBoost 集成了所有树的预测结果，通过对所有树的输出进行加权平均，生成最终的回归预测。

(9) LightGBM 模型^[14]：LightGBM 同样是一种基于梯度提升决策树（GBDT）的高效实现。与 XGBoost 类似，LightGBM 采用了不同的优化策略，以提高训练速度和模型的性能。LightGBM 的核心创新点包括使用直方分裂算法（Histogram-based splitting）、基于叶子增长的策略（Leaf-wise growth）以及对稀疏数据和类别特征的高效处理。LightGBM 训练过程首先基于 GBDT 的框架进行，不同点在于：1. LightGBM 通过构建直方图来存储特征值，将数据分成离散的区间，然后在这些区间中找到最优分裂点，加速了模型的分裂过程；2. LightGBM 使用基于叶子生长的策略，在每次迭代中选择当前误差最大的叶子节点进行分裂，使得 LightGBM 可以更快地降低损失。

8.3.3 机器学习模型训练与优化

我们使用上述九种机器学习模型进行回归任务，按照设计思路，我们从由五种基本影响因子（温度、频率、波形、磁通密度峰值，及磁芯材料）开始，逐步添加新构造的特征，并分析训练结果，分析各个模型的拟合效果。我们按照 8:2 的比例将附件一中的全部数据划分为训练集和测试集，并在五个指标（MSE、RMSE、MAE、 R^2 、平均相对误差）上评价模型的拟合效果。

(1) 选取五种基本特征下进行训练

训练结果如表 8-2 所示，其中决策树、随机森林、梯度提升树、ExtraTrees、CatBoost、XGBoost 和 LightGBM 相比数学模型的拟合效果取得了巨大的提升。KNN 与数学模型方法基本一致，我们分析判断 KNN 由于没有训练过程，并且部分特征范围差异较大，因此以均值方式聚合最近的 N 个点是误差变大的关键原因。在九种模型中，CatBoost 取得了最佳效果，其 R^2 值取得了最高拟合效果，达到 0.993，并且平均相对误差减少到 0.1 以内。

表 8-2 选取五种特征下训练结果

模型名称	MSE	RMSE	MAE	泛化能力(R^2)	平均相对误差
决策树	2915652765	53996.78476	20064.23967	0.97833	0.14101
随机森林	1864963346	43185.22139	17135.9313	0.98614	0.11645
梯度提升树	3121484844	55870.25008	21903.75201	0.9768	0.1656
KNN	8651455752	93013.20203	34771.52516	0.9357	0.19916
ExtraTrees	1457416457	38176.12417	13353.40852	0.98917	0.08574
AdaBoost	19395532027	139267.8428	51187.22984	0.85584	0.39045
CatBoost	940475971.3	30667.18069	10789.6989	0.99301	0.07358
XGBoost	3392297459	58243.43275	22294.45191	0.97479	0.16662
LightGBM	3740823602	61162.2727	22647.74004	0.9722	0.16705

由于仅采用五种标准特征进行训练，通过调整输入特征组合可能进一步增加模型的拟合效果，因此我尝试结合问题一、二、三中选取的波形特征，对回归任务进行进一步的优化。

(2) 结合峰度值的优化方案

在问题一中，峰度值作为区分三种波形的关键指标，可以直接实现三种波形的分类。考虑到峰度值相比离散波形形状，能够以量化的方式反映波形内部的分布细节，对于回归任务能够提供更多的启发信息。因此我们作出假设：**峰度值一定程度上能够反映波形的形状特征对磁芯损耗的影响。**

根据假设前提，我们再将九种模型在五种特征及峰度值下进行训练，其回归任务拟合效果如下表所示：

表 8-3 选取五种特征及峰度值训练结果

模型名称	MSE	RMSE	MAE	泛化能力 (R^2)	平均相对 误差
决策树	3686826927	60719.2468	22623.5376	0.9726	0.1492
随机森林	2016349150	44903.7766	17622.7862	0.98501	0.11239
梯度提升树	4461896108	66797.4259	24019.3329	0.96684	0.15111
KNN	4.2227E+10	205492.068	75313.0196	0.68613	0.56849
ExtraTrees	1123131511	33513.1543	11604.629	0.99165	0.067549
AdaBoost	3.4507E+10	185760.851	63678.8252	0.74352	0.38876
CatBoost	404050336	20101.0034	6801.96395	0.997	0.040123
XGBoost	5615959252	74939.7041	25253.5773	0.95826	0.1518
LightGBM	5609479757	74896.4602	25279.2912	0.95831	0.15261

分析拟合结果发现加入峰度值作为特征训练下，大部分的机器学习模型的泛化能力有所增强，并且取得了更小的平均相对误差。我们关注在五种特征下取得最佳效果的 CatBoost 模型，可以看到其 R^2 值由 0.994 提升至 0.997，并且平均相对误差由 0.07 降低到了 0.04。因此先前作出的关于峰度值的假设得到了有力证明。

(3) 结合先验知识模型的优化方案

考虑到峰度值的引入能够对模型拟合效果产生较大的正向积极影响，我们思考如何进一步的结合波形特征以及其他潜在因素，提升模型性能。通过观察峰度值可以发现，峰度值作为波的一种统计特征，较为抽象的概括了波形分布数据。因此我们思考能否进一步以更加细粒度的方式表征波形分布。

通过阅读文献，我们观察到已有模型充分挖掘磁芯材料的物理性质，提出磁芯损耗和磁通密度变化率 $\frac{dB(t)}{dt}$ 呈现一定程度的正相关性，因此我们分析已有方法结合磁通密度变化率的方式。已有模型提出了 IGSE 模型^[4]，将磁通密度变化率以积分的形式作为磁芯损耗的关系项，其公式如下所示。

$$P = \frac{k_i(\Delta B)^{\beta-\alpha}}{T} \int_0^T \left| \frac{dB}{dt} \right|^\alpha dt$$

$$k_i = \frac{k}{(2\pi)^{\alpha-1} \int_0^{2\pi} |\cos \theta|^\alpha 2^{\beta-\alpha} d\theta}$$

阅读文献了解到 IGSE 模型能够取得较好的拟合效果，因此我们将 IGSE 模型作为先验知识模型，以**模型堆叠**的方式结合进机器学习算法。我们同样在九种机器学习模型下，通过五种基本特征，并引入 IGSE 的计算结果作为新特征，训练得到结果如表 8-4 所示。

表 8-4 选取五种特征及峰度值和先验知识模型

模型名称	MSE	RMSE	MAE	泛化能力 (R^2)	平均相对 误差
决策树	2468064180	49679.61534	18789.38353	0.98166	0.12711
随机森林	1365509007	36952.7943	13453.49114	0.98985	0.07989
梯度提升树	2386278450	48849.54912	18253.06402	0.98226	0.12813
KNN	12399228177	111351.8216	40555.43826	0.90784	0.20232
ExtraTrees	863183576.7	29379.98599	9525.11261	0.99358	0.05326
AdaBoost	23118784283	152048.6247	53450.00471	0.82816	0.3462
CatBoost	247574467.6	15734.49928	5605.67209	0.99816	0.03542
XGBoost	2660035551	51575.53249	19101.43237	0.98023	0.12985
LightGBM	2316309806	48128.05632	18522.13814	0.98278	0.12883

观察验证结果，我们发现除了 KNN 和 AdaBoost 模型外，其 R^2 全部提升到 0.98 以上，证明了引入 IGSE 模型作为先验知识模型的有效性。关注在前两个模型上取得最佳效果的 CatBoost 模型，我们发现其 R^2 值取得了最高水平 0.998，并且平均相对误差进一步下降到了 0.035。该结果证明将传统的数学建模和数据驱动的机器学习相结合，能够充分利用两者的优势。通过引入 IGSE 的计算结果作为先验知识，使得模型特征具备更强的可解释性，同时基于机器学习较强的非线性学习能力，能够有效增加模型鲁棒性，兼顾模型的准确性、鲁棒性和可解释性。

8.4 预测与模型总结

我们将七种模型（由于 KNN 和 AdaBoost 在本任务中 R^2 值过低，因此不予考虑）在三种不同特征组合方式下的 R^2 和平均相对误差以雷达图的形式进行绘制，以综合评价不同模型的拟合效果，如图 8-4 所示：




图 8-4 九种模型在不同特征下的综合比较

通过雷达图可以直观看到，CatBoost 模型取得最优异的表现，并且经过合理特征选择优化，我们最终选定该模型作为本问题的主要预测工具，并选定特征组合 3（五种基本特征结合 IGSE 模型先验预测值）作为回归任务的特征组合。在训练过程中，采用了**模型堆叠**的策略，将不同模型的预测结果与原始特征结合，形成了一个强大的综合预测体系。CatBoost 在这种架构中扮演了核心角色，其强大的性能使得模型能够在复杂的回归任务中取得最佳效果，尤其是在处理非线性、多维交互数据时表现出色。这一成果展示了机器学习模型与领域先验知识相结合的巨大潜力，不仅提升了算法的可解释性，也为后续的工业应用提供了宝贵的参考。同时，该方案具有良好的泛化能力，可推广到更多复杂的工程问题中，助力智能制造、电力系统等领域的创新发展。

最后，按照题目要求，我们对附件三中的数据进行预测，按照要求我们选取特定的行，如下表所示：

表 8-5 部分磁芯损耗预测结果

序号	磁芯损耗预测结果
16	1014. 5
76	1544849. 4
98	11408
126	1753. 2
168	95190. 7
230	70098. 8
271	1885331. 8
338	13601. 1
348	897234. 2
379	1347. 9

九、问题五模型建立与求解分析

9.1 分析与思路

在磁性元件的设计与优化中，磁芯损耗和传输磁能是两个重要的评价指标。为了实现整体性能的卓越与最优化，本研究将建立一个双目标优化模型，旨在同时最小化磁芯损耗和最大化传输磁能（频率与磁通密度峰值的乘积）。本题的技术路线如图 9-1 所示：




图 9-1 问题五思路流程图

1. 目标函数构建：

最小化磁芯损耗：基于之前建立的磁芯损耗预测模型，目标为最小化损耗值，模型可以表示为：

$$\min L(T, f, w, m, B_m)$$

其中， L 表示磁芯损耗， T, f, w, m, B_m 为影响因素，分别代表温度、频率、波形、磁芯材料、磁通密度峰值。

最大化传输磁能：传输磁能可以通过频率 f 与磁通密度峰值 B_m 的乘积来表示，目标为最大化该乘积：

$$\max E(f, B_m) = f \times B_m$$

2. 模型简化：

为了求解双目标优化问题，通常需要将其简化为单目标优化，本文中我们选取权重法，给定两个目标的权重，将其线性组合为一个目标函数：

$$\min Z = \omega_1 \cdot L(T, f, w, m, B_m) - \omega_2 \cdot E(f, B_m)$$

其中， ω_1 和 ω_2 为权重系数，反映两个目标的重要性。在默认情况下，我们采用 1:1 的权重比，确保模型在综合优化时平衡考虑两者的重要性。

3. 评价指标构建：

基于磁芯损耗和传输磁能这两个核心目标，我们设计了以下的评价指标：

损耗与传输磁能的比值 LER：

$$LER = \frac{L(T, f, w, m, B_m)}{E(f, B_m)}$$

该指标用于直接衡量传输磁能相对于损耗的效率，LER 越小，说明磁芯损耗相对于传输磁能的比例越小，系统效率越高。

效率最大化指标 EMI：

$$EMI = \frac{L(T, f, w, m, B_m)}{L(T, f, w, m, B_m) + E(f, B_m)}$$

该指标关注传输磁能效率的最大化，该指标可以反映系统在能量传输上的整体效率，适用于对传输效率要求较高的设计场景。

通过使用以上的评价指标，能够从不同维度分析磁芯设计方案的优劣，帮助选择在磁芯损耗和传输磁能之间达到最佳平衡的优化方案。

4. 模型求解与分析

通过使用适当的优化算法（如遗传算法、粒子群优化等），对构建的模型进行求解。分析优化结果，识别出在不同条件下能够达到最小磁芯损耗和最大传输磁能的设计方案，进而为实际工程提供指导。

9.2 模型的建立、求解

9.2.1 优化算法

在本研究中，我们分别使用遗传算法、粒子群优化算法和灰狼优化算法作为不同的优化模型，比较其在磁性元件设计双目标优化问题中的效果。每种算法将单独优化磁芯损耗与传输磁能的综合性能表现。通过对比各个算法的收敛速度、优化结果质量以及全局搜索能力，我们能够找到最适合该问题的优化方法。

(1) 遗传算法^[16]:

遗传算法是一种基于自然选择和遗传机制的优化算法，它模拟了生物进化的过程。通过选择、交叉和变异等操作，遗传算法能够从种群中逐步进化出更优的解。遗传算法适用于全局搜索，避免陷入局部最优解，但在处理精细局部搜索时效率较低。

算法流程:

- 初始化种群: 随机生成一组个体（候选解），每个个体由一组参数表示。
- 适应度评估: 根据目标函数计算每个个体的适应度。
- 选择操作: 根据适应度值选择较优的个体作为父代。
- 交叉操作: 通过基因交换产生新的子代。
- 变异操作: 对部分个体的基因进行随机修改，增加种群的多样性。
- 迭代: 重复适应度评估、选择、交叉和变异操作，直到满足停止条件（如达到最大迭代次数或找到满意的解）。
- 输出: 选取最终的最优解作为问题的解。




图 9-2 遗传算法示意图

(2) 粒子群优化算法^[15]

粒子群优化算法是一种模拟鸟群觅食行为的群体智能算法。每个解被看作一个粒子，粒子在搜索空间中移动，通过学习自身的历史最优解和全局最优解，逐步更新位置来找到最优解。粒子群优化算法收敛速度较快，尤其在早期搜索阶段表现出色，适合优化精度要求较高的问题。

算法流程：

- 初始化粒子群：随机生成粒子的位置和速度，每个粒子代表一个解。
- 计算适应度值：评估每个粒子的位置（解）的适应度值。
- 更新个体最优和全局最优：每个粒子更新自己的历史最优位置，同时整个群体更新全局最优位置。
- 更新速度和位置：根据当前速度、个体最优位置和全局最优位置，更新粒子的速度，并计算粒子的下一个位置。
- 迭代：重复步骤 2 至 4，直到满足停止条件（如迭代次数或精度要求）。
- 输出：最终返回全局最优解。

（3）灰狼优化算法^[17]

灰狼优化算法模仿灰狼的捕猎行为，使用领导层级结构（ α 、 β 、 δ 和 ω ）来引导搜索过程。 α 狼是最优解， β 和 δ 狼协助领导捕猎， ω 狼则代表普通的候选解。通过模拟捕猎、围攻和追逐猎物，灰狼优化算法能够高效地寻找全局最优解。特点：灰狼优化算法能平衡全局与局部搜索，适合复杂多目标优化问题，并且在收敛速度和跳出局部最优的能力方面优于遗传算法和粒子群优化算法。

算法流程：

- 初始化种群：随机生成初始种群（狼群），每只狼代表一个解。
- 计算适应度值：根据目标函数评估每只狼的适应度值。
- 更新位置：根据 α 、 β 和 δ 三只最优狼的位置信息，引导其他狼的位置更新。狼群通过围绕最优狼捕猎并逐渐收缩搜索空间。
- 迭代：重复位置更新过程，模拟捕猎行为，直到满足停止条件（如达到最大迭代次数或找到满意的解）。
- 输出：返回狼群中的最优解作为问题的最终解。




图 9-3 灰狼优化算法位置向量

9.2.2 特征向量

基于基于磁性元件设计上述问题的分析，我们选择以下特征作为优化模型的输入：

1. **温度**：温度是影响磁芯损耗和传输磁能的关键因素之一。根据问题三中的实验分析，高频时选取 70°C ，低频时选取 90°C 能有效降低磁芯损耗，因此在优化过程中需要**重点**关注不同温度的影响。

2. **频率**：频率直接影响传输磁能的大小，并且对磁芯损耗有显著影响。实验结果显示，在高频和低频下，温度对磁芯损耗的影响有所不同，因此在模型中需要精确考量频率的变化。

3. **波形**：磁性元件的励磁波形会显著影响磁芯的工作状态。根据前期的分析，正弦波的激励波形能够使磁芯损耗更小，因此波形将固定为正弦波，不作为优化变量。

4. **磁芯材料**：不同材料的磁性能和损耗特性差异较大。根据前面的问题分析，材料四在实验中表现出较小的磁芯损耗，因此我们优先考虑材料四，并减少其他材料的选择。

5. **磁通密度峰值**：磁通密度峰值与传输磁能直接相关。为了最大化传输磁能，作为一个重要变量进行优化。其大小对磁芯损耗和传输性能都会产生直接影响。

为了控制时间和资源成本，基于问题三的实验结果，我们将波形固定为正弦波，材料优先选择材料四，减少了对材料和波形的多样化选择。同时，通过分析频率与温度的关系，明确了优化时需要重点考虑的温度区间，进一步缩小了优化参数空间。

9.3 预测与模型总结

在本研究中，我们利用三种优化算法（遗传算法、粒子群优化算法和灰狼优化算法）对双目标优化问题进行求解，分别分析其在不同条件下（温度、频率、波形、磁通密度峰值及磁芯材料）的优化效果。优化目标为最小化磁芯损耗和最大化传输磁能。

从表中结果可以看出，灰狼优化算法在综合性能上优于粒子群优化算法，且粒子群优化算法又优于遗传算法。灰狼优化算法在频率和传输磁能上的优化结果显著优于其他算法，且磁芯损耗最小。

在偏高的频率（约 188000 Hz）、温度 90℃、正弦波、磁通密度峰值为 0.012T、使用材料四的条件下，灰狼优化算法表现出最优效果。这些条件共同作用，能够实现**最小磁芯损耗**和**最大传输磁能**的优化目标，为磁性元件的设计与优化提供了具体的指导。

表 9-1 三种不同优化模型的实验结果 (T=70℃)

	遗传算法	粒子群优化算法	灰狼优化算法
频率	187324.92	188027.85	188190.57
磁通密度峰值	0.019	0.019	0.019
磁芯损耗	2184.78	2124.23	2054.35
传输磁能	3559.17	3572.52	3575.62
LER	61.38%	59.46%	57.45%
EMI	38.04%	37.29%	36.49%

表 9-2 三种不同优化模型的实验结果 (T=90℃)

	遗传算法	粒子群优化算法	灰狼优化算法
频率	187456.84	187922.18	188151.53
磁通密度峰值	0.019	0.019	0.012
磁芯损耗	2159.56	2117.97	831.89
传输磁能	3561.68	3570.52	2259.83
LER	60.63%	59.32%	36.81%
EMI	37.74%	37.23%	26.91%

为严谨起见，我们使用灰狼优化算法，对 48 种变量组合情况进行了实验，如下表所示：

表 9-3 三种不同优化模型的 LER 预测结果(正弦波)

	材料 1	材料 2	材料 3	材料 4
T=25℃	50.50%	53.00%	50.83%	53.01%
T=50℃	40.07%	40.10%	42.38%	40.18%
T=70℃	58.15%	58.62%	58.47%	38.87%
T=90℃	40.34%	56.94%	40.34%	36.81%

表 9-4 三种不同优化模型的 LER 预测结果(三角波)

	材料 1	材料 2	材料 3	材料 4
T=25℃	50.87%	53.25%	52.99%	53.01%
T=50℃	40.62%	40.15%	41.13%	40.05%
T=70℃	43.18%	57.36%	43.91%	43.45%
T=90℃	58.31%	58.23%	58.22%	58.56%

表 9-5 三种不同优化模型的 LER 预测结果(梯形波)

	材料 1	材料 2	材料 3	材料 4
T=25℃	53.01%	50.80%	53.00%	50.91%
T=50℃	48.08%	40.00%	42.38%	40.30%
T=70℃	57.32%	57.29%	36.74%	43.89%
T=90℃	55.78%	39.46%	58.24%	58.15%

十、模型评价和改进

10.1 模型优点

1. 对于问题一，根据磁通密度分布特征识别励磁的三种波形，采用决策树和随机森林对收集和变换的 19 种特征进行特征重要性判断，选取重要特征后采用投票法集成六种不同模型/特征的分类模型。利用集成算法优势避免单个特征/算法不稳定的缺点。
2. 对于问题二，构造使用不同温度变化的磁芯损耗修正方程，我们分别将温度作为线性项、对数项和自变量交互项，构建了线性/非线性模型对原始数据进行拟合，分析各种可能的影响因素组成，我们选择了一种最优的修正方程作为传统斯坦麦茨方程的改进方案。
3. 对于问题三，研究温度、励磁波形和磁芯材料对磁芯损耗的影响，我们分别使用单因素方差分析法和双因素方差分析法，分析三种因素独立和相互作用下对磁芯损耗的影响，问题三的分析结论帮助我们理解三种因素对磁芯损耗的影响，对后续问题的求解起到了推动作用。
4. 对于问题四，构建能够跨越不同材料类型和工况的磁芯损耗预测模型，我们应用了九种不同的特征组合，并在三组不断迭代改进的特征组合上进行训练，最终采用模型堆叠的方式训练 CatBoost 模型取得了最优的预测拟合效果。
5. 对于问题五，判断达到最小磁芯损耗和最大工况条件的传输磁能，我们选择了先进的灰狼仿生智能优化算法，利用其强大全局搜索能力和局部优化能力的平衡，计算得到最优解。

10.2 模型缺点

1. 问题一中根据经验和观察选取出两种特征，能够针对给定规则集实现 0 误差分类，但是由于选取特征较少，可能存在针对未知数据的泛化能力较差的可能性。
2. 我们仅讨论六种修正方程假设，而温度可能以更高阶的非线性因素参与影响，因此模型存在进一步优化的空间。
3. 由于采用随机抽样的方式进行方差分析，因此抽取样本的频率和磁通量密度峰值可能方差结论产生影响，导致最终分析结果可能出现不一致的情况。

4. 由于 IGSE 已经达到相对较高的预测精准度，因此引入机器学习模型和数学模型的堆叠方法可能存在过拟合的风险。
5. 使用仿生智能优化算法尽管达到了部分优化效果，但是在其他成分组合上出现了更优的方案，我们分析可能的原因的灰狼优化算法陷入了局部最优。

10.3 模型的改进和推广

1. 针对问题一，我们可以采集更多的磁芯材料数据和磁芯密度分布以选取更多细粒度的特征，也可以引入选取泛化能力更强的分类模型。
2. 针对问题二，可以引入机器学习算法估计温度因素对斯坦麦茨方程的影响，其非线性方程拟合能力能够帮助我们进一步改善模型拟合精度。
3. 针对问题三，其分析结果与问题五的解决方案设计息息相关，因此我们可以对抽样方式进行进一步改进，通过更严谨的抽样方法提升结论的健壮性。
4. 针对问题五，可以通过使用新的仿生智能优化算法改进优化问题求解。

参考文献

- [1] G. Bertotti. General properties of power losses in soft ferromagnetic materials. IEEE Transactions On Magnetism, 1988: 621-630.
- [2] C. P. Steinmetz. On the law of hysteresis. AIEE Transactions, vol. 9, 1892: 3-64.
- [3] Rudy Severns. HF core loss for non-sinusoidal waveforms. Proc. HFPC'91, 1991: 140-148.
- [4] Venkatachalam K, Sullivan C R, Abdallah T, et al. Accurate prediction of ferrite core loss with nonsinusoidal waveforms using only Steinmetz parameters[C]//IEEE Workshop on Computers in Power Electronics. Mayaguez, Puerto Rico, USA, 2002: 36-41.
- [5] 叶建盈, 陈为, 汪晶慧. PWM波及直流偏磁励磁下磁芯损耗模型研究[J] 中国电机工程学报. 2015, 35(10): 2601-2606.
- [6] Song Y Y, Ying L U. Decision tree methods: applications for classification and prediction[J]. Shanghai archives of psychiatry, 2015, 27(2): 130.
- [7] Rigatti S J. Random forest[J]. Journal of Insurance Medicine, 2017, 47(1): 31-39.
- [8] Ke G, Meng Q, Finley T, et al. Lightgbm: A highly efficient gradient boosting decision tree[J]. Advances in neural information processing systems, 2017, 30.
- [9] Guo G, Wang H, Bell D, et al. KNN model-based approach in classification[C]//On The Move to Meaningful Internet Systems 2003: CoopIS, DOA, and ODBASE: OTM Confederated International Conferences, CoopIS, DOA, and ODBASE 2003, Catania, Sicily, Italy, November 3-7, 2003. Proceedings. Springer Berlin Heidelberg, 2003: 986-996.
- [10] Geurts P, Ernst D, Wehenkel L. Extremely randomized trees[J]. Machine learning, 2006, 63: 3-42.
- [11] Ying C, Qi-Guang M, Jia-Chen L, et al. Advance and prospects of AdaBoost algorithm[J]. Acta Automatica Sinica, 2013, 39(6): 745-758.
- [12] Hancock J T, Khoshgoftaar T M. CatBoost for big data: an interdisciplinary review[J]. Journal of big data, 2020, 7(1): 94.
- [13] Sheridan R P, Wang W M, Liaw A, et al. Extreme gradient boosting as a method for quantitative structure-activity relationships[J]. Journal of chemical information and modeling, 2016, 56(12): 2353-2360.
- [14] Ke G, Meng Q, Finley T, et al. Lightgbm: A highly efficient gradient boosting decision tree[J]. Advances in neural information processing systems, 2017, 30.
- [15] Kennedy J, Eberhart R. Particle swarm optimization[C]//Proceedings of ICNN'95-international conference on neural networks. IEEE, 1995, 4: 1942-1948.
- [16] Lambora A, Gupta K, Chopra K. Genetic algorithm-A literature review[C]//2019 international conference on machine learning, big data, cloud and parallel computing (COMITCon). IEEE, 2019: 380-384.
- [17] Wu H S, Zhang F M. Wolf pack algorithm for unconstrained global optimization[J]. Mathematical Problems in Engineering, 2014, 2014(1): 465082.

附录

人工智能技术使用披露
使用了 ChatGPT 进行以下方面的辅助工作： - 了解、理解关于常见机器学习模型（如 CatBoost、LightGBM 等）的基本概念和使用方法，修正部分代码的错误。 - 在数据处理与结果分析中，使用 ChatGPT 帮助润色论文中的部分文字表达，以确保语言的准确性与流畅度。
算法与技术组合的关键开发框架
编程框架：本文在代码开发和建模过程中，主要使用了以下开源框架与工具： - numpy：用于数值计算和数据操作。 - pandas：用于数据整理与清洗，数据框操作。 - matplotlib：用于可视化和绘图。 - pytorch：用于深度学习模型的开发和训练。 - scikit-learn：使用 sklearn 的机器学习算法进行磁芯损耗预测模型的构建和评估等。
数据分析与处理工具
本文使用 SPSSPRO 软件进行方差分析，用于分析温度、波形、频率、磁芯材料等因素对磁芯损耗的显著性结果。此外，还使用 SPSSPRO 进行频数分析，用于变量分布的描述。
问题 1 代码（部分）
<pre>import pandas as pd import numpy as np data = pd.read_csv("./data/train_2.csv") print(data.shape) selectColumns = data[[str(i) for i in range(1024)]] for j in range(2000,2500): temp = selectColumns.iloc[j].to_numpy() # 进行 FFT fft_result = np.fft.fft(temp) frequencies = np.fft.fftfreq(len(temp)) # 只取正频率部分 positive_frequencies = frequencies[:len(frequencies)//2] fft_magnitude = np.abs(fft_result[:len(fft_result)//2]) # 归一化到 [0, 1] 之间 fm_min = np.min(fft_magnitude)</pre>


```

fm_max = np.max(fft_magnitude)

fft_magnitude = (fft_magnitude - fm_min) / (fm_max - fm_min)

data_X = []
data_Y = []
for i in range(len(positive_frequencies)):
    if fft_magnitude[i] > 0.01:
        data_X.append(positive_frequencies[i])
        data_Y.append(fft_magnitude[i])
print(j, len(data_Y), data.iloc[j, 3])

```

问题 2 代码（部分）

```

import matplotlib.pyplot as plt
import pandas as pd
import math
import numpy as np
from sklearn.linear_model import LinearRegression
from sklearn.model_selection import KFold
from sklearn.metrics import mean_squared_error, r2_score

# 读取数据
data = pd.read_csv("./data/train_4.csv")

# 初始化列表
X, Y, Z, T, XY, XT, YT, TT = [], [], [], [], [], [], [], []

# 数据处理
for d in data.iloc:
    if d[3] != "正弦波":
        continue
    P = d[2]
    f = d[1]
    tt = d[0]
    B = max([abs(i) for i in d[4:1028]])
    logP = math.log(P)
    logf = math.log(f)
    logB = math.log(B)
    logT = tt

    X.append(logf)
    Y.append(logB)

```

```

XY.append(logf*logB)
T.append(logT)
XT.append(logT*logf)
YT.append(logT*logB)
Z.append(logP)

x = np.array(X)
y = np.array(Y)
xy = np.array(XY)
t = np.array(T)
xt = np.array(XT)
yt = np.array(YT)
z = np.array(Z)

# 将 x, y, t 组合成一个特征矩阵
XMat = np.column_stack((x, y, t, xt, yt))

# K 折交叉验证
kf = KFold(n_splits=5, shuffle=True, random_state=42)
mse_list = [] # 存储每折的均方误差
mse_exp_list = []
r2_list = [] # 存储每折的 R^2 分数
r2_exp_list = []

for train_index, test_index in kf.split(XMat):
    X_train, X_test = XMat[train_index], XMat[test_index]
    y_train, y_test = z[train_index], z[test_index]

    # 创建线性回归模型
    model = LinearRegression()

    # 拟合模型
    model.fit(X_train, y_train)

    # 预测
    y_pred = model.predict(X_test)

    # 计算均方误差和 R^2 分数
    mse = mean_squared_error(y_test, y_pred)
    mse_exp = mean_squared_error(np.exp(y_pred), np.exp(y_test))
    r2 = r2_score(y_test, y_pred)
    r2_exp = r2_score(np.exp(y_pred), np.exp(y_test))

```

```

mse_list.append(mse)
mse_exp_list.append(mse_exp)
r2_list.append(r2)
r2_exp_list.append(r2_exp)

# 计算平均均方误差和平均 R^2 分数
mean_mse = np.mean(mse_list)
mean_mse_exp = np.mean(mse_exp_list)
mean_r2 = np.mean(r2_list)
mean_r2_exp = np.mean(r2_exp_list)

# 提取最后一折的参数
final_model = LinearRegression()
final_model.fit(XMat, z) # 使用整个数据集训练
a = final_model.coef_[0]
b = final_model.coef_[1]
c = final_model.coef_[2]
d = final_model.coef_[3]
e = final_model.coef_[4]
k = final_model.intercept_

# 输出结果
print(f"参数 a: {a}, b: {b}, c: {c}, d: {d}, e: {e}, k: {k}")
print(f"平均均方误差: {mean_mse}")
print(f"平均均方误差 EXP: {mean_mse_exp}")
print(f"平均 R^2 分数: {mean_r2}")
print(f"平均 R^2 分数 EXP: {mean_r2_exp}")

# 对整个训练集进行训练
z_pred = final_model.predict(XMat) # 使用模型预测整个训练集

# 创建三维图形
fig = plt.figure(figsize=(10, 7))
ax = fig.add_subplot(111, projection='3d')
ax.view_init(elev=4, azim=-15)
# 绘制真实值的三维散点图
scatter_real = ax.scatter(x, y, z, c='#D64161', alpha=0.2, marker='.')

# 绘制预测值的三维散点图
scatter_pred = ax.scatter(x, y, z_pred, c='#8A2BE2', alpha=0.5, marker='.')

```

```

# 设置坐标轴标签
ax.set_xlabel('log(f)')
ax.set_ylabel('log(B)')
ax.set_zlabel('log(P)')
ax.set_xticks([11, 11.5, 12, 12.5]) # X轴刻度
ax.set_yticks([-2, -3, -4]) # Y轴刻度
ax.set_zticks([8, 10, 12, 14]) # Z轴刻度
ax.set_xlabel('log(f)', fontsize=14, labelpad=10)
ax.set_ylabel('log($B_m$)', fontsize=14, labelpad=10)
ax.set_zlabel('log(P)', fontsize=14, labelpad=10)
plt.savefig("./q2_opt4.png", dpi=300)
# 显示图形
plt.show()

```

问题 4 代码（部分）

```

import math
import numpy as np
import pandas as pd
from catboost import CatBoostRegressor
from sklearn.metrics import mean_squared_error
from sklearn.model_selection import train_test_split
from scipy.stats import kurtosis, skew

# 读取数据
data1 = pd.read_csv("data/train_1.csv")
data1['材料'] = '材料 1'
data2 = pd.read_csv("data/train_2.csv")
data2['材料'] = '材料 2'
data3 = pd.read_csv("data/train_3.csv")
data3['材料'] = '材料 3'
data4 = pd.read_csv("data/train_4.csv")
data4['材料'] = '材料 4'
data = pd.concat([data1, data2, data3, data4])

# 特征处理函数
def checkFeature0(t):
    return [1 if t == x else 0 for x in [25, 50, 70, 90]]

def checkFeatureMaterial(data):
    return [1 if data == f'材料{i+1}' else 0 for i in range(4)]

```

```

def checkFeature3(t):
    return [1 if t == wave else 0 for wave in ['正弦波', '三角波', '梯形波']]

# 处理数据
dataX = []
dataY = []
for index, row in data.iterrows():
    feature = []
    feature.append(math.log(row[0])) # 温度
    feature.append(math.log(row[1])) # 频率
    feature.extend(checkFeature3(row[3])) # 波形
    feature.extend(checkFeatureMaterial(row['材料'])) # 材料特征向量

    maxB = max(abs(i) for i in row[4:1028])
    peak_kurtosis = kurtosis(row[4:1028].to_numpy().astype(np.float32))
    peak_skewness = skew(row[4:1028].to_numpy().astype(np.float32))

    feature.append(maxB) # B 最大值

    dataX.append(feature)
    dataY.append(math.log(row[2]))

# 划分数据集
X_train, X_test, y_train, y_test = train_test_split(dataX, dataY, test_size=0.3,
random_state=42)

# 创建 CatBoost 回归器
catboost_model = CatBoostRegressor(iterations=1000, depth=6, learning_rate=0.1,
loss_function='RMSE', verbose=0)

# 训练模型
catboost_model.fit(X_train, y_train)

# 预测
y_pred = catboost_model.predict(X_test)

# 评估模型
mse = mean_squared_error(y_test, y_pred)
tss = np.mean((y_test - np.mean(y_test)) ** 2)
r2 = 1 - (mse / tss)

```

```

print(f'Mean Squared Error of the CatBoost model: {mse:.2f}')
print(f'R^2 score: {r2:.2f}')

true_mse = 0.0
relative_errors = []

for i in range(len(y_pred)):
    pred_value = math.exp(y_pred[i])
    true_value = math.exp(y_test[i])

    absolute_error = abs(pred_value - true_value)

    if true_value != 0:
        relative_error = (absolute_error / true_value) * 100
    else:
        relative_error = float('inf')

    relative_errors.append(relative_error)
    true_mse += (pred_value - true_value) ** 2

    print(f"Sample {i}: Predicted: {pred_value:.2f}, Actual: {true_value:.2f}, 绝对误差: {absolute_error:.2f}, 相对误差: {relative_error:.2f}%")

print(f'True Mean Squared Error of the CatBoost model: {true_mse:.2f}')
mean_relative_error = np.mean(relative_errors)
print(f'平均相对误差: {mean_relative_error:.2f}%')

```

问题 5 代码（部分）

```

import math
import numpy as np
import pandas as pd
from catboost import CatBoostRegressor
from tqdm import tqdm
from sklearn.metrics import mean_squared_error
from sklearn.model_selection import train_test_split
from scipy.stats import kurtosis, skew

# 读取数据
data1 = pd.read_csv("data/train_1.csv")
data1['材料'] = 1
data2 = pd.read_csv("data/train_2.csv")

```

```

data2['材料'] = 2
data3 = pd.read_csv("data/train_3.csv")
data3['材料'] = 3
data4 = pd.read_csv("data/train_4.csv")
data4['材料'] = 4
data = pd.concat([data1, data2, data3, data4])

# 替换波形名称
data.iloc[:, 3] = data.iloc[:, 3].replace({'正弦波': 1, '三角波': 2, '梯形波': 3})

# 特征处理函数
def checkFeatureMaterial(data):
    return [1 if data == i + 1 else 0 for i in range(4)]

def checkFeature3(t):
    return [1 if t == wave else 0 for wave in [1, 2, 3]]

# 处理数据
dataX = []
dataY = []
for index, row in data.iterrows():
    feature = []
    feature.append(math.log(row[0])) # 温度
    feature.append(math.log(row[1])) # 频率
    feature.extend(checkFeature3(row[3])) # 波形
    feature.extend(checkFeatureMaterial(row['材料'])) # 材料特征向量

    maxB = max(abs(i) for i in row[4:1028])
    feature.append(maxB) # B 最大值

    dataX.append(feature)
    dataY.append(math.log(row[2])) # 损耗

# 划分数据集
X_train, X_test, y_train, y_test = train_test_split(dataX, dataY, test_size=0.3,
random_state=42)

# 创建 CatBoost 回归器
catboost_model = CatBoostRegressor(iterations=1000, depth=6, learning_rate=0.1,

```

```

loss_function='RMSE', verbose=0)

# 训练模型
catboost_model.fit(X_train, y_train)

# 定义目标函数
def objective_function(params):
    temperature, frequency, waveform, peak_B, material = params
    wave_dict = {1: '正弦波', 2: '三角波', 3: '梯形波'}
    material_dict = {1: '材料 1', 2: '材料 2', 3: '材料 3', 4: '材料 4'}

    # 预测磁芯损耗
    feature = [np.log(temperature), np.log(frequency)]
    feature.extend(checkFeature3(wave_dict[int(waveform)])) # 确保使用整数作为索引
    feature.extend(checkFeatureMaterial(material_dict[int(material)])) # 确保使用整数作为索引
    feature.append(peak_B)

    log_loss = catboost_model.predict([feature])[0] # 预测损耗
    predicted_loss = np.exp(log_loss) # 还原损耗值

    # 计算传输磁能
    transmission_energy = frequency * peak_B

    # 目标函数: 最小化损耗, 同时最大化传输磁能
    return predicted_loss - transmission_energy

# 粒子群优化设置
def pso(num_particles, max_iter):
    t=25
    x=3
    y=1
    # 初始化粒子的位置
    particles = np.zeros((num_particles, 5))
    # particles[:, 0] = np.random.uniform(25, 90, num_particles) # 温度
    particles[:, 0] = t
    particles[:, 1] = np.random.uniform(50000, 500000, num_particles) # 频率
    # particles[:, 2] = np.random.randint(1, 4, num_particles) # 波形 (1, 2, 3)

```



```

particles[:, 2]=x
particles[:, 3] = np.random.uniform(0.009, 0.319, num_particles) # 最大B
# particles[:, 4] = np.random.randint(1, 5, num_particles) # 材料 (1, 2, 3,
4)
particles[:, 4] = y # 材料 (1, 2, 3, 4)

velocities = np.random.rand(num_particles, 5) * 0.1 # 随机速度
best_positions = np.copy(particles)
best_scores = np.array([objective_function(p) for p in best_positions])
global_best_position = best_positions[np.argmin(best_scores)]

for _ in tqdm(range(max_iter)):
    for i in range(num_particles):
        # 更新速度和位置
        r1, r2 = np.random.rand(2)
        velocities[i] = velocities[i] + r1 * (best_positions[i] - particles[i])
+ r2 * (global_best_position - particles[i])
        particles[i] = particles[i] + velocities[i]

        # 限制范围
        # particles[i][0] = np.clip(particles[i][0], 25, 90) # 温度
        particles[i][0] = t # 温度
        particles[i][1] = np.clip(particles[i][1], 50000, 500000) # 频率
        # particles[i][2] = int(np.clip(particles[i][2], 1, 3)) # 波形
        particles[i][2] = x
        particles[i][3] = np.clip(particles[i][3], 0.009, 0.319) # 最大B
        # particles[i][4] = int(np.clip(particles[i][4], 1, 4)) # 材料
        particles[i][4] = y
        # 更新个体最佳
        score = objective_function(particles[i])
        if score < best_scores[i]:
            best_scores[i] = score
            best_positions[i] = particles[i]

        # 更新全局最佳
        global_best_score = np.min(best_scores)
        global_best_position = best_positions[np.argmin(best_scores)]

    return global_best_position

# 执行粒子群优化
best_params = pso(num_particles=100, max_iter=100)

```

```

print("优化后的参数:")
print(f"温度: {best_params[0]:.2f}, 频率: {best_params[1]:.2f}, 波形: {int(best_params[2])}, "
      f"最大B: {best_params[3]:.3f}, 材料: {int(best_params[4])}")

# 计算最终的损耗和能量值
final_temperature = best_params[0]
final_frequency = best_params[1]
final_waveform = int(best_params[2])
final_peak_B = best_params[3]
final_material = int(best_params[4])

predicted_loss = objective_function(best_params) + final_frequency * final_peak_B
# 获取预测损耗

transmission_energy = final_frequency * final_peak_B # 计算传输磁能

print(f"最终损耗: {predicted_loss:.2f}, 传输磁能: {transmission_energy:.2f}")
print(f"LER:{(predicted_loss/transmission_energy)*100:.2f}%")
print(f"EMI:{(predicted_loss/(transmission_energy+predicted_loss))*100:.2f}%"
)

```