



中国研究生创新实践系列大赛
“华为杯”第二十一届中国研究生
数学建模竞赛

学 校 华侨大学

参赛队号 24103850092

1.周文浩

队员姓名 2.李虎峰

3.欧雪雯

中国研究生创新实践系列大赛

“华为杯”第二十一届中国研究生

数学建模竞赛

题 目： 多源异构数据驱动的暴雨成灾机理及其时空演变特征研究

摘 要：

随着全球气候变化日趋剧烈，极端天气事件，尤其是暴雨的发生频率显著增加，对生态环境安全和人类经济社会发展构成了严峻挑战。本研究旨在通过整合多源异构数据，系统性地分析降水量和土地利用/土地覆盖（LULC）类型的时空动态特征，并深入探讨它们在暴雨致灾过程中的作用机制及其相互作用关系。研究分为四个主要部分，每个部分均涉及特定的模型构建和定量分析过程，从而得出一系列具有价值的结论。

对于**问题一**，基于 1990 至 2020 年间中国的长时间序列数据，采用年均降水量和 LULC 类型变化作为主要指标，通过描述性统计和空间分析，得出降水量与土地利用/土地覆盖（LULC）的时空演变特征。结果显示，中国降水量和 LULC 呈现显著的空间异质性。东南沿海地区年均降水量普遍超过 600 毫米，同时该区域经历了显著的城市化进程，伴随着耕地面积的持续减少。相比之下，西北地区年均降水量通常低于 200 毫米，LULC 变化相对缓慢，以农业用地和草地为主导类型。通过探讨降水量和 LULC 的空间变化情况和时间演化特征，揭示了降水量和 LULC 在空间分布上的不均衡性，反映气候变化与人类活动对区域环境系统的复杂影响。为深入理解中国不同区域的水文过程和土地利用动态提供了重要的实证基础。

对于**问题二**，研究主要聚焦于探讨“地形-气候”相互作用与极端降水事件的形成机制。采用决策树算法，量化地形和气候因素在暴雨形成过程中的交互影响，结合地理信息系统（GIS）技术，深入分析地形特征和气候要素对极端降水事件的影响。在模型构建过程中，将地形特征和气候因素作为自变量，年平均降水量作为因变量，同时将暴雨事件的发生与否作为二元分类变量。此外，我们还考虑了经纬度和土地利用类型等因素，以探讨它们在降水量和极端天气形成过程中的交互作用。研究结果表明，年平均降水量主要受到气温和地理位置的显著影响。在低纬度地区，由于气温较高，年平均降水量明显增加。这一现象可以通过 Clausius-Clapeyron 方程进行解释：高温环境下大气持水能力增强，为充沛降水提供了充足的水汽来源。此外，高温还促进了大气对流活动，有利于云系的形成和发展，进而增加降水概率。在东部地区，海洋性气候的影响尤为显著，丰富的水汽源结合东亚季风在夏季的强烈水汽输送，导致低纬度地区降水量显著增加。极端暴雨事件的形成同样受到气温和地理位置的复杂交互作用。具体而言，低温低纬的东部地区、中高温区域及高温低纬区域均表现出较高的极端暴雨发生可能性。从气象动力学角度分析，低温低纬东部地区可能存在显著的温度梯度，有利于锋面系统的形成，进而触发强降水。中高温地区的

大气具有较强的持水能力，为暴雨提供了充足的水汽源。而在高温低纬区域，强烈的太阳辐射加热地表，增加了大气的不稳定性，促进了对流性降水的形成。此外，研究还揭示了地形特征在暴雨形成过程中的关键作用。东南沿海复杂的山地和丘陵地形，通过抬升效应强化了降水强度。潮湿气流遇到地形障碍时，被迫上升运动导致降水量增加。

对于**问题三**，主要关注于暴雨成灾的临界条件及脆弱性预测。基于前两部分的研究成果，通过多变量交互分析，确定影响暴雨成灾的关键临界条件。在本部分中，通过 XGBoost 算法和决策树模型，发现暴雨成灾的临界条件涉及多个变量的复杂组合。具体而言：低纬度的耕地地区（纬度 $\leq 35.5^{\circ}$ N）在高降雨趋势（ >0.759 ）和低土地覆被（ ≤ 0.067 ）下，尤其容易发生暴雨成灾。此外，低纬东部的草地地区（经度 $>113.6^{\circ}$ E，纬度 $\leq 35.5^{\circ}$ N）在低降雨趋势（ ≤ 0.759 ）、中低土地覆被（ >0.089 ）及较高的降雨量（ $>430.469\text{mm}$ ）条件下，同样面临较高的暴雨风险。在中高纬度东部地区，随着降雨趋势的增加（ >1.307 ）和海拔高度的升高（ $>3840.559\text{m}$ ），暴雨成灾的风险进一步加剧。此外，低纬度地区在高降雨趋势（ >0.893 ）、中低土地覆被（ >0.089 ）及较高海拔高度（ $>60.153\text{m}$ ）的条件下，降雨量（ $>628.906\text{mm}$ ）的增多也会加剧暴雨的成灾潜力。最后，低纬东部的灌木丛地区在低降雨趋势（ ≤ 0.759 ）和中高降雨量（ $>430.469\text{mm}$ ）的背景下，显示出显著的暴雨成灾风险。在对暴雨灾害脆弱性指数的计算及未来 2025-2035 年的预测中，通过熵值法从自然触发因素、物理脆弱性和土地脆弱性三个方面进行综合评估。结合 ARIMA 算法，预测了降雨量及耕地、林地、草原、灌木和湿地五类土地覆盖类型的变量自相关变化，明确这些变量的未来变化趋势。同时，利用 SVR 算法对 2025-2035 年间的暴雨灾害脆弱性指数进行预测。结果显示高脆弱性区域主要集中在东南沿海的江苏、浙江、福建、广东和广西，以及周边的山东、河南、安徽、湖北、湖南、贵州和云南等省份。东北的吉林和辽宁边境区域以及西藏的藏南地区也显示出一定的脆弱性。为进一步探讨暴雨成灾的空间特征，本文采用 ArcGIS 软件对预测结果进行可视化处理。通过地图形式呈现，为地方政府制定防灾减灾措施提供了重要的参考依据。

对于**问题四**，本文主要研究土地利用变化特征与结构分析，利用地理大数据，结合前三部分的分析结果，本文对中国土地利用变化的特征与结构进行了综合描述。通过数学模型的建立，本文分析了土地利用变化的时空演变，尤其是耕地、林地、草地等不同土地类型的分布变化。研究发现，耕地和林地的分布整体呈现出扩张趋势，而草地、灌木和湿地则有收缩的迹象。此外，本文进一步验证了标准差椭圆的准确性和有效性，并通过有效性分析推导得出了一条“和仲线”，以明确不同区域的资源开发潜力与保护需求。

关键词： 暴雨成灾；极端天气；多源异构数据；土地利用；机器学习

目录

一、研究背景及问题重述	5
1.1 研究背景	5
1.2 问题重述	5
1.2.1 降水量和土地利用/土地覆被类型的时空演化特征	5
1.2.2 地形-气候相互作用对极端天气的影响	6
1.2.3 暴雨成灾的临界条件及脆弱地区预测	6
1.2.4 中国土地利用变化的特征与结构分析	6
1.3 总体解题思路	6
二、本文数学符号说明	8
三、问题一求解及分析	9
3.1 问题描述	9
3.2 数据的预处理工作	9
3.2.1 降水量数据的预处理	10
3.2.2 土地利用/土地覆被类型数据的预处理	11
3.3 数据的描述性统计与分析总结	11
3.3.1 降水量数据的描述性统计与分析总结	11
3.3.2 土地利用数据的描述性统计与分析总结	13
3.4 本章小结	21
四、问题二求解及分析	22
4.1 问题描述	22
4.2 问题求解	22
4.2.1 数据准备与整合	22
4.2.2 变量准备	23
4.2.3 数据描述与相关性分析	24
4.2.4 决策树建模	27
4.2.5 建模结果	28
4.3 本章小结	34
五、问题三求解及分析	36
5.1 问题描述	36
5.2 问题求解	36
5.2.1 数据准备与特征工程	36
5.2.2 模型构建	39
5.2.3 暴雨灾害脆弱性指数评价	41
5.2.4 基于 XGBoost 模型的暴雨成灾的临界条件分析	45
5.2.5 未来脆弱地区预测的结果	49
5.3 本章小结	59
六、问题四求解及分析	61
6.1 问题描述	61
6.2 问题求解	61
6.2.1 1990-2020 年间中国土地利用的分布与重心变化	61
6.2.2 准确性验证	66

6.2.3 有效性验证	72
6.3 本章小结	75
七、结论与展望	77
7.1 研究结论	77
7.2 未来展望	78
参考文献	79
附录	81

一、研究背景及问题重述

1.1 研究背景

地理系统是一个复杂的巨系统，包含自然地理和人文地理要素的综合作用^[1]。自然地理要素包括地形、气候、水文、土壤、植被等，而人文地理要素涵盖人口、经济、土地利用等。这些要素之间相互作用、相互影响，构成了复杂的地理结构和动态演化过程^[2]。传统的地理学研究通过宏观结构和定性分析对地理系统进行简化和概括，从而帮助人们认识和理解自然环境的基本特征^[3]。例如，中国的地形特征通过“三大阶梯”进行概括，气候分布则以秦岭—淮河线为界，将中国南北的温度、降水、植被、土壤和生态环境等地理现象进行划分^[4]。此外，由胡焕庸线所揭示的人口分布格局，则将中国划分为东部人口密集、西部人口稀疏的两部分。这些地理学上的概括性框架，为研究生态保护、社会经济发展、城市规划和国家安全保障提供了重要的理论基础和决策支持^[5]。

然而，随着全球气候变化的加剧，地理系统中的自然和人文要素正发生着复杂且迅速的变化。极端天气事件如暴雨、干旱、热浪等现象的频发，严重威胁到人类的生存环境和生产活动。此外，人类活动的快速扩展和全球化进程的推进，导致了土地利用和土地覆被的剧烈变化^[6]。面对这些新兴问题，地理学的研究需求发生了转变，迫切需要新的方法来应对这些动态变化。

近年来，遥感技术、全球定位系统（GPS）、地理信息系统（GIS）以及大数据技术的飞速发展，使得本文能够以极高的空间和时间分辨率观测地理系统的演化^[7,8]。通过对地观测数据的积累，学者们可以获取从气候、降水、土地利用到人口迁移等一系列多维度的地理信息数据。大数据的引入使得量化、数据驱动的分析手段成为可能，能够以更精确、更全面的方式揭示自然地理和人文地理要素之间的复杂交互关系。例如，遥感影像数据可以实时捕捉地球表面植被、土壤以及水体变化的细节，气象数据能够提供极端天气事件发生的动态信息，土地利用数据则能展示城市扩展、农业生产区域变化等人类活动的影响。这些数据的规模和复杂性远远超过了传统地理学的分析能力，如何利用大数据技术对地理系统进行综合分析，已经成为地理学研究的核心问题之一^[9]。极端天气事件，尤其是暴雨、洪涝、台风等灾害，随着气候变化的加剧，发生的频率和强度显著增加。这些极端事件不仅对人类的生命财产造成重大威胁，也对生态系统产生深远影响。暴雨的形成过程受到多种因素的影响，包括气候系统的变化、地形的作用、土地利用的方式等。因此，深入研究这些因素之间的相互作用机制，对于理解极端天气事件的发生规律以及提高灾害防御能力具有重要的现实意义。

在这样的背景下，本研究的核心目标是利用地理大数据，结合数学建模的方式，研究中国地理环境的时空演化特征，并探讨极端天气事件的成灾机制。通过建立模型，分析降雨、地形、土地利用之间的相互作用，揭示暴雨等极端天气的形成机理，并预测未来脆弱地区的灾害风险。同时，还将对中国的土地利用变化进行综合分析，探讨自然和人文要素的相互作用如何影响土地的空间分布和结构演变。最终，这些研究成果将为提升中国应对气候变化的能力、优化土地利用管理、提高自然灾害防御水平提供科学依据和决策支持。

1.2 问题重述

本研究赛题一共涉及四个子问题，均依赖于地理大数据和数学建模技术：

1.2.1 降水量和土地利用/土地覆被类型的时空演化特征

问题一要求基于 1990 至 2020 年间的中国范围数据，分析降水量和土地利用/土地覆被类型的时空演化。两者分别为连续变化的变量和离散分布的变量，并且都具有时空不均匀性。本问题的目标是为这两个变量构建描述性统计方法，利用 1~3 个统计指标或图表来总结其演变特征。

1.2.2 地形-气候相互作用对极端天气的影响

第二个问题要求建立数学模型，说明地形和气候因素在极端天气，尤其是暴雨形成中的作用。本问题的目标是通过地形与气候相互作用机制的定量化分析，揭示其对极端天气形成过程的贡献。

1.2.3 暴雨成灾的临界条件及脆弱地区预测

第三个问题在第二问的基础上，进一步探讨降雨、地形和土地利用等因素在暴雨灾害形成中的交互作用。本问题的目标是确定暴雨成灾的临界条件，并结合降水和土地利用的历史时空演化特征，预测 2025 至 2035 年间中国境内暴雨灾害最脆弱的地区。

1.2.4 中国土地利用变化的特征与结构分析

土地利用变化反映了自然和人文地理要素的交汇点，如何利用前三个问题的分析结果，建立数学模型，描述中国土地利用的时空变化特征，并验证模型结果的准确性和有用性，是该问题的核心。

1.3 总体解题思路

本研究旨在探讨我国降水、土地利用变化及其对暴雨成灾风险的影响，采取多源异构数据融合的方法，从数据处理到模型构建，再到结果分析，形成一套系统的研究框架。首先，通过将不同类型的数据进行整理和初步处理，将像素坐标转换为地理空间坐标，以提取空间信息。这一过程不仅包括对降水量和土地利用数据的重采样和投影，还涉及对三十年来土地利用变化的时空特征进行深入分析。通过这一阶段的研究，本文能够直观展示区域内降水和土地利用的动态变化，为后续分析奠定基础。

在研究的第二阶段，基于提取的气温、降水、高程和土地利用等相关变量，构建决策树模型以探讨地形和气候等因素在暴雨形成过程中的相互作用。通过分析决策规则，识别出影响年平均降水量的主要因素，并进一步理解不同地理和气候条件下暴雨的形成机制。这一阶段的核心在于挖掘数据背后的规律，以量化的方式揭示气候因素如何通过交互作用影响降水量，从而引发极端天气事件。决策树的结果不仅提供了丰富的变量间关系，也为后续使用更复杂的模型如 XGBoost 算法进行深入分析打下了坚实基础。

最后，为了预测未来暴雨灾害脆弱性，结合 XGBoost 算法、ARIMA 模型和 SVR 算法，针对 2025 至 2035 年间的气候变化趋势及其对降雨和土地利用的影响进行综合预测。通过建立脆弱性指数，研究不同区域在面对极端天气时的应对能力，并通过土地类型的空间分布分析，进一步探讨不同土地利用模式对暴雨成灾风险的影响。这一部分的研究将提供更详细的空间分析，揭示土地利用变化如何在时间和空间上影响暴雨成灾的潜在风险。最终，通过标准差椭圆分析和有效性验证，构建国土空间资源开发的新思路，将为相关政策的制定提供科学依据，从而实现对我国自然灾害管理和资源可持续利用的全面优化。

通过以上各阶段的系统研究，本研究不仅提供了对降水、土地利用变化及暴雨成灾关系的深入理解，还为今后在相关领域的研究提供了新的方法论视角。本文希望通过多维度、多层次的分析，促进自然科学与社会经济学的交叉融合，为实现可持续发展目标提供有效的理论支撑和实践指导。

本文的总体解题思路如图 1.1 所示。




图 1.1 本文总体研究思路

二、本文数学符号说明

本文中出现的数学符号及相关含义说明如下表 2.1 所示。

表 2.1 本文涉及的数学符号及说明

<i>IDW</i>	反距离权重	<i>Rain</i>	平均降雨量
<i>Area_ratio</i>	土地覆被面积比例	<i>Entropy</i>	熵
<i>RMSE</i>	均方根误差	<i>MSE</i>	均方误差
<i>MAE</i>	平均绝对误差	<i>Rain_RollingMean_3</i>	降雨量三年滚动平均值
<i>Longitude</i>	经度	<i>Rain_YoY_Change</i>	年度降雨量变化率
<i>Latitude</i>	纬度	<i>Rain_RollingStd_3</i>	降雨量的滚动标准差
<i>Coverage_ratio</i>	用地覆盖率	<i>Rain_Cumulative</i>	累计降雨量
<i>Temperature</i>	年平均气温	<i>Rain_Trend_Slope</i>	降雨量的趋势斜率
<i>Extreme_Rain_Count</i>	极端降雨事件的次数	<i>Extreme_Rain_YoY_Change</i>	极端降雨事件的年际变化率
<i>XGBoost</i>	极端梯度提升树	<i>Temp_Coverage_Interaction</i>	温度与土地覆盖率的交互项
<i>GBDT</i>	梯度提升决策树	<i>CART</i>	决策树，classification and regression tree
<i>Slope</i>	坡度	<i>Elevation</i>	高程
<i>Geological Stability</i>	地质稳定性	<i>Vegetation Coverage</i>	植被覆盖率
<i>Land Use Change Rate</i>	土地利用变化率	<i>V_index</i>	脆弱性指数
<i>L_t</i>	<i>XGBoost</i> 中第 <i>t</i> 棵树的损失 <i>u</i> 函数	<i>Year</i>	年份变量

三、问题一求解及分析

3.1 问题描述

对于问题一，核心任务是分析 1990 至 2020 年间中国范围内降水量和土地利用/土地覆被类型的时空演化特征。给定的数据集包括降水量^[10]和五种土地覆被类型（耕地、林地、草地、灌木丛、湿地）的 GeoTIFF 图像文件^[11, 12]，每个像素的大小为 $0.5^{\circ} \times 0.5^{\circ}$ ，像素值在 0~1 之间，表示该覆被类型在像素中所占的面积比例。问题一的主要任务主要包括以下三个方面：

（1）对多源异构数据进行有效的预处理工作，以便于从中抽取得到有效的时空信息。问题一中的数据集包括但不限于 tif、nc、tfw 等格式的数据。在本部分中分别使用 Python、ArcGIS 等软件对于相关数据进行信息抽取和预处理工作，通过投影映射等方式，将各类像素坐标数据转化为地理空间中的真实坐标，以助力数据的预处理工作。

（2）在异构数据的基础上，针对抽取得到的数据进行适当的可视化工作，以直观准确地展示相关数据的时空变化情况。具体而言，研究将进行双三次卷积等方式对于离散的锯齿数据进行重采样工作，并进行投影并导出，展示降水、土地利用等信息在时空演进过程中的变化情况。同时，通过折线图等方式展示全国范围内，年平均降水量、耕地、林地、灌木、草地和湿地等土地的年变化情况。

（3）在数据处理、针对收集数据描述性统计的基础上，进一步针对两个变量（降水量、土地利用 / 土地覆被类型）中的描述性统计指标和图表进行分析，讨论 1990-2020 年间中国范围内降水和土地利用的时空演化特征并进行总结。

因此，基于所要完成的任务需求，在本部分构建如图 3.1 所示的技术框架：




图 3.1 问题一求解思路及技术框架

3.2 数据的预处理工作

如表 3.1 所示，TFW 文件使用六个参数来实现图像的仿射变换，以确保栅格图像能精确地对齐到地理坐标系中。这六个参数分别为：每个像素在 X 方向上的分辨率，描述为像素在 X 轴上的单位距离；图像在 X 方向上的旋转系数，用于表示图像相对于 X 轴的旋转角度；图像在 Y 方向上的旋转系数，用于表示图像相对于 Y 轴的旋转角度；每个像素在 Y

方向上的大小，通常表示为负值，代表图像在 Y 轴向下的单位距离；以及左上角像素的 X 坐标和 Y 坐标，表示该像素在地理坐标系中的具体位置。这些参数共同作用，确保在地理信息系统（GIS）中，栅格图像能够进行精确的地理校正并适当地对齐，从而实现与现实地理位置的一致性。

表 3.1 TFW 数据仿射变换说明

行号	数据说明
行 1	地图单元中的一个像素在 X 方向上的 X 分辨率尺度
行 2	旋转系数，用于描述图像在 X 方向上的旋转
行 3	旋转系数，用于描述图像在 Y 方向上的旋转
行 4	每个像素在 Y 方向上的大小（单位：地理坐标单位，通常为负值，表示图像 Y 轴向下）
行 5	左上角像素的 X 坐标（地理坐标）
行 6	左上角像素的 Y 坐标（地理坐标）

3.2.1 降水量数据的预处理




图 3.2 降水数据预处理的求解思路

降水量数据的求解思路如图 3.2 所示，在降水量数据预处理过程中，对名为 "CHM_PRE_0.25dg_19612022.nc" 的 NetCDF 格式数据集进行处理和深入分析。该数据集包含了长期的降水观测数据，处理目标是从中提取有价值的信息，并将其转化为更易于分析和可视化的格式。首先，需要从这个大型数据集中提取出基于年份的点要素降水数据。利

用 Python 软件中的 NetCDF4 库对日均降水的空间数据集进行初步的数据处理和预览。通过这一步骤将获得一个基于降水数据的空间矩阵。接下来，对导入的数据进行更深入的处理。遍历整个数据集，对每一天的降水数据进行累加，从而计算出年总降水量，这一过程涉及到大量的循环操作和数学计算。在得到年总降水量后，还需要计算多年的平均值，以获得年平均降水数据。这些计算结果将被导出，并进行矩阵到列表的转换，最终形成一个包含点要素的、基于年份的坐标降水数据集。这个数据集将包含每个空间点的地理坐标和对应的年均降水量。为了进一步提高数据的可用性和可视化效果，本文将利用地理信息系统软件 ArcGIS 进行后续处理。将先前得到的点要素数据集导入 ArcGIS。在 ArcGIS 中，应用反距离权重（IDW）插值方法，基于距离远近来分配权重，可将离散的点数据转换为连续的空间表面。通过这种插值，可以估算出没有直接观测数据的区域的降水量。最后，对插值后的数据进行空间投影，确保数据在地理空间上的准确性。将处理后的数据导出为 TIFF（Tagged Image File Format）格式的栅格文件。TIFF 格式是一种广泛使用的地理空间数据格式，它可以保存高分辨率的图像数据，同时保留地理参考信息，得到一个基于年份的、覆盖整个研究区域的空间降水数据集。

3.2.2 土地利用/土地覆被类型数据的预处理

如图 3.3 所示，数据预处理阶段主要聚焦于土地利用/土地覆被(LULC)数据的处理与整合。LULC 数据以 GeoTIFF 格式存储，每个文件代表一种特定的覆被类型，其像素值反映了该类型在对应像素中的比例分布。本研究涉及五种主要覆被类型：耕地（cropland）、森林（forest）、草地（grass）、灌木（shhru）和湿地（wetland）。对于 LULC 数据的处理主要包括以下步骤：首先，通过 ArcGIS 逐一读取各覆被类型的 GeoTIFF 文件，将不同覆被类型的数据在空间维度上进行叠加，以构建每个像素在不同时间点的完整 LULC 分布情况，这一步骤涉及多波段数据的整合和时间序列的构建。将处理后的 TIFF 格式文件导入 ArcGIS 软件进行进一步分析，空间投影变换：对栅格数据进行重投影，以确保数据符合空间分析的要求，利用 ArcGIS 的 Spatial 分析工具中的掩膜提取功能，剔除研究区域外的无效数据点，仅保留中国境内包含有效 LULC 信息的数据。使用 ArcGIS 的转换工具，将栅格数据转换为包含每个坐标点 LULC 信息的矢量数据。导出处理后的数据，为后续的时间序列分析和统计建模做准备。




图 3.3 土地利用数据预处理的求解思路

在完成数据提取后，本文进一步选择合适的统计指标来总结降水量和土地利用的时空分布特征。对于降水量，选取年平均降水量和降水极差这两种常见的气候学统计指标，以充分反映中国降水量的总体趋势及其波动性。对于土地利用/土地覆被，通过提取每类土地的面积占比、变化率指标来评估土地利用的变化程度，分析城市化进程、农田减少等趋势。


3.3 数据的描述性统计与分析总结

3.3.1 降水量数据的描述性统计与分析总结

(1) 年均降水量的空间分布

图 3.4 展示了我国 1990-2020 年间年降水量等线的空间分布及其变化趋势。从图中可

以明显观察到，我国年降水量的分布格局主要受地形因素的影响，呈现出明显的地域差异性。同时，在过去的 30 年间，北方地区湿度逐年上升，这一变化反映在 50mm、200mm、400mm 和 600mm 降水量等线均不同程度地向北偏移。具体而言，我国年降水量等线的分布与主要山脉系统呈现出高度的一致性。50mm 降水量等线分布受“贺兰山-祁连山-昆仑山”山系的显著影响。这条等线大致沿着这一山系走向延伸，反映了这些山脉对大气水汽输送的阻挡作用。200mm 降水量等线走向与“太行山-秦岭-大巴山-横断山脉”一线高度吻合，揭示了中国中部山地对降水分布的重要调控作用。400mm 降水量等线分布受到东南部的“武夷山-雪峰山”山系的影响，等线走势与这些山脉走向基本一致，反映了这些山脉对来自东南方向水汽的抬升作用。600mm 降水量等线主要位于广东、福建沿海地区，这条等线的分布与东南丘陵的走势高度一致，说明了沿海丘陵地形对局部降水分布的显著影响。这种由地形因素主导的降水分布格局，最终形成了我国东南地区降水丰沛，西北地区降水量相对较少降水量的整体空间特征。这种格局不仅反映了地形对降水的直接影响，也体现了大尺度大气环流系统（如季风）与复杂地形之间的相互作用。




注：本图基于自然资源部标准地图服务系统下载的标准地图制作，底图无修改，下同。

图 3.4 1990-2020 年年均降水量变化情况

值得注意的是，1990-2020 年间观察到的北方地区降水等线北移现象，可能暗示了气候变化对我国降水格局的潜在影响。这种变化趋势不仅对区域水资源分布产生影响，也可能对农业生产、生态系统平衡等方面带来深远影响，因此值得进一步深入研究。

（2）年均降水量的时序演化

如图 3.5 所示,1990-2020 年间,中国年均降水量波动起伏较大,从 1990 年的 166.62mm 增加到 2020 年的 177.59mm。这种逐渐增加的趋势可能与全球气候变化有关,具体原因可能包括全球变暖导致的大气含水量增加,降水量有所提升。东南季风强度和路径的改变,引发大气环流模式的变化,并进而对海洋-大气相互作用产生影响,如厄尔尼诺的南方涛动。此外,年均降水量存在着较为显著的年际波动,在 1998 年、2016 年经历了两次较高度程的上涨,当年年均降水量分别上升为 178.08mm、186.32mm。显著高值的出现可能与强厄尔尼诺事件有关。在 2011 年时年均降水量最低,当年仅为 142.51mm,当年降水量的走低可能与特定的大尺度气候模态(如拉尼娜事件)或区域环流异常相关。1990-2020 年间年均降水量极值的波动逐渐放缓,降水量极值波动逐渐放缓,反映了气候系统的稳定性增加,可能与大尺度气候振荡的特定阶段有关。同时,区域性气候调节机制的变化,如植被覆盖、土地利用变化等对局地水循环的影响,也有助于增强降水波动的稳定性。在 2009 年降水量的极值最小为 1190mm,在 1998 年降水量的极值最大为 2400mm。



(a) 1990-2020 年年均降水量变化情况

(b) 1990-2020 年降水量极值变化情况

图 3.5 1990-2020 年降水量时序变化情况

3.3.2 土地利用数据的描述性统计与分析总结

（1）土地覆被类型的空间分布

如图 3.6 所示,1990 年至 2019 年这三十年间,我国耕地利用的整体格局保持相对稳定。耕地利用高密度区域集中分布在东北平原、华北平原、长江中下游平原、江汉平原、关中平原以及四川盆地等几个主要的地理单元中,这种分布趋势反映了我国农业生产的地理特征和历史传统。从整体上看,我国耕地利用呈现出明显的南北差异和东西差异。北方地区的耕地利用程度普遍高于南方地区,这可能与北方广阔的平原地形以及适宜大规模机械化耕作的自然条件有关。同时,东部地区的耕地利用情况也明显优于西部地区,这一现象可能源于东部地区较为发达的经济水平、较高的人口密度以及相对完善的农业基础设施。

纵观这 30 年的时间跨度,虽然各区域的耕地利用情况呈现出一定的波动性,但总体而言,变化的幅度并不显著。这种相对稳定的状态可能反映了我国在保护耕地资源、维持粮食安全方面所做的持续努力,同时也可能暗示了进一步优化耕地利用结构和提高利用效率的潜在空间。

根据经济地理学的视角,我国耕地利用的空间分布格局反映了自然条件、区位优势、

经济发展水平、人口分布、历史文化传统以及政策导向等因素的综合影响。东部沿海地区具备优越的自然资源禀赋、便利的市场区位、较高的经济发展水平和充足的劳动力供给，加之完善的基础设施和先进的农业技术，形成了耕地高密度利用的格局。相比之下，西部地区受制于相对劣势的自然条件、远离主要市场的地理位置、较低的经济发展和稀疏的人口分布，其耕地利用程度相对较低。这种东西差异和南北差异不仅体现了我国复杂的地理环境和不均衡的经济发展状况，也反映了长期以来形成的农业文化传统和区域发展政策的影响。




图 3.6 1990-2019 年耕地用地空间变化情况

如图 3.7 所示，1990 年至 2019 年间，我国林地利用情况差异不大。其主要分布在小兴安岭一带、东南丘陵以及北部高原等区域，这种分布趋势反映了我国林地资源集中分布的地理特征。一方面，小兴安岭、东南丘陵和北部高原等地区拥有较为丰富和稳定的森林资源，自然条件十分适宜林木生长。另一方面，该地区未受到大规模的开发和利用，保留了较高的林地覆盖率。不仅如此，在过去的三十年中我国经济和社会发展迅速，却未对林地进行过度开发，这与我国近年来的生态保护政策密切相关，尤其是国家森林资源保护和恢复政策的实施。

根据经济地理学的视角，我国林地利用的空间分布格局反映了自然资源禀赋、气候条件、地形地貌等因素对土地利用的深刻影响。同时，经济地理学还强调人类活动与自然资源的协调发展。我国在林地利用上保持相对稳定，反映了政策调控、生态保护与经济发展的

之间的平衡。这种空间分布格局既体现了区域经济发展模式的差异，例如北部地区的林业资源开发与南方地区的农业经济互为补充，也形成了区域间资源与产业的分工与互补关系。

如图 3.8 所示，1990 年至 2019 年间，我国草地利用情况较为集中，其主要分布在西北地区。这种分布趋势反映了我国自然地理条件的区域性差异以及土地利用方式与自然环境的相互适应。一方面，西北地区气候干旱、降水稀少，更适合草地生态系统的存在与发展。另一方面，东部地区的气候条件则更有利于森林资源的生长。同时，这种趋势还揭示了我国在土地资源开发与利用过程中，依据不同区域的自然禀赋和生态特性，形成了因地制宜的土地利用格局，体现了生态环境保护与土地利用的协调发展。这一相对稳定的状态不仅体现了我国在保护草地资源、维护生态平衡方面所做的持续努力，也反映了国家在防治荒漠化和促进可持续发展方面的政策成效。同时，这种稳定性也意味着在草地资源的利用和管理中，已有相对成熟的机制来防止过度开发和草地退化。此外，这一现象也暗示了未来通过进一步提升草地利用效率和加强草原生态保护措施，仍有空间优化我国草地资源的可持续利用策略。




图 3.7 1990-2019 年林地用地空间变化情况

从经济地理学角度来看，草地利用格局受到区域经济发展水平、基础设施和政策导向的影响。国家实施的生态保护政策，如退耕还草和防治荒漠化政策，进一步促进了草地资源的保护与合理利用，突出了草地资源在我国不同区域中的经济功能和生态功能，揭示了

因地制宜的土地资源管理策略对区域可持续发展的重要性。

如图 3.9 所示，1990 年至 2019 年间，我国灌木用地情况分布较为均匀，其主要集中在北部高原与西北盆地。这种分布趋势反映了我国自然地理条件与气候特征对灌木植被生长的影响。由于北部高原和西北盆地气候干燥、降水量少，土壤较为贫瘠，这些地区不适合高大乔木生长，但适宜耐旱、耐贫瘠的灌木植被繁衍。因此，灌木用地在这些区域形成了较高的密度。此外，这一分布趋势还揭示了生态环境的区域适应性和人类土地利用方式的选择。灌木用地在这些地区的广泛分布，表明了这些区域在过去三十年中虽然经济开发活动有限，但保持了相对稳定的生态功能。同时，这也反映了国家在生态保护和荒漠化防治方面的努力，尤其是在干旱、半干旱地区通过植被恢复和灌木种植来减少水土流失，促进生态系统的可持续性。这一相对稳定的状态不仅体现了我国在生态保护与土地资源管理方面的持续努力，也反映了国家在荒漠化治理和水土保持等方面的政策成效。




图 3.8 1990-2019 年草地用地空间变化情况

从经济地理学角度来看，灌木用地格局也反映了自然条件与人类活动之间的相互作用，特别是在资源利用与区域经济发展中的重要角色。西北和北部高原地区经济开发水平相对较低，农业和工业活动较少，灌木植被的保护与利用在这些区域具有较强的生态和经济双重意义。一方面，这些地区通过保护灌木用地来维持生态平衡，减少生态退化的风险；另一方面，灌木资源的开发也为区域提供了经济机会，例如在中药材、灌木能源、生态旅

游等产业上的潜在应用。

如图 3.10 所示，1990 年至 2019 年间，我国湿地用地情况变化不大，其主要集中在大兴安岭与青藏高原附近。这种分布趋势反映了我国湿地资源的自然分布规律及其与气候、地形的密切关系以及不同区域的生态功能和地理特征。大兴安岭湿地在调节区域水循环、保护生物多样性等方面发挥着关键作用，青藏高原湿地则在全球气候调节和高原生态环境保护中具有独特的意义。这种相对稳定的湿地分布情况反映了我国近年来在湿地保护方面的成效，通过实施湿地保护政策与生态修复项目，确保了湿地的生态功能得以维持。湿地作为重要的生态系统，在调节气候、涵养水源、维持生物多样性方面发挥着不可替代的作用。通过一系列湿地保护政策的实施，如湿地恢复、退化湿地治理和自然保护区建设，我国有效遏制了湿地面积的进一步减少。




图 3.9 1990-2019 年灌木用地空间变化情况

湿地资源的分布呈现出明显的空间异质性，主要集中在人口密度较低、经济活动相对不发达的地区。这种分布格局反映了经济发展与自然资源保护之间的权衡关系。经济发展过程中，资源利用呈现出明显的空间选择性。相较于其他土地类型，湿地的经济开发往往面临更高的技术门槛和环境成本，这在一定程度上抑制了对湿地的大规模开发。区域经济

发展的不平衡为湿地保护提供了机遇。经济欠发达地区的湿地资源由于开发压力较小，得以保留其自然形态。国家在湿地资源开发与保护方面，维持着较为审慎的态度。




图 3.10 1990-2019 年湿地用地空间变化情况

(2) 土地覆被类型的时序演化特征

如图 3.11 所示，我国耕地面积在全国的占比逐渐走低，并在 2006 年前后开始回升。在 1990-2006 年间，我国耕地面积占全面面积由峰值时期的 21.51%下落到 2006 年时的 20.51%，并在随后开始回升，到 2019 年时，回升为 21.04%。与之相对，我国耕地面积占比的极值则经历了“先增后减”的相反趋势，耕地面积占比极值从 1990 年起不断攀升，到 2007 年时达到峰值 93.65%，随后出现波动，在 2012 年时触底，极值占比为 92.50%。

我国耕地面积占比的变化趋势反映了经济发展与资源保护之间的动态平衡关系。1990 年至 2006 年间，中国快速的城市化和工业化进程导致耕地面积占比下降。在 2006 年后的回升趋势主要归因于严格的耕地保护政策实施，特别是“十八亿亩耕地红线”的制定，促使各地加强土地整理和复垦工作，有效遏制了耕地减少的趋势。同时，农业现代化和土地利用效率的提高也在一定程度上缓解了对新增耕地的需求。耕地面积占比极值的“先增后减”趋势则反映土地利用结构的优化过程，从初期的大规模开垦到后期的质量导向型管理。体

现了我国在经济快速发展中对耕地资源保护的重视，也凸显了未来需要继续关注耕地质量提升和可持续利用的重要性。




图 3.11 1990-2019 年耕地面积时序变化





图 3.12 1990-2019 年林地面积时序变化

如图 3.12 所示，在 1990-2019 年间，我国林地面积占比均值呈现上升趋势，林地面积占比极值先上升后下降，随后又呈现上升趋势，最终趋于平缓。一方面，我国林地面积占比均值总体呈现增长趋势，反映出国家在生态保护和环境修复方面的政策成效。说明我国通过实施一系列植树造林、退耕还林等政策措施，积极推动了森林资源的恢复与扩展。另一方面，林地面积占比极值“先上升后下降，随后又趋于平缓”的波动趋势，表明不同区域的林地恢复进展存在差异。在早期，大规模植树造林活动使得部分区域的林地面积快速增长，极值上升至峰值。受到自然条件、经济开发等因素的影响，导致林地增长遇到瓶颈，占比极值下降。随着国家进一步强化生态保护政策，林地占比极值再次上升，并最终趋于平缓，说明林地资源在这一时期趋于稳定发展。


如图 3.13 所示，在 1990-2019 年间，我国草地面积占比均值呈现下降趋势，草地面积占比极值未出现明显波动的情况。草地面积占比均值下降意味着我国草地资源在此期间逐渐减少，主要是受到多种因素的影响，例如农业扩展、城市化进程、工业发展以及土地开

发等。这一现象表明, 草地资源在部分地区逐步被其他土地利用形式所取代, 尤其是在经济开发较为活跃的区域, 草地资源面临一定的压力。与此同时, 草地面积占比极值未出现明显波动, 说明在某些地区, 草地面积相对稳定, 未受到较大规模的开发或破坏。其主要是因为该区域的草地资源受自然地理条件或政策保护的影响较少开发, 保持了相对稳定的生态功能。



(a)1990-2019 年草地面积占比均值情况 变化 (b)1990-2019 年草地面积占比极值情况 变化

图 3.13 1990-2019 年草地面积时序变化




(a)1990-2019 年灌木面积占比均值情况 变化 (b)1990-2019 年灌木面积占比极值情况 变化

图 3.14 1990-2019 年灌木面积时序变化

如图 3.14 所示, 在 1990-2019 年间, 我国灌木面积占比均值呈现下降趋势, 灌木面积占比极值未出现明显波动的情况。灌木面积占比均值下降趋势表明灌木资源在此期间有所减少。这说明在经济开发较为集中的区域部分灌木用地被大力开发, 灌木植被遭到破坏。此外, 随着生态保护政策逐渐向森林、湿地等更高生态价值的植被类型倾斜, 灌木地的保护和恢复可能没有得到同等的重视, 导致灌木面积持续减少。此外, 灌木面积占比极值未出现明显波动的情况说明, 某些地区的生态系统相对封闭, 经济发展具有一定的局限性, 灌木用地受到的干扰较小, 面积变化不大。

如下图 3.15 所示,在 1990-2019 年间,我国湿地面积占比均值呈现缓慢下降趋势,湿地面积占比极值急速下降后趋于稳定。湿地面积占比均值的缓慢下降反映出湿地资源在此

期间逐步减少，尽管幅度不大，但呈现出持续下滑的趋势。这说明土地扩张和城市化活动影响了湿地覆被情况，导致湿地面积占比均值下降。此外，气候变化和水资源利用的变化也可能对湿地面积产生一定影响。同时，湿地面积占比极值的急速下降后趋于稳定现象，表明由于过度开发和生态环境的破坏，湿地资源在前期经历了大幅度的减少。但随着国家对湿地保护的加强，如自然保护区的设立、湿地修复工程的实施，湿地占比极值趋于稳定，反映出湿地得到了较好的保护和恢复。



(a)1990-2019 年湿地面积占比均值情况 (b)1990-2019 年湿地面积占比极值情况
变化 变化

图 3.15 1990-2019 年湿地面积时序变化

3.4 本章小结

在本章中，利用 Python 和 ArcGIS 等工具对多源异构数据（tif、nc、tfw 等格式）进行处理，将像素坐标转化为地理空间坐标，提取空间中的信息；进一步，通过双三次卷积等方法对离散数据进行重采样和投影，直观展示降水和土地利用的时空变化，并使用折线图等方式呈现全国范围内年平均降水量和各类土地覆被的年度变化；最后，基于可视化结果和描述性统计结果，深入分析并总结 30 年间的变化趋势和特点，得出如下结论：

（1）我国年平均降水量分布呈现明显的地域差异，这主要受到山系分布和山脉走势的显著影响。东南沿海地区降水丰沛，而西北地区降水相对稀少。中国地势上整体呈现三级阶梯分布，从东南向西北逐渐升高，东部沿海地区地势不高，有利于水汽输送，西部地区深处内陆，高原和山地阻碍了来自海洋的暖湿气流，导致降水量逐渐减少。此外，我国降水量等线逐渐北移，降水潜力逐渐上升，极值波动放缓，年均降水趋于稳定。随着全球气候逐渐变暖，气温升高导致大气持水能力增强，加剧水循环过程，增加降水潜力，降水带逐渐向北扩展。同时，年均降水量的极值波动逐渐放缓，可能与厄尔尼诺-南方涛动（ENSO）循环的频率和强度变化有关，ENSO 事件的发生逐渐规律和更加温和，导致了年际降水波动的逐渐稳定。

（2）在我国土地利用的空间分布上，耕地用地主要集中分布于东北平原、华北平原、长江中下游平原和四川盆地等区域；林地用地主要分布于外兴安岭、东南丘陵和云贵高原、秦岭等区域；草地用地主要分布于西北地区的内蒙古高原、青藏高原、天山山脉等地区；灌木丛用地主要分布于内蒙古高原和东南丘陵区域；湿地用地主要分布于东北平原、青藏高原等地区。通过时序分布规律可以发现，在过去的 30 年间，除林地用地外，我国的耕地、草地、灌丛和湿地用地面积均在不同程度上缩减。这种变化趋势反映了城市化、工业化进程加快，以及国家生态政策实施的影响。同时，气候变化、人口压力和技术进步等因素也在塑造土地利用格局。

四、问题二求解及分析

4.1 问题描述

问题 2 要求建立数学模型，定量分析地形与气候相互作用在暴雨极端天气形成过程中的作用机制，解决这一问题需要深入理解地形和气候因素如何共同影响极端天气事件的作用和强度。本文采用机器学习模型从历史数据中学习地形与气候因素对极端天气的影响规律，捕捉复杂的非线性关系。

首先，变量选择与数据整合是模型构建的重要环节，本问题涉及的自变量包括地形特征和气候因素两方面，因变量则是极端天气事件的指标，即强降雨量。通过 GIS 技术，将地形数据与气象数据进行空间叠加和匹配，确保数据的空间一致性和精确性。自变量一共包括土地覆被类型、土地利用面积占比、近地表温度、年份及经纬度位置。因变量为降水量。

其次，对模型进行构建与训练。本文将数据分为训练集和测试集，其中 70% 的数据用于拟合决策树模型，剩下 30% 数据用于测试模型构建的有效性与准确性。在训练过程中，本文通过统计 R^2 、均方根误差 RMSE、平均绝对误差 MAE 等指标来评估决策树模型预测性能。模型验证与评估是确保模型可靠性的关键步骤^[13]。通过与实际观测数据的对比，检验模型的预测能力和准确性。最后本文结合气候变化背景，构建了地形因素、气候因素与降雨的决策树模型，分别探讨了不同土地覆被类型下地形-气候的相互作用，通过将降雨量规模高于 300 毫米的地区设置为暴雨极端天气地区，以 CART 决策树模型的分类结果探讨地形与气候因素在极端天气事件中的互动机制，为未来极端天气的预测和防灾减灾提供科学依据。因此，基于所要完成的任务需求，在本部分构建如下图 4.1 所示的技术框架：




图 4.1 问题二求解思路及技术框架

4.2 问题求解

4.2.1 数据准备与整合

在极端天气事件的研究中，数据的整合是模型构建的关键环节。为探索地形与气候相

互作用对极端天气形成过程的影响，本文首先将土地覆盖比例、近地表气温和降水量三个数据源整合到同一个数据集中。这一过程不仅确保了数据的一致性，还为后续的机器学习建模提供了统一的输入格式。

数据整合的第一步是处理土地覆盖比例数据。本文使用的土地覆盖数据集包含了不同年份、不同地理位置（以经纬度表示）的五种主要土地类型：耕地（cropland）、林地（forest）、草地（grassland）、灌木丛（shrubland）和湿地（wetland）。每个像素的值范围在 0 到 1 之间，表示该像素内某种土地类型所占的比例。该数据以 $0.5^{\circ} \times 0.5^{\circ}$ 的空间分辨率进行采集，本文通过读取 GeoTIFF 图像文件并解析对应的像素值，将每个像素点的土地覆盖信息提取出来。

为了进一步分析，本文对经纬度进行取整处理。例如，经纬度值 72.47499999 和 72.97599999 都被归为经度 72，确保不同数据集的空间分辨率保持一致。在进行取整后，本文对覆盖在相同经纬度的多个像素值进行了平均化处理，计算出每个整数经纬度点的土地类型覆盖比例。通过这种方式，本文将空间上的细致分辨率统一为整数经纬度的网格，使得不同地理数据更便于对齐和比较。

在土地覆盖数据处理完毕后，本文开始处理气温和降水量数据。气温数据反映了近地表的温度变化，通常以日或月为单位进行记录。降水量数据则是极端天气事件中最直接的指标，本文选用的降水量数据同样具有较高的时间和空间分辨率。为了将气温和降水量数据与土地覆盖数据匹配，本文首先将气温和降水量数据按经纬度进行重新取整和空间插值处理。这一过程中，本文通过插值算法将气温和降水量的高分辨率数据转换为与土地覆盖数据相同的 $0.5^{\circ} \times 0.5^{\circ}$ 分辨率网格，从而在每个经纬度点上获得统一的土地覆盖、气温和降水量信息。

经过这一系列的数据处理步骤，本文成功构建了一个包含经纬度、土地覆盖比例、气温和降水量的综合数据集。每个经纬度点都记录了该点在不同年份的土地覆盖类型及其比例、近地表气温和降水量的时空变化信息。此数据集不仅覆盖了中国广阔的地理区域，还在时间上涵盖了从 1990 年到 2019 年的历史数据，反映了土地利用变化与气候波动的长期趋势。本文将基于这一整合数据集进行后续的机器学习建模，以探讨地形和气候之间的复杂相互作用，以及它们在极端天气事件形成中的关键作用。

4.2.2 变量准备

在数据整合完成后，本文的下一步是变量提取与数据合并。这一步的主要任务是从土地覆盖、气温和降水量数据中提取出关键的自变量和因变量，并将它们整合为一个可供机器学习模型使用的统一数据集。本文的自变量包括年份、土地类型、覆盖面积比例和气温，而因变量则是降水量。

首先，本文从整合的数据集中提取土地类型及其覆盖面积比例。每个经纬度点对应多个时间段的土地覆盖数据，这些数据包含五种主要土地类型：耕地、林地、草地、灌木丛和湿地。本文将每个像素点的土地覆盖比例作为自变量，代表该地块不同年份的土地利用情况。这一步骤的目标是为每个经纬度点创建一个包含土地类型和其覆盖比例的信息矩阵，使其与其他变量（如气温、降水量）共同组成特征向量。接下来，本文提取气温数据。近地表气温数据是另一个重要的自变量，反映了不同年份、不同经纬度点的温度变化情况。本文对气温数据按照时间（年份）和空间（经纬度）进行处理，确保每个土地覆盖数据点都有相应的气温记录。在同样的经纬度网格中，本文通过空间插值的方式确保气温数据与土地覆盖数据对齐，并且保证数据之间的时间一致性。这样，气温变化就能够与土地利用的动态变化相结合，为后续的建模提供更丰富的信息。最后，本文将降水量数据作为因变量进行提取。降水量是极端天气形成过程中的关键指标，因此本文以每个经纬度点的降水量作为因变量，用以预测地形-气候相互作用对降水量的影响。与气温数据的处理方法类似，

本文确保降水量数据与土地覆盖数据和气温数据在时间和空间上的一致性。通过将多个年份、多个经纬度点的降水数据与对应的土地利用和气温数据对齐，本文构建了一个完整的训练数据集。

本文将各个变量年份、土地类型、覆盖面积比例、气温、降水量，同时结合经纬度坐标，整合为一个综合数据集，其中每一行代表某一年份、某一经纬度点的土地类型和比例、气温以及降水量。这些数据将作为输入特征用于后续的机器学习模型，通过模型分析地形-气候相互作用对降水量和极端天气的影响。相关的变量符号及含义说明如表 4.1 所示。

表 4.1 变量含义与单位

特征变量	符号	单位
降水量	<i>Rain</i>	毫米
土地覆盖比例	<i>Coverage_ratio</i>	%
土地类型	<i>Land_type</i>	无
近地表气温	<i>Temperature</i>	摄氏度
经度坐标	<i>Longitude</i>	度
维度坐标	<i>Latitude</i>	度
年份控制变量	<i>Year</i>	无

4.2.3 数据描述与相关性分析

其中，降水量的样本数据大致趋势如图 4.2 所示。由图可知，我国降水量呈现出较为明显的周期性变化特点。具体而言，降水量在每个时间周期内由低到高再重新走低，形成了规律性的波动。在每个降水周期的波峰处，降水量达到最大值随后迅速下降，回到相对稳定的低值状态。尽管各个降水周期的峰值存在一定的波动，但在总体上仍呈现出一定的规律性，并未出现极端的异常值，从较长的时间周期来看，峰值的变化情况是逐渐减小的。此外，在每个周期内降水的变化波动情况具有相同的时间间隔，降水量的变化具有明显的规律性和周期性。




图 4.2 降水量的样本值描述

通过表 4.2 可以发现，中国地理样本区域的经度（longitude）范围在 75.000 到 133.000 之间，平均值为 103.419，标准差 13.892；纬度范围（latitude）在 22.000 到 53.000 之间，平均值为 36.376，标准差 6.723。经纬度数据显示出样本区域跨越了多个地带，涵盖了中国的广泛地理区域。用地覆盖率（Coverage_ratio）的平均值为 0.200，标准差为 0.254，最低值为 0.000，最高值达到 1.000。这表明样本区域内的地表覆盖情况较为分散，其中一些区域可能有人类密集活动，而其他区域则保持自然状态。年平均气温（Temperature）均值为 -8.399℃，标准差为 10.398℃，最低温度为 -44.414℃，最高温度为 20.623℃。这一数据展示了中国区域整体气温较低，且存在较大范围的温度变动，部分区域甚至出现极端低温。中国年平均降雨量（Rain）的平均值为 161.625 毫米，标准差为 143.028 毫米，最低降雨量为 2.000 毫米，最高降雨量高达 1205.875 毫米。降雨量数据同样表现出较大的变动范围，表明中国各个地区的降水情况存在显著差异。统计数据的差异显示了中国不同经纬度区域

在地形和气候上的广泛变异性，还为进一步研究两者之间的关系提供了坚实的基础。

表 4.2 地形-气候相关变量描述性统计结果

统计量	<i>longitude</i>	<i>latitude</i>	<i>Coverage_ratio</i>	<i>Temperature</i>	<i>Rain</i>
count	122960.000	122960.000	122960.000	122960.000	122960.000
mean	103.419	36.376	0.200	-8.399	161.625
std	13.892	6.723	0.254	10.398	143.028
min	75.000	22.000	0.000	-44.414	2.000
25%	91.000	31.000	0.005	-15.660	49.313
50%	104.000	36.000	0.095	-9.398	124.688
75%	115.000	41.000	0.296	-0.855	223.641
max	133.000	53.000	1.000	20.623	1205.875

通过对 Rain（降水量）、Coverage_ratio（土地覆盖比例）和 Temperature（气温）三者进行相关性分析，绘制变量间的相关性热力图如图 4.3 所示。发现 Rain 与 Temperature 的相关性相关系数为 0.694，这表明降水量与气温之间有较强的正相关关系，说明随着气温的升高，降水量也可能增加。这种正相关性可能反映了气候变化和气温升高对降水量的影响。例如，气温升高导致更多的水蒸发到大气中，从而形成更多的降雨，这与全球变暖背景下观测到的现象一致。特别是在某些地区，高温可能伴随着强对流天气，从而导致更频繁的暴雨。




图 4.3 变量间的相关性热力图结果

如图 4.4 所示，根据中国地形数字高程图（1km）可以发现，中国整体的地形特征可以归纳为“三阶梯”分布，即西高东低。西部以青藏高原为主，地势高峻，多高山和高原；中部为第二阶梯，包括内蒙古高原、黄土高原和云贵高原等地，地势逐渐降低；东部为第三阶梯，主要是广阔的平原和丘陵，如华北平原、长江中下游平原和东北平原。这样的地形分布不仅决定了河流的流向和水系结构，还对全国的自然环境产生深远影响。西高东低的地势导致了气流的运动模式，使东部地区受季风影响明显，降水较为充足，而西部地区相对干燥。同时，高原和山地区域的气温一般较低，气候寒冷，而东部平原和丘陵地区气候相对温暖湿润，适合农业生产。整体地形特征显著地影响了中国的生态系统、农业布局、气象环境以及资源分布。





图 4.4 中国地形数字高程图(1km)

如图 4.5 所示, 1990-2018 年间, 中国年均气温呈现显著上升趋势, 这一变化在空间分布上表现为气温带的明显北移和扩张。具体而言, -4°C 以下的低温带面积逐渐缩小并向北退缩, 而 2°C - 8°C 、 8°C - 14°C 和 14°C 以上的温暖气温带则不断扩大并向北推进。这种变化模式主要由全球气候变暖驱动, 同时受到区域气候特征、人类活动和自然气候变率等多重因素的综合影响。

随着时间推移, 气温带分布的变化愈发明显。到 2018 年, 2°C - 8°C 气温带已经扩展至山东半岛南部、黄淮海平原、江汉平原和四川盆地等地区; 8°C - 14°C 气温带的范围进一步扩大, 囊括了四川盆地、福建南部、湖南南部、广东、广西和云南的大部分地区; 14°C 以上的高温带也显著增加, 覆盖了整个海南省及珠江流域的大部分区域。这种气温带的迁移和扩张不仅反映了全球变暖对中国气候系统的深刻影响, 也预示着区域生态环境、农业生产格局和人类生活方式可能面临的重大变化。大气中温室气体浓度的持续增加导致全球平均气温上升; 其次, 中国快速的工业化和城市化进程加剧了局部地区的热岛效应; 再者, 土地利用方式的改变 (如森林砍伤、农田扩张等) 也影响了地表能量平衡; 此外, 自然气候系统的内部变率 (如厄尔尼诺-南方涛动、北极涛动等) 也在一定程度上调节着区域气温的年际和年代际变化。

这种气温分布的变化对中国的生态系统、农业生产和社会经济发展具有深远影响。例如, 它可能导致某些物种分布范围的北移或缩小, 农作物种植带的调整, 以及水资源分布的改变。同时, 这也为中国制定适应和缓解气候变化的政策和战略提供了重要的科学依据。因此, 持续监测和深入研究这一气候变化趋势, 对于中国乃至全球的可持续发展具有重要的现实意义和长远价值。



图例：—— 国界线 —— 省界 —— 海岸线 ■ $\leq -16^{\circ}\text{C}$ ■ $-16^{\circ}\text{C} \sim -10^{\circ}\text{C}$ ■ $-10^{\circ}\text{C} \sim -4^{\circ}\text{C}$
 ■ $-4^{\circ}\text{C} \sim 2^{\circ}\text{C}$ ■ $2^{\circ}\text{C} \sim 8^{\circ}\text{C}$ ■ $8^{\circ}\text{C} \sim 14^{\circ}\text{C}$ ■ $> 14^{\circ}\text{C}$

图 4.5 1990-2018 年中国年均气温变化情况

4.2.4 决策树建模

决策树是一种广泛应用于分类和回归任务的监督学习算法^[14]。其基本思想是通过递归地将数据集划分成更小的子集，直到子集足够“纯净”为止。根据任务的不同，决策树可以分为分类树（CART 分类）和回归树（CART 回归）^[15]。

（1）分类树原理与建模流程

分类树的分类目标是通过数据划分，使每个叶节点中的样本类别尽量一致，从而提高子集的纯度，常用的分裂标准包括信息增益和基尼系数等^[16]。其中，信息增益是基于熵（Entropy）来衡量分裂前后不确定性的减少，信息增益越大，分裂后的子集越纯。基尼系数则是用于衡量数据集中不纯的程度，越小表示越纯。分类树用于处理分类任务，其目标是将数据集按某些特征进行划分，使得每个叶节点中的样本尽可能属于同一类别。

首先选择分裂特征，通过计算每个特征的信息增益或基尼系数，选择最优特征进行分裂；接着对子集递归进行分裂，直到满足停止条件，如达到最大树深度或每个节点的样本数小于设定的最小值；当递归达到终止条件时，生成叶节点并赋予对应的类别标签；最后，可以通过剪枝减少过拟合的风险，剪枝方式包括提前停止树的生长或进行后剪枝。计算过

程如下：

$$IG(D, A) = H(D) - \sum_{v \in \text{Values}(A)} \frac{|D_v|}{|D|} H(D_v) \quad (4-1)$$

$$Gini(D) = 1 - \sum_{i=1}^k p_i^2 \quad (4-2)$$

式中， p_i 是类别 i 的概率， k 为类别总数。 $H(D)$ 为当前数据集的熵，定义为：

$$H(D) = - \sum_{i=1}^k p_i \log(p_i) \quad (4-3)$$

（2）回归树原理与建模流程

回归树的目标是通过按特征划分数据集，使每个叶节点中的目标值相对稳定，通常以叶节点中样本的均值作为预测值，分裂时常用方差减少（公式(4-5)）或均方误差（mean-square error, MSE）（公式(4-6)）作为标准，以最大化子集方差的减少。回归树用于处理回归任务时是将数据划分成多个子集，使得每个叶节点中的目标值尽量一致，通常用均方误差或方差减少来作为划分依据^[17]。

首先通过计算各特征的方差减少，选择方差减少最大的特征进行分裂；接着对子集递归进行分裂，直到满足停止条件，如节点样本数达到最小值或节点方差较小；当递归终止时，生成叶节点，并将节点中样本目标值的均值作为预测值；最后，可以通过剪枝来减少模型复杂度，防止过拟合。计算过程如下：

$$\Delta Var = Var(D) - \left(\frac{|D_L|}{|D|} Var(D_L) + \frac{|D_R|}{|D|} Var(D_R) \right) \quad (4-4)$$

式中，其中， D_L 和 D_R 分别表示分裂后的左右子集， $Var(D)$ 表示数据集 D 的方差，定义为：

$$Var(D) = \frac{1}{D} \sum_{i=1}^{|D|} (y_i - \bar{y})^2 \quad (4-5)$$

其中， $\bar{y}$ 为 D 中预测目标值的均值。

$$MSE = \frac{1}{|D|} \sum_{i=1}^{|D|} (y_i - \hat{y})^2 \quad (4-6)$$

其中， $\hat{y}$ 为预测目标值。

4.2.5 建模结果

（1）决策树模型拟合效果

图 4.6 为基于决策树模型的预测结果，其中横轴代表真实值，纵轴代表预测值，散点越接近斜角线，说明模型的预测效果越好。根据预测结果可以发现，大部分散点分布在靠近斜对角线直线的区域，说明模型在较大程度上捕捉得到了数据的真是趋势和规律，决策树模型在预测过程中具有较高精度，但是也存在部分散点偏离了斜对角线，表现出一定的预测误差。这可能是由于数据的噪声、异常值或模型在处理某些复杂非线性关系时的局限所导致的。




图 4.6 决策树模型预测效果

(2) 决策树分析

图 4.7 为全样本的决策树结果，从图可以看出，对年平均降水量起主导作用的变量主要包括年平均气温和当地坐标。其中，年平均气温较高 ($> -0.473^{\circ}\text{C}$) 的低纬度 (≤ 31.5) 东部地区 (经度 > 108.5) 取得了最高水平的年平均降雨量 (446.328mm)。这表明在年平均气温较高的低纬度东部区域，也更容易取得较高水平的年平均降水量。




图 4.7 决策树效果图

较高的年平均气温显著促进了水分蒸发和大气水汽含量的增加，从而有利于降水的形成。低纬度地区由于接收更多的太阳辐射，整体气温更高，蒸发和对流活动更强，同样有助于降水的增加。东部地区靠近海洋，水汽来源丰富，受海洋性气候和东亚季风影响显著，带来了充沛的湿润空气。这三者的交互作用使得年平均气温较高、纬度较低且位于东部地区的区域更容易获得高水平的年均降水量，显示出气温、纬度和经度的共同作用对降水分布的复杂影响。

(3) 异质性地形下的决策树分析

为充分讨论地形因素与气候因素之间的交互关系及其对暴雨形成的作用原理，本文将土地的五种类型作为异质性情境变量，探讨五种类型下地形-气候的交互决策影响，构建不同情境下的决策树。所构建的决策树模型均通过网格算法寻得最有参数，通过 70%训练集和 30%测试集的数据划分，其数据基本情况如表 4.3 所示。

表 4.3 异质性地形下的决策树数据描述

	训练集	测试集
总样本量	(74713, 5)	(32024, 5)
模型一 forests 数据	(17214, 5)	(7378, 5)
模型二 grass 数据	(13514, 5)	(5792, 5)
模型三 cropland 数据	(11916, 5)	(5108, 5)
模型四 cropland 数据	(15335, 5)	(6573, 5)
模型五 wetland 数据	(16734, 5)	(7173, 5)

为了便于可视化，本文展示最大树深度 $\text{max_depth}=3$ 的可视化效果，分别得到如图 4.8 至图 4.12 所示的决策树效果。

在林地（forests）类土地覆被类型中，年均降雨量主要受到气温、所处区域的经纬度和林地覆盖率等因素的影响。在年平均气温较低（ $\leq -0.740^{\circ}\text{C}$ ）、林地覆盖率较低（ ≤ 0.000 ）的林地覆被地区中，当地区所处维度较低（ ≤ 34.5 ）时，年均降水量更高，为 102.97mm 。当地区维度位置较高时，年均降水量相对较低，仅为 49.21mm 。在年平均气温较低（ ≤ -0.740 ），林地覆盖率较低（ ≤ 0.000 ）的林地覆被地区中，较低纬度同样能够获得更多的年平均降水（ 215.73mm ）。在年平均气温较高（ $> -0.740^{\circ}\text{C}$ ）的低纬度地区（ ≤ 31.5 ），相对也更容易获得更多的年均降水量，当地区位于东部沿海区域（经度 > 108.5 ）时，更容易获得更高的年平均降水量（ 443.03mm ）。因此，结合图 4.8 和数据分析可以发现，中国林地年均降雨量的分布呈现出复杂的空间模式，主要受到气温、林地覆盖率和地理位置等多重因素的综合影响。年平均气温较高（ $> -0.740^{\circ}\text{C}$ ）、纬度较低（ ≤ 31.5 ）的地区，尤其是东部沿海区域（经度 > 108.5 ），往往拥有更高的年均降水量。较高的气温增强了大气的水汽容纳和输送能力；低纬度地区接收更多太阳辐射，促进了对流活动；而东部沿海地区则得益于充足的水汽来源和显著的季风影响。虽然数据中林地覆盖率的直接影响不明显，但理论上较高的森林覆盖通过蒸腾作用和改变地表特性也能促进降水。这些因素的相互作用形成了一个复杂的系统，共同决定了林地降水的空间分布特征。




图 4.8 林地 forest 的决策树结果

在草地（grass）类土地覆被类型中，年均降雨量主要受到年平均气温和经纬度等因素的影响。在年平均气温较低（ $\leq -0.48^{\circ}\text{C}$ ）的区域，同样不易取得更高的年平均降水量。在低温区域，年均降水量还受到经度的影响，在东部地区（经度 >95.5 ）更容易比内陆区域获得更高的年降水量，在西部内陆地区（经度 ≤ 95.5 ），低纬度（ ≤ 33.5 ）区域同样更容易获得较高水平的年降水量（111.95mm）。在高温的草地覆被类型中，较低纬度的东部区域同样比高纬度的西部内陆地区更容易获得较高水平的年降水量。因此，结合图 4.9 和数据分析可以发现，较高气温（ $> -0.48^{\circ}\text{C}$ ）、东部地区（经度 >95.5 ）和低纬度（ ≤ 33.5 ）区域往往拥有更高的年均降水量。较高的气温促进水分蒸发和大气对流，增加大气水汽含量；东部地区靠近海洋，受季风影响显著，水汽来源充足；低纬度地区接收更多太阳辐射，有利于降水形成。这些因素的相互作用形成了一个复杂的系统，其中东部低纬度地区由于同时具备有利条件，形成了最适宜降水的环境。值得注意的是，即使在低温区域，东部地区仍比西部获得更多降水，突显了地理位置的重要性。




图 4.9 草地 grass 的决策树结果

在耕地（cropland）类土地覆被类型中，年均降雨量主要受到覆盖率和年平均气温等因素的影响。在年平均气温较低（ $\leq -0.51^{\circ}\text{C}$ ）的区域，同样不易取得更高水平的年平均降水量。在低温区域，耕地覆盖面积更高（ >0.000 ）的区域更容易取得更高水平的年平均降水量，年平均气温较高的区域，更容易取得较高水平的年平均降水量。在年平均气温较高（ $> -0.51^{\circ}\text{C}$ ）的区域，年均降雨量还受到耕地覆盖率和年平均气温的影响，在耕地覆盖率低（ ≤ 0.443 ）的区域，反而更容易取得较高水平的年均降雨量。同时，年平均气温更高的区域能够取得更高水平的年平均降雨量。结合图 4.10 和数据分析结果，较高气温（ $> -0.51^{\circ}\text{C}$ ）的地区通常拥有更多的降水，这主要是由于高温促进水分蒸发、增加大气水汽含量，并有助于大气对流。然而，耕地覆盖率的影响则呈现非线性特征：在低温区域（ $\leq -0.51^{\circ}\text{C}$ ），高耕地覆盖率（ >0.000 ）与更多降水相关，可能是因为农业活动改变了地表特性并增加局地水汽；而在高温区域，低耕地覆盖率（ ≤ 0.443 ）反而与更多降水相关，这可能与自然植被或水体的保留有关。气温和耕地覆盖率的交互作用进一步复杂化了这一关系，表明在不同温度条件下，土地利用对降水的影响可能发生变化。




图 4.10 耕地 cropland 的决策树结果

在灌木丛 (shrub) 类土地覆被类型中, 年均降雨量主要受到年平均气温、灌木丛覆盖率和纬度位置的影响。在年平均气温较低 ($\leq -0.51^{\circ}\text{C}$) 的灌木丛区域, 不易取得更高水平的年平均降水量。进一步, 在灌木丛覆盖率较高 (> 0.000) 的区域, 年平均降水量相对更高; 同时, 年均降水量还受到年平均气温的影响当灌木丛覆盖率较高 (> 0.000) 时, 年平均气温较高的区域 ($> -3.32^{\circ}\text{C}$) 更容易取得高水平的年平均降水量; 而当灌木丛覆盖率相对较低时 (≤ 0.000), 年平均气温较高的区域 ($> -29.88^{\circ}\text{C}$) 不易取得高水平的年平均降水量。此外, 当年平均气温较高时 ($> 0.51^{\circ}\text{C}$), 灌木丛覆盖率较高 (> 0.4429) 的区域不易取得较高水平的年平均降水量。结合图 4.11 和数据分析结果, 可以发现, 较高的气温 ($> -0.51^{\circ}\text{C}$) 通常促进更多降水, 高温增加大气水汽含量和对流活动。灌木丛覆盖率的影响呈现非线性特征, 在低温区域, 高覆盖率与更多降水相关, 灌木丛改变了地表特性和局地水汽循环; 而在高温区域, 高覆盖率反而与较少降水相关, 这可能涉及复杂的生态系统水分消耗机制。此外, 气温和灌木丛覆盖率的交互作用进一步复杂化了这一关系, 表明在不同温度和植被条件下, 降水形成机制可能发生变化。

在湿地 (wetland) 类土地覆被类型中, 年降水量主要受到年平均气温、经度位置和湿地覆盖率的影响。在年平均气温较低 ($\leq -0.48^{\circ}\text{C}$) 的湿地区域, 同样不易取得更高水平的年平均降水量。进一步, 东部地区 (经度 > 95.50) 的湿地更容易取得高水平的年平均降水量。此外, 湿地地区年平均降水量还受到湿地覆盖率的影响, 在湿地覆盖率较高 (> 0.000) 的区域, 更容易取得高水平的年平均降水量 (65.88mm)。同时, 在年平均气温较高 ($> 0.48^{\circ}\text{C}$) 的湿地区域, 年平均降水量受到温度和经度的进一步影响, 在温度较高的东部区域更容易取得较高的年平均降水量。结合图 4.12 和数据分析结果, 可以发现, 由于东部靠近海洋, 水汽来源充足, 且受东亚季风影响显著, 而西部内陆则受大陆性气候影响, 降水相对较少。此外, 湿地覆盖率的作用也不容忽视。高覆盖率 (> 0.000) 的湿地区域倾向于获得更多降水, 这可能是由于湿地本身通过蒸发和蒸腾过程向大气提供水汽, 同时改变局地微气候, 形成有利于降水的条件。这种机制可能导致了一个正反馈循环: 更多湿地促进更多降水, 而更多降水又维持和扩大湿地面积。气温和经度位置存在交互作用。在高温条

件下 ($>0.48^{\circ}\text{C}$)，东部地区的降水优势更为明显，这反映了温度和地理位置的协同效应，创造了最有利于降水形成的环境。




图 4.11 灌木丛 shrub 的决策树结果

(4)极端天气的形成过程解析

综上分析可以发现，地形与气候条件的交互与组合作用对地区降雨产生了显著的影响，这也为后续分析暴雨极端天气的形成过程提供了理论视角。本文将每年地区降雨量超过 300 毫米的样本标记为“暴雨”天气，构建土地类型、覆盖面积比例、气温与降雨量之间的 CART 决策树模型，同时结合经纬度坐标分析地形与气候因素组合在暴雨极端天气形成过程中的作用，得到如图 4.13 所示的决策结果。其中，类标签 High 表示地区为暴雨极端天气，类标签 Low 则为非暴雨极端天气。

如图 4.12 所示，我国暴雨极端天气的形成主要受到年平均气温和经纬度位置的影响。在低温（气温 $\leq -2.912^{\circ}\text{C}$ ）的低纬度（ ≤ 32.5 ）东部区域（经度 > 101.5 ），较容易产生暴雨极端天气；此外，在温度中高（ $-2.912^{\circ}\text{C} < \text{气温} \leq 0.104^{\circ}\text{C}$ ）的低纬度（ ≤ 33.5 ）区域，也较为容易产生暴雨极端天气。在温度较高（气温 $> 0.104^{\circ}\text{C}$ ）的低纬度（纬度 ≤ 32.5 ）地区，也容易产生暴雨极端天气。在温度较高（气温 $> 0.104^{\circ}\text{C}$ ）的中低纬度（ $32.5 < \text{纬度} \leq 33.5$ ）地区，东部区域（经度 > 113.5 ）更容易产生极端暴雨天气。可以发现，我国极端暴雨天气较易发生于长江以南的东部沿海地区，此外，由于这些地区的年平均气温相对不高，因此，推断这些区域可能处于较高海拔区域，因此，在我国东南沿海的高海拔区域，更容易产生极端暴雨天气。

相对气温较高的区域，蒸发强度较大，大气中水汽含量丰沛，水汽输送和对流活动的强度较高，增加了降水的可能性；同时，低纬度区域往往接受更多太阳辐射，增大了蒸发和对流活动的频繁性，东部地区相对靠近海洋，湿润气流丰富，并容易受到东亚季风的影响，易产生暴雨天气。此外，一些高海拔区域由于地形的抬升作用，导致气流上升、冷却并产生凝结，增强降水强度，山脉等阻碍物可以触发和加剧对流，大大增加了暴雨天气发生的概率。低纬度、较高海拔的东部沿海地区在多重因素叠加下，成为极端暴雨高发区。





图 4.12 湿地 wetland 的决策树结果

4.3 本章小结


在本章中，基于对问题二的分析，建立决策树模型分析地形与气候等因素在暴雨极端天气形成过程中的作用机制。通过结合 GIS 技术，整合地形特征和气候因素作为自变量，将年平均降水量作为因变量，暴雨天气发生与否作为离散化的分类变量，探讨不同经纬度条件、土地利用类型等条件下对降水量和极端天气的交互作用效果，得出如下结论：

(1) 年平均降水量主要受到气温、经纬度等因素的交互影响，在气温较高的东部低纬度地区，更容易获得较高水平的年平均降水量。根据 Clausius–Clapeyron 方程，高温地区的大气往往能够容纳更多水汽，为丰沛降水提供了充足的水源；同时，高温地区往往更容易促进大气对流，有利于云的形成与发展，增加了降水的可能性。在东部地区，受海洋气候的影响显著，水汽来源充足，东亚季风也能够在夏季带来大量水汽，低纬度地区靠近热带辐合带，水汽输送更加便捷，首先受到季风影响，与邻近海洋的热量和水汽交换更为频繁。

(2) 与此同时，极端暴雨天气的形成同样受到气温、经纬度等因素的交互作用，低温低纬度的东部地区、中高纬度的地位地区和高温低纬区域都容易产生极端暴雨天气。从气象学角度，低温低纬度东部地区可能存在显著的温度梯度，有利于锋面系统的形成，从而引发强降水；中高纬度地区的大气持水能力较强，为暴雨提供充足的水汽来源；高温低纬区域的强烈太阳辐射加热地表，增加大气不稳定性，有利于对流性降水的形成。同时，东部地区的复杂地形（如山地、丘陵）可能引起地形抬升效应，加强降水强度；靠近海洋的区域水汽输送充足，为极端降水提供条件。不同温度和纬度条件下，暴雨形成的主导机制可能有所不同。低温低纬度东部地区可能更多受到锋面系统和地形影响；中高纬度地区可能主要受益于充足的水汽和适宜的大气层结；高温低纬区域则可能更多依赖于强烈的对流活动。



(a)暴雨极端天气决策树-1



(a)暴雨极端天气决策树-2

图 4.13 暴雨天气的地形-气温交互作用

五、问题三求解及分析

5.1 问题描述

问题 3 旨在确定暴雨成灾的临界条件，并基于历史数据和预测模型，预测 2025~2035 年间中国境内最易受到暴雨灾害影响的脆弱地区。该问题需要综合考虑降雨、地形和土地利用三个方面的因素及其交互作用。

临界条件的确定是解决问题 3 的重点任务。首先，基于问题 2 中建立的地形-气候相互作用模型，可以分析降雨强度与地形特征之间的关系，确定降雨量超过当前地区当前前 95% 分位数降雨量时为暴雨极端天气，从而综合探讨地形如何放大暴雨的影响。

其次，要对受暴雨地区的脆弱性进行评价，脆弱性评估模型的构建涉及综合评估降雨、地形和土地利用三个方面的相对重要性，采用加权指数法，将各因素的影响权重进行量化，并综合构建并计算暴雨灾害脆弱性指数。其中，降雨量、土地利用面积占比、土地覆被类型等指标分别赋予不同权重，通过加权求和得到每个区域的脆弱性评分，最后结合 GIS 技术，可以将脆弱性指数在空间上进行可视化，识别出高风险区域。

对于脆弱性地区的时空预测，本文利用时间序列模型，预测 2025~2035 年间降雨量和土地利用的变化趋势，采用 ARIMA 模型对不同地区暴雨灾害脆弱性指数的相关影响因素进行中长期预测，通过训练 ARIMA 模型，预测未来降雨量、土地类型及利用面积占比的变化模式以及土地利用类型的动态演变。结合地形、气候和降雨情况，评估未来暴雨灾害的风险变化。

脆弱地区的预测与空间可视化是问题 3 的最终目标。基于支持向量机 SVR 预测的暴雨灾害脆弱性指数，结合临界条件评估各区域在未来十年内的脆弱性水平。利用 GIS 工具，生成脆弱地区的空间分布地图，直观展示高风险区域，采用地图可视化结果不仅为地方政府制定防灾减灾策略提供参考，也有助于公众了解自身所处区域的灾害风险，提升防灾意识和应对能力。

5.2 问题求解

5.2.1 数据准备与特征工程




图 5.1 年均降雨量

数据准备与特征工程是整个建模过程的基础，决定了后续分析和模型的准确性与有效性。本文涉及多种数据类型^[18, 19, 20]，包括降雨量、土地利用、地形等，需要对这些数据分别进行特征工程处理。通过数据预处理，整理得到地区的年平均降雨量趋势、年度最大单次降雨量变化趋势分别如图 5.1 和图 5.2 所示，同时绘制不同年份下地区的降雨量箱线分

布如图 5.1 所示。

从图像中展示的年均降雨量数据可以看出，降雨量在 1990 年至 2018 年这段时间内呈现出一定的波动性。这种波动可能受到多种因素的影响，包括自然气候周期、全球气候变化以及地区性的天气模式。在这段时间内，降雨量的变化并不是线性的，而是呈现出不规则的上升和下降趋势。某些年份，如 1998 年和 2002 年，降雨量达到了相对的高峰，这可能与特定年份的气候条件有关，比如强烈的季风活动或是异常的气候现象。而在其他年份，如 2004 年和 2006 年，降雨量则相对较低，这可能指示了干旱期或是气候的自然波动。整体来看，虽然降雨量有波动，但并没有显示出一个明确的长期上升或下降趋势。这表明该地区的降雨量可能受到多种复杂因素的影响，而不是单一因素所决定。




图 5.2 年度最大单次降雨量变化趋势




图 5.3 不同年份降雨量分布箱线图

通过分析降雨量与近地表温度的散点关系，得到如图 5.4 所示的结果，可以看出，在温度较低的情况下，降雨量与气温之间并没有明显的线性关系，而在温度较高的样本数据中，二者呈现微弱的正相关关系。其次，从地区经纬度的细粒度分析视角来看，降雨量的空间分布情况如图 5.5 所示，可以看出降雨量较高的地方基本在沿海一带。




图 5.4 降雨量与温度的关系




图 5.5 降雨量的空间分布

特别地，本文在进行数据处理时，还构建了一系列与降雨相关的指标，以揭示降雨量的时空变化趋势及其对暴雨灾害的潜在影响。首先，为了平滑降雨量的年度波动并捕捉长期趋势，本文计算了降雨量的三年滚动平均值（Rain_RollingMean_3）。通过对每个区域的年度降雨量进行滚动平均处理，可以有效减少随机性影响，展示降雨的潜在变化趋势。

其次，本文通过年度降雨量变化率（Rain_YoY_Change）来反映降雨的年际波动。该

指标是通过计算每年降雨量相对于上一年的百分比变化而得出的，有助于分析不同年份间降雨量的增长或减少幅度，识别出降雨的波动性和异常变化。与此相关的还有降雨量的滚动标准差（Rain_RollingStd_3），该指标衡量降雨量在连续三年中的波动程度，用于评估降雨的稳定性以及极端天气发生的可能性。

为了反映降雨量在长期尺度上的积累效应，本文计算了累计降雨量（Rain_Cumulative）。通过对降雨量的累积处理，可以显示一个地区在一段时间内降雨的总量，特别是对于长期干旱或暴雨的地区，该指标能够为分析气候变化的影响提供参考。

降雨量的变化趋势在时间维度上是本文重点关注的内容之一。通过线性回归拟合的方法，本文计算了降雨量的趋势斜率（Rain_Trend_Slope）。该指标描述了每个区域在若干年间降雨量的变化方向和速度。正的斜率代表降雨量在逐年增加，而负的斜率则表明降雨量在逐年减少，从而为预测未来趋势提供定量依据。

除了常规的降雨量指标外，本文还特别关注极端降雨事件的发生，即暴雨灾害事件。首先，定义了极端降雨事件（Extreme_Rain），即降雨量超过地区当年降雨量 95 百分位数的情况。接着，统计了每年发生极端降雨事件的次数（Extreme_Rain_Count），以便了解暴雨频率的变化情况。此外，极端降雨事件的年际变化率（Extreme_Rain_YoY_Change）进一步揭示了这些事件在不同年份之间的波动，有助于分析极端天气事件的增加或减少趋势。最后，本文还探讨了温度与土地覆盖率之间的交互作用对降雨量的潜在影响。通过构建温度与土地覆盖率的交互项（Temp_Coverage_Interaction），本文试图探索气温上升与土地利用变化如何共同影响降雨模式，这一变量能够为分析气候与土地利用对暴雨灾害的协同作用提供重要依据。

5.2.2 模型构建

极端梯度提升（eXtreme Gradient Boosting, XGBoost）是一种基于梯度提升决策树（Gradient Boosting Decision Tree, GBDT）算法进行改进的新方法，在 GBDT 的基础上进行了建模效果优化^[21]。其中，GBDT 是一种基于 boosting 集成思想的加法模型，在进行模型训练时，采用前向分布算法达到贪婪学习的目的，模型每进行一次迭代，与此同时都会学习一颗 CART 树，对前 $t-1$ 颗树的训练结果与训练样本真实值之间的残差进行拟合。XGBoost 算法的基本思想和 GBDT 相一致，XGBoost 也是一个加法模型，但是它结点分裂的标准发生了新的变化。无论是回归问题还是分类问题，都需要先定义一个可微的损失函数。之后遍历所有的树结构，计算所有样本在树结构下的一阶导和二阶导，进而得到每个树结构的损失，通过比较所有树结构的损失，从中选择最小损失对应的结构作为当前的新学习器。

首先介绍 XGBoost 算法中的损失函数，该损失函数是在 GBDT 损失函数上进行的改进，以 GBDT 损失函数 $L(y, f_{t-1}(x) + h_t(x))$ 为基础，XGBoost 算法在其中加入正则项：

$$\Omega(h_t) = \gamma J + \frac{\lambda}{2} \sum_{j=1}^J \omega_j^2 \quad (5-1)$$

其中 J 为叶子节点的个数， ω_j 为第 j 个叶子节点的最优值，由此得到 XGBoost 算法的损失函数表达式为：

$$L_t = \sum_{i=1}^m L(y_i, f_{t-1}(x_i) + h_t(x_i)) + \gamma J + \frac{\lambda}{2} \sum_{j=1}^J \omega_j^2 \quad (5-2)$$

在第 t 个决策树中，要想得到该决策树的最优所有 J 个叶子节点区域，以及每个叶子

节点区域的最优解 ω_j ，就需要极小化算法的损失函数，XGBoost 算法在解决此问题时与 GBDT 算法有所不同，GBDT 算法是从泰勒展开式的一阶导数入手解决此问题，而 XGBoost 算法是从损失函数的二阶泰勒展开式入手解决此问题的，该算法损失函数的二阶泰勒展开式如下所示：

$$L_t = \sum_{i=1}^m L(y_i, f_{t-1}(x_i) + h_t(x_i)) + \gamma J + \frac{\lambda}{2} \sum_{j=1}^J \omega_j^2 \quad (5-3)$$

$$L_t \approx \sum_{i=1}^m (L(y_i, f_{t-1}(x_i)) + \frac{\partial L(y_i, f_{t-1}(x_i))}{\partial f_{t-1}(x_i)} h_t(x_i) + \frac{1}{2} \frac{\partial^2 L(y_i, f_{t-1}(x_i))}{\partial f_{t-1}^2(x_i)} h_t^2(x_i)) + \gamma J + \frac{\lambda}{2} \sum_{j=1}^J \omega_j^2 \quad (5-4)$$

将第 i 个样本在第 t 个弱学习器的一阶导数和二阶导数分别记为：

$$g_{ti} = \frac{\partial L(y_i, f_{t-1}(x_i))}{\partial f_{t-1}(x_i)}, \quad h_{ti} = \frac{\partial^2 L(y_i, f_{t-1}(x_i))}{\partial f_{t-1}^2(x_i)} \quad (5-5)$$

则损失函数表达式为：

$$L_t \approx \sum_{i=1}^m (L(y_i, f_{t-1}(x_i)) + g_{ti} h_t(x_i) + \frac{1}{2} h_{ti} h_t^2(x_i)) + \gamma J + \frac{\lambda}{2} \sum_{j=1}^J \omega_j^2 \quad (5-6)$$

在最小化损失函数的过程中，损失函数表达式中的 $L(y_i, f_{t-1}(x_i))$ 为常数，常数对于该过程不会产生影响，因此可以将其进行忽略，加之对于每个决策树来说，其第 J 个叶子节点的取值都是 ω_j ，因此可以对损失函数进一步进行简化：

$$L_t = \sum_{j=1}^J (\omega_j \sum_{x_i \in R_j} g_{ti} + \frac{1}{2} (\sum_{x_i \in R_j} h_{ti} + \lambda) \omega_j^2) + \gamma J \quad (5-7)$$

对于如何一次性求解决策树最优的所有叶子节点区域和求解每个叶子节点区域的最优解，可以将其拆分为 2 个问题：

- (1) 如果已经求出第 t 个决策树的 J 个最优的叶子节点区域，如何求出每个叶子节点区域的最优解 ω_j 。
- (2) 为达到最小化损失函数的目的，当前决策树进行子树分裂决策的过程中，应该采用什么策略或标准来选择特征和特征值进行分裂。

针对第一个问题，可以直接基于损失函数对 ω_j 进行求导并且令其导数为 0，即可得叶子区域的最优解 ω_j 表达式：

$$\omega_j = -\frac{G_j}{H_j + \lambda}$$

针对第二个问题，GBDT 算法是直接进行 CART 回归树的拟合过程，因此该算法在进行树节点分裂时使用的是均方误差。XGBoost 算法和 GBDT 算法有所不同，在 XGBoost 算法中是采用贪心算法进行分裂，在每一次进行分裂时都试图使损失函数的误差

达到最小。

在 ω_{ij} 取最优解时损失函数表达式为：

$$L_t = -\frac{1}{2} \sum_{j=1}^J \frac{G_{ij}^2}{H_{ij} + \lambda} + \gamma J \quad (5-8)$$

该算法在进行每一次左右子树分裂时，都希望最大化地降低损失函数的损失，将当前状态中左右子树的一阶导数和以及二阶导数和分别记作 G_L, H_L, G_R, H_R ，便可以得到下式：

$$\max \frac{1}{2} \frac{G_L^2}{H_L + \lambda} + \frac{1}{2} \frac{G_R^2}{H_R + \lambda} - \frac{1}{2} \frac{(G_L + G_R)^2}{H_L + H_R + \lambda} - \gamma \quad (5-9)$$

此时 XGBoost 算法就不是使用 CART 回归树的均方误差作为决策树的分裂标准，而是使用上式(5-9)作为分裂标准进行决策树的分裂过程。在整个 XGBoost 算法流程中，先输入训练集样本 $I = \{(x_1, y_1), (x_2, y_2), \dots, (x_m, y_m)\}$ ，最大迭代次数 T ，损失函数 L ，以及正则化系数，最后输出强学习器 $f(x)$ 。在每一次迭代过程中：

(1) 计算在当前迭代次数中，第 i 个样本的损失函数 L 基于 $f_{t-1}(x_i)$ 的一阶导数 g_{ti} ，二阶导数 h_{ti} ，并且计算所有样本的一阶导数和 G_t 以及二阶导数和 H_t 。

(2) 以当前节点为基础开始决策树的分裂过程，默认分数 $\text{score}=0$ ，当前分裂节点的一阶导数和以及二阶导数和分别为 G 和 H 。

对于特征序号 $k=1, 2, \dots, K$ ：

1) $G_L=0, H_L=0$ 。

2) 以特征 k 为依据将样本按照从小到大的顺序进行排列，并将第 i 个样本依次取出，之后以当前样本放入左子树为前提计算左右子树的一阶导数和、二阶导数和：

$$G_L = G_L + g_{ti}, \quad G_R = G - G_L$$

$$H_L = H_L + h_{ti}, \quad H_R = H - H_L$$

3) 依据式(5-9)更新最大分数。

(3) 以最大分数为依据，在进行子树分裂时选择其所对应的特征和特征值。

(4) 如果最大分数为 0，则表示当前决策树建立完毕，之后计算所有叶子节点区域的 ω_{ij} 得到弱学习器 $h_i(x)$ ，进行强学习器的更新，进入下一轮弱学习器的迭代，否则转至第(2)步继续分裂决策树。

5.2.3 暴雨灾害脆弱性指数评价

为了分析暴雨成灾的临界条件，本文首先对地区的暴雨灾害脆弱性指数（Vulnerability Index for Rainstorm Disasters, VIRD）这一目标概念和变量进行内涵界定与量化，该指标的构建旨在综合反映不同地区在暴雨灾害中的脆弱性，基于降雨强度、地形特征、土地利用等多方面因素，评估一个区域在暴雨灾害中的承受能力。该指数能够量化各地区暴雨灾害风险，为脆弱区域的识别和预测提供依据。

暴雨灾害的成因复杂，多因素交织在一起，为了系统化这一复杂过程，本文从自然触发因素、物理脆弱性和土地脆弱性三个维度构建暴雨灾害脆弱性指数，其中自然触发因素主要考虑到暴雨的强度和频次，物理脆弱性则关注地形稳定性和海拔高度，土地脆弱性则主要是植被覆盖率与土地利用面积占比。其中，每一维度都对应着不同的具体指标，并通过标准化和加权汇总的方式综合形成暴雨灾害脆弱性指数，该指标的综合评价体系如表 5.1 所示。

表 5.1 地区暴雨灾害脆弱性指数的综合评价体系

一级指标	二级指标	三级指标	单位
自然触发因素	降雨强度 R_{rain}	年最大日降雨量 P_{max}	毫米
		年总降雨量 P_{total}	毫米
	暴雨频率 $P_{extreme}$	暴雨频次 $P_{extreme}$	次
物理脆弱性	高程	海拔高度	米
	坡度	地形坡度	米
	地质稳定性	降雨量滚动标准差	毫米
土地脆弱性	植被覆盖率	植被覆盖率	%
	土地利用面积占比	土地利用面积占比	%

其中，自然触发因素这一维度反映了暴雨事件的强度和频次，通过年度降雨变化率、累计降雨量和暴雨频次等指标进行评估。它展示了暴雨灾害的外在自然条件。物理脆弱性关注地形条件，特别是海拔高度和地形稳定性（通过降雨量的滚动标准差来反映），这两项指标用于评估暴雨对区域地形结构的影响及易损程度。而土地脆弱性主要关注区域植被覆盖率和土地利用状况，较高的植被覆盖率有助于降低暴雨带来的破坏性，而土地利用面积占比则衡量了区域内人类活动对生态系统稳定性的影响。

第一，暴雨的强度和频次是暴雨灾害的直接触发因素，主要通过以下几个指标来衡量：
年最大日降雨量（Maximum Daily Rainfall, P_{max} ）：用于衡量暴雨的最大强度，单位为毫米。

年总降雨量（Annual Total Rainfall, P_{total} ）：反映一个地区在一年内的总体降雨量，有助于识别高降雨量的地区。

极端降雨事件频次（ $P_{extreme}$ ）：定义为超过 95%分位数的降雨事件次数，代表极端降雨的发生频次。

上述指标的标准化计算公式为：

$$R_{rain} = \frac{P_{max}}{P_{total}} \times \log(1 + P_{extreme})$$

(5-10)

这个暴雨强度指数综合了最大降雨量和极端事件的频率，反映了暴雨的潜在威胁。
第二，地形因素直接影响水流的路径和暴雨后的地表响应，相关的地形指标包括：
坡度（Slope, S_{slope} ）：地形坡度较大的地区，水流加速，容易形成洪涝和山体滑坡。
高程（Elevation, $E_{elevation}$ ）：地势较低的地区更容易积水，洪涝风险更高。
地质稳定性（Geological Stability, $G_{stability}$ ）：通过数字地形模型（DEM）提取，反映该地区的地质条件是否易于发生滑坡等灾害。

地形脆弱性指数的计算公式为：

$$R_{terrain} = S_{slope} \times \left(1 - \frac{E_{elevation}}{E_{max}} \right) \times G_{stability} \quad (5-11)$$

该公式体现了坡度、高程和地质稳定性对暴雨灾害的影响，其中坡度与灾害风险成正比，而高程与风险成反比。

第三，土地利用类型和人类活动会显著影响暴雨的成灾程度，相关的土地利用指标包括：

植被覆盖率（Vegetation Coverage, V_{veg} ）：植被覆盖率越高，雨水渗透和滞留能力越强，防止暴雨径流过快流入低洼地区。

土地利用变化率（Land Use Change Rate, L_{change} ）：快速变化的土地利用模式，尤其是城市扩张，会增加暴雨成灾的风险。

土地利用脆弱性指数计算公式为：

$$R_{land} = (1 - V_{veg}) \times \log(1 + L_{change}) \quad (5-12)$$

这一公式表明植被覆盖率越低、城市化率越高、土地利用变化越剧烈，区域的暴雨灾害脆弱性越高。

在计算各个子指标后，通过加权汇总每个子指标，得到最终的暴雨灾害脆弱性指数。暴雨灾害脆弱性指数 V_{index} 的综合公式为：

$$V_{index} = w_1 R_{rain} + w_2 R_{terrain} + w_3 R_{land} \quad (5-13)$$

其中， w_1, w_2, w_3 分别为暴雨强度、地形条件、土地利用的权重，在本文中通过熵权法求得。熵权法是一种客观赋权方法，它根据各指标所含信息有序程度的差异性进行定权，指标离散程度越大，其蕴含的信息量越大，则该指标对评价结果的影响或权重就越大。本研究在传统熵权法赋权的基础上加入时间变量，综合考量所有样本数据在每项评价指标的权重分配，从而得到更为客观的评价分析结果，具体计算如下：

（1）确定初始指标

对于 m 个样本， n 个评价指标和 t 个年份，则 $x_{ik}^{(j)}$ 表示第 i ($i=1,2,\dots,m$) 个样本的第 j ($j=1,2,\dots,n$) 个指标在第 k ($k=1,2,\dots,t$) 年份的指标值。

（2）异质指标同质化

由于各项指标的量纲和单位并不统一，因此在计算评价结果之前需要进行标准化处理，解决不同指标的同质化问题。

①对于效益型指标，其标准化方法为：

$$y_{ik}^{(j)} = \frac{x_{ik}^{(j)} - \min_i x_{ik}^{(j)}}{\max_i x_{ik}^{(j)} - \min_i x_{ik}^{(j)}} \quad (5-14)$$

②对于成本型指标，其标准化方法为：

$$y_{ik}^{(j)} = \frac{\max_i x_{ik}^{(j)} - x_{ik}^{(j)}}{\max_i x_{ik}^{(j)} - \min_i x_{ik}^{(j)}} \quad (5-15)$$

（3）计算第 j 个指标的第 i 个样本在所有样本中占该指标的比重：

$$p_{ik}^{(j)} = \frac{y_{ik}^{(j)}}{\sum_{i=1}^m y_{ik}^{(j)}} \quad (5-16)$$

(4) 计算第 j 个指标在第 k 年份的信息熵值:

$$e_{jk} = -\frac{1}{\ln(n)} \sum_{i=1}^m p_{ik}^{(j)} \ln(p_{ik}^{(j)}), \quad j=1,2,\dots,n \quad (5-17)$$

特别地, 当 $p_{ik}^{(j)}=0$ 时, $p_{ik}^{(j)} \ln(p_{ik}^{(j)})=0$ 。

(5) 计算信息冗余度:

$$d_{jk} = 1 - e_{jk}, \quad j=1,2,\dots,n \quad (5-18)$$

(6) 计算特定年份 k 中各指标的权重:

$$w_{jk} = \frac{d_{jk}}{\sum_{j=1}^n d_{jk}} \quad (5-19)$$

(7) 对不同年份下指标 j 的权重进行均值化处理得到综合评价体系中的最终指标权重为:

$$w_j = \frac{1}{t} \sum_{k=1}^t w_{jk} \quad (5-20)$$

基于式 (5-20) 和式 (5-13) 的计算, 将各指标的熵权纳入到暴雨灾害脆弱性指数的计算体系中, 即可得到最终赋权后的各地区暴雨灾害脆弱性指数 V_{index} 。

经过上述综合评价过程, 将暴雨灾害脆弱性指数 V_{index} 的直方图展示如图 5.6 所示。通过直方图的展示, 可以直观地观察到 V_{index} 的分布情况, 判断大部分地区的脆弱性水平, 同时, 通过分析高于 0.37 的样本数据, 即 75% 的数据作为脆弱性的判断, 深入了解这些地区的特征和潜在风险, 为进一步的研究和决策提供数据支持。




图 5.6 暴雨灾害脆弱性指数的直方图

进一步展示暴雨灾害脆弱性指数 V_{index} 与地形因素、降雨因素之间的相关性，绘制其散点图如图 5.7 所示。




图 5.7 暴雨灾害脆弱性指数与土地、降雨的相关性散点图

可以发现，暴雨灾害脆弱性指数 V_{index} 与地区降雨量之间存在显著的正相关关系，而与地形因素中的植被覆盖面积和地形海拔高度的线性关系并不明显，因此可以推断地区的暴雨灾害可能并非是由单一因素影响的，单一因素难以全面解释其变化，这一发现强调了在制定应对暴雨灾害的政策时，需要综合考虑多个因素，以提升地区的韧性和适应能力。

5.2.4 基于 XGBoost 模型的暴雨成灾的临界条件分析

结合上述影响地区暴雨灾害脆弱性的非线性关系探索结果，本文进一步采用 XGBoost 模型对暴雨成灾的临界条件进行分析，旨在识别和量化影响暴雨灾害脆弱性的重要因素。利用 XGBoost 模型的优势^[22]，本文对训练集进行训练，并对测试集进行验证，评估模型的性能。通过交叉验证和网格搜索，优化模型参数以提高预测准确性。在模型训练完成后，本文分析了特征重要性，以识别哪些变量对 V_{index} 的影响最为显著。

在临界条件的分析中，本文特别关注以下几个方面：首先，确定降雨量的临界值，超过此阈值时，暴雨成灾的风险显著增加；其次，评估植被覆盖率和海拔高度在不同降雨条件下的作用，探讨其对脆弱性的调节效应。通过构建决策边界，观察不同变量的交互作用，本文能够更好地理解成灾的临界条件。最后，通过分析模型输出的特征重要性，本文关注那些在未来可能成为关键因素的变量，以便提前采取相应的地区管理适应策略。这一预测不仅有助于识别高风险地区，还为资源的合理分配和应急准备提供了依据，从而在暴雨灾害发生之前增强社区的韧性和适应能力，地方政府和相关机构也能够更有效地规划和实施应对暴雨灾害的措施，降低未来潜在的损失。

在 XGBoost 建模中，因变量为经过离散化之后的地区暴雨灾害脆弱性指数，对于高于 0.37 的样本为高，即地区的暴雨灾害风险等级为高，对于低于 0.37 的样本则为暴雨灾害风险等级为低。自变量包括经度 *longitude*、纬度 *latitude*、降雨量 *Rain*、植被覆盖比例 *Coverage_ratio*、海拔高度 *altitude* 降雨变化率 *Rain_Trend_Slope*、降雨波动性 *Rain_RollingStd_3*、土地类型 *Land_type_forest*、*Land_type_grass*、*Land_type_shrub*、*Land_type_cropland* 和 *Land_type_wetland*，这些变量不仅涵盖了气象、地理和生态因素，还反映了地区的土地利用状况，因此能够为暴雨灾害风险的分析提供全面的视角。

在样本划分完成后，本文采用 *train_test_split* 方法将数据集分为训练集和测试集，比例为 80% 和 20%，这种划分方式有助于在训练模型时减少过拟合风险，同时保留一部分数据用于评估模型的泛化能力。经过划分，模型将主要在训练集上进行学习，而测试集则用于检验模型在未见数据上的表现。

模型的构建使用了 XGBoost 分类器，这是一种基于决策树的集成学习方法，因其在处理高维数据和非线性关系时表现出色而受到广泛应用^[23]。在构建模型时，本文选择了

use_label_encoder=False 和 eval_metric='logloss' 作为参数，以便优化模型的性能。通过这种设置，模型能够有效处理类别标签，并且使用对数损失作为评估指标，确保分类效果的准确性。在模型训练完成后，本文对测试集进行了预测，并使用混淆矩阵和分类报告评估了模型的性能。混淆矩阵展示了预测结果与实际类别之间的对比，提供了真阳性、真阴性、假阳性和假阴性的数量，而分类报告则给出了精确度、召回率和 F1 分数等指标。这些评估结果能够帮助本文全面了解模型的分类能力，特别是在高风险类别的识别上，反映出模型在实际应用中的有效性。

最后，本文对特征重要性进行了分析，以识别对模型预测影响最大的变量。通过提取模型的特征重要性，本文能够直观地展示各自变量在预测暴雨灾害风险时的贡献程度。这一分析不仅为本文理解模型的决策过程提供了依据，也揭示了哪些因素对地区脆弱性的影响最为显著。例如，降雨量和植被覆盖比例等变量可能在模型中占据较高的重要性，表明它们对暴雨成灾的风险有直接影响。而土地类型的不同也可能反映出地区在应对暴雨时的差异。

通过以上的建模过程，本文不仅建立了一个有效的 XGBoost 分类模型来预测地区的暴雨灾害风险等级，还深入分析了影响脆弱性的主要因素。这一研究不仅为理论探讨提供了数据支持，也为实际的灾害管理和政策制定提供了参考，帮助相关机构在应对暴雨灾害时更具针对性和科学性。未来的研究可以基于此模型进行更深入的时空分析，探讨气候变化和土地利用变化对暴雨灾害脆弱性的长期影响。

经过 XGBoost 建模，得到对应前 8 个特征变量的重要性评分，如图 5.8 所示。根据特征重要性分数，降雨量（Rain）和覆盖比例（Coverage_ratio）显然是最重要的特征，分别占据了 63.63%和 3.39%的重要性。这表明，在预测暴雨灾害的脆弱性时，降雨量的变化对结果的影响最大，可能是因为降雨量直接关系到水分输入，对土壤和地表的水文过程具有重要影响。覆盖比例则可能反映了土地利用类型对暴雨响应的调节作用，较高的覆盖比例通常意味着更好的水分保持能力。其次，降雨趋势斜率（Rain_Trend_Slope）和三年滚动标准差（Rain_RollingStd_3）也显示出较高的特征重要性，分别占有 10.97%和 6.69%。这表明，降雨的时序变化和波动性在评估脆弱性时也不可忽视，能够揭示区域气候变化对极端天气事件的潜在影响。






图 5.8 特征重要性评分结果

其他特征，如经度、纬度和土地类型（森林、草地、灌木、湿地）在模型中的重要性较低，分别为 3.39%、0.85%、0.80%、0.08%、0%。这表明，这些特征在预测过程中可能不如降雨量和土地利用比例那样具有决定性影响，但它们仍然可能在特定情境下提供额外信息。总体而言，通过 XGBoost 的特征重要性分析，本文能够识别出对暴雨灾害脆弱性预测的关键因素，为后续的决策提供数据支持，进而为区域风险管理与应对策略的制定提供参考。



(a)暴雨成灾的决策规则划分



(b)决策树效果

图 5.9 暴雨成灾的决策临界条件组合

通过对暴雨灾害脆弱性的 XGBoost 建模，得到如下图 5.9 所示的决策规则。通过决策树可视化，能够深入理解暴雨成灾的决策规则，揭示影响风险等级的重要特征及其相互关系。决策树是一种直观的分类模型，能够通过层次分明的树状结构展示决策过程。在可视化过程中，根节点代表了决策的起始点，通常是最具区分力的特征。随着树的逐层深入，每个节点通过特征的条件划分，逐渐细化了对暴雨成灾风险的判断。这种逐步分裂的方式，使本文能够清楚地看到每个特征在模型中的作用及其对最终决策的影响。在分析决策树时，本文首先关注根节点特征，这是模型判断暴雨成灾风险的首要条件。接着，逐层向下跟随路径，观察每个条件是如何将数据分割成不同的子集，最终形成叶子节点，代表了不同的风险等级。通过这种方式，决策树不仅提供了模型的可解释性，还揭示了变量间的相互作用。例如，降雨量作为一个关键特征，可能在多个决策路径中反复出现，显示出其在评估风险中的重要性。同时，其他特征如覆盖比例、海拔和降雨趋势斜率等也可能在特定条件下显著影响风险的最终判定。通过分析这些特征的分裂点，本文可以识别出哪些条件会导致高风险，而哪些条件则可能降低风险。

此外，通过观察决策树的深度和结构，本文可以识别出特征之间的交互作用，不同特

征在不同的决策路径中进行交互与组合，形成复杂的决策规则。例如，降雨量和覆盖比例的结合可能比单一特征对风险的影响更为显著，这提示本文在评估暴雨成灾风险时需要考虑多维度的特征组合。利用这种可视化工具，本文不仅理解了单一特征的重要性，还能洞察到多特征之间的复杂关系，从而为风险评估提供更全面的视角。通过建模，最终得到决策规则的划分及效果如图 5.9 所示，为了便于可视化，这里仅展示最大树深度为 4 的决策效果。

经过决策树的可视化处理，根据最大树深为 6 的条件组合提炼相应的关键临界条件如表 5.2 所示。

表 5.2 暴雨成灾的临界条件

临界条件	降雨	海拔高度	土地类型	利用面积	降雨趋势	经度	纬度
临界条件 1	>96.656	-	耕地	≤0.067	>0.759	-	≤35.5°
临界条件 2	> 430.469	-	草地	>0.089	≤0.759	>113.6°	≤35.5°
临界条件 3	-	>3840.559	-	-	>1.307	>113.6°	>35.5°
临界条件 4	> 628.906	>60.153	-	>0.089	>0.893		≤35.5°
临界条件 5	> 430.469	-	灌木丛	>0.023	≤0.759	>113.6°	≤35.5°

从暴雨成灾的临界条件中可以看出，一共存在四种关键的条件组合，反映了地形、降雨和土地利用等多方面因素的交互作用。首先，降雨量是暴雨成灾的直接因素。根据临界条件 1 和临界条件 2，降雨量的具体值被设定为重要阈值。临界条件 1 要求降雨量超过 96.656 毫米，而临界条件 2 则设定为超过 430.469 毫米。这表明，当降雨量达到这些值时，土壤饱和、径流增加、滑坡和洪水的风险显著上升。尤其是在临界条件 2 中，降雨量达到 430.469 毫米时，草地的存在可能对水土保持有一定的作用，但如果未能有效管理，仍可能导致水土流失和相关灾害。因此，降雨量不仅是影响灾害的直接因素，同时也是一个重要的触发器，其数值变化可以直接影响其他条件的作用效果。

其次，海拔高度作为自然地理因素，对降雨的影响和成灾风险具有重要作用。临界条件 3 中提到，当海拔高度超过 3840.559 米时，降雨趋势也会相应影响成灾的可能性。较高的海拔地区通常会经历更大的降雨量和温度变化，导致土壤的水管理变得复杂。同时，山地地区由于坡度较大，雨水流动迅速，容易形成山洪和滑坡。此外，高海拔地区的植被覆盖率通常较低，无法有效固定土壤，导致更高的侵蚀风险。因此，海拔高度的变化与降雨量结合起来，形成了暴雨成灾的重要环节。

从临界条件结果来看，土地类型与土地覆盖面积在暴雨成灾中起着关键的调节作用。根据临界条件 1、2 和 4，不同的土地类型（如耕地、草地和灌木丛）在面对同等降雨条件时，其影响差异显著。耕地的覆盖面积≤0.067 时，虽然降雨量已超过 96.656 毫米，但由于土地覆盖面积有限，土壤的保水能力减弱，导致洪水风险增加。而在临界条件 2 中，草地的覆盖面积>0.089，能够一定程度上减缓降雨引发的径流，从而降低水土流失的风险。因此，土地类型和覆盖面积共同影响着暴雨成灾的程度，选择合理的土地利用方式能有效减缓暴雨带来的损害。

除此之外，降雨趋势的变化也在暴雨成灾中扮演了不可或缺的角色。临界条件中提到的降雨趋势值影响了地表水的积累与流失。当降雨趋势>1.307 时，意味着过去一段时间

内降雨量的增长速度加快，这可能导致土壤的长期饱和，增加洪水和滑坡等灾害的发生概率。因此，降雨趋势不仅关乎当期的降雨量，还反映了更长时间内的降雨模式，能够为灾害风险评估提供有力支持。研究降雨趋势的变化，有助于预测未来的极端天气事件，制定相应的防灾措施。

经纬度作为地理坐标，虽然在临界条件中发挥的作用有限，但其对暴雨成灾的影响同样值得关注。经度和纬度关系到气候带的差异，直接影响区域的降雨量和气候特征。从表 5.2 中的临界条件分析来看，特定的经纬度区域容易产生暴雨成灾，这些区域通常与气候带、地形特征及土地利用等因素密切相关。根据条件中的经度 ($>113.6^{\circ}$) 和纬度 ($\leq 35.5^{\circ}$)，可以推断出这些地区主要位于中国的南方及部分西南地区，一方面包括南方地区，如广东、广西、湖南、湖北、四川等省份。这些地区受到季风气候的影响，夏季降雨集中，且常常伴随强降雨和暴雨事件。另一方面包括，西南山区如云南和西藏的部分地区，这些区域因地形复杂，海拔高度变化大，降雨量也较为集中。

从上述分析可见，表 5.2 中列出的暴雨成灾临界条件并不是孤立存在的，而是相互关联、相辅相成的。降雨量、海拔高度、土地类型和覆盖面积、降雨趋势、经纬度和纬度之间的相互作用共同决定了暴雨成灾的风险。降雨量是直接的触发因素，而海拔高度则影响降雨的分布和强度，土地类型和覆盖面积则调节了水分的流失和土壤的稳定性。降雨趋势提供了一个时间维度，帮助评估降雨模式的变化对成灾的影响，最后，地理坐标则将所有这些因素置于特定的气候和地理背景中。

5.2.5 未来脆弱地区预测的结果

为了预测未来暴雨灾害的脆弱地区，即对脆弱性指数 (V_index) 进行时间序列预测，需要综合考虑多个因素，包括降雨量和不同土地覆盖类型的年均变化趋势，本文涉及数据准备、特征构建、模型选择和预测等多个环节，以下是详细的思路。

首先，数据准备是预测的基础。需要整合包含暴雨灾害脆弱性指数、降雨量以及五种土地覆盖类型（森林、草地、灌木、湿地和总覆盖比例）的历史数据。确保数据的完整性和一致性非常重要，特别是要处理缺失值。对于缺失数据，本文采用均值填充法进行填补，以确保模型训练时数据的完整性。最终整理得到暴雨灾害脆弱性指数数据，其年均变化趋势如图 5.10 所示。




图 5.10 暴雨灾害脆弱性指数的年均变化趋势

五种土地覆被类型的占比年均变化趋势如图 5.11 所示。




图 5.11 五种土地覆被类型的占比年均变化趋势

为了完成预测过程，本文将年均降雨量和五种土地覆盖类型（森林、草地、灌木、湿地和耕地）的占比作为输入特征，而待预测的脆弱性指数则作为目标变量，构建支持向量机预测模型^[24]。由于 2025 年 2035 年输入特征数据是未知的，本文采用 ARIMA 模型进行预测输入特征变量 2025-2035 年的数据，然后基于地区经纬度坐标、地区降雨量和五种土地覆盖类型的占比输入数据，对地区的暴雨灾害脆弱性指数进行预测，并采用 GIS 技术将脆弱性指数在地图上呈现。

对于六个输入特征变量的预测数据结果如表 5.3 所所示。

表 5.3 输入特征的未来预测结果

Year	Rain (mm)	Coverage_forest	Coverage_grass	Coverage_shrub	Coverage_wetland	Coverage_cropland
2019	300.709	0.02	0.061	0.056	0.003	0.021
2020	156.769	0.003	0.020	0.068	0.008	0.045
2021	340.534	0.045	0.090	0.032	0.001	0.023
2022	308.169	0.024	0.075	0.011	0.000	0.027
2023	200.23	0.042	0.093	0.038	0.003	0.027
2024	277.801	0.044	0.129	0.053	0.005	0.041
2025	183.91	0.045	0.123	0.046	0.005	0.022
2026	201.557	0.066	0.133	0.022	0.004	0.037
2027	310.123	0.054	0.100	0.019	0.003	0.034
2028	146.58	0.050	0.091	0.048	0.003	0.044
2029	272.063	0.052	0.071	0.047	0.003	0.030
2030	174.5	0.033	0.118	0.031	0.004	0.038

2031	111.776	0.041	0.113	0.035	0.004	0.030
2032	274.281	0.028	0.124	0.052	0.004	0.044
2033	214.785	0.025	0.153	0.06	0.004	0.033
2034	238.882	0.033	0.134	0.039	0.004	0.039
2035	308.737	0.030	0.111	0.015	0.003	0.035

根据预测结果，未来几年内的年均降雨量和土地覆盖类型的变化呈现出一定的波动性，这反映了气候和生态环境的复杂性。从 2019 年到 2035 年，年均降雨量的预测结果显示显著的波动。2019 年降雨量达到 300.709 毫米，而 2020 年骤降至 156.769 毫米，这一变化可能受到气候因素的影响，表明极端天气事件的潜在风险。之后的年份中，降雨量在 2021 年又回升至 340.534 毫米，之后波动在 200 到 300 毫米之间。

从土地覆盖类型的预测变化趋势来看，各种土地类型的覆盖比例变化各异，且趋势不一。森林覆盖比例（Coverage_forest）从 2019 年的 0.02 上升到 2035 年的 0.03，虽然总体变化幅度不大，但随着森林资源的逐渐恢复和植树造林政策的实施，森林覆盖率的轻微增加可能会对生态环境产生积极影响，增强水土保持能力。草地覆盖比例（Coverage_grass）在 2020 年达到最低值 0.003，随后有所回升，至 2035 年时为 0.111。草地的恢复可能与气候条件的改善及管理措施的实施有关。草地的增加有助于提高土壤的保水能力，并为生态系统提供栖息地。灌木覆盖比例（Coverage_shrub）这一比例整体变化不大，预测值在 0.015 到 0.068 之间波动，稳定的灌木覆盖率有助于维持生物多样性和土壤稳定性。湿地覆盖比例（Coverage_wetland）在预测期内始终保持较低水平，最高为 0.008。这反映出湿地生态系统面临的压力，可能受到城市化和农业开发的威胁。湿地的减少会直接影响水质和生物多样性。耕地覆盖比例（Coverage_cropland）在 2020 年达到最高值 0.045，随后逐渐减少至 0.035。这一变化可能与土地利用政策及气候条件的变化有关。农田的减少可能会影响粮食生产，但也可能意味着土地向更可持续的利用转型。

通过可视化 ACF 和 PACF 图，本文可以观察到各个变量的自相关性，这对于选择合适的 ARIMA 模型参数至关重要。ACF 图展示了数据中各个滞后期的相关性，而 PACF 图则帮助本文确定 AR（自回归）部分的阶数。这一过程不仅直观易懂，还为后续模型的构建提供了科学依据。

在完成 ACF 和 PACF 分析后，本文为每个变量选择了合适的 ARIMA 模型参数，包括自回归阶数（p）、差分次数（d）和滑动平均阶数（q）。这一步骤的关键在于平衡模型的复杂性与其预测能力。本文选择的模型需要在不过拟合的前提下尽可能提高预测准确度。接下来，本文使用 ARIMA 模型对每个变量进行了拟合，并预测了 2019 年至 2035 年的未来趋势。在这一阶段，本文不仅绘制了历史数据和预测结果的折线图，还包含了拟合值。通过这些可视化图表，本文能够直观地观察到模型对历史数据的拟合效果以及对未来趋势的预测能力。

预测结果显示，在历史数据的基础上，年均降雨量在未来十年的变化趋势表现出一定的波动性，而不同类型的土地覆盖比例在未来的变化中也显示出各自的特征，具体 ACF 和 PACF 及 ARIMA 模型预测的可视化效果如图 5.13 至图 5.23 所示。




图 5.12 Rain 的 ACF 和 PACF 图示




图 5.13 Rain 的 ARIMA 预测结果




图 5.14 Coverage_forest 的 ACF 和 PACF 图示




图 5.15 Coverage_forest 的 ARIMA 预测结果




图 5.16 Coverage_grass 的 ACF 和 PACF 图示




图 5.17 Coverage_grass 的 ARIMA 预测结果





图 5.18 Coverage_shrub 的 ACF 和 PACF 图示




图 5.19 Coverage_shrub 的 ARIMA 预测结果





图 5.20 Coverage_wetland 的 ACF 和 PACF 图示




图 5.21 Coverage_wetland 的 ARIMA 预测结果




图 5.22 Coverage_cropland 的 ACF 和 PACF 图示




图 5.23 Coverage_cropland 的 ARIMA 预测结果

总体来看，年均降雨量和土地覆盖类型的变化趋势相互关联，反映出气候变化和人类活动的复杂交互作用。降雨量的波动可能会影响不同类型土地的利用和管理，尤其是农业和生态恢复领域。高降雨量的年份，可能促进草地和农田的生长，而干旱年份则可能导致土壤侵蚀和植被退化。此外，随着气候变化的加剧，未来的降雨模式可能会更加不可预测，这对地方政府和相关部门的决策提出了更高的要求。为了应对这种不确定性，政策制定者需要实施更为灵活和综合的土地管理策略，以增强生态系统的韧性，确保水资源的可持续利用。

表 5.4 SVR 模型的拟合与预测效果

	MSE	MAE	R ²
训练集（80%）	0.0029	0.0443	0.8579
测试集（20%）	0.0029	0.0442	0.8565

进一步地，为了对中国各地区地暴雨灾害脆弱性指数进行预测，构建支持向量机回归 SVR 模型，使用包含多种特征的完整数据集，这些特征包括：Year（年份）、longitude（经度）、latitude（纬度）、V_index（脆弱性指数）、Rain_x（年均降雨量）、Coverage_forest（森林覆盖比例）、Coverage_grass（草地覆盖比例）、Coverage_shrub（灌木覆盖比例）、Coverage_wetland（湿地覆盖比例）、Coverage_cropland（农田覆盖比例）。在数据清洗阶段，本文去除了任何缺失值，以确保模型训练的准确性。如果有缺失数据，可能会导致模型性能下降，因此要保持数据的完整性。为了评估模型的性能，本文将数据集拆分为训练集和测试集。通常，本文会将大约 80%的数据用作训练集，其余 20%作为测试集。这种拆分方式可以帮助本文在训练过程中调整模型参数，并在测试阶段评估模型的泛化能力。SVR 通过寻找最优超平面来实现预测，在这个过程中，本文选择径向基核（RBF）作为默认选项，它能有效处理非线性关系。在模型建立后，本文用训练集对其进行拟合。这一过程涉及到最小化损失函数，从而找到最佳的支持向量，模型通过这些支持向量进行预测。拟合完成后，本文将模型应用于测试集，获取相应的脆弱性指数预测值。在模型预测完成后，本文需要评估其性能。常用的评估指标包括均方误差（MSE）和平均绝对误差（MAE）和 R2。通过计算这些指标，本文可以量化模型的预测误差，并进一步分析模型的效果，通过 SVR 建模得到如下表 5.4 所示的测试集效果。

可以发现训练集和测试集的均方误差均为 0.0029。这一指标衡量了模型预测值与真实值之间的差异，值越小，表示模型预测的准确性越高。此结果表明，模型在训练和测试阶段表现一致，具有良好的拟合能力和稳定性。训练集的平均绝对误差为 0.0443，而测试集的 MAE 为 0.0442，两者非常接近。MAE 衡量的是模型预测值与真实值之间的平均绝对差异，数值小于 0.1 表示模型在预测脆弱性指数时具有较高的准确性。这种一致性说明模型不仅在训练数据上表现良好，也能够有效地推广到未见过的数据（测试集）。训练集的 R² 为 0.8579，测试集的 R²为 0.8565。这一指标表示模型解释了大约 86%的数据变异性，接近于 1 意味着模型能够很好地捕捉数据的趋势。R²值的相似性表明模型在训练和测试数据上都表现出色，且没有出现过拟合的现象。综合来看，SVR 模型在预测脆弱性指数时展现了良好的性能。较低的 MSE 和 MAE 以及较高的 R²值表明，模型能够有效捕捉输入特征与目标变量之间的关系。这些结果不仅增强了对模型预测能力的信心，也为后续决策和政策制定提供了坚实的数据支持。

通过 2025 年至 2035 年预测好的输入特征变量，结合各经纬度坐标，对未来 2025-2035 的地区暴雨灾害脆弱性进行预测，预测结果如图 5.24 所示，红色区域表示该地区的暴雨灾害脆弱性指数更高，有更大的受灾风险。从图 5.24 可以观察到，在 2025 年至 2035 年期间，中国的暴雨灾害脆弱性区域逐渐向南部沿海地区转移。在 2025 年，云南省大部分地区、

广西全境、江苏省大部分地区以及山东省的部分区域仍被归入暴雨灾害的脆弱性区域范围内。然而，随着时间的推移，这些脆弱性区域的面积逐渐减少。其中，以云南省最为显著，其中大多数地区已经逐步摆脱了暴雨灾害脆弱性区域的范围。随着经济的不断发展，尤其是东南部沿海地区的经济发展和人口增长，当地的土地利用方式发生着深刻变化，城市化进程的加快改变着当地的土地利用格局，沿海城市的扩张导致了自然地表覆盖的减少，地表径流的增加导致了排水能力不断下降，增加了暴雨灾害的脆弱性。同时，气候变化也对暴雨灾害脆弱性区域的调整产生重要影响，全球的气候变暖使得降水模式发生变化，沿海地区在暴雨期间更容易发生内涝和洪涝灾害，进一步提升其在暴雨灾害中的脆弱性。





图 5.24 2025-2035 年均降水量 Getis-Ord Gi*分析

图 5.25 为 2025-2035 年间中国的暴雨灾害脆弱性区域叠加分析图，可以发现，2025-2035 年间，我国易遭受暴雨灾害，脆弱性较强的地区主要位于东南沿海的江苏、浙江、福建、广东、广西以及安徽、河南、湖北、四川、重庆、云南、贵州、湖南和江西等地。此外，在山东、辽宁、吉林和西藏等地也有部分区域位于暴雨灾害脆弱性区域范围内。东南沿海地区如江苏、浙江、福建等省份以及部分内陆省份如四川、重庆、湖北和湖南，均是我国经济活动和人口高度集中的区域。高密度的人口和经济活动不仅增加了对土地和水资源的

压力，还提高了暴雨灾害潜在影响的严重程度。大规模的城市开发项目导致自然植被和湿地的大量消失，转而被不透水的建筑物和道路覆盖，这显著减少了地面的自然吸水能力，增加了暴雨期间的地表径流，从而提升了这些区域暴雨灾害的脆弱性。在江苏、安徽、河南、湖北等农业发达地区，农田高强度利用会导致土地的结构变得紧密，吸水能力下降，使得这些区域在遭遇暴雨时更易受到灾害影响。气候变化导致全球气温升高，水循环加速，引发更多的极端天气事件，如强降雨和台风。这些气候变化影响使东南沿海地区、南部和部分内陆地区更易遭受频繁和强烈的暴雨袭击，导致暴雨灾害脆弱性显著增加。东亚夏季风和西南季风的强度和路径变化，也容易使得长江中下游和华南地区的降水模式发生变化，进一步增加了这些地区在暴雨期间的风险。




图例：—— 国界线 —— 省界 —— 海岸线
 异常值点：■ 99%置信区间异常降雨极大值点 ■ 95%置信区间异常降雨极大值点
 ■ 99%置信区间异常降雨极小值点 ■ 95%置信区间异常降雨极小值点

图 5.25 2025-2035 年年均降水量 Getis-Ord Gi*叠加分析

图 5.26 为基于 Anselin Local Moran's I 的 2025-2035 年降水量分析。从图中可以发现，2025-2035 年间，我国降水量分布的 H-H 聚类（高-高聚类）区域与暴雨灾害脆弱性区域分布大致吻合，主要集中于东南沿海地区，L-L 聚类（低-低聚类）区域主要分布于西北内陆地区。此外，在东部沿海的江苏、浙江、福建、广东、广西和海南；西南部内陆地区的云南和西藏边境区域，还存在一些 L-H 聚类（低-高聚类）区域，这些区域当地的降雨量相对于周边地区较少，更加容易遭受暴雨灾害的侵袭。东南沿海地区由于受季风和台风影响，降水强度和频率增加，使得这些区域成为降水量的 H-H 聚类区域，同时也是暴雨灾害的高脆弱性区域。西北内陆地区本来就是干旱半干旱地区，气候变暖进一步加剧了这些地区的干旱情况，使得降水量减少，形成 L-L 聚类区域。东南沿海地区靠近海洋，地形复杂且多为丘陵和盆地，这些地理特征容易积聚水汽，导致降水量增加。同时，这些地区海拔较低，排水能力有限，更容易在暴雨期间受到威胁。在一些 L-H 聚类区域，如江苏、浙江、福建、广东和广西等地，虽然总体降水量较高，但由于某些局部地区的森林砍伐和农业开发，导致这些地区的植被覆盖减少，使得本身降雨量少的区域也容易受到暴雨灾害的影响。L-H 聚类区域的存在表明，这些区域虽然降水量低，但依然容易受到极端气候事件的影响。东部沿海和西南边境地区时常受到突如其来的强降雨事件的冲击，某些年份的降水异常使得

这些区域更加脆弱。同时，L-H 聚类区域的基础设施和防灾能力可能不如 H-H 区域，这些区域在遭遇极端降水事件时，因准备不足而更容易蒙受暴雨灾害的侵袭。



图例：——国界线 ——省界 ——海岸线
Anselin Local Moran's I 聚类结果： L-L 聚类 H-H 聚类 L-H 聚类
图 5.26 基于 Anselin Local Moran's I 的 2025-2035 年降水量分析

5.3 本章小结

在本章中，通过提取地形、降雨、土地利用等相关数据，并基于 XGBosst 算法进行交互探索，讨论三方面因素在暴雨成灾过程中的临界条件和交互作用。使用熵值法，从自然触发因素、物理脆弱性和土地脆弱性三方面及结算地区的暴雨灾害脆弱性指数。通过 ARIMA 算法，分别预测降雨量和耕地、林地、草原、灌木、湿地四类土地覆盖类型的变量自相关变化情况，预测 2025-2035 年各个变量的未来取值，并借助 SVR 算法预测 2025-2035 年间的暴雨灾害脆弱性指数，并通过 ArcGIS 软件在地图中实现可视化，同时基于 Anselin Local Moran's I 聚类评估高暴雨灾害脆弱区域中在暴雨形成过程中最容易受到威胁的 L-H 聚类点。本章的主要结论如下：

- (1) 暴雨成灾的临界条件主要包括：低纬耕地地区（纬度 $\leq 35.5^{\circ}\text{N}$ ），高降雨趋势（ > 0.759 ），低土地覆被（ ≤ 0.067 ），中低降雨量（ $> 96.656\text{mm}$ ）；低纬东部草地地区（经度 $> 113.6^{\circ}\text{E}$ ，纬度 $\leq 35.5^{\circ}\text{N}$ ），低降雨趋势（ ≤ 0.759 ），中低土地覆被（ > 0.089 ），中高降雨量（ $> 430.469\text{mm}$ ）；中高纬度东部地区（经度 $> 113.6^{\circ}\text{E}$ ，纬度 $> 35.5^{\circ}\text{N}$ ），高降雨趋

势 (>1.307)，高海拔高度 (>3840.559)；低纬度地区 (纬度 $\leq 35.5^{\circ}\text{N}$)，高降雨趋势 (>0.893)，中低土地覆被 (>0.089)，中高海拔高度 ($>60.153\text{m}$)，较高降雨量 ($>628.906\text{mm}$)；低纬东部灌木丛地区 (经度 $>113.6^{\circ}\text{E}$ ，纬度 $\leq 35.5^{\circ}\text{N}$)，低降雨趋势 (≤ 0.759)，中低土地覆被 (>0.023)，中高降雨量 ($>430.469\text{mm}$)。

(2) 通过对暴雨灾害脆弱性指数的计算和未来 2025-2035 年预测，并进行可视化。可以发现，2025-2035 年高暴雨灾害脆弱性指数的地区主要集中于东南沿海的江苏、浙江、福建、广东和广西地区；周边的山东、河南、安徽、湖北、湖南、贵州、云南、江西等省份；东北的吉林、辽宁的边境区域；西藏的藏南地区。进一步，基于 Anselin Local Moran's I 的 2025-2035 年降水量聚类分析，可以发现，高-高聚类的省份与暴雨脆弱性指数较高的省份大致重合；同时，在东南沿海的江苏、浙江、福建、广东和广西；云南、西藏等省份的边境区域，存在着一些低-低聚类点，这些区域本身降雨量水平相对较低，但又处于高降水、高暴雨灾害脆弱性区域周边，容易受到突如其来的强降雨事件的冲击，因准备不足而更容易蒙受暴雨灾害的侵袭。

六、问题四求解及分析

6.1 问题描述

问题 4 要求本文在利用前三问的分析结果的基础上，结合地理大数据^[25-28]，建立一个数学模型，以描述中国土地利用变化的特征与结构。具体而言，任务包括通过数据简化和综合方法，揭示土地利用变化的主要特征和结构演变，并从准确性和有用性两个方面进行验证。

首先，通过标准差椭圆统计，从多个角度分析土地利用变化情况。具体步骤包括计算重心、重心位置偏移、椭圆面积变化等指标。从这些指标中，得出耕地、林地、草地、灌丛和湿地等多种土地类型的利用变化情况。基于这些指标的动态变化，揭示出不同土地利用类型的主要特征和结构演变。例如，重心位置的偏移可以反映出土地利用类型在空间上的迁移，而椭圆面积的变化可以反映出利用强度的变化。此外，这些分析将帮助本文理解不同时间节点上的土地利用变化，进而提供指导性的见解。

在此基础上，需要进一步验证结果的准确性。具体方法是通过测算各类数据的分布情况，并结合置信区间的分布范围，来评估结果的准确性。置信区间的分析可以帮助本文理解计算结果的置信水平，提高预测的可靠性。如果数据点大部分落在置信区间内，这说明本文的模型具有较高的准确性。

最后，为了验证模型结果的有效性，需要将耕地、林地、草地、灌丛和湿地等土地利用类型的分布图像与人口分布和 GDP 分布的点数据进行叠加比较。通过叠加分析，观察到不同土地利用类型在地理空间上的分布规律，以及其与经济活动和人口分布的关系。在此过程中，标准差椭圆的分布情况将作为主要参考，通过与地理大数据的匹配程度来说明结果的有效性。

6.2 问题求解

6.2.1 1990-2020 年间中国土地利用的分布与重心变化

(1) 标准差椭圆基本原理

如图 6.1 所示，标准差椭圆（Standard Deviation Ellipse, SDE）是地理空间统计中的一个重要概念，主要用于描述和分析点数据的空间分布特征，以理解地理现象的空间分布趋势、方向性和集中程度。通过将输入的点要素转化为一个标准化的椭圆进行计算，以反映数据的空间分布情况。其中，标准差椭圆的中心点通常为所有观测点的平均重心（mean center），长轴和短轴分别表示数据分布的主要和次要方向，而标准差椭圆的大小反映数据的离散程度。




图 6.1 标准差椭圆的基本原理

假设存在 n 个观测点，每个观测点的坐标为 (x_i, y_i) 。对标准差椭圆的计算过程如下：

(1) 计算观测点的平均重心 $(\bar{x}, \bar{y})$ ：

$$\bar{x} = \sum \frac{x_i}{n}, \quad \bar{y} = \sum \frac{y_i}{n} \quad (6-1)$$

(2) 计算角度旋转:

$$\tan\theta = (a-b)/c \quad (6-2)$$

其中:

$$a = \sum (x_i - \bar{x})^2, \quad b = \sum (y_i - \bar{y})^2, \quad c = 2 \sum (x_i - \bar{x})(y_i - \bar{y}) \quad (6-3)$$

(3) 计算长轴(σ_x)和短轴(σ_y)的标准差:

$$\sigma_x = \sqrt{\sum ((x_i - \bar{x}) \cos \theta - (y_i - \bar{y}) \sin \theta)^2 / n}, \quad \sigma_y = \sqrt{\sum ((x_i - \bar{x}) \sin \theta + (y_i - \bar{y}) \cos \theta)^2 / n} \quad (6-4)$$

(4) 计算椭圆面积:

$$Area = \pi \cdot \sigma_x \cdot \sigma_y \quad (6-5)$$

(5) 计算离心率:

$$e = \sqrt{1 - (\sigma_y^2 / \sigma_x^2)} \quad (6-6)$$

通过最终的结果计算,可以获得数据分布的整体趋势(标准差椭圆长轴),同时基于计算得出的椭圆面积的大小,可以得知数据的集中趋势,当椭圆面积越小时,数据分布越集中;椭圆面积越大时,数据分布越发散。同时通过计算椭圆的离心率,可以进一步了解数据的分布特征,当离心率接近 0 时,说明整体的分布近似于圆形,分布的方向性不明显,当离心率接近于 1 时则说明整体的分布呈现出了明显的线性特征,通过比较不同时期和不同类型的空间分布特征,能够揭示地理现象间的空间关系和模式。

(2) 中国土地利用的标准差椭圆计算




图 6.2 耕地分布及标准差椭圆变化

图 6.3 林地分布及标准差椭圆变化

代入标准差椭圆公式及筛选得出的相关坐标数据,分别计算我国 1990、2000、2010

和 2019 年耕地、林地、草地、灌丛和湿地的标准差椭圆分布变化情况，具体结果如下：

截止 2021 年，我国第三次国土调查结果显示，我国耕地面积 19.179 亿亩（共计 127.83 万平方千米），占我国国土总面积的 13.316%，以此为基准，筛选各年份中面积占比大于 13.316%的耕地栅格数据。导入 ArcGIS 中进行标准差椭圆的求解和分布中心的计算。耕地分布数据叠加 1990-2019 年全样本数据，标准差椭圆求解使用一倍标准差进行计算，所得结果如图 6.2 所示。

根据《2022 年中国国土绿化状况公报》显示，目前我国森林面积达 2.31 亿公顷，林地覆盖率达 24.02%，以此为基准，筛选各年份中面积占比大于 24.02%的林地的栅格数据。导入 ArcGIS 中进行标准差椭圆的求解和分布中心的计算。林地分布数据叠加 1990-2019 年全样本数据，标准差椭圆求解使用一倍标准差进行计算，所得结果如图 6.3 所示。

根据国家林草局 2021 年公布的中国林草资源及生态状况数据，可以发现，我国草原面积 39.68 亿亩，草地综合植被覆盖度为 50.32%。以此为基准，筛选各年份中面积占比大于 50.32%的草地栅格数据。导入 ArcGIS 中进行标准差椭圆的求解和分布中心的计算。草地分布数据叠加 1990-2019 年全样本数据，标准差椭圆求解使用一倍标准差进行计算，所得结果如图 6.4 所示。




图 6.4 草地分布及标准差椭圆变化

图 6.5 灌木分布及标准差椭圆变化

由于国内并无灌丛覆盖的详细数据，参考林地覆盖面积和相关比例，同样将 24.02%作为基准，筛选各年份中面积占比大于 24.02%的灌丛面积的栅格数据。导入 ArcGIS 中进行标准差椭圆的求解和分布中心的计算。灌丛分布数据叠加 1990-2019 年全样本数据，标准差椭圆求解使用一倍标准差进行计算，所得结果如图 6.5 所示。

根据《全国湿地保护规划（2022-2030 年）》，目前我国湿地面积约为 5635 公顷，合计 0.005635 万平方千米，占我国国土总面积的 0.00000587%，以此为基准，筛选各年份中面积占比大于 0.00000587%的湿地栅格数据。导入 ArcGIS 中进行标准差椭圆的求解和分布中心的计算。湿地分布数据叠加 1990-2019 年全样本数据，标准差椭圆求解使用一倍标准

差进行计算，所得结果如图 6.6 所示。

求解得出的各年份标准差椭圆的基本信息如表 6.1 所示：

通过对图 6.2 和表 6.1 的综合分析，本文可以得出以下结论：在 1990 年至 2019 年这三十年间，中国耕地用地的空间分布格局呈现出显著的“东北-西南”走向。这种分布模式反映了我国地形、气候和历史耕作习惯等多重因素的综合影响。东部地区存在大量的平原和盆地，同时处于季风气候区，降水丰沛，土地肥沃，适于进行大规模的农业生产，这些有利因素为耕地用地“东北-西南”方向的分布奠定了重要基础。值得注意的是，高密度耕地用地的分布重心呈现出明显的西北迁移趋势。具体而言，标准差椭圆的重心由 1990 年的河南省武陟县逐步向西北方向移动，到 2019 年已迁移至山西省泽州县。这一现象可能与西部大开发战略的实施、农业技术的进步以及气候变化等因素密切相关。政策性的导向，尤其是西部大开发战略的实施，可能是促进耕地空间分布向西北方向偏移的重要因素，随着现代灌溉技术、机械化耕作和优良品种推广等农业技术的引入，使得部分气候土地条件欠佳的西部地区也能够得以进行高效的农业生产活动，促进这些地区高密度耕地的形成和扩展。同时，本文观察到标准差椭圆的面积呈现逐年递增的趋势，我国高密度耕地的空间分布范围正在不断扩大。这种扩张可能是由多项农业政策的实施、耕地保护措施加强以及农业现代化进程的推进所驱动的。




图 6.6 湿地分布及标准差椭圆变化

通过对图 6.3 和表 6.1 的综合分析，本文可以得出以下结论：在 1990 年至 2019 年这三十年间，从 SDE 重心坐标和位置来看，林地的重心在不同时间节点上主要集中在河南省的几个县市，这表明该区域在林地分布上具有一定的稳定性。同时，重心位置的变化走向为“西南方向”和“西北方向”的移动反映了该地区林地的分布发生了空间上的转移，这可能与区域内的土地利用变化、植被恢复政策及人类活动密切相关。其次，SDE 面积的变化（如 453.1 万 km²到 483.6 万 km²）表明在这一期间林地的总面积经历了小幅波动。整体的平稳趋势可能反映出国家在林业管理和生态保护方面的政策效果，尤其是在植树造林和生态恢复项目的推动下，林地面积有所回升。最后，SDE 分布方向保持在东北-西南方向，反映出林地在空间分布上的一致性，表明在这一方向上的生态环境相对稳定，适宜林地生长。这一方向的持续性可能与当地的气候、土壤条件及水资源状况密切相关。

通过对图 6.4 和表 6.1 的综合分析，本文可以得出以下结论：在 1990 年至 2019 年这

三十年间,草地用地的 SDE 重心坐标集中在青海省德令哈市附近,这表明该区域草地资源的稳定分布,反映了青海独特的自然条件,如适宜的气候、丰富的水源和良好的土壤特性,这些因素共同支持着草地生态系统的形成与维持。尽管重心的移动情况显示出向“西北”和“西南”的变化,表明该地区草地利用的空间变动,这可能与生态环境变化和人类活动的双重影响有关。特别是西北方向的移动可能与草地退化、过度放牧或土地利用方式的调整密切相关,这种现象在经济发展和资源利用加剧的背景下尤为明显。草地用地面积从 570.5 万 km²逐步减少至 551.5 万 km²,揭示草地资源在这一时间段内面临着明显的压力,可能源于过度利用、气候变化、以及城市化进程等多重因素的叠加影响。过度放牧和不合理的土地开发不仅导致草地的减少,还可能引发土壤退化和生物多样性的降低,进而影响生态平衡。与此同时,草地的分布方向保持在“东北-西南”,表明该区域的草地资源在空间分布上具有一致性。这一方向性可能与当地的自然地理特征、风力、水流方向及人类活动密切相关,说明草地生态系统在一定程度上维持了其稳定性,尽管面临着环境压力与资源利用的挑战。因此,针对该区域的草地管理与保护措施显得尤为重要,以确保生态系统的可持续性和草地资源的合理利用。

表 6.1 各类土地类型标准差椭圆变动情况

土地利用类型	标准差椭圆指标	1990	2000	2010	2019
耕地 (cropland)	SDE 重心坐标	(113.511°E, 35.038°N)	(113.492°E, 35.187°N)	(113.313°E, 35.358°N)	(112.763°E, 35.582°N)
	SDE 重心位置	河南省武陟县	河南省修武县	河南省修武县	山西省泽州县
	SDE 重心移动情况	-	西北方向	西北方向	西北方向
	SDE 面积	423.9 万 km ²	442.4 万 km ²	467.5 万 km ²	508.3 万 km ²
	SDE 分布方向	东北-西南	东北-西南	东北-西南	东北-西南
林地 (forest)	SDE 重心坐标	(114.675°E, 35.108°N)	(113.464°E, 33.899°N)	(112.195°E, 33.815°N)	(112.002°E, 33.837°N)
	SDE 重心位置	河南省长垣市	河南省襄城县	河南省襄城县	河南省栾川县
	SDE 重心移动情况	-	西南方向	西北方向	西南方向
	SDE 面积	453.1 万 km ²	435.1 万 km ²	484.1 万 km ²	483.6 万 km ²
	SDE 分布方向	东北-西南	东北-西南	东北-西南	东北-西南
草地 (grass)	SDE 重心坐标	(97.275°E, 37.207°N)	(96.795°E, 37.293°N)	(96.535°E, 37.274°N)	(96.469°E, 37.137°N)
	SDE 重心位置	青海省德令哈市	青海省德令哈市	青海省德令哈市	青海省德令哈市
	SDE 重心移动情况	-	西北方向	西南方向	西南方向
	SDE 面积	570.5 万 km ²	559.8 万 km ²	556.0 万 km ²	551.5 万 km ²
	SDE 分布方向	东北-西南	东北-西南	东北-西南	东北-西南
灌木丛	SDE 重心坐标	(100.528°E, 35.969°N)	(98.495°E, 37.417°N)	(97.473°E, 38.332°N)	(97.014°E, 38.702°N)

(shrub)	SDE 重心位置	青海省共和县	青海省天峻县	青海省德令哈市	甘肃省肃北蒙古族自治县
	SDE 重心移动情况	-	西北方向	西北方向	西北方向
湿地 (wetland)	SDE 面积	462.5 万 km ²	432.67 万 km ²	410.4 万 km ²	392.4 万 km ²
	SDE 分布方向	西北-东南	西北-东南	西北-东南	西北-东南
	SDE 重心坐标	(105.738°E, 36.648°N)	(105.814°E, 36.623°N)	(105.798°E, 36.640°N)	(106.604°E, 37.529°N)
	SDE 重心位置	宁夏回族自治区海原县	宁夏回族自治区海原县	宁夏回族自治区海原县	宁夏回族自治区吴忠市
	SDE 重心移动情况	-	东南方向	西北方向	东北方向
	SDE 面积	690.3 万 km ²	688.2 万 km ²	688.7 万 km ²	671.0 万 km ²
	SDE 分布方向	东北-西南	东北-西南	东北-西南	东北-西南

通过对图 6.5 和表 6.1 的综合分析，本文可以得出以下结论：在 1990 年至 2019 年这三十年间，灌木丛的 SDE 重心坐标主要集中在青海省的共和县、天峻县和德令哈市，以及甘肃省的肃北蒙古族自治县，表明这些地区是灌木丛资源的关键分布区域。重心位置的变化趋势向“西北方向”移动，反映出灌木丛的空间分布在一定程度上受到了生态环境变化和人类活动的影响，尤其是土地开发和气候变化的双重作用。SDE 面积的逐步减少，从 462.5 万 km²下降至 392.4 万 km²，显示出灌木丛资源在这一时间段内的显著减少，可能与过度开发、草地转化以及生态环境恶化有关。这样的趋势不仅表明了灌木丛面积的减少，还可能影响到区域生态系统的稳定性和生物多样性，增加了土壤侵蚀和水土流失的风险。同时，灌木丛的分布方向保持在“西北-东南”，表明该区域的灌木丛资源在空间分布上呈现出一致性。这一方向性可能与地形、气候和水文条件的变化密切相关，表明这些区域具有相对适宜的生长环境。尽管面临面积减少的挑战，但灌木丛在空间上的分布一致性提示了其生态系统的相对稳定性。

通过对图 6.6 和表 6.1 的综合分析，本文可以得出以下结论：在 1990 年至 2019 年这三十年间，湿地的 SDE 重心坐标主要集中在宁夏回族自治区的海原县和吴忠市，这表明这些地区是湿地资源的重要分布区域。湿地重心位置的变化显示出“东南方向”、“西北方向”及“东北方向”的移动，反映出湿地的空间分布在一定程度上受到生态环境变化与人类活动的影响。例如，“东南方向”的移动可能与区域内水资源管理和土地利用变化有关，而“西北”和“东北”方向的移动则可能与气候变化和土地开发等因素相关。SDE 面积的变化从 690.3 万 km²逐渐减少至 671.0 万 km²，显示出湿地资源在这一时间段内的整体减少。这一趋势可能源于城市化、农业扩张和水资源的过度开发等因素的叠加，导致湿地面积的萎缩。这种减少不仅影响湿地生态系统的功能，还可能加剧水土流失和生物多样性降低的问题。湿地的分布方向始终保持在“东北-西南”，表明该区域湿地资源在空间分布上的一致性。这种方向性可能与自然地理特征、水流方向和气候条件密切相关，表明这些区域的湿地生态系统在一定程度上维持了其稳定性，尽管整体面积呈下降趋势。

6.2.2 准确性验证

(1) 数据分布检查

为验证标准差椭圆计算结果的有效性，需要通过检查数据的分布形态来进行确认。具体而言，标准差椭圆假设数据分布接近正态分布，因此应关注数据是否满足这一关键假设。

可以使用直方图、核密度估计（KDE）图等可视化工具来查看数据的总体分布形态。如果数据的分布接近钟形曲线，即呈现正态分布的特征，那么可以初步认为标准差椭圆的运用是合理的。通过可视化和形态分析，能够确保所计算的标准差椭圆在统计基础上的有效性。

如图 6.7 所示，图形显示数据密度在横轴上的变化情况，KDE 曲线在 0.2 附近达到峰值，表明在该范围内的数据密度最高，图形整体呈现单峰分布的特征，KDE 曲线在连段逐渐接近于 0，极端值（0-1）附近的数据相对较少。在 1990-2019 年间，高密度耕地用地覆盖率分布数据主要集中在 0.2-0.8 区间并逐渐向两端分布，形成一个主峰和次峰的结构，这种分布在一定程度上满足了正态分布的假设，数据的集中趋势符合标准差椭圆计算假设下的数据集中性要求。尽管在 0.6 附近存在一个次峰，但是其密度相对较低且均匀分布，在验证标准差椭圆的有效性过程中影响不大。




图 6.7 耕地(cropland)覆盖率数据分布检查

如图 6.8 所示，在 1990 至 2019 年间，KDE 曲线在 0.3 附近达到了峰值，表明该范围内的数据密度最高。在 1990 至 2000 年间，曲线整体呈现单峰分布特征，而在 2010 至 2019 年间则表现出双峰分布特征。KDE 曲线末端逐渐接近于 0，极端值（0-1）附近的数据相对较少。三十年来，高密度林地用地覆盖率的分布数据主要集中在区间[0.3, 0.7]，并逐渐向两端扩展，形成一个主峰和一个次峰的结构。这种分布在一定程度上满足了正态分布的假设，且数据的集中趋势符合标准差椭圆计算假设下的数据集中性要求。尽管在 0.7 附近存在一个次峰，其密度相对较低且分布均匀，但对标准差椭圆有效性的验证影响不大。







图 6.8 林地(forest)覆盖率数据分布检查

如图 6.9 所示，在 1990-2019 年间，KDE 曲线在接近 1.0 的位置达到了其峰值，这说明该区间内数据点的密集程度最高。整个时间段内，曲线形态展现出双峰分布的特点，两端逐渐趋于平缓并接近 0 值，而极端值（0-1）的数据点则较为稀少。特别地，关于高密度草地用地的覆盖率数据，其主要集中分布在 $[0.55, 1.0]$ 的区间内，并随时间向区间两端扩展，形成了主、次两个明显的峰值区域。这种分布模式与正态分布的特征有一定的相似性，同时满足标准差椭圆分析中对数据集中性的基本假设。尽管在 0.55 附近存在一个次高峰，但其密度相较于主峰较低且分布较为均匀，因此这一特征对标准差椭圆方法用于分析数据集中趋势的有效性不构成显著影响。






(c)2010




(d)2019

图 6.9 草地(grass)覆盖率数据分布检查


如图 6.10 所示，在 1990 至 2019 年间，KDE 曲线在接近 0.3 处达到峰值，由此可见该区间内的数据点密集程度最高。整个时间跨度内，曲线呈现出双峰分布的特征，两端逐渐平缓并接近 0，而极端值（0-1）的数据点稀疏分布。高密度灌木丛用地的覆盖率数据主要集中在[0.3, 0.9]区间，并逐渐向两端扩展，形成明显的主峰和次峰。这种分布模式类似于正态分布特征，并满足标准差椭圆分析中对数据集中性的基本假设。尽管在 0.9 处存在次高峰，但其密度相对主峰较低且分布均匀，因而对标准差椭圆分析数据集中趋势的有效性影响有限。




(a)1990



(b)2000



(c)2010



(d)2019

图 6.10 灌丛(shrub)覆盖率数据分布检查

如图 6.11 所示，从 1990 年至 2019 年间，KDE 曲线在约 0.02 的位置达到峰值，表明该区间内数据点具有最高的密集度。在整个时间范围内，曲线呈现出一个典型的单峰分布形态，其两侧逐渐变得平缓并最终趋近于 0，而极端值（即接近 0 或 1 的数值）则表现出较为稀疏的分布特点。对于高密度湿地用地的覆盖率数据，其主要集中分布在[0.0, 0.5]的区间内，并随着数值的增大或减小而逐渐向区间两端扩展，形成了一个鲜明的主峰。这种数据分布模式与正态分布的特征相吻合，同时也满足了标准差椭圆分析对数据集中趋势进行量化评估的基本假设条件。值得注意的是，KDE 曲线在整个观察期间内仅在 0.02 附近存在一个显著的高峰，并未出现其他明显的次峰，这进一步证实了数据的集中性和单一性。因此，这种分布特点对标准差椭圆分析在评估数据集中趋势方面的有效性影响是有限的，即标准差椭圆能够准确地反映数据的主要集中区域。




图 6.11 湿地(wetland)覆盖率数据分布检查

(2) 置信区间验证

在置信区间验证中，需要通过计算数据点实际落在标准差椭圆内部的比例并与预期比例进行比较，验证标准差椭圆建立的准确性。图 6.12 为标准正态分布曲线，深蓝色区域为距离平均值小于一个标准差之内的数值范围，在正态分布中，此范围所占比率应为全部数值之和的 68%，两个标准差之和比率合计应为 95%，三个标准差之内的比率合计应为 99%。因此，在单个标准差椭圆内，应有 68%的样本点数量，证明其通过置信区间的验证。

图 6.13 为耕地数据置信区间检验结果，根据图 6.13 可以发现，68%比例的高密度耕地数据分布于一个标准差范围内的标准差椭圆中，同时结合图 6.7 中的验证结果，其大致

符合标准正态分布，因此，通过数据分布检查和置信区间验证，证明了标准差椭圆的准确性，可以确认标准差椭圆的估计结果在统计意义上是合理而准确的。




图 6.12 标准正态分布曲线

图 6.14 展示了林地数据的置信区间检验结果。根据图 6.14 可以得出，68%的高密度林地位置数据分布在一个标准差范围内的标准差椭圆中。同时结合图 6.8 中的验证结果，可以看出数据大致符合标准正态分布。因此，通过数据分布检查和置信区间验证，证明了标准差椭圆的准确性，可以确认标准差椭圆的估计结果在统计意义上是合理且准确的。




图 6.13 耕地数据置信区间验证结果


图 6.14 林地数据置信区间验证结果

图 6.15 显示了草地数据的置信区间检验结果。从图中可以看出，高密度草地位置数据的 68%分布在一个标准差范围内的标准差椭圆中。同时结合图 6.9 中的验证结果，可以得知数据大致符合标准正态分布。因此，通过数据分布检查和置信区间验证，可以证明标准差椭圆的准确性，并确认其估计结果在统计上是合理且准确的。

图 6.16 展示了灌丛数据的置信区间检验结果。根据图 6.16 可以观察到，68%的高密度灌丛位置数据位于一个标准差范围内的标准差椭圆中。同时结合图 6.10 中的验证结果，可以看到数据大致符合标准正态分布。因此，通过数据分布检查和置信区间验证，证明了标准差椭圆的准确性，可以确认标准差椭圆的估计结果在统计意义上是合理且准确的。


图 6.17 展示了湿地数据的置信区间检验结果。通过图 6.17，可以看到 68%的高密度湿地位置数据分布在一个标准差范围内的标准差椭圆中。同时，结合图 6.11 中的验证结果，

数据大致符合标准正态分布。因此，通过数据分布检查和置信区间验证，证明了标准差椭圆的准确性，可以确认标准差椭圆的估计结果在统计意义上是合理且准确的。




■标准差椭圆内点 ■非标准差椭圆内点

图 6.15 草地数据置信区间验证结果



■标准差椭圆内点 ■非标准差椭圆内点

图 6.16 灌丛数据置信区间验证结果



■标准差椭圆内点 ■非标准差椭圆内点

图 6.17 湿地数据置信区间验证结果

6.2.3 有效性验证

(1) 标准差椭圆与人口数据的结合及地理分界划分

将 1990 年至 2019 年间的耕地、林地、草原、灌丛和湿地的标准差椭圆与 1990 年至 2020 年的人口分布数据相结合分析（图 6.18），已验证其有效性。通过验证可以发现，连接高密度湿地标准差椭圆的长轴线，并将之与边界城市衔接，可以绘制出一条横跨吉林省延边朝鲜族自治州和龙市及西藏自治区日喀则地区仲巴县的地理分界线段（下文中简称“和仲线”）。在“和仲线”以东的区域，汇集了中国主要的人口分布聚集地和大部分的开垦耕地、大部分的林地，半数的湿地，接近半数的草地和部分灌丛用地。在“和仲线”以西区域则汇集了大部分的灌丛用地和草地用地，半数的湿地，部分的林地和开垦土地，以及少部分的人口聚集区域。因此，通过标准差椭圆能够进行地理和生态区域的有效划分，以揭示不同土地利用类型和人口分布的空间模式，证明了方法的有效性。

(2) 标准差椭圆与经济数据的结合及地理分界划分

图 6.19 展示了我国 1990-2020 年间 GDP 均值^[29,30]的分布情况，图中点要素为 GDP 值高于全国平均取值的热点要素，从蓝色到红色，颜色越深代表当地经济发展水平越高。通过标准差椭圆与经济数据的结合，可以观察到经济高值区域的分布集中在东部沿海地区，即和仲线东部地区，这与 GDP 分布的空间格局基本吻合。红色点较为密集的区域，例如东南沿海，京津冀和长三角地区，这些区域经济发展水平较高，与其人口密度和经济活动的集中度高度相关。与此同时，低 GDP 的浅色区域大多分布在西部内陆及东北部分地区，这些地区的经济发展水平较低，GDP 贡献较小，这也进一步反映了经济地理的分布不均衡性。标准差椭圆的空间变化能够验证这种分布特征：在经济发达区域，椭圆的分布方向与经济活动的密集度方向相一致，而在经济较为落后的区域，椭圆则呈现更为分散的分布，说明这些区域经济发展较为滞后。




图 6.18 标准差椭圆与人口数据的结合及地理分界划分

(3) 标准差椭圆与降雨数据的结合及地理分界线划分

如图 6.20 所示，图中通过标准差椭圆展示了 1990-2020 年降水数据、人口密度及经济活动之间的空间关联性，结合地理分界线进行了冷热点分析。红色区域代表降水异常或，表明这些区域内降水量呈现显著过高的特征。结合降水异常分布与人口密度、经济活动的来看，东南部沿海经济发达、人口密集地区的降水异常相对较多，表明这些地区的用地量与降水分布不均衡。与此同时，通过异常值聚类分布分析揭示了降水异常与经济、人口之间的复杂互动关系。降水异常点的集中区域与标准差椭圆的重心、方向相一致，这进一步验证了标准差椭圆方法的有效性。通过降水异常与用地量的结合分析，可以发现区域经济活动的扩展与降水量异常情况密切相关，表明自然资源的变化对人类活动和经济发展具有重要影响。




图 6.19 标准差椭圆与经济数据的结合及地理分界划分




图 6.20 标准差椭圆与降雨数据的结合及地理分界划分

6.2.4“和仲线”的提出及比较

基于 6.2.3 中对有效性验证的相关内容，本章提出了一条连接吉林省和龙市至西藏自治区仲巴县的“和仲线”（见图 6.21），用以作为区域开发情况划分的分界线。这条和仲线不仅涵盖了中国东部的经济和人口密集区域，还包括了中国绝大多数的耕地、林地、大约一半的湿地面积、部分草地以及少部分的灌木地。这条线在一定程度上也平衡了南北方经济区域之间的关系，与博台线^[31]相结合，“和仲线”将中国划分为四大主要区域：

西北部林地灌木未开发区域：包括黑龙江全境，吉林省大部分，辽宁省、河北省、甘肃省、宁夏回族自治区、新疆维吾尔自治区部分区域。此区域主要是未开发的林地和灌木丛分布地带。

西南部林地灌木未开发区域：包括新疆维吾尔自治区大部分，西藏自治区、青海省、甘肃省的部分区域。此区域同样主要由未开发的林地和灌木丛组成。

东北部人口经济密集带：包括北京、天津、河南、安徽、江苏、浙江全境，以及河北省、山西省的大部分地区，陕西省、湖北省、江西省、福建省的部分地区。这个区域是人口和经济活动高度集中的带状区域。

东南部人口经济密集带：位于东南部沿海地区，是另一重要的人口和经济密集带。

特别注意的是，由于大部分降水异常区域集中在中国的东南沿海地区，因此，东南部人口经济密集带的人与自然资源关系最为紧张，这一区域受到资源 and 环境压力的影响尤为严重。通过这种空间划分，不仅可以更好地理解中国不同区域的开发情况与生态、经济之间的关系，也为进一步的区域规划和资源管理提供了重要依据。




图 6.21 胡焕庸线、博台线、和仲线的比较

6.3 本章小结

在本章中，通过导入耕地、林地、草原、灌木和湿地五类土地利用类型的空间分布点要素，并计算标准差椭圆，观察标准差椭圆的重心移动、面积变化，总结了五类土地类型的变化特征与结构，并通过数据分布检查和置信区间验证两种方式分别探讨标准差椭圆绘

制结果的准确性和有效性。基于有效性的验证结果，提出了一条连接吉林省和龙市至西藏自治区仲巴县的“和仲线”，用以划分区域开发的基本情况，本章主要结论如下：

（1）耕地 *cropland*、林地 *forest*、草地 *grass*、湿地 *wetland* 的空间分布整体生均呈现“东北-西南”的分布态势，灌木丛 *shrub* 的空间分布呈现“西北-东南”的分布态势。随着时间的演化，耕地、林地、灌木丛三类用地整体上均向西北内陆地区移动；草地用地分布整体上向西南方向移动；湿地整体上向东北方向移动。耕地、林地两类土地的分布呈现逐渐扩张的趋势；草地、灌木丛和湿地三类土地的分布整体上呈现聚集收缩的态势。

（2）通过对标准差椭圆结果的准确性验证和有效性分析，本文提出了一种新的划分国土区域空间的思路：连接吉林省和龙市到西藏自治区仲巴县的“和仲线”，“和仲线”整体上与胡焕庸线相一致，其东部区域包括为人口密集、经济发达的地区，而西部地区则多为由湿地、灌木丛和草地等用地类型组成的人口分布稀疏、开发程度较低的未开发区域。进一步，“和仲线”与“博台线”相交，共同构成了国内资源开发的四个象限：均由大量未开发林地、湿地和灌丛租车的西北部林地灌木未开发区域和西南部林地灌木未开发区域；人口密集，耕地、林地用地集中的东北部人口经济密集带；同样人口密集，耕地林地集中，但降雨异常事件频发，生态环境较为脆弱的东南部人口经济密集带。



图 6.22 西藏仲巴县



图 6.23 吉林和龙市

七、结论与展望

7.1 研究结论

通过对多源异构数据的系统处理与分析,将像素坐标转换为地理空间坐标,有效提取空间坐标信息。通过数据重采样和投影技术,直观展示了 30 年间降水和土地利用的时空变化模式,深入剖析土地利用的长期变化趋势和特征。基于这些分析,本文得出如下结论:

我国年平均降水量分布呈现显著的地域差异,这种差异主要受到山系分布和山脉走势的影响。东南沿海地区降水丰沛,而西北内陆地区降水相对稀少,二者形成鲜明的空间对比。值得注意的是,受厄尔尼诺-南方涛动(ENSO)等大尺度气候现象的影响,我国整体降水潜力呈现上升趋势,降水带逐渐向北扩展。同时,ENSO 事件发生的频率和强度趋于规律化和温和化,导致年际降水波动逐渐稳定。在土地利用方面,我国呈现明显的空间聚集趋势。这种格局的形成和演变受到人口压力、气候变化等多重因素的持续影响和塑造。特别是在经济发达地区和人口密集区,土地利用强度和类型的变化尤为显著。

基于问题一中提取的气温、降水、高程和土地利用等数据,构建决策树模型,深入探讨地形和气候因素在暴雨极端天气形成过程中的作用机制和相互作用。通过分析决策规则,本文发现:

年平均降水量的空间分布主要受到气温、经纬度等因素的交互影响。在东部低纬度沿海地区,年平均降水量相对更高。高温地区的大气具有更强的水汽容纳能力,为区域降水提供了充足的水源。同时,高温还能促进大气对流,有利于云的形成与发展,增加降水概率。东部沿海地区受海洋气候和东亚季风的双重影响,水汽交换频繁,有利于形成更高的年降水量。在不同的温度和纬度条件下,暴雨的主导形成机制存在显著差异。例如,在东部低纬度丘陵地区,锋面系统和地形抬升效应往往是产生高强度降水的主要原因。而在东部低纬度平原地区,极端暴雨天气可能主要由海洋水汽输送和强烈的对流活动引发。

进一步,本文识别出极端暴雨天气的发生与气温、经纬度等因素之间存在复杂的交互相关关系。同时,降雨、土地利用状况和地形等因素能够在暴雨天气向灾害演变的过程中起到加剧或减缓的作用。基于这一认识,本文采用 XGBoost 算法深入分析了降雨、土地利用和地形三个方面因素的交互作用。此外,基于熵权法测度暴雨灾害脆弱性指数,并结合 ARIMA 模型和 SVR 算法对 2025-2035 年中国境内暴雨灾害脆弱性最高的地区进行预测。主要研究结论如下:

过高的降雨量、较高的海拔高度、较为稀疏的地表植被覆盖(如耕地、草地、灌木)以及东南部沿海的地理位置都可能加剧暴雨天气演变为灾害的过程。2025-2035 年期间,暴雨灾害脆弱性指数较高的地区主要集中在以下几个区域:东南沿海一带;长江以南的湖南、贵州、云南、江西等省份;北方的山东、辽宁和吉林等省份的部分区域。这一预测结果为未来防灾减灾工作的重点区域提供了科学依据。

最后,通过导入耕地、林地、草原、灌木和湿地五类土地类型的空间分布数据,计算高密度要素点分布的标准差椭圆,并分析标准差椭圆的重心、面积等关键指标。通过观察椭圆形状、重心移动和面积变化等因素,总结五类不同土地类型的变化特征与结构,并进行准确性和有效性的验证。主要结论如下:

耕地、林地、草地、湿地整体上呈现“东北-西南”方向的分布态势,灌木呈现“西北-东南”的分布态势。耕地、林地、灌木三类用地随时间逐渐向西北内陆方向移动,草地分布整体向西南方向移动,湿地整体向东北方向移动。耕地、林地呈现扩张趋势,草地、灌木和湿地整体上呈现收缩聚集的态势。通过数据分布检查和置信区间验证两种方法验证标准差椭圆分析结果的准确性,将标准差椭圆结果与人口、GDP 和降水数据进行叠加分析,以验证其有效性。基于这些分析,本文提出了一种新的国土区域空间划分思路:连接吉林省和

龙市到西藏自治区仲巴县的“和仲线”。这条线将国内资源开发区域划分为四个象限：西北部林地灌木未开发区域、西南部林地灌木未开发区域、东北部人口经济密集带和东南部人口经济密集带。这种划分方法为理解中国区域发展差异、制定区域协调发展策略提供了新的视角和依据。

7.2 未来展望

本文研究也存在一些不足之处：

（1）降水模式、暴雨天气的形成及其导致的灾害是一个多因素、高度复杂的系统。本研究虽然考虑了气温、土地覆盖类型、海拔高度等因素，但仍有诸多重要变量未能纳入分析框架。例如，当地河流径流量、城市化程度、基础设施建设水平等因素都可能对降水模式和暴雨灾害的发生产生显著影响。未来研究应当进一步拓展分析范围，深入探讨这些相关因素在降水形成、暴雨天气演变以及区域灾害发生过程中的作用机制和相互作用。特别是，应当着重关注不同因素之间的协同效应和非线性关系，以更全面地把握降水和暴雨灾害的动态特征。

（2）本研究采用年度数据进行分析，这种时间尺度可能无法有效捕捉短时间内发生的极端天气事件。考虑到暴雨灾害往往发生在较短的时间周期内，未来研究应当采用更细粒度的时间序列数据，如日均数据甚至小时级数据，以提高对极端天气事件的预测精度。这不仅能够增强研究结果的时效性，还能为灾害预警和应急响应提供更加及时和准确的信息支持。此外，高时间分辨率的数据分析还可能揭示出年度数据无法反映的季节性模式和短期波动，从而深化本文对降水和暴雨灾害形成机制的理解。

（3）自工业革命以来，人类活动对气候系统的影响日益显著，传统的气候变化预测模型可能已经不足以准确把握未来的气候变化趋势。因此，未来研究需要更加全面地考虑人类活动对气候变化的加速作用。这不仅包括工农业生产、交通出行、资源开采等直接影响因素，还应考虑土地利用变化、城市化进程、能源结构调整等间接影响因素。同时，应当建立更加复杂和动态的模型，整合社会经济发展情景、技术进步路径和政策调控措施等变量，以更好地模拟和预测人类活动与气候变化之间的相互作用。

参考文献

- [1] 陈述彭. 地理系统与地理信息系统 [J]. 地理学报, 1991, 46(1): 1-7.
- [2] 李亚云, 忻静, 丛婧. 多尺度人口空间大数据聚合模型在地图可视化中的研究与应用[J]. 测绘通报, 2024(03): 145-150.
- [3] 阎国年, 周成虎, 林琚, 陈旻, 乐松山, 温永宁. 地理综合研究方法的发展与思考 [J]. 科学通报, 2021, 66(20): 2542-2554.
- [4] 周秋雪, 康岚, 龙柯吉等. 基于稠密雨量观测的四川省复杂地形降水特征分析 [J/OL]. 高原气象, 1-9.
- [5] 陈结堂. 地理信息技术赋能国土空间规划实施监督和体检评估预警[J]. 测绘与空间地理信息, 2024, 47(07): 76-77+81.
- [6] 孙雪健, 李国栋, 任晓娟等. 城市扩张下安徽省土地利用变化及其生态环境效应 [J/OL]. 环境科学, 1-17.
- [7] 罗健梅, 阿布都热合曼·哈力克, 段越帆等. 艾比湖流域植被 NPP 时空演变特征及其驱动因素分析[J/OL]. 生态学报, 1-15.
- [8] 彭书时, 朴世龙, 于家烁, 刘永稳, 汪涛, 朱高峰, 董金玮, 缪驰远. 地理系统模型研究进展[J]. 地理科学进展, 2018, 37(1): 109-120.
- [9] 张爽, 高启晨, 张戎等. 基于 PLUS-InVEST 模型碳储量时空演变及驱动因素分析——以纳帕海流域为例[J]. 中国环境科学, 2024, 44(09): 5192-5201.
- [10] Han, J., Miao, C. (2022). A new daily gridded precipitation dataset for the Chinese mainland based on gauge observations. figshare. Dataset.
- [11] 余振, Philippe Ciais, 朴世龙等. 1900-2019 年中国土地利用和覆盖变化数据集[DS/OL]. 国家生态科学数据中心, 2022.
- [12] Yu, Z., Ciais, P., Piao, S., Houghton, R. A., Lu, C., Tian, H., Agathokleous, E., Kattel, G. R., Sitch, S., Goll, D., Yue, X., Walker, A., Friedlingstein, P., Jain, A. K., Liu, S., & Zhou, G. (2022). Forest expansion dominates China's land carbon sink since 1980. Nature Communications, 13(1), 5374.
- [13] 周姣娣, 鲁栋梁, 许玉萍等. 基于 InVEST 和 GIS 模型的广西北部湾沿海地区碳储量时空演变研究[J]. 海洋环境科学, 2024, 43(05): 715-722+732.
- [14] 李梦帆, 郑江华, 钱安良等. 基于决策树的天山冰湖提取方法研究[J/OL]. 干旱区研究, 2024: 1-9.
- [15] 王熙照, 杨晨晓. 分支合并对决策树归纳学习的影响[J]. 计算机学报, 2007, (08): 1251-1258.
- [16] 陈婷, 谢志龙. 基于改进决策树的不平衡数据集分类算法研究[J]. 计算机仿真, 2024, 41(08): 497-501.
- [17] 魏佳妹, 袁书娟, 孔闪闪等. 轻梯度提升机算法的发展与应用[J/OL]. 计算机工程与应用, 2024: 1-13.
- [18] Fang, S., Mao, K., Xia, X., Wang, P., Shi, J., M. Bateni, S., Xu, T., Cao, M., & Heggy, E. (2021). A Daily near-surface Air Temperature Dataset for China from 1979 - 2018 (Version 1.0) [Data set]. Zenodo.
- [19] 王灿, 王嘉琛. (2022). 中国历史人口空间分布公里网格数据集 (1990-2015 逐年). 国家青藏高原数据中心.
- [20] 徐新良. (2017). 中国人口空间分布公里网格数据集. 资源环境科学数据注册与出版系统

- [21]王元庆, 李佳玥, 刘备等. 基于 XGBoost-SHAP 方法的建设项目碳排放空间异质性分析[J/OL]. 环境科学, 2024: 1-15.
- [22]杨秀梅, 黄武斌, 李天江等. 两种机器学习模型在甘肃小时气温预报中的应用[J/OL].大气科学学报, 2024: 1-11.
- [23]王思超,蔡玉林,朱子正等. XGBoost 和 DSCGAN 模型协同的 SMAP 土壤水分降尺度方法[J]. 地球信息科学学报, 2024, 26(09): 2213-2225.
- [24]周皓秋, 冯晖, 董泽君等.基于 SVM 及 PCSP 的全极化探地雷达地雷探测方法研究[J/OL]. 地球物理学进展, 2024: 1-14.
- [25]胡焕庸. 中国人口之分布——附统计表与密度图 [J]. 地理学报, 1935, 2(2): 33-74.
- [26]王灿, 王嘉琛. (2022). 中国历史人口空间分布公里网格数据集 (1990-2015 逐年) . 国家青藏高原数据中心. <https://doi.org/10.12078/2017121101>
- [27]徐新良. (2017). 中国人口空间分布公里网格数据集.资源环境科学数据注册与出版系统(<http://www.resdc.cn/DOI>).
- [28]Graham, M., & Shelton, T. (2013). Geography and the future of big data, big data and the future of geography. *Dialogues in Human Geography*, 3(3), 255-261. <https://doi.org/10.1177/2043820613513121>
- [29]Liu, H., Jiang, D., Yang, X., & Luo, C. (2005). Spatialization approach to 1 km grid GDP supported by remote sensing. *Geo-Inf. Sci*, 7, 120-123.
- [30]Yi, L., Xiong, L., & Yang, X. (2006). Method of pixelizing GDP data based on the GIS. *J. Gansu Sci*, 18, 54-58.
- [31]方创琳. 博台线——中国区域发展均衡线的重要功能与建设构想[J]. 地理学报, 2020, 75(02): 211-225.

附录

问题一代码

```
from rasterio.plot import show
import rasterio
import numpy as np
import os
import pandas as pd
from rasterio.transform import Affine
import matplotlib.pyplot as plt
from skimage import measure
from sklearn.cluster import DBSCAN

plt.rcParams['axes.unicode_minus']=False
plt.rcParams['font.family'] = ['Times New Roman','SimSun']
plt.rcParams['font.size']=12 # 可以设置你想要的字体大小

def read_tfw(tfw_path):
    with open(tfw_path, 'r') as file:
        lines = file.readlines()
        A = float(lines[0].strip())
        D = float(lines[1].strip())
        B = float(lines[2].strip())
        E = float(lines[3].strip())
        C = float(lines[4].strip())
        F = float(lines[5].strip())
        transform = Affine(A, D, C, B, E, F)
    return transform

def calculate_area(tif_file):
    data=rasterio.open(tif_file)
    ds_array=data.read(1)
    transform=data.transform
    left, top = transform * (0, 0) # 左上角的经纬度
    pixel_width = transform.a # 像素宽度（经度方向）
    pixel_height = -transform.e # 像素高度（纬度方向）
    width = data.width
    height = data.height

    # 创建行和列的索引
    rows = np.arange(height)
    cols = np.arange(width)

    # 创建网格索引
```

```

cols_grid, rows_grid = np.meshgrid(cols, rows)
longitudes = left + (cols_grid + 0.5) * pixel_width
latitudes = top - (rows_grid + 0.5) * pixel_height
# 创建一个 DataFrame
data1 = {
    'longitude': longitudes.flatten(),
    'latitude': latitudes.flatten(),
    'coverage_ratio': ds_array.flatten()
}
df1 = pd.DataFrame(data1)
return df1

```

dir_path=r"E:\博士工作\比赛\2024-第 21 届华为杯中国研究生数学建模\赛题\数据集 4-中国大陆 0.5°土地利用和覆盖变化数据集(1900-2019 年)\数据实体"

```
file_list=os.listdir(dir_path)
```

```
result=[]
```

```
for i in file_list:
```

```
    if i.endswith('.tif') and int(i.split('.')[0].split('-')[1])>=1990:
```

```
        tif_file=dir_path+'\\'+i
```

```
        type=i.split('.')[0].split('-')[0]
```

```
        year=i.split('.')[0].split('-')[1]
```

```
        df1=calculate_area(tif_file=tif_file)
```

```
        df1.insert(0,'year',year)
```

```
        df1.insert(1,'type',type)
```

```
        df1.to_excel(r"E:\博士工作\比赛\2024-第 21 届华为杯中国研究生数学建模\赛题\赛题\土地利用矩阵数据
```

```
\%s.xlsx"%(i.split('.')[0]),index=0)
```

```
#         result.append(df1)
```

```
##数据集 6-GDP
```

```
dir_path=r"E:\博士工作\比赛\2024-第 21 届华为杯中国研究生数学建模\赛题\数据集 6\GDP_output"
```

```
file_list=os.listdir(dir_path)
```

```
result=[]
```

```
for i in file_list:
```

```
    if i.endswith('.tif'):
```

```
        tif_file=dir_path+'\\'+i
```

```
        type=i.split('.')[0].split('-')[0]
```

```
        year=i.split('.')[0][-4:]
```

```
        result.append({'year':year,'type':type,'ratio':calculate_area(tif_file)[0],'ratio_max':calculate_area(tif_file)[1]})
```

```
result_df=pd.DataFrame(result)
```

```
print(result_df)
```

```
result_df.to_excel(r"E:\博士工作\比赛\2024-第 21 届华为杯中国研究生数学建模\赛题\赛题\2-GDP.xlsx",index=0)
```

问题二代码

```
from rasterio.plot import show
import rasterio
import numpy as np
import os
import pandas as pd
from rasterio.transform import Affine
import matplotlib.pyplot as plt
from skimage import measure
from sklearn.cluster import DBSCAN

plt.rcParams['axes.unicode_minus']=False
plt.rcParams['font.family'] = ['Times New Roman','SimSun']
plt.rcParams['font.size'] = 12 # 可以设置你想要的字体大小

# dir_path=r"E:\博士工作\比赛\2024-第 21 届华为杯中国研究生数学建模\赛题\数据集 2\数据集 2\日平均数据\1979_avg"

def year_calculate(dir_path):
    result=[]
    file_list=os.listdir(dir_path)
    for i in file_list:
        if i.endswith('.tif'):
            tif_file=dir_path+'\\'+i
            year=i.split('_')[0][:4]
            date=i.split('_')[0][4:8]
            data=rasterio.open(tif_file)
            ds_array=data.read(1)
            d=ds_array[ds_array>2000]
            result.append({'year':year,'date':date,'mean':np.mean(d),'median':np.median(d),'max':np.max(d),'min':np.min(d),'std':n
p.std(d)})
    return pd.DataFrame(result)
describes=[]
for y in range(1990,2019):
    dir_path=r"E:\博士工作\比赛\2024-第 21 届华为杯中国研究生数学建模\赛题\数据集 2\数据集 2\日平均数据
\%s_avg"%(y)
    print(dir_path)

    # describes.append(year_calculate(dir_path))
# print(pd.concat(describes,axis=0,ignore_index=True))
# pd.concat(describes,axis=0,ignore_index=True).to_excel(r"E:\博士工作\比赛\2024-第 21 届华为杯中国研究生数学建模\赛
题\赛题2-气温数据集 2 转换.xlsx")

def calculate_area(tif_file):
    data=rasterio.open(tif_file)
```



```

ds_array=data.read(1)
transform=data.transform
left, top = transform * (0, 0) # 左上角的经纬度
pixel_width = transform.a      # 像素宽度（经度方向）
pixel_height = -transform.e     # 像素高度（纬度方向）
width = data.width
height = data.height

# 创建行和列的索引
rows = np.arange(height)
cols = np.arange(width)

# 创建网格索引
cols_grid, rows_grid = np.meshgrid(cols, rows)

# 计算每个像素的经度和纬度
# 经度 = 左 + (列索引 + 0.1) * 像素宽度
# 纬度 = 上 - (行索引 + 0.1) * 像素高度
longitudes = left + (cols_grid + 0.1) * pixel_width
latitudes = top - (rows_grid + 0.1) * pixel_height

# 创建一个 DataFrame
data1 = {
    'longitude': longitudes.flatten(),
    'latitude': latitudes.flatten(),
    'centigrade': ds_array.flatten()
}
dfl = pd.DataFrame(data1)
return dfl

for y in range(1990,2019):
    dir_path=r"E:\博士工作\比赛\2024-第 21 届华为杯中国研究生数学建模\赛题\数据集 2\数据集 2\日平均数据
\%s_avg\%s"%(y,y)+'0101_avg.tif'
    print(dir_path)
    dfl=calculate_area(tif_file=dir_path)
    dfl.insert(0,'year',y)
    dfl.insert(0,'date','0101')
    # print(dfl)
    dfl.to_excel(r"E:\博士工作\比赛\2024-第 21 届华为杯中国研究生数学建模\赛题\赛题\地表温度矩阵数据
\%s-%s.xlsx"%(y,'0101'),index=0)

##经纬度坐标数据的简化处理

```

```

import pandas as pd
import matplotlib.pyplot as plt
plt.rcParams['axes.unicode_minus']=False
plt.rcParams['font.family'] = ['Times New Roman','SimSun']

##降水数据
rains=[]
for year in range(1990,2021):
    data_rain=pd.read_csv(r"E:\博士工作\比赛\2024-第 21 届华为杯中国研究生数学建模\赛题\赛题\年均降水量表格数据\
年均降水量表格数据\pre_%s_converted.csv"%(year))
    # 对经纬度进行取整处理
    data_rain['Longitude'] = data_rain['Longitude'].round(0)
    data_rain['Latitude'] = data_rain['Latitude'].round(0)

    grouped_data = data_rain.groupby(['Longitude', 'Latitude']).mean().reset_index()
    grouped_data['year']=year
    grouped_data.rename(columns={'Longitude':'longitude','Latitude':'latitude'},inplace=True)
    rains.append(grouped_data)
rains_df=pd.concat(rains,axis=0,ignore_index=True)
print(rains_df)
rains_df.to_excel(r"E:\博士工作\比赛\2024-第 21 届华为杯中国研究生数学建模\赛题\赛题\问题 2-降水数据.xlsx",index=0)

##气温数据
temps=[]
for year in range(1990,2019):
    data_temp=pd.read_excel(r"E:\博士工作\比赛\2024-第 21 届华为杯中国研究生数学建模\赛题\赛题\地表温度矩阵数据\
%s-0101.xlsx"%(year))

    # 对经纬度进行取整处理
    data_temp['longitude'] = data_temp['longitude'].round(0)
    data_temp['latitude'] = data_temp['latitude'].round(0)
    grouped_data = data_temp.groupby(['longitude', 'latitude']).mean().reset_index()
    print(grouped_data)
    temps.append(grouped_data)
temp_df=pd.concat(temps,axis=0,ignore_index=True)
print(temp_df)
del temp_df['date']
temp_df.to_excel(r"E:\博士工作\比赛\2024-第 21 届华为杯中国研究生数学建模\赛题\赛题\问题 2-气温数据.xlsx",index=0)

##地形数据

lands=[]
land_types = ['shrub', 'forest', 'grass', 'wetland', 'cropland']

```

```

for land_type in land_types:
    for year in range(1990, 2020):
        file_path = r"E:\博士工作\比赛\2024-第 21 届华为杯中国研究生数学建模\赛题\赛题\土地利用矩阵数据\%s-%s.xlsx" % (land_type, year)
        data_land = pd.read_excel(file_path)

        data_land=data_land.iloc[:,2:]
        # 对经纬度进行取整处理
        data_land['longitude'] = data_land['longitude'].round(0)
        data_land['latitude'] = data_land['latitude'].round(0)
        grouped_data = data_land.groupby(['longitude', 'latitude']).mean().reset_index()
        grouped_data['year']=year
        grouped_data['type']=land_type
        print(grouped_data)
        lands.append(grouped_data)
land_df=pd.concat(lands,axis=0,ignore_index=True)
print(land_df)
land_df.to_excel(r"E:\博士工作\比赛\2024-第 21 届华为杯中国研究生数学建模\赛题\赛题\问题 2-土地数据.xlsx",index=0)

###数据合并
land_df=pd.read_excel(r"E:\博士工作\比赛\2024-第 21 届华为杯中国研究生数学建模\赛题\赛题\问题 2-土地数据.xlsx")
rains_df=pd.read_excel(r"E:\博士工作\比赛\2024-第 21 届华为杯中国研究生数学建模\赛题\赛题\问题 2-降水数据.xlsx")
temp_df=pd.read_excel(r"E:\博士工作\比赛\2024-第 21 届华为杯中国研究生数学建模\赛题\赛题\问题 2-气温数据.xlsx")
merged_df = pd.merge(land_df, rains_df, on=['year', 'longitude', 'latitude'], how='right')
merged_df1 = pd.merge(merged_df, temp_df, on=['year', 'longitude', 'latitude'], how='outer')

merged_df2=merged_df1[merged_df1['centigrade']>=100000]
merged_df2=merged_df2[merged_df1['Value']>=99]
merged_df2['Value']=100*merged_df2['Value']
# 输出合并后的数据
print(merged_df2)
merged_df2.to_excel(r"E:\博士工作\比赛\2024-第 21 届华为杯中国研究生数学建模\赛题\赛题\问题 2-合并数据.xlsx",
index=False)

# merged_df2.reset_index(inplace=True)

plt.figure(figsize=(20,6))
plt.plot(merged_df2['Value'],c='blue')
plt.ylabel('降水量')
plt.xlabel('k')
plt.show()

```

```

###数据建模

import pandas as pd
from sklearn.model_selection import train_test_split
from sklearn.tree import DecisionTreeRegressor, plot_tree, export_graphviz, DecisionTreeClassifier
from sklearn.metrics import mean_squared_error, r2_score
import matplotlib.pyplot as plt
import seaborn as sns
import graphviz
from sklearn.preprocessing import LabelEncoder
import dtreeviz
from sklearn.model_selection import GridSearchCV

plt.rcParams['axes.unicode_minus']=False
plt.rcParams['font.family'] = ['Times New Roman','SimSun']

df=pd.read_excel(r"E:\博士工作\比赛\2024-第 21 届华为杯中国研究生数学建模\赛题\赛题\问题 2-合并数据.xlsx")

selected_columns = df[['Rain', 'Coverage_ratio', 'Temperature']]
# 计算相关性矩阵
correlation_matrix = selected_columns.corr()
print("相关性矩阵: ")
print(correlation_matrix)

# 绘制相关性散点图
sns.heatmap(correlation_matrix)
plt.show()

##开始建模
# 读取数据
data = pd.read_excel(r"E:\博士工作\比赛\2024-第 21 届华为杯中国研究生数学建模\赛题\赛题\问题 2-合并数据.xlsx")

label_encoder = LabelEncoder()
# 转换 Land_type 列
data['Land_type'] = label_encoder.fit_transform(data['Land_type'])

# 自变量
X = data[['longitude', 'latitude', 'Coverage_ratio', 'Year', 'Temperature', 'Land_type']]

```

```

# 因变量
y = data['Rain']

# 70%用于训练, 30%用于测试
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.3, random_state=42)

# 检查数据集的大小
print("训练集大小: ", X_train.shape)
print("测试集大小: ", X_test.shape)

# 定义参数范围
param_grid = {
    'max_depth': [None, 1, 2, 3, 4, 5],
    'min_samples_split': [2, 5, 10],
    'min_samples_leaf': [1, 2, 4]
}

# 创建决策树回归模型
dt_regressor = DecisionTreeRegressor(random_state=42)

# 使用 GridSearchCV 进行参数优化
grid_search = GridSearchCV(estimator=dt_regressor, param_grid=param_grid, scoring='r2', cv=5)
grid_search.fit(X_train, y_train)

# 获取最佳参数和对应的 R²
results = grid_search.cv_results_
mean_r2 = results['mean_test_score']
params = results['params']

# 可视化 R²值
depths = [param['max_depth'] for param in params]
min_samples_splits = [param['min_samples_split'] for param in params]
min_samples_leaves = [param['min_samples_leaf'] for param in params]

# 创建网格图
fig = plt.figure(figsize=(10, 6))
scatter = plt.scatter(depths, min_samples_splits, c=mean_r2, cmap='viridis', s=100)
plt.colorbar(scatter, label='Mean R²')
plt.xlabel('Max Depth')
plt.ylabel('Min Samples Split')
plt.title('Parameter Optimization: Decision Tree R²')
plt.grid()

# 绘制每种配置的 R²

```



```

for i, txt in enumerate(mean_r2):
    plt.annotate(f'{txt:.2f}', (depths[i], min_samples_splits[i]), fontsize=8)

plt.show()

# 输出最佳参数
print("最佳参数:", grid_search.best_params_)
print("最佳 R²:", grid_search.best_score_)

data = pd.read_excel(r"E:\博士工作\比赛\2024-第 21 届华为杯中国研究生数学建模\赛题\赛题\问题 2-合并数据.xlsx")
# label_encoder = LabelEncoder()
# 转换 Land_type 列
# data['Land_type'] = label_encoder.fit_transform(data['Land_type'])

data1=data.iloc[:109536,:]

data2=data1[data1['Land_type']=='cropland']
print(data2)

# 自变量

X = data2[['Year', 'Coverage_ratio', 'Temperature',]]

# 因变量
y = data2['Rain']
print(X)
# 70%用于训练, 30%用于测试
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.3, random_state=42)
# 检查数据集的大小
print("训练集大小: ", X_train.shape)
print("测试集大小: ", X_test.shape)

# 初始化决策树回归模型
tree_model = DecisionTreeRegressor(random_state=42,max_depth=3)

# 训练模型
tree_model.fit(X_train, y_train)

# 使用测试集进行预测
y_pred = tree_model.predict(X_test)

```

```

# 计算均方误差 (MSE)
mse = mean_squared_error(y_test, y_pred)
print("均方误差: ", mse)

# 计算 R^2 分数
r2 = r2_score(y_test, y_pred)
print("R^2 分数: ", r2)

# 可视化决策树
dot=export_graphviz(tree_model,feature_names=X.columns,filled=True)
m=dtreeviz.model(tree_model,X_train=X_test,y_train=y_test,feature_names=X.columns,target_name='Rain')
m.view()
# graphviz.Source(dot).render(r"E:\博士工作\比赛\2024-第 21 届华为杯中国研究生数学建模\赛题\赛题\问题 2-决策树")

data1=data.sample(n=105626,random_state=2024)
label_encoder = LabelEncoder()
data1['Land_type'] = label_encoder.fit_transform(data1['Land_type'])
data1.to_excel(r"E:\博士工作\比赛\2024-第 21 届华为杯中国研究生数学建模\赛题\赛题\问题 2-最终数据.xlsx",index=0)

# 绘制真实值和预测值的散点图
plt.figure(figsize=(10, 6))
plt.scatter(y_test, y_pred, color='blue', edgecolor='b', alpha=0.6)
plt.xlabel("真实值 (Rain)")
plt.ylabel("预测值 (Predicted Rain)")
# plt.title("决策树模型：真实值与预测值对比")
plt.show()
data1['Rain'].describe()

data = pd.read_excel(r"E:\博士工作\比赛\2024-第 21 届华为杯中国研究生数学建模\赛题\赛题\问题 2-合并数据.xlsx")
data1=data.sample(n=105626,random_state=2024)
X = data1[['Coverage_ratio', 'Temperature','longitude','latitude']]
# X = data1[['Year', 'Coverage_ratio', 'Temperature','Land_type','longi]]

# 因变量
y = [1 if i>250 else 0 for i in data1['Rain']]

# 70%用于训练， 30%用于测试
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.3, random_state=42)
# 检查数据集的大小

```

```

print("训练集大小: ", X_train.shape)
print("测试集大小: ", X_test.shape)

# 初始化决策树回归模型
tree_model = DecisionTreeClassifier(random_state=42,max_depth=4)

# 训练模型
tree_model.fit(X, y)

# 使用测试集进行预测
y_pred = tree_model.predict(X)

# 计算均方误差 (MSE)
mse = mean_squared_error(y, y_pred)
print("均方误差: ", mse)

# 计算 R^2 分数
r2 = r2_score(y, y_pred)
print("R^2 分数: ", r2)

# 可视化决策树
dot=export_graphviz(tree_model,feature_names=X.columns,filled=True,class_names=['Low','High'])
# m=dtreeviz.model(tree_model,X_train=X_test,y_train=y_test,feature_names=X.columns,class_names=['High','Low'])
# m.view()
graphviz.Source(dot).render(r"E:\博士工作\比赛\2024-第 21 届华为杯中国研究生数学建模\赛题\赛题\问题 2-暴雨决策树")

```

问题三代码

```
import pandas as pd
import matplotlib.pyplot as plt
import seaborn as sns
from rasterio.plot import show
import rasterio
import numpy as np
import os
import pandas as pd
import folium
from folium.plugins import HeatMap
from rasterio.transform import Affine
from skimage import measure
from sklearn.cluster import DBSCAN

plt.rcParams['axes.unicode_minus']=False
plt.rcParams['font.size']=12 # 可以设置你想要的字体大小
plt.rcParams['font.family']=['Times New Roman','SimSun']

data=pd.read_excel(r"E:\博士工作\比赛\2024-第21届华为杯中国研究生数学建模\赛题\赛题\问题三\问题2-合并数据.xlsx")
# 查看年份范围
print("年份范围:", data['Year'].min(), "至", data['Year'].max())
# 计算每年的总降雨量
annual_rainfall = data.groupby('Year')['Rain'].mean().reset_index()

# 绘制年度降雨量趋势图
plt.figure(figsize=(12, 6))
sns.lineplot(x='Year', y='Rain', data=annual_rainfall, marker='o', color='b')
# plt.title('年均降雨量趋势')
plt.xlabel('年份')
plt.ylabel('年均降雨量 (mm)')
plt.xticks(list(range(1990,2019,2)))
plt.grid(True)
plt.show()

# 计算每年的最大降雨量
annual_max_rainfall = data.groupby('Year')['Rain'].max().reset_index()

# 绘制年度最大降雨量变化图
plt.figure(figsize=(12, 6))
sns.barplot(x='Year', y='Rain', data=annual_max_rainfall, palette='viridis')
# plt.title('年度最大单次降雨量变化趋势')
plt.xlabel('年份')
```

```

plt.ylabel('最大降雨量 (mm)')
plt.xticks(rotation=45)
plt.show()

plt.figure(figsize=(14, 8))
sns.boxplot(x='Year', y='Rain', data=data)
# plt.title('不同年份降雨量分布箱线图')
plt.xlabel('年份')
plt.ylabel('降雨量 (mm)')
plt.xticks(rotation=45)
plt.show()

plt.figure(figsize=(14, 8))
sns.boxplot(x='Land_type', y='Rain', data=data)
plt.title('不同土地利用类型的降雨量分布')
plt.xlabel('土地利用类型')
plt.ylabel('降雨量 (mm)')
plt.xticks(rotation=45)
plt.show()

plt.figure(figsize=(12, 6))
sns.scatterplot(x='Temperature', y='Rain', data=data, alpha=0.6, color='g')
# plt.title('降雨量与温度的关系')
plt.xlabel('温度 (°C)')
plt.ylabel('降雨量 (mm)')
plt.grid(True)
plt.show()

plt.figure(figsize=(12, 8))
scatter = plt.scatter(data['longitude'], data['latitude'], c=data['Rain'], cmap='Blues', alpha=1)
plt.colorbar(scatter, label='降雨量 (mm)')
# plt.title('降雨量的空间分布')
plt.xlabel('经度')
plt.ylabel('纬度')
plt.grid(True)
plt.show()

# 选择一个特定年份进行示例，例如 2020 年
year = 2018
data_year = data[data['Year'] == year]

```



```

# 创建 Folium 地图
m = folium.Map(location=[data['latitude'].mean(), data['longitude'].mean()], zoom_start=5)

# 添加热力图
heat_data = [[row['latitude'], row['longitude'], row['Rain']] for index, row in data_year.iterrows()]
HeatMap(heat_data, radius=10, max_zoom=13).add_to(m)

# 保存地图
m.save(r"E:\博士工作\比赛\2024-第 21 届华为杯中国研究生数学建模\赛题\赛题\问题三\rainfall_heatmap_2020.html")

##构建新变量 综合评价（暴雨灾害脆弱性指数）
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
import seaborn as sns
from scipy.stats import linregress

# 读取数据
data=pd.read_excel(r"E:\博士工作\比赛\2024-第 21 届华为杯中国研究生数学建模\赛题\赛题\问题三\问题 2-合并数据.xlsx")

# 查看数据基本信息
print(data.head())
print(data.info())

# 处理缺失值（如果有）
data = data.dropna()

# 确保数据类型正确
data['Year'] = data['Year'].astype(int)
data['Rain'] = data['Rain'].astype(float)
data['Temperature'] = data['Temperature'].astype(float)
data['Coverage_ratio'] = data['Coverage_ratio'].astype(float)

# 创建区域标识（假设经纬度精确到小数点后两位）
data['Region'] = data['longitude'].round(2).astype(str) + '_' + data['latitude'].round(2).astype(str)

# 排序数据以确保时间序列的顺序
data = data.sort_values(by=['Region', 'Year'])

```

```

# 计算 3 年滚动平均降雨量
data['Rain_RollingMean_3'] = data.groupby('Region')['Rain'].transform(lambda x: x.rolling(window=3, min_periods=1).mean())

# 计算年度降雨量变化率
data['Rain_YoY_Change'] = data.groupby('Region')['Rain'].transform(lambda x: x.pct_change() * 100)

# 计算 3 年滚动标准差
data['Rain_RollingStd_3'] = data.groupby('Region')['Rain'].transform(lambda x: x.rolling(window=3, min_periods=1).std())

# 计算累计降雨量
data['Rain_Cumulative'] = data.groupby('Region')['Rain'].transform('cumsum')

# 定义函数计算趋势斜率
def calculate_trend_slope(x):
    if len(x) < 2:
        return np.nan
    slope, intercept, r_value, p_value, std_err = linregress(x['Year'], x['Rain'])
    return slope

# 计算趋势斜率
trend_slope = data.groupby('Region').apply(calculate_trend_slope).reset_index(name='Rain_Trend_Slope')
data = data.merge(trend_slope, on='Region', how='left')

# 定义极端降雨阈值（95 百分位数）
data['Extreme_Rain_Threshold'] = data.groupby('Region')['Rain'].transform(lambda x: x.quantile(0.95))

# 标记极端降雨事件
data['Extreme_Rain'] = np.where(data['Rain'] > data['Extreme_Rain_Threshold'], 1, 0)

# 计算每年的极端降雨事件次数
data['Extreme_Rain_Count'] = data.groupby(['Region', 'Year'])['Extreme_Rain'].transform('sum')

# 计算极端降雨事件变化率
data['Extreme_Rain_YoY_Change'] = data.groupby('Region')['Extreme_Rain_Count'].transform(lambda x: x.pct_change() * 100)

# 创建温度与覆盖率的交互项
data['Temp_Coverage_Interaction'] = data['Temperature'] * data['Coverage_ratio']

# 使用 One-Hot 编码对 Land_type 进行编码
data = pd.get_dummies(data, columns=['Land_type'], drop_first=True)

# 用全体平均趋势斜率填补缺失值
average_slope = data['Rain_Trend_Slope'].mean()
data['Rain_Trend_Slope'] = data['Rain_Trend_Slope'].fillna(average_slope)

```

```

# 删除辅助列
data = data.drop(columns=['Extreme_Rain_Threshold'])

# 查看新变量
print(data.head())

# 检查新变量的描述统计
print(data[['Rain_RollingMean_3', 'Rain_YoY_Change', 'Rain_RollingStd_3', 'Rain_Cumulative', 'Rain_Trend_Slope',
'Extreme_Rain_Count', 'Extreme_Rain_YoY_Change', 'Temp_Coverage_Interaction']].describe())

# 可选：保存处理后的数据
data.to_csv(r"E:\博士工作\比赛\2024-第 21 届华为杯中国研究生数学建模\赛题\赛题\问题三\rainfall_data_engineered.csv",
index=False)

##s=海拔高度
tif_file=r"E:\博士工作\比赛\2024-第 21 届华为杯中国研究生数学建模\赛题\数据集 1-中国数字高程图
(1km)\Geo\TIFF\chinadem_geo.tif"
data=rasterio.open(tif_file)
ds_array=data.read(1)
transform=data.transform
left, top = transform * (0, 0) # 左上角的经纬度
pixel_width = transform.a      # 像素宽度（经度方向）
pixel_height = -transform.e     # 像素高度（纬度方向）
width = data.width
height = data.height
# 创建行和列的索引
rows = np.arange(height)
cols = np.arange(width)

# 创建网格索引
cols_grid, rows_grid = np.meshgrid(cols, rows)

# 计算每个像素的经度和纬度
# 使用 0.5 来代表像素中心，而不是 0.1
longitudes = left + (cols_grid + 0.5) * pixel_width
latitudes = top - (rows_grid + 0.5) * pixel_height

# 创建一个 DataFrame
data1 = {
    'longitude': longitudes.flatten(),
    'latitude': latitudes.flatten(),
    'altitude': ds_array.flatten()
}

```

```

}
df1 = pd.DataFrame(data1)
# print(df1)
# 对经纬度进行取整处理
df1['longitude'] = df1['longitude'].round(0)
df1['latitude'] = df1['latitude'].round(0)
grouped_data = df1.groupby(['longitude', 'latitude']).mean().reset_index()
print(grouped_data)

years = list(range(1990, 2020)) # 包含 1990 到 2019 年
df_years = pd.DataFrame({'year': years})

# 为了进行笛卡尔积，添加一个辅助键
grouped_data['key'] = 1
df_years['key'] = 1

# 进行笛卡尔积
df_final = pd.merge(grouped_data, df_years, on='key').drop('key', axis=1)
print(df_final)
df_final.to_excel(r"E:\博士工作\比赛\2024-第 21 届华为杯中国研究生数学建模\赛题\赛题\问题三\问题三-海拔高度.xlsx", index=0)

altitude_df = pd.read_excel(r"E:\博士工作\比赛\2024-第 21 届华为杯中国研究生数学建模\赛题\赛题\问题三\问题三-海拔高度.xlsx")
rain_df = pd.read_csv(r"E:\博士工作\比赛\2024-第 21 届华为杯中国研究生数学建模\赛题\赛题\问题三\rainfall_data_engineered.csv")
rain_df.fillna(0, inplace=True)
result = pd.merge(rain_df, df_final, on=['longitude', 'latitude'], how='inner')
print(result)

result.to_csv(r"E:\博士工作\比赛\2024-第 21 届华为杯中国研究生数学建模\赛题\赛题\问题三\问题三-合并数据.csv", index=0)
result1 = result[result['Extreme_Rain'] == 1]
del result['year']
result1.to_csv(r"E:\博士工作\比赛\2024-第 21 届华为杯中国研究生数学建模\赛题\赛题\问题三\问题三-暴雨灾害合并数据.csv", index=0)

df = pd.read_csv(r"E:\博士工作\比赛\2024-第 21 届华为杯中国研究生数学建模\赛题\赛题\问题三\问题三-暴雨灾害合并数据.csv")

# 选择需要标准化的列
columns_to_standardize = [

```

```

    'Rain_RollingMean_3',
    'Rain_RollingStd_3',
    'Rain_Trend_Slope',
    'Rain_Cumulative',
    'altitude'
]

# 检查这些列是否存在于 DataFrame 中
missing_columns = [col for col in columns_to_standardize if col not in df.columns]
if missing_columns:
    raise ValueError(f'缺少以下列: {missing_columns}')

# 初始化 StandardScaler
scaler = MinMaxScaler()

# 对选择的列进行标准化
df_standardized = df.copy()
df_standardized[colums_to_standardize] = scaler.fit_transform(df[colums_to_standardize])

# 这里假设权重相等
df_standardized['V_index'] = df_standardized[colums_to_standardize].mean(axis=1)

# 将 V_index 添加到原始 DataFrame 中（如果需要）
df['V_index'] = df_standardized['V_index']

# 检查所需的列是否存在
required_columns = ['V_index', 'Rain', 'Coverage_ratio', 'altitude']
missing_columns = [col for col in required_columns if col not in df.columns]
if missing_columns:
    raise ValueError(f'缺少以下列: {missing_columns}')

# 设置绘图风格
sns.set(style="whitegrid")

# 创建一个包含三个子图的画布
fig, axes = plt.subplots(1, 3, figsize=(18, 6))

# 1. V_index 与 Rain 的散点图
sns.scatterplot(data=df, x='Rain', y='V_index', ax=axes[0], hue='V_index', palette='viridis', edgecolor='w', alpha=0.7)
axes[0].set_title('V_index vs Rain')
axes[0].set_xlabel('Rain')
axes[0].set_ylabel('V_index')

```


2. V_index 与 Coverage_ratio 的散点图

```
sns.scatterplot(data=df, x='Coverage_ratio', y='V_index', ax=axes[1], hue='V_index', palette='viridis', edgecolor='w', alpha=0.7)
axes[1].set_title('V_index vs Coverage_ratio')
axes[1].set_xlabel('Coverage_ratio')
axes[1].set_ylabel('V_index')
```

3. V_index 与 altitude 的散点图

```
sns.scatterplot(data=df, x='altitude', y='V_index', ax=axes[2], hue='V_index', palette='viridis', edgecolor='w', alpha=0.7)
axes[2].set_title('V_index vs Altitude')
axes[2].set_xlabel('Altitude')
axes[2].set_ylabel('V_index')
```

调整布局

```
plt.tight_layout()
```

显示图形

```
plt.show()
```

1. 绘制 V_index 的直方图

```
plt.figure(figsize=(10, 6))
sns.histplot(df['V_index'], bins=30, kde=True, color='blue')
plt.axvline(x=0.37, color='red', linestyle='--', label='阈值 0.37')
plt.title('V_index 直方图')
# plt.xlabel('脆弱性指数 (V_index)')
plt.ylabel('频数')
plt.legend()
plt.grid(True)
plt.show()
```

###XGBoost 建模

```
import numpy as np
from sklearn.model_selection import train_test_split
from sklearn.preprocessing import LabelEncoder
from xgboost import XGBClassifier
from sklearn.metrics import classification_report, confusion_matrix
```

1. 数据预处理

离散化 V_index

```
df['Risk_Level'] = np.where(df['V_index'] > 0.37, 'High', 'Low')
```

编码因变量

```
label_encoder = LabelEncoder()
df['Risk_Level'] = label_encoder.fit_transform(df['Risk_Level'])
```

```

# 选择自变量
features = ['longitude', 'latitude', 'Rain', 'Coverage_ratio', 'altitude',
            'Rain_Trend_Slope', 'Rain_RollingStd_3',
            'Land_type_forest', 'Land_type_grass',
            'Land_type_shrub', 'Land_type_wetland']

X = df[features]
y = df['Risk_Level']

# 2. 划分训练集和测试集
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.3, random_state=42)

# 3. 构建 XGBoost 分类模型
model = XGBClassifier(use_label_encoder=False, eval_metric='logloss', n_estimators=50, max_depth=3)
model.fit(X_train, y_train)

# 4. 进行预测
y_pred = model.predict(X_test)

# 5. 评估模型性能
print("混淆矩阵: ")
print(confusion_matrix(y_test, y_pred))
print("\n 分类报告: ")
print(classification_report(y_test, y_pred))

# 6. 特征重要性
importance = model.feature_importances_
feature_importance_df = pd.DataFrame({'Feature': features, 'Importance': importance})
feature_importance_df = feature_importance_df.sort_values(by='Importance', ascending=False)

# 绘制特征重要性图
plt.figure(figsize=(10, 6))
sns.barplot(data=feature_importance_df, x='Importance', y='Feature', palette='viridis')
# plt.title("特征重要性")
plt.show()

print(model.feature_names_in_)
print(model.feature_importances_)

# 绘制特征重要性图
plt.figure(figsize=(10, 6))
xgb.plot_importance(model, importance_type='weight', max_num_features=10)
plt.title("特征重要性")
plt.savefig('feature_importance.png') # 导出为 PNG 文件

```

```

plt.show()

from sklearn.tree import DecisionTreeClassifier, export_graphviz
import graphviz
import dtreeviz
# 选择自变量
features = ['longitude', 'latitude', 'Rain', 'Coverage_ratio', 'altitude',
            'Rain_Trend_Slope', 'Rain_RollingStd_3',
            'Land_type_forest', 'Land_type_grass',
            'Land_type_shrub', 'Land_type_wetland']

X = df[features]
y = df['Risk_Level']

# 2. 划分训练集和测试集
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.3, random_state=42)

# 创建决策树分类器
dt_classifier = DecisionTreeClassifier(random_state=42, max_depth=4)

# 训练模型
dt_classifier.fit(X_train, y_train)

# 进行预测
y_pred = dt_classifier.predict(X_test)

# 评估模型
print("混淆矩阵:")
print(confusion_matrix(y_test, y_pred))
print("\n 分类报告:")
print(classification_report(y_test, y_pred))

dot = export_graphviz(dt_classifier, feature_names=X.columns, filled=True, class_names=['Low', 'High'])
m = dtreeviz.model(dt_classifier, X_train=X_test, y_train=y_test, feature_names=X.columns, class_names=['Low', 'High'])
m.view()

##ARIMA 预测

import pandas as pd
import numpy as np
from statsmodels.graphics.tsaplots import plot_acf, plot_pacf
import matplotlib.pyplot as plt

```

```

from statsmodels.tsa.arima.model import ARIMA

plt.rcParams['axes.unicode_minus']=False
plt.rcParams['font.family'] = ['Times New Roman','SimSun']
plt.rcParams['font.size'] = 12 # 可以设置你想要的字体大小

data=pd.read_csv(r"E:\博士工作\比赛\2024-第 21 届华为杯中国研究生数学建模\赛题\赛题\问题三\问题三-脆弱性指数.csv")
data2=pd.read_excel(r"E:\博士工作\比赛\2024-第 21 届华为杯中国研究生数学建模\赛题\赛题\问题三\问题 2-合并数据.xlsx")
data2=data2.iloc[:, :-2]

final_data=pd.merge(data,data2)

data=pd.get_dummies(final_data, columns=['Land_type'])
data.to_csv(r"E:\博士工作\比赛\2024-第 21 届华为杯中国研究生数学建模\赛题\赛题\问题三\问题三-更新脆弱性指数.csv",index=0)

annual_data = data.groupby(['longitude', 'latitude', 'Year']).agg({
    'V_index': 'mean',
    'Rain': 'mean',
    'Coverage_ratio': 'mean'
}).reset_index()

# 计算土地覆盖变化率
# 先排序
annual_data = annual_data.sort_values(by=['longitude', 'latitude', 'Year'])

# 计算变化率
annual_data['Coverage_Change_Rate'] = annual_data.groupby(['longitude', 'latitude'])['Coverage_ratio'].pct_change() * 100

# 处理缺失值
annual_data['Coverage_Change_Rate'] = annual_data['Coverage_Change_Rate'].fillna(0) # 用 0 替代缺失值

# 输出处理后的数据
print(annual_data)

annual_data = pd.read_csv(r"E:\博士工作\比赛\2024-第 21 届华为杯中国研究生数学建模\赛题\赛题\问题三\问题三-更新脆弱性指数.csv")
annual_data['Year'] = annual_data['Year'].astype(int)
# 创建新的列计算不同土地类型的覆盖比例
annual_data['Coverage_forest'] = annual_data['Coverage_ratio'] * annual_data['Land_type_forest'].astype(int)
annual_data['Coverage_grass'] = annual_data['Coverage_ratio'] * annual_data['Land_type_grass'].astype(int)

```

```

annual_data['Coverage_shrub'] = annual_data['Coverage_ratio'] * annual_data['Land_type_shrub'].astype(int)
annual_data['Coverage_wetland'] = annual_data['Coverage_ratio'] * annual_data['Land_type_wetland'].astype(int)
annual_data['Coverage_cropland'] = annual_data['Coverage_ratio'] * annual_data['Land_type_cropland'].astype(int)
# 按年份计算年均值
annual_means = annual_data.groupby('Year').agg({
    'V_index': 'mean',
    'Rain': 'mean',
    'Coverage_forest': 'mean',
    'Coverage_grass': 'mean',
    'Coverage_shrub': 'mean',
    'Coverage_wetland': 'mean',
    'Coverage_cropland': 'mean'
}).reset_index()
annual_means.to_excel(r'E:\博士工作\比赛\2024-第21届华为杯中国研究生数学建模\赛题\赛题\问题三\问题三-时间序列数据汇总.xlsx', index=0)

# 绘制折线图
plt.figure(figsize=(12, 6))
plt.plot(annual_means['Year'], annual_means['V_index'], marker='o', linestyle='-', color='g', label='V_index')

plt.xlabel('Year')
plt.xticks(ticks=list(range(1990, 2019, 2)))
plt.ylabel('Values')
plt.legend()
plt.grid()
plt.show()
d1=final_data[['longitude', 'latitude', 'Year']]
d2=annual_means
d=pd.merge(d1,d2,on='Year')
d.to_csv(r"E:\博士工作\比赛\2024-第21届华为杯中国研究生数学建模\赛题\赛题\问题三\问题3-合并数据.csv", index=0)

# 读取数据
data = pd.read_excel(r"E:\博士工作\比赛\2024-第21届华为杯中国研究生数学建模\赛题\赛题\问题三\问题三-时间序列数据汇总.xlsx")

# 确保年份为整数类型
data['Year'] = data['Year'].astype(int)

feature=data['Rain']
# 设置年份为索引
data.set_index('Year', inplace=True)

```



```

# 定义要预测的变量
variables = ['Rain', 'Coverage_forest', 'Coverage_grass',
             'Coverage_shrub', 'Coverage_wetland', 'Coverage_cropland']

# 存储预测结果
forecast_results = {}

error_metrics = {}

# variable=variables[2]
for variable in variables[4:5]:
    # ACF 和 PACF 图
    # plt.figure(figsize=(12, 5))

    plot_acf(data[variable], lags=13)
    plt.title(f'ACF of {variable}')
    plot_pacf(data[variable], lags=13)
    plt.title(f'PACF of {variable}')

    plt.show()

    # 根据 ACF 和 PACF 图定阶
    p = 3 # 根据 PACF 图调整
    d = 0 # 差分次数
    q = 6 # 根据 ACF 图调整

    # 构建 ARIMA 模型
    model = ARIMA(data[variable], order=(p, d, q))
    model_fit = model.fit()
    # print(model)
    # 预测未来到 2035 年
    forecast_steps = 17 # 从 2019 到 2035 年
    forecast = model_fit.forecast(steps=forecast_steps)

    # 存储预测结果
    forecast_results[variable] = forecast

    # 可视化历史数据、拟合值和预测值
    plt.figure(figsize=(12, 6))
    plt.plot(data.index, data[variable], label='历史数据', marker='o')

    # 绘制拟合值
    fitted_values = model_fit.fittedvalues

```

```

plt.plot(data.index, fitted_values, label='拟合值', color='orange')

# 绘制预测值
forecast_index = range(2019, 2036)
plt.plot(forecast_index, forecast, label='预测值', marker='o', linestyle='--', color='red')

plt.title(f'{variable} 预测')
plt.xlabel('年份')
plt.ylabel(variable)
plt.xticks(ticks=list(range(1990,2038,2)))
plt.axvline(2018.5,ls='--',lw=1.5,c='k')
plt.legend()
plt.grid()
plt.show()

# 计算误差
mse = np.mean((data[variable] - fitted_values) ** 2)
mae = np.mean(np.abs(data[variable] - fitted_values))
error_metrics[variable] = {'MSE': mse, 'MAE': mae}

#####预测结果
f=round(pd.DataFrame(forecast),3)

print(f)
f.to_excel(r"E:\博士工作\比赛\2024-第 21 届华为杯中国研究生数学建模\赛题\赛题\问题三\问题三-预测结果-
-%s.xlsx"%(variable))

###临界条件分析
import pandas as pd
df=pd.read_csv(r"E:\博士工作\比赛\2024-第 21 届华为杯中国研究生数学建模\赛题\赛题\问题三\1-SVR 预测数据.csv")

df2=pd.read_csv(r"E:\博士工作\比赛\2024-第 21 届华为杯中国研究生数学建模\赛题\赛题\问题三\问题三-暴雨灾害合并数
据.csv")
df2=df2[['altitude','Year','longitude','latitude','Rain_Trend_Slope','Rain_RollingStd_3']]
data=pd.merge(df,df2,on=['Year','longitude','latitude'],how='inner')

import numpy as np
from sklearn.model_selection import train_test_split
from sklearn.preprocessing import LabelEncoder
import dtreeviz
import graphviz
from sklearn.tree import DecisionTreeClassifier,export_graphviz
from sklearn.metrics import classification_report, confusion_matrix

```

```

data.rename(columns={'Rain_x':'Rain'},inplace=True)

# 1. 数据预处理

# 离散化 V_index
data['Risk_Level'] = np.where(data['V_index'] > 0.37, 1, 0)


# 选择自变量
features = ['longitude', 'latitude', 'Rain', 'Coverage_forest', 'Coverage_grass',
            'Rain_Trend_Slope', 'Rain_RollingStd_3',
            'Coverage_shrub', 'Coverage_wetland',
            'Coverage_cropland', 'altitude']

X = data[features]
y = data['Risk_Level']

# 2. 划分训练集和测试集
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.3, random_state=42)

# 3. 构建 XGBoost 分类模型
model = DecisionTreeClassifier(random_state=42,max_depth=6)
model.fit(X_train, y_train)

# 4. 进行预测
y_pred = model.predict(X_test)

# 5. 评估模型性能
print("混淆矩阵: ")
print(confusion_matrix(y_test, y_pred))
print("\n 分类报告: ")
print(classification_report(y_test, y_pred))
dot=export_graphviz(model,feature_names=X.columns,filled=True,class_names=['Low','High'])

#
##SVR 预测

import pandas as pd
from sklearn.model_selection import train_test_split
from sklearn.svm import SVR
from sklearn.metrics import mean_squared_error, mean_absolute_error,r2_score
import matplotlib.pyplot as plt

plt.rcParams['axes.unicode_minus']=False

```

```

plt.rcParams['font.family'] = ['Times New Roman','SimSun']
plt.rcParams['font.size'] = 12 # 可以设置你想要的字体大小

data=pd.read_csv(r"E:\博士工作\比赛\2024-第 21 届华为杯中国研究生数学建模\赛题\赛题\问题三\1-SVR 预测数据.csv")
data = data.dropna()
# 特征选择与构建自变量和目标变量
X = data[['Rain_x', 'Coverage_forest', 'Coverage_grass',
          'Coverage_shrub', 'Coverage_wetland', 'Coverage_cropland']]
y = data['V_index']

# 数据拆分
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.2, random_state=42)

# 创建 SVR 模型
model = SVR(kernel='rbf,')

# 拟合模型
model.fit(X_train, y_train)

# 进行预测
y_pred = model.predict(X_test)

r2=r2_score(y_train, y_pred1)
# 输出评估结果
print(f'Mean Squared Error: {mse}')
print(f'Mean Absolute Error: {mae}')
print(f'R2: {r2}')

y_pred1 = model.predict(X_train)
mse = mean_squared_error(y_train, y_pred1)
mae = mean_absolute_error(y_train, y_pred1)
r2=r2_score(y_train, y_pred1)
# 输出评估结果
print(f'Mean Squared Error: {mse}')
print(f'Mean Absolute Error: {mae}')
print(f'R2: {r2}')

```

问题四代码

```
##人口数据处理
from rasterio.plot import show
import rasterio
import numpy as np
import os
import pandas as pd
from rasterio.transform import Affine
import matplotlib.pyplot as plt
from skimage import measure
from sklearn.cluster import DBSCAN
from pyproj import Proj, transform

plt.rcParams['axes.unicode_minus']=False
plt.rcParams['font.family'] = ['Times New Roman','SimSun']
plt.rcParams['font.size'] = 12 # 可以设置你想要的字体大小

#人口
year=2015
tif_file=r"E:\博士工作\比赛\2024-第21届华为杯中国研究生数学建模\赛题\数据集5\pop_output\pop2015\pop%s.tif"%(year)
data=rasterio.open(tif_file)
ds_array=data.read(1)
transform1=data.transform

left, top = transform1 * (0, 0) # 左上角的经纬度
pixel_width = transform1.a # 像素宽度（经度方向）
pixel_height = -transform1.e # 像素高度（纬度方向）
width = data.width
height = data.height
# 创建行和列的索引
rows = np.arange(height)
cols = np.arange(width)

# 创建网格索引
cols_grid, rows_grid = np.meshgrid(cols, rows)

# 计算每个像素的平面坐标
x_coords = left + (cols_grid + 0.5) * pixel_width
y_coords = top - (rows_grid + 0.5) * pixel_height

# 创建一个 DataFrame
data1 = {
    'x_coord': x_coords.flatten(),
```

```

        'y_coord': y_coords.flatten(),
        'people': ds_array.flatten()
    }
    df1 = pd.DataFrame(data1)
    # 对坐标进行处理
    df1['x_coord'] = df1['x_coord'].round(2)
    df1['y_coord'] = df1['y_coord'].round(2)

    wkt = 'PROJCS["Krasovsky_1940_Albers",GEOGCS["Unknown datum based upon the Krassowsky 1940
    ellipsoid",DATUM["Not_specified_based_on_Krassowsky_1940_ellipsoid",SPHEROID["Krassowsky
    1940",6378245,298.3,AUTHORITY["EPSG","7024"]],AUTHORITY["EPSG","6024"]],PRIMEM["Greenwich",0],UNIT["degre
    e",0.0174532925199433,AUTHORITY["EPSG","9122"]],AUTHORITY["EPSG","4024"]],PROJECTION["Albers_Conic_Equa
    l_Area"],PARAMETER["latitude_of_center",0],PARAMETER["longitude_of_center",105],PARAMETER["standard_parallel_1
    ",25],PARAMETER["standard_parallel_2",47],PARAMETER["false_easting",0],PARAMETER["false_northing",0],UNIT["met
    re",1,AUTHORITY["EPSG","9001"]],AXIS["Easting",EAST],AXIS["Northing",NORTH]]'
    proj_from = Proj(wkt)

    # proj_from = Proj('EPSG:32650') # 替换为您的平面坐标系
    proj_to = Proj('EPSG:4326') # WGS84 经纬度坐标系

    # 使用 transform 函数进行转换
    df1['latitude'], df1['longitude'] = transform(proj_from, proj_to, df1['x_coord'].values, df1['y_coord'].values)

    # 处理人口数
    grouped_data = df1.groupby(['x_coord', 'y_coord']).mean().reset_index()
    grouped_data = grouped_data[grouped_data['people'] >= 0]
    #####

    grouped_data['longitude'] = grouped_data['longitude'].round(0)
    grouped_data['latitude'] = grouped_data['latitude'].round(0)
    grouped_data1 = grouped_data.groupby(['longitude', 'latitude']).mean().reset_index()
    print(grouped_data1)

    #GDP
    tif_file=r"E:\博士工作\比赛\2024-第 21 届华为杯中国研究生数学建模\赛题\数据集 6\GDP_output\gdp2014.tif"
    data=rasterio.open(tif_file)
    ds_array=data.read(1)
    transform1=data.transform

    left, top = transform1 * (0, 0) # 左上角的经纬度
    pixel_width = transform1.a # 像素宽度（经度方向）
    pixel_height = -transform1.e # 像素高度（纬度方向）
    width = data.width
    height = data.height

```



```

# 创建行和列的索引
rows = np.arange(height)
cols = np.arange(width)

# 创建网格索引
cols_grid, rows_grid = np.meshgrid(cols, rows)

# 计算每个像素的平面坐标
x_coors = left + (cols_grid + 0.5) * pixel_width
y_coors = top - (rows_grid + 0.5) * pixel_height

# 创建一个 DataFrame
data1 = {
    'x_coord': x_coors.flatten(),
    'y_coord': y_coors.flatten(),
    'gdp': ds_array.flatten()
}
df1 = pd.DataFrame(data1)

# 对坐标进行处理
df1['x_coord'] = df1['x_coord'].round(2)
df1['y_coord'] = df1['y_coord'].round(2)

wkt = 'PROJCS["Krasovsky_1940_Albers",GEOGCS["Unknown datum based upon the Krassowsky 1940
ellipsoid",DATUM["Not_specified_based_on_Krassowsky_1940_ellipsoid",SPHEROID["Krassowsky
1940",6378245,298.3,AUTHORITY["EPSG","7024"]],AUTHORITY["EPSG","6024"]],PRIMEM["Greenwich",0],UNIT["degre
e",0.0174532925199433,AUTHORITY["EPSG","9122"]],AUTHORITY["EPSG","4024"]],PROJECTION["Albers_Conic_Equa
l_Area"],PARAMETER["latitude_of_center",0],PARAMETER["longitude_of_center",105],PARAMETER["standard_parallel_1
",25],PARAMETER["standard_parallel_2",47],PARAMETER["false_easting",0],PARAMETER["false_northing",0],UNIT["met
re",1,AUTHORITY["EPSG","9001"]],AXIS["Easting",EAST],AXIS["Northing",NORTH]]'
proj_from = Proj(wkt)

# proj_from = Proj('EPSG:32650') # 替换为您的平面坐标系

proj_to = Proj('EPSG:4326') # WGS84 经纬度坐标系

# 使用 transform 函数进行转换
df1['longitude'], df1['latitude'] = transform(proj_from, proj_to, df1['x_coord'].values, df1['y_coord'].values)

# 处理人口数
grouped_data = df1.groupby(['x_coord', 'y_coord']).mean().reset_index()
grouped_data = grouped_data[grouped_data['gdp'] >= 0]
#####

```

```

grouped_data['longitude'] = grouped_data['longitude'].round(0)
grouped_data['latitude'] = grouped_data['latitude'].round(0)
grouped_data1 = grouped_data.groupby(['longitude', 'latitude']).mean().reset_index()

print(grouped_data1)

###标准差椭圆分析
import pandas as pd
import seaborn as sns
import matplotlib.pyplot as plt

cropland_nineties = pd.read_csv("cropland-1990.csv")
cropland_noughties = pd.read_csv("cropland-2000.csv")
cropland_decade = pd.read_csv("cropland-2010.csv")
cropland_twentieth = pd.read_csv("cropland-2019.csv")

forest_nineties = pd.read_csv("forest-1990.csv")
forest_noughties = pd.read_csv("forest-2000.csv")
forest_decade = pd.read_csv("forest-2010.csv")
forest_twentieth = pd.read_csv("forest-2019.csv")

grass_nineties = pd.read_csv("grass-1990.csv")
grass_noughties = pd.read_csv("grass-2000.csv")
grass_decade = pd.read_csv("grass-2010.csv")
grass_twentieth = pd.read_csv("grass-2019.csv")

shrub_nineties = pd.read_csv("shrub-1990.csv")
shrub_noughties = pd.read_csv("shrub-2000.csv")
shrub_decade = pd.read_csv("shrub-2010.csv")
shrub_twentieth = pd.read_csv("shrub-2019.csv")

wetland_nineties = pd.read_csv("wetland-1990.csv")
wetland_noughties = pd.read_csv("wetland-2000.csv")
wetland_decade = pd.read_csv("wetland-2010.csv")
wetland_twentieth = pd.read_csv("wetland-2019.csv")

column_name = 'coverage_ratio'
sns.kdeplot(cropland_nineties[column_name], fill=True, color='#FFD700')
sns.kdeplot(cropland_noughties[column_name], fill=True, color='#FFD700')
sns.kdeplot(cropland_decade[column_name], fill=True, color='#FFD700')
sns.kdeplot(cropland_twentieth[column_name], fill=True, color='#FFD700')

```

```
sns.kdeplot(forest_nineties[column_name], fill=True, color='#006400')
sns.kdeplot(forest_noughties[column_name], fill=True, color='#006400')
sns.kdeplot(forest_decade[column_name], fill=True, color='#006400')
sns.kdeplot(forest_twentieth[column_name], fill=True, color='#006400')

sns.kdeplot(grass_nineties[column_name], fill=True, color='#90EE90')
sns.kdeplot(grass_noughties[column_name], fill=True, color='#90EE90')
sns.kdeplot(grass_decade[column_name], fill=True, color='#90EE90')
sns.kdeplot(grass_twentieth[column_name], fill=True, color='#90EE90')

sns.kdeplot(shrub_nineties[column_name], fill=True, color='#6B8E23')
sns.kdeplot(shrub_noughties[column_name], fill=True, color='#6B8E23')
sns.kdeplot(shrub_decade[column_name], fill=True, color='#6B8E23')
sns.kdeplot(shrub_twentieth[column_name], fill=True, color='#6B8E23')

sns.kdeplot(wetland_nineties[column_name], fill=True, color='purple')
sns.kdeplot(wetland_noughties[column_name], fill=True, color='purple')
sns.kdeplot(wetland_decade[column_name], fill=True, color='purple')
sns.kdeplot(wetland_twentieth[column_name], fill=True, color='purple')
```