



中国研究生创新实践系列大赛
“华为杯”第二十一届中国研究生
数学建模竞赛

学 校 中国石油大学（华东）

参赛队号 24104250063

1.吴世玉

队员姓名 2.武李曼

3.郑直

中国研究生创新实践系列大赛
“华为杯”第二十一届中国研究生
数学建模竞赛

题 目： 大数据驱动的地理综合问题

摘 要：

大自然无时无刻在影响人类生活，人类活动也不停地影响着自然，人文、自然等多种要素组合成了**地理系统**，相互依存。随着对地观测技术的飞速发展，如何利用巨量的对地观测数据对地理系统进行综合评估以及预测，成为了目前地理学科的关键问题。本文基于多种自然地理、人文地理的观测数据，对我国环境要素的变化、环境要素间的作用、极端天气灾害等进行了建模研究。

问题一：针对我国长时序的降水量、土地利用/土地覆被类型数据，在预处理数据后进行时空趋势分析和特征分析，基于 **Mann-Kendall 检验法**进行显著性检验，用于探测变化较大点，利用 **Sen's 法**进行斜率估计，用于预测估计降水量等地理参数的变化量。

问题二：为了探究地理因子对于暴雨等极端天气的影响程度，通过可视化分析，采用皮尔逊指数对各值进行**相关性分析**，通过建立**多元回归模型**以及四种机器学习模型（**随机森林、支持向量机、XGB 与 ADB**），并采用网格搜索法与交叉验证法进行机器学习模型的**超参数调优**与模型验证，通过数学模型来说明探究地理因子间的影响与它们对极端天气的影响。

问题三：为了预测应对暴雨灾害能力最为脆弱的地区，首先，基于我国 **DEM 数据**得到**径流数据**，并基于 2010 年-2020 年降水量数据预测 **2025 年-2035 年的我国降水量数据**，基于已构建模型情况判断暴雨成灾的临界条件。然后，基于 **H-E-V 模型**构建我国应对暴雨灾害能力**脆弱性评价体系**，选择各级指标，利用**层次分析法**确定各个指标权重。最后，基于脆弱性评价体系预测 2025 年-2035 应对暴雨灾害能力脆弱地区，结合地区的地形以及气候因素，针对三个重点区域分开进行讨论。

问题四：为探究我国土地利用变化的特征与结构，可视化分析了我国多种地理、人文**分界线**，对于土地利用的**增长率与减少率**分开讨论，土地利用变化率与多种地理因素分别进行相关性讨论，建立**机器学习模型**并验证，基于地理因素**预测 2025 年-2035 年的我国土地利用变化率**并进行分析说明。

关键词： 时空特征分析；H-E-V 模型；机器学习；预测模型；评价体系

目录

1. 问题综述	4
1.1 问题背景	4
1.2 问题分析	4
2. 模型假设	4
3. 问题一的分析与求解	5
3.1 问题分析	5
3.2 数据处理	5
3.3 降水量时空演化特征分析	7
3.3.1 相关性分析	7
3.3.2 Mann-Kendall 检验法	10
3.3.3 Sen's 斜率估计法	12
3.4 土地利用/土地覆被类型时空演化特征分析	13
3.4.1 相关性分析	13
3.4.2 特征分析	16
4. 问题二的分析与求解	18
4.1 问题分析	18
4.2 数据处理	18
4.3 数据分析	20
4.3.1 可视化分析	20
4.3.2 相关性分析	25
4.4 模型建立	27
4.4.1 多元回归模型	27
4.4.2 机器学习模型	31
4.5 结果分析	32
5. 问题三的分析与求解	33
5.1 数据处理	33
5.2 2025-2035 降水量预测	34
5.3 暴雨成灾的临界条件	35
5.4 暴雨灾害能力脆弱性研究	36
5.4.1 指标参数选择	36
5.4.2 指标权重确定	36
5.4.3 脆弱地区预测	38
5.5 预测结果分析	39
6. 问题四的分析与求解	41
6.1 数据处理	41
6.2 地理分析	41
6.3 模型建立	45
6.3.1 相关性分析	45
6.3.2 机器学习模型	48
6.3.3 准确性分析	48
6.3.4 有用性分析	49
7. 模型的评价与改进	50

7.1	模型的优点.....	50
7.2	模型的不足.....	51
7.3	模型的改进.....	51
参考文献		51
附录		52

1. 问题综述

1.1 问题背景

地理系统包括人类赖以生存和生活并影响的整个**自然环境和社会经济环境**，在空间上包括地球表层的各个圈层：**岩石圈、水圈、大气圈、生物圈**。随着地球观测体系的发展，如何准确利用对地观测数据，对研究全球气候变化下中国地理环境的**变化趋势及未来演化**具有重要意义。

我国地域辽阔，自然条件复杂，属于典型的季风气候区，因此灾害天气种类繁多，且不同地区具有**差异性**。持续性强降水、极端低温、复合型极端高温干旱、群发性热浪和台风等极端天气气候事件对我国经济社会和可持续发展影响巨大。与此同时，在全球气温变化的背景下，灾害天气更具持续性、突发性等特点。据数据显示，2023 年全国自然灾害致**9544.4 万人次**受灾，直接经济损失**3454.5 亿元**。全年洪涝灾害共造成**5278.9 万人次**不同程度受灾，直接经济损失**2445.7 亿元**。

传统的暴雨天气临近预报主要依赖雷达，雷达可以探测到大气中的降水物，从而提供有关降水强度、类型和位置等信息。采用雷达外推预报方法来估计未来时刻的降水量。然而，影响暴雨发生发展的因素繁多且复杂，风云变幻的过程和影响很难被精确量化。随着**大数据**积累和计算机算力的提升，**深度学习**技术的迅速发展为改进强对极端天气的预测提供了新的机会。如何通过地理大数据，对以暴雨为代表的极端天气事件变化趋势及未来演化进行**预测**，探索全球气候变化下中国地理环境的**演化**，已经成为当前地球科学研究的关键问题。

1.2 问题分析

针对利用地理大数据探究各环境要素之间的**相互作用**，并预测以暴雨为代表的极端天气事件变化趋势，建立数学模型是一种常见的解决方法。下面是针对本文的问题分析以及建模思路：

问题一：要求总结**降水量与土地利用/土地覆被类型**在 1990 至 2020 年间中国范围内的**时空演化特征**，主要用到的数据有数据集 3（日降水）、数据集 4（土地利用/土地覆被类型）的数据，对他们预处理、可视化分析并进行**趋势分析**以及**特征分析**。

问题二：要求建立数学模型以说明**地形-气候**相互作用在**极端天气**形成过程中的作用，主要用到的数据为数据集 1（高程）、数据集 2（地表气温）、数据集 3（日降水）的数据，对他们进行预处理、相关性分析，分别建立**多元回归模型**与**机器学习模型**进行对比，择优模型用于说明地形-气候在极端天气形成过程中的作用。

问题三：要求确定暴雨成灾的**临界条件**，以地图的形式对 2025 至 2035 年间中国境内应对暴雨灾害能力最为脆弱的地区进行**预测**。旨在针对暴雨灾害**脆弱性**进行**评价体系的构建**，首先选取指标并确认权重，再对脆弱地区进行预测，最后分析预测结果。

问题四：旨在建立数学模型描述中国土地利用变化的特征与结构，通过选择指标并进行相关性分析，建立机器学习模型，**预测**中国土地利用变化趋势，**解释验证**所得的结果，并进行**准确性**和**有用性**评价。

2. 模型假设

- （1）假设优化过程中各观测数据样本是**独立的**，不会相互影响。

- (2) 假设人口密度越高，**城市化**越严重，会增加暴雨成灾的风险。
- (3) 假设我们所使用的数据**可靠**，具有合理的分辨率和精度。
- (4) 假设实验过程中不会有**极端天气**影响。
- (5) 假设数据变化趋势不受**政策**影响。
- (6) 假设我们所使用的数据具有**代表性**，模型经过训练后具有可推广性。

3. 问题一的分析与求解

3.1 问题分析

首先，我们选择使用 Matlab 和 ArcGIS 作为工具。要对研究区域内降水量的**时空演化特征**进行分析，需要对原始数据进行处理，原始数据为 **Netcdf** 格式，转换成需要的 **GeoTIFF** 格式，以便后续的处理分析，接着使用转换后的数据计算月平均降水量、季平均降水量和年平均降水量。以此为基础，我们可以建立一个分析指标体系，包括**年均变化率**、**标准差**以及两者之间的关系，并计算**皮尔逊相关系数**。这些指标将帮助我们量化降水量的变化特征。接下来，使用 **Mann-Kendall (MK) 检验**来检测降水量时间序列的单调性趋势，并通过 **Sen's 斜率估计**最终的趋势斜率。通过以上步骤，我们能够全面分析 1990 至 2020 年间中国范围内降水量的时空演化特征。这一分析不仅揭示了降水量的变化趋势和波动性，还为气候变化研究和水资源管理提供了重要依据。

同样，要对研究区域内土地利用/土地覆被类型的时空演化特征进行分析，需要根据原始数据计算各土地利用/土地覆被类型在 1990 至 2019 年间的占比，并进一步计算土地利用/土地覆被类型的**变化率**，通过绘制折线图进行可视化分析，最后计算各土地利用/土地覆被类型在 1990 至 2019 年间的**年均分布情况**和变化率，分别绘制专题图进行可视化分析，这样可以更直观地展示其时空演化特征。这种方法将有助于我们理解土地利用变化的动态过程以及其对生态环境的潜在影响。




图 3-1 时空演化分析结构图

3.2 数据处理

数据处理是数据分析和建模过程中的关键步骤，能够为后续的分析奠定坚实的基础，从而提高了研究结果的可靠性和科学性。为了统计指标和图表，对降水量和土地利用/土地

覆被类型在 1990 至 2020 年间中国范围内的时空演化特征进行描述和总结，本节选择题目提供的数据集 3（日降水）和数据集 4（土地利用/土地覆被类型）中的数据进行处理分析，所选数据详细信息如表 3-1 所示。

表 3-1 问题一数据集信息表

数据集	数据	时间分辨率	空间分辨率	时间范围	数据格式
数据集 3	日平均降水数据	1day	0.25°	1961-2022	NetCDF
数据集 4	土地利用/土地覆被类型	1year	0.5°	1900-2019	TIFF




图 3-2 NetCDF 数据结构

降水量的原始数据是一个 NetCDF 文件，由于该格式具有数据存储量小、传输速度快以及自描述信息等优点被广泛用于与气象领域，可使用 panoly 进行数据信息的查看与简单的可视化。文件中包含了 22645 层图像，每一层图像对应从 1961 年 1 月 1 日至 2022 年 12 月 31 日每一天的降水量分布（中国台湾省及南海地区数据暂缺）。每一层图像中，像素大小为 0.25°×0.25°，像素的值代表了地表对应位置的降水量，单位为毫米。该数据集的经纬度范围为 18°N 至 54°N 和 72°E 至 136°E，适用于气候研究和水资源管理等多个领域。

表 3-2 降水量数据参数

参数项	数据信息
空间分辨率	0.25°×0.25°
时间分辨率	1day
经纬度范围	18°N-54°N, 72°E-136°E
格网数量	144×256
数据时间	1961-01-01 00:00:00
原始数据量大小	3.29GB
原始数据格式	NetCDF

为了便于后续的分析和应用，我们需要对降水量的原始数据进行格式转换。使用 Matlab 将原始数据转换为 TIFF 格式。这一转换过程生成了 1961 年至 2022 年间的逐日降水栅格图像，总计 22645 张 TIFF 图像。这些图像不仅保留了时间和空间的信息，还使得数据处理和可视化更加方便。

在获得转换后的逐日降水栅格数据后，我们需要进一步计算月平均降水量、季平均降水量和年平均降水量。这一计算过程需要特别注意不同年份和月份的具体日期，以确保最终结果的准确性。例如，某些年份的 2 月可能包含 29 天，而其他年份则只有 28 天。通过这种方式，我们能够更准确地反映降水量的时空变化特征，为后续的气候分析提供可靠的

数据基础。

月平均降水量:

$$P_{月} = \frac{1}{n} \sum_{i=1}^n P_{日,i} \tag{3-1}$$

其中， $P_{日,i}$ 为该月的每日降水量， n 为该月的天数。

季平均降水量:

$$P_{季} = \frac{1}{n} \sum_{j=1}^n P_{月,j} \tag{3-2}$$

其中， $P_{月,j}$ 为该季的月平均降水量， n 为该季的月数。

年平均降水量:

$$P_{年} = \frac{1}{n} \sum_{k=1}^n P_{季,k} \tag{3-3}$$

其中， $P_{季,k}$ 为该年的季平均降水量， n 为该年的季数。

土地利用/土地覆被类型的原始数据集包含 1900-2019 年耕地、林地、草地、灌木丛、湿地五种土地覆被类型在中国的分布情况，以 GeoTIFF 图像格式保存，共 600 幅影像。每一类覆被类型的文件分别以覆被类型的英文名词开头，以年份结尾。图像中每个像素的大小为 $0.5^{\circ} \times 0.5^{\circ}$ ，像素的值在 0~1 之间，表示像素中该覆被类型所占面积比例。GeoTIFF 是一种扩展的 TIFF（Tagged Image File Format）文件格式，专门用于存储地理空间数据。它能够将图像数据与地理参考信息结合在一起，使得图像可以在地理信息系统（GIS）中进行有效的使用和分析。

表 3-3 土地利用/土地覆被类型数据参数

参数项	数据信息
空间分辨率	$0.5^{\circ} \times 0.5^{\circ}$
时间分辨率	1year
经纬度范围	18.125°N–53.875°N, 72.125°E–135.875°E
栅格数量	144×256
数据时间	1900-2019 年
原始数据量大小	23.3MB
原始数据格式	GeoTIFF

3.3 降水量时空演化特征分析

3.3.1 相关性分析

年平均降水量是指在该年内，研究区域的总降水量（包括雨水、雪水等）除以该年内的天数，通常以毫米（mm）为单位表示。它反映了一个地区在一年内的平均降水水平，是气候研究和水资源管理的重要指标。年平均降水量及其变化率的计算在多个领域中具有重要的应用价值，对于科学研究和实际决策都提供了必要的技术支持。我们使用计算好 1990

至 2020 年间每年的年平均降水量来进一步计算每年的年平均降水量的变化率。年平均降水量变化率计算公式：

$$R = \frac{P_{\text{年},t} - P_{\text{年},t-1}}{P_{\text{年},t-1}} \times 100\% \quad 3-4$$




图 3-3 研究区域年均降水量与年变化率(1990-2020)

图中横坐标为年份，左侧纵坐标为年平均降水量，右侧纵坐标为降水量变化率，图中蓝色线条表示从 1990 年到 2022 年研究区域平均降水量的变化趋势，单位为毫米（mm）。红色线条则显示降水量的年变化率，展示了每年与前一年相比的降水量变化百分比。通过该图，我们可以观察到，在这段时间内，年均降水量虽然存在波动，但并未呈现出明显的上升或下降趋势。此外，年变化率大部分年份保持在 10% 之内，个别年份如 2010 年和 2012 年则表现出相对较为剧烈的波动。总体来看，1990 年至 2020 年间，研究区域平均降水量的变化较为波动，但并没有显著的长期增加或减少趋势。年变化率也相对稳定，但个别年份的降水量出现了明显的增减。例如，变化量最大的年份是 2012 年，其变化量为 0.13 mm，而变化率最高的年份同样是 2012 年，达到了 21.56%。这些数据表明，尽管整体趋势平稳，但特定年份的降水变化依然值得关注，可能与气候变化或极端天气事件有关。

为了度量研究区域年平均降水量在 1990 至 2020 年之间的波动性，我们通过对每年的标准差进行计算并随年份变化进行可视化，揭示降水量在时空上的波动情况。年平均降水量标准差是指在研究区域中一定时间范围内（如多个年份）计算的年平均降水量的离散程度。它反映了不同年份年平均降水量的波动性或变异性。标准差越大，表示降水量的波动越大；标准差越小，表示降水量相对稳定。年平均降水量标准差的计算在气候研究、水资源管理、农业规划等方面都具有重要的实际意义，能够帮助我们更全面地理解和应对降水变化带来的问题。

年平均降水量标准差计算公式：

$$\sigma = \sqrt{\frac{1}{n} \sum_{m=1}^n (P_{\text{年},m} - \bar{P})^2} \quad 3-5$$

其中， $\bar{P}$ 为年平均降水量的平均值。




图 3-4 研究区域平均降水量标准差(1990-2022)

在该图中，纵轴表示标准差，单位为毫米（mm），横轴表示年份（Year）。从图中可以看出，全国平均降水量的标准差大部分集中在 1.1 至 1.4 mm 的范围内，且整体上没有明显的上升或下降趋势。年平均降水量的标准差都大于 1mm，这表明在 1990-2020 年，降水量的波动性是相对较大的。标准差最大的年份是 **2016 年**，标准差为 **1.49 mm**，这表明在这一年研究区域的降水量波动较大。经过查阅资料发现，2016 年国内发生了多项极端天气事件，使得全年平均降水量创下 1951 年以来的最高记录，长江流域的降水尤为严重，导致长江中下游全线超警。此外，该年还经历了“莫兰蒂”台风、超强厄尔尼诺事件、“Boss 级”寒潮，以及罕见的龙卷风等极端天气现象。这些事件引发了大面积的洪涝、风雹、滑坡、泥石流等自然灾害，导致了巨大的直接经济损失。相对而言，标准差最小的年份是 **2011 年**，标准差为 **1.07 mm**，表明该年降水量的波动性较小，整体较为稳定。这些分析结果为理解降水量的时空波动特征及其与极端天气事件之间的关系提供了重要依据。

为了衡量年平均降水量和年降水量标准差两个变量之间的线性关系，我们引入了**皮尔逊相关系数（Pearson Correlation Coefficient）**。皮尔逊相关系数是一种衡量两个变量之间线性关系强度和方向的统计指标，其计算公式如下：

$$r = \frac{n\sum(XY) - \sum X \sum Y}{\sqrt{[n\sum X^2 - (\sum X)^2][n\sum Y^2 - (\sum Y)^2]}} \quad 3-6$$

X代表年平均降水量，Y代表年降水量标准差

n：数据点的数量（年数）

$\sum(XY)$ ：年平均降水量与年降水量标准差对应值的乘积的总和

$\sum X$ ：年平均降水量的总和

$\sum Y$ ：年降水量标准差的总和

$\sum X^2$ ：年平均降水量的平方的总和

$\sum Y^2$ ：年降水量标准差的平方的总和

$r = 1$ ：完全正相关

$r = -1$ ：完全负相关

$r = 0$ ：没有线性相关性

$0 < r < 1$ ：正相关

$-1 < r < 0$ ：负相关




图 3-5 研究区域平均降水量和标准差关系图(1990-2020)

年平均降水量和年降水量标准差的皮尔逊相关系数为 **0.85**，这表明这两个变量之间存在强烈的**正相关**关系。图中横坐标为年平均降水量，单位为毫米（mm），纵坐标为其标准差，通过研究区域年平均降水量与标准差的散点图，我们可以拟合出两者之间的线性关系，得到线性关系式 $y=1.65x+0.13$ ，其中 y 代表年降水量标准差，而 x 代表年平均降水量。这意味着年平均降水量每增加一个单位，年降水量标准差大约增加 1.65 个单位。此外，常数项 0.13 表示在年平均降水量为零时，年降水量标准差的预测值。该线性关系进一步验证了年平均降水量与其标准差之间的密切联系，为进一步研究水资源管理和气候变化提供了重要参考依据。

3.3.2 Mann-Kendall 检验法

MK 检验是一种非参数秩检验的气候诊断与预测技术，可以实现序列趋势的显著性判断[5]，尤其适用于气候和水文数据的**趋势分析**。该方法的优点是对数据的分布没有特定要求，适合处理含有缺失值和异常值的情况，计算也比较简便，这种方法已广泛应用于世界各地，可用来检测气候和水文变量的趋势。MK 检验法定义的统计量 S 表示为：

$$S = \sum_{i=1}^{n-1} \sum_{j=i+1}^n \text{sgn}(X_j - X_i) \quad 3-7$$

在这个式子中， n 是时间序列的数据长度（在本研究下， $n = 30$ 年）， X_j 与 X_i 是分别通过将 j 和 i 年的年平均值再次进行平均而得出的数据值，其中 $j > i$ ，而 $\text{sgn}(X_j - X_i)$ 为符号函数，其含义是：

$$\text{sgn}(X_j - X_i) = \begin{cases} 1 & \text{if } (X_j - X_i) > 0 \\ 0 & \text{if } (X_j - X_i) = 0 \\ -1 & \text{if } (X_j - X_i) < 0 \end{cases} \quad 3-8$$

当 $n \geq 10$ 时，可以将统计量 S 近似看作为正态分布，此时正态分布的均值 $E(S) = 0$ 。进而使 S 标准化得到 Z ，再进行**显著性检验**，判断序列的升降趋势。获得 Z 的公式可以表达为：

$$Z = \begin{cases} \frac{S-1}{\sqrt{V(S)}} & \text{if } S > 0 \\ 0 & \text{if } S = 0 \\ \frac{S+1}{\sqrt{V(S)}} & \text{if } S < 0 \end{cases} \quad 3-9$$

其中方差 $V(S)$ 可由此公式得到：

$$V(S) = \frac{n(n-1)(2n+5) - \sum_{i=1}^m t_i(t_i-1)(2t_i+5)}{30} \quad 3-10$$

此式子中 m 为序列中的结的个数，结是指重复出现的数据组。 t_i 指结的宽度，即重复数据组的重复数据个数。在此研究中结为 0，故分子中的被减数为 0。用双边趋势检验 Z ，在给定显著水平 α 的情况下，若 $|Z| \leq Z_{1-\alpha/2}$ ，表明趋势不显著，反之，若 $|Z| > Z_{1-\alpha/2}$ 说明趋势显著。当 $Z \geq Z_{1-\alpha/2}$ 则表明序列呈上升趋势， $Z < -Z_{1-\alpha/2}$ 时说明序列呈下降趋势。

其中 $Z_{1-\alpha/2}$ 是从标准正态累积分布表中获得的。对于 90%，95%和 99%的置信水平， Z 的临界值分别为 1.65、1.96 和 2.58。对于标准值 Z 的计算结果，如果其值大于 0，则表示序列呈上升趋势；如果其值小于 0，则表示序列呈下降趋势。




图 3-6 Z 值分布图

如图所示， Z 值有 76.07% 大于 0，有 1.82% 等于 0，还有 22.11% 小于 0，根据 Z 值的分布情况，我们可以得出在 1990 到 2020 年之间，有 76.07% 的研究区域降水量呈上升趋势，22.11% 的研究区域降水量呈下降趋势，而 1.82% 的研究区域降水量保持相对稳定。这表明大多数研究区域在此期间经历了降水量的增加。




图 3-7 MK(Mann-Kendall)检验法计算 Z 值结果

根据 MK 检验计算出的 Z 值绘制研究区域的 Z 值分布变化情况 TIFF 图像,如图所示,偏蓝色部分代表降水量呈下降趋势的区域,且颜色越蓝,表示下降趋势越显著;偏红色部分则表示降水量呈上升趋势,颜色越红则上升趋势越显著。在 1990 到 2020 年之间,研究区域内大部分降水量呈上升趋势,而降水量呈下降趋势的区域则相对集中。这种分布特征可能反映了区域性气候变化的影响。当 Z 的绝对值大于等于 1.64、1.96、2.58 时则说明该时间序列分别通过了置信水平 90%、95%、99% 的显著性检验。本文选择 1.65 为判断标准。

表 3-4 在 90%置信下,降水趋势及面积比例表

Z	降水趋势	面积比例
>1.65	显著	27.44%
-1.65~1.65	不显著	70.99%
<-1.65	显著	1.56%




图 3-8 Z 值分布柱状图

由图表可得,在 90% 的置信水平下,1990 至 2020 年间,有 28.99% 的研究区域降水变化显著,其中大部分年平均降水量变化显著的地区呈上升趋势。同时,有 70.99% 的研究区域降水变化不显著,表明这些区域的降水量变化情况较为稳定。整体计算结果与实际情况较为吻合,在一定程度上反映了研究区域内降水量变化的特征和趋势。

3.3.3 Sen's 斜率估计法

Sen’s 斜率估计法是一种用于计算时间序列趋势的非参数方法，并不受异常值的影响，抗燥性强[4]，通常与 Mann-Kendall 检验结合使用，在进行 MK 检验后，如果发现趋势显著，可以进一步使用 Sen’s 斜率估计法来量化趋势的大小。既可实现序列趋势的显著性判断并且估计趋势斜率。斜率的计算可由 n 对数据点的所有斜率中值得到，公式为：

$$\beta = Median\left(\frac{x_j - x_i}{j - i}\right), \forall j > i \tag{3-11}$$

其中 X_j 与 X_i 是分别通过将 j 和 i 年的年平均降水值再次进行平均而得出的数据值。Median 表示中值函数。估计斜率 β 表示此序列的平均变化率以及时间序列的趋势，正值表示上升趋势，而负值则表明下降趋势。通过将 Sen’s 斜率估计法和 MK 检验法算出 1990-2020 年研究区域内降水量的时间序列，进行趋势分析，以确定降水量的变化速率大小。




图 3-9 Sen’s 斜率估计法计算 β 值结果

表 3-5 MK-Sen’s 降水量趋势统计

β	Z	降水趋势	面积比例
>0.0005	>1.65	明显加强	27.44%
>0.0005	-1.65~1.65	轻微加强	45.67%
-0.005~0.005	-1.65~1.65	基本不变	6.91%
<0.0005	-1.65~1.65	轻微减弱	18.40%
<0.0005	<-1.65	明显减弱	1.56%

研究区域年平均降水量变化的斜率估计结果 β 与 Z 统计值如表所示，其中 β 代表年平均降水量趋势的斜率，Z 统计值则通过 MK 检验获得。Z 的范围反映了年平均降水量在不同显著性水平下的变化情况。数据表明，**76.07%** 的 Z 统计值大于 0，显示出不同程度的上升趋势。同时，有 **77.11%** 的 β 值大于 0，且范围在 0 到 0.048 之间。分析结果表明，约 **29%** 的研究区域在 90% 的置信水平下显示出显著的正趋势，降水趋势轻微加强的区域占最大比例，达到 **45.67%**；而降水趋势明显减弱的区域占最小，仅为 **1.56%**。

3.4 土地利用/土地覆被类型时空演化特征分析

3.4.1 相关性分析

为了对研究区域内土地利用/土地覆被类型的时空演化特征进行分析，首先需要计算各土地利用/土地覆被类型在 1990 至 2019 年间的占比，土地利用占比是指某一特定土地利用

类型在一定区域内所占的比例，通常用百分比表示。它反映了不同类型土地在某一地区的分布情况，帮助分析和理解土地资源的管理与利用。**土地利用占比**计算公式：

$$P_t = \left(\frac{A_t}{A_{\text{total}}} \right) \times 100\% \quad 3-12$$

其中：

P_t = 当前年份的土地利用占比，

A_t = 当前年份特定土地利用类型的面积

A_{total} = 总土地面积（包括所有土地利用类型）




图 3-10 土地利用类型的占比(1990-2019)

图中横坐标为年份，纵坐标为各土地类型的平均占比，不同颜色的线条代表五种土地利用类型：农田（蓝色）、森林（橙色）、草地（黄色）、灌木（紫色）和湿地（绿色），它们的占比随时间变化。从图中可以看出，各类土地利用类型在时间上的变化**相对较小**，整体上没有显著的上升或下降趋势。森林（橙色）的占比呈现出相对较为明显的上升趋势，而农田（蓝色）、草地（黄色）、灌木（紫色）和湿地（绿色）四类土地类型则总体呈相对下降趋势，其中，草地（黄色）的下降趋势最为明显。这些变化可能反映了土地利用管理和生态环境变化的影响。

为了分析特定土地利用类型的动态变化趋势，我们需要进一步计算土地利用类型的年变化率。土地利用类型的年变化率是指某种土地利用类型在一年内的面积变化相对于该类型初始面积的比例，通常用百分比表示。土地利用类型的**年变化率**计算公式：

$$R_t = \left(\frac{A_t - A_{t-1}}{A_{t-1}} \right) \times 100\% \quad 3-13$$

其中：

R_t = 年变化率

A_t = 当前年份的面积

A_{t-1} = 前一年（即 t-1 年）的面积




图 3-11 土地利用类型的年变化率(1990-2019)

图中横坐标为年份，纵坐标为各土地类型的年变化率，从土地利用类型的年变化率图中可以看出，森林（橙色）的年变化率始终保持为正值，且在 1994 年达到最高增长速率，为 **3.6%**，随后总体增长率逐渐减小，草地（黄色）、灌木（紫色）和湿地（绿色）的变化率则持续为负，逐年减少。其中，湿地（绿色）在 2015 年的减少速率突然显著降低，增至 **-0.258%**。农田（蓝色）的年变化率基本保持在 0 附近，但在 2003 年变化率突然下降至最小值 **-1.659%**。这些变化反映了不同地形在时间上的动态变化，可能与气候变化和人类活动密切相关。

为了进一步定量分析不同土地利用类型在以研究时间内的平均增减幅度，我们对各土地利用类型在 1990 至 2019 年的年均变化率进行了计算分析。土地利用类型年均变化率是指在一定时间段内（通常为若干年）某一特定土地利用类型（如农田、森林、草地等）面积变化的平均比率。土地利用类型年均变化率是一个重要的指标，能够为土地管理、环境保护及可持续发展提供有价值的信息和依据。**年均变化率**计算公式：

$$R_{\text{avg}} = \frac{R_{\text{total}}}{N} \quad 3-14$$

其中：

R_{avg} =年均变化率

R_{total} =总变化率（可以是多个年份的变化率之和）

N=计算的年份数




图 3-12 土地利用类型的年均变化率(1990-2019)

图中横坐标为各土地利用类型，纵坐标为各土地利用类型在 1990 至 2019 年的平均变化率。从土地利用类型的年均变化率图中可以看出，在 1990 至 2019 年间，五种土地利用类型的增长速率从小到大依次为森林、农田、草地、灌木和湿地。其中，只有森林为正增长，达到 **1.92%**，显示出研究区域森林资源的逐渐恢复。其余四种土地利用类型均呈现负增长，其中湿地的负增长速率最大，为**-1.35%**，这可能反映了湿地生态系统的严重退化。农田的年均变化率基本保持不变，仅为**-0.06%**，表明农业用地的变化相对稳定，但仍需关注其长期发展趋势。

3.4.2 特征分析




图 3-13 1990-2019 年土地利用年均分布情况

为了分析研究区域土地利用/土地覆被类型在空间上的演化特征，我们对各土地利用类

型在 1990 至 2019 年的年均分布情况进行了计算及可视化。由图可得，**农田**（a）主要集中在华东和东北地区，反映出这些区域的农业生产活动较为旺盛，土壤肥沃，气候条件适宜。**森林**（b）主要分布在东北、西南和东南地区，这些地区的降水量和气温适合森林的生长，具有丰富的生态资源。**草地**（c）主要分布在青藏高原、内蒙古和西北地区，展现了这些区域的干旱和半干旱特征，适合牧羊和放牧。**灌木**（d）则主要分布在北部地区，适应了该地区相对寒冷和干燥的气候条件。**湿地**（e）主要分布在东北地区和中南地区，这些地区的湿地为生物多样性提供了重要栖息地，并在调节水文循环中发挥了关键作用。通过这些分析，可以更好地理解土地利用变化对生态环境的影响，以及为未来的土地管理和规划提供科学依据。




图 3-14 1990-2019 年土地利用变化率

为了进一步研究土地利用/土地覆被类型在空间上的演化特征，我们对各土地利用类型

在 1990 至 2019 年的变化率进行了计算及可视化。由图可得，**农田**（a）覆盖度在大部分地区呈现略微上升趋势，显示出农业生产的逐步提升和对耕地的合理利用。**森林**（b）覆盖度在大部分地区呈现上升趋势，尤其是在中南地区，增长幅度更为显著，反映出该区域的生态恢复和植树造林措施的成效。**草地**（c）覆盖度在东南地区整体呈下降趋势，可能与城市化进程和土地开发有关；而在西北地区，草地覆盖度变化较为稳定，显示出该地区生态环境的相对平衡。**灌木**（d）覆盖度的变化与草地覆盖度相似，在东南地区整体呈下降趋势，可能受到土地利用变化的影响，而在西北地区则保持稳定，表明该地区的自然环境相对保守。**湿地**（e）覆盖度在大部分地区呈下降趋势，且这一趋势较为明显，可能与人类活动、城市化和水资源开发有关，警示我们对湿地保护的迫切需求。通过这些分析，可以更好地理解土地利用变化对生态环境的影响，从而为未来的土地管理和生态保护提供指导。

4. 问题二的分析与求解

4.1 问题分析

问题二针对暴雨为代表的极端天气事件，提出通过结合**地形-气候**数据设计数学模型，说明地形与气候两个因素相互作用在极端天气形成过程中的作用。

将问题二分为三个部分，首先对数据集进行数据预处理（格式转换、数据合成、重采样等），获得月\季\年尺度的地形、气候的演变情况，然后对发生极端天气事件进行判断和记录分析，最后构建数学模型来判断地形-气候**相互作用**在极端天气形成过程中的作用。

问题二属于**数学回归问题**，对于解决此类问题一般使用多元线性回归、相关性分析以及机器学习等方法：将极端天气事件（如暴雨次数）作为**因变量**，将地形特征（高程、坡度、坡向）以及气候特征（温度）作为**自变量**，通过线性回归或非线性回归方法，建立自变量与因变量之间的数学关系，使用 **R²**、均方误差（**mean-square error, MSE**）等指标评估数学模型的**拟合**优度和预测能力，最后选择效果最佳的数学模型来阐述地形-气候相互作用在极端天气形成过程中的作用。

4.2 数据处理

在解决本问题中，数据预处理是构建可靠分析模型的关键步骤之一。对原始数据处理的准确性是影响研究结果的关键因素之一。因此，为了确保数据以及后续分析和建模的准确性，对给出的数据进行数据清洗、数据转换、数据处理等预处理工作。

为了明确地形在极端天气形成过程中的作用，使结果具有准确行以及综合性，本节针对该问题选择了数据集 1（高程）、数据集 2（地表气温）、数据集 3（日降水）中的数据进行数学建模，所选数据详细信息如表 4-1 所示。

表 4-1 数据详细信息

数据集	数据	时间分辨率	空间分辨率	时间范围	数据格式
数据集 1	chinadem_geo	——	1000m	——	TIFF
数据集 2	日平均气温数据	1day	0.1°	1979-2018	TIFF
数据集 3	日平均降水数据	1day	0.25°	1961-2022	NetCDF

（1） 高程数据处理

数据集 1 的 chinadem_geo 栅格数据信息为每个栅格点的经纬度以及高程值，为中国领土的 DEM 数据图 4-1，由高程值可以推算出**坡度（slope）**以及**坡向（aspect）**。




图 4-1 中国领土的 DEM 数据

坡度是地形表面相对于水平面的倾斜程度，通常以角度或百分比表示。坡度的计算基于 DEM 数据中某个点的高程变化速率，可以使用该点周围的八个邻点的高程值来估算。为了计算某点的坡度，首先需要计算出 DEM 数据中该点东西方向及南北方向的高程变化率，可以通过差分近似（公式 4-1）来计算：

$$\frac{\partial Z}{\partial x} = \frac{(Z_{i+1,j} - Z_{i-1,j})}{2d} \quad 4-1$$

其中， d 是网格的实际距离。以高程值矩阵 Z 为例，其每个元素代表该点的高程，计算某点 (i,j) 的坡度即（公式 4-2）：

$$Slope = \arctan \left(\sqrt{\left(\frac{\partial Z}{\partial x} \right)^2 + \left(\frac{\partial Z}{\partial y} \right)^2} \right) \quad 4-2$$

坡向是指地形坡面的朝向。坡向用于识别出从每个像元到其相邻像元方向上值的变化率最大的下坡方向。坡向是一个角度，将按照顺时针方向进行测量，角度范围介于 0（正东）到 360（仍是正东）之间，即完整的圆。坡向的计算基于使用坡度与 DEM 图中东西和南北方向的高程差异，用公式 3 计算得到：

$$Aspect = \text{atan2} \left(\frac{\partial Z}{\partial y}, -\frac{\partial Z}{\partial x} \right) \quad 4-3$$

由于坡度范围定义为 0 到 360 度，因此有时需要对计算结果进行调整。若 $Aspect < 0$ ，则加上 360 度。基于 MATLAB 对该数据进行栅格计算，根据公式 4-1、公式 4-2 与公式 4-3 计算得出坡度、坡向值，得到中国范围内坡度 TIFF 图以及坡向 TIFF 图（图 4-2）。




图 4-2 坡度数据（左）以及坡向数据（右）

（2）气温数据处理

数据集 2 的日地表气温数据为 1979 年-2018 年的天尺度中国范围内的地表气温数据。为了能以综合、全面的角度分析地表气温数据，根据公式 4-4 对日地表气温数据进行平均值融合：

$$T_{avg} = \frac{1}{n} \sum_{i=1}^n T_i \tag{4-4}$$

其中 T_{avg} 是融合后的平均气温， T_i 是第*i*观测值， n 是观测值的数量。最终获得中国月\季\年尺度的地表气温数据，以及 1961 年-2022 年的平均地表温度数据，纬度、海拔高度和海陆分布是影响我国温度分布的主要自然地理要素[15]。如图 4-3 所示，除青藏高原区域外，我国年均温分布特征表现为“南高北低”。




图 4-3 我国 1961 年-2022 年的平均地表温度数据

（3） 降水数据处理

为了对极端天气进行判断与记录，基于 MATLAB 对数据集 3 日降水 NC 数据转成日降水 TIFF 数据。基于中国气象局 (<https://www.cma.gov.cn/>) 对于降水的等级划分，如表 4-2 所示，以 24 小时降水总量 50mm 和 100mm 为阈值，采用**最大值合成法**，基于 MATLAB 计算 1961 年-2022 年单位栅格的降水次数、总降水量、暴雨次数、暴雨总量、大暴雨次数、大暴雨总量。

表 4-2 降水强度等级划分表

降水等级	24 小时降水总量(mm)
小雨	<10
中雨	10~25
大雨	25~50
暴雨	50~100
大暴雨	100~250
特大暴雨	>250

4.3 数据分析

本节通过对**地表温度、高程、坡度、坡向、降水量、降水次数**等因素进行可视化分析以及相关性分析，以便更直观的理解这些变量之间的关系以及它们对极端天气事件的影响。

4.3.1 可视化分析

降水量的变化具有很强的**时空异质性和随机性**，受到多种气象系统和天气现象的影响，难以用简单的规律来描述和预测[16]。本小节旨在通过绘制降水量与地形特征（高程、坡度

与坡向），降水量与气候特征（地表气温）关系图，直观显示变量的变化趋势以及变量之间的相关性。

（a） 降水参数与高程的可视化分析

分别绘制降水次数、总降水量、暴雨次数、暴雨总量、大暴雨次数、大暴雨总量与高程的散点图，由图 4-4 所示，中降水次数、总降水量与高程的散点图可以直观的看出我国降水较为集中在 **0m-2000m** 和 **4000m-6000m** 的区域：在 0m-2000m 的低海拔区域，尤其是沿海地区，水汽容易被海洋蒸发带入，并在陆地上形成降水，并且我国东部地区受夏季东南季风影响，带来丰富的水汽，特别是在低海拔区域，降水量明显增加。同时，沿海地区和河流流域受海洋影响较大，海洋提供的水汽在遇到地形抬升时容易形成降水；在 4000m-6000m 的高海拔地区，在 4000m-6000m 的高海拔地区，高原的**热力驱动作用**使暖湿气流从低纬度海洋向高原输送、汇聚[17]，气流上升导致温度降低，从而促进水汽凝结成降水，降水量依然可观。此外，我国的主要山脉（如喜马拉雅山、天山、秦岭等）和高原地区（如青藏高原）对降水有显著影响，山脉阻挡水汽，使得**迎风坡**区域降水量大，而**背风坡**则相对干燥。




图 4-4 降水参数与高程的散点图

结合降水参数与高程的散点图可知，随着高程的增加，暴雨次数与总量、大暴雨次数与总量都在迅速得减少：暴雨次数在高程增加到约 **3000m** 时开始趋近于 0；大暴雨次数在高程增加到约 **2000m** 时开始趋近于 0。




图 4-5 各降水参数与高程柱状图

对高程以 **500m** 的间距分段，绘制各降水参数与高程的柱状图，如图 4-5 所示，可以更直观的看出降水、暴雨以及大暴雨更集中的分布在 **0m-500m** 的区域，随着高程的增加，降水、暴雨以及大暴雨的次数和总量都在减少，只有降水的次数以及总量由于我国的特殊地貌以及高压的影响，会在高程抵达 **4000m** 之后出现少量增加的迹象。该现象说明了在 **0m-500m** 的低海拔地区，由于温暖湿润的气候条件，水汽更容易凝结并形成降水，因此，降水、暴雨和大暴雨在这一范围内更为集中。

综上所述，通过对于降水参数与高程的可视化分析，可以初步得知高程这一地形参数是影响降水的重要参数。在低海拔地区，降水更为集中，而在高海拔地区，降水的减少是普遍趋势，但特定条件下仍可能出现**局部**的降水增加。

(b) 降水参数与坡度、坡向的可视化分析

绘制降水天数与坡度、坡向的散点图，如图 4-6 所示，由图可知将降水天数均匀地分布在坡向 0° - 360° ，表明降水的发生与坡向的关系不大。这可能意味着降水主要受到气候因素（如季风、季节变化）和天气系统的影响，而不是地形的坡向。而降水总量更集中分布在 0° 左右以及 60° - 90° 的坡度中，表明在地势平缓的区域，没有山峦的阻碍，降水量较大，在 60° - 90° 坡度范围内，存在有利于降水集聚的地形特征，比如**地形抬升效应**，在坡度较大的区域，尤其是 70° - 90° ，可能促进了水汽的上升和凝结，从而产生更多的降水，或者是特定坡度更易受到湿润空气的影响，影响土壤水分的保持能力，进一步影响降水的汇集。




图 4-6 降水天数与坡度、坡向的散点图

由此可知，基于简单的可视化分析，坡度对于降水的影响要明显大于坡向对降水的影响。为了进一步探究坡度对于降水的影响，绘制了坡度等高线图，如图 4-7 所示。等高线图在地理和气象分析中主要用于展示变量的空间分布，每条等高线代表变是在该区域具有相同的值，通过观察等高线的密集度和形态，可以了解变量在空间上的变化趋势。结合图 4-8，可以大致发现在图 4-7 所展示的中国三个明显的大面积坡度较低的区域为中国西北部的阿克苏-和田地区、中国东北部的长春附近地域以及中国东部沿海地区。其中中国西北部的阿克苏-和田地区、中国东北部的长春附近地域由于整体坡度较周围地势不一，降水天数较周边都有明显的变化，而中国东部沿海地区相较东南沿海地区也有降水次数的变化。可知在我国，坡度对于降水有明显的影响。




图 4-7 坡度与总降水量的等高线图




图 4-8 降水天数图

通常情况下，由于季风以及地势等原因，降水受坡度和坡向的共同影响，由于探究以暴雨为例的极端天气，绘制不同坡度和坡向组合下的暴雨次数热力图，如图 4-9 所示，可知我国的暴雨更集中发生在坡度在 0° - 60° ，且坡向在 0° - 180° 的区间范围内，主要是由于地形的影响和气候条件的共同作用。适中的坡度有助于水分的积聚和径流，促进水汽的冷却与凝结，形成降水。同时，中国的降水主要受到季风气候的影响，尤其是东南季风，坡向朝向湿润气流的区域（如南方的东南坡）更容易接收到来自海洋的水汽，导致降水频繁，而朝向干燥区域或山区的坡向则可能降水较少。所以坡向 0° - 180° 区域受东南季风和湿润气流的影响，这些气流在遇到地形抬升时会增强降水，此外这些坡向通常面向海洋，便于接收丰富的水汽，进一步增加降水的频率和强度。因此，坡度和坡向的结合使得这些区域成为暴雨的高发地带。




图 4-9 不同坡度和坡向组合下的暴雨次数热力图

综上所述，通过对降水参数与坡度还有坡向的可视化分析，可以得知坡度对降水的影响比坡向对降水的影响更大，但是通常情况下是两者公共影响着降水。

（c） 降水参数与地表气温的可视化分析

绘制降水、暴雨以及大暴雨与年平均气温的散点图，由图 4-10 可知，无论是降水、暴雨还是大暴雨，都更集中分布在 0° 以上的温度区间，而暴雨与大暴雨主要出现在 10° - 20° 的温度区间内，在 0° 以下的温度区间次数很少。




图 4-10 降水、暴雨以及大暴雨与年平均气温的散点图

将温度以 5° 进行分段，绘制降水、暴雨以及大暴雨与年平均气温的柱状图，由图 4-11 可知，我国降水、暴雨以及大暴雨都在 -5° -5° 温度区间达到一个小峰值，然后在 10° -20° 温度区间达到一个大峰值，主要是由于大气稳定性和热量、水汽的结合：在 -5° 至 5° 的低温区间，空气稳定且湿度较高，易形成云层，促进降水；当温度升高到 10° 至 20° 时，空气热量增加，水汽饱和度提升，导致对流增强，从而引发更强的降水。此外，季风的影响在这一温度范围内尤为显著，带来大量水汽，增强了降水的强度。因此，这两个温度区间的降水峰值反映了大气中温度、湿度和气流的不稳定性及相互作用。




图 4-11 降水、暴雨以及大暴雨与年平均气温的柱状图

通过对降水参数与地表温度的可视化分析，可知降水、暴雨以及大暴雨更通常发生在 10° -20° 的区域，地表温度对于降水有着显著的影响。

4.3.2 相关性分析

相关性分析相较于可视化分析，提供了更系统和量化的视角。相关性分析在数据分析中具有重要性，尤其在研究降水与地形特征（如坡度和坡向）之间的关系时，能够量化变量之间的关系强度和方向。此外，相关性分析有助于后续的建立预测模型，通过已有数据预测其他变量的变化，并揭示潜在的机制，为因果分析提供线索。

在相关性分析中，相关系数是一种定量描述两组随机变量的统计学相关性的指标[18]。其中，**Pearson 相关系数**是一种衡量两个变量之间线性关系强度和方向的统计指标，取值范围从-1 到 1。值为 1 表示完全正相关，值为-1 表示完全负相关，而值为 0 则表示没有线性关系。Pearson 相关系数通过计算变量的协方差与它们标准差的乘积之比来得出，适用于连续型变量。由于它仅反映线性关系，因此在使用时需确保数据符合**正态分布**，并且对异常值敏感。因此，在分析变量关系时，Pearson 相关系数是一个重要且常用的工具，通常使用公式 4-5 计算：

$$r = \frac{n(\sum xy) - (\sum x)(\sum y)}{\sqrt{[n\sum x^2 - (\sum x)^2][n\sum y^2 - (\sum y)^2]}} \quad 4-5$$

其中， r 是 Pearson 相关系数， n 是样本数量， x 和 y 是两个变量的观测值， $\sum xy$ 是 x 和 y 的乘积之和， $\sum x$ 和 $\sum y$ 分别是变量 x 和 y 的总和， $\sum x^2$ 和 $\sum y^2$ 是变量 x 和 y 的平方和。

本节研究的参数主要为降水参数（降水天数、暴雨参数与大暴雨天数），地形特征参数（高程、坡度与坡向）和地表温度 7 个参数，基于公式 4-5 计算各个参数之间的 Pearson 相关系数，绘制相关性矩阵热力图，如图 4-12 所示。




图 4-12 各个参数之间相关性矩阵热力图

由图 4-12 可知，在地形特征参数之间，由于坡度与坡向是通过高程计算得来的，所以它们具有极高的相关性，相关性接近于 1。在降水参数之间，暴雨天数与降水天数和大暴雨天数相关性都较高，而大暴雨天数与降水天数相关性较低，说明降水频繁的地区，出现暴雨以及大暴雨的几率更高，而大暴雨作为极端天气，出现的条件受各方因素的影响，发生的频率要远远低于暴雨。地表温度与地形特征参数和降水参数之间都有明显的相关性。

由于本节研究对象为以暴雨为代表的极端天气事件，所以绘制了暴雨次数与其他参数的相关性柱状图，由图可知除了降水参数之外，与暴雨次数相关性最高的为地表温度，达到了 0.27，而地形特征参数的相关性相较更低（高程为 0.07、坡度为 0.06、坡向为 0.06）。尽管地形特征参数的相关性较低，但是为相较地表温度而言，由 4.3.1 可视化分析部分可知，地形特征参数对于暴雨有着明显的影响。




图 4-13 暴雨次数与其他参数的相关性柱状图

经过相关性分析，对于各个参数之间的相关性有了更直观的了解，为 4.4 模型建立中参数的选择以及权重的分配提供了数值参考。

4.4 模型建立

本节结合 3.3 对各参数数据的分析，旨在建立数学模型，说明地形-气候相互作用在极端天气形成过程中的作用。该问题为数学回归问题，常用的数学模型线性回归、多元回归以及机器学习等模型，由于该问题涉及多种参数因子，多元回归模型是用于研究多个自变量与一个因变量之间的关系[19]，故选择建立多元回归以及机器学习模型，并对模型进行验证择优，选取优秀模型来解释地形-气候相互作用在极端天气形成过程中的作用。

由于研究对象为以暴雨为代表的极端天气事件，所以以降水量与暴雨次数分布作为 Y，高程、坡度、坡向、地表温度为 X 建立数学模型。考虑到地形对地表气温也会有影响，所以以地表气温为 Y，高程、坡度、坡向为 X 建立数学模型。同时以降水量为 Y，以地表气温为 X 立数学模型来探究气温与降水量的数理关系。

为了验证所构建的模型，并选择**效果最优模型**，采取决定系数（ R^2 ）以及均方误差（Mean Squared Error, MSE）来评估模型的精度，这两个指标的公式如下：

$$R^2 = 1 - \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{\sum_{i=1}^n (y_i - \bar{y})^2} \quad 4-6$$

$$MSE = \frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2 \quad 4-7$$

其中， y_i 是实际值， $\hat{y}_i$ 是预测值， n 是数据点的数量， $\bar{y}$ 是实际值的平均值。

4.4.1 多元回归模型

为探究地形-气候相互作用在极端天气形成过程中的作用，选择降水总量或者暴雨次数作为因变量，选择高程（可以直接影响降水的分布，通常是重要的自变量）、坡度（影响水流和降水积聚）、坡向（影响阳光照射和气候，可能影降水）、地表气温（可以影响蒸发和降水的形成，是重要因素）作为自变量，建立如下多元回归模型：

$$Y_{\text{地表气温}} = \beta_0 + \beta_1 X_{\text{高程}} + \beta_2 X_{\text{坡度}} + \beta_3 X_{\text{坡向}} + \epsilon_1 \quad 4-8$$

$$Y_{\text{降水总量}} = \beta_0 + \beta_1 X_{\text{地表气温}} + \epsilon_2 \quad 4-9$$

$$Y_{\text{降水总量}} = \beta_0 + \beta_1 X_{\text{高程}} + \beta_2 X_{\text{坡度}} + \beta_3 X_{\text{坡向}} + \beta_4 X_{\text{地表气温}} + \epsilon_3 \quad 4-10$$

$$Y_{\text{暴雨次数}} = \beta_0 + \beta_1 X_{\text{高程}} + \beta_2 X_{\text{坡度}} + \beta_3 X_{\text{坡向}} + \beta_4 X_{\text{地表气温}} + \epsilon_3 \quad 4-11$$

其中，Y 是降水总量或者暴雨次数等因变量，X 是高程、坡度、坡向等自变量， β 是回归系数， ϵ 是误差项。

（1）地形对地表温度的影响

基于公式 4-8，为例探究地表温度与高程之间的影响，首先对高程分段与地表温度进行相关性探究，结果如果如图 4-14 所示，由图可知随着高度的增加，平均地表温度逐渐减小，在高程抵达 4500m 之后地表温度由正值变为负值并继续减小，由此可以直观的看出两者的关系，说明高程区间对于地表温度有着明显影响。




图 4-14 分段高程与地表气温柱状图

以平均地表温度数据作为该模型的 Y 值，该数据适用于研究长期气候趋势的变化，消除了季节性和短期气候波动的影响，可以更好地展示地形对气温的宏观影响，以地形特征参数（高程、坡度与坡向）作为 X 值，以探究地形特征参数是如何影响地表气温的。基于 PyCharm 构建多元回归模型，以总样本量的 3/5 作为训练集、1/5 作为验证集、1/5 作为测试集，为探究特定高程对于气温的影响，对高程进行分段建模，建立多个模型进行比较，建模结果如表 4-3 所示。

表 4-3 模型验证结果表

模型	高程区间	均方误差	测试集 R ²	模型系数	模型截距
模型 a	0-500m	30.774	0.116	[-0.01354881 0.01059104 -0.00285433]	14.052
模型 b	0-1000m	33.951	0.128	[-0.00694435 0.00104221 -0.00214623]	13.628
模型 c	0-1500m	33.239	0.143	[-0.00490563 0.0033859 -0.00348209]	13.094
模型 d	0-2000m	33.980	0.106	[-0.00352745 0.0020257 -0.00420633]	12.745
模型 e	0-2500m	34.782	0.087	[-0.00276922 0.00135804 -0.0046713]	12.466
模型 f	0-3000m	35.412	0.102	[-0.0026691 0.00180806 -0.00466708]	12.373
模型 g	0-3500m	35.741	0.112	[-0.00245372 0.00145733 -0.00467294]	12.261
模型 h	0-4000m	35.867	0.129	[-0.0022913 0.00107854 -0.00455579]	12.164
模型 i	0-4500	35.474	0.190	[-0.00233968 0.00121666 -0.00420754]	12.125
模型 j	0-5000	34.032	0.322	[-0.00263692 0.0020054 -0.00374127]	12.235
模型 k	0-5500	32.926	0.395	[-0.00272902 0.00197466 -0.00351859]	12.281
模型 l	0-6000	32.718	0.406	[-0.00272668 0.00201034 -0.00349281]	12.268
模型 m	0-6500	32.712	0.408	[-0.00272422 0.00191136 -0.00346994]	12.270
模型 n	0-7000	32.750	0.407	[-0.00272532 0.00184435 -0.00344931]	12.274

结果显示随着高程模型选择区间的增大，模型的 R² 越来越接近于 1，而均方误差呈减小的趋势，大区间的高程模型更能体现地形与地表温度的整体相关性，根据 R² 变化制作折线图，如图 4-15 所示，R² 值的增加指示模型对数据的拟合度显著提高，说明在更广泛的高程范围内，地形因素对地表温度变化的影响更加明显。这种趋势可能源于更大高程区间能够捕捉到更复杂的地形特征和气候变化模式，从而增强了模型的解释能力。均方误差的降低进一步支持了这一结论，表明预测值与实际观测值之间的差异减小，反映出模型的可靠性和准确性。




图 4-15 R²变化折线图

结合 R²值和均方误差的变化趋势，可以得出结论：在进行地形与地表温度关系的建模时，选择适当的**高程模型区间**至关重要。本研究的结果证明了地形因素对地表温度的影响。

(2) 地表温度与降水之间的影响

基于公式 4-9 探究降水总量与地表温度的联系，选择降水总量作为 Y 值，能更综合的考虑总体的变化趋势，选择地表温度作为 X 值。由于特定气温区域对于降水总量可能有特殊的相关性，所以将地表温度进行分段建模，模型结果如表 4-4 所示。

表 4-4 气温分段建模结果表

模型	数据区间	均方误差	测试集 R²	模型系数	模型截距
模型 a	ALL	291385769	0.368	[1693.36587967]	17028
模型 b	Temperature>5	274626784	0.541	[3940.83221006]	-13844
模型 c	Temperature<5	382778390	0.156	[1202.70769342]	20387

由建模结果可知，由于**数据量庞大**，以及降水变化性和不确定性，模型的均方误差较大，但是将三种区间先计较，仍可发现地表气温在 5° + 的区间，模型的精度以及效果比其他区间的更好，绘制模型的预测降水量与实际降水量散点图，如图 4-16 所示，可以较为直观地发现降水量在地表温度 5° + 之后呈线性上升的趋势，但在 -5° 至 5° 的地表温度区间也大量集中，但是总量不高，在 -5° 的温度区间，降水量随地表温度的降低而减少，在 -12.5° 处接近于零。同时，基于地表温度 5+ 区间构建的模型 b 也验证了降水量在该区间与地表温度存在相关性（R²=0.541）。




图 4-16 预测降水量与实际降水量散点图

根据建模结果，可以得知地表温度与降水量在特定的温度区间（地表温度 > 5°）存在着明显的线性关系。

（3）地形、地表温度与降水之间的影响

通过建立地形、地表温度与降水量之间的多元回归模型，结果如表 4-5 所示，可以得知地表温度 $>5^{\circ}$ 且降水量 >1000 的区间内，模型 h 的相关性最好， R^2 达到 **0.377**，根据散点图 4-17 所示，更能直观的看到降水量在该区间预测值与真实值的拟合程度最好。

表 4-5 地形、地表温度与降水量的多元回归模型

模型	数据区间	均方误差	测试集 R2	模型系数	模型截距
模型 a	ALL	425213766	0.096	[8.26272928e-02 1.95562083e+00 -7.14703028e+00 2.17694763e+02]	27911
模型 b	Temperature >5	468148775	0.220	[3.81399801e-02 9.23935566e+00 -7.80119337e+00 9.27389547e+02]	23937
模型 c	Temperature <5	151282381	0.073	[3.99585878e-02 7.37421198e+00 -9.98202161e+00 3.60201034e+02]	20298
模型 d	Rainfall >10000	559064780	0.197	[-1.13570223e-01 1.20885158e+00 -6.03034323e+00 4.62246987e+02]	37233
模型 e	Rainfall >20000	490255213	0.235	[-1.49979490e-01 2.06780074e+00 -4.09176020e+00 5.62037777e+02]	41696
模型 f	Rainfall >40000	313368700	0.292	[-2.42587749e-01 1.24814774e+00 -3.15765293e+00 1.13117954e+03]	51134
模型 g	T >5 、R >40000	308103669	0.244	[-1.54141873e-01 -1.11690655e+01 -5.86244264e+00 1.72562332e+03]	44468
模型 h	T >5 、R >10000	501918066	0.377	[-3.05003050e-01 4.15640624e+00 -9.73983345e+00 1.50638441e+03]	31362
模型 i	T >5 、R >20000	442989513	0.373	[-4.74942916e-01 1.91458485e+01 -6.79817875e+00 1.50189931e+03]	31826




图 4-17 地形、地表温度与降水量的多元回归模型预测散点图（从上至下，从左往右依次为 a 至 i）

建立地形、地表温度与暴雨次数之间的多元回归模型，模型构建结果如表 4-6 所示，可以得知在地表温度大于 5° 的温度区间中，**模型 b** 的预测效果最好（ $R^2=0.448$ ），根据散点图 4-18 可以看出，模型 b 的预测值与真实值更加收敛于回归线，整体趋势接近 1:1 线，说明该模型能有效的说明地形、地表温度与暴雨次数之间的联系。

表 4-6 地形、地表温度与暴雨次数的多元回归模型

模型	数据区间	均方误差	测试集 R2	模型系数	模型截距
模型 a	ALL	2404.793	0.348	[1.02484925e-04 -1.10072358e-01 -1.95661413e-02 4.84809899e+00]	9.236
模型 b	Temperature >5	3028	0.448	[-7.96792537e-05 7.93143520e-02 -1.27136267e-02 1.11008970e+01]	-86.619
模型 c	Temperature <5	3078.39	0.136	[-1.06248816e-04 -6.04914050e-03 -8.13694252e-04 6.89838735e-01]	2.926
模型 d	R >50 、T >5	5739	0.130	[-8.30282658e-04 2.13328095e-01 -5.82764609e-02 8.30336466e+00]	-10.56
模型 e	R >20 、T >5	4582	0.294	[-1.04851385e-03 2.33207851e-01 -4.12823682e-02 9.31586427e+00]	-47.981
模型 f	R >30 、T >5	4917	0.211	[-1.07463380e-03 2.16664703e-01 -3.54086457e-02 8.83577565e+00]	-34.356




图 4-18 图 4-17 地形、地表温度与暴雨次数的多元回归模型预测散点图（从上至下，从左往右依次为 a 至 f）

4.4.2 机器学习模型

基于机器学习方法研究地形特征因素以及地表温度对于暴雨次数的影响，选择了利用目前回归领域应用比较广泛的**随机森林（Random Forest, RF）**、**支持向量机（Support Vector Machine, SVM）**、**极端梯度提升（Extreme Gradient Boosting, XG Boost）**、**自适应提升（Adaptive Boosting, Ada Boosts）**四种机器学习方法构建反演模型。基于 Python 语言的 **Scikit-learn 库** 和 **XG Boost 库** 完成四种机器学习模型构建。

通过**网格搜索与交叉验证(Grid Search with Cross-Validation)**调整各模型参数以使各模型反演效果达到最优，网格搜索与交叉验证是一种系统化的**超参数调优**方法，广泛应用于机器学习模型的优化。它通过指定一组超参数，并利用交叉验证评估模型在所有可能组合下的性能，网格搜索的过程是创建一个超参数值的“网格”，其中可以包含学习率、树的数量、最大深度等各种参数的不同配置。算法会针对每种超参数组合训练并评估模型，从而帮助研究人员识别出表现最佳的参数集。交叉验证是一种用于评估统计分析结果如何推广到独立数据集的技术。它涉及将数据集划分为多个子集，在某些子集上训练模型（训练集）并在其他子集上进行验证（验证集）。最常见的形式是 k 折交叉验证，其中数据集被划分为 k 个子集。模型被训练 k 次，每次使用不同的子集作为验证集，其余子集作为训练集。

RF 是一种强大的**集成学习**方法，通过构建多个**决策树**并引入随机性的方式，有效地应对复杂的回归问题。这种方法不仅提高了模型的性能，还具备良好的**抗过拟合能力**，可表示为：

$$\hat{y} = \frac{1}{N_{trees}} \sum_{i=1}^{N_{trees}} f_i(x) \quad 4-12$$

其中， $\hat{y}$ 是最终的回归预测值， N_{trees} 是树的数量， $f_i(x)$ 是第 i 棵树的回归预测。SVM、XG Boost 以及 AdaBoost 也都是目前被广泛使用的机器学习方法。

本研究基于四种机器学习模型，以暴雨次数作为因变量（Y 值），高程、坡度、坡向以及地表气温作为自变量（X 值），构建了模型的训练集。在模型构建过程中，我们进行了数据清洗，删除了无效值和异常值，以确保数据的质量和模型的可靠性。在模型训练与验证阶段，采用了随机森林（RF）、极端梯度提升（XG Boost, XGB）、自适应提升（AdaBoost, ADB）和支持向量机（SVM）四种算法。经过参数调优和交叉验证，模型的构建结果如表 4-7 所示。

表 4-7 模型构建结果表

模型	机器学习	数值区间	均方误差	测试集 R2	最佳超参数
模型 a	RF	ALL	1620.793	0.561	{'max_depth':10,'max_features':'sqrt','min_samples_leaf':2,'min_samples_split': 10, 'n_estimators': 200}
模型 b	SVM	ALL	2609.736	0.292	{ 'kernel ': 'rbf', 'C ':100, ' gamma ':0.1}
模型 c	XGB-	ALL	1613.645	0.562	{'learning_rate': 0.1, 'max_depth': 5, 'n_estimators': 50, 'subsample': 0.8}
模型 d	ADB	ALL	1675.085	0.545	{'base_estimator': DecisionTreeRegressor(max_depth=5), 'learning_rate': 0.01, 'n_estimators': 50}

4.5 结果分析

结果表明, RF、XGB 和 ADB 模型的 R^2 值均达到了 0.5 以上, 显示出良好的拟合效果。其中, XGB 模型的预测精度最佳, $R^2=0.562$, 均方误差 (MSE) 为 1612.645, 略高于 RF 模型的精度, $R^2=0.561$, $MSE=1620.793$ 。这表明在本研究的数据集上, XGB 模型在捕捉暴雨次数与地形及气温特征之间的关系上表现出更强的能力。此外, 模型的性能差异可能与各算法的特性有关。XGB 作为一种集成学习方法, 能够有效处理非线性关系和复杂的特征交互, 因此在本研究中能够获得更高的预测准确性。而 RF 模型虽然也表现出色, 但在某些情况下可能受限于单棵树的决策能力。绘制暴雨次数预测与真实暴雨次数的散点图, 如图 4-19 所示, 可以清楚的看见 RF 模型与 XGB 模型的三点更与回归线接近, 且更接近于 1: 1 线。

综上所述, 研究结果突显了高程、坡度、坡向和地表气温等变量对暴雨次数的影响, 并证明了 RF 与 XGB 模型在此类预测任务中的优越性, 为后文的气象预测和灾害预警提供了理论支持。




图 4-19 暴雨次数预测与真实暴雨次数的散点图

所构建的 RF 模型与 XGB 模型，根据各指标特征重要性，绘制重要特征性饼状图 4-20，由图可知，地表气温在两个模型中的重要性最高，RF 模型中为 **0.829**，XG 模型中为 **0.814**，表明地表气温对暴雨发生的影响显著。此外，RF 模型中高程的重要性为 0.1，坡度为 **0.047**，坡向为 **0.021**，而 XG 模型中高程的重要性为 **0.072**，坡度为 **0.061**，坡向为 **0.051**。这些结果表明，虽然地形因素（如高程、坡度和坡向）对暴雨次数也有一定的影响，但相较于地表气温，其影响力较小。这可能是因为气温直接影响大气中的水汽含量和对流活动，从而更直接地影响降水的发生频率。整体来看，研究结果强调了气温在暴雨形成中的关键作用，同时也提示了地形特征在气象现象中的辅助作用，为进一步的气象预测和灾害管理提供了重要依据。




图 4-20 RF（左）与 XGB（右）重要特征性饼状图

5. 问题三的分析与求解

5.1 数据处理

针对降水从“暴雨”到“灾害”的问题，对于河流、湖泊的地形考虑是十分有必要的，这些地形影响水流的汇聚与排放，降水期间，地表径流会流向河流和湖泊，直接影响其水位和流量，从而影响洪水的发生和强度。此外，湖泊作为自然的蓄水设施，可以暂时存储降水造成的水量，减缓洪水流动。然而，当降水量过大或湖泊水位已满时，湖泊可能会溢出，导致周边地区发生洪涝灾害。河流和湖泊的地形特征还会影响生态系统的稳定性和生物多样性，极端天气事件可能导致水质污染和生态系统破坏，从而加剧环境风险。同时，河流和湖泊周边的人类活动（如城市建设、农业开发）会改变水流模式，增加暴雨成灾的风险。

基于 ArcGIS，使用中国 DEM 数据生成河流和湖泊的栅格数据的过程通常包括几个关键步骤。首先，需要将 DEM 数据导入 ArcGIS，确保数据覆盖研究区域。接下来，使用“Fill”工具填充 DEM 中的凹陷，以消除水流积聚导致的错误，确保水流在栅格模型中的正确流动。之后，利用“Flow Direction”工具计算每个栅格的水流方向，生成流向栅格，其中每个像素指示水流的主要方向。

生成流量累积数据是下一步的关键，使用“Flow Accumulation”工具计算每个栅格的流量累积，识别水流汇聚区域。流量较大的区域通常更可能成为河流。根据流量累积数据，使用“Stream Order”或“Extract by Attribute”工具提取河流，设置阈值以确定河流的起始点和分布。对于湖泊的生成，可以通过提取高程较低且水流汇聚的区域来识别，使用“Raster Calculator”或“Reclassify”工具定义湖泊的栅格值。最后，将生成的河流和湖泊栅格数据

合并以便进行进一步分析，如图 5-1 所示。以便后续结合降水数据和其他地形特征，评估其对暴雨成灾的影响。




图 5-1 河流和湖泊栅格数据展示

5.2 2025-2035 降水量预测

降水、地形和土地利用对暴雨等极端天气灾害的形成具有不可忽视的影响。其中，降水的时空变异性和不可控性尤为显著。因此，我们首先需要对 2025-2035 年的降水量进行独立预测。在问题一中，我们已对 1990-2020 年的降水量进行了 **Mann-Kendall (MK) 检验**和 **Sen’s 斜率估计**，以判断降水量变化的显著性，并得出了降水量的变化趋势。

基于前期分析，我们接下来可以对 2025-2035 年间的年均降水量进行预测。我们以 2010-2020 年间的年均降水量数据作为基础进行预测。首先，利用 MK 检验判断每个像素点的变化是否显著。如果变化不显著，则直接将该点的 2020 年像素值作为 2025-2035 年间的年均降水量预测结果；如果变化显著，则进一步使用 Sen’s 斜率估计的 β 值进行计算，以获得 2025-2035 年间该点的年均降水量的像素值，流程图如 5-2 所示。

在计算过程中，通过将所有计算得到的像素值合成图像，我们最终形成了预测结果。由于采用了**线性趋势**模型，2025-2035 年间的年均降水量预测能够有效反映其变化趋势。同时，中间年份的降水量也遵循相同的线性趋势。因此，我们只需专注于 2025-2035 年的年均降水量预测，以便为极端天气事件的风险评估和管理提供科学依据。这一预测不仅有助于理解未来降水模式的变化，还能为制定应对极端天气的策略和措施提供重要支持。




图 5-2 2025-2035 年年均降水量预测流程图

5.3 暴雨成灾的临界条件

在我国，从“暴雨”到“灾害”的过程涉及降水、地形和土地利用三者的复杂交互作用。降水的强度、持续时间和频率直接影响暴雨是否会造成灾害。高强度的降水容易导致水位迅速上升，形成洪涝灾害，而持续降水则可能使土壤水分饱和，增加地表径流，进而引发灾害。

基于上文的分析得知，地形因素如高程、坡度和坡向对于降水有着明显的影响，且他们对水流的汇聚和排放有显著影响。高程在 2000m 以上，就很少会发生暴雨，所以在 2000m 以下的区域发生暴雨成灾的几率更大。坡度在 60°-90°范围，陡峭的坡度显著影响水流的动态特征，加快了水流速度，这一现象在暴雨条件下尤为明显。随着降水强度的增加，坡面上的水流迅速汇聚，导致水流量急剧上升。当降水量超过土壤的渗透能力时，地表径流开始形成，进一步加剧水流的流速。在这种情况下，土壤的稳定性受到严重影响，增加了土壤侵蚀的风险，导致泥土流失和坡体失稳。此外，陡峭的坡度使得水流在短时间内集中在较小的区域内，形成强烈的冲刷作用，这不仅加剧了土壤侵蚀，还显著提高了滑坡的发生概率。因此，在暴雨成灾的临界条件下，坡度在 60°至 90°的区域极易成为自然灾害的重灾区。坡向在 60°-180°范围，主要包括东北、东、东南及南向坡面，这些坡面通常面朝海洋，具有较强的水汽接收能力。特别是在中国东南沿海地区，海洋的影响显著，季风气候进一步增强了这一坡向区域的降水特征。面朝海洋的坡向能够有效吸引来自海洋的水汽，尤其是在夏季和秋季的季风季节，导致降水量显著增加。这一坡向区域的降水分布呈现空间差异，东南坡面通常获得更高的降水量，而南向坡面也表现出一定的优势。

根据温度与降水的相关性分析以及建模结果可知，在平均地表温度介于 10°C 至 20°C 的范围内，降水、暴雨和大暴雨的发生频率显著增加。这一温度范围通常与季节性气候条件密切相关，温暖的气温促进了水汽的蒸发和积聚，进而增强了大气中的湿度。当气温适中时，降水系统更容易形成并发展，导致降水强度的增加。特别是在这种温度条件下，热对流活动更加活跃，暴雨和大暴雨事件的发生概率显著提升。暴雨的临界条件通常与降水量的突然增加和持续时间的延长有关，当降水量超过土壤的渗透能力和水体的承载能力时，地表径流迅速增加，极易引发洪涝灾害。因此，在平均地表温度为 10°C 至 20°C 的区域，暴雨成灾的风险显著加大。

在土地利用中，在五种土地类型中（农田、森林、草地、灌丛、湿地），农田是最容易因暴雨成灾的类型。农田通常在降水期间缺乏足够的水土保持措施，使得暴雨导致的强降水很容易引发地表径流的快速增加。当降水量超过土壤的渗透能力时，水分无法有效被土壤吸收，造成地表径流的形成，进而导致洪涝现象。此外，农田中作物的根系通常较浅，这使得土壤的稳定性降低，增加了土壤侵蚀和泥石流的风险。在暴雨期间，集中的降水会迅速淹没农田，损害作物生长，造成经济损失。

表 5-1 暴雨成灾的临界条件

因素	指标	单位	临界条件
地形	高程	m	<2000
地形	坡度	°	60-90
地形	坡向	°	60-180
气候	地表气温	°	10-20
土地	土地利用	--	农田

降水、地形和土地利用之间的交互作用进一步复杂化了暴雨成灾的机制。不同地形条件下的降水强度会产生不同的影响，而城市化地区的强降水往往导致更严重的内涝。此外，在斜坡上进行农业开发可能导致土壤侵蚀，增加降水后地表径流的速度，从而加剧滑坡和

泥石流的风险。因此，综合考虑这三者的作用，对有效的灾害管理和防范至关重要，也为后文的脆弱性分析提供了思路。

5.4 暴雨灾害能力脆弱性研究

5.4.1 指标参数选择

构建洪涝灾害风险评估模型时，选取科学适当的**评估指标**至关重要，本文遵循五个原则：**全面性**，充分考虑自然和社会因素的综合作用；**易获取性**，确保指标数据易于收集并能在 GIS 中可视化；**科学性**，依据洪涝灾害的形成规律选取指标；**因地制宜**，结合研究区的实际情况选取适当的因子；**适量性**，避免因子过多导致重要性下降，确保评估结果的准确性。

洪涝灾害风险评估模型的构建基于多个复杂因素的综合分析，当前主要有三种研究观点：H-V 模型认为洪涝灾害风险由危险性和脆弱性组成，H-E-V 模型增加了暴露性因素，而 H-E-V-R 模型还考虑了防灾减灾能力。本文采用**危险性-暴露性-脆弱性（H-E-V）**模型，其表达式为：

$$D = f(h, e, v) = H \times E \times V$$

5 - 1

将洪涝灾害风险表达为危险性、暴露性和脆弱性的函数。危险性方面，本文选取**降水量、高程、坡度、坡向、地表温度**和**河流湖泊**等自然因素；暴露性考虑**人口密度**和**单位面积 GDP**；脆弱性则通过**土地利用类型**来衡量。这一综合评估框架更全面地反映了洪涝灾害的自然和社会属性，划分结果如图 5-3 所示。




图 5-3 脆弱性综合评估指标划分

5.4.2 指标权重确定

同一类别中每个指标地位和发挥的作用有所不同，所以就需要根据每个权重对总体“贡献性”的大小赋予不同的权重，权重越大，表明这个指标对总体的贡献性越大，反之指标权重越小，表明其对总体的贡献性越小。目前计算指标体系权重的方法一般有两类，分别是主观赋值法和客观赋值法。主观赋值法计算的权重主要是根据经验和主观判断得到，虽然解释性强，应用范围广，但是太依赖经验，缺乏**客观性**，具体方法有**层次分析法(AHP)**、**序关系分析法(G1)**、**多元分析法**、**集值迭代法(Set-valued Iteration)**和**模糊统计法(Fuzzy Statistics)**等。本文采用层次分析（Analytic Hierarchy Process, AHP）计算各指标权重。

层次分析法是由美国运筹学家 **T.L. Saaty** 在 20 世纪 70 年代首次提出的[20]，它是一种解决复杂多目标决策问题的简单有效的方法。该方法的基本原理是根据研究问题的性质和将问题划分成多个因素，通过分析各因素之间的**层次关系**，形成一个多层次的结构模型，

然后根据专家打分结果对因素的重要性进行定量表示，之后通过排序和**一致性检验**，最终得到各因素的权重。具体步骤如下：

① 明确问题，构建层次结构模型

根据研究区洪涝灾害的影响因子、形成机制和相互之间属性关系，构建研究区洪涝灾害层次结构模型。

② 确定**重要性标度**

洪涝灾害风险评估是一个将定性因素和定量因素相结合的多目标，多因素的评估过程，各个因素对于洪涝灾害的发生发挥的作用不相同，因此需要通过同一个子集中两两因素的对比，确定各因素的重要程度。层次分析法中通常用**9级标度法**进行标度，具体含义如表5-2所示。

表 5-2 层次分析法 1-9 标度的含义	
标度 a_{ij}	含义
1	a_i 比 a_j 一样重要
3	a_i 比 a_j 略微重要
5	a_i 比 a_j 较为重要
7	a_i 比 a_j 非常重要
9	a_i 比 a_j 绝对重要
2, 4, 6, 8	a_i 比 a_j 的重要性介于上述两个相邻等级之间
倒数 $a_{ji}=1/a_{ij}$	a_i 比 a_j 的重要性 a_{ji} 是 a_{ij} 的倒数

③ 构建**判断矩阵**

该步骤是层次分析法中最关键的步骤，即根据专家打分结果将同一层级中各个指标的重要性进行定量表示并构建判断矩阵 $[a_{ij}]$ ，结果如表所示。

表 5-3 层次分析法的判断矩阵				
	a_1	a_2	...	a_n
a_1	a_{11}	a_{21}	...	a_{1n}
a_2	a_{21}	a_{22}	...	a_{2n}
...	...	...	...	...
a_n	a_{n1}	a_{n2}	...	a_{nn}

该矩阵需要满足以下条件：

$$\begin{cases} \sum a_{ij} = 1 \\ a_{ji} = \frac{1}{a_{ij}} \end{cases} (i, j = 1, 2, 3 \cdots, n) \tag{5-2}$$

④ **层次单排序**

通过判断矩阵获得的各个因素对比的重要程度，进行层次单排序。计算出各个指标层的权向量，并获得矩阵的特征向量和最大特征值。

⑤ **一致性检验**

为了检查判断矩阵的准确性，需要对其进行一次性检验，通常用 CR 和 CI 进行检验，其公式为：

$$CR = \frac{CI}{RI} \tag{5-3}$$

$$CI = \frac{\lambda_{max} - n}{n - 1} \tag{5-4}$$

式中， λ_{max} 是最大特征根，n为矩阵阶数，CR为一致性比率，CI为一致性判定指标。CI通常用随机一致性指标RI来衡量，其取值范围如表所示。

表 5-4 随机一致性指标 RI 取值表

n	1	2	3	4	5	6	7	8	9	10	11	12
RI	0	0	0.58	0.9	1.12	1.24	1.32	1.41	1.45	1.49	1.51	1.54

当 CR<0.1 时，判断矩阵的不一致性在规定范围内，一致性检验通过；当 CR≥0.1 时，一致性检验不通过，需要重新检查判断矩阵再进行计算，直至通过一致性检验为止。

表 5-5 危险性因子判断矩阵特征向量以及一致性检验结果

危险性	降水量	河流湖泊	坡度	高程	坡向	地表温度	指标权重	计算结果
降水量	1	2	3	4	5	6	0.3794	$\lambda_{max}=6.61889$ CI=0.0338 CR=0.0302
河流湖泊	1/2	1	2	3	4	5	0.2488	
坡度	1/3	1/2	1	2	3	4	0.1604	
高程	1/4	1/3	1/2	1	2	3	0.1024	
坡向	1/5	1/4	1/3	1/2	1	2	0.0655	
地表温度	1/6	1/5	1/4	1/3	1/2	1	0.0434	

表 5-6 暴露性因子判断矩阵特征向量以及一致性检验结果

暴露性	人均 GDP	人口密度	指标权重	计算结果
人均 GDP	1	2	0.6667	$\lambda_{max}=2.0$
人口密度	1/2	1	0.333	CR=0

表 5-7 洪涝灾害风险评估指标权重值

目标层	准测层	指标层	单位	属性	层次分析法权重
危险性 (H)	水文因子	河流湖泊	--	正相关	0.1576
危险性 (H)	地形因子	高程	m	负相关	0.0648
危险性 (H)	地形因子	坡度	(°)	负相关	0.1016
危险性 (H)	地形因子	坡向	(°)	正相关	0.0415
危险性 (H)	气候因子	降水量	mm	正相关	0.2403
危险性 (H)	气候因子	地表温度	(°)	正相关	0.0275
暴露性 (E)	人文因子	人均 GDP	亿元/Km²	正相关	0.0868
暴露性 (E)	人文因子	人口密度	人/Km²	正相关	0.1737
脆弱性 (V)	土地因子	土地利用	--	-----	0.1062

5. 4. 3 脆弱地区预测

基于应对暴雨灾害能力脆弱性体系，对 2025-2035 年中国境内应对暴雨灾害能力最为脆弱的地区进行预测。利用 ArcGIS 的加权总和功能，对我国高程数据、坡向数据、坡度数据、河流湖泊数据、2025-2035 我国年均降水量、我国历史平均地表温度、2025-2035 年人均 GDP 数据、2025-2035 年人口密度根据所构建的应对暴雨灾害能力**脆弱性体系**权重进行叠加，得到 2025~2035 年间中国境内应对暴雨灾害能力最为脆弱地区预测图，如图 5-4 所示。




图 5-4 2025~2035 年间中国境内应对暴雨灾害能力最为脆弱地区预测图

5.5 预测结果分析

本文将应对暴雨灾害能力分为 5 个等级，分别为极高脆弱性、较高脆弱性、中等脆弱性、较低脆弱性以及极低脆弱性，由图可知在我国东南沿海部分极高脆弱性与较高脆弱性地区较多，而在东北地区中等脆弱性地区最多，在我国西部地区，则较低脆弱性以及极低脆弱性地区最多。下文将针对东南沿海地区、西部地区、东北地区进行详细的分析。

(1) 东南沿海地区




图 5-5 东南沿海地区脆弱性图（左）、降水量（左上）、高程（右上）、坡度（左下）、地表温度（右下）

如图 5-5 所示，由应对暴雨灾害能力最为脆弱地区预测图可知，我国东南沿海地区以极高脆弱性与较高脆弱性地区为主。结合该地区的降水量、高程、坡度以及地表温度数据，可知极高脆弱性与较高脆弱性地区主要在降水量高的地区，而该地区的高程普遍较低。在极高脆弱性地区主要分布在湖泊流域附近与我国南部沿海，且坡度发生明显变化的地方。

东南沿海地区的气候特征使其降水量显著高于其他区域，尤其是在夏季和秋季，强降雨事件频繁出现。降水量的增加使得地表水分迅速积聚，导致内涝和洪涝灾害的风险显著提升。低高程区域如湖泊流域，土壤的水分饱和度较高，降水后容易形成积水。而在南部沿海，低洼地势使得水流汇聚速度加快，导致短时间内水位迅速上升，增加了洪水风险。坡度的变化明显影响水流的动态特征。在坡度较陡的地方，水流速度加快，容易引发土壤侵蚀和滑坡；而在坡度较缓的区域，水流滞留，造成内涝现象的发生。这些因素相互作用，

使得极高脆弱性与较高脆弱性地区在暴雨灾害面前表现出更强的脆弱性。

(2) 东北地区




图 5-6 东北地区脆弱性图（左）、降水量（左上）、高程（右上）、坡度（左下）、地表温度（右下）

如图 5-6 所示，我国东北地区主要为以中等脆弱性与较低脆弱性地区为主。结合降水量、高程、坡度以及地表温度数据，可知中等脆弱性地区主要在降水量一般、高程较低、坡度变化较大的地区，而该地区的较低脆弱性地区主要分布在该地区西北部——降水量相对较少，坡度较高、温度较低、高程相对较高的地方。

东北地区的主要山脉如长白山和小兴安岭等，形成了明显的地形高差。这些山脉不仅影响了区域的降水分布，还对地表水流动产生了重要影响。在山脉的迎风坡上，由于水汽的集中，降水量往往相对较高，而在背风坡及其周边地区，降水量则显著减少。这导致了中等脆弱性地区的形成，主要集中在降水量一般的低洼区域。其次，高程较高的地区通常具有较大的坡度，这些区域的水流汇聚速度较快，能有效排水，减少内涝的发生。因此，较低脆弱性地区主要分布在西北部那些高程高、坡度大的地方。这些地区的降水量相对较少，加上温度较低，土壤水分蒸发速度较慢，进一步降低了洪涝风险。东北地区的气候特点也影响了脆弱性的分布。在冬季，低温导致降水主要以雪的形式存在，春季融雪则对水土保持有利，减少了暴雨带来的水土流失风险。这些因素共同作用，使得东北地区呈现出中等脆弱性与较低脆弱性的空间分布特征。

(3) 西部地区




图 5-7 西部地区脆弱性图（左）、降水量（左上）、高程（右上）、坡度（左下）、地表温度（右下）

如图 5-7 所示，我国西部地区主要研究**拉萨地区**，该地区为**极高脆弱性地区**，同时为高降水量、坡度变化极大、地表温度较高的地区。而在该地区的西北方向，地区脆弱性由极高脆弱性地区迅速变为较低以及极低脆弱性，降水量由高变低，同时高程急剧上升，地表温度也骤降。

拉萨地区位于青藏高原的核心地带，海拔较高，地形复杂多变，形成了显著的**高程差异**。该地区的降水量受季风影响，尤其在夏季，湿润的空气从印度洋和南海进入，导致高降水量的形成。同时，拉萨地区的坡度变化极大，陡峭的山坡和谷地使得水流汇聚迅速，增加了土壤侵蚀和滑坡的风险。此外，较高的地表温度使得蒸发速率加快，进一步加剧了水分的集中和流失。然而，向西北方向延伸，地区的地形特征发生了显著变化。新疆地区的高程普遍较高，尤其是天山和阿尔泰山等山脉的存在，使得地形更加陡峭，降水量逐渐减少。这些高山地区的迎风坡通常会聚集水汽，而在背风坡，降水量显著减少，形成干旱或半干旱气候。此外，随着高程的急剧上升，气温骤降，导致水分的蒸发速率降低，土壤水分保持状况改善，从而降低了洪涝风险。

拉萨地区与新疆的地形特征形成了明显的**脆弱性梯度**。拉萨地区的极高脆弱性与高降水量、高坡度及较高地表温度密切相关，而向西北方向的脆弱性降低则主要归因于高程的增加、降水量的减少和地表温度的骤降。这一变化也强调了区域地形对水文过程和灾害风险的深远影响。

6. 问题四的分析与求解

6.1 数据处理

为描述中国土地利用变化的特征与结构并从准确性和有用性两个方面对结果进行解释和验证，本节选择了数据集 1（高程）、数据集 3（日降水）、数据集 4（土地利用/土地覆被类型）、数据集 5（人口空间分布）、数据集 6（人均 GDP）中的数据进行数学建模，所选数据详细信息如表 6-1 所示。其中人口空间分布数据和人均 GDP 数据坐标投影与其他数据不同，使用前需要转换成 **WGS84** 坐标系。

表 6-1 问题四数据集信息表

数据集	数据	时间分辨率	空间分辨率	时间范围	数据格式
数据集 1	chinadem_geo	——	1km	——	TIFF
数据集 3	日平均降水数据	1day	0.25°	1961-2022	NetCDF
数据集 4	土地利用/土地覆被类型	1year	0.5°	1900-2019	TIFF
数据集 5	人口空间分布	1year	1km	1990-2015	TIFF
数据集 6	人均 GDP	1year	1km	1990-2015	TIFF

6.2 地理分析

（1）自然地理特征的 “三级阶梯”

中国地形的三级阶梯是指中国地貌的分层结构，主要包括高原、山地和丘陵等不同高度的地形单元。**第一阶梯**位于中国西南部，涵盖西藏和青海等地。被称为“世界屋脊”，平均海拔在 **4000 米**以上。地形复杂，拥有高山、湖泊和冰川。主要山脉包括喜马拉雅山脉、昆仑山脉等。**第二阶梯**包括四川盆地、云贵高原、华北平原等地区。海拔通常在 **1000 米至 3000 米**之间，地形起伏较大。主要山脉如秦岭、大巴山、雪山等。该阶梯的地区气候

多样，适合多种农业和林业发展。**第三阶梯**包括东北平原、华北平原、长江中下游平原等。海拔通常在 **0 米至 1000 米**之间，地形相对平坦。适合农业生产，尤其是水稻、小麦等粮食作物。丘陵地区的土壤肥沃，适合发展园艺和畜牧业。

不同阶梯的地形影响了当地的气候、土壤和水资源分布，决定了各地区的农业和工业发展方向。地形对交通运输和经济活动有重要影响，高原地区相对隔离，而平原地区则更便于开发和居住。总而言之，中国的三级阶梯地形结构为多样的生态环境和丰富的自然资源奠定了基础，同时也对人类的生产和生活方式产生了深远的影响。通过了解和进一步的分析这些地形特征，可以更好地认识中国的自然环境和区域发展。

表 6-2 中国三级阶梯信息表

地势阶梯	平均海拔	主要地形类型	主要地形区
第一级阶梯	4000 米以上	高原	青藏高原、柴达木盆地
界线		昆仑山--祁连山--横断山脉	
第二级阶梯	1000-2000 米	盆地和高原	内蒙古高原、黄土高原、云贵高原、准噶尔盆地、塔里木盆地、四川盆地
界线		大兴安岭--太行山--巫山--雪峰山	
第三级阶梯	500 米以下	丘陵和平原	东北平原、华北平原、长江中下游平原、东南丘陵、山东丘陵、辽东丘陵

我们使用题目提供的数据集 1（高程）对中国的地形进行可视化，得到中国高程专题图，通过对特定区间的设置，我们可以明显观察到中国地形的三级阶梯。第一阶梯海拔最高，主要分布在**青藏高原地区**附近，第二阶梯主要分布在中国**中部和西北地区**，第三阶梯海拔最低，主要分布在**东北和东南地区**。




图 6-1 中国三级阶梯图

(2) 800mm 等降水量线

中国的 800mm 等降水量线是一个重要的气候特征线，用于表示年降水量为 800 毫米的地区。中国 800mm 等降水量线大致与**秦岭-淮河**一线重合，这条线从淮河、秦岭一线画向青藏高原东南边缘。这个降水量通常被视为**农业和生态系统**的一个重要水分标准。我们

使用题目提供的数据集 3（日降水）计算出了 1990 至 2020 年每年的年均降水量，以此为基础计算 2010 至 2020 年这十年间的年均降水量数据并进行可视化。




图 6-2 年均总降水量分布图（2010-2020）

图中颜色越深的地区降水量越大，其中 800mm 等降水量线如图所示，与实际情况十分相似，证明了结果的准确性和有效性。800mm 等降水量线具有多重地理意义：**湿润区与半湿润区的分界线**：此线以东以南为湿润地区，年降水量一般在 800mm 以上；以西以北为半湿润地区，年降水量一般在 800mm 以下。**气候分界线**：亚热带季风气候与温带季风气候的分界线，1 月 0℃等温线也大致与此线重合。此线以南为湿润气候区，年降水量丰富，适合农作物生长；以北为半湿润气候区，降水量较少。**农作物种植分界线**：在 800mm 线以南，农业以水稻和其他水需求较高的作物为主；而在 800mm 线以北，主要以小麦、玉米等耐旱作物为主，反映了不同的农业生产和饮食习惯。**森林植被分界线**：热带亚热带常绿阔叶林与温带落叶阔叶林的分布分界线。**河流结冰情况分界线**：此线以南的河流常年不结冰，适合水生生物和航运；以北的河流冬季会结冰，影响了水资源的利用和航运。800mm 等降水量线在中国的气候、农业和生态系统中扮演着重要角色，了解这一线的分布对于水资源管理和农业规划具有重要意义。

（3）“胡焕庸线”

胡焕庸线是中国著名的地理分界线，通常用于描述中国南北方在自然、经济和社会等方面的差异。这条线由地理学家胡焕庸于 1950 年代提出，旨在揭示中国**地理和人口分布**的特点。胡焕庸线在中国人口地理上起着画龙点睛的作用，一直以来为国内外人口学者和地理学者广泛认可和引用，甚至被美国俄亥俄州立大学的田心源教授称为“胡焕庸线”。这条线从黑龙江省的瑷珲（1956 年改称爱辉，1983 年改称黑河市）延伸至云南省的腾冲，形成一条大致倾斜 45 度的基本直线。

为具体分析胡焕庸线与各因素之间的关系，我们根据题目提供的数据绘制了各因素的空间分布情况，并与胡焕庸线进行相关性分析。通过可视化这些因素的分布，如**人口密度**、**人均 GDP**、**农田占比**和**年均降水量**等，我们能够更直观地观察到各区域在自然、经济和社会发展方面的差异。




图 6-3 各因素与胡焕庸线对比图

从中国人口密度分布图 (a)、人均 GDP 分布图 (b)、农田占比分布图 (c)、年均总降水量分布图 (d) 以及中国三级阶梯图 (e) 与胡焕庸线的关系可以看出, 胡焕庸线在多个方面具有深远的意义。从自然地理角度来看, 胡焕庸线以南地区通常气候温暖、降水丰富, 适合农业发展, 其地形特征包括平原、水网、丘陵、喀斯特和丹霞地貌, 自古以来以农耕为经济基础。而胡焕庸线以北地区则气候寒冷、降水较少, 主要以林业和牧业为主, 涵盖草原、沙漠和雪域高原, 自古以来是游牧民族的领地。从经济差异来看, 南方地区经济发展较快, 工业、农业和服务业相对发达; 北方地区则发展相对滞后, 仍然依赖传统产业。这种经济差异使得胡焕庸线在一定程度上成为城镇化水平的分割线: 东南各省区市的城镇化水平大多数高于全国平均水平, 而西北各省区则大多数低于全国平均水平。在人口分布方面, 胡焕庸线是我国人口发展水平和经济社会格局的重要分界线。其东侧分布着我

国 96%的人口，而西侧仅占 4%。经过半个多世纪的发展，西侧人口仅增加了 2%，而东侧仍居住着 94%的人口，且经济差距更加悬殊。这一现象反映了区域发展不均衡的问题，提示我们需要关注西部地区的人口与经济发展。

总之，胡焕庸线不仅是一个地理概念，更是中国南北方在自然、经济和文化等多个方面差异的综合体现。理解这条线有助于深入认识中国的地理和社会经济状况，为制定区域发展政策提供重要参考，推动区域协调发展，缩小南北差距。

6.3 模型建立

6.3.1 相关性分析

(1) 中国土地种类间相关性分析

为了利用地理大数据，建立相应的数学模型，对数据进行简化和综合，描述中国土地利用变化的特征与结构，需要分析五种地形（农田,森林,草地,灌丛,湿地）的 1990-2019 年的变化率和高程（三级阶梯）、降水量（800mm 等降水量线、秦岭—淮河线）与人均 GDP 以及人口密度（胡焕庸线）的相关性。




图 6-4 不同土地覆盖类型相关矩阵热图

首先通过分析不同土地覆盖类型的变化，揭示耕地、森林、草地、灌木丛及湿地在不同增减模式下的相互关系，利用相关矩阵热图 6-4 显示了各土地类型变化的相关系数，相关系数的取值范围从-1 到 1，其中正相关表示两变量同向变化，负相关表示反向变化。分析结果表明，不同土地覆盖类型的变化具有显著的正负相关关系，表明了土地利用和生态系统管理之间的复杂性：

森林减少率与湿地增加率相关系数为-0.86，是图中最显著的负相关关系之一。这表明在湿地面积增加的同时，森林面积大幅减少，可能表明森林的退化与湿地扩展具有密切联系，或是因为土地利用变化导致生态系统转换。森林增加率与灌木减少率相关系数为 0.14，表明森林增加与灌木减少之间存在弱正相关关系。这可能反映了森林恢复过程中灌木减少

的趋势，说明在某些地区，森林扩展的同时灌木可能逐渐消失。

草地增加率与灌木增加相关系数为**-0.19**，表明草地和灌木的增加呈现轻微负相关。这可能是由于草地和灌木丛在某些地区存在竞争关系，当草地扩展时，灌木丛可能会被替代。草地减少率与湿地较少率的相关系数为**0.23**，表明草地和湿地的减少有一定的正相关关系。这个结果可能反映了某些地区由于土地退化或其他因素导致的整体生物生产力下降。

灌木减少率与湿地增加率相关系数为**0.30**，说明灌木丛减少时，湿地增加存在弱正相关关系。湿地扩展可能伴随着灌木丛的减少，这一现象可能与生态系统变化、湿地恢复等环境管理措施有关。

通过分析不同土地覆盖类型的变化相关性，揭示了生态系统之间复杂的**相互作用**。耕地、森林、草地、灌木丛和湿地的变化不仅反映了土地利用的动态变化，也表明了生态系统之间的相互影响。为后续建立数学模型提供了理论基础。

(2) 与自然地理与人文地理相关性分析

将草地参数与自然、人文地理因素进行相关性分析，由图 6-5 所示，草地减少率与总降水量之间存在显著的负相关性（**-0.69**），表明降水量的增加抑制了草地的生长，可能是由于水分过剩导致植物生长不良。此外，草地增长率与人口密度呈负相关（**-0.37**），而人均 GDP 则呈正相关（**0.37**），这意味着人口密度的增加抑制了草地生长，而经济发展促进了草地的恢复。同时，草地增长率与总降水量之间的正相关性（**0.47**）表明适度的降水量有助于草地生长，而高程的增加对草地增长产生负面影响（**-0.36**），可能由于高海拔地区的气候条件较为严酷。总体而言，这些结果强调了多种环境因素对草地变化的影响。




图 6-5 草地（左）、耕地（右）与自然地理与人文地理相关矩阵热图

由图 6-5 得知，耕地增加率与总降水量之间的相关性为**-0.15**，表明总降水量对耕地增加的影响较弱，但可能存在一定的抑制作用。与人口密度的负相关性（**-0.36**）则表明，人口密度的增加可能抑制耕地的扩展，原因在于高人口密度地区土地利用竞争加剧，耕地面积难以扩张。相对而言，与人均 GDP 的正相关性（**0.36**）则暗示经济发展可能促进耕地的增加，经济增长带来的资金投入和技术进步可能改善农业生产条件，进而推动耕地的扩展。此外，耕地增加率与高程之间的负相关性（**-0.32**）表明，高海拔地区由于气候条件和土壤质量限制，耕地扩展受到**抑制**。




图 6-6 森林（左）、灌木（右）与自然地理与人文地理相关矩阵热图

森林减少率与总降水量之间的相关性为 **0.29**，表明降水量的增加可能与森林减少存在一定的正相关性，这可能是由于过量降水导致的土壤侵蚀和植被破坏，从而促进了森林面积的减少。另一方面，森林增加率与总降水量的相关性为 **0.46**，说明降水量的增加显著促进了森林的生长，充足的水分有助于森林生态系统的恢复和扩展。此外，森林增加率与人口密度呈现负相关（**-0.42**），这表明高人口密度可能对森林资源造成压力，导致森林面积的减少，因而抑制了森林的生长。而人均 GDP 的负相关性（**-0.42**）则反映了经济活动对森林资源的影响，经济发展往往伴随着对森林的开发和利用，进而抑制森林的增加。与高程的正相关性（**0.20**）则显示出，高海拔地区由于相对较低的人类活动干扰和较好的气候条件，有利于森林的生长。因此，这些因素相互作用，共同影响了森林的变化趋势。

灌木减少率与总降水量之间存在显著的负相关性（**-0.71**），这表明降水量的减少可能抑制了灌木的生长，导致其面积的缩减。这种抑制效应可能源于水分不足对灌木生态系统的影响，使得灌木无法维持健康的生长状态。相反，灌木增加率与总降水量的相关性为 **0.53**，表明充足的降水量促进了灌木的生长和扩展，水分的增加为灌木提供了必要的生长条件。此外，灌木增加率与人口密度呈现负相关（**-0.35**），这说明高人口密度可能对灌木生境造成压力，从而抑制了灌木的生长。同时，灌木增加率与人均 GDP 呈正相关（**0.35**），暗示经济发展可能在一定程度上推动了灌木的种植和管理。然而，灌木增加率与高程之间的相关性较低（**-0.12**），表明高程对灌木生长的影响较小。




图 6-7 湿地与自然地理与人文地理相关矩阵热图

湿地减少率与总降水量之间存在负相关性（**-0.34**），这表明降水量的减少可能对湿地生态系统产生抑制作用，从而导致湿地面积的缩减。降水量不足可能导致湿地水位降低，进而影响湿地植物的生长和生态功能。此外，湿地减少率与高程之间的相关性较低（**-0.054**），暗示高程对湿地面积变化的影响不显著。相对而言，湿地增加率与总降水量的相关性为**0.45**，表明充足的降水量促进了湿地的恢复和扩展。降水量的增加为湿地提供了必要的水分条件，支持湿地生态系统的健康发展。

黄框范围内研究自然地理与人文地理之间的关系：我国人口密度与高程之间存在显著的正相关性（**0.8**），这表明在人口密集的地区，高程相对较低，可能与城市化和基础设施发展有关。此外，人口密度与总降水量之间的正相关性（**0.47**）则表明降水量丰富的区域，往往能够支持更高的人口聚集和农作物生产，这可能促使人们在这些地区定居。因此，这些相关性揭示了地理、经济和气候因素在影响人口分布与经济复杂交互关系。

6.3.2 机器学习模型

分别以五种地形（农田,森林,草地,灌丛,湿地）的 1990-2019 年的变化率作为 Y 值，以高程（三级阶梯）、降水量（800mm 等降水量线、秦岭—淮河线）与人均 GDP 以及人口密度（胡焕庸线）作为 X 值，建立机器学习模型，以探究自然地理与人文地理对中国土地利用变化的影响。所构建模型如表 6-3 所示，在构建的模型之中，XGB 模型的效果普遍要高于 RF 模型，以灌木变化率为例，基于 XGB 构建的模型 4 的 R^2 为 **0.362**，MSE 为 **330.730**，皆高于基于 RF 构建的模型 3（ R^2 为 **0.318**，MSE 为 **353.752**）。

表 6-3 模型构建结果表

模型	Y 值	机器学习方法	R^2	MSE
模型 1	草地变化率	RF	0.554	190.329
模型 2	草地变化率	XGB	0.569	183.651
模型 3	耕地变化率	RF	0.318	353.752
模型 4	耕地变化率	XGB	0.362	330.730
模型 5	灌木变化率	RF	0.521	186.282
模型 6	灌木变化率	XGB	0.535	180.864
模型 7	森林变化率	RF	0.396	484.855
模型 8	森林变化率	XGB	0.511	392.408
模型 9	湿地变化率	RF	0.360	898.222
模型 10	湿地变化率	XGB	0.425	806.982

6.3.3 准确性分析

基于构建的模型，绘制预测值与实际值的散点图，可知 RF 模型与 XGB 模型，无论低值还是高值，对于草地、耕地与灌木都有较好的预测能力，预测值与实际值三点**收敛于 1：1**线附近。对于森林的预测结果，XGB 的预测能力要高于 RF 模型，XGB 模型所预测的比 RF 预测的更贴近真实值，散点图更**收敛于 1：1**线。相比于其他土地类型，两者对于湿地的预测效果稍差，但是 XGB 的预测效果仍好于 RF 的效果。总体来说，RF 模型与 XGB 模型对于五种土地类型的预测都能达到良好的效果，XGB 模型的预测效果比 RF 模型的更好。




图 6-8 草地、耕地、灌木图、森林与湿地预测散点图（上排为 RF，下排为 XGB）

本模型基于相关性选择 X 值指标，覆盖了自然地理与人文地理因素，能够综合的评估中国土地利用变化的特征与结构。经分析得，自然地理与人文地理因素对于土地利用影响深远，目前我国耕地的增长速度开始减缓，森林绿植的增长率开始变大。我国土地利用率的变化说明了随着环境保护、退耕还林的政策持续落实，节能减排理念深入人心，即使在全球变暖大环境的情况下，我国生态环境质量仍能在党的带领下持续好转,出现了稳中向好的趋势。虽然成效并不稳固,稍有松懈就有可能出现反复，犹如逆水行舟，不进则退，我们应从自己做起，为生态文明建设、绿色家园建设贡献自己的力量。

6.3.4 有用性分析

基于构建的模型，根据模型精度以及对预测值与实际值散点图判断，选择 XGB 模型作为预测模型，通过输入高程数据以及预测的 2025-35 年平均降水量、人均 GDP、人口密度，预测 2025-35 年的草地、耕地、灌木、森林以及湿地变化率，如图 6-9 所示。




图 6-9 2025-2035 平均变化率预测图

由图 6-9 可知，在 2025-35 年，草地与灌木的变化趋势相近，我国草地与灌木受自然地理以及人文地理的影响，在我国东南部处于减少趋势，而在我国西北部趋于不变，在四川盆地处于增长趋势：东南部地区由于城市化进程加快和土地利用方式的转变，草地与灌木面积逐渐减少，农业和基础设施的扩张占用了大量草地资源；而在西北部，干旱和

半干旱气候条件限制了土地的开发与利用，导致草地与灌木面积趋于**不变**，这一地区的生态环境相对稳定，草地与灌木维持现状；此外，四川盆地因其独特的地形和气候条件，水资源相对丰富，农业生产潜力较大，**促进**了草地与灌木的生长。

对于耕地变化变化情况，在 2025–35 年，我国中部、南部与东北部的耕地趋于**不变**甚至**缓慢变少**，这主要是由于这些地区的城市化进程加快和工业化发展导致了耕地的非农化现象。此外，农业生产方式的转变以及对生态环境保护的重视，使得耕地的开发和利用受到了一定限制。而在我国新疆的东南部**减少**最多，我国新疆西北区域有增长趋势。潜在的原因可能是新疆东南部地区由于自然条件的严峻性及气候变化的影响，耕地减少情况最为明显，面临着水资源短缺和土壤退化的问题。而新疆西北区域则表现出**增长**趋势，这可能是由于政策扶持、农业技术的进步以及灌溉设施的改善，促进了该地区耕地的开发与利用。

在 2025–35 年，我国森林的变化趋势十分可观，在我国中部、南部、东部乃至东北、新疆的大部分区域呈**增长**趋势，这一增长趋势的主要原因可归结为国家对生态环境保护的重视和森林资源的可持续管理政策的实施。近年来，我国加大了植树造林和生态恢复的力度，推动了生态红线的划定和自然保护区的建立，从而有效促进了森林覆盖率的提升。此外，随着人们环保意识的增强，社会各界对森林保护的支持力度不断加大。相较之下，东北地区东部及新疆东南部的森林下降趋势则主要受到气候变化、土地利用方式转变和人为活动影响的制约。例如，东北地区的经济发展和城市化进程加快，导致部分森林被砍伐用于基础设施建设和农业扩展；而新疆东南部则因干旱气候和水资源短缺，森林生长受到限制。森林变化的趋势不仅反映了生态环境政策的有效性，也提示我们在区域发展与生态保护之间寻求平衡的重要性。

针对湿地变化，由图可知我国的湿地绝大多数处于**减少**的状态，仅青海区域、东北地区东部有缓慢增长的趋势。湿地的减少往往与农业扩展、城市化进程和基础设施建设等因素密切相关，尤其是在中部和南部地区，湿地被改造成农田和城市用地，导致生态环境的严重破坏。此外，气候变化引发的干旱和水资源短缺也对湿地生态系统造成了负面影响，降低了湿地的水位和面积。然而，青海地区和东北地区东部的湿地增长趋势则可能得益于当地实施的湿地保护政策和生态恢复措施。例如，青海省通过加强湿地保护与恢复，开展生态补偿政策，有效提升了湿地的生态功能；而东北地区东部则可能受到气候相对湿润的影响，促进了湿地植被的恢复。因此，湿地变化的趋势不仅反映了生态环境的**脆弱性**，也强调了持续开展湿地保护和恢复工作的**必要性**。

7. 模型的评价与改进

7.1 模型的优点

1. 本文充分考虑了地理大数据的**格式、坐标系、分辨率**特征，针对不同地理数据进行了格式转换、重投影、重采样等数据**预处理**。
2. 本文在地理参数上的分析上采用了数理的说明，不只是凭借感觉选择参数，而是依据既得的**评价指标**选择参数。
3. 本文不只列出表格例证，同时也重视可视化数据的展示与说明，让读者更加直观的感受数据中蕴藏的规律。

4. 本文针对同一个问题，建立了多种模型，对同一种模型，进行了**超参数调优**，择优建模，考虑较为全面。
5. 针对中国土地利用变化问题，本文考虑到了中国土地利用变化中每种土地类型的正向变化以及负向变化，较为综合得处理问题。

7.2 模型的不足

1. 本文对于地理大数据的处理方式还不够完善，基于地理大数据所建立得模型**精度**还有待提升，且利用模型回答问题的**逻辑**还不够清晰。
2. 本文针对描述中国土地利用变化的特征与结构采用的机器学习模型**种类有限**，对于本文针对中国土地利用变化的解释有**局限性**。

7.3 模型的改进

1. 采用更多种的数学模型，包括但不限于神经网络等**深度学习**算法。
2. 考虑针对地理大数据对机器学习模型进行底层的改进，而不单单是以“**黑盒**”的形式使用。

参考文献

- [1] Han, J., Miao, C. (2022). A new daily gridded precipitation dataset for the Chinese mainland based on gauge observations. figshare. Dataset. <https://doi.org/10.6084/m9.figshare.21432123.v4>.
- [2] 余振, Philippe Ciais, 朴世龙等. 1900-2019 年中国土地利用和覆盖变化数据集[DS/OL]. 国家生态科学数据中心, 2022. <https://doi.org/10.12199/nesdc.ecodb.pa.2022.11>.<https://cstr.cn/15732.11.nesdc.ecodb.pa.2022.11>.
- [3] Yu, Z., Ciais, P., Piao, S., Houghton, R. A., Lu, C., Tian, H., Agathokleous, E., Kattel, G. R., Sitch, S., Goll, D., Yue, X., Walker, A., Friedlingstein, P., Jain, A. K., Liu, S., & Zhou, G. (2022). Forest expansion dominates China's land carbon sink since 1980. Nature Communications, 13(1), 5374. <https://doi.org/10.1038/s41467-022-32961-2>.
- [4] Mosaedi A, Sough MG, Sadeghi SH. Sensitivity analysis of monthly reference crop evapotranspiration trends in Iran: a qualitative approach[J]. Theor Appl Climatol, 2017,128:857–873.
- [5] 兰琳, 流域的旅游气候舒适度及时空演变研究[D]. 华中师范大学, 2016.
- [6] 汤国安. (2019). 中国数字高程图 (1KM). 国家青藏高原数据中心. [Tang, G. (2019). Digital elevation model of China (1KM). National Tibetan Plateau / Third Pole Environment Data Center.].
- [7] Fang, S., Mao, K., Xia, X., Wang, P., Shi, J., M. Bateni, S., Xu, T., Cao, M., & Heggy, E. (2021). A Daily near-surface Air Temperature Dataset for China from 1979 - 2018 (Version 1.0) [Data set]. Zenodo. <https://doi.org/10.5281/zenodo.5502275>.
- [8] 王灿, 王嘉琛. (2022). 中国历史人口空间分布公里网格数据集 (1990-2015 逐年). 国家青藏高原数据中心. <https://doi.org/10.12078/2017121101> [Wang, C., Wang, J. (2022). Kilometer grid dataset of China's historical population spatial distribution (1990-2015). National Tibetan Plateau / Third Pole Environment Data Center. <https://doi.org/10.12078/2017121101>].
- [9] 徐新良. (2017). 中国人口空间分布公里网格数据集. 资源环境科学数据注册与出版系统 (<http://www.resdc.cn/DOI>). DOI:10.12078/2017121101.

- [10]王灿, 王嘉琛. (2022). 中国历史 GDP 空间分布公里网格数据集 (1990-2015). 国家青藏高原数据中心. <https://doi.org/10.12078/2017121102> [Wang, C., Wang, J. (2022). Kilometer grid dataset of China's historical GDP spatial distribution (1990-2015). National Tibetan Plateau / Third Pole Environment Data Center. <https://doi.org/10.12078/2017121102>].
- [11]徐新良. (2017). 中国 GDP 空间分布公里网格数据集. 资源环境科学数据注册与出版系统(<http://www.resdc.cn/DOI>). DOI:10.12078/2017121102.
- [12]Liu, H., Jiang, D., Yang, X., & Luo, C. (2005). Spatialization approach to 1 km grid GDP supported by remote sensing. *Geo-Inf. Sci*, 7, 120-123.
- [13]黄莹, 包安明, 陈曦, 刘海隆, & 杨光华. (2009). 基于绿洲土地利用的区域 GDP 公里格网化研究. *冰川冻土*, (1), 158-165.
- [14]Yi, L., Xiong, L., & Yang, X. (2006). Method of pixelizing GDP data based on the GIS. *J. Gansu Sci*, 18, 54-58.
- [15]方精云.地理要素对我国温度分布影响的数量评价[J].生态学报,1992,(02):97-104.
- [16]刘 阳 . 基 于 CatBoost 模 型 的 降 水 量 预 测 研 究 [D]. 西 南 大 学,2023.DOI:10.27684/d.cnki.gxndx.2023.000283.
- [17]陈浩然,耿飞,刘黎平等.西藏墨脱复杂地形 X 波段相控阵偏振天气雷达降水观测和反演方法研究[J].高原气象,2024,43(01):99-113.
- [18]许岩,苏诺尔,冯中姝.基于 Logistic 回归分析的人员疏散出口二次选择行为研究[J].科学技术与工程,2022,22(36):16260-16268.
- [19]王琪明.基坑混凝土支撑轴力监测系统与数据处理方法研究[D].西南科技大学,2021.DOI:10.27415/d.cnki.gxngc.2021.001011.
- [20]苏文成,洪舒悦,卢章平等.人工智能风险体系与模块化评价指标构建实证研究[J/OL].情报杂志,1-11[2024-09-25].<http://kns.cnki.net/kcms/detail/61.1167.G3.20240828.1050.002.html>.

附录

Sen's 斜率估计法.py

```
import numpy as np
import rasterio
import os
from scipy import stats

# 设置文件路径
data_dir = r'C:\Users\WuShiYu\Desktop\年平均降水'
output_file = r'C:\Users\WuShiYu\Desktop\sen\SEN.tif'

# 读取样本文件以获取数据维度和投影信息
sample_file = os.path.join(data_dir, 'precipitation_1990_avg.tif')
with rasterio.open(sample_file) as src:
    a = src.read(1)
    R = src.transform
    m, n = a.shape

cd = 30 # 设置时间跨度为 30 年 (1990-2019)
datasum = np.full((m * n, cd), np.nan)
```

```

# 循环读取每年的数据
for k, year in enumerate(range(1990, 2020)):
    filename = os.path.join(data_dir, f'precipitation_{year}_avg.tif')
    with rasterio.open(filename) as src:
        data = src.read(1).flatten()
        datasum[:, k] = data

result = np.full((m, n), np.nan)

# 遍历每个像素点
for i in range(datasum.shape[0]):
    data = datasum[i, :]
    if np.min(data) > 0:
        valuesum = []
        # 计算每对年份之间的变化率
        for k1 in range(1, cd):
            for k2 in range(k1):
                cz = data[k1] - data[k2]
                j1 = k1 - k2
                value = cz / j1
                valuesum.append(value)
        # 计算变化率的中位数
        if valuesum:
            value = np.median(valuesum)
            result[i // n, i % n] = value

# 将结果写入 GeoTIFF 文件
with rasterio.open(output_file, 'w', driver='GTiff',
                    height=m, width=n, count=1, dtype=result.dtype,
                    crs=src.crs, transform=R) as dst:
    dst.write(result, 1)

print(f'Results saved to {output_file}')

```

Mann-Kendall 检验法.py

```

import numpy as np
import rasterio
from rasterio.transform import from_origin
from scipy import stats
import os

# 设置文件路径
data_dir = r'C:\Users\WuShiYu\Desktop\年平均降水'

```

```

output_file = r'C:\Users\WuShiYu\Desktop\mk\MK222.tif'

# 获取数据维度
sample_file = os.path.join(data_dir, 'precipitation_1990_avg.tif')
with rasterio.open(sample_file) as src:
    a = src.read(1)
    R = src.transform
    m, n = a.shape

cd = 30 # 设置时间跨度为 30 年
datasum = np.full((m * n, cd), np.nan)

# 循环读取每年的数据
for year in range(1990, 2020):
    filename = os.path.join(data_dir, f'precipitation_{year}_avg.tif')
    with rasterio.open(filename) as src:
        data = src.read(1).flatten()
        datasum[:, year - 1990] = data

sresult = np.full((m * n, ), np.nan)

# 对每个像素点进行循环
for i in range(m * n):
    data = datasum[i, :]
    if np.all(data > 0):
        sgnsum = []
        for k in range(1, cd):
            for j in range(k):
                sgn = data[k] - data[j]
                sgnsum.append(np.sign(sgn))
            sresult[i] = np.sum(sgnsum)

# 计算方差
vars = cd * (cd - 1) * (2 * cd + 5) / 18
zc = np.full((m, n), np.nan)

# 计算 Z 值
zc[sresult == 0] = 0
zc[sresult > 0] = (sresult[sresult > 0] - 1) / np.sqrt(vars)
zc[sresult < 0] = (sresult[sresult < 0] + 1) / np.sqrt(vars)

# 将结果写入 GeoTIFF 文件
with rasterio.open(output_file, 'w', driver='GTiff',
                    height=m, width=n, count=1, dtype=zc.dtype,

```

```

        crs=src.crs, transform=R) as dst:
    dst.write(zc, 1)

print(f'Results saved to {output_file}')

```

随机森林回归.py

```

import rasterio
import numpy as np
import pandas as pd
from scipy.ndimage import zoom
from sklearn.model_selection import train_test_split, GridSearchCV
from sklearn.ensemble import RandomForestRegressor
from sklearn.metrics import mean_squared_error, r2_score
import matplotlib.pyplot as plt
import seaborn as sns

# 设置中文字体
plt.rcParams['font.family'] = 'SimHei' # 黑体
plt.rcParams['axes.unicode_minus'] = False # 处理负号显示问题

# 文件路径
rainfall_file = r'D:\数学建模\D 题附件数据集\数据集 3 (日降水)\暴雨次数.tif'
elevation_file = r'D:\数学建模\D 题附件数据集\数据集 1 (高程)\数据集 1\中国数字高程图
(1km)\Geo\TIFF\chinadem_geo.tif'
slope_file = r'D:\数学建模\D 题附件数据集\数据集 1 (高程)\数据集 1\中国数字高程图
(1km)\Geo\TIFF\slope.tif'
aspect_file = r'D:\数学建模\D 题附件数据集\数据集 1 (高程)\数据集 1\中国数字高程图
(1km)\Geo\TIFF\aspect.tif'
temp_file = r'D:\数学建模\D 题附件数据集\数据集 2 (地表气温)\数据集
2\annual_mean_temperature.tif'

# 读取数据的函数
def read_raster(file_path):
    with rasterio.open(file_path) as dataset:
        data = dataset.read(1) # 读取第一波段
    return data

# 读取数据
rainfall_data = read_raster(rainfall_file)
elevation_data = read_raster(elevation_file)
slope_data = read_raster(slope_file)
aspect_data = read_raster(aspect_file)
temp_data = read_raster(temp_file)

```

```

# 打印数据的形状
print("降水量数据形状:", rainfall_data.shape)
print("高程数据形状:", elevation_data.shape)
print("坡度数据形状:", slope_data.shape)
print("坡向数据形状:", aspect_data.shape)
print("地表温度数据形状:", temp_data.shape)

# 获取高程数据的尺寸
rainfall_shape = rainfall_data.shape

# 计算重采样因子
zoom_factors_rainfall = (rainfall_shape[0] / elevation_data.shape[0],
rainfall_shape[1] / elevation_data.shape[1])
zoom_factors_temp = (rainfall_shape[0] / temp_data.shape[0],
rainfall_shape[1] / temp_data.shape[1])

# 重采样数据
resampled_temp_data = zoom(temp_data, zoom_factors_temp, order=1)
resampled_elevation_data = zoom(elevation_data, zoom_factors_rainfall,
order=1)
resampled_slope_data = zoom(slope_data, zoom_factors_rainfall, order=1)
resampled_aspect_data = zoom(aspect_data, zoom_factors_rainfall, order=1)

# 检查重采样后的数据形状
print("重采样后的降水量数据形状:", resampled_elevation_data.shape)
print("重采样后的坡度数据形状:", resampled_slope_data.shape)
print("重采样后的坡向数据形状:", resampled_aspect_data.shape)
print("重采样后的地表温度数据形状:", resampled_temp_data.shape)

# 创建数据框以便处理
data = pd.DataFrame({
    'rainfall': rainfall_data.flatten(),
    'elevation': resampled_elevation_data.flatten(),
    'slope': resampled_slope_data.flatten(),
    'aspect': resampled_aspect_data.flatten(),
    'temperature': resampled_temp_data.flatten()
})

# 筛选出地表温度小于 5 度的数据
#data = data[data['temperature'] > 5]

# 处理 NaN 值（删除含 NaN 的行）
data.dropna(inplace=True)

```

```

# 打印数据框的形状
print("处理后的数据框形状:", data.shape)

# 特征矩阵 X 和目标变量 y
X = data[['elevation', 'slope', 'aspect', 'temperature']]
y = data['rainfall']

# 划分训练集和测试集
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.2,
random_state=42)

# 定义随机森林回归模型
rf_model = RandomForestRegressor(random_state=42)

# 定义超参数网格
param_grid = {
    'n_estimators': [50, 100, 200], # 树的数量
    'max_depth': [None, 10, 20, 30], # 最大深度
    'min_samples_split': [2, 5, 10], # 分裂所需的最小样本数
    'min_samples_leaf': [1, 2, 4], # 叶子节点最小样本数
    'max_features': ['auto', 'sqrt', 'log2'] # 特征选择方式
}

# 进行网格搜索
grid_search = GridSearchCV(estimator=rf_model, param_grid=param_grid,
                           cv=5, n_jobs=-1, verbose=2,
                           scoring='neg_mean_squared_error')
grid_search.fit(X_train, y_train)

# 输出最佳参数
print("最佳参数:", grid_search.best_params_)

# 使用最佳参数训练模型
best_rf_model = grid_search.best_estimator_
y_pred = best_rf_model.predict(X_test)

# 评估模型
mse = mean_squared_error(y_test, y_pred)
r2 = r2_score(y_test, y_pred)

print(f"测试集均方误差: {mse:.4f}")
print(f"测试集 R²: {r2:.4f}")

```

```

# 输出特征重要性
feature_importance = best_rf_model.feature_importances_
coef_df = pd.DataFrame({
    '变量': ['高程', '坡度', '坡向', '地表温度'],
    '重要性': feature_importance
})

print(coef_df)

# 绘制散点图和回归线
data_sample = pd.DataFrame({'真实暴雨次数': y_test, '预测暴雨次数': y_pred})

plt.figure(figsize=(12, 6))
sns.regplot(x=data_sample['真实暴雨次数'], y=data_sample['预测暴雨次数'],
            scatter_kws={'alpha': 0.6}, line_kws={'color': 'red'})
plt.xlabel('真实暴雨次数', fontsize=20)
plt.ylabel('预测暴雨次数', fontsize=20)
plt.title('暴雨次数预测散点图及回归线', fontsize=20)

plt.xlim(0, max(data_sample['真实暴雨次数']))
plt.ylim(0, max(data_sample['预测暴雨次数']))

plt.grid(True)
plt.show()

```

XGBoost.py

```

import rasterio
import numpy as np
import pandas as pd
from scipy.ndimage import zoom
from sklearn.model_selection import train_test_split, GridSearchCV
from xgboost import XGBRegressor # 导入 XGBoost 回归器
from sklearn.metrics import mean_squared_error, r2_score
import matplotlib.pyplot as plt
import seaborn as sns

# 设置中文字体
plt.rcParams['font.family'] = 'SimHei' # 黑体
plt.rcParams['axes.unicode_minus'] = False # 处理负号显示问题

# 文件路径
rainfall_file = r'D:\数学建模\D 题附件数据集\数据集 3 (日降水)\暴雨次数.tif'
elevation_file = r'D:\数学建模\D 题附件数据集\数据集 1 (高程)\数据集 1\中国数字高程图

```

```

(1km)\Geo\TIFF\chinadem_geo.tif'
slope_file = r'D:\数学建模\D 题附件数据集\数据集 1（高程）\数据集 1\中国数字高程图
(1km)\Geo\TIFF\slope.tif'
aspect_file = r'D:\数学建模\D 题附件数据集\数据集 1（高程）\数据集 1\中国数字高程图
(1km)\Geo\TIFF\aspect.tif'
temp_file = r'D:\数学建模\D 题附件数据集\数据集 2（地表气温）\数据集
2\annual_mean_temperature.tif'

# 读取数据的函数
def read_raster(file_path):
    with rasterio.open(file_path) as dataset:
        data = dataset.read(1) # 读取第一波段
    return data

# 读取数据
rainfall_data = read_raster(rainfall_file)
elevation_data = read_raster(elevation_file)
slope_data = read_raster(slope_file)
aspect_data = read_raster(aspect_file)
temp_data = read_raster(temp_file)

# 打印数据的形状
print("降水量数据形状:", rainfall_data.shape)
print("高程数据形状:", elevation_data.shape)
print("坡度数据形状:", slope_data.shape)
print("坡向数据形状:", aspect_data.shape)
print("地表温度数据形状:", temp_data.shape)

# 获取高程数据的尺寸
rainfall_shape = rainfall_data.shape

# 计算重采样因子
zoom_factors_rainfall = (rainfall_shape[0] / elevation_data.shape[0],
rainfall_shape[1] / elevation_data.shape[1])
zoom_factors_temp = (rainfall_shape[0] / temp_data.shape[0],
rainfall_shape[1] / temp_data.shape[1])

# 重采样数据
resampled_temp_data = zoom(temp_data, zoom_factors_temp, order=1)
resampled_elevation_data = zoom(elevation_data, zoom_factors_rainfall,
order=1)
resampled_slope_data = zoom(slope_data, zoom_factors_rainfall, order=1)
resampled_aspect_data = zoom(aspect_data, zoom_factors_rainfall, order=1)

```

```

# 检查重采样后的数据形状
print("重采样后的降水量数据形状:", resampled_elevation_data.shape)
print("重采样后的坡度数据形状:", resampled_slope_data.shape)
print("重采样后的坡向数据形状:", resampled_aspect_data.shape)
print("重采样后的地表温度数据形状:", resampled_temp_data.shape)

# 创建数据框以便处理
data = pd.DataFrame({
    'rainfall': rainfall_data.flatten(),
    'elevation': resampled_elevation_data.flatten(),
    'slope': resampled_slope_data.flatten(),
    'aspect': resampled_aspect_data.flatten(),
    'temperature': resampled_temp_data.flatten()
})

# 处理 NaN 值 (删除含 NaN 的行)
data.dropna(inplace=True)

# 特征矩阵 X 和目标变量 y
X = data[['elevation', 'slope', 'aspect', 'temperature']]
y = data['rainfall']

# 划分训练集和测试集
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.2,
random_state=42)

# 定义参数范围
param_grid = {
    'n_estimators': [50, 100], # 树的数量
    'max_depth': [3, 5], # 树的最大深度
    'learning_rate': [0.01, 0.1], # 学习率
    'subsample': [0.8, 1.0] # 随机抽样比例
}

# 实例化模型
xgb_model = XGBRegressor(random_state=42)

# 使用 GridSearchCV 进行超参数调优
grid_search = GridSearchCV(estimator=xgb_model, param_grid=param_grid,
scoring='neg_mean_squared_error', cv=3, n_jobs=-1)

# 训练模型
grid_search.fit(X_train, y_train)

```

```

# 输出最佳参数
print("最佳参数:", grid_search.best_params_)

# 使用最佳参数的模型进行预测
best_model = grid_search.best_estimator_
y_pred = best_model.predict(X_test)

# 评估模型
mse = mean_squared_error(y_test, y_pred)
r2 = r2_score(y_test, y_pred)

print(f"测试集均方误差: {mse:.4f}")
print(f"测试集 R2: {r2:.4f}")

# 绘制散点图和回归线
data_sample = pd.DataFrame({'真实暴雨次数': y_test, '预测暴雨次数': y_pred})

plt.figure(figsize=(12, 6))
sns.regplot(x=data_sample['真实暴雨次数'], y=data_sample['预测暴雨次数'],
            scatter_kws={'alpha': 0.6}, line_kws={'color': 'red'})
plt.xlabel('真实暴雨次数', fontsize=20)
plt.ylabel('预测暴雨次数', fontsize=20)
plt.title('暴雨次数预测散点图及回归线', fontsize=20)

plt.xlim(0, max(data_sample['真实暴雨次数']))
plt.ylim(0, max(data_sample['预测暴雨次数']))

plt.grid(True)
plt.show()

```