



中国研究生创新实践系列大赛
“华为杯”第二十一届中国研究生
数学建模竞赛

学 校 曲阜师范大学

参赛队号 24104460003

	1.姜喆
队员姓名	2.常芮源
	3.刘鲁倩

中国研究生创新实践系列大赛 “华为杯”第二十一届中国研究生 数学建模竞赛

题 目： _____ 大数据驱动的地理综合问题 _____

摘 要：

地理系统是多要素作用的复杂系统。根据中央气象台和国家气象信息中心国家级气象观测站数据统计，以暴雨为代表的**极端天气**事件给人类的生产生活带来了巨大的影响，**2012—2023 年**（截至 2023 年 9 月 15 日），我国发生暴雨天气事件共 **503** 次。本文利用地理大数据，使用**统计测度、机器学习和统计模型**等方法，系统地研究了**极端天气成因**及其影响因素、**地形—气候**间的交互作用和**我国地理变化的特征与结构**。

针对问题一，降水量和土地利用（土地覆被类型）时空演化特征建模。首先，从**数据集 3**（日降水量数据）和**数据集 4**（年土地利用类型数据）中提取 1990-2019 年的**经纬度、降水量和土地利用类型**的数据。其次，对降水数据定义不同年份的**年均降水量、月均降水量、降水距平百分率和区域方差**指标，对土地利用数据定义每年的**动态度和成分度**。再次，对月均降水量进行**时间序列分解**，提取其**长期趋势、循环因素和随机误差**。最后，对上述原始数据以及各种时空指标使用**箱线图、折线图、地图、堆砌条形图**进行可视化，得出如下结论：

针对**降水量**：**（1）**西北地区和青藏地区是全国年均降水量最少的区域。华中地区与东北地区降水量适中。**（2）**华南地区、华东沿海地区海和西藏南部地区降水量变化大，容易发生极端降水事件。**（3）**自 2014 年，华中地区容易发生极端降水事件。针对**土地利用/土地覆被**：**（1）**草地利用分布范围最广，湿地最少。耕地利用率最高在东北地区、华北地区和华东地区；黑龙江地区和华东沿海地区的林地利用率最高；内蒙古中部地区的灌木丛利用率最高；西北中部地区的湿地利用率最高。**（2）**湿地和灌木丛的利用率最低，且呈现逐年递减的趋势。土地类型利用率最高的是草地。**（3）**各土地利用类型的动态度均呈现不同程度的递减趋势，其中灌木丛和湿地利用率持续呈现递减趋势。更详细的时空结果见正文。

针对问题二，地形—气候在极端天气形成中的交互作用研究。首先，提取数据 1（山影、坡度、坡向、海拔和高程）和数据 4（土地利用）中的**地形数据**以及数据 2（日气温）和数据 3（日降水）的气候数据。通过**重抽样**将不同数据源的像素统一成 0.5°，根据**经纬度、时间**将这些数据**连接**到一起，共得到 **6169803** 条数据，并将降水量通过**等级划分**对数据进行打标签。其次，检验整合后数据库的**缺失值**并进行删除和插值得到 **5990100** 条数据库（具体数据变量见正文），通过对降水数据划分等级来探究数据的不平衡特征，其中特大暴雨仅有 92 条，占全数据的 **0.0025%**，可见该数据库中的数据呈现出极其不平衡状态。再次，采用欠采样技术抽取“无雨”数据 **6000** 条，“小雨”数据 **5000** 条，“中雨”数据 **4000** 条，“大雨”数据 **3000** 条，“暴雨”数据 **1500** 条，“大暴雨”数据 **1208** 条，“特大暴雨”数据 **92** 条建立抽样数据库。最后，基于抽样数据对 **92** 条特大暴雨的样本点做统计分析，对

全部抽样数据做相关性检验，建立联合均值与方差模型、决策树模型和 MCP 变量选择模型，得出具体结论如下：

地形方面：（1）**海拔和坡度**与降水等级呈负相关，**山影和坡向**与降水等级呈正相关。（2）**草地和灌木丛**与降水等级呈负相关，**耕地和林地**与降水等级呈正相关。（3）针对特大暴雨数据分析，在暴雨发生区域，林地利用率是 **0.797**，然而**耕地、草地、湿地和灌木丛**利用率低，表明不是暴雨发生的主要地形区域。气候方面：（1）**气温和降水量**对降水等级呈正相关。暴雨天气的形成与特定的环境条件紧密相关，暴雨天气的形成与气温（超过 **8°**）和海拔（超过 **1084 米**）紧密相关，这些条件有利于降水形成。通过决策树模型可知**经度 $\geq 97.2^\circ$** 是划分暴雨和大暴雨的第一个分界点，其次是**气温 $< 20.6^\circ$ 、经度 $< 109^\circ$ 和坡度 $\geq 0.112^\circ$** 。综合**均值和方差模型**的结果结论一致，即**纬度、气温和土地利用率**对极端天气形成有较大的影响。更详细的地形—气候相互作用结果见正文。

针对问题三，降雨、地形和土地利用对极端天气的影响因素和预测研究。首先，根据问题二的抽样数据将数据变量离散化后建立 **XGBoost 模型**，探究雨量等级的**影响因素**和不同变量间的**交互效应**。分别对降水量和气温使用**高斯混合模型**进行**空间聚类**，将空间数据划分成**9 份**不同的区域，并根据第二问的结论对不同的空间数据进行打标签，得出 2025—2035 年应对暴雨灾害最脆弱的地区。其次，通过经纬度把不同源数据的数据聚合到空间上，识别删除聚合后的**缺失值**，建立**支持向量机**和**随机森林模型**。最后，通过 ROC 曲线、**混淆矩阵、精度和 AUC 值**衡量不同模型的好坏，其中**支持向量机**的精度和 AUC 值为 **0.993** 和 **0.671**；**随机森林**的精度和 AUC 值为 **0.999** 和 **0.999**。得出主要结论如下：

（1）影响极端天气的前三个因素为**气温、海拔和草地的利用率**。（2）**聚类模型**表明**东南沿海地区、长江中下游地区、西南地区**附近在 2025—2035 年可能成为暴雨重灾区或暴雨高风险地区。（3）**预测模型**表明**大珠江三角洲地区、西藏自治区和云南交界线、长江中下游（长沙、武汉和南昌）地区**附近在 2025-2035 年可能会成为暴雨重灾区。

针对问题四，中国土地利用变化结构特征建模分析。首先，读取数据 5（人口空间分布数据）和数据 6（GDP 空间分布数据）的年空间数据，关于人口数据选取 5000，3000，1000，300 进行截断，对 GDP 数据选取 100 进行截断。其次，对上述数据使用地图进行可视化，分别从**三级阶梯、南北地区、东西地区**进行分析。最后，对地形数据、土地利用类型数据和气候数据分别根据南北部和东西部的分界线进行聚合统计，使用**假设检验（独立 t 检验）**分析不同变量是否存在显著差异，得出如下结论：

（1）东西部地区存在显著差异，降水量差幅为 **1.604**，气温差幅为 **1.353**。除此之外，**草地、林地、灌木丛和湿地**利用率均存在显著差异。耕地的利用率差幅中等。（2）南北方地区在**降水量**上差幅为 **1.452**，气温上差幅为 **0.776**。在**耕地、林地、草地、灌木丛和湿地**的利用率上均存在显著差异。

最后，本文所展示的额外可视化结果及代码程序见附录。

关键词：极端天气大数据；不平衡数据抽样；XGboost 模型；高斯混合聚类；机器学习模型；联合均值与方差模型

目 录

一、绪论	6
1.1 问题背景	6
1.2 文献综述	7
1.3 问题重述	8
1.4 问题分析	9
1.5 全文框架	10
二、降水量、土地利用和土地覆被类型统计测度研究	11
2.1 降水量指标模型	12
2.1.1 数据处理及相关指标定义	12
2.1.2 年降水量指标建立与可视化	13
2.1.3 月降水量指标建立与可视化	14
2.1.4 月降水量数据的时间序列分解模型	16
2.1.5 不同区域年均降水量的空间可视化	17
2.1.6 不同区域降水距平百分率的均方差的空间可视化	18
2.1.7 不同区域的年降水量均方差的空间可视化	19
2.2 土地利用/土地覆被统计测度模型	20
2.2.1 数据整理与可视化	21
2.2.2 不同区域的土地利用类型动态度的空间可视化	23
2.2.3 不同区域的土地利用类型成分度的可视化	24
2.3 本章小结	25
三、基于统计模型的地形—气候数据在极端天气形成的影响研究	27
3.1 地形数据整合	28
3.1.1 海拔数据处理与整合	28
3.1.2 山影、坡度和坡向数据处理	28
3.1.3 土地利用类型数据处理	30
3.2 气候数据整合	31
3.2.1 气温数据整合	31
3.2.2 降水数据整合	32
3.3 数据预处理和可视化	33

3.3.1 变量整合及缺失值数据预处理	33
3.3.2 不平衡数据	34
3.4 数据抽样与相关性分析	34
3.4.1 数据抽样	34
3.4.2 相关性分析	35
3.5 特大暴雨地形—气候分析	37
3.6 基于联合均值与方差模型的地形—气候分析	39
3.6.1 联合均值与方差模型	39
3.6.2 模型建立与求解	40
3.6.3 模型检验	41
3.7 基于决策树和 MCP 变量选择的地形—气候分析	41
3.7.1 决策树简介	41
3.7.2 MCP 惩罚回归模型	42
3.7.3 决策树求解和讨论	42
3.7.4 MCP 变量选择求解和讨论	43
3.8 本章小结	44
四、基于深度学习的中国境内受灾能力脆弱地区的长期预测	45
4.1 数据选取和整合	45
4.1.1 基于问题 2 地形—气候的聚类数据整合	45
4.1.2 基于经纬度的空间数据整合	46
4.2 基于空间地形—气候聚类研究	47
4.2.1 高斯混合聚类简介	47
4.2.2 基于空间降水聚类模型结果	48
4.2.3 基于空间气温聚类模型结果	49
4.3 基于 XGBoost 模型的影响作用分析	51
4.3.1 XGboost 模型简介	51
4.3.2 保护因素和危险因素分析	52
4.3.3 因素间的交互作用分析	54
4.4 基于经纬度数据的预测建模研究	57
4.4.1 支持向量机简介	57
4.4.2 随机森林概述	58

4.4.3 精度参数比较	58
4.4.4 模型结果比较	59
4.5 灾害能力预测结果可视化	61
4.5.1 基于聚类模型的灾害能力预测可视化	61
4.5.2 基于预测模型的灾害能力预测可视化	63
4.6 本章小结	63
五、中国土地利用变化的特征与结构研究	65
5.1 数据整合与可视化	65
5.1.1 数据整合	66
5.1.2 人口空间分布可视化研究	67
5.1.3 GDP 空间分布可视化研究	69
5.2 中国土地利用变化特征的准确性和有用性讨论	69
5.2.1 中国地区的气候数据	70
5.2.2 中国地区的地形数据	71
5.3 本章小结	73
六、主要结论与模型优缺点讨论	74
6.1 主要结论	74
6.1.1 问题一的主要结论	74
6.1.2 问题二的主要结论	74
6.1.3 问题三的主要结论	75
6.1.4 问题四的主要结论	75
6.2 模型优缺点	75
参考文献	76
附录	79
附录 A 问题一的额外可视化结果	79
附录 B 问题一：时空分析代码	86
附录 C 问题二：地形气候相互代码	89
附录 D 问题三：暴雨灾害能力预测代码	91
附录 E 问题四：中国土地利用特征代码	94

一、绪论

1.1 问题背景

近年来，以暴雨为代表的极端天气事件给人类的生产生活带来了巨大的影响，从农业减产、城市内涝到基础设施损坏，无一不凸显出应对极端天气挑战的重要性和迫切性。中国气象局针对极端天气提出了“聚焦灾害性天气，强化气象监测预报预警”的策略，利用大数据手段对地理系统进行分析，是实现监测和预防极端天气这一策略的重要手段。而地理系统作为一个由自然与人文等大量相互联系、相互作用的要素相互交织、相互影响的复杂巨系统，具有由于地理系统具有高度的综合性、复杂性和动态性的特征。因此地理学家通常会选择地理综合的方式，用系统性思维来分析这一复杂系统的主导特征、内在规律以及各要素之间的相互作用关系。



地理综合分析通常将地理空间数据和相关属性数据结合起来，揭示不同地理现象之间的相互关系和规律。在分析过程中时，通常会采用多种统计方法，其中描述性统计是一种常用的方法。描述性统计通过数值和图形的方式对数据集进行概括和总结，以便于我们理解数据的特征和分布情况。



因此在应对极端天气方面，大数据分析展现出了其独特的优势。通过对海量气象数据的收集、整理与分析，结合先进的算法模型，气象部门能够实现对暴雨等极端天气的精确预测。这种预测不仅涉及发生时间、地点，还包括了对强度的精准判断，为政府及相关部门提前部署防灾减灾措施提供了科学依据，有效降低了灾害带来的损失。

1.2 文献综述

全球气候变化导致自然灾害的发生频率、其强度及其影响范围也日益加剧，尤其是洪水、干旱、地震、台风、泥石流等灾害对人民生命财产安全、经济社会发展构成严重威胁。因此，国务院在 2020 年至 2023 年 2 月期间开展了首次全国自然灾害综合风险普查，结合中国复杂的人文和自然地理特征，深入摸清自然灾害风险隐患，并建立了风险普查成果的应用体系，确保防控成果能够应对频发的灾害风险。同时，全面精确的自然灾害风险数据及科学的风险评估方式在预防和控制重大自然灾害中发挥了重要作用，具有极其重要的战略意义和现实意义。

近年来，学者们对于自然灾害的防治也逐渐深入，早期马九杰等^[1]主要分析了农业自然灾害风险对粮食生产和粮食安全的影响，以及提升自然灾害抵御能力对增强粮食生产能力和减少粮食不安全性的重要作用；Gabriel 等^[4]表明自然灾害对经济增长有负面影响，而制度质量和国际开放程度能够缓解这些负面影响。

在自然灾害与气候变化的关系方面，现已有很多专家学者们对此作出针对研究。党群等^[23]以晋陕蒙毗邻地区为典型寒冬灾害地区，发现大约每 5 年发生一次寒冻灾害，秋季最频繁，认为灾害与气候变化紧密相关，主要由寒潮或强冷空气活动引发；李鸣阳等^[24]分析发现气候变化与农业病虫害的发生频率之间密切相关，良好气候促进农业，极端气候则阻

碍发展并引发病虫害。

在自然灾害的风险管理方面，李小伟等^[25]以常受台风侵袭的海南地区为典型台风灾害地区，研究海南台风特点及防控现状，提出了通过加强精细化预报和会商研判的建议，来应对台风侵袭。许小华等^[26]针对旱情机理不明、监测预警能力不足的问题，以鄱阳湖流域为典型旱灾地区，研究构建了全要素、全过程的预测预警和风险评估技术体系，为科学应对旱灾提供了技术支撑。

在自然灾害的大数据技术应用与创新方面，胡启元^[27]发现人工智能技术的发展在气候预测领域取得了显著进步，提高了预测的准确性和时效性，能够应对气候变化带来的灾害趋势提供了新的可能性和解决方案。邓志强等^[28]分析了阿克苏地区冰雹天气的成因、特征和人影防雹技术经验，并探讨了人工防雹工作，为当地农业生产和社会经济效益提供借鉴。

在自然灾害的大数据技术应用与创新方面，胡启元^[33]发现人工智能技术的发展在气候预测领域取得了显著进步，提高了预测的准确性和时效性，能够应对气候变化带来的灾害趋势提供了新的可能性和解决方案。邓志强等^[34]分析了阿克苏地区冰雹天气的成因、特征和人影防雹技术经验，并探讨了人工防雹工作，为当地农业生产和社会经济效益提供借鉴。Beringer 等^[1]在气候变化的情况下，模拟了由不同气候模型数据驱动的雨养和灌溉生物质产量，并将这些模拟结果与未来能源作物土地可用性的情景评估相结合。

1.3 问题重述

基于上述背景研究，题目提供了大量的地理数据。具体描述见正文。

问题一：

基于数据集 3 和数据集 4 中的数据信息，描述 1990 年至 2020 年间，中国境内降水量与土地利用/土地覆被类型这两个变量在时间和空间上的特征。

问题二：

基于数据集 1-4 中的暴雨数据信息，探索地形-气候之间的相互作用以及其在暴雨天气形成过程中的作用，建立地形-气候与暴雨天气的相互作用模型。

问题三：

结合地形-气候在暴雨天气相互作用模型，给出暴雨成为灾的临界条件。其次，结合数据集 4 人类活动与自然灾害之间的相互作用，建立对 2025-2035 年中国境内暴雨灾害脆弱地区的多因素的预测模型，包括降雨、地形和土地。

问题四：

在前三个问题的基础上，进一步考虑地形、人口密度以及社会经济活动总量这三个变

量，综合多个关键因素来构建中国土地利用模型，预测未来土地利用变化的特征与结构。

1.4 问题分析

针对问题一，对降水量和土地利用/土地覆被两个变量分别构建描述性统计分析。首先根据给定的中国大陆 0.25° 逐日降水数据集和土地利用和覆盖变化数据集，提取出 1990 年-2020 年间的每日降水量和土地利用/土地覆被数据依次按照月 and 年进行数据聚合，定义出 13 个指标，分时间和空间两个维度进行可视化。

针对问题二，极端天气中地形-气候影响作用的建模分析。本题主要以暴雨为代表的极端天气事件，根据题目给出的数据集，选择前 4 个数据集（即中国数字高程图、中国 1° 近地表气温数据集、中国大陆 0.25° 逐日降水数据集和中国 0.5° 土地利用和覆盖变化数据集）。在提取数据之前需对所有图片文件的像素精度进行统一。统一像素精度之后，以空间维度整合地形数据，以时间维度整合气候数据，将时空数据合并在一起。结合国家发布的降水量划分标准，给每条数据打上雨量等级的标签，若出现不平衡数据，则需进行重采样。最后，分别对抽样的地形—气候数据建立联合均值和方差模型以及决策树模型，研究地形和气候的变量对极端天气产生的影响大小。

针对问题三，地形-气候对极端天气的影响和交互作用建模分析与预测。直接使用问题二的数据库，建立混合高斯模型对各地区的降水量进行聚类，对全国地区进行划分，尤其是划分出重灾区，对这部分数据进行重点分析。随后，将各连续变量数据进行划分，将地形—气候数据转换为分类数据，再建立 XGBoost 模型，使用 Shap 方法细致化研究地形—气候变量对灾难的影响以及各变量间的交互作用。最后，建立聚类模型，根据以上的分析结果建立模型预测各地区发生灾难的概率，并对结果进行可视化。

针对问题四，中国土地利用变化的特征与结构分析。本题使用的数据在问题二和问题三的基础上，加入中国大陆 1km 逐年历史人口空间分布公里网格数据集和中国大陆 1km 逐年历史 GDP 空间分布公里网格数据集。提取人口空间分布数据和历史 GDP 空间分布数据之后，需对两个原始数据集进行描述性统计分析以及可视化。随后，结合前三个问题得到的关于地形、气候和土地利用类型对极端天气的影响结论，根据南北结构，东西差异，三级阶梯进行数据整合，并进行假设检验。

1.5 全文框架




图 1-1 全文框架图

二、降水量、土地利用和土地覆被类型统计测度研究

本章的具体解题思路见图 2-1。




图 2-1 问题一的求解流程图

本章整合了题目中所给的中国大陆 0.25° 逐日降水数据集^[5]和中国 0.5° 土地利用合覆盖变化数据集^[12]，对降水量和土地利用/土地覆被两个变量进行描述性统计分析。本章的符号假设见表 2-1。

表 2-1 符号说明

符号	说明
RY	年平均降水量
RM	某年的月平均降水量
MSE_{RY}	年降水量均方差

符号	说明
MSE_{RM}	某年的月降水量均方差
SR_Y	年累计降水量
SR_M	某年的月累计降水量
RYA	年降水距平百分率
RMA	某年的月降水距平百分率
MSE_{RYA}	年降水距平百分率的均方差
U	土地利用的数量
LK	土地利用类型动态度
Lty	土地利用/土地覆被率
SK	土地类型成分度

2.1 降水量指标模型

2.1.1 数据处理及相关指标定义

本节首先读取中国大陆 0.25° 逐日降水数据集中的 NetCDF 文件，文件中包含了 22645 层图像，包含了 1961 年 1 月 1 日至 2022 年 12 月 31 日每日的降水量分布。随后筛选出本体所需要的 1990-2020 年的每日降水量数据，并根据以下定义的相关指标对数据进行整合。

定义年降水距平百分率和年降水距平百分率的均方差

$$RYA_i = \frac{RY_i - \overline{RY}}{\overline{RY}} \times 100\%, \quad i = 1, 2, \dots, N, \quad (2-1)$$

$$MSE_{RYA} = \sqrt{\frac{1}{N} \sum_{i=1}^N (RYA_i - \overline{RYA})^2}, \quad i = 1, 2, \dots, N, \quad (2-2)$$

$$RYM = \frac{RM_i - \overline{RM}}{\overline{RM}} \times 100\%, \quad i = 1, 2, \dots, n, \quad (2-3)$$

其中 RYA_i 表示第 i 年的年降水距平百分率， RY_i 表示第 i 年的年均降水量， $\overline{RY}$ 表示 1990-

2020 年的平均降水量，即 $N = 31$ ， $\overline{RY} = \frac{1}{N} \sum_{i=1}^N RY_i$ ； RM_i 表示某年第 i 月的年均降水量， $\overline{RM}$

表示某年的平均降水量，即 $n = 12$ ， $\overline{RM} = \frac{1}{n} \sum_{i=1}^n RM_i$ 。

其次定义土地利用类型动态度

$$LK_j = \frac{U_{i,j} - U_{i-1,j}}{U_{i,j}} \times \frac{1}{T} \times 100\%, \quad (2-4)$$

其中 LK_j 表示第 j 种土地利用类型动态度, $U_{i,j}$ 表示第 i 段时间内第 j 种土地利用的数量,

T 为时间段。

最后定义土地利用类型成分度

$$SK_k = \frac{\#(I\{Lty_k \neq 0\})}{\sum_{i=1}^5 \#(I\{Lty_k \neq 0\})}, \quad (2-5)$$

其中 LC_k 表示第 k 种土地利用类型成分度, Lty_k 表示第 k 种土地利用类型的土地利用/土地覆被率。

2.1.2 年降水量指标建立与可视化

本节将基于每日降水量数据, 以年为时间单位, 计算出每一年降水量的均值、方差和标准差, 具体结果如表 2-2 所示。分析表 可知, 我国的年降水量在 1992 年首先出现了降水量低峰, 随后年降水量递增再递增循环, 一直到 2005 年, 再 1998 年出现了第一个年降水量高峰; 从 2006 年到 2020 年, 在 2011 年出现了降水量的历史低峰, 并在 2016 年迎来了历史高峰。

表 2-2 年降水量的均值、方差和标准差表

year	RYm	RYs	RYsd	year	RYm	RYs	RYsd
1990	1.666	9834605.71	5.525	2006	1.510	8910204.149	5.368
1991	1.574	9287713.81	5.526	2007	1.553	9168761.94	5.409
1992	1.497	8859831.14	5.180	2008	1.651	9773802.77	5.721
1993	1.649	9733305.429	5.334	2009	1.471	8685240.49	5.141
1994	1.609	9499460.38	5.693	2010	1.744	10292446.89	5.831
1995	1.565	9236441.879	5.645	2011	1.425	8411525.35	5.021
1996	1.604	9493787.549	5.798	2012	1.724	10204312.7	5.776
1997	1.529	9022141.84	5.520	2013	1.666	9831151.05	5.854
1998	1.781	10510957.25	6.099	2014	1.621	9565371.369	5.513
1999	1.554	9170191.3	5.491	2015	1.710	10091208.42	5.795
2000	1.554	9195041.7	5.397	2016	1.863	11027804.19	6.257
2001	1.526	9009948.77	5.336	2017	1.683	9934041.03	5.705
2002	1.672	9868188.25	5.674	2018	1.728	10197501.72	5.539
2003	1.623	9581774.259	5.432	2019	1.655	9768726.07	5.627
2004	1.522	9007958.521	5.217	2020	1.776	10510829.17	6.012
2005	1.600	9442224.82	5.408				

基于表 2-2 的结果，本文绘制了分布图，如图 2-2 所示。其中第一个图是年降水量的误差图，第二个图是年均降水量的折线分布图，第三个图是年降水量均方差的折线分布图，将三个图对比分析可知：在均值和方差的最小值处，对应的误差范围较小，而最大值处的误差范围较大，其余的误差范围变动不大；年均降水量呈周期性下降再增长的趋势，且出现了三个比较明显的局部最小值和最大值；年降水量均方差在 2012-2020 年整体相比 2012 年以前呈上升趋势。




图 2-2 年降水量误差图（上）和年均降水量（中）以及年降水量均方差（下）折线图

2.1.3 月降水量指标建立与可视化

本节将每日降水量数据以月为时间单位，计算出每年每月降水量的均值、方差和标准差，截取部分结果如表 2-3 所示。分析表 2-3 可知，每年 1 月和 12 月的降水量最少，2 月到 4 月内的降水量是冰冻变化的，而从 5 月开始一直到 7 月逐渐达到降水量的高峰之后逐月下降。

表 2-3 月降水量的均值、方差和误差表

No	year	month	Rmm	Rms	Rmss
1	1990	1	0.479699	240473.8	2.032702
2	1990	2	1.004497	454824.2	3.738375
3	1990	3	0.980857	491704.6	3.310685
...	...	...	...	...	...

No	year	month	Rmm	Rms	Rmss
230	2009	2	0.494211	223772.8	2.213353
231	2009	3	0.854114	428168.1	3.323339
232	2009	4	1.359887	659721.8	4.748939
.....					
370	2020	10	0.874905	438591	3.429398
371	2020	11	0.52211	253291	2.628899
372	2020	12	0.155925	78165.17	0.795962




图 2-3 1990—2020 年的月均降水量的散点拟合分布图

基于表 2-3 的结果,首先绘制了 1990—2020 年每月的降水量均值分布,如图 2-3 所示。从整体上看,每年的 1 月和 12 月的月均降水量是最低的,从 2 月开始逐渐呈现上升的趋势,一直增长到 8 月达到降水量的高峰,随后开始逐月下降,由此可知,我国地区的夏季降水量占全年降水量的一半,是降水最多的季节,春季和秋季降水量紧随其后,而冬季是降水最少的季节。图 2-4 的月均降水量的误差分布也佐证了我国降水呈现季节性分布。6 月~8 月的降水分布范围最大,1 月和 12 月的降水分布范围最小,整体的降水范围变换呈中

间高两边低的现象。




图 2-4 1990-2020 年月均降水量的误差图

2.1.4 月降水量数据的时间序列分解模型

将月均降水量转换为时间序列数据，并对该数据进行分解。

Wold 分解定理：任何的平稳过程都可以分解为两个不相关的平稳过程之和。一部分为确定性部分，可以用过去值描述现在值的部分；另一个是纯随机性部分。

Cramer 分解定理：任何一个时间序列都可以分解为确定性趋势成分和平稳的零均值误差成分。

确定性因素分解：由确定性因素导致的非平稳现象，因其显示出明显规律，因此，通常将确定性因素作为研究重点，采用确定性因素分解法进行分析。序列的变化是多样的，但可以大致归为以下四类：

- 长期趋势（Trend）：这种因素表现为序列出现明显的长期趋势。
- 循环波动（Circle）：序列会出现从低到高再由高至低的循环运动。
- 季节性变化（Season）：序列呈现出和季节变化相关的稳定的周期波动。
- 随机波动（Immediate）：序列会受到各种其他因素的综合影响，而这些影响导致序列呈现出一定的随机波动。

在信息确定时，这四种因素会影响序列，从而呈现出不同的波动。在实际中，这四种因素有加法和乘法两种模型，如下：

加法模型：

$$x_t = T_t + C_t + S_t + I_t . \tag{2-6}$$

乘法模型：

$$x_t = T_t \cdot C_t \cdot S_t \cdot I_t . \tag{2-7}$$




图 2-5 月降水量数据的时间序列分解图

从图 2-5 可以看出，月降水量随季节的变动规律性变化，有明显的季节效应，而且在 1990 年至 2020 年月降水量整体上呈现上升趋势，但其周期性难以判断，认为月降水量是一个含有季节性成分和趋势成分的时间序列。

2.1.5 不同区域年均降水量的空间可视化

由于将 1990—2020 年的年均降水量的空间分布热力图（见附录 A.1）以年为单位进行对比时，视觉上没有较为明显的区别，因此本节分别对年均降水量和年降水量均方误差的进行等级划分，划分标准如表 2-4 所示。为了更突出表现出不同年份之间的年均降水量的变化，选择每间隔 6 年进行绘图，得到的划分等级的降水量空间分布热力图如图 2-6 所示。

表 2-4 年均降水量的等级划分

等级	年均降水量范围
0	<1
1	1~3
2	3~5
3	5~7
4	7~9
5	>9

通过分析图 2-6 可知，从整体上看西北地区和青藏地区是全国年均降水量最少的地区，这与这些地区的地理位置和地形特征有关，通常这些内陆地区远离海洋，降水量较少。华中地区和东北地区的年均降水量等级在 1~2 的范围内，表明这些地区降水量适中。南部地区的年均降水量显著高于其他地区，尤其是华东沿海地区和华南地区，可能是由于受到季风的影响，年均降水量显著高于其他地区。在 2002 年，南方地区整体的年均降水量明显高于其他年份。从 2008 年起，高年均降水量地区逐渐从华南地区向华东地区 and 华中地区转移。




图 2-6 年均降水量空间分布热力图

2.1.6 不同区域降水距平百分率的均方差的空间可视化

降水距平百分率的均方差是一个用来衡量降水量相对于其长期平均值（通常是一个气候基准期，如 30 年）的偏离程度的波动大小的统计量。这个统计量反映了降水量在不同时

间或空间上的变异性或稳定性。因此，这里给出了我国每年降水距平百分率的均方差的空间分布热力图，如图 所示。




图 2-7 降水距平百分率的均方差的空间分布热力图

通过分析图 2-7 可知，华南地区和华东沿海地区以及西藏的最南部地区的年降水距平百分率的均方差最大，表示降水量与其年均降水量的平均值之间的偏差最大，即降水量的年际或季节性变化较大，意味着这些地区更容易受到降水变化的影响，发生极端降水事件（如干旱或洪涝）的可能性较高。相反，西北部地区的年降水距平百分率的均方差最小，此地区易出现正常等级气候事件，而华北地区和东北地区的降水量则较为稳定。

2.1.7 不同区域的年降水量均方差的空间可视化

由于均方差能够反映出降水量的波动振幅大小，均方差高值的区域易出现异常等级气候事件，均方差低值区域易出现正常等级气候事件。本节首先绘制了未划分等级的 1990—2020 年的年降水量均方差的空间分布热力图（见附录 A.2）和月降水量均方差的空间分布热力图（见附录 A.4），根据表 2-5 所示的等级划分标准，随后绘制了 1990—2020 年每 6 年的年降水量均方差空间分布热力图，如图 2-8 所示。

表 2-5 年降水量均方差的等级划分	
等级	年降水均方差范围
0	<5
1	5~10
2	11~15
3	16~20
4	>20

分析图 2-8 可知，从整体上看，西藏的最南部地区、华南地区和华东沿海地区的均方差是最大的，但是在 2014 年之后，均方差最大的地区从华南地区和华东沿海地区逐渐向华中地区转移，表明近几年华中地区开始经常发生极端降水事件。而华北地区和东北的均方差分布范围在 2020 年达到最大，表明该类地区的降水范围扩大，发生极端降水事件的概率增加，而西北地区和青藏地区的降水量则是最稳定的。




图 2-8 年降水量均方差空间分布热力图

2.2 土地利用/土地覆被统计测度模型

本节将中国 0.5° 土地利用和覆盖变化数据集中 1990-2019 年的 GeoTIFF 图像文件进行提取，文件中包含了 22645 层图像，根据题目要求提取了 1990 年至 2019 年耕地、林地、草地、灌木丛和湿地的数据，数据中的相关变量说明见表 2-6。

表 2-6 变量说明对应表

变量	说明
year	年份
x	经度
y	纬度
cropland	耕地
forest	林地
grass	草地
shrub	灌木丛
wetland	湿地

变量	说明
value	土地利用/土地覆盖率
Sk	土地类型成分度
LandType	土地类型

2.2.1 数据整理与可视化

将 1990-2019 年五种土地利用类型图像文件全部读取之后，筛选出土地利用/土地覆盖率等 5 个变量的数据，并将这些进行整合，如表 2-7 所示。随后，将数据按照土地类型进行分组整合，并计算出每种土地类型数据下土地利用/土地覆盖率最小值等 6 种统计量，如表 2-8 所示。

表 2-7 土地利用/和覆盖变化数据

NO	value	x	y	year	LandType
1	0.003094	122.475	53.325	1990	cropland
2	9.05E-05	122.975	53.325	1990	cropland
3	0.003794	123.975	53.325	1990	cropland
4	0.000872	124.475	53.325	1990	cropland
5	0.002206	124.975	53.325	1990	cropland
.....					
528023	0.002903	110.975	19.325	2019	wetland
528024	3.34E-05	108.975	18.825	2019	wetland
528025	0.000611	110.475	18.825	2019	wetland
528026	0.000109	109.475	18.325	2019	wetland
528027	4.90E-05	109.975	18.325	2019	wetland

表 2-8 数据描述性统计表

统计量	土地类型				
	cropland	forest	grass	shrub	wetland
最小值	5.61E-06	3.08E-07	4.97E-08	9.87E-09	1.21E-07
1/4分位数	1.81E-02	1.08E-02	2.23E-01	4.47E-02	6.32E-04
中位数	1.20E-01	8.01E-02	5.00E-01	1.26E-01	4.35E-03
均值	2.08E-01	1.95E-01	5.06E-01	1.82E-01	2.50E-02
3/4分位数	3.21E-01	3.21E-01	7.88E-01	2.34E-01	2.03E-02
最大值	9.36E-01	9.98E-01	1.00E+00	1.00E+00	5.17E-01

根据表 2-8 的数据，以年为单位，绘制了每隔 6 年的土地利用/土地覆被率的空间热力分布图，如图 所示。通过图 可知，我国地形中的草地利用分布范围最大，其次是灌木丛、耕地和林地，湿地利用的分布范围最小。其中，草地利用率最大的区域是新疆、内蒙古和

西藏地区；耕地利用率最大的地区是东北地区、华北地区和华中地区；林地利用率最大的地区是黑龙江省和华东沿海地区；灌木丛利用率最大的地区是内蒙古中部地区；湿地利用率最大的地区是西北中部地区。




图 2-9 不同土地利用类型的土地利用/土地覆被率的空间热力分布图

随后以年为单位，将每年的不同的土地利用类型土地利用/土地覆被率数据进行聚合，绘制了如图 2-10 所示的分布图。通过分析图 2-10 可知，湿地和灌木丛的土地利用/土地覆被率最低，且呈现逐年递减的趋势；其次是耕地、灌木丛和草地的土地利用/土地覆被率，且耕地和灌木丛呈现先减少后增加的趋势，草地呈现逐年递增的趋势；土地利用/土地覆被率最高的是草地，且呈现逐年递减的趋势。




图 2-10 不同的土地利用类型的年均土地利用率分布图

2.2.2 不同区域的土地利用类型动态度的空间可视化

基于土地利用/和覆盖变化数据，以年为单位，依据式(2-4)计算土地利用类型成分度，将每年的不同的土地利用类型成分度数据进行聚合，划分成动态度增加和减少两个维度，绘制了如图 2-11 所示的分布图。



图 2-11 土地利用类型动态度（增加）的空间热力分布图

通过分析图 2-11 中可知，耕地的土地利用类型动态度的增加量逐年递减，但在 2014 年之后开始增加后再减少；林地的土地利用类型动态度的增加量增长到 2008 年之后开始逐年递减了，而草地的土地利用类型动态度的增加量增长到 2002 年之后就逐年递减了；灌木丛和湿地的土地利用类型动态度的增加量一直在逐年减少。




图 2-12 土地利用类型动态度（减少）的空间热力分布图

通过分析图 2-12 中可知，耕地的土地利用类型动态度的减少量逐年递增，但在 2014 年之后开始减少；林地的土地利用类型动态度的减少量增长到 2002 年之后开始逐年递减了，而草地的土地利用类型动态度的减少量增长到 2008 年之后就逐年递减了；灌木丛和湿地的土地利用类型动态度的减少量一直在逐年减少。

2.2.3 不同区域的土地利用类型成分度的可视化

基于土地利用/和覆盖变化数据，以年为单位，依据式(2-5)计算土地利用类型成分度，将每年的不同的土地利用类型成分度数据进行聚合，得到了如表 2-9 所示的结果。

表 2-9 土地利用类型成分度数据

No	year	LandType	value	Sk
1	1990	cropland	0.061839	0.288916
2	1990	forest	0.052275	0.32869
3	1990	grass	0.22466	0.420351
4	1990	shrub	0.073848	0.371391
5	1990	wetland	0.009749	0.325661
...	...	...	...	...

No	year	LandType	value	Sk
146	2019	cropland	0.060795	0.296083
147	2019	forest	0.090773	0.395821
148	2019	grass	0.201469	0.421159
149	2019	shrub	0.06276	0.372098
150	2019	wetland	0.006574	0.268423

根据表 2-9 的结果，绘制了如图 2-13 所示的分布图。通过图 2-13 中可知，耕地的土地利用类型成分度最低，虽呈现逐年递增的趋势，但是变化较小；其次是湿地和灌木丛，且湿地的土地利用类型成分度在 2014 年前基本不变，但在 2014 年发生突变，和灌木丛的呈现先减少后增加的趋势，草地呈现逐年递增的趋势；土地利用类型成分度最高的是草地，且呈现逐年递减的趋势。然而，5 种土地利用类型的成分度均在 2014 年发生阶梯式骤降，随后再逐年递增，但整体上还是低于 2014 年以前的。




图 2-13 不同的土地利用类型的年均土地利用类型成分度分布图

2.3 本章小结

本章对降水量和土地利用/土地覆被两个变量分别构建描述性统计分析，得到的结论如下：

1. 我国降水呈现季节性分布特点，夏季降水量最多，占全年一半，且降水分布范围最广，反之，冬季最少。整体降水范围变换呈出中间高两边低的趋势。

2. 西北地区和青藏内陆地区是全国年均降水量最少的区域。华中与东北地区降水量适中。南部地区，受季风影响，年均降水量显著高于其它地区。自 2002 年起南方地区降水量偏高，自 2008 年起高降水量区域逐渐从华南移向华东和华中。

3. 华南、华东沿海和西藏南部地区降水量变化大，容易极端降水事件，而华北和东北地区降水量较为稳定。自 2014 年，华中地区容易发生极端降水事件。华北和东北地区降水范围扩大，发生极端降水事件的概率增加，而西北地区和青藏地区的降水量则是最稳定的。

4. 草地利用分布范围最广，湿地最少。草地利用率最高在新疆、内蒙古和西藏地区；耕地利用率最高在东北、华北和华中地区；林地利用率最高在黑龙江和华东沿海地区；灌木丛利用率最高在内蒙古中部；湿地利用率最高在西北中部。

5. 湿地和灌木丛的土地利用/土地覆被率最低，且呈现逐年递减的趋势。土地利用/土地覆被率最高的是草地，且呈现逐年递减的趋势。

6. 各类土地利用类型（耕地、林地、草地、灌木丛、湿地）的动态变化均表现出不同程度的递减趋势，其中灌木丛和湿地的持续递减趋势，而耕地为复杂的变化过程。

7. 五类土地利用类型的成分度在 2014 年都发生骤降，之后虽然逐年递增，但整体上仍然低于 2014 年以前的水平，且之后未能复到之前的水平。草地的成分度虽然最高，但正在逐年下降，而其他类型的成分度则在不同程度上有所波动。

三、基于统计模型的地形—气候数据在极端天气形成的影响研究

本章的具体解题思路见图 3-1。




图 3-1 问题二求解流程图

本章整合了上一章使用到的两个数据集、中国数字高程图（1km）^[1]和中国 0.1° 近地表气温数据集^[2]，分别提取这些数据集中的经纬度、海拔和气温等数据，经过数据处理的

整合之后，建立相关分析模型，研究地形—气候在极端天气形成的中的影响作用。

3.1 地形数据整合

地形数据主要包括题目所给的中国数字高程图（1km）是根据中国 1:25 万等高线和高程点形成的 1km 数据，包含经纬度和高程、山影（hillshade）、坡度（Slope）、坡向（Aspect）图，也包含了对应位置的海拔高度数据，以及上文使用的中国 0.5° 土地利用合覆盖变化数据集，包含每日的土地利用类型数据。由于这两种的数据集的像素精度和数据维度均不是统一的，因此若想将这数据整合成一个数据，需对这些数据进行像素精度和维度的统一。

3.1.1 海拔数据处理与整合

从中国数字高程图数据集提取出海拔数据，即 GeoTIFF 图像数据，原始海拔数据的处理原理如图 所示，并将处理前后的海拔数据进行空间可视化，如图 3-2 所示，可以明显的看出，随着像素精度的降低，对应的海拔高度范围也发生了变化，海拔高度上限降低。




图 3-2 高精度（左）和 0.5° 像素（右）的中国地域海拔图

3.1.2 山影、坡度和坡向数据处理

从中国数字高程图数据集提取出正轴割圆锥等面积投影数据，即 GeoTIFF 图像数据，选取经纬度和山影等数据，并对这些数据进行处理，其原理如图 3-3 所示。随后，为了将这些数据与海拔数据合并成一个数据，需对山影等数据进行经纬度坐标的统一，即与海拔数据的经纬度统一，再进行像素统一处理。最后，将处理前后的数据进行空间可视化，如图 3-4 至图 3-6 所示，可以明显的看出，随着像素精度的降低，对应的数据范围也发生了变化，其上限降低。




图 3-3 数据像素降低原理




图 3-4 高精度（左）和 0.5° 像素（右）的中国地域山影图




图 3-5 高精度（左）和 0.5° 像素（右）的中国地域坡度图




图 3-6 高精度（左）和 0.5° 像素（右）的中国地域坡向图

高程图的海拔数据和山影等数据经过经纬度和像素精度统一后，合并在一个数据表中，截取部分数据如表 3-2 所示。

表 3-2 高程图数据整合表

No	Longitude	Latitude	Aspect	Hillshade	Slope	Elevation
1	120.975	53.825	172.560	180.776	2.128	464.309
2	121.475	53.825	168.161	178.489	2.302	474.497
3	121.975	53.825	184.562	180.479	2.338	488.579
4	122.475	53.825	181.023	180.674	1.994	474.770
5	122.975	53.825	177.344	179.795	1.949	429.677
...	...	...	...	...	...	...
4527	110.475	17.825	185.565	180.193	2.668	0.000
4528	108.475	17.325	180.158	179.659	2.736	0.000
4529	108.975	17.325	182.311	180.671	2.446	0.000
4530	109.475	17.325	177.720	179.498	2.575	0.000
4531	109.975	17.325	179.261	180.039	2.204	0.000

3.1.3 土地利用类型数据处理

选取问题一所应用的每日土地利用/土地覆被率数据，对这些数据进行处理，将 5 种土地类型设置成新的数据变量，其过程如图 3-7 所示，合并在一个数据表中，截取部分数据如表 3-3 所示。




图 3-7 土地类型数据整理过程
表 3-3 土地利用类型数据整合表

No	year	Longitude	Latitude	cropland	forest	grass	shrub	wetland
1	2015	72.475	16.825	0	0	0	0	0
2	2016	72.475	16.825	0	0	0	0	0
3	2017	72.475	16.825	0	0	0	0	0
4	2018	72.475	16.825	0	0	0	0	0
5	2015	72.475	17.325	0	0	0	0	0
...	...	...	...	...	...	...	...	...
39620	2018	135.475	54.825	0	0	0	0	0
39621	2015	135.475	55.325	0	0	0	0	0
39622	2016	135.475	55.325	0	0	0	0	0
39623	2017	135.475	55.325	0	0	0	0	0
39624	2018	135.475	55.325	0	0	0	0	0

3.2 气候数据整合

3.2.1 气温数据整合

从中国大陆 0.1° 近地表气温数据集提取出 2015—2018 年期间的每日均气温数据，截取部分数据如表 3-4 所示。

表 3-4 每日气温数据整理

No	Time	Longitude	Latitude	Temperature
1	2015/1/1	122.475	53.825	-30.82838783
2	2015/1/1	122.975	53.825	-30.67347781
3	2015/1/1	123.475	53.825	-30.179604
4	2015/1/1	120.475	53.325	-33.86013467
5	2015/1/1	120.975	53.325	-33.57429913
...	...	...	...	...
6169799	2018/12/31	108.975	18.325	15.03099375
6169800	2018/12/31	109.475	18.325	14.98677028
6169801	2018/12/31	109.975	18.325	15.01806718
6169802	2018/12/31	109.475	17.825	16.3519742
6169803	2018/12/31	109.975	17.825	16.19897079

随后，分别以月和年为单位，计算出对应的月均气温和年均气温。按照表 3-5 的气温等级划分标准，给每行数据打上标签。

表 3-5 气温等级划分标准

日均气温		月均气温		年均气温	
严寒	<-10℃	寒冷	<0℃	寒带气候	<-3℃
寒冷	-10~-1℃	凉爽	0~9℃	亚寒带气候	-3~9℃
凉爽	0~9℃	温暖	10~19℃	温带气候	10~17℃
温和	10~27℃	高温	>20℃	亚热带气候	18~25℃
闷热	28~34℃			热带气候	>26℃
炎热	35~37℃				
高温	>38℃				

3.2.2 降水数据整合

从中国大陆 0.25° 逐日降水数据集提取出 2015—2018 年期间的每日降水量数据，截取部分数据如表 3-6 所示。

表 3-6 每日降水量数据整理

No	Time	Longitude	Latitude	rain
1	2015/1/1	121.975	53.825	0
2	2015/1/1	122.475	53.825	0
3	2015/1/1	122.975	53.825	0
4	2015/1/1	123.475	53.825	0
5	2015/1/1	120.475	53.325	0
...	...	...	...	...
6042692	2018/12/31	109.975	18.825	0.402399998
6042693	2018/12/31	110.475	18.825	0.1296
6042694	2018/12/31	108.975	18.325	0.104
6042695	2018/12/31	109.475	18.325	0.111199999
6042696	2018/12/31	109.975	18.325	0.082000003

随后，分别以月和年为单位，计算出对应的月均降水量和年降水量。按照表 3-7 的降水量等级划分标准，给每行数据打上标签。

表 3-7 降水量等级划分标准

日降水量		月均降水量		年降水量	
小雨	<10mm	干旱地区	<10mm	干旱地区	<200mm
中雨	10~25mm	半干旱地区	10~25mm	半干旱地区	200~400mm
大雨	25~50mm	半湿润地区	25~50mm	半湿润地区	400~800mm
暴雨	50~100mm	潮湿地区	>100mm	潮湿地区	>800mm
大暴雨	100~200mm				
特大暴雨	>200mm				

3.3 数据预处理和可视化

3.3.1 变量整合及缺失值数据预处理

通过分别对地形数据和气候数据的处理与整合，本节通过链接数据中相同的经度、纬度和事件，将上述两种数据整合在一起，并对整合在一起的数据变量进行统一的说明，具体如表 3-8 所示。

表 3-8 变量说明表

数据名称	变量名	说明	取值范围	类型
地形数据	Longitude	经度	[73.47,134.97]	连续
	Latitude	纬度	[17.82,53.83]	连续
	Hillshade	山影	[160.9,188.8]	连续
	Slope	坡度	[0,23.79]	连续
	Aspect	坡向	[24.82,310.1]	连续
	Elevation	海拔	[0,5569]	连续
	cropland	耕地	[0,1]	离散
	forest	林地	[0,1]	离散
	grass	草地	[0,1]	离散
	shrub	灌木丛	[0,1]	离散
	wetland	湿地	[0,1]	离散
气候数据	Rain	降水量	[0,570.03]	连续
	Temperature	气温	[0,41.6]	连续

然而实际生活中由工具故障、系统问题等都会导致数据存在缺失，忽略数据缺失情况直接进行数据分析，会导致不正确甚至是错误的结论。因此，了解数据的缺失形式和缺失机制是非常重要的，所以我们需要对数据进行预处理，对上述整理后的地形—气候数据表的缺失值进行判断和处理，具体如表 3-9 所示。地形—气候数据总量为 6169803 条，其中降水量的缺失值最多，海拔、坡向、坡度和山影也存在缺失值，将含有这些缺失值的数据删除之后，地形—气候数据总量变为 5990100 条。

表 3-9 地形—气候数据统计分析

变量	最小值	1/4 分位数	中位数	均值	3/4 分位数	最大值	缺失量
Longitude	73.47	91.47	104.97	104.08	116.47	134.97	0
Latitude	17.82	30.82	36.83	36.42	41.83	53.83	0
Temperature	-50.96	-2.73	8.28	7.22	18.52	41.6	0
Rain	0	0	0.02	1.73	0.77	570.03	179703
Elevation	0	402.4	1121.6	1745.9	2884.8	5569	5844
Aspect	24.82	165.84	175.26	175.17	185.1	310.1	5844

变量	最小值	1/4 分位数	中位数	均值	3/4 分位数	最大值	缺失量
Hillsade	160.9	178.7	179.5	179	179.9	188.8	5844
Slope	0	0.77	2.17	3.08	4.26	23.79	5844
cropland	0	0	0.02	0.14	0.2	0.93	0
forest	0	0.01	0.08	0.21	0.35	0.99	0
grass	0	0.17	0.45	0.47	0.76	1	0
shrub	0	0.01	0.09	0.15	0.18	1	0
wetland	0	0	0	0.02	0.01	0.5	0

3.3.2 不平衡数据

根据题目要求，将地形—气候数据中划分出的每日降雨等级，统计了各雨量等级的占比，如图 3-8 所示。在有雨的天气中，小雨的占比高达 92%，而暴雨及以上仅占比约 0.35%，由此可知，该数据是不平衡数据。为了提高模型对少数类别的识别能力，避免模型偏向多数类别。对于不平衡数据，可以考虑使用重采样技术，即过采样少数类数据或者欠采样多数类数据。




图 3-8 日降水量等级占比饼图

3.4 数据抽样与相关性分析

3.4.1 数据抽样

通过统计地形—气候数据中各雨量等级的数据量可知，“无雨”数据有 2395914 条，“小雨”数据有 3313572 条，“中雨”数据有 214314 条，“大雨”数据有 54220 条，“暴雨”数据有 10780 条，“大暴雨”数据有 1208 条，“特大暴雨”数据有 92 条。根据这些数据量，考虑采用欠采样技术，即抽取“无雨”数据 6000 条，“小雨”数据 5000 条，“中雨”数据 4000 条，“大雨”数据 3000 条，“暴雨”数据 1500 条，“大暴雨”数据 1208 条，“特大暴

雨”数据 92 条，得到了共 20800 条地形—气候数据。最后，使用此数据建立相关模型，进而分析。

3.4.2 相关性分析

对地形—气候数据的所有变量进行相关性分析，得到如图 3-9 所示的相关性热力图。由此可知，与雨量等级相关性较强的变量主要是气温、维度，海拔，林地利用率、草地利用率。为了更细致化分析变量间的相关性，分地形和气候分别绘制相关性图。

首先分析雨量等级与海拔、山影、坡度和坡向数据的相关性关系，如图 3-10 所示。海拔、山影、坡度和坡向变量与雨量等级的相关关系均显著，海拔和坡度与雨量等级呈负相关，山影和坡向与雨量等级呈正相关。海拔与山影、坡度和坡向的相关关系均显著，且只有坡度与其呈正相关，坡向和坡度都与山影呈显著负相关，坡向与坡度呈现负关系。




图 3-9 地形—气候数据的变量相关性热力图




图 3-10 海拔、山影、坡度和坡向数据的相关性图

随后，分析雨量等级与土地利用类型数据的相关性关系，如图 3-11 所示。耕地、林地、草地和灌木丛的土地利用率和灌木丛与雨量等级的相关关系均显著，草地和灌木丛与雨量等级呈负相关，耕地和林地与雨量等级呈正相关。耕地与林地、草地和灌木丛的相关关系均显著，且均呈负相关，林地和草地都与灌木丛呈显著负相关，林地与草地呈显著负关系。

最后，分析雨量等级与经度、纬度、气温和降水量数据的相关性关系，如图 3-12 所示。经度、纬度、气温和降水量与雨量等级的相关关系均显著，纬度与雨量等级呈负相关，经度、气温和降水量与雨量等级呈正相关。经度与纬度、气温和降水量的相关关系均显著，且均呈正相关，纬度与气温和降水量均呈显著负相关，气温与降水量呈现显著正相关关系。




图 3-11 土地利用类型数据的相关性图







图 3-12 经度、纬度、气温和降水量数据的相关性图

3.5 特大暴雨地形—气候分析

针对地形—气候数据中的特大暴雨事件，将其作为一种特殊现象单独进行分析，相关数据统计分析结果如表 所示。从表 3-10 的结果可知，暴雨其可能与特定的环境条件紧密相关。当气温超过 8°C ，温暖的温度条件有助于大气中的水汽保持活跃状态，为中高层大气的对流活动提供了能量基础。发生暴雨的区域海拔均值达到 1084 米，地处中海拔的区域

往往由于地形抬升作用，能够促使气流上升，进一步增强水汽的凝结和降水的形成，为暴雨的形成提供了有利的动力抬升作用。

表 3-10 特大暴雨事件中各变量的影响				
变量	图片	最小值	中位数	最大值
Temperature		8.726	19.815	26.073
Elevation		37.51	1084.11	2444
Aspect		150.5	182.1	200.2
Hillshade		160.9	176.9	180.6
Slope		0	10.521	15.737
cropland		0	0.009	0.794
forest		0.021	0.797	0.993
grass		0	0.068	0.662
shrub		0	0.033	0.362

耕地、湿地和草地作为自然生态系统的重要组成部分，在水分循环中扮演着关键角色，但它们通常并不是暴雨发生的主要区域。这些区域往往由于植被覆盖类型、土壤湿度以及地表粗糙度等因素的影响，对气流的扰动相对较小，不利于形成强烈的气流上升和大规模的水汽凝结。

发生暴雨区域的林地利用率是 0.797，可能是由于林地茂密的植被覆盖、丰富的生物多样性以及复杂的地形结构，往往成为暴雨频发的区域。林地的树木通过蒸腾作用释放大量

水汽到大气中，为暴雨提供了充足的水源。

3.6 基于联合均值与方差模型的地形—气候分析

3.6.1 联合均值与方差模型

联合均值与方差模型是一种能对均值参数建模，同时又能对方差参数建模的模型。与单纯的均值回归模型相比，这种模型的适应能力更强，它同时可以涵盖和阐述众多的实际问题。尤其是在关注方差或者振动的领域。首先，该模型对方差很重视，只有对方差重视起来，才能更好地观察数据的变化规律。其次，对方差的影响因素进行进一步的研究，从而高效地控制方差，那么就需要建立关于方差的参数模型。联合均值与方差模型的实际背景主要来自于产品的品质改良测验。其目的就是，不仅要提高产品的品质，而且还要表现在顾客的满意度上，同时在使用过程中能够给顾客和社会带来较少的损失。换句话说，就是使期望达到所要求的范围，同时方差尽可能的小。这便引出了均值和方差同时建立模型的问题。目的就是用建立的模型来选择使振动达到最小而均值达到所要求的范围的变量。

以上简略介绍了联合均值与方差的优点以及应用。下面介绍一个相关模型首先，介绍一下常见的正态线性模型如下：

$$\begin{cases} y_i = x_i^T \beta + \varepsilon_i, \\ \varepsilon_i \sim N(0, \sigma^2), \\ i = 1, 2, \dots, n. \end{cases} \quad (3-1)$$

其中， $x_i = (x_{i1}, \dots, x_{ip})^T$ 是 p 维的自变量，也就是解释变量， y_i 表示因变量，也就是响应变量， $\beta = (\beta_1, \dots, \beta_p)^T$ 是 p 维位置回归参数， T 是转置。

由于线性回归模型的形式比较简单，估计起来较为方便。但是在实际问题中会存在大量异方差的数据，所以这种方差齐性的假设并不符合实际，所以要在 (1.1) 的基础上对方差进行建模。下面就介绍一下，联合均值与方差的模型，如下：

$$\begin{cases} y_i \sim N(\mu_i, \sigma_i^2), \\ \mu_i = x_i^T \beta, \\ \log \sigma_i^2 = z_i^T \gamma, \\ i = 1, 2, \dots, n. \end{cases} \quad (3-2)$$

其中， $x_i = (x_{i1}, \dots, x_{ip})^T$ 和 $z = (z_{i1}, \dots, z_{iq})^T$ 是自变量，也称解释变量， y_i 是相应的自，也就是响应变量， $\beta = (\beta_1, \dots, \beta_p)^T$ 是 $p \times 1$ 的均值模型的未知参数向量， $\gamma = (\gamma_1, \dots, \gamma_q)^T$ 是 $q \times 1$ 的方差模型的未知参数向量。当 $\sigma_i^2 = \sigma^2 (i = 1, 2, \dots, n)$ 时，该模型为正态线性回归模型。

3.6.2 模型建立与求解

对地形—气候数据建立联合均值和方差模型，得到的模型结果如表 3-11 所示。一方面从均值模型分析可知，经度、温度、坡度、耕地和林地利用率对极端天气性形成有正向影响，纬度、海拔、坡向、山影、草地、灌木丛和湿地的利用率则产生负向影响。另一方面从方差模型分析可知，纬度、海拔、坡向、山影、灌木丛和湿地的利用率对极端天气性形成有正向影响，经度、坡度、耕地、林地和草地的利用率对极端天气的形成则产生负向影响。均值模型正向影响越大，方差模型负向影响越大，综合均值和方差模型的结果，结论一致，即纬度、气温和土地类型利用率对极端天气形成有较大的影响。

表 3-11 联合均值与方差模型的结果表

模型	变量	Estimate	趋势	Std. Error	t value	Pr(> t)
均值	(Intercept)	34.531		9.621	3.589	0.0003
	Longitude	0.082	↑	0.009	9.197	0.0000
	Latitude	-0.588	↓	0.021	-28.231	0.0000
	Temperature	0.171	↑	0.007	26.049	0.0000
	elevation	-0.001	↓	0.000	-9.480	0.0000
	Aspect	-0.010	↓	0.003	-3.204	0.0014
	hillshade	-0.063	↓	0.052	-1.198	0.2310
	Slope	0.058	↑	0.033	1.763	0.0780
	cropland	14.368	↑	1.237	11.611	0.0000
	forest	14.860	↑	1.027	14.464	0.0000
	grass	-2.265	↓	0.888	-2.550	0.0108
	shrub	-5.452	↓	0.905	-6.027	0.0000
	wetland	-7.283	↓	1.493	-4.878	0.0000
方差	(Intercept)	21.111		0.893	23.645	0.0000
	Longitude	0.005	↓	0.001	3.830	0.0001
	Latitude	-0.074	↑	0.002	-47.574	0.0000
	elevation	-0.001	↑	0.000	-51.725	0.0000
	Aspect	-0.002	↑	0.001	-3.606	0.0003
	hillshade	-0.078	↑	0.005	-16.938	0.0000
	Slope	0.078	↓	0.003	22.515	0.0000
	cropland	3.137	↓	0.235	13.363	0.0000
	forest	3.101	↓	0.233	13.317	0.0000
	grass	1.057	↓	0.232	4.554	0.0000
	shrub	-0.388	↑	0.237	-1.639	0.1013
	wetland	-2.333	↑	0.374	-6.238	0.0000

3.6.3 模型检验

为了验证模型是否能够合适地描述数据的特征，对建立的联合均值和方差模型进行检验，得到如图 3-13 所示的模型检验图。其中左上为残差图，右上为拟合 QQ 图，左下为标准差图，左下为尺度—位置图，右下为残差与杠杆值图。




图 3-13 模型检验图

3.7 基于决策树和 MCP 变量选择的地形—气候分析

3.7.1 决策树简介

1966 年 Hunt、Stone 和 Marin 提出了一种以大量数据为基础的归纳学习法被称为决策树算法，为数据挖掘技术中一种十分重要的分类回归方法。本节使用决策树回归模型作为一个非线性土壤化学性质预测模型。决策树回归主要指 CART(classification and regression)算法，是在已知各种情况发生概率的基础上，通过构成决策树来求取净现值的期望值大于等于零的概率。内部节点特征的取值为“是”和“否”，为二叉树结构。

本质就是将特征空间划分成若干个单元，每一个划分单元有一个特定的输出。划分的边界是平行于坐标轴的。对于测试数据，只要按照特征将其归到某个单元，便得到对应的输出值。

3.7.2 MCP 惩罚回归模型

当惩罚函数为如下定义时：

$$p_{\lambda}(|\beta_j|, \gamma) = [\lambda |\beta_j| - \beta_j^2 / (2\gamma)] I(|\beta_j| < \gamma\lambda) + \gamma\lambda^2 / 2 I(|\beta_j| \geq \gamma\lambda), \quad (3-3)$$

称为 MCP。根据 Zhang 在研究中推荐 $\gamma = 3$ 。针对 MCP 方法，本文中我们也采用 3 这个值进行模拟。

$$\beta_j^{(t+1)} = \begin{cases} \frac{F(t_j, n\lambda)}{h_j - 1/\gamma}, & |t_j| \leq \lambda\gamma h_j \\ \frac{t_j}{h_j}, & |t_j| > \lambda\gamma h_j \end{cases}. \quad (3-4)$$

3.7.3 决策树求解和讨论

对地形—气候数据建立决策树模型，结果如图 3-14 所示。分析可知经度、气温、纬度和坡度对极端天气形成有较大的影响，其中经度 ≥ 97.2 是划分暴雨和大暴雨的第一个分界点，其次是气温 < 20.6 、经度 < 109 和坡度 $\geq 0.112^\circ$ ，总结模型结果可知，大坡度地形区域的南部地区在温和气候中，若发生大降水量现象，有较高的概率出现极端天气。




图 3-14 决策树图

随后，基于决策树模型又建立了暴雨以及上雨量等级的极端天气的条件决策树模型，模型结果如图 3-15 所示。在中北部地区发生大降水量现象，发生特大暴雨事件的概率大于暴雨和大暴雨现象。然而，在南部地区总体上相比中北部地区，具有更高的概率发生极端天气事件，其中低海拔地区发生暴雨、大暴雨和特大暴雨事件的概率相差不大，高海拔地区则更易发生暴雨事件，发生大暴雨和特大暴雨事件的概率很低。




图 3-15 条件决策树图

3.7.4 MCP 变量选择求解和讨论

对决策树模型绘制了变量选择路径图，如图 3-16 所示。由此可知，随着 λ （正则化参数）的增加，变量选择的路径越来越少，说明此模型倾向于选择更少的特征，以减少惩罚项的影响，即影响较大的因素较少。




图 3-16 变量选择路径图

通过分析如图 3-17 所示的交叉验证的变量选择图可知，随着 λ 的增加，模型选择出来的变量个数越少，在 $\log(\lambda) = -2$ 处选择的变量个数可以达到模型最优。




图 3-17 交叉验证的变量选择图

表 3-12 模型结果表

变量	系数	变量	系数
Longitude	-0.23	cropland	14.43
Latitude	-0.6	forest	25.11
Temperature	0.59	shrub	-9.3
hillshade	-1.3	wetland	5.72
Slope	0.88		

最终的模型分析结果如表 3-12 所示。气温、坡度、耕地、林地和湿地的利用率对极端天气的形成均为正向影响，且正向影响较大是耕地、林地和湿地的利用率。经度、纬度、山影和灌木丛均为负向影响，且负向影响较大是山影和灌木丛的利用率。

从这些结果可以推断，土地利用和自然地形特征对极端天气的形成有显著影响。耕地、林地和湿地的开发利用率高，会加剧极端天气的形成，特别是由于它们可能改变局部温度、湿度和气流的模式。同时，地理特征如山影和灌木丛对极端天气的抑制作用较强，可能因为它们帮助减缓风速、保留水分或调节温度。因此，合理的土地利用和保护自然地形可能有助于减缓极端天气的频率和强度。

3.8 本章小结

本章通过对地形—气候对极端天气的影响和交互作用建模分析与预测，得到的结论如下：

1. 海拔、山影、坡度和坡向变量与雨量等级的相关关系均显著，海拔和坡度与雨量等级呈负相关，山影和坡向与雨量等级呈正相关，三者之间密切相关。

2. 耕地、林地、草地和灌木丛的土地利用率和灌木丛与雨量等级的相关关系均显著，草地和灌木丛与雨量等级呈负相关，而耕地和林地与雨量等级呈正相关。暴雨发生区域的林地利用率是 0.797，而暴雨发生区域的耕地、草地、湿地和灌木丛利用率低，认为它们通常并不是暴雨发生的主要区域。

3. 纬度与雨量等级呈负相关，经度、气温和降水量与雨量等级呈正相关；经度与纬度、气温和降水量的相关关系均显著，且均呈正相关。暴雨天气的形成与特定的环境条件紧密相关，暴雨天气的形成与温暖气温（超过 8℃）和地形抬升（海拔均值 1084 米）紧密相关，这些条件有利于水汽活跃和降水形成。

4. 中北部地区更易发生特大暴雨，南部地区发生极端天气概率更高。在低海拔地区发生各类暴雨事件概率相近；但在高海拔地区，暴雨较常见，而大暴雨和特大暴雨概率较低。

四、基于深度学习的中国境内受灾能力脆弱地区的长期预测

本章的具体解题思路见图 4-1。




图 4-1 问题三求解流程图

4.1 数据选取和整合

4.1.1 基于问题 2 地形—气候的聚类数据整合

在对问题 2 的分析中，发现降雨、地形和土地利用都对暴雨天气有不同程度的影响。在本文研究中发现，极端天气往往伴随者高温和降雨，且和经纬度有明显的关系。因此我们在本章中选择分别选择经度、纬度和降水数据以及经度、纬度和温度数据进行建模。首先我们将第二问的数据进行整理，如表 4-1 所示。随后，再分别对经度、纬度和温度以及经度、纬度和降水建立高斯混合聚类模型。

表 4-1 聚类数据的聚合表

No	Longitude	Latitude	rain	Longitude	Latitude	气温
1	122.5	53.8	0.577	122.5	53.8	-3.096
2	123.0	53.8	0.568	123.0	53.8	-3.209

No	Longitude	Latitude	rain	Longitude	Latitude	气温
3	123.5	53.8	0.563	123.5	53.8	-2.971
4	120.5	53.3	0.869	120.5	53.3	-3.454
5	110.5	19.3	5.240	110.5	19.3	25.170
...	...	...	...	...	...	...
4096	110.0	18.8	6.122	110.0	18.8	23.488
4097	110.5	18.8	3.631	110.5	18.8	24.839
4098	109.0	18.3	2.029	109.0	18.3	24.323
4099	109.5	18.3	4.303	109.5	18.3	23.978
4100	110.0	18.3	0.894	110.0	18.3	24.656

4.1.2 基于经纬度的空间数据整合

在实际生活中由工具故障、系统问题等都会导致数据存在缺失，忽略数据缺失情况直接进行数据挖掘，会导致不正确甚至是错误的结论。因此，了解数据的缺失形式和缺失机制是非常重要的，所以我们需要对数据进行预处理，对上述整理后的数据表格（表 4-2）的缺失值进行判断和处理。




图 4-2 数据处理前（上）后（下）的缺失值识别图

本文使用 R 语言 VIM 包中的 `aggr()` 函数对收集的数据做缺失值分布的识别，得到缺失直方图（如图 4-2 左图）和变量的缺失分布图（如图 4-2 右图），其中蓝色表示未缺失，红色表示缺失。图 4-2 显示本文收集的数据中存在缺失值，将缺失值删除后，截取部分数据如表 4-2 所示。

表 4-2 经纬度空间数据

No	Longitude	Latitude	grass	...	hillshade	Slope	风险水平
1	120	53	0.98	...	180.19	2.67	低风险区
2	121	53	0.68	...	179.66	2.74	低风险区
3	121	53	0.52	...	180.67	2.45	低风险区
4	122	53	0.35	...	179.5	2.58	低风险区
5	122	53	0.3	...	180.04	2.2	低风险区
...	...	...	...	...	...	...	...
4096	110	19	0.19	...	179.8	0.01	重灾区
4097	110	19	0.58	...	179.58	0.1	低风险区
4098	109	18	0.7	...	180.78	2.13	低风险区
4099	109	18	0.47	...	178.49	2.3	低风险区
4100	110	18	0.77	...	180.48	2.34	低风险区

4.2 基于空间地形—气候聚类研究

4.2.1 高斯混合聚类简介

本文将利用高斯混合模型进行图像分割，高斯混合模型与聚类一样属于无监督学习统计模型，用以拟合数据的分布特征，从而完成图像分割。高斯混合模型的基本思想是利用多个高斯分布函数去近似任意的概率分布，也即是高斯混合是由多个单高斯密度分布组成。高斯混合将待聚类的数据点看成是分布的采样点，通过采样点利用类似极大似然估计的方法估计高斯分布的参数，求出参数（用 EM 算法求解）即得出了数据点对分类的隶属函数，高斯混合模型的概率密度函数如下：

$$p_M(x)=\sum_{k=1}^Kp(k)p(x|k)=\sum_{k=1}^K\alpha_kp(x|\mu_k,\Sigma_k)\tag{4-1}$$

其中， K 为模型的个数， α_k 为属于第 k 个高斯的概率， $p(x|k)$ 为第 k 个高斯的概率密度，其均值向量为 μ_k ， Σ_k 为协方差矩阵。

据分为 9 类是合适的；从中我们可以看出，基于高斯混合模型的聚类将空间降水分类成了 9 个类别。在节省成本且残差值最小的条件下，9 个类别将原数据点最可能地划分开，从而达到数据点特征相似的，聚为一类，数据点特征差异较大的，使其进入不同的类别。




图 4-5 基于高斯混合模型的空间降水数据分类图

表 4-3 基于空间降水数据的中心数据

类别	Longitude	Latitude	Rain	灾害类别
1	91.728	33.405	1.100	低风险区
2	93.708	40.019	0.211	低风险区
3	114.868	31.311	2.454	低风险区
4	124.141	46.915	1.404	低风险区
5	111.805	38.531	1.314	低风险区
6	114.949	25.963	5.335	高风险区
7	85.513	44.572	0.733	低风险区
8	80.993	38.162	0.256	低风险区
9	105.093	28.581	3.134	重灾区

计算出每类的聚类中心值，根据前两问的结论将降水量最多的两个地区分别标注为高风险区（类别 6）、重灾区（类别 9）以及低风险区（剩余类别）。并将其标注在原始数据中，最后对其进行可视化展示。

4.2.3 基于空间气温聚类模型结果

本小节运用 R 语言中常用的聚类分析空间气温数据进行聚类分析。mclust 能够基于高斯有限混合模型进行聚类，分类以及密度估计(Density estimation)。

图 4-6 为不同分组的 BIC 曲线图，它描述了基于贝叶斯信息判别标准评估不同模型在不同分组下的可能性；从图中可以看出数据选择 9 类是在 BIC 的下最优的。将数据分为 9

组，BIC 值区域平缓，因此降水数据分为 9 个组别是合适的。




图 4-6 空间气温数据不同分组的 BIC 曲线图

图 4-7 为空间气温数据基于有限高斯混合模型的分类图，它直观地向我们展示了将数据分为 9 类是合适的；从图中我们可以看出，基于高斯混合模型的聚类将空间气温分类成了 9 个类别。在节省成本且残差值最小的条件下，9 个类别将原数据点最可能地划分开，从而达到数据点特征相似的，聚为一类，数据点特征差异较大的，使其进入不同的类别。




图 4-7 空间气温数据数据基于高斯混合模型的分类图

表 4-4 基于空间气温数据的中心数据

类别	Longitude	Latitude	气温	灾害类别
1	97.45	32.86	-0.57	低风险区
2	88.35	40.35	0.54	低风险区
3	85.66	41.89	9.91	低风险区
4	108.05	26.73	16.76	重灾区
5	104.39	39.23	9.07	低风险区
6	121.12	44.05	4.89	低风险区
7	115.47	32.64	16.21	高风险区
8	85.37	32.84	-3.76	低风险区
9	122.91	50.90	-2.11	低风险区

计算每类的聚类中心值，根据前两问的结论将气温最高的两个地区分别标注为高风险区（类别 7）、重灾区（类别 4）以及低风险区（剩余类别）。随后，将其标注在原始数据中，并对其进行可视化展示。

4.3 基于 XGBoost 模型的影响作用分析

4.3.1 XGboost 模型简介

XGBoost 是一个优化的分布式梯度增强库，旨在实现高效，灵活和便携。它在 Gradient Boosting 框架下实现机器学习算法。XGBoost 提供并行树提升（也称为 GBDT，GBM），可以快速准确地解决许多数据科学问题。肖寅东^[35]等基于 XGBoost 决策树模型提出了一种优化模拟集成电路测试参数数目的方法，讨论了故障数目、特征重要性和 Shapley 值 3 种评估测试参数间表征能力的指标，表明故障数目是一种优秀的评估指标。黄锐等^[36]将生产设备工况与环保设备工况结合产生环保工况，利用 XGBoost 模型进行环保工况识别，有效地监测企业的环保工况的问题。白广栋等^[37]通过对比发现 XGBoost 模型对空铁联运中转城市进行推荐的结果最优，首次证明出发与到达的客观属性信息对旅客选择中转城市有重要影响。

其次，XGBoost 是一种基于梯度提升树实现的集成学习模型，由于其对目标函数进行二阶泰勒展开，保留了更多有效信息，在分类与回归问题上具有较高的精度。XGBoost 的集成模型如公式（4-2）所示：

$$\hat{y}_i = \sum_{k=1}^K f_k(x_i), f_k(x_i) \in R, \quad (4-2)$$

式中， x_i 是输入的第 i 个特征向量； $\hat{y}_i$ 表示预测值； K 表示回归树的数量； R 是回归树的集合空间； f_k 表示集合 R 上的一个函数，用来表示学习器的输出。

累加迭代过程结果，得到 XGBoost 的目标函数：

$$X_{obj} = \sum_{i=1}^n l(y_i, \hat{y}_i) + \sum_{k=1}^K \Omega(f_k), \quad (4-3)$$

式中， $l(y_i, \hat{y}_i)$ 是损失函数项，计算预测值和真实值之间的误差； $\Omega(f_k)$ 是正则化项。

进行泰勒展开和求导，得到目标函数：

$$X_{obj} = -\frac{1}{2} \sum_{j=1}^T \frac{G_j^2}{H_j + \lambda} + \gamma T, \quad (4-4)$$

式中， γ 为惩罚函数系数； T 为 k 次迭代后树叶中叶子节点个数； λ 为正则化惩罚项系数；

G_j 表示当前叶子结点所有一阶导数和； H_j 表示当前样本所有二阶导数和。

4.3.2 保护因素和危险因素分析

XGBoost 是一种强大的梯度提升树算法，可以用于分类、回归和排序等任务，本文将 SHAP 方法应用于 XGBoost 模型中，来解释模型输出结果的原因，并发现重要的预测特征。




图 4-8 PCL 性质瀑布图

瀑布图可以解释单个预测，瀑布图从底部的模型输出的预期值开始，每一行显示每个特征的是正（黄色）或负（红色）贡献，即如何将值从数据集上的模型预期输出值推动到模型预测的输出值。Class_1 指无雨和暴雨以下雨量等级（小雨、中雨和大雨）的天气，Class_2 指暴雨及以上雨量等级（大暴雨和特大暴雨）的天气，通过分析图 4-8 和图 4-9 可知，Class_1 数据的基准线为 2.77，Class_2 数据的基准线为 -1.77，气温、草地的利用率、坡度、耕地的利用率、山影和灌木丛的利用率为保护因素（即降低极端天气发生的概率的

因素), 林地的利用率、坡向、湿地的利用率和海拔为危险因素 (即增加极端天气发生的概率的因素), 其中气温为保护因素中对预测值的贡献率最大的因素, 林地的利用率为危险因素中对预测值的贡献率最大的因素, 得到的贡献程度排序为气温>草地的利用率>林地的利用率>坡度>耕地的利用率>山影>坡向>湿地的利用率>灌木丛的利用率>海拔。




图 4-9 PCL 得分瀑布图

通过上述分析可知, 保护因素分别为气温—凉爽、草地利用率—中度利用、坡度—缓坡、耕地利用率—未利用、山影—中山影和灌木丛的利用率—未利用, 其中 QIWEN=3 即气温等级为凉爽的气候发生极端天气事件的概率较低, 对极端天气形成的影响大小为 0.903; CAODI=3 即草地的利用率为中度利用的土地类型发生极端天气事件的概率较低; PODU=2 即高程图中的坡度为缓坡、GENGDI=1 即耕地的利用率为未利用、SHANYING=2 即高程图中的山影高度为中山影和 GUANMU=1 即灌木丛的利用率为未利用的地形区域发生极端天气事件的概率相对较低。从以上结果可以得出, 气温、地形和土地利用方式是影响极端天气事件发生概率的重要因素, 这些因素通过降低极端天气事件的概率, 显示出对极端天气形成的显著抑制作用。他们的结合为减缓和预防极端天气事件提供了重要的自然防御机制, 表明在这些条件下的地区可能更具有气候韧性。由此说明了在城市规划、土地管理和环境保护中考虑这些保护因素的重要性, 以增强地区对极端天气的抵御能力, 即在规划土地利用和生态保护时, 合理的草地和灌木丛管理, 减少耕地开发, 以及维护特定的地形特征, 都可能在缓解极端天气方面发挥关键作用。

通过上述分析可知, 危险因素分别为林地利用率—低利用、坡向—南、湿地利用率—

未利用和海拔—高海拔，其中 LINDI=2 即林地利用率为低利用的土地类型发生极端天气事件的概率较高，对极端天气形成的影响大小为 0.074；POXIANG=5 即高程图中的坡向方向为南、SHIDI=1 即湿地的利用率为未利用的区域、HAIBA=3 即海拔高度为高海拔的地形区域发生极端天气事件的概率相对较高。从以上结果可以得出，地形、土地利用和地理特征对极端天气事件的发生具有重要影响，低利用率的林地、朝南的坡向、未利用的湿地以及高海拔这些区域由于特殊的地理或利用特征，极易受到极端气候条件的影响，可能需要加强管理与防护措施来减轻这些地区的风险。这些危险因素可能通过改变地表的能量平衡、影响水分循环或改变地形对气候的局部影响，从而增加了极端天气事件的可能性。因此，这些地区的规划和管理需要特别注意，以减少极端天气事件的潜在影响。由此说明了在这些特定条件下的地区采取适应性措施的重要性，如改进土地利用规划、加强生态保护和提高社区的气候韧性，以减轻极端天气带来的负面影响。

4.3.3 因素间的交互作用分析




图 4-10 变量重要性图

由图 4-10 可知，数据中变量的重要性程度排序为气温>海拔>草地的利用率>林地的利用率>耕地的利用率>坡向>灌木丛的利用率>坡度>湿地的利用率>山影，气温的特征值最高，

对模型预测的输出影响最大，其次是海拔和对是否发生极端天气事件的影响较大。基于变量的重要性程度筛选出排名靠前的 9 个变量，根据因变量极端天气事件，分别研究两种情况下各变量间的交互影响，如图 4-11 和图 4-12 所示。




图 4-11 无雨和暴雨以下雨量等级的多变量依赖图

通过分析图 4-11 知，随着气温的增加，对无雨和暴雨以下雨量等级（Class_1）的影响减少到低峰后再增长，添加海拔作为第二特征之后，低值的海拔高度会导致原本较高的 Class_1 影响上升，故表现为出现无雨和暴雨以下雨量等级的天气的概率可能随着海拔和气温的适度降低而增加；随着海拔高度的增加，对 Class_1 的影响逐渐增加，添加草地的利用率作为第二特征之后，草地的利用率对低海拔地区的影响不大，即不会导致对 Class_1 影响上升或降低，而对高海拔地区，高草地利用率会增大对 Class_1 的影响，故表现出现对无雨和暴雨以下的雨量等级的天气的概率可能随着高海拔地区的草地利用率的增加而适度增加；随着草地利用率的增加，对 Class_1 的影响逐渐增加，添加气温作为第二特征之后，发现起对草地利用率的影响不大，即高温天气不会增强或降低草地利用率对 Class_1 的影响，故表现为出现无雨和暴雨以下的雨量等级的天气的概率可能随着草地利用率的增加而增加；随着林地利用率的增加，对 Class_1 的影响缓慢降低，添加海拔作为第二特征之后，发现高海拔会导致低林地利用率地区对 Class_1 的影响增强，故表现为发生无雨和暴

雨以下的雨量等级的天气事件的概率可能随着低林地利用率地区的海拔高度的增加而适度增强；随着耕地利用率的增加，对 Class_1 的影响在一定范围内波动，添加林地利用率作为第二特征之后，低林地利用率会对原本较低的 Class_1 的影响增强，故表现为发生无雨和暴雨以下的雨量等级的天气事件的概率可能随着耕地和林地利用率的降低而增加；随着高程图中的坡向角度的增加，仅在小范围对 Class_1 有影响，添加气温作为第二特征之后，在北坡向地区严寒和炎热天气都会增加影响，故表现为严寒和炎热天气会增强北坡向地区发生无雨和暴雨以下的雨量等级的天气发生的概率；随着灌木丛利用率的增加，对 Class_1 的影响显著增加，添加高程图中的山影作为第二特征之后，仅高山影会产生影响，故表现为在高山影地区增强灌木丛利用率会增强无雨和暴雨以下的雨量等级的天气发生的概率；高气温会增强对高坡度地区对 Class_1 的影响，且林地利用率仅对低湿地利用率地区的极端天气事件产生影响。




图 4-12 暴雨及以上雨量等级的多变量依赖图

通过分析图 4-12 知，随着气温的增加，对暴雨及以上雨量等级 (Class_2) 的影响增长，添加海拔作为第二特征之后，高海拔会导致原本较大的 Class_2 影响降低，故表现为对暴雨及以上雨量等级的天气的发生概率可能随着低气温地区的海拔增加而增强；随着海拔高度的增加，对 Class_2 的影响先降低再增强，添加草地的利用率作为第二特征之后，草地

的利用率和低海拔地区的联合影响会导致对 Class_2 影响降低，而对高海拔地区，高草地利用率会增大对 Class_2 的影响，故表现为出现暴雨及以上雨量等级的天气的概率可能随着高海拔地区的草地利用率的增加而降低；随着草地利用率的增加，对 Class_2 的影响逐渐增加，添加气温作为第二特征之后，高温天气会增强草地利用率对 Class_2 的影响，故表现为出现暴雨及以上雨量等级的天气的概率可能随着草地地区的气温增加而降低；随着林地利用率的增加，对 Class_2 的影响缓慢降低，添加海拔作为第二特征之后，发现高海拔会导致低林地利用率地区对 Class_2 的影响增强，故表现为出现暴雨及以上雨量等级的天气影响可能随着低林地利用率地区的海拔高度的增加而适度降低；随着耕地利用率的增加，对 Class_2 的影响在一定范围内波动，添加林地利用率作为第二特征之后，低林地利用率会对原本较低的 Class_2 的影响增强，故表现为发生暴雨及以上雨量等级的天气事件概率可能随着耕地和林地利用率的降低而降低；随着高程图中的坡向角度的增加，仅在小范围对 Class_2 有影响，添加气温作为第二特征之后，在东南坡向地区严寒和炎热天气都会增加影响，故表现为严寒和炎热天气会增强东南坡度地区发生暴雨及以上雨量等级的天气发生的概率；随着灌木丛利用率的增加，对 Class_2 的影响显著增加，添加高程图中的山影作为第二特征之后，仅高山影会产生影响，故表现为在高山影地区增强灌木丛利用率会降低暴雨及以上雨量等级的天气发生的概率；高气温会增强对低坡度地区对 Class_2 的影响，且林地利用率仅对低湿地利用率地区的极端天气事件产生影响。

4.4 基于经纬度数据的预测建模研究

4.4.1 支持向量机简介

本节选用支持向量机回归（SVR）作为第四个非线性土壤化学性质预测模型^[38]，在解决非线性的任务中 SVR 表现出了很好的效果。

支持向量机（SVM）是一种经典的机器学习算法，在小样本数据集的场景中有较为广泛的应用。支持向量机回归（SVR），顾名思义是利用支持向量机来进行回归预测，而支持向量机是一种按监督学习方式对数据进行二元分类的广义线性分类器，其决策边界是对学习样本求解的最大边距超平面^[7]。




图 4-13 支持向量机原理图

SVR 是 SVM 对回归问题的一种运用，主要是升维之后，在高维空间中构造线性决策函数来实现线性回归。SVR 模型的模型函数是非线性高斯核，用下式表示：

$$\phi_{\gamma}(x, \ell) = \exp(-\gamma \|x - \ell\|^2) \quad (4-5)$$

这是一个从 0（离地标差的非常远）到 1（跟地标一样）变化的钟形函数。

4.4.2 随机森林概述

随机森林(Random Forest)属于机器学习中的集成学习算法，它通过组合多个决策树，引入随机性和投票策略来提高模型的性能和泛化能力，对于分类和回归问题都有很好的适用性。随机森林采用 Bagging 思想，它通过多次有放回地抽样数据集来生成不同的训练集，然后每个训练集训练一个决策树，从而降低模型的方差，减少过拟合。随机森林引入了两种随机性：一是针对数据，每个决策树的训练数据是通过有放回抽样(Bootstrap 抽样)从原始数据中抽取的，这样每个决策树都有略微不同的数据集。二是针对特征，在每个节点的分裂时，只考虑特征集的一个随机子集而非所有特征，从而降低模型的方差，提高泛化能力。

4.4.3 精度参数比较

关于 AUC 值，在机器学习领域，AUC (Area under the Curve of ROC) 值是用来评价二分类模型的训练的效果,为 ROC 曲线所覆盖区域的面积，AUC 越大，分类器的分类效果越好。

当 $AUC = 1$ 时，分类器是完美分类器，使用这个预测模型时，无论设置什么阈值都可以得出完美预测；

当 $0.5 < AUC < 1$ 时，优于随机猜测，预测模型的阈值妥善设定，则具有预测价值；

当 $AUC = 0.5$ 时，同随机猜测一样，预测模型没有价值；

当 $AUC < 0.5$ 时，不如随机猜测，但如果总是反预测，那么优于随机猜测。

关于混淆矩阵，两类分类问题的原始类为 **positive**、**negative**，分类后的类别为 p' 、 n' 。排列组合后得到四种结果，如表 4-5 所示。

表 4-5 混淆矩阵表

		真实值		总数
		p	n	
预测输出	p	真阳性 (TP)	伪阳性 (FP)	P
	n	伪阴性 (FN)	真阴性 (TN)	N
总数		P	N	P+N

因此得到四个指标：真阳性、伪阳性、伪阴性、真阴性，则伪阳性率（TPR）：

$$TRP = \frac{TP}{(TP + FN)}, \quad (4-6)$$

真阳性率（FPR）：

$$FRP = \frac{FP}{(FP + TN)}. \quad (4-7)$$

4.4.4 模型结果比较

图 4-14 显示了两种不同方法的 ROC 曲线。其中，四种方法分别是 SVM、随机森林。纵轴表示灵敏度(sensitivity)，横轴表示特异度(Specificity)，从中可以得到随机森林的 ROC 曲线与横轴（特异度）围成的面积是最大的，而 ROC 曲线与横轴围成的面积越大，说明该方法预测的准确度就越高。因此，在两种不同方法中，随机森林方法预测的效果最好。




图 4-14 不同方法的 ROC 曲线

表 4-6 显示了两种模型的精度以及它们相应的 AUC 值，所选取的两种预测模型的预测精度都达到了 85%以上，说明在选择两种预测方法中我们进行了仔细地思考。其中，两种预测方法中，随机森林模型的预测精度是最高的，支持向量机的预测精度相对最低。在 AUC 值中，随机森林模型也带到了最高，由此，我们可以认为选择**随机森林模型**进行预测降水的效果最佳。

表 4-6 四种模型的预测输出结果对比表

SVM		低风险区	重灾区	总数	精度	AUC
预测 输出	低风险区	4059	27	4086	0.993	优于随机猜测 (0.671)
	重灾区	0	14	14		
总数		4059	41	4100		
随机森林		低风险区	重灾区	总数	精度	AUC
预测 输出	低风险区	4058	0	4058	0.999	完美分类器 (0.999)
	重灾区	1	41	42		
总数		4059	41	4100		

4.5 灾害能力预测结果可视化

4.5.1 基于聚类模型的灾害能力预测可视化

中国容易发生暴雨的地区分布广泛，但主要集中在东南沿海和内陆的部分地区。这些地区由于地理位置、气候条件和地形地貌等因素的共同作用，使得暴雨天气频繁发生。




图 4-15 2025-2035 年间中国境内应对暴雨灾害能力的区域分布图

通过图 4-15 可以看出，东南沿海（福州、广州、海口和浙江东南部等）地区附近在 2025-2035 年可能会成为暴雨重灾区，这些地区位于东南沿海，受季风和台风影响显著，每年夏秋季节暴雨频繁。特别是在台风登陆前后，往往伴随大范围的暴雨甚至特大暴雨；长江中下游（合肥、武汉、长沙和南昌等）地区附近在 2025-2035 年可能会成为暴雨重灾区，这些地区在梅雨季节，常常出现持续性暴雨，历时长、面积广、暴雨量也大；西南（成都、昆明和贵阳）地区附近在 2025-2035 年可能会成为暴雨高风险地区，地形复杂，夏季风活跃，暴雨天气频发。特别是四川盆地边缘的山区，由于地形抬升作用，暴雨强度往往更大。

气温是影响暴雨发生的重要因素之一，高温通过增加饱和水汽量、加速水循环和增强对流活动等方式，为暴雨的形成提供了有利条件。而热带和亚热带地区、沿海城市以及特定地形区域则是由于温度影响容易发生暴雨的典型地区。随着全球气候变暖的加剧，这些地区暴雨的发生频率和强度可能会进一步增加，对人类生活和社会经济产生更大的影响。因此，加强气候变化研究和应对极端天气事件的能力显得尤为重要。

从第三章的内容可以得知，暴雨的发生与气温之间存在着密切的关联，气温是一个关键的影响因素，对暴雨的形成起着重要作用，当温度高于 8°C ，它通过增加饱和水汽量、

加速水循环和增强对流活动等方式，为暴雨的形成提供了有利条件。




图 4-16 2025-2035 年间中国境内应对高温灾害能力的区域分布图

通过图 4-16 可以看出，热带和亚热带地区（南宁、广州、海口等）地区附近在 2025-2035 年可能会成为暴雨重灾区。这些地区靠近赤道，太阳辐射强烈，气温普遍较高，为暴雨的形成提供了充足的水汽条件和热力支持，夏季时受季风槽和台风影响，加之高温高湿的气候条件，暴雨天气频发；沿海城市（杭州、福州、香港、澳门和海口）附近在 2025-2035 年可能会成为暴雨重灾区，由于海洋性气候的影响，夏季时随着海洋暖湿气流的增强，气温上升，同时季风带来的大量水汽也为暴雨的发生提供了条件；一些特定地形区域（成都、重庆和昆明等）地区是暴雨高风险地区，由于地形闭塞，热量不易散发，容易形成高温天气。同时，周边地区的水汽在这些地形区域聚集，当遇到冷空气或上升气流时，容易形成暴雨。

4.5.2 基于预测模型的灾害能力预测可视化




图 4-17 2025-2035 年间中国境内受灾能力的区域分布图

通过图 4-17 可以看出，大珠江三角洲（广州、澳门和香港）地区附近在 2025-2035 年可能会成为暴雨重灾区，位于中国南部沿海地区，会受到海洋性气候的显著影响，同时大珠江三角地区属于亚热带季风气候区，夏季炎热多雨，冬季温和湿润，这种气候特点使得该地区在夏季容易受到季风、台风等天气系统的影响，引发特大暴雨；西藏自治区和云南交界线附近在 2025-2035 年可能会成为暴雨重灾区，西藏自治区与云南交界线地区紧邻横断山脉，这一区域地形复杂，山脉纵横交错，河谷深切，为降水的形成提供了有利的地形条件；长江中下游（长沙、武汉和南昌）附近在 2025-2035 年可能会成为暴雨重灾区，由于位于亚热带季风区，受夏季风影响显著，且集中在夏季，多暴雨。这是该地区易发大暴雨的根本原因之一；江西和福建交界线附近在 2025-2035 年可能会成为暴雨重灾区，江西与福建交界地区位于中国东南沿海，地势西北高、东南低，交界地带山川秀丽包括武夷山脉等高大山脉的阻隔，使得气流在上升过程中容易形成降雨。

4.6 本章小结

本章通过研究地形—气候数据在极端天气形成的影响作用，得到的结论如下：

1. 影响发生极端天气的九个因素按重要性排列为，气温影响最大，依次是海拔、草地的利用率、林地的利用率、耕地的利用率、坡向、灌木丛的利用率、坡度、湿地的利用率，山影对是否发生极端天气的影响最小。
2. 凉爽气候、中度利用的草地、缓坡、耕地未被利用、中山影以及灌木丛未被利用，这些因素均会导致该地区发生极端天气事件的概率相对较低；林地利用率低、坡向为南、

湿地未被利用、高海拔，这些因素均会导致该地区发生极端天气事件的概率相对较高，同时这些因素之间相互影响。

3. 通过降雨量和温度都能预测得出，东南沿海、长江中下游地区附近在 2025-2035 年可能成为暴雨重灾区，而且西南地区附近可能成为暴雨高风险地区。进一步通过缩小预测地区范围，大珠江三角洲、西藏自治区和云南交界线、长江中下游（长沙、武汉和南昌）附近在 2025-2035 年可能会成为暴雨重灾区。

五、中国土地利用变化的特征与结构研究

本章的具体解题思路见图 5-1。




图 5-1 问题四求解流程图

5.1 数据整合与可视化

本章整合了上文使用的地形—气候数据、中国大陆 1km 逐年历史人口空间分布公里网格数据集^{[13][14]}和中国大陆 1km 逐年历史 GDP 空间分布公里网格数据集^{[15][16][6][17][10]}，分别提取这些数据集中的人口和 GDP 数据，经过数据处理和整合之后，建立相关分析模型，研究中国土地利用变化的特征与结构。

5.1.1 数据整合

中国人口空间分布与三级阶梯地形、800mm 等降水线以及胡焕庸线之间密切相关，具体表现为人口分布随地形阶梯由东南向西北递减，与年降水量分布趋势一致，跟胡焕庸线的划分大致一样，形成东南密集、西北稀疏的总体格局。




图 5-2 “三级阶梯”和“秦岭—淮河线”的划分图




图 5-3 2015 年人口（左）和 GDP（右）的“胡焕庸线”空间分布图

基于上文用到的地形数据，按照“秦岭—淮河线”和“胡焕庸线”的区域划分，分别 将地形数据以南北部地区和东西部地区将数据进行整合，得到的数据如表 5-1 所示。由此 可知，南部地区整体海拔高于北部地区，而坡向、坡度和山影则相差不大，没有显著差异； 西部地区的坡向、坡度和山影虽与东部地区相比相差无几，但其海拔远高于东部地区，具 有非常显著的地形差异。以上结果表明，在中国的地理分布中，南部地区相对于北部地区 具有更高的平均海拔，这可能与南部地区的地形特征有关，如多山的地貌和复杂的地势。

尽管南部和北部地区在坡向、坡度和山影方面的差异不显著，但海拔高度的显著性差异可能对气候、生态以及人类活动产生重要影响。同样，西部地区与东部地区在坡向、坡度和山影方面的相似性表明，这些地形特征在东西方向上相对一致，然而西部地区的海拔显著高于东部地区，这可能与西部地区如青藏高原等高海拔地形有关。这种显著的地形差异对理解区域气候模式、水资源分布、生物多样性以及土地利用等方面具有重要意义。

表 5-1 中国地形数据整合表

地区	Elevation	Aspect	Slope	Hillshade
北部	1625.157102	173.8195796	2.256872839	179.4034361
南部	1836.429921	178.1386416	4.612066843	178.2521848
西部	2017.296147	174.6503506	3.109146824	179.118885
东部	271.4346088	178.5205172	3.02148428	178.4347267

5.1.2 人口空间分布可视化研究




图 5-4 1990 年人口空间分布图

通过图 5-4 可以看出，1990 年人口分布总体上大致呈现出东密西疏的特点。可能由于东部地区由于气候温暖湿润、地形平坦、经济发达等因素，吸引了大量人口聚集。而西部地区 1990 年当时自然条件相对恶劣、经济发展滞后，人口分布相对稀疏；随着人口数上限的增加，一些中心城市和大城市由于其经济实力、产业结构、就业机会和公共服务等方面

的优势，吸引了大量的人口流入。这导致了这些城市的人口和经济活动快速增长，城市规模迅速扩张。例如，京津冀、长三角、珠三角等地区的发展尤为显著。同时气候适宜农业生产的平原，也是人们选择安家的重要原因。




图 5-5 2015 年人口空间分布图

通过图 5-5 可得，2015 年人口分布总体上还呈现东密西疏的特征，东部沿海地区由于经济发达、就业机会多、基础设施完善等优势条件，吸引了大量人口流入。这些地区的人口密度相对较高，城市规模也较大。尽管西部地区也在积极发展经济和提高城镇化水平，但由于历史、地理、经济等多方面因素的影响，其人口聚集程度仍然低于东部沿海地区。

对比 1990 年和 2015 年人口空间分布，可以看出城镇化进程偏向“中心城市”增长，城市首位度偏低。中心城市和大城市凭借经济、产业、就业和公共服务优势，吸引了大量人口流入，导致这些城市人口和经济活动快速增长，规模迅速扩张，如京津冀、长三角、珠三角等地。

5.1.3 GDP 空间分布可视化研究




图 5-6 2000 年（左）和 2015 年（右）GDP 空间分布图

分析图 5-6 可知，中高等收入人口主要集中在沿海地区和平原地区，东部沿海地区，特别是珠三角、长三角等区域，拥有发达的制造业、服务业和高科技产业。这些产业的蓬勃发展不仅创造了大量的就业机会，也为高收入人群提供了广阔的舞台，中部平原地区拥有广阔的耕地和丰富的农业资源，是我国重要的粮食生产基地。

5.2 中国土地利用变化特征的准确性和有用性讨论

关于中国土地利用变化特征的讨论，本节主要通过独立样本 t 检验分别分析南北地区和东西部地区的差异性，来进行讨论。其中，独立样本 t 检验，又称成组 t 检验(two-sample group t -test)或两独立样本 t 检验(two independent-sample t -test)，医学研究中常用于完全随机设计两样本均数的比较，即将受试对象完全随机分配到两个不同处理组，研究者关心的是两样本均数所代表的两总体均数是否不等。此外，在观察性研究中，独立从两个总体中进行完全随机抽样，获得的两样本均数的比较，也可采用独立样本 t 检验。

使用独立样本 t 检验，需要满足六个条件：（1）观察变量为连续变量。（2）观察变量相互独立。（3）观察变量分为 2 组。（4）观察变量不存在显著的异常值。（5）各组观察变量为正态(或近似正态)分布。（6）两组观察变量的方差相等。若是未通过正态性检验，可选用独立样本 MannWhitney 检验。若是未通过方差齐性检验，可采用 Welch's T 检验。

5.2.1 中国地区的气候数据

(一) 南北地区

表 5-2 南北地区的气候差异性检验结果

变量	变量值	平均值	标准差	中位数值 差值	Welch's T 检验	平均值 差值	Cohen's d 值
Rain	北方	0.959	0.852	1.894	T=-7.112 P=0.000***	2.216	1.452
	南方	3.175	1.984				
Temp	北方	4.601	11.702	6.666	T=-3.8 P=0.000***	7.336	0.776
	南方	11.937	6.473				

注：***、**、*分别代表 1%、5%、10%的显著性水平

一方面，北方地区和南方地区在降水量上的均值分别为 0.959 和 3.175，由于方差齐性检验和正态性检验均未通过，故采用独立样本 Mann Whitney 检验和 Welch's T 检验，其 P 值为 0.000，结果显著，说明北方地区和南方地区在降水量上存在显著差异，且差异幅度（Cohen's d 值）为 1.452，差异幅度非常大。另一方面，北方地区和南方地区在气温上的均值分别为 4.601 和 11.937，其检验的 P 值为 0.000，结果显著，说明北方地区和南方地区在气温上存在显著差异，且差异幅度为 0.776，差异幅度中等。

(二) 东西地区

表 5-3 东西地区的气候差异性检验结果

变量	变量值	平均值	标准差	中位数值 差值	Welch's T 检验	平均值差 值	Cohen's d 值
Rain	西部	1.284	1.097	11.907	T=-7.857 P=0.000***	2.747	1.604
	东部	4.031	2.16				
Temp	西部	5.122	10.363	2.802	T=-6.631 P=0.000***	12.188	1.353
	东部	17.31	7.401				

一方面，西部地区和东部地区的气候数据由于方差齐性检验和正态性检验均未通过，故采用独立样本 Mann Whitney 检验和 Welch's T 检验，通过表 5-3 的结果可知，其降水量的检验 P 值为 0.000，结果显著，说明西部地区和东部地区在降水量上存在显著差异，且差异幅度为 1.604，差异幅度非常大。另一方面，西部地区和东部地区在气温检验的 P 值为 0.000，结果显著，说明西部地区和东部地区在气温上存在显著差异，且差异幅度为 1.353，差异幅度非常大。

5.2.2 中国地区的地形数据

(一) 南北地区

表 5-4 南北地区的地形差异性检验结果

变量	变量值	平均值	标准差	中位数值 差值	Welch's T 检验	平均值 差值	Cohen's d 值
cropland	南方	0.053	0.002	0.014	T=-27.999 P=0.000***	0.013	7.353
	北方	0.066	0.001				
forest	南方	0.091	0.017	0.035	T=8.882 P=0.000***	0.032	2.332
	北方	0.059	0.009				
grass	南方	0.157	0.009	0.1	T=-49.02 P=0.000***	0.097	12.873
	北方	0.254	0.006				
shrub	南方	0.047	0.006	0.037	T=-33.134 P=0.000***	0.036	8.702
	北方	0.083	0.002				
wetland	南方	0.003	0.001	0.009	T=-31.959 P=0.000***	0.009	8.393
	北方	0.012	0.001				




图 5-7 南北地区的土地类型利用率均值直方图

南方地区和北方地区的土地利用类型数据方差齐性检验和正态性检验均未通过，故采用独立样本 Mann Whitney 检验和 Welch's T 检验，通过表 5-4 的结果可知，南方地区和北方地区在耕地、林地、草地、灌木丛和湿地的利用率上均存在显著差异，且差异幅度非常大。

（二）东西地区

表 5-5 东西地区的地形差异性检验结果

变量	变量值	平均值	标准差	中位数值 差值	Welch's T 检验	平均值 差值	Cohen's d 值
grass	西部	0.259	0.008	0.002	T=96.766 P=0.000***	0.174	25.412
	东部	0.085	0.005				
cropland	西部	0.061	0.001	0.016	T=2.708 P=0.010**	0.001	0.711
	东部	0.06	0.002				
forest	西部	0.068	0.012	0.175	T=-4.72 P=0.000***	0.016	1.24
	东部	0.084	0.013				
shrub	西部	0.079	0.003	0.044	T=40.136 P=0.000***	0.043	10.54
	东部	0.036	0.005				
wetland	西部	0.01	0.001	0.008	T=34.217 P=0.000***	0.008	8.986
	东部	0.002	0.001				

东部地区和西部地区的土地利用类型数据除林地利用率数据外，方差齐性检验和正态性检验均未通过，故仅对林地利用率数据采用独立样本 t 检验，其余 4 种土地利用类型数据采用独立样本 Mann Whitney 检验和 Welch's T 检验，通过表 5-5 的结果可知，东部地区和西部地区的草地、林地、灌木丛和湿地利用率均存在显著差异，且差异幅度非常大。耕地的利用率存在显著差异，且差异幅度中等。




图 5-8 南北地区的土地类型利用率均值直方图

通过以上分析可知，中国南北方地区在在自然环境和资源利用上存在显著的差异。降水量的巨大差异表明南方地区雨水充沛，而北方则较为干旱，南方地区比北方地区拥有更丰富的降水资源，这可能与南方地区更温暖湿润的气候条件以及季风影响相关。气温差异

中等说明虽然北方冬季寒冷而南方相对温暖，但这种差异不如降水量那样显著，这可能反映了中国南北气候类型的多样性。此外，耕地、林地、草地、灌木丛和湿地的利用率差异也非常显著，这可能与不同地区的地形、土壤质量、农业活动和环境保护政策有关。这些差异可能源于各地不同的地理特征、生态环境和经济活动需求，也可能对农业生产、生态系统健康和地区可持续发展产生重要影响，因此需要在土地规划和管理中予以充分考虑。

中国东西部地区在自然条件和土地利用方面存在显著差异。降水量和气温的显著差异表明，西部地区与东部地区在气候条件上具有较大差别，西部地区可能面临更加干旱和温度波动较大的环境。这种气候差异可能对农业种植、水资源管理和生态保护策略产生重要影响。同时，草地、林地、灌木丛和湿地的利用率差异非常大，表明东部和西部地区在土地利用模式和生态保护方面采取了不同的策略或面临不同的挑战，东部地区可能因气候较为湿润而更适合发展这些类型的土地利用。耕地利用率的中等差异则可能反映了耕作活动在两地区均具有重要地位，然而两地区在农业生产和土地开发上的差异可能与地理条件、经济发展水平、人口分布和政策导向等多种因素有关，需要在区域发展规划和环境政策制定时予以充分考虑，以实现区域协调发展和生态环境的可持续管理。整体来看，气候条件对土地利用的影响显著，反映了区域生态环境的多样性。

5.3 本章小结

本章通过结合人文地理特征研究中国土地利用变化的特征与结构，得到的结论如下：

1. 中国人口分布呈现出明显的东密西疏特征，这种分布主要受到自然地理条件和经济发展水平的影响。东部地区由于气候温暖湿润、地形平坦、经济发达和基础设施完善等优势，吸引了大量人口聚集，尤其是京津冀、长三角、珠三角等城市群。这些地区的人口和经济活动快速增长，城市规模迅速扩张。相比之下，西部地区由于自然条件相对恶劣、经济发展滞后，人口分布相对稀疏。到 2015 年，东部沿海地区因经济发展和就业机会继续吸引人口流入，人口密度和城市规模进一步扩大。尽管西部地区在积极发展经济和推动城镇化，但由于历史、地理及经济等因素的制约，人口聚集程度仍然较低。

2. 南方地区和北方地区在降水量和土地利用方面存在显著差异，南方地区降水丰富，更适合林地、湿地等生态系统的发展，而北方地区降水较少，气候较为干燥，导致耕地和草地的利用更为普遍。这些差异反映了两地的生态、农业和气候条件对资源利用方式的显著影响。

3. 东部地区和西部地区在气候条件和土地利用上存在显著差异，东部地区的降水量和气温普遍高于西部，这直接影响了两地区的生态环境和土地资源的利用方式。东部地区气候湿润，草地、林地、灌木丛和湿地的利用率明显高于西部，而耕地的利用差异幅度较小。

六、主要结论与模型优缺点讨论

6.1 主要结论

6.1.1 问题一的主要结论

我国降水季节性明显，夏季占全年一半且分布广，冬季最少，整体呈中间高两边低趋势。西北地区和青藏地区降水量最少，华中地区和东北地区适中，南部地区因季风降水量高。自 2002 年起南方降水量增加，2008 年起降水区域北移。华南地区、华东沿海地区和西藏南部易发生极端降水，华北和东北较稳定。2014 年后，华中地区极端降水事件增多。

全国各地区的土地利用类型中草地分布最广，湿地最少。新疆、内蒙古和西藏草地利用率高；东北地区、华北地区和华东地区的耕地利用率高；黑龙江和华东沿海林地利用率高；内蒙古中部灌木丛利用率高；西北中部地区湿地利用率高。湿地和灌木丛土地利用/覆被率低逐年下降，草地最高却呈下降趋势。各类土地利用类型的动态度多呈递减趋势，灌木丛和湿地持续下降，耕地变化复杂。然而，自 2014 年起 5 类土地利用类型成分度骤降，之后虽逐年递增，但未恢复至之前水平，其中草地的土地类型成分度虽仍是最高但依旧是下降的，其他的土地类型成分度呈现波动变化。

6.1.2 问题二的主要结论

海拔和坡度与雨量等级呈负相关，山影和坡向与雨量等级呈正相关，表明地形和光影对雨量等级有显著影响。各土地利用类型的土地利用中，草地和灌木丛的利用率与雨量等级呈负相关，而耕地和林地的利用率与雨量呈正相关，其中暴雨区域的林地利用率高，其他的土地利用类型的利用率较低。纬度与雨量等级呈负相关，而经度、气温和降水量与雨量等级呈正相关，表明地理位置和气候环境条件对暴雨形成至关重要。

中北部地区更易发生特大暴雨，南部地区极端天气概率高，高海拔地区暴雨常见，大暴雨和特大暴雨概率低。土地利用和地形特征显著影响极端天气，合理利用土地和保护自然地形有助于减缓极端天气。

土地利用和地形特征显著影响极端天气。高耕地、林地和湿地利用率可能增加极端天气风险，通过改变局部气候条件。相反，山影和灌木丛等地理特征有助于减少极端天气，可能因为它们帮助减缓风速、保留水分或调节温度。合理利用土地和保护自然地形可能会减轻极端天气发生的频率和强度。

6.1.3 问题三的主要结论

极端天气的发生受多种因素影响，其中气温是最主要的，其次是海拔、草地利用率、林地利用率等。凉爽气候、中度草地利用、缓坡、未利用的耕地、中山影和未利用的灌木丛有助于降低极端天气的发生概率；而低林地利用率、南坡向、未利用的湿地和高海拔则可能增加风险。预测显示，2025-2035 年东南沿海、长江中下游及西南地区可能面临较高暴雨风险，尤其是大珠江三角洲、西藏与云南交界、长江中下游城市如长沙、武汉和南昌。

6.1.4 问题四的主要结论

中国人口分布的东密西疏特征明显，主要由自然地理条件和经济发展水平决定。东部地区因气候适宜、地形平坦、经济繁荣和基础设施完善而人口密集，尤其是京津冀、长三角、珠三角等城市群，人口和经济活动增长迅速，城市规模不断扩大。相比之下，西部地区自然条件较差、经济发展缓慢，人口较为稀疏。到 2015 年，东部沿海地区因经济和就业优势继续吸引人口，而西部地区尽管努力发展经济和城镇化，人口聚集程度仍低。南方地区降水丰富，适宜林地和湿地发展，北方地区则因降水较少、气候干燥，耕地和草地利用更普遍。东部地区和西部地区在气候和土地利用上也存在差异，东部气候湿润，草地、林地、灌木丛和湿地利用率高，而西部则相对较低，耕地利用差异较小。这些差异体现了不同地区的生态、农业和气候条件对资源利用方式的影响。

总体来看，中国的人口分布和土地利用模式受到自然条件、经济发展水平和地理位置等多方面因素的影响。这些差异不仅反映了中国不同地区的生态和农业特点，也对区域发展规划、资源管理和环境保护提出了不同的挑战和要求。

6.2 模型优缺点

本节总结了不同模型的优缺点见表 6-1。

表 6-1 不同的模型的优缺点

模型	优点	缺点	适用数据
XGboost	精度较高、解释性好	拟合较慢	有监督、回归
决策树	拟合快、精度较高	解释性差	有监督、回归
支持向量机	拟合快、精度较高	解释性差	有监督、回归
联合均值与方法模型	解释性好，同时方差和均值	精度一般	有监督、回归
惩罚回归	解释性较好，具有稀疏性	需要选择参数，拟合慢	有监督、回归
高斯混合聚类模型	自动选择聚类个数	拟合慢，假设条件强	有监督、回归

参考文献

- [1] Beringer T I M, Lucht W, Schaphoff S. Bioenergy production potential of global biomass plantations under environmental and agricultural constraints[J]. *GCB Bioenergy*, 2011, 3(4): 299-312.
- [2] Fang, S., Mao, K., Xia, X., Wang, P., Shi, J., M. Bateni, S., Xu, T., Cao, M., & Heggy, E. (2021). A Daily near-surface Air Temperature Dataset for China from 1979 - 2018 (Version 1.0) [Data set]. Zenodo. <https://doi.org/10.5281/zenodo.5502275>.
- [3] Graham, M., & Shelton, T. (2013). Geography and the future of big data, big data and the future of geography. *Dialogues in Human Geography*, 3(3), 255-261. <https://doi.org/10.1177/2043820613513121>.
- [4] Gabriel F., & Jasmin G. Naturally Negative: The Growth Effects of Natural Disasters. *Journal of Development Economics*, 2014(111), 92-106.
- [5] Han, J., Miao, C. (2022). A new daily gridded precipitation dataset for the Chinese mainland based on gauge observations. figshare. Dataset. <https://doi.org/10.6084/m9.figshare.21432123.v4>
- [6] Liu, H., Jiang, D., Yang, X., & Luo, C. (2005). Spatialization approach to 1 km grid GDP supported by remote sensing. *Geo-Inf. Sci*, 7, 120-123.
- [7] Mingjing W, Yingqi L, Zhongyi H, et al. Lupus nephritis diagnosis using enhanced moth flame algorithm with support vector machines[J]. *Computers in Biology and Medicine*, 2022, 145.
- [8] Peuquet, D. J. (1988). Representations of Geographic Space: Toward a Conceptual Synthesis. *Annals of the Association of American Geographers*, 78(3), 375-394. <https://doi.org/https://doi.org/10.1111/j.1467-8306.1988.tb00214.x>
- [9] Yu, Z., Ciais, P., Piao, S., Houghton, R. A., Lu, C., Tian, H., Agathokleous, E., Kattel, G. R., Sitch, S., Goll, D., Yue, X., Walker, A., Friedlingstein, P., Jain, A. K., Liu, S., & Zhou, G. (2022). Forest expansion dominates China's land carbon sink since 1980. *Nature Communications*, 13(1), 5374. <https://doi.org/10.1038/s41467-022-32961-2>.
- [10] Yi, L., Xiong, L., & Yang, X. (2006). Method of pixelizing GDP data based on the GIS. *J. Gansu Sci*, 18, 54-58.
- [11] 汤国安. (2019). 中国数字高程图 (1KM). 国家青藏高原数据中心. [Tang, G. (2019). Digital elevation model of China (1KM). National Tibetan Plateau / Third Pole Environment Data Center.]

- [12] 余振, Philippe Ciais, 朴世龙等. 1900-2019 年中国土地利用和覆盖变化数据集[DS/OL]. 国家生态科学数据中心, 2022.
- [13] 王灿, 王嘉琛. (2022). 中国历史人口空间分布公里网格数据集 (1990-2015 逐年). 国家青藏高原数据中心. <https://doi.org/10.12078/2017121101> [Wang, C., Wang, J. (2022). Kilometer grid dataset of China's historical population spatial distribution (1990-2015). National Tibetan Plateau / Third Pole Environment Data Center. <https://doi.org/10.12078/2017121101>]
- [14] 徐新良. (2017). 中国人口空间分布公里网格数据集. 资源环境科学数据注册与出版系统 (<http://www.resdc.cn/DOI>). DOI:10.12078/2017121101
- [15] 王灿, 王嘉琛. (2022). 中国历史 GDP 空间分布公里网格数据集 (1990-2015). 国家青藏高原数据中心. <https://doi.org/10.12078/2017121102> [Wang, C., Wang, J. (2022). Kilometer grid dataset of China's historical GDP spatial distribution (1990-2015). National Tibetan Plateau / Third Pole Environment Data Center. <https://doi.org/10.12078/2017121102>]
- [16] 徐新良. (2017). 中国 GDP 空间分布公里网格数据集. 资源环境科学数据注册与出版系统 (<http://www.resdc.cn/DOI>). DOI:10.12078/2017121102
- [17] 黄莹, 包安明, 陈曦, 刘海隆, & 杨光华. (2009). 基于绿洲土地利用的区域 GDP 公里格网化研究. 冰川冻土, (1), 158-165.
- [18] 陈述彭. 地理系统与地理信息系统 [J]. 地理学报, 1991, 46(1): 1-7. <https://doi.org/10.11821/xb199101001>
- [19] 彭书时, 朴世龙, 于家烁, 刘永稳, 汪涛, 朱高峰, 董金玮, 缪驰远. 地理系统模型研究进展[J]. 地理科学进展, 2018, 37(1): 109-120. <https://doi.org/10.18306/dlkxjz.2018.01.012>
- [20] 胡焕庸. 中国人口之分布——附统计表与密度图 [J]. 地理学报, 1935, 2(2): 33-74 <https://doi.org/10.11821/xb193502002>
- [21] 阎国年, 周成虎, 林琿, 陈旻, 乐松山, 温永宁. 地理综合研究方法的发展与思考[J]. 科学通报, 2021, 66(20): 2542-2554. <https://doi.org/10.1360/TB-2020-0799>
- [22] 马九杰, 崔卫杰, 朱信凯. 农业自然灾害风险对粮食综合生产能力的影响分析[J]. 农业经济问题, 2005, (04): 14-17+79.
- [23] 党群, 殷淑燕, 徐兆红. 1260~1911 年晋陕蒙毗邻地区寒冻灾害及与气候变化关系[J]. 干旱区资源与环境, 2018, 32 (09): 109-116.
- [24] 李鸣阳, 王翔宇. 气候变化对我国农业气象灾害及其病虫害的影响研究[J]. 新农业, 2023, (06): 86-87.

- [25] 李小伟, 邓长涛, 陈有平等. 海南台风灾害重大风险防控与应急管理机制研究[J]. 中国应急管理科学, 2024, (08): 53-65.
- [26] 许小华, 张秀平, 史艳萍等. 鄱阳湖流域干旱灾害风险防控体系构建研究[J]. 江西水利科技, 2024, 50 (04): 275-281.
- [27] 胡启元. 气候变化加剧背景下人工智能技术创新赋能自然灾害预防[J]. 上海信息化, 2024, (07): 17-20.
- [28] 邓志强, 吴萍, 王拥政. 阿克苏地区冰雹天气特征与防雹技术探讨[J]. 农业灾害研究, 2020, 10 (07): 87-88+129.
- [29] 张保华, 蒋玉华, 肖燕等. 县域土地利用/覆被变化可持续性评价指标体系初探[J]. 世界科技研究与发展, 2011, 33(05): 839-842.
- [30] 王曙东, 惠建忠, 张国平等. 短时临近气象服务降水量等级标准研究[C]. 中国气象学会. 第 34 届中国气象学会年会 S11 创新驱动智慧气象服务——第七届气象服务发展论坛论文集. 中国气象局公共气象服务中心, 2017: 2.
- [31] 杨小波, 陈丽娟, 刘芸芸. 我国降水和气温的分级概率时空分布特征[J]. 应用气象学报, 2011, 22(05): 513-524.
- [32] 王娟. 艾比湖流域水质空间格局识别及其与土地利用/覆被类型变化的关系研究[D]. 新疆大学, 2017.
- [33] 胡启元. 气候变化加剧背景下人工智能技术创新赋能自然灾害预防[J]. 上海信息化, 2024, (07): 17-20.
- [34] 邓志强, 吴萍, 王拥政. 阿克苏地区冰雹天气特征与防雹技术探讨[J]. 农业灾害研究, 2020, 10 (07): 87-88+129.
- [35] 肖寅东, 曾宇通, 刘科, 胡聪. 基于 XGBoost 的模拟集成电路测试参数优化方法[J]. 电子测量与仪器学报: 1-9[2023-03-29].
- [36] 黄锐, 李霄铭, 余翔, 熊军, 陈汉城. 基于 XGBoost 的非侵入式污染企业环保工况识别[J]. 机电信息, 2023(06): 50-53.
- [37] 白广栋, 翁涅元, 张启蒙, 朱建军, 黄家玮. 基于 XGBoost 模型的空铁联运中转城市研究[J]. 铁道运输与经济, 2023, 45(03): 24-31.
- [38] 李福祥, 王雪, 张驰等. 基于边界点的支持向量机分类算法[J]. 陕西理工大学学报(自然科学版), 2022, 38(03): 30-38.

附录

附录 A 问题一的额外可视化结果

附录 A.1 未划分等级的降水量空间分布图（年均，1990-2020）




图 A-1 未划分等级的年均降水量空间分布热力图(1990-2005)




图 A-2 未划分等级的年均降水量空间分布热力图(2006-2020)

附录 A.2 未划分等级的降水量空间分布图（年地区均方差，1990-2020）




图 A-2 未划分等级的年降水量均方差空间分布热力图(1990-2005)




图 A-2 未划分等级的年降水量均方差空间分布热力图(2006-2020)

附录 A.3 划分等级的降水量空间分布图（年均，1990-2020）




图 A-3 划分等级的年均降水量的空间分布热力图(1990-2005)




图 A-3 划分等级的年均降水量的空间分布热力图(2006-2020)

附录 A.4 划分等级的降水量空间分布图（年地区均方差，1990-2020）




图 A-4 划分等级的年降水量均方差的空间分布热力图(1990-2005)




图 A-4 划分等级的年降水量均方差的空间分布热力图(2006-2020)

附录 A.5 不同土地利用类型的土地利用/土地覆被率的空间分布可视化(1990-2019，全)




图 A-5 土地利用/土地覆被率的空间分布可视化（1990-2000）




图 A-5 土地利用/土地覆被率的空间分布可视化（2001-2010）




图 A-5 土地利用/土地覆被率的空间分布可视化（2010-2019）

附录 B 问题一：时空分析代码

```
install.packages("lattice")
install.packages("versions")
install.packages("rasterVis")
# 1. library packages
library(raster)
library(ncdf4)
library(lubridate)
library(data.table)
library(ggplot2)
library(patchwork)
library(rasterVis)
# 1.1 Definition of rainfall metrics
path1 = ".\\data\\"
Names1 <- list.files(path = path1, "Data3")
Data3 <- stack(x = paste0(path1, Names1))
x <- names(Data3[[1]])
NameToDate <- function(x){
  x <- strsplit(x, split = "\\.")[[1]]
  x <- c(unlist(strsplit(x[1], "X"))[[2]], x[2:3])
  x <- as.Date(paste0(x, collapse = "/"))
  return(x)
}
Names <- names(Data3)
Namesi <- c()
for(i in 1:22645){
  Namesi[i] <- NameToDate(Names[i])
  cat("i = ", i, "\n")
}
Namesi <- as.Date("1970/01/01") + Namesi
Start <- which(Namesi == as.Date("1990/1/1"))
End <- which(Namesi == as.Date("2020/12/31"))
Namesi <- Namesi[Start:End]
Data3 <- Data3[[Start:End]]
Ye <- 1990:2020
Year <- 1990
Day3 <- c()
Dam3 <- c()
DancM <- Data3[[1:length(Ye)]]
DancS <- Data3[[1:length(Ye)]]
DancSD <- Data3[[1:length(Ye)]]
names(DancM) <- paste0("Year", Ye)
```



```

names(DancS) <- paste0("Year", Ye)
names(DancSD) <- paste0("Year", Ye)
n <- length(values(Data3[[3]]))
for(Year in Ye){
  da3 <- c()
  Pos <- which(year(Namesi) == Year)
  for(pos in Pos){
    Da <- Data3[[pos]]
    da3 <- rbind(da3, data.table(Pos = 1:n, Time = Namesi[pos], rainfall = values(Da)))
    cat("Year = ", Year, "pos = ", pos, "\n")
  }
  DancD <- da3[, .(M = mean(rainfall), S = sum(rainfall), SD = sd(rainfall)), .(Pos)]
  da3 <- da3[is.na(rainfall) != T,]
  Day3 <- rbind(Day3, da3[,.(RYm = mean(rainfall),
  RYs = sum(rainfall), RYsd = sd(rainfall)), by = .(year(Time)))])
  Dam3 <- rbind(Dam3, da3[,.(Rmm = mean(rainfall, na.rm = T),
  Rms = sum(rainfall, na.rm = T), Rmss = sd(rainfall, na.rm = T)), by = .(month(Time)))])
  values(DancM[[which(Year == Ye)])] <- DancD$M
  values(DancS[[which(Year == Ye)])] <- DancD$S
  values(DancSD[[which(Year == Ye)])] <- DancD$SD
}
write.csv(Day3, "Day3.csv")
write.csv(Dam3, "Dam3.csv")
p <- ggplot(data = Day3, aes(x = year , y = RYm, col = "red"))+
guides(col = FALSE)+ theme_bw()
P1 <- p + geom_point(aes(x = year , y = RYm, col = "red"),size=5)+
  geom_errorbar(aes(x = year,ymin = RYm - RYsd, ymax = RYm + RYsd),
    width = 0.6, size = 2, col = "red" )

P2 <- p + geom_point(size=5) + geom_line()
P3 <- p + geom_point(aes(y = RYsd), size=5) + geom_line(aes(y = RYsd)) + ylab("RYsd")
P1 / P2 + P3
Dam3 <- cbind(year = rep(Ye, each = 12), Dam3)
p <- ggplot(data = Dam3, aes(x = year , y = Rmm, col = factor(month)))+
guides(col = FALSE)+ theme_bw()
P1 <- p + geom_point(size=5)+
  geom_errorbar(aes(x = year,ymin = Rmm - Rmss, ymax = Rmm + Rmss),
    width = 0.6, size = 2, col = "red" ) +
facet_wrap(month~., 3, 4, scales="fixed")
P2 <- p + geom_point(size=5)+
facet_wrap(month ~ ., 3, 4, scales="free") + geom_smooth()
P2 <- p + geom_point(size=5) + geom_line()
Ts <- ts(data = Dam3$Rmm, start = c(1990, 1), frequency = 12)

```

```

Res <- decompose(Ts, type = "additive")
plot(Res)
# 没有划分等级
i = 1
DancM1 <- DancM
for(i in 1:31){
  Tem <- values(DancM1[[i]])
  values(DancM1[[i]]) <- (Tem > 1) + (Tem > 3) + (Tem > 5) + (Tem > 7) + (Tem > 9)
}
plot(DancM1[[1:16]])
plot(DancM1[[17:31]])
DancSD1 <- DancSD
for(i in 1:31){
  Tem <- values(DancSD1[[i]])
  values(DancSD1[[i]]) <- (Tem > 5) + (Tem > 10) + (Tem > 15) + (Tem > 20)
}
plot(DancSD1[[1:16]])
plot(DancSD1[[17:31]])
YeSelec <- seq(1, 31, by = 6)
plot(DancM1[[YeSelec]])
plot(DancSD1[[YeSelec]])
DancM2 <- DancM
Vals <- c()
for(i in 1:31){
  Tem <- values(DancM2[[i]])
  Vals <- cbind(Vals, Tem)
}
DancM2 <- DancM2[[1]]
values(DancM2) <- apply(Vals, 1, sd)
plot(DancM2)
test <- DancM[[1]]
test_spdf <- as(test, "SpatialPixelsDataFrame")
test_df <- as.data.table(test_spdf)
# 赋值列名
colnames(test_df) <- c("value", "x", "y")
#开始绘图
land_use <- ggplot() +
  geom_raster(data = test_df, aes(x = x, y = y, fill = factor(value))) +
  scale_fill_manual(name = "Category", values = classcolor, labels = landclass) +
  labs(x = 'Longitude(E)', y = 'Latitude(N)',
       title = "Raster data Charts Exercise",
       subtitle = "land use data",
       caption = 'Visualization by DataCharm')+

```

```

theme_bw()+
theme(text = element_text(family = "Times_New_Roman",face='bold'),
      title = element_text(family = 'Times_New_Roman',size = 16,face = 'bold'),
      axis.text = element_text(family = 'Times_New_Roman',size = 12,face = 'bold'),
      #修改刻度线内
      axis.ticks.length=unit(-0.22, "cm"),
      #设置刻度 label 的边距
      axis.text.x = element_text(margin=unit(c(0.5,0.5,0.5,0.5), "cm")),
      axis.text.y = element_text(margin=unit(c(0.5,0.5,0.5,0.5), "cm")))
)
land_use

```

附录 C 问题二：地形气候相互代码

```

# 2.1 read data
path1 = "\\data\\"
Names1 <- list.files(path = path1, "Data1")
Map1Da <- raster(x = paste0(path1, Names1))
Names3 <- list.files(path = path1, "Data3")
Map3Da <- stack(x = paste0(path1, Names3))
# 2.2 Year
YNames <- names(Map3Da)
YNamesi <- c()
for(i in 1:length(YNames)){
  YNamesi[i] <- NameToDate(YNames[i])
  cat("i = ", i, "\n")
}
YNamesi <- as.Date("1970/01/01") + YNamesi
B <- raster(x = "cropland-1900.tif")
Ye <- 2015:2018
Pos <- which(year(YNamesi) %in% Ye)
Map3Da <- Map3Da[[Pos]]
YNamesi <- YNamesi[Pos]
resample(Map3Da, B)
pos <- 1
Year <- 2015
da3 <- c()
for(Year in Ye){
  Pos <- which(year(YNamesi) == Year)
  for(pos in Pos){
    Da <- Map3Da[[pos]]
    Da <- resample(Da, B)
    Da <- as.data.table(as(Da, "SpatialPixelsDataFrame"))
    names(Da) <- c("rain", "x", "y")
  }
}

```

```

da3 <- rbind(da3, cbind(YNamesi[pos], Da))
cat("Year = ", Year, "pos = ", pos, "\n")
}
}
da3 <- da3[,.(
level = (rain > 0) + (rain >= 10) +
(rain >= 25) + (rain >= 50) +
(rain >= 100) + (rain >= 200),
rain, x, y),]
table(da3[rain != 0, ]$level)
write.csv(table(da3[rain != 0, ]$level), "Data2_2.csv", fileEncoding = "GBK")
values(Map1Da)[values(Map1Da) < 0] <- NA
plot(Map1Da)
Map1Da <- resample(Map1Da, B)
plot(Map1Da)
da1 <- as.data.table(as(Map1Da, "SpatialPixelsDataFrame"))
names(da1) <- c("Geo", "x", "y")
Da1 <- c()
Map1Daall <- stack()
path1 = ".\\data\\"
Names1 <- list.files(path = path1, "chdem")
Map11Da <- raster(x = paste0(path1, Names1[2]))
Map11Da <- projectRaster(Map11Da, crs="+proj=longlat +datum=WGS84")
values(Map11Da)[values(Map11Da) < 0] <- NA
plot(Map11Da, main = names(Map11Da))
Map11Da <- resample(Map11Da, B)
plot(Map11Da, main = paste0("resample_", names(Map11Da)))
Da1 <- cbind(Da1, as.data.table(as(Map11Da, "SpatialPixelsDataFrame"))[,1])
Map11Da <- raster(x = paste0(path1, Names1[3]))
Map11Da <- projectRaster(Map11Da, crs="+proj=longlat +datum=WGS84")
values(Map11Da)[values(Map11Da) < 0] <- NA
plot(Map11Da, main = names(Map11Da))
Map11Da <- resample(Map11Da, B)
plot(Map11Da, main = paste0("resample_", names(Map11Da)))
paths4 = ".\\data\\Data4\\"
Names4 <- list.files(path = paths4, "tif")
da4 <- c()
for(Year in Ye){
  Names4 <- list.files(path = paths4, paste0(Year, ".tif"))
  for(j in 1:5){
    test <- raster(paste0(paths4, Names4[j]))
    test_spdf <- as(test, "SpatialPixelsDataFrame")
    test_df <- as.data.table(test_spdf)

```

```

colnames(test_df) <- c("value", "x", "y")
da4 <- rbind(da4, cbind(test_df,
year = Year, LandType = strsplit(Names4[j], "-")[[1]][1]))
}
cat("year = ", Year, "\n")
}
paths2 = ".\\data\\Data2\\"
Names2 <- list.files(path = paths2, "")
Pos <- unlist(lapply(strsplit(Names2, "_"), function(x) x[1]))
da2 <- c()
for(Year in Ye){
  Names <- list.files(path = paste0(paths2, Year, "_avg\\"), ".tif")
  Date0 <- as.Date(unlist(lapply(strsplit(Names, "_"), function(x) x[1])), "%Y%m%d")
  for(j in 1:length(Date0)){
    test <- raster(paste0(paste0(paths2, Year, "_avg\\"), Names[j]))
    test <- resample(test, B)
    test_spdf <- as(test, "SpatialPixelsDataFrame")
    test_df <- as.data.table(test_spdf)
    colnames(test_df) <- c("栅格值", "x", "y")
    da2 <- rbind(da2, cbind(test_df,
year = Date0[j]))
    cat("year = ", Year, ", j = ", j, "\n")
  }
}
}

```

附录 D 问题三：暴雨灾害能力预测代码

```

# 数据处理
names(da1) <- c("elevation", "Longitude", "Latitude",
"Aspect", "hillshade", "Slope")
names(da2) <- c("气温", "Longitude", "Latitude", "time")
names(da3) <- c("time", "rain", "Longitude", "Latitude")
names(da4) <- c("value", "Longitude", "Latitude", "year", "LandType")
da4 <- data.table(dcast(da4, Longitude + Latitude + year ~
LandType, value.var = "value"))
n <- dim(da1)[1]
da2 <- da2[, .(气温 = mean(气温)), by= .(Longitude, Latitude)]
da3 <- da3[, .(rain = mean(rain)), by= .(Longitude, Latitude)]
da4 <- da4[, .(grass = mean(grass),
forest = mean(forest)), by= .(Longitude, Latitude)]
da1 <- da2[da1, , on= .(Longitude, Latitude)]
da1 <- da3[da1, , on= .(Longitude, Latitude)]
da1 <- da4[da1, , on= .(Longitude, Latitude)]
Data <- da1

```

```

# 数据整合
aggr(Data)
Data <- na.omit(Data)
aggr(Data)
str(Data)
summary(Data$rain)
mean(Data$rain > 6)
sum(Data$rain > 6)
write.csv(
cbind(Data, 风险度 = recode((Data$rain > 6)*1,
""1' = '重灾区';'0' = '低风险区'')),
file = "Pro3Data.csv")
Data <- cbind(Data, level = (Data$rain > 6)*1,
风险水平 = recode((Data$rain > 6)*1,
""1' = '重灾区';'0' = '低风险区''))
library(e1071)
fitsvm <- svm(factor(风险水平) ~ grass +rain+ forest + 气温+
elevation+Aspect+hillshade+Slope, data = Data)
Pre_svm <- predict(fitsvm)
table(factor(Data$风险水平), predict(fitsvm))
table(predict(fitsvm))
library(pROC)
roc_svm <- roc(Data$lev, as.numeric(Pre_svm)-1)
library(randomForest)
x <- Data[,3:10]
y <- factor(Data$风险水平)
fitrf <- randomForest(x, y)
Pre_rf <- predict(fitrf)
table(factor(Data$风险水平), predict(fitrf))
roc_rf <- roc(Data$lev, as.numeric(Pre_rf)-1)
plot(roc_svm,col="red",
      legacy.axes=T,
      print.auc=F,
      print.thres=F,grid=c(0.2,0.2),
      grid.col=c("blue","yellow"))
plot(roc_rf,add = TRUE,col="blue",
      legacy.axes=T,
      print.auc=F,
      print.thres=TRUE,grid=c(0.2,0.2),
      grid.col=c("blue","yellow"))
write.csv(
cbind(Data, 森林风险水平 = predict(fitrf)),
file = "Pro3Datarf.csv")

```

```

write.csv(
cbind(Data, SVM 风险水平 = predict(fitsvm)),
file = "Pro3Datasvm.csv")
library(npmlda)
library(readxl)
data=read_excel("C:/Users/86133/Desktop/new_data.xlsx")
# 划分训练集和测试集
set.seed(123)
train_indices <- sample(x = 1:nrow(data), size = 0.8 * nrow(data), replace = FALSE)
test_indices <- sample(setdiff(1:nrow(data), train_indices), size = 0.2 * nrow(data), replace =
FALSE)
train_data <- data[train_indices, ]
test_data <- data[test_indices, ]
library(shapviz)
library(xgboost)
library(pROC)
#假设 num_class 是类别的总数
num_class <- length(unique(train_data$Y))
bst <- xgboost(data = as.matrix(train_data[,1:10]), label = train_data$Y-1,
               max_depth = 6,
               eta = 0.1,
               nthread = 2,
               nrounds = 100,
               objective = "multi:softmax",
               num_class = num_class)
pred <- predict(bst, as.matrix(test_data[,1:10]))
library(MLmetrics)
library(ggplot2)
library(lattice)
library(caret)
# 计算多分类混淆矩阵
cm <- confusionMatrix(as.factor(pred), as.factor(test_data$Y-1))
print(cm)
# 计算真阳性率和假阳性率
roc<- pROC::roc(test_data$Y ,pred)
# 绘制 ROC 曲线
plot(roc, main = "ROC Curve", print.auc = TRUE, auc.polygon = TRUE, grid = TRUE,
legacy.axes = TRUE,col="blue")
# 加载 ggplot2 和 reshape2 包
library(ggplot2)
library(reshape2)
table_matrix <- cm$table
# 将混淆矩阵转换为长格式

```



```

long_table <- reshape2::melt(table_matrix)
# 绘制图形
ggplot(long_table, aes(x = long_table$Prediction, y = long_table$Reference, fill =
long_table$value)) +
  geom_tile() +
  scale_fill_gradient(low = "white", high = "steelblue") +
  theme_minimal() +
  xlab("Predicted") +
  ylab("Actual") +
  ggtitle("Confusion Matrix")
# 计算 SHAP 值
shp <- shapviz(bst, X_pred = as.matrix(data[,1:10]))
# waterfall plot
sv_waterfall(shp,row_id = 2)
# force plot
sv_force(shp,row_id = 2)
# 基于 SHAP 的变量重要性 (SHAP summary plot)
sv_importance(shp,kind = "beeswarm")
sv_importance(shp)
sv_importance(shp, kind = "both")
# SHAP dependence plots (依赖图)
sv_dependence(shp, "QIWEN", alpha = 0.5,size = 1.5,color_var = NULL)

```

附录 E 问题四：中国土地利用特征代码

```

names(da1) <- c("elevation", "Longitude", "Latitude",
"Aspect", "hillshade", "Slope")
names(da2) <- c("气温", "Longitude", "Latitude", "time")
names(da3) <- c("time", "rain", "Longitude", "Latitude")
names(Da4) <- c("value", "Longitude", "Latitude", "year", "LandType")
Da4 <- data.table(dcast(Da4, Longitude + Latitude + year ~
LandType, value.var = "value"))
# 数据整合 (南北)
da1 <- cbind(da1[,.(南北 = recode(1*(Latitude < 33), "1 = '南方';0='北方'")),], da1)
da2 <- cbind(da2[,.(南北 = recode(1*(Latitude < 33), "1 = '南方';0='北方'")),], da2)
da3 <- cbind(da3[,.(南北 = recode(1*(Latitude < 33), "1 = '南方';0='北方'")),], da3)
Da4 <- cbind(Da4[,.(南北 = recode(1*(Latitude < 33), "1 = '南方';0='北方'")),], Da4)
D10 <- da1[,.(elevation = mean(elevation), Aspect = mean(Aspect),
Slope = mean( Slope), hillshade = mean(hillshade)), by = .( 南北 )]
D20 <- da2[,.(气温 = mean(气温)), by = .( 南北, year(time), month(time) )]
D30 <- da3[,.( rain = mean( rain)), by = .( 南北, year(time), month(time) )]
D40 <- Da4[,.(cropland = mean(cropland), forest = mean(forest),
grass = mean(grass), shrub = mean(shrub), wetland = mean(wetland)),
by = .(南北, year)]

```

```

write.csv(D10, "D10.csv")
write.csv(D20, "D20.csv")
write.csv(D30, "D30.csv")
write.csv(D40, "D40.csv")
da1 <- cbind(da1[,.(lhat = 0.8*Longitude - 59.57),], da1)
da2 <- cbind(da2[,.(lhat = 0.8*Longitude - 59.57),], da2)
da3 <- cbind(da3[,.(lhat = 0.8*Longitude - 59.57),], da3)
Da4 <- cbind(Da4[,.(lhat = 0.8*Longitude - 59.57),], Da4)
# 数据整合（南北）
da1 <- cbind(da1[,.(南北 = recode(1*(Latitude < lhat), "1 = '东部';0='西部'")),], da1)
da2 <- cbind(da2[,.(南北 = recode(1*(Latitude < lhat), "1 = '东部';0='西部'")),], da2)
da3 <- cbind(da3[,.(南北 = recode(1*(Latitude < lhat), "1 = '东部';0='西部'")),], da3)
Da4 <- cbind(Da4[,.(南北 = recode(1*(Latitude < lhat), "1 = '东部';0='西部'")),], Da4)
da1 <- cbind(da1[,.(南北 = recode(1*(Latitude < 33), "1 = '南方';0='北方'")),], da1)
da2 <- cbind(da2[,.(南北 = recode(1*(Latitude < 33), "1 = '南方';0='北方'")),], da2)
da3 <- cbind(da3[,.(南北 = recode(1*(Latitude < 33), "1 = '南方';0='北方'")),], da3)
Da4 <- cbind(Da4[,.(南北 = recode(1*(Latitude < 33), "1 = '南方';0='北方'")),], Da4)
D10 <- da1[,-3][,.(elevation = mean(elevation), Aspect = mean(Aspect),
Slope = mean( Slope), hillshade = mean(hillshade)), by = .( 南北 )]
D20 <- da2[,-3][,.(气温 = mean(气温)), by = .( 南北, year(time), month(time) )]
D30 <- da3[,-3][,.( rain = mean( rain)), by = .( 南北, year(time), month(time) )]
D40 <- Da4[,-3][,.(cropland = mean(cropland), forest = mean(forest),
grass = mean(grass), shrub = mean(shrub), wetland = mean(wetland)),
by = .(南北, year)]
write.csv(D10, "D10W.csv")
write.csv(D20, "D20W.csv")
write.csv(D30, "D30W.csv")
write.csv(D40, "D40W.csv")

```