



中国研究生创新实践系列大赛
“华为杯”第二十一届中国研究生
数学建模竞赛

学 校

贵州大学

参赛队号

24106570027

队员姓名

1.

王邱婧涵

2.

唐昊

3.

陈埭立

中国研究生创新实践系列大赛

“华为杯”第二十一届中国研究生

数学建模竞赛

题 目： 大数据驱动的地理综合问题建模与分析

摘 要：

地理系统是一个集聚人文自然的负责系统，地理学家经常使用地理综合的方式来描述地理系统的基本特征。随着地球观测方法的迅速发展，已经积累了大量的对地观测数据。如何利用大数据综合地理系统，在全球气候变化的背景下研究中国不断变化的地理环境，是当前地球科学研究的关键问题。因此，本文建模旨在研究以大数据为驱动的地理综合问题。

本文要解决的问题主要有以下几点：一是降水量和土地利用/土地覆被类型的时空演化特征建模与分析。二是地形-气候影响极端天气的建模分析与求解。三是脆弱性评估的多模型构建与求。四是多维度土地利用动态特征提取模型的建立与求解。

针对问题一，通过选择多个有关降水量、土地利用/土地覆被类型的衡量指标，分别以年均、季度维度，从多元的角度建立了降水量、土地利用/土地覆被类型的时空特征分析模型。多指标、多维时空分析模型来描述降水量和土地利用/覆被在 1990-2020 年间的时空演化特征，通过结合时间序列、空间自相关分析等方法。使用经过克里金（Kriging）插值、栅格矢量化、叠加分析等预处理的数据，在指标选择上除了常规降雨量指标外，使用了 Moran's I、变差系数（CV）。针对降雨量特征建立了 ARIMA 模型、Mann-Kendall 检验、长短期记忆网络（LSTM）神经网络模型的描述性方法。针对土地利用/土地覆被类型使用 5 个指标构建了土地动态度分析、Theil-SenMedian 趋势分析的描述性方法。其中拟合模型差异稳定在 5000mm 内，LSTM 的损失值接近 0.050，并且时空维度上都通过了 95% 置信水平显著性检验。模型结果表示结果为：1) 1990-2020 年，中国气温与降水东南高西北低，两者年际均上升。南方气温升速快，北方慢；降水变化率东高北低。（2）同期，中国植被 NPP 南高北低，年际呈增长趋势，反映气候与生态改善。此外，文章详细从降水季节性波动、年降水量趋势、降水长期趋势、降水极端事件、降水空间演化特征、土地利用/土地覆被类型的时空变化特征共 7 个方面总结了 1990-2020 年间的降水量和土地利用/土地覆被类型时空演化特征。

针对问题二，为地形与气候相互作用在极端天气事件形成机制中的核心作用，我们构建了一个综合性的多模型集成分析框架，综合考虑统计关系、非线性相互作用和物理机制。

通过整合元高斯模型中极端时间重现期的全微分方程、极端气候事件相关大尺度物理场的分析、随机森林特征重要性分析模型、DEM 降尺度插值法等方法进行建模，建模完成后我们采用了差分模型来分析各个参数因子（地形-气温-降雨）对于极端天气的影响因子，并分析出海拔、坡度、气候等特征对极端天气影响的回归系数。结果表明：海拔、坡度等地形特征和气候特征对极端降水事件的影响，例如，我们发现在西南山地地区，地形抬升效应可以导致降水强度增加 20% 左右。

针对问题三，创新设计一套多情景的脆弱性评估模型，精准界定暴雨引发灾害的阈值条件，并基于该模型预测未来十年（2025-2035 年）间，中国哪些区域在应对暴雨灾害时将面临最为严峻的脆弱性挑战。集合多维动态脆弱性评估模型、XGBoost 机器学习模型、OLS 回归模型、长短期记忆网络（LSTM）神经网络模型。分析得到：（1）海拔和坡度越高，降水量越少。（2）中国不同地区的暴雨灾害脆弱性存在显著差异，东南沿海和西南山区是未来 10 年内脆弱性较高的地区。例如，模型预测在某些沿海城市，暴雨灾害风险增加 40% 左右。新疆、甘肃等西南省份对于暴雨极端天气的脆弱度最高，最容易收到暴雨极端天气的影响。山东、浙江、辽宁等省对于暴雨极端天气的脆弱度最低，抵抗暴雨极端天气的能力最强。

针对问题四，土地利用变化的特征与结构分析，利用土地利用/土地覆被这一处于自然地理和人文地理交汇点的数据，通过转移矩阵整合极端天气众多影响因子，结合多影响因子回归预测模型，通过 XGBoost 模型对中国土地利用差异化及土地利用空间变化进行建模。这一模型能有效预测区域人文环境和自然环境变化，为未来各区域所需面临之考验进行预警。

上述模型与分析工具在洞悉并预测中国地理环境变迁方面展现出巨大潜力，其理论与实际应用价值不言而喻。然而，我们亦需正视其局限性，如高度依赖数据质量、计算负担沉重，以及部分理论假设的简化处理等。展望未来，研究应聚焦于提升模型精准度与泛化能力，强化实地验证环节，并跨学科（如生态学、经济学）的深度融合，以期实现更加全面、深入的环境变化理解与预测。

关键词： 多维时空演化特征分析 预测模型 地理信息系统综合分析 极端天气 统计分析 机器学习

1 问题背景与问题重述

1.1 问题背景

地理环境是一个由自然与人文多要素交织而成的复杂巨系统，其内部蕴含着众多变量指标，地理学家们长期以来致力于通过综合地理分析的方法，提炼出能够概括地理系统主导特征的关键指标。例如，以“三大阶梯”形象、胡焕庸线、T型开发结构等理论模型，深刻刻画了我国人口分布、社会经济活动的空间格局及其演变趋势。但是针对巨量对地观测数据的使用，这些定性分析往往依赖于专家的经验 and 直觉，难以全面、精准地捕捉地理系统内部复杂多变的相互作用关系；其次，宏观结构描述虽能概括整体特征，但容易忽略细节信息和局部差异，难以支撑精细化管理和科学决策的需求。因此，我们需要探索更加先进的数据处理与分析技术，如大数据分析、人工智能、机器学习等，以实现地理信息的智能化提取、融合与应用。基于以上问题，通过对描述全球和中国地理不同方面特征的大数据指标进行地理系统综合分析，可以探索全球气候变化下中国地理环境的演化，进一步解决地球科学研究的关键问题。

针对降水量这一变量，根据 IPCC 报告显示，在气候变暖背景下，全球降水格局呈现出总量不变而极端事件增多的变化趋势。研究显示，我国西北和东北地区降水事件增多，中部地区降水事件减少；干旱、强暴雨降水事件增加，导致一些地区干旱程度加剧、另一些地区洪涝灾害频发。降水量变化存在格局及其区域分布不确定性、时空编译性和不可控性，因此研究不同区域降水量的变化特征是当前全球气候变化研究的重要内容之一。通过使用降水量数据的不同聚合指标来进行时空多维分析，可以对降水量的演化趋势进行预测，分析降水量与其他地理因素对暴雨极端天气的驱动作用，有效预测暴雨灾害进行及时防御，减少人身财产损失。

针对土地利用/土地覆被类型这一变量，土地利用/土地覆被变化（Land-Use and Land-Cover Change,LUCC）是反映人类活动对环境影响的最重要因素之一，可控地随时空进行演化。人类活动是土地利用变化的驱动因素，土地覆被变化则是土地利用变化的必然结果。随着全球气候的加速变化以及城镇化建设的不断推进，土地利用/土地覆被发生了巨大变化，开展土地覆被类型变化研究，可为土地规划、城市建设、水土资源保护等提供决策依据。因此研究不同区域降水量的变化特征是当前全球气候变化研究的重要探索。发掘中国土地利用/土地覆被类型变化的时空特征和驱动力，结合降雨量及人文地理数据建立土地利用变化模型与人类活动情况的关联，提供政策制定、环境保护和城市规划等时代课题的参考依据。

综上所述，为使用大数据的手段对地理系统进行综合 [1?]，可以使用降雨量和土地利用/土地覆被类型这一特征的数据探索全球气候变化下中国地理环境的演化，这些技术不

仅能够提升我们对地理系统复杂性的认识水平，还能为生态保护、灾害预警、城市规划、经济发展等多个领域提供更加精准、高效的决策支持。

全球和中国地理不同方面特征的变量变化存在时空变异性、时空分布不均匀、可控性不定的特征，极端天气对人类生产生活造成的影响巨大，据《中国气候变化蓝皮书（2024）》显示，中国年暖昼日数平均每 10 年增加 6.7 天；全国年累计暴雨（日降水量 ≥ 50 毫米）站日数每 10 年增加 4.1%。因此，利用大数据的手段对地理系统进行综合，探索全球气候变化下中国地理环境的演化，是当前地球科学研究的关键问题。首先，构建降雨量和土地利用/土地覆被类型变量的描述性统计方法，挖掘两变量的时空演化特征，并对未来几年的降水量、土地利用/土地覆被类型进行预测，并分析降水量与地理因素之间的关联。其次，充分发掘分析地形、气候相互作用在极端天气形成过程中的作用，确定暴雨成灾天气的临界条件，实现对中国境内应对暴雨灾害能力最为脆弱地区进行预测。最后，综合以上特性，整合人文地理和自然地理两要素建立土地利用变化模型与来预测地形、降水、人口、经济活动对全球变暖气候变化的驱动作用。

1.2 数据介绍

本题包含了六个数据集，本节会对数据集进行介绍及初步分析。

1.2.1 数据集

本题具有六个数据集，分别为以下部分：

(1) 中国数字高程图（1km）：该数据集通过 DEM 算法提取了大量的地表形态信息，包括了流域网格单元的坡度、坡向以及单元格之间的关系等。再次基础之上通过一定的算法可以计算出地表水流路径、河流网络和流域的边界。数据集具有正轴割圆锥等面积投影 Albers Conical Equal Area（105、25、47）及大地坐标 WGS84 坐标系两种投影方式。数据集在空间上每个数据格点表示了 $1\text{Km} \times 1\text{km}$ 大小的地形数据。空间范围在经度上涵盖了从西经 73.2° 到东经 135.5° ，在纬度上涵盖了从南纬 17.8° 到北纬 53.9° 的经纬度范围。时间节点位于 2000 年，数据不随时间发生变化，没有时间维度。

(2) 中国 0.1° 近地表气温数据集（1979-2018 年）：该数据集涵盖了在时间维度上包含了从 1979 年至 2018 年每一天的气温平均值，在空间维度上以 $0.1^\circ \times 0.1^\circ$ 为单元格大小，代表了每个单元格内的日平均气温，单位为摄氏度。

(3) 中国大陆 0.25° 逐日降水数据集（1961-2022 年）：该数据集涵盖了在时间维度上包含了从 1961 年 1 月 1 日至 2022 年 12 月 31 日每一天的降水量平均值分布（存在部分地区数据缺少），在空间维度上以 $0.25^\circ \times 0.25^\circ$ 为单元格大小，代表了每个单元格内的日平均降雨量，单位为毫米。

(4) 中国 0.5° 土地利用和覆盖变化数据集（1900-2019 年）：该数据集涵盖了在时间维

表 1.1 数据集介绍表

序号	数据集名称	内容
1	中国数字高程图	该数据集包含两种采用两种不同坐标系的数据，涵盖了地表海拔高度等数据
2	中国 0.1° 近地表气温数据集	该数据集包含全国 1979-2018 年每日的气温平均值的分布
3	中国大陆 0.25° 逐日降水数据集	该数据集包含了 1961 年至 2022 年每一天的降水量分布
4	中国 0.5° 土地利用和覆盖变化数据集	该数据集包含耕地、林地、草地、灌木丛、湿地五种土地覆被类型在中国的分布情况
5	人口空间分布公里网格数据集	该数据集包含了在一年中中国人口的空间分布情况
6	GDP 空间分布公里网格数据集	该数据集包含了在一年中 GDP 的空间分布情况

度上从 1900 至 2019 年共计 120 年的土地覆被年分布情况，时间上以年为单位。具有五种植被类型分别为耕地、林地、草地、灌木丛、湿地五种，每种存在于不同的图上。在空间维度上以 0.5°×0.5° 为单元格大小，代表了每个单元格内某一种植被覆被所占面积比例。

(5) 中国大陆 1km 逐年历史人口空间分布公里网格数据集 (1990-2015 年)：该数据集涵盖了在时间维度上包含了从 1990 年至 2015 年每一年的中国人口空间分布，在空间维度上以 0.1Km×0.1Km 的栅格数据，空间范围在经度上涵盖了从西经 57.48° 到东经 150.65°，在纬度上涵盖了从南纬 2.07° 到北纬 56.8° 的经纬度范围。代表了每个单元格人口数 pop。

(6) 中国大陆 1km 逐年历史 GDP 空间分布公里网格数据集 (1990-2015 年)：该数据集涵盖了在时间维度上包含了从 1990 年至 2015 年每一年的 GDP 数据，在空间维度上以 0.1Km×0.1Km 的栅格数据，空间范围在经度上涵盖了从西经 52.01° 到东经 154.49°，在纬度上涵盖了从南纬 0.88° 到北纬 57.8° 的经纬度范围。代表了每个单元格内的 GDP 总值，单位为万元/平方千米。

1.2.2 目标变量

本题的目标变量包括以下三个：

(1) 第一题降雨量的目标变量是年份、经度、纬度、日期、降雨量；土地利用/土地覆被类型的变量是单一土地利用度、综合土地利用动态、土地利用强度变化、土地利用开发度、土地利用耗减度。

(2) 第二题的目标变量为地形-气候相互作用在极端天气形成过程中的作用权重因子，使用 $\frac{\partial r_{xy}}{\partial r_y}$ 等来表示作用权重因子。

(3) 第三题的目标变量为暴雨成灾的临界条件点及降雨量和土地利用/土地覆被变化的回归预测方程。

(4) 第四题的目标变量为土地利用变化数学模型以及数学模型的有用性评估因子，准确性评估因子

1.2.3 地理大数据信息

各个格点的地理大数据信息包含了以下字段：

(1) 地形数据：高度、坡度、坡向等地形数据。

(2) 日均气温：每天的气温，单位摄氏度。

(3) 日均降水：每天的单位降水量，单位毫米。

(4) 土地利用和覆盖变化：每个地区内某一种植被覆被所占面积比例，耕地、林地、草地、灌木丛、湿地五种植被。

(5) 人口数据：地区的人口总量。

(6) GDP 数据：地区的 GDP 总量，单位万元/平方千米。

1.2.4 极端天气相关特征

极端天气相关特征包含两个大类：

(1) 单一极端天气：低温，高温，干旱，暴雨等极端天气。分别需要定义出高低温阈值和干旱暴雨阈值。

(2) 混合极端天气：低温干旱，高温干旱，低温暴雨，高温暴雨等极端天气。当同时满足单一极端天气中的两个极端天气时，将会进一步变为混合极端天气。

1.3 问题重述

围绕大数据手段综合地理系统，主要使用降雨量和土地利用/土地覆被类型两个变量，实现全球气候变化下地理环境的演化特征和变化预测，本文依次提出如下问题：

问题一：为降水量和这土地利用/土地覆被类型这两个变量分别构建一套描述性统计方法，用 13 个较为简洁的统计指标或统计图表，对这两个变量在 1990 2020 年间中国范

围内的时空演化特征进行描述和总结。

问题二：结合附件中所给的数据，建立数学模型，说明地形-气候相互作用在极端天气形成过程中的作用。

问题三：考虑第 2 问所反映的从“暴雨”到“灾害”中上述三方面因素的角色及其交互作用，确定暴雨成灾的临界条件；并结合第 1 问中降雨量和土地利用/土地覆被变化的历史时空演化特征，对 2025 2035 年间中国境内应对暴雨灾害能力最为脆弱的地区进行预测，并以地图的形式呈现你们的预测结果。

问题四：描述自然地理特征的地形可以概括为“三级阶梯”，而降水中具有标志性意义的“800mm 等降水量线”则与区分我国南北方的“秦岭—淮河”一线大体重合；描述人文地理特征的人口分布及其社会经济活动总量等指标，则被由连接黑龙江黑河与云南腾冲的“胡焕庸线”清晰地划分成东密西疏的两部分。对于自然地理和人文地理交汇点的土地利用/土地覆被情况，结合其在前三问中描述、估计和预测任务中的“特性”，利用地理大数据，建立相应的数学模型，对数据进行简化和综合，描述中国土地利用变化的特征与结构。并从准确性和有用性两个方面解释验证所得总结。

2 模型的假设与符号说明

2.1 模型的假设

- 数据完整性与准确性：假设所选取的降水量、土地利用/土地覆被类型、植被 NPP 值等数据集在 1990 年至 2020 年期间是完整且准确的，缺失值和异常值已经通过合理的方法进行了有效处理，不会对研究结果产生显著影响。
- 统计方法的有效性：均值法、趋势法、Mann-Kendall 检验等统计方法能够准确描述和总结中国范围内降水量和土地利用/土地覆被类型的时空演化特征，且这些方法的应用结果具有代表性和可靠性。
- DEM 降尺度分析法的适用性：在华北地区，DEM 降尺度分析法能够有效分析地形与极端事件之间的关系，揭示极端事件形成的地理原因，并且其分析结果能够为极端气候事件的评估和预测提供科学依据。
- 风险评估模型的准确性：频率比方法和层次分析法结合使用，能够准确计算内涝风险，并通过与淹没范围和内涝点的验证，确定暴雨成灾的临界条件。同时，基于支持向量机、XGBoost 模型和随机森林的机器学习预测模型，能够有效预测未来中国境内应对暴雨灾害能力最为脆弱的地区。土地利用变化模型的可靠性：最大似然法、地理信息系统空间分析方法以及数理统计方法构建的模型，能够准确计算出我国土地利用类型的动态转移矩阵，并定量分析土地利用时空变化，为土地可持续利用提供可靠的决策支持。

2.2 符号说明

符号	意义
x_b	剩余误差
dv_{max}	异常识别和消除后的最大距离
Y	遥感数据的像素值
N	时间序列的长度
P_{ij}	联合概率
$g(\cdot)$	输出层的传递函数
CV	变差系数
K	单一土地利用动态度
LC	综合土地利用动态度
LU_i	研究时段内初期的 i 类土地覆被类型的面积
T	研究时长
Q	土地利用变化强度

符号	意义
U_{total}	研究区域总面积
X_{ab}	为从时刻 a 到时刻 b 的研究时段内其他土地覆被类型转变为该土地覆被类型的面积之和
J_{ab}	为从时刻 a 到时刻 b 的研究时段内该土地覆被类型转变为其他土地覆被类型的面积之和
Z	土地利用程度综合指数
SPI	标准化降水指数
STI	标准化温度指数
LC	综合土地利用动态度
O_i	i 时间点的数据观测值
μ	数据集 SPI、STI 和 SGI 的均值
σ	数据集 SPI、STI 和 SGI 的方差
P_{xy}	SPI、STI 和 SGI 的相关性系数
r_x1	极寒天气回归周期
r_x2	高温天气回归周期
r_y1	干旱天气回归周期
r_y2	暴雨天气回归周期
$\phi(x)$	线性映射
ξ_i	松弛变量

3 问题一：降水量和土地利用/土地覆被类型的时空演化特征建模与分析

3.1 问题分析

问题一主要研究 1990 年至 2020 年间中国范围内降水量和土地利用/土地覆被类型两个变量的时空演化特征描述和分析，旨在时间维度上预测未来降水量和地形变化趋势，以及降水量与地理因素之间的关系。该问题包括两个子问题：

(1) 分析降水量的时空演化特征由于降水量数据为逐日数据，因此我们对降水量数据集中时间跨度为 1990 年-2020 年的数据中的负值数据进行剔除，使用克里金 (Kriging) 插值方法，验证是否存在异常年份，并采用插值法填补无效数据，规整为以“年度”为单位的分析维度。在降水量时空描述性统计方案中，使用了 3 个常用年降水量的统计指标以及变差系数 CV，又使用 Moran 's I 空间自相关分析方法，同时使用 ARIMA 模型对时间序列建模，分析得到个指标下的平面热力图、3D 热力图、折线图、统计表格。具体描述性统计方案如下：

①基于降水量的降水量、经度、维度,通过使用年平均降水量、年降水量标准差、年最大降水量，发掘该 30 年间不同年份降水量的平均趋波动程度和极端降水事件。

②在时间维度上使用三种方法进行统计描述：第一种方法是，通过选择移动回归结束和自回归阶数拟合时间序列模型，使用 ARIMA 模型对时间序列上的降水量进行建模，实现对降水量趋势的量化，预测未来几年的降水情况；第二种方法是：使用长短期记忆 (Long Short-Term Memory, LSTM) 网络来预测降雨时间序列，能够捕捉和记忆长序列中的信息，因此非常适用于降雨时间序列数据。

③在空间维度上使用两种方法进行统计描述：第一种方法是，基于变差系数 CV 的 annual 统计特征，由于数据集是逐日数据，每年的年均降水量不同，因此适用 CV 来描述降雨的空间特征，CV 值通过标准差和平均值的比率来消除变量的维数；第二种方法是，使用 Moran 's I 空间自相关分析来发掘降水量在空间维度上的聚集程度，得到降水量的高度集中区域。最后，通过建立地理加权回归模型 (GWR) 得到降水量和地形、地貌、土地利用等地理因素的关联。

(2) 分析土地利用/土地覆被类型的时空演化特征基于 1990 年-2020 年的土地利用和覆盖变化数据集，以 10 年为一个间隔，利用变化检测法发掘土地利用/土地覆被类型的时空变化情况，识别在该 30 年间发生显著变化的地区，并使用土地覆被类型热力图和指标数表可视化土地利用/土地覆被类型的时空演化特征，具体方案如下：

①针对时间维度的变化，使用土地利用动态度来定量地表示土地利用的变化速度，预测未来的土地利用变化趋势，分别使用单一土地利用动态度、综合土地利用动态度、土地利用变化强度、土地利用开发度、土地利用耗减度得到土地利用/覆被变化描述指数值，得到田地、森林、草、灌木、湿地等不同土地覆被类型的变化速度、开发速度、为湿地和水

体的增减互动关系等土地利用/土地覆被类型的时间变化。

②针对空间维度变化，使用马尔可夫模型定量描述不同土地覆被类型的增加缘由和减少面积的去处，借用土地转移矩阵清晰表明中国境内土地覆被类型变换速率。土地利用变化主要是数量和空间分布的变化，空间分布则为各土地覆被类型的分布位置。通过比较各土地覆被类型的面积研究土地利用的动态空间变化，从面积上来加以分析不同年份各土地覆被类型的面积及其变化趋势。

3.2 数据预处理及分析

3.2.1 数据集选择

1、降水量数据集(中国大陆 0.25° 逐日降水数据集, 1961-2022 年), 提取其中 1990-2020 年降雨量数据作为问题一的数据集。

2、土地利用/土地覆被数据集(中国 0.5° 土地利用和覆盖变化数据集, 1900-2019 年), 提取其中 1990-2020 年土地利用和覆盖变化数据作为问题一的数据集。

3.2.2 数据介绍

1、以年为单位分析

通过使用经度、纬度、年均降水量指标分析图3.1可知：在 1990 年至 2020 年间，我国东北地区年平均降水量在 2000mm，东南季风为我国带来太平洋的水汽，我国东南沿海地区会最先得到东南季风带来的水汽，形成丰富的降水，也就成为了我国年降水量最为丰富的地区。从年降水量的地区分布状况来看，我国年降水量总体上由东南往西北递减，我国的西北地区由于深居内陆，距海遥远，成为我国年降水量最少的地区，西南地区将与量最大约 3500mm。西北地区和东北地区降水量最少。




图 3.1 30 年年均降水量热力图

2、以季度为单位分析

本研究季节划分为:12 月 次年 2 月为冬季、3 月 5 月为春季、6 月 8 月为夏季、9 月 11 月为秋季。全国数据的选取范围为:70° 135°E, 15°N 50°N; 西北地区数据的选取范围为:90°E 100°E, 30°N 40°N; 华北地区数据的选取范围为:110°E 120°E, 30°N 40°N。




图 3.2 1990 年到 2020 年四季降水量热力图

通过加和 1990 年至 2020 年 30 年间春、夏、秋、冬四季的降水量, 并制作成热力图3.2,

从图中可知，冬季和春季的降雨量特征最为相似，集中在东南沿海地区；夏季和秋季的降雨逐渐向内陆扩展，降雨范围最大最广。

3.2.3 数据预处理

针对降雨量的数据集，在采用 1990-2020 年这三十年间的大陆降雨量数据时，我们首先进行了严格的数据清洗工作，专注于处理其中存在的错值问题，特别是那些不合逻辑的负降雨量值。针对这些错误数据点，我们采取了克里金 (Kriging) 插值技术来替代它们。克里金插值法凭借其考虑空间自相关性和变异性的优势，能够基于周围已知降雨量的观测数据，通过复杂的数学模型预测并填充错误或缺失的降雨量值。这一过程不仅保证了数据的完整性和连续性，还确保了替换后的数据在统计特性和物理规律上与原始数据保持一致，从而极大地增强了数据的可靠性和可用性。

针对土地利用/土地覆被类型的数据集，提取 1990-2020 年地表覆盖数据，按国家编码标注土地覆被类型。生成土地利用/覆被变化图，进行栅格矢量化、叠加分析并计算面积，结果导入 Excel。通过透视分析构建面积转移矩阵，分析土地利用/覆被变化特征。




图 3.3 1990 年到 2020 年间年度降雨量分布箱线图

箱线图3.3直观地展示了从 1990 年到 2020 年间年度降雨量的分布情况，且图中明确标注了没有异常值的影响，由于没有异常值，箱线图的上下须 (whiskers) 直接连接到数据的最小值和最大值。从图中可以看出，降雨量的中位数位于箱体中部，表明这期间的降雨量数据较为集中，没有显著的偏移或极端分布。同时，箱体的宽度也反映了降雨量的四分位距 ($IQR = Q3 - Q1$)，即数据中间 50% 的离散程度。

3.3 子问题一：分析降水量的时空演化特征


3.3.1 指标分析

针对降水量数据的分析，降水量的描述性统计使用 3 个指标，分别是：年平均降水量、年降水量标准差、年最大降水量，使用平均值可以平滑短期波动,突出长期趋势，其中每个指标的定义如下：

(1) 年均降水量：用于描述每年的降水整体情况。

$$P_{\text{avg}}(t) = \frac{1}{n} \sum_{i=1}^n P_i(t) \quad (3.1)$$

其中， $P_i(t)$ 为第 i 年的降水量， t 为年份， n 为一年中的总天数。






图 3.4 年均降水量热力图

在 1990 年至 2020 年间，将预处理后的逐日降雨量按照年度加和后，每距离 5 年对年均降水量数据进行对比分析，发现全国降水量在过去 30 年间仅小范围降水量有明显变化差异，该小范围地区主要集中在辽宁省（红色框图）、西南地区东部（黄色框图）、华东地区中部（黑色框图）。其中，分析图3.4的红色框图发现，辽宁省在 2010 年前后 5 年区间的降雨量在这 30 年中明显增多，辽宁省的整体降雨量发展呈现明显的驼峰走向。而黄色框图西南地区东部的呈现整体稳定高降水量的弯钩形地区，仅在 2015 年前后有降水量降低的迹象，而黑色框图中的华东地区中部，高降雨量地区从分散的片区逐渐集中成一个整体片区。总体分析，在 1990 年至 2020 年间 2015 年全国降水量都较少。

(2) 年降水量的标准差，用于衡量降水量的波动性，评估特定区域内降水量的年际波动。

$$\sigma p(t) = \sqrt{\frac{1}{n-1} \sum_{i=1}^n (P_i(t) - P_{\text{avg}}(t))^2} \quad (3.2)$$

(3) 年最大降水量，帮助我们锁定每年中降水量最大的网格值，便于分析极端天气事件。

$$P_{\text{max}}(t) = \max (P_1(t), P_2(t), \dots, p_n(t)) \quad (3.3)$$




图 3.5 年均降水量、年降水量的标准差、年最大降水量

由图3.5 (a) 可知，针对年均降水量，三十年间的平均降雨量可以用来衡量降雨量随时间的变化趋势，由折线图可知年平均降雨量在 1990 年至 2000 年间先是下降最后上升，在 1997 年附近达到顶峰，2020 年较 1990 有所下降。最近几年的年平均降雨量较之前有所提高。针对年平均降雨量的波动程度，绿色折现表明波动幅度与年均降水量有相似的幅度。红色折线表示了极端天气的恶性情况，当年平均降水量增加时，也意味着极端天气的恶劣程度与之关联。

由图3.5 (b) 折线图可知，年平均降雨量在 1990 年至 2000 年间，年均降水量、年降水量的标准差、年最大降水量的整体拟合程度都不错，其中除了 1995 年的数据出现明显峰值和差异外，年均降水量、年降水量的标准差的拟合效果最好，而年最大降水量的拟合差异稳定在 5000mm 内。

3.3.2 降雨量的时间特征模型构建与分析

针对剔除负值并插值补充后的 1990 年-2020 年的降水量数据，使用其中的降水量、经度、纬度等特征数据，以“年度”为单位加和每一年的日降水量数据。并对 30 年的年降水量数据进行一下步骤：

模型一：ARIMA 时间序列预测模型

首先需要对观测值序列进行平稳性检测，如果不平稳，则对其进行差分运算直到差分

后的数据平稳；在数据平稳后则对其进行白噪声检验，白噪声是指零均值常方差的随机平稳序列；如果是平稳非白噪声序列就计算 ACF（自相关系数）、PACF（偏自相关系数），进行 ARMA 等模型识别；对已识别好的模型，确定模型参数，最后应用预测并进行误差分析。设置自回归项的数量（ $p=2$ ）、差分阶数（ $d=1$ ）和移动平均项的数量（ $q=2$ ）对时间序列模型进行拟合，数学公式如下：

$$X_t = c + \Phi_1 X_{t-1} + \Phi_2 X_{t-2} + \cdots + \Phi_p X_{t-p} + \theta_1 \varepsilon_{t-1} + \cdots + \theta_q \varepsilon_{t-q} + \varepsilon_t \quad (3.4)$$

使用 80% 的数据作为训练集使用 1990 年-2015 年的年降水量作为训练集，使用 2015 年-2020 年的年降水量作为测试集，确保测试集涵盖了来自训练集的较晚时间段，以确保模型不会从未来时间段获取信息。ARIMA 时间序列预测模型分析降水量在未来几年的预测折线图钟，不难发现该预测方法与实际降雨量情况存在一致的变化趋势。




图 3.6 ARIMA 时间序列预测折线图

模型二：Mann-Kendall 检验 Mann-Kendall（MK）检验不受少数异常值的影响。MK 检验法对 Theil-SenMedian 趋势分析所得到的三十年间植被 NPP 变化趋势进行显著性检验，其趋势检验结果分为无明显变化、显著变化、不显著变化。计算公式如下图所示：

$$S = \sum_{i=1}^{(n-1)} \sum_{j=1}^n sgn(x_j - x_i) \quad (3.5)$$

其中， x_i 和 x_j 分别为第 i 、 j 时间序列对应的像元值， n 表示时间序列长度， m 表示研究时间段中重复的数据组个数； t_i 为第 i 组重复数据组中的重复个数。当 $|Z| \leq 1.96$ ，则未通过 95% 置信度检验，即趋势不显著；若 $|Z| \geq 1.96$ ，通过 95% 置信度检验，即趋势显著。




图 3.7 1990-2020 中国各区域年降水均值变化图

图3.7显示，各地区年平均降雨量波动很大，但总体上呈上升趋势，在某些年份可能会急剧下降。近 30 年来，中国植被平均降雨量为 543.96 毫米。在这些地区中，中国东部和东北地区降雨量趋势变化速度较快，东部降雨量年增长率最高，为 6.6 毫米/公顷，其次是东北地区，年增长率为 6.36 毫米/公顷。分开在西北部和西南部地区，年降雨量变化不大，趋势系数分别为 0.71mm/a 和 1.71mm/a。全年降雨量变化如下：东部 > 中部 > 西部。六个主要地区的年降雨量高峰地区存在区域差异，2001 年和 2002 年东北、北部和西北地区降雨量低；南部、东部和西南部地区的最高降雨量为 2016 年至 2017 年。

模型三：长短期记忆网络 (LSTM) 神经网络模型

由数据分析中的年降雨量数据可以知道，每年的降雨量数据可能是相当不平稳的。与温度不同，温度通常在四季中表现出明显的趋势，而雨量作为一个时间序列可能是相当不平稳的。使用长短期记忆 (Long Short-Term Memory, LSTM) 网络来预测降雨时间序列。LSTM 是一种递归神经网络 (Recurrent Neural Network, RNN)，专门用于处理序列数据中的长期依赖关系。LSTM 网络能够捕捉和记忆长序列中的信息，因此非常适用于降雨时间序列数据。

LSTM 网络在降雨时间序列预测中具有以下优势：

- 捕捉长期依赖关系：与传统的前馈神经网络不同，LSTM 网络具有可以存储和更新信息的记忆单元。这使得它们能够学习输入序列中的模式和依赖关系。如图3.8LSTM 单元的关键组成部分是输入门、遗忘门和输出门。这些门控制信息进出单元的流动，使 LSTM 能够选择性地保留或丢弃信息。LSTM 的记忆单元使网络能够记住并利用来自较早时间步的信息，这对于建模具有长期依赖关系的降雨模式至关重要。




图 3.8 LSTM 神经网络模型

- 遗忘门 (forget gate): 图中红色线条部分，其决定从细胞状态中丢弃什么信息。

$$f_t = \sigma(W_f \cdot [h_{t-1}, x_t] + b_f) \quad (3.6)$$

- 输入门 (input gate): 图中青色线条部分，其决定让多少新的信息加入细胞状态，这一步将输出细胞状态。

$$\begin{aligned} i_t &= \sigma(W_i \cdot [h_{t-1}, x_t] + b_i) \\ \tilde{C}_t &= \tanh(W_C \cdot [h_{t-1}, x_t] + b_C) \end{aligned} \quad (3.7)$$

$$C_t = f_t * C_{t-1} + i_t * \tilde{C}_t \quad (3.8)$$

- 输出门 (output gate): 图中绿色线条部分，其确定输出值，该输出值基于细胞状态。

$$\begin{aligned} o_t &= \sigma(W_o \cdot [h_{t-1}, x_t] + b_o) \\ h_t &= o_t * \tanh(C_t) \end{aligned} \quad (3.9)$$

- 处理可变长度序列：降雨时间序列通常由于测量之间的不规则间隔而具有不同的长度。LSTM 网络可以处理这样的可变长度序列，无需固定大小的输入。

- 非线性建模：LSTM 网络可以学习输入特征和降雨模式之间的复杂非线性关系，从而能够捕捉传统统计模型可能忽略的复杂依赖关系。

其

建模过程如下：首先使用 1990 年-2015 年的年降雨量数据作为测试机，确保识别到时间序列的波动性或极端值，与 LSTM 模型的预测结果进行比较。然后形成一个数据集矩阵，将时间序列与过去的数值进行回归，接着用 MinMaxScaler 对数据进行标准化处理，通过把输入被转换为样本、时间步骤、特征的格式进行预测。




图 3.9 LSTM 模型损失

图3.9展示 LSTM 模型在训练过程中的损失值变化。横坐标代表了训练过程中的不同时间点，具体为 epoch 数，从 20 开始逐渐增加至 100。纵坐标则表示损失值，范围从 0.250 到接近 0.050，显示出随着训练的进行，损失值在逐渐降低。图表上清晰地展示了随着训练 epoch 的增加，LSTM 模型的损失值在持续下降，表明模型在逐步学习和优化，以提高其预测或分类的准确性。




图 3.10 LSTM 模型拟合效果

LSTM 模型在预测时通常依赖于前面的时间步数据，因此在创建输入数据时，前 5 年的数据 (1990-1994) 用于预测 1995 年的降水量，接着以此类推。图3.10清晰地展示了从 1995 年至 2020 年间，历史平均年降水量（Historical Mean Precipitation）与使用长短期记忆网络（LSTM）模型预测的历史平均年降水量（LSTM Historical Prediction）之间的对比。图中，黄色的星号标记了实际的历史降水量数据点，它们在不同年份间波动，但总体保持在一定范围内。与此同时，蓝色的折线则代表了 LSTM 模型的预测值，结合表3.3可以看出，显示出模型在预测年降水量方面具有较高的准确性。

表 3.3 1995 年-2020 年 LSTM 模型预测结果（单位：mm）

year	2015	2016	2017	2018	2019	2020
Prediction	262.84225	260.08557	270.5438	270.62848	273.0116	276.20404
True_Value	262.84225	260.08557	270.5438	270.62848	273.0116	276.20404

模型四：时间特征演化的显著性检验

为了研究选取时期内中国不同时期降水的变化趋势，将原始降水数据采用 5 年滑动平均处理后，对降雨量数据进行线性回归分析作为降雨量随时间长期变化特征。对趋势显著性的检验采用 Mann-Kendall 非参数检验法，该方法对数据分布没有要求，已在气候统计分析方面得到广泛应用。因此本文提高对降水长期变化的显著性检验标准，以通过 95% 置信水平检验为显著变化的标准。




图 3.11 1990 年至 2020 年间平均降水量的 95% 置信水平的显著性检验结果

针对 1990 年至 2020 年间平均降水量的时间分布，图3.11左图展示 95% 置信水平的显著性检验结果，从图表中的数值范围和分布来看，平均降水量从南向北呈现一定的变化趋势，但显著变化的点可能集中在我国华东地区南部，突出了具有显著变化的区域，如

图3.11右图的空间图放大了显著区域，显示了降水量的时间变异性。

3.3.3 降雨量的空间特征模型构建与分析

模型一：均值法

使用像素平均法计算了长时间序列遥感数据的平均像素值。该研究采用平均法分析了中国和地区 NPP 气候和植被变化特征。计算公式如下：

$$\sum_{i=1}^n (e^j)^i \quad (3.10)$$

其中，Y 表示遥感数据的像素值，N 表示时间序列的长度。

图3.12揭示了中国近三十年来的年平均降雨量存在显著的地域性差异，其范围广泛，从最低的 3.82 毫米到最高的 2003 毫米不等，总跨度接近 2000 毫米。这一降雨量的空间分布模式与年平均气温的分布趋势高度相似，整体呈现出由东南向西北递减的趋势。中国中部、南部以及东部南部地区享受着最为充沛的降雨，年平均降雨量超过 1500 毫米，是国家的多雨带。而位于中国东部、中部及西南部的部分地区，其年降雨量则介于 1000 至 1500 毫米之间，显示出较为丰沛的水资源。中国西南、东北、中部及南部的广大区域，年降雨量保持在 500 至 1000 毫米之间，为中等雨量区。相比之下，中国北方、西北及西南的部分地区则面临较为干旱的状况，年降雨量普遍低于 500 毫米，其中西北地区尤为突出，其年平均降雨量仅为 239.7 毫米，是全国降雨量最少的地区之一。

尽管中国东部地区的降雨量总体不及南部和中部，但其平均降雨量（约 333.4 毫米）仍显著高于西北地区。此外，东北部和西南部的某些区域年降雨量可达到约 600 毫米，而中南部和东部的更多地区则能超过 1000 毫米的年降水量，显示出显著的地理分布差异。




图 3.12 降水均值分布图

模型二：Moran' s I 莫兰指数

在进行空间计量之前，通常要进行空间相关性的检验，Moran' s I 莫兰指数，是用来描述空间相关性的一个指数。Moran's I 值范围在 $(-1, 1)$ 之间。Moran's I > 0 表示空间正相关性，其值越大，空间相关性越明显。Moran's I < 0 表示空间负相关性，其值越小，空间差异越大，否则，Moran's I $= 0$ ，空间呈随机性。

$$I = \frac{N}{\sum_i \sum_j \omega_{ij}} \frac{\sum_i \sum_j \omega_{ij} (P_i - \bar{P}) (P_j - \bar{P})}{\sum_i (P_i - \bar{P})^2} \quad (3.11)$$

其中， P_i 和 P_j 是第 i 和第 j 个区域的降水量， ω_{ij} 是空间权重矩阵，用于衡量区域 i 和 j 之间的空间邻近性， $\bar{P}$ 代表降水量的总体平均值， N 是总区域数。




图 3.13 Moran's I 莫兰指数折线图

从 Moran's I 指数值上我们可以看出这 30 年降雨量在中国境内空间整体表现出轻微的正向空间自相关性，且这种空间自相关性在 2000 年和 2015 年附近产生最大正相关性。

模型三：基于变差系数 CV 的年际统计特征

变差系数 (Coefficient of Variation, CV) 又称“离散系数”，年际变化率可以反映变化速度，是概率分布离散程度的一个归一化量度。其值能够反映年降水量的年际变化规律，能够表征某一地区降水的年际变化程度。CV 的大小反映了年降水量的逐年变化的相对大小。通过标准差和平均值的比率来消除变量的维数，即在计算时消除了测站本身降水的差异性。

$$CV = \frac{\sigma}{R} = \frac{1}{R} \sqrt{\frac{1}{n-1} \sum (R_i - R)^2} \quad (3.12)$$

CV 值用于不同组别数据的离散程度，当计量单位或平均数不同时，比较其变异程度就不能直接采用标准差，而采用变异系数来比较。通常，变异系数越小，说明数据的变异程度越小。由于数据集是逐日数据，每年的年均降水量不同，因此适用 CV 来描述降雨的空间特征。图3.14呈现出由西到东逐渐减小的空间分布特征，而年降水则呈现出由西南向东递增的分布特征，二者具有相反的空间分布特征。

3D Coefficient of Variation (CV) of Annual Precipitation (1990-2020)




图 3.14 CV 值热力图

模型四：空间特征演化的显著性检验

为了深入探究中国选定时期内不同地区降水的演变趋势，本研究首先对中国各地区原始的降水数据实施了 5 年滑动平均技术，以平滑短期波动并突出长期趋势。随后，利用线性回归分析对这些处理后的降水量数据进行建模，所得结果作为不同地区的降雨量变化长期特征指标。为了验证这些趋势的显著性，我们采用了 Mann-Kendall 非参数检验方法，该方法因其无需预设数据分布的特性，在气候统计学的应用领域中具有广泛认可度和实践基础。本研究将显著性检验的门槛提升至 95% 置信水平，旨在确保所识别的降水不同地区变化趋势具备更高的统计可靠性和显著性。如图 1990 年至 2020 年间平均降水量的空间分布图3.15左图展示 95% 置信水平的显著性检验结果，图3.15右图的空间图放大了显著区域，显示了降水量的空间变异性。




图 3.15 1990 年至 2020 年间平均降水量的空间分布 95% 置信水平的显著性检验结果

3.4 子问题二：分析土地利用/土地覆被类型的时空演化特征

3.4.1 模型构建与分析

模型一：土地利用动态度

土地利用动态度可以定量地表示土地利用的变化速度,能够预测未来的土地利用变化趋势,分别使用单一土地利用动态度、综合土地利用动态度、土地利用变化强度、土地利用开发度、土地利用耗减度得到土地利用/覆被变化描述指数值,全面发掘田地、森林、草地、灌木、湿地及水体等土地覆被类型在时间轴上的动态演变图景,特别是湿地与水体的增减互动,为土地管理和生态保护策略的制定提供了深刻洞察。

(1) 单一土地利用动态度 (K)。

单一土地利用动态度 (K) 是衡量某一特定土地覆被类型在单位时间内面积变化幅度的指标。K 值的大小直接反映了该土地覆被类型变化的剧烈程度: K 值越小,表明该类型土地在单位时间内的面积变化越为微弱;反之, K 值越大,则意味着其面积变化越为剧烈。

$$K = \frac{1}{T} \left(\frac{U_b - U_a}{U_a} \right) \times 100\% \quad (3.13)$$

(2) 综合土地利用动态度 (LC)

综合土地利用动态度 (LC) 是衡量研究区域内整体土地利用变化速度和强度的一个指标。它的计算公式提供了一种量化评估土地利用变化速率的方法,能够反映出在一定时间段内,研究区内不同土地利用类型之间相互转换的活跃程度和总体变化速率。简而言之, LC 值越高,表明该区域的土地利用变化越频繁、越剧烈。

$$LC = \frac{1}{T} \left(\frac{\sum_{i=1}^n (\Delta LU_{ij})}{2 \sum_{i=1}^n LU_i} \right) \times 100\% \quad (3.14)$$

其中： LU_i 为研究时段内初期的 i 类土地覆被类型的面积； ΔLU_{i-j} 为研究时段内 i 类土地覆被类型转换为 j 类 (j 类, 非 i 类) 土地覆被类型的面积； n 为土地覆被类型分级数； T 为研究时长。

(3) 土地利用变化强度 (Q 值)

土地利用变化强度 (Q 值) 是衡量人类活动对土地覆盖类型影响程度的一个重要量化指标，它反映了在特定时间段内，不同土地覆盖类型面积变化的剧烈与否。具体来说，Q 值的大小直接关联到土地覆被类型变化的显著程度：Q 值越小，意味着在该时间段内，土地覆被类型的转变或面积变化相对平缓，变化强度较弱；反之，Q 值越大，则表明土地覆被类型经历了更为显著的变化，变化强度更为剧烈。

$$Q = \left(\frac{U_a - U_b}{U_{\text{total}}} \right) \times 100\% \quad (3.15)$$

(4) 土地利用开发度 (LUD)

土地利用开发度 (LUD) 表示一定时间范围内某土地覆被类型面积的增加情况，以单位时间内某土地覆被类型新增加的面积与研究初期该土地覆被类型面积的比值来表达。其计算公式为：

$$LUD = \left(\frac{X_{ab}}{U_a} \frac{1}{T} \right) \times 100\% \quad (3.16)$$

其中： X_{ab} 为从时刻 a 到时刻 b 的研究时段内其他土地覆被类型转变为该土地覆被类型的面积之和。

(5) 土地利用耗减度 (LUC)

土地利用耗减度 (LUC) 是衡量在一定时间跨度内，特定土地覆被类型面积减少程度的指标。它通过计算单位时间内该土地覆被类型新减少的面积与研究初期该土地覆被类型总面积的比例来得出。换句话说，LUC 值反映了某种土地覆被类型在研究期间内消失或转化为其他类型的速度或强度。

$$LUC = \left(\frac{J_{ab}}{U_a} \frac{1}{T} \right) \times 100\% \quad (3.17)$$

其中： J_{ab} 为从时刻 a 到时刻 b 的研究时段内由该土地覆被类型的面积转换为其他土地覆被类型的面积之和。

(6) 土地利用程度综合指数 (Z)

土地利用程度综合指数 (Z) 是一个综合性的度量指标，它旨在全面反映研究区域内土地利用的变化趋势和集约利用水平。这个指数通过整合多种土地利用类型的信息，评估了土地在不同使用方式下的综合开发强度和效率，从而为土地利用程度的综合评价提供了量化依据。

$$Z = 100 \times \left(\sum_{i=1}^n A_i C_i \right) \quad (3.18)$$

通过对 1990 年-2020 年土地利用/土地覆被类型数据集进行以上指标的分析，得到下表的结果。

表 3.4 土地利用 / 覆被描述指数值 (单位: %)

		田地	森林	草	灌木	湿地
单一土地利用率	1990-2000	0.017758	2.561795	-0.336966	-0.650894	-1.153579
	2000-2010	-0.346666	2.105965	-0.364588	-0.432412	-1.323177
	2010-2020	0.209042	1.040309	-0.30412	-0.427508	-0.932658
综合土地利用动态	1990-2000			0.18585		
	2000-2010			0.198		
	2010-2020			0.128396		
土地利用强度变化	1990-2000	0.002599	0.316911	-0.179147	-0.11375	-0.026613
	2000-2010	-0.050556	0.334266	-0.186621	-0.070475	-0.026613
	2010-2020	0.029459	0.202413	-0.149542	-0.066328	-0.016001
土地利用开发度	1990-2000	0.19089	2.623178	0.029117	0.017411	0.024277
	2000-2010	0.096746	0.000951	0.043703	0.058419	0.150114
	2010-2020	0.100119	0.000775	0.045494	0.061367	0.175987
土地利用 耗减度	1990-2000	0.173131	0.061382	0.366083	0.668305	1.177856
	2000-2010	0.106546	0.153398	0.014705	0.010403	0.003094
	2010-2020	0.11026	0.125137	0.015308	0.010928	0.003627

分析上表得到如下结论：

(1) 单一土地利用率：在 1990-2000 年期间，耕地和林地的单一土地利用率指数分别呈现正增长，而草、灌木和湿地则呈现负增长；2000-2010 年期间，耕地的单一土地利用率

指数下降，森林增长放缓，其他类型土地继续减少；2010-2020 年期间，耕地的单一土地利用指数有所回升，森林增长减缓，而草、灌木和湿地的减少趋势有所缓解。

(2) 在 1990 至 2000 年间，草和灌木的动态指数呈上升趋势，显示出草和灌木利用动态的增加；2000 至 2010 年间，草的动态指数继续增长，而灌木动态指数缺失，但推测变化不大；2010 至 2020 年间，草的动态指数出现下降，反映出草的利用动态减缓。

(3) 在 1990 至 2000 年期间，田地的土地利用强度变化指数轻微上升，而森林的强度变化指数显著增加，显示出森林利用强度的明显增长；草、灌木和湿地的强度变化指数则为负值，表明这些土地类型的利用强度下降。2000 至 2010 年期间，田地的土地利用强度变化指数转为负值，森林增长速度减缓，而草、灌木和湿地的利用强度进一步下降。2010 至 2020 年期间，田地的土地利用强度变化指数有所回升，森林增长速度继续放缓，草、灌木和湿地的利用强度减少趋势有所缓解。

(4) 土地利用开发度：在 1990-2000 年期间田地的土地利用开发度显著增加，而 2000-2010 年期间增长速度有所放缓，2010-2020 年期间田地开发度有所回升，尽管森林、草地、灌木和湿地的开发度指数在三个时期均为正值，但整体增长幅度呈现减缓趋势。

(5) 土地利用耗减度：从 1990 至 2000 年，耕地的土地利用耗减度上升，而森林、草地、灌木和湿地的耗减度指数亦呈正增长，表明这些土地类型面积减少；2000 至 2010 年，耕地耗减度下降，但其他土地类型的耗减速度加快；2010 至 2020 年，耕地耗减度小幅回升，而其他土地类型的耗减幅度有所减缓。




图 3.16 1990-2020 每隔 5 年的土地覆被类型变化

图中，橙色部分表示田地，深蓝色森林，浅蓝色表示绿地，红色表示灌木，黄色表示湿地。如图中绿色框图对比可以看出，这 30 年东南地区的灌木面积在逐渐减少，如图中黑色框图对比可以看出，森林面积得到改善，东南地区森林面积逐渐变大。

在 1990 至 2019 年的三十年间，耕地和林地的土地利用和开发呈增长趋势，而草、灌木和湿地则呈减少趋势，土地利用强度变化和开发度的波动揭示了土地利用的动态性和复杂性，尤其是林地的显著增长，而土地利用耗减度的正增长则警示了土地资源的减少，强调了对土地资源可持续利用和保护的需求。

模型二：Theil-SenMedian 趋势分析

Theil-SenMedian 趋势分析是一种分析时间序列数据斜率趋势的非参数估计方法。Theil-SenMedian 趋势分析与其他趋势分析相比，突变数据对研究结果影响较小，适用与在某一年变化较大的趋势分析。通过该方法计算二十年间中国气候以及植被 NPP 逐像元的变化斜率，从而得到气候和植被 NPP 值逐年的时空变化趋势，分析其二十年间的变化。Theil-SenMedian 趋势分析计算公式如下所示：

$$\text{Slope} = \text{Median} \left(\frac{x_j - x_i}{j - i} \right) \quad (3.19)$$

x_j 和 x_i 分别表示 j 年和 i 年的像元值， n 为时间序列长度。Slope 值反映了变化趋势， $\text{slope} \geq 0$ 表示呈上升趋势，反之为下降趋势。

中国依据地理位置可划分为六大行政区：东北、北部、东部、中部、中南以及西南和西北地区。图??清晰展示了这些区域在年平均净初级生产力（NPC）方面的显著差异。具体而言，中部与南部地区展现出最高的 NPC 水平，平均达到 668 GC/ (M2 · a)，而西北地区则相对最低，平均仅为 109 GC/ (M2 · a)。在全国范围内，植物净初级生产力（NPP）的分布格局呈现出自东南向西北递减的趋势，且东部与西部的 NPP 相对较低，而南部与北部的 NPP 则呈现出南高北低的态势。

从植被类型来看，南部地区以森林和耕地为主，得益于其低纬度、高年降雨量和温暖的气候条件，该地区的年平均植被效率较为优越。相比之下，北部地区则以草地、农田和森林为主要植被类型，其较高的纬度导致年温度和降雨量均低于南部，从而影响了植被的净初级生产力。

进一步观察 2001 年至 2020 年这二十年间中国各地区植物 NPP 的变化趋势，可以发现中国北部、东北部以及中南部的 NPP 增长率均超过了全国平均水平。其中，中国北部的增长尤为显著，其年均增长率高达 3.88 Hz/ (m², a)，位居全国之首。东北地区紧随其后，年增长率为 2.64 Hz/ (m², a)。相比之下，东部、西南部和西北部地区的 NPP 增长率则低于全国平均，特别是西北地区，其增长率最低，仅为 1.4 Hz/ (m² · a)。这一变化趋势反映了不同区域在生态环境保护和植被恢复方面的成效差异。




图 3.17 1990—2020 年中国区域植被 NPP 年际变化图

在 2001-2020 年的两个十年间??，中国六大主要地区的植被净初级生产力（NPP）增长率普遍上升，但存在显著差异。第一阶段（2001-2010 年），仅中国东部地区 NPP 出现负增长；而第二阶段（2011-2020 年）则全面增长。对比两阶段，中国北方、东北和西北地区的 NPP 增长率在第一阶段就高于南方、东部和西南地区，且第二阶段继续领先，但增长率较第一阶段有所下降。相反，东部、中部和西南地区的 NPP 增长率在第二阶段显著上升，特别是东部和南部地区，增长率提升尤为明显。中国北方在第一阶段的 NPP 增长率显著高于第二阶段，差距达 $2.21 \text{ Hz}/(\text{m}^2 \cdot \text{a})$ 。而东部、南部和西南地区的 NPP 增长率则在第二阶段大幅提升，分别增长了 $3.97 \text{ Hz}/(\text{M}^2 \cdot \text{A})$ 、 $1.25 \text{ Hz}/(\text{M}^2 \cdot \text{A})$ 和 $0.97 \text{ Hz}/(\text{M}^2 \cdot \text{A})$ 。这种地区间 NPP 增长率的变化可能归因于气候差异、气候变化的时间性、经济发展速度的差异以及人类活动的不同影响。总体而言，过去一段时间里，北部等地区的 NPP 增长率保持高位，而南部等地区则在近期表现出更高的增长率。




图 3.18 1990—2020 年中国六大区域植被 NPP 年际变化图

如图3.18所示，西北地区的 NPP 植被增长率有所下降，将 1990-2010 年期间的 NPP 植被变化率与 2011-2020 年期间的 NPP 植被变化率进行了比较。中国北方的植物 NPP 增长率从较高转向较低，整个地区的增长趋势仍在继续；西北地区东部地区从快速增长转向缓慢增长，而西北地区西部地区的增长率保持稳定，前十名的总体增长趋势有所下降；中国西南部东部和南部地区植物 NPP 增长增加，而其他地区变化不大，总体增长率上升；在中国东部，南部大部分地区的下降趋势呈上升趋势，植被 NPP 变化的总体速度显著变化；中部和南部地区植被覆盖率增益的区域差异不大。




图 3.19 1990—2020 年中国六大区域植被 NPP 变化趋势空间分布

根据图??趋势分析和植物净初级生产力（NPP）的重要性评估，中国大部分地区在过去二十年间维持了相对稳定的植物 NPP 水平。从植被覆盖率的角度来看，全国平均植被覆盖率为 74.6%，而各地区之间存在显著差异。具体而言，中国东北地区的植被覆盖率最高，达到了 97.3%，紧随其后的是中南部地区，为 94.6%，而西北地区的植被覆盖率则相对较低，仅为 47.7%。

从整体上观察，中国六大行政区的植被趋势呈现出由东向西逐渐递减的趋势。具体来说，东北地区的植被状况最为优越，其次是中南地区、中国东部地区、西南地区、中国北部地区，最后是西北地区。这一分布模式反映了中国不同区域在生态环境和植被保护方面的差异。

3.5 特征总结

我们分别从多指标、多维时空分析模型来描述降水量和土地利用/覆被在 1990-2020 年间的时空演化特征，通过结合时间序列、空间自相关分析、95% 置信水平显著性检验等方法。使用经过克里金 (Kriging) 插值、栅格矢量化、叠加分析等预处理的数据，在指标选择上除了常规降雨量指标外，使用了 Moran's I、变差系数 (CV)，建立了 ARIMA 模型、长短期记忆网络 (LSTM) 神经网络模型。模型结果表明，中国降水量具有显著的空间异质性和时间变异性，土地利用/覆被变化则具有明显的区域差异性。

1990-2020 年间降水量和土地利用/覆被的时空演化特征有：

1、降水季节性波动：通过对四个季节降水距平的对比分析，我们可以明显观察到：在西北地区，降水量的季节性波动主要集中于夏季，表现为显著的变异性，而相比之下，春季、秋季及冬季的降水量则展现出较为平稳的趋势，波动幅度较小。这揭示了西北地区降水特征的季节性集中现象。转而观察华北地区，其四季降水距平普遍高于西北地区，这一发现揭示了华北地区降水具有更高的不确定性。具体而言，华北地区的降水在春季、夏季及秋季均呈现出大幅度的波动，显示出强烈的季节性和不稳定性。然而，在冬季，华北地区的降水距平则与西北地区相接近，波动较为平缓，变化不大。

2、年降水量趋势：在年降雨量变化趋势上，呈现出较为分散的特点。那些经历着年降雨量普遍增加的区域，主要集中在东北至东部、东南至东南以及东南至南部的地带。其中，东北地区的年降雨量增长趋势尤为显著，达到了 79.98% 的增长率，位居全国之首。紧随其后的是中国北部地区，年降雨量增长率也达到了 70.07%。

3、降水长期趋势：1990 ~ 2020 年，中国年均降水量呈增加趋势，平均每 10 年增加 5mm；1990-2000 年间降水量以偏多为主，21 世纪最初十年总体偏少，2012 年持续增多。2020 年，中国平均降水量为 694mm，较常年值偏多 10% 左右。1990 ~ 2020 年，中国平均年降水日数呈显著减少趋势。图??展示了中国降水趋势的复杂分布情况，其年降水变化率范围广泛，从 -37.3mm/a 的减少趋势到 26.6mm/a 的增加趋势不等，且空间分布极不均衡。具体来说，中国降雨较少的区域占据了总降雨量的较大比例，达到了 57.55%，而降雨量相对丰富的区域则占据了剩余的 42.45%。

4、降水极端事件：1990 年来中国极端强降水事件呈增多趋势，累计暴雨数呈增加趋势；2020 年，中国年累计暴雨站日数为 1990 年以来第二多。华北平原地区分钟级别降水的极端性也高于江南丘陵地区。总体来看，中国大陆每分钟的降水并未趋向于极端化，极端降水量的增加可主要归因于暴雨过程持续时间的增加。

5、降水空间演化特征：中国不同等级降水变化的空间分布差异较大。弱降水仅在西北部 and 青藏高原地区以增加为主，在华南和西南地区以显著减少为主；中等强度降水在西南地区东部以显著减少为主，在其余地区以增长为主；强降水在大部分地区呈现增长趋势，仅在京津冀和重庆部分地区呈现减少趋势。特别是西北地区，其年降雨量减少的比例

最高，达到了 73.48%，成为全国范围内降雨量减少最为明显的区域。此外，西南地区的年降雨量减少比例也相对较高。相比之下，中国南部和东部地区的年降雨量变化趋势则较为平稳，大约占据了全国的一半左右，即约 50% 的区域其年降雨量变化率处于相对较低的水平。

6、土地利用/土地覆被类型的时间变化特征：从时间维度看，这一时期内，耕地和林地的单一土地利用指数正增长，反映出这两类土地的开发利用强度在增强，而草、灌木和湿地则出现负增长，表明其面积在减少。同时，森林的土地利用强度变化指数显著增加，显示出森林利用强度的明显提升。此外，田地的土地利用开发度也显著增加，进一步证实了土地开发活动的加剧。

7、土地利用/土地覆被类型的空间变化特征：在空间分布上，这些变化并非均匀分布，而是呈现出区域性的差异，特别是耕地和林地的扩张往往与人口密集区和经济活动中心相关联，而草、灌木和湿地的减少则可能发生在生态环境较为脆弱的区域。在 2001-2020 年的两个十年间（图 5-6），中国六大行政区的植被净初级生产力（NPP）增长率普遍上升，但表现各异。第一阶段（2001-2010 年），仅中国东部出现 NPP 负增长。对比两阶段，北方、东北和西北地区的 NPP 增长率在第一阶段就高于南方、东部和西南，且第二阶段继续领先，但增长率较第一阶段有所下降。相反，东部、中部和西南地区的 NPP 增长率在第二阶段显著提升。特别地，中国北方在第一阶段的 NPP 增长率远高于第二阶段，两者相差 $2.21 \text{ Hz}/(\text{m}^2 \cdot \text{a})$ 。而东部、南部和西南部的 NPP 增长率在第二阶段较第一阶段有大幅提升，分别增长了 $3.97 \text{ Hz}/(\text{M}^2 \cdot \text{A})$ 、 $1.25 \text{ Hz}/(\text{M}^2 \cdot \text{A})$ 和 $0.97 \text{ Hz}/(\text{M}^2 \cdot \text{A})$ 。这种地区间 NPP 增长率的差异，可能归因于气候条件的差异、气候变化的时间性、经济发展速度的变化以及人类活动的不同影响。总体来看，这一时期土地利用/土地覆被类型的变化呈现出以耕地和林地扩张为主导，同时伴随着草、灌木和湿地减少的趋势，且这种变化在时间和空间上均存在显著差异。

4 问题二：地形-气候影响极端天气的建模分析与求解

4.1 问题分析




图 4.20 地形-气候对极端天气形成的影响建模流程图一

问题二的目标是分析地形-气候对极端天气形成的影响。为了探究三者之间的数学关系，我们使用了基于差分模型的权重归因分析方法。将问题分解为三个部分：首先，数据处理阶段，在这一阶段中我们需要对数据进行预先处理，在空间时间上统一数据规格，并将数据转化为标准化参数指数；其次，数学模型构建，在本文中我们使用了三维高斯模型来拟合地形-气温-降雨这三者之间的互相影响。并定义了极端天气的回归周期，在此基础上我们还进一步扩展，对危害更大的混合极端天气进行了建模；建模完成后我们采用了差分模型来分析各个参数因子（地形-气温-降雨）对于极端天气的影响因子。流程图如下图所示。




图 4.21 地形-气候对极端天气形成的影响建模流程图二

我们还采取了另一种方案对这一问题进行建模，在这一方案中我们首先提取了地形数据，包括海拔、坡度、坡向等，并对地形数据进行回归分析。并定义了极端天气 EPI。通过随机森林算法输出了极端事件 P 的概率。通过差分分析法分析了气流对降水的影响因子 $\frac{dqs}{dz}$ 和 $\frac{dT}{dz}$ 等。然后通过 stacking 集成算法对三个模型的产出进行集成，得到了地形-气候对极端天气形成的建模影响因子。

4.2 数据分析及预处理

4.2.1 数据集选择

1、降水量数据集 (中国大陆 0.25° 逐日降水数据集,1961-2022 年)，提取其中 1990-2020 年降雨量数据。

2、土地利用/土地覆被数据集 (中国 0.5° 土地利用和覆盖变化数据集，1900-2019 年)，提取其中 1990-2020 年数据。

3. 气温数据集 (中国大陆 0.1° 近地表气温数据集，1979-2018 年)，提取其中 1990-2020 年气温数据。

4.2.2 数据分析

为了明确建模需求，本文首先对使用到的数据进行特征分析。在本题中将会使用 3 个数据集合分别为中国数字高程图 (1km)、中国 0.1° 近地表气温数据集及中国大陆 0.25° 逐日降水数据集。中国数字高程图 (1km) 数据集使用两种投影方法，通过 DEM 提取大量地表形态信息，从此数据集中我们能够获取单元网格的坡度、坡向等局部地形特征。中国

0.1° 近地表气温数据集以日为单位记录了以 0.1° 经纬度变化为单位的每日平均气温。中国大陆 0.25° 逐日降水数据集以 0.25° 经纬度变化为单位的每日平均降雨量。

4.2.3 数据预处理

该问题的求解，涉及到三个数据集的使用。数据预处理共分为四个步骤。第一步，因为三个数据集之间的单位面积、时间并不相同因此首先需要统一数据集之间的单位面积，采用向上取整的方式将中国 0.1° 近地表气温数据集及中国大陆 0.25° 逐日降水数据集中的单位面积统一为 0.5° 经纬度，中国数字高程图（1km）需要通过距离与经纬度换算算法处理后也将其转化为 0.5° 经纬度数据；第二步，将 0.1° 近地表气温数据集及中国大陆 0.25° 逐日降水数据两个数据集在时间维度对齐；第三步，去除多余数据，三个数据（1km）集有的包含了某些经纬度格点，但有的数据集并不包含。因此统一去除掉三个数据集不完整的经纬度点位，在时间维度上进行同样处理，去除掉缺失数据时间点；最后，中国数字高程图（1km）并不具备时间特性，经过文献查询我们可知晓地形是最为稳定、不易改变的因素，因此我们并不需要将这个数据集补充为时序数据集，而是直接将该数据使用于每一个时间节点。

4.3 模型一：构建元高斯模型中极端时间重现期的全微分方程

与单独的极端气候事件相比，并发性复合干旱与高温事件（CDHEs）对生态系统与人类社会的破坏性更为显著。随着气候变化的加剧，全球范围内此类复合事件的频率正不断增加。本文提出了一种创新的数学方法，该方法依托于元高斯模型，通过构建 CDHEs 重现期的全微分方程，精确地将 CDHEs 的变化量化为降水变化、温度变化以及两者间相互依赖关系变动的结果。

降雨数据和温度数据都随着时空变化具有时空异变性和强不可控性。如果直接使用降水量这一指标，在不同时间节点上难以直接进行比较，因此我们需要将这些数据标准化。在本节中将会分别介绍我们将三种数据标准化的过程及趋势分析。

1、参数标准化

（1）标准化降水指数与标准化温度指数

SPI（Standardized Precipitation Index，标准化降水指数），是指由于不同时间、不同地区降水量变化幅度很大，直接用降水量很难在不同时空尺度上相互比较，而且降水分布是一种偏态分布，不是正态分布，所以在降水分析中，采用 r 分布概率来描述降水量的变化，然后再经正态标准化求得 SPI 值。STI（Standardized temperature Index，标准化温度指数）与标准化降水指数计算方法类似。也是通过正态分位数转换算法来计算出温度的正态标准化分布。

计算方式为通过计算降水量/温度的累积分布函数计算出所有小于等于某一值的数据量出现的概率的和。然后通过标准正态分布的逆累积分布函数将它映射到标准正态分布

中。通过这两个计算后就得到了具有标准正态分布的 SPI 和 STI 的正态分布函数，便于后续分析。后续使用 $\bar{X}$ 表示 SPI， $\bar{Y}$ 表示 STI。以下是标准化降水指数与标准化温度指数的计算公式：

$$\bar{X} = \Phi^{-1}(CDF(x)) \quad (4.20)$$

$$\bar{Y} = \Phi^{-1}(CDF(y)) \quad (4.21)$$

在上列式子中， $CDF(\cdot)$ 表达的是累积分布函数，该函数的作用是将数值进行一个转化，转化为其在正态分布中百分位的位置。 Φ^{-1} 是标准正态分布的逆类积分分布函数。其作用是将计算出来的百分位再次计算后转化为标准正态分布中的数值。

(2) 标准化地形指数

地形指数并没有找到相似的标准化指数。因此我们参考上节中类似方法。也同样通过累积分布函数与标准正态分布的逆累积分布函数将它映射到标准正态分布中并将标准化地形指数称为 (SGI, Standardized ground Index)。后续使用 $\bar{Z}$ 表示 STI。以下是标准化地形指数的计算公式：

$$\bar{Z} = \Phi^{-1}(CDF(z)) \quad (4.22)$$

2、趋势分析

趋势分析法基于已知信息，通过定量的数学工具，判断事物未来的发展趋势。它通过对于对同时期的同一指标的数据进行比较，得出标准化指数的增减变动、发展趋势与相关性系数。在本文中为评估上述标准化指数的趋势和相关性，在本节中我们引入了两种趋势检验法分别为 Theil-Sen Median 斜率估计法和 Mann-Kendall 趋势分析法。

(1) Mann-Kendall 趋势分析法

Mann-Kendall 趋势分析法可用于分析中心趋势不稳定的时间序列，它通过数据的秩，而不是数据本身进行分析。因此它是一个非参数检验，适用于所有的分布 (即数据不需要满足正态分布的假设)，其优点在于其不要求样本遵从一定的分布，也不受少数测量误差和离群值的干扰。常用于对降水、气温和径流等要素时间序列变化趋势和突变点分析。但在使用的过程中，需要注意该分析方法的数据应该不存在序列相关性，如果数据具备序列相关性，则产生显著性的影响。以下是该分析方法的计算公式：

$$\beta = Median\left(\frac{O_j - O_i}{j - i}\right) \quad (4.23)$$

在上列式子中， O_i 和 O_j 表达的是在 i 和 j 两个时间点的数据观测值。

(2) Theil-Sen Median 斜率估计法

Theil-Sen Median 方法，也称为 Sen 斜率估计，是一种稳健的非参数统计趋势计算方法，广泛应用于数据分析领域。优点是较高的计算效率，能够有效处理具有测量误差和离

群值的数据。因此该方法适合用于大数据长时间的时间序列数据的趋势分析，能有效降低测量误差和离群数据的干扰。该方法通过计算数据集中两点之间的斜率来估计数据的趋势。这些斜率的中位数被用于最终的趋势估计，从而达到削弱测量误差和离群数据的影响，与上一种方法相比这种方法能够处理具备时间序列相关性的数据。以下是该分析方法的计算公式：

$$S = \sum_{i=1}^{m-1} \sum_{j=i+1}^m \text{sign}(O_j - O_i) \quad (4.24)$$

3、三维高斯模型构建

在上述标准化数据指数完成之后我们得到了数据集的分布情况，首先我们将数据的分布表示为多个高斯模型分布的组合，每个高斯模型都有自己的均值和方差，模型通过使用相关系数和加权来用这些单个的高斯模型分布计算得出一个复杂的三维高斯模型分布。三维高斯模型标准化降水指数、标准化温度指数及标准化地形指数的联合分布函数如下所示：

$$\begin{bmatrix} \bar{X} \\ \bar{Y} \\ \bar{Z} \end{bmatrix} \sim N \begin{bmatrix} \mu_x \\ \mu_y \\ \mu_z \end{bmatrix} \begin{bmatrix} \sigma_x^2 & P_{xy}\sigma_x\sigma_y & P_{xz}\sigma_x\sigma_z \\ P_{xy}\sigma_x\sigma_y & \sigma_y^2 & P_{yz}\sigma_y\sigma_z \\ P_{xz}\sigma_x\sigma_z & P_{yz}\sigma_y\sigma_z & \sigma_z^2 \end{bmatrix} \quad (4.25)$$

在上列式子中， μ 表示的是数据集 SPI、STI 和 SGI 的均值， σ 表示的是数据集 SPI、STI 和 SGI 的平均值。 P_{xy} 表示的是 SPI、STI 和 SGI 的相关性系数。

4、极端天气数学模型构建

在本节中主要考虑四种单一极端天气，及高温、极寒、干旱、暴雨。并使用返回周期来对其进行描述。返回周期是指在某一个时间段内发生某些重大事件的平均频率，在项目管理中常被用于评估产品风险、能帮助管理者提高产品质量，提高对于将要到来的风险的应对准备。在本文中返回周期被定义为联合概率的倒数，下列公式分别对应极寒、高温、干旱、暴雨等事件的返回周期。

$$r_{x1} = \frac{1}{Pr(\bar{X} \leq \theta_{x1})} = \frac{1}{\Phi\left(\frac{\theta_{x1} - \mu_{x1}}{\sigma_{x1}}\right)} \quad (4.26)$$

$$r_{x2} = \frac{1}{Pr(\bar{X} > \theta_{x2})} = \frac{1}{1 - \Phi\left(\frac{\theta_{x2} - \mu_{x2}}{\sigma_{x2}}\right)} \quad (4.27)$$

$$r_{y1} = \frac{1}{Pr(\bar{Y} \leq \theta_{y1})} = \frac{1}{\Phi\left(\frac{\theta_{y1} - \mu_{y1}}{\sigma_{y1}}\right)} \quad (4.28)$$

$$r_{y2} = \frac{1}{Pr(\bar{Y} > \theta_{y2})} = \frac{1}{1 - \Phi\left(\frac{\theta_{y2} - \mu_{y2}}{\sigma_{y2}}\right)} \quad (4.29)$$

在上列式子中, r_{x1} 表示极寒天气重现期既为 SPI 小于阈值 θ_{x1} 的概率的倒数、 r_{x2} 高温天气重现期既为 SPI 大于阈值 θ_{x2} 的概率的倒数、 r_{y1} 干旱天气重现期既为 SPI 小于阈值 θ_{y1} 的概率的倒数、 r_{y2} 暴雨天气重现期既为 SPI 小于阈值 θ_{y2} 的概率的倒数。 $x1$ 表示极寒的阈值, $x2$ 表示高温的阈值, $y1$ 表示干旱的阈值, $y2$ 表示暴雨的阈值。

5、混合极端天气数学模型构建

混合极端天气作为一种危害性更高的极端天气, 对其的分析具有更大的指导意义。在上一节的基础之上, 在本节中我们将建立混合极端天气的数学模型, 即高温干旱、高温暴雨、极寒干旱及极寒暴雨返回周期。公式如下所示。

$$r_{x1y1} = \frac{1}{Pr(\bar{X} \leq \theta_{x1}, \bar{Y} \leq \theta_{y1})} = \frac{1}{\Phi_3\left(\Phi^{-1}\left(\frac{1}{r_{x1}}\right), \Phi^{-1}\left(\frac{1}{r_{y1}}\right), \bar{Z}, \sum P\right)} \quad (4.30)$$

$$r_{x1y2} = \frac{1}{Pr(\bar{X} \leq \theta_{x1}, \bar{Y} > \theta_{y2})} = \frac{1}{\frac{1}{r_{x1}} - \Phi_3\left(\Phi^{-1}\left(\frac{1}{r_{x1}}\right), \Phi^{-1}\left(1 - \frac{1}{r_{y1}}\right), \bar{Z}, \sum P\right)} \quad (4.31)$$

$$r_{x2y1} = \frac{1}{Pr(\bar{X} > \theta_{x2}, \bar{Y} \leq \theta_{y1})} = \frac{1}{\frac{1}{r_{y1}} - \Phi_3\left(\Phi^{-1}\left(1 - \frac{1}{r_{x2}}\right), \Phi^{-1}\left(\frac{1}{r_{y1}}\right), \bar{Z}, \sum P\right)} \quad (4.32)$$

$$r_{x2y2} = \frac{1}{Pr(\bar{X} > \theta_{x2}, \bar{Y} > \theta_{y2})} = \frac{1}{\Phi_3\left(\Phi^{-1}\left(1 - \frac{1}{r_{x2}}\right), \Phi^{-1}\left(1 - \frac{1}{r_{y2}}\right), \bar{Z}, \sum P\right)} \quad (4.33)$$

在上列式子中, $\Phi^{-1}(\cdot)$ 表示表示一维正态分布函数的标准单变量的逆累积分布函数的反函数, $\Phi_3(\cdot)$ 表示三维正态分布函数的标准单变量的逆累积分布函数, $\bar{Z}$ 表示 STI 标准化地形指数对于三维正态分布的影响系数, $\sum P$ 表示数据集之间相关性系数的集合, 包含了所有的相关性系数。

6、差分模型

在权重归因分析法中, 差分模型是量化各驱动因素共享的重要方法。

(1) 总微分方程

根据上一小节中的公式, 我们可以看出各种极端天气的返回周期由降水、温度、相关系数 P 等综合决定。如下的公式提出了总微分方程。以高温干旱为例。

$$dr_{xy} = \frac{\partial r_{xy}}{\partial r_x} dr_x + \frac{\partial r_{xy}}{\partial r_y} dr_y + \frac{\partial r_{xy}}{\partial r_z} dr_z + \frac{\partial r_{xy}}{\partial P} dP \quad (4.34)$$

其中 $\frac{\partial r_{xy}}{\partial r_x} dr_x$ 表示了 r_{xy} 对于 dr_x 的贡献度, $\frac{\partial r_{xy}}{\partial r_y} dr_y$ 表示了 r_y 对于 dr_x 的贡献度, $\frac{\partial r_{xy}}{\partial r_z} dr_z$ 表示了 r_z 对于 dr_x 的贡献度, $\frac{\partial r_{xy}}{\partial P} dP$ 表示了 P 对于 P 的贡献度。

(2) 偏导数表达式

对高温干旱情况下的混合极端天气模型进行分析, 可以得到以下权重分析式。

$$\frac{\partial r_{xy}}{\partial r_x} = \frac{r_{xy}^2}{r_x^2} \left(1 - \Phi \left(\frac{\Phi^{-1} \left(1 - \frac{1}{r_y} \right) - P \Phi^{-1} \left(\frac{1}{r_x} \right)}{\sqrt{1 - p^2}} \right) \right) \quad (4.35)$$

$$\frac{\partial r_{xy}}{\partial r_y} = \frac{r_{xy}^2}{r_x^2} \Phi \left(\frac{\Phi^{-1} \left(\frac{1}{r_x} \right) - P \Phi^{-1} \left(1 - \frac{1}{r_y} \right)}{\sqrt{1 - p^2}} \right) \quad (4.36)$$

$$\frac{\partial r_{xy}}{\partial r_z} = \frac{r_{xy}^2}{r_z^2} \Phi \left(\frac{\Phi^{-1} \left(\frac{1}{r_x} \right) - P \Phi^{-1} \left(1 - \frac{1}{r_y} \right)}{\sqrt{1 - p^2}} \right) \quad (4.37)$$

$$\frac{\partial r_{xy}}{\partial r_y} = \Phi_2 \left(\Phi^{-1} \left(\frac{1}{r_x} \right), \Phi^{-1} \left(1 - \frac{1}{r_y} \right); p \right) r_{xy}^2 \quad (4.38)$$

通过上述偏导式可以分析出在特定地区区域条件中给定降雨条件和温度条件时的敏感性权重因子。当通过上一节中的公式建模后, 我们可以利用全周期数据的偏导数量化这些数据集对于联合事件的回归周期的共享度和相对贡献度。分别如下列公式所示。

$$\Delta r_i = \frac{\partial f_{u_i}}{\partial u_i} \times \Delta u_i \quad (4.39)$$

$$\eta_i = \frac{\partial f_{u_i}}{\partial u_i} \times \frac{\Delta u_i}{r_{xyz}} \times 100\% \quad (4.40)$$

在上列式子中, Δu_i 代表某一个参数对于天气预测的驱动权重。 $\frac{\partial f_{u_i}}{\partial u_i}$ 表示收益率对权重因子的偏导数。 Δr 和 η_i 分别表示某一个驱动因素的贡献和相对贡献。

4.4 模型二：极端气候事件相关大尺度物理场的分析

为了深入理解东亚季风强度波动如何影响多样化的极端气候事件，探讨与不同季风强度相关联的大规模大气物理场的变化显得尤为关键。针对夏季极端高温事件（如热日数和热持续时间指数），本研究聚焦于分析 500 百帕和 1000 百帕等压面上的位势高度场以及 1000 百帕的垂直速度变化，这些指标能够揭示夏季副热带高压的位置与强度的潜在变动，进而与地表高温事件的强度和持续时间建立联系。此外，鉴于 700 百帕层温暖平流层对极端温度事件的显著影响，我们还分析了该层的温度分布，以阐释不同季风强度下对流层中部温度变化如何驱动地表极端温度事件的发生。

对于冬季极端低温事件（如霜冻天数和寒冷持续时间指数），本研究则着眼于 300 百帕风场（反映中高纬度西风急流和极地涡旋活动的潜在变化）和 500 百帕高度场（展示东亚大槽位置）的分析，同时结合海平面至 1000 百帕层的温度、压力和流场变化，以探究这些变量如何共同作用于冬季极端低温的形成。

在极端降水事件的分析中，我们重点关注了水平风场、850 百帕垂直速度、静力不稳定条件以及高低层温度平流等物理场变量。特别地，湿静力不稳定性的评估，即 850 至 300 百帕间的等效位温差，是识别对流活动潜在强度的关键。考虑到地形和非绝热加热引起的强垂直风切变可能促进对流的发展，从而引发极端降水，本研究还深入分析了 700 百帕湿涡度的不同分量变化，以期更全面地理解极端降水事件的物理机制。

MPV 计算公式如下：

$$MPV = MPV_1 + MPV_2 \quad (4.41)$$

MPV_1 和 MPV_2 分别为正压项和斜压项：

$$MPV_1 = -g(\xi + f) \frac{\partial \theta_e}{\partial p} \quad (6.2)$$

$$MPV_2 = g \left(\frac{\partial v}{\partial p} \frac{\partial \theta_e}{\partial x} - \frac{\partial u}{\partial p} \frac{\partial \theta_e}{\partial y} \right) \quad (6.3)$$

4.5 模型三：随机森林

4.5.1 模型构建

为说明地形-气候相互作用对极端天气的影响，随机森林算法能有效提升个体决策树的预测准确率，关键在于它通过构建多个决策树并将它们的预测结果进行集成，从而显著降低了单一决策树模型的方差，实现了更稳健、更准确的预测。

在构建随机森林时，通常选择决策树作为基学习器，并引入参数 k 来控制属性选择的随机性， k 值的大小直接影响到模型的随机程度和泛化能力。在降雨量预测这类任务中，合理设置 k 值能够帮助随机森林更好地捕捉数据的复杂模式，进而提升预测的精准度，令：

Algorithm 1 Process and Model Precipitation Data

```
1: 创建输出文件夹"output1"
2: if not exists then output_folder
3:   创建文件夹 output_folder
4: end if
5: 读取 NetCDF 文件 data_path
6: 过滤负值并计算每年平均降水量
7: 数据时间范围限定在 1998 年到 2018 年
8: 读取地形数据 dem_path
9: 剔除地形数据中的负值
10: 计算坡度
11: 初始化数据列表 data_list
12: for year  $\in$  [1998, 2018] do
13:   计算当年降水量
14:   读取对应的气温数据 temperature_path
15:   确保所有数据具有相同的长度
16:   for i in range min_length do
17:     添加数据到列表 data_list
18:   end for
19: end for
20: 转换列表为 DataFrame
21: 数据预处理, 标准化数据
22: 创建二维数组 data_matrix
23: 标准化数据
24: 更新 DataFrame 中的特征
25: 构建响应变量 y
26: 建立模型, 对极端降雨量进行建模
27: 使用最小二乘法 (OLS) 拟合模型
28: 打印模型摘要
29: 关闭数据集
30: 可视化特征分布并保存图像
31: 绘制回归系数并保存图像
32: 绘制实际值与预测值并保存图像
```

$$k = \sqrt{F} \quad (4.42)$$

其中 F 为特征个数, k 为选取的特征子集, 即通过随机选取的方法获取总特征数的平方根个特征作为特征子集, 在这个子集上选择一个最优特征进行划分; 这样可以保证不同树之间的差异性; 假定随机森林模型包含 T 个基决策树 $\nu_1, \nu_2, \dots, \nu_T$, 其中样本 x 在第 i 决策树 ν 上的输出为 $\nu_i(x)$ 。降雨量预测问题使用平均法:

$$\nu(x) = \frac{1}{T} \sum_{i=1}^T \nu_i(t) \quad (4.43)$$

也就是每个样本的输出就是这个样本在其决策树上的均值输出。具体的模型构建如下:

1、数据读取与预处理: 代码从 NetCDF 文件中读取降水量数据, 并计算 1998 年至 2018 年的年平均降水量。地形数据 (海拔) 和气温数据也通过 GDAL 读取并进行了处理, 包括负值剔除。

2、特征计算: 计算了坡度作为额外特征, 以便在模型中考虑地形对降水的影响。

3、数据归一化: 使用 Min-Max 缩放对特征 (海拔、气温、坡度) 进行了归一化, 以提高模型的训练效果。

4.5.2 模型训练与评估

1、模型选择: 使用随机森林回归模型进行降水量预测。

2、模型结果:

Mean Squared Error: 1.9271207951410998

R-squared: 0.16133557771836016

理想情况下, 如图4.22左图的散点图, 点应紧密沿着红色参考线 ($y=x$) 分布, 表示预测准确。若存在较大偏离, 说明模型在某些情况下的预测能力不足。

如图4.22右图的残差图, 用于检查模型是否存在系统性偏差。理想情况下, 残差应随机分布在 0 附近。如果存在模式或趋势, 可能表明模型未能捕捉到某些特征或关系。




图 4.22 模型散点图和残差图

3、模型性能：

- 均方误差 (MSE) =1.93，表示预测值与实际值之间的平均平方差。较低的 MSE 表明模型的预测能力较好，但具体是否满意还需根据数据上下文判断。
- 决定系数 (R^2) =0.16，表明模型只能解释约 16

4.6 模型三：多元线性回归模型

为达到分析地形与气候对暴雨天气形成的相互作用，使用多元线性回归模型，该模型可以根据一些大气因素预测是否会有降雨。

4.6.1 模型构建

叠加气候因素，并结合地形和气候之后，可以建立一个多元线性回归模型，尝试通过以下形式来描述降水量 P ，模型的形式为：

$$\text{Precipitation} = \beta_0 + \beta_1 \times \text{Elevation} + \beta_2 \times \text{Temperature} + \beta_3 \times \text{Slope} + \epsilon \quad (4.44)$$

其中： β_0 表示截距项， β_1 、 β_2 、 β_3 对应与海拔、温度、坡度的回归系数， ϵ 表示误差项。模型构建的步骤如下：

1、数据读取与预处理：

使用 `xarray` 读取 NetCDF 格式的降水量数据。通过 `gdal` 读取下采样后的地形数据（数字高程模型）和气温数据。对于降水量和气温，剔除负值，确保数据的有效性。

2、特征计算：

首先计算坡度，通过对地形数据的梯度计算得到坡度信息，这对于理解水流和降水分布非常重要。

3、数据整合：

将降水量、气温、海拔和坡度等信息整合到一个数据框中，为后续建模做准备。

4、数据标准化：

使用 `StandardScaler` 对特征进行标准化处理，确保各特征在同一量纲下，避免模型训练时某些特征的影响被放大或减弱。

5、模型构建：

使用 `statsmodels` 的 OLS（普通最小二乘法）进行线性回归建模，探索特征与极端降水量之间的关系。

4.6.2 模型结果及评估

多元线性回归模型的模型结果入下图所示：




图 4.23 模型结果图

图4.23中 R-squared (R^2)= 0.078，说明模型对降水量的解释能力较弱，仅能解释约 7.8% 的变异性。这表明，虽然模型能够捕捉一些地形和气候对降水的影响，但还有其他因素未被考虑。分析图4.23中的显著性: 得到，所有特征（海拔、温度、坡度）的 p 值均为 0，说明这些变量对降水量的影响在统计上是显著的。




图 4.24 海拔、气温、坡度回归系数柱状图

如图4.24，Elevation（海拔）其回归系数为正，表示海拔与暴雨天气的形成之间存在正相关关系。也就是说，随着海拔的升高，暴雨天气的形成可能性增加。这可能是由于高海拔地区的气象条件、地形特征或水汽运动方式更有利于暴雨的形成。Temperature（温度）其回归系数为负，表明温度与暴雨天气的形成之间存在负相关关系。即随着温度的升高，暴雨天气的形成可能性降低。这可能是因为高温会促进水汽的蒸发，减少空气中的水汽含量，从而降低了暴雨形成的条件。Slope（坡度）其回归系数同样为负，说明坡度与暴雨天气的形成也呈负相关。这意味着在坡度较大的地区，暴雨天气的形成可能性较低。这可能与坡度对降水分布、地表径流和水汽保持能力的影响有关。




图 4.25 海拔、气温、坡度分布图

如图4.25所示，海拔（Elevation）与一般观察到的海拔与降雨量正相关的现象一致。随着海拔的升高，降雨量可能会增加，直达到一个最大值，之后可能会减少。这可能是由于高海拔地区云层更易形成，导致更多的降水。然而，超过某个点后，由于温度降低可能导致降水以雪的形式出现，而不是雨。温度（Temperature）一图表明在研究的特定区域或

时间段内，温度的升高与降雨量的减少相关。这可能与该地区的气候条件有关，例如，高温可能导致水分蒸发增加，减少了降雨量。然而，这与一般认为的温暖空气能够容纳更多水分的观点相矛盾，表明其他因素（如季风、地形和海洋流）可能在该地区的降雨量形成中起着更重要的作用。坡度（Slope）可能会影响降雨的分布，因为风向和地形会影响云层的移动和降雨的分布，坡度越大降雨量约少。例如，在山区，风向可能会将云层推向山坡的一侧，导致迎风坡的降雨量比背风坡更多。

海拔、气温、坡度各个元素影响暴雨天气的回归系数及分析如下：

表 4.5 海拔、气温、坡度回归系数结果及分析

序号	指标	回归系数	说明	相互作用
1	海拔	-0.0934	表明海拔每增加一个单位，降水量平均减少约 0.0934 单位。	反映了高海拔地区由于气候条件和降水模式的变化，降水量较低的趋势。
2	温度	-0.3514	说明温度每增加一个单位，降水量平均减少约 0.3514 单位。	这与气温升高导致的蒸发增加有关，进而影响降水的形成和强度。
3	坡度	-0.053	表示坡度每增加一个单位，降水量平均减少约 0.0530 单位。	较陡的坡度会影响降水的分布和流失，导致局部降水量的减少。

从图5.37中可以看出，橙色点并未紧密围绕在黑色虚线周围，而是呈现出一种较为散乱的分布状态。这表明模型的预测值与实际观测值之间存在较大的偏差，说明该模型的预测准确性不高。尽管横轴（预测值）在增加，但纵轴（实际值）并没有相应地增加，这进一步证实了模型可能未能正确捕捉到降水量的变化趋势或影响因素。





图 4.26 多元线性回归降水量预测

4.7 模型求解

1. 通过上节中的标准化参数指标算法，分别得到了 STI、SPI 及 SGI 后通过，趋势分析法对这些数据进行分析我们得到了这些年内的降水趋势图和温度趋势图。通过分析这些年的温度趋势图我们能够看出中国东南部降水偏多，西北部降水偏少。中国西北等干旱地区的平均值较小，导致变异系数较大。在江苏省、浙江省、安徽省、福建省、江西省、山东省、河北省、山西省、内蒙古自治区等其他区域，变异系数分布较为均匀。青海和西藏的夏季气温均值和变率系数与其他地区有较大的差异平均气温普遍较低。青海、西藏部分地区的变异系数较大。此外，中国夏季气温偏度系数一直很小。



(a) 降水趋势图



(b) 温度趋势图

图 4.27 气候趋势图

再通过高维正态分布建模得到了降水-温度相关系数图。从图中我们还能看出降水和温度在夏季往往表现出很强的负相关关系。负相关程度在红河等地区增加，在淮河等地区减少。总的来说，在过去的一个一百二十年里，温度的变化是最强烈的，其次是降水的变化。气温与降水的相关性变化仅在新疆、湖北、河南、安徽、江苏、山东六个省份中比较显著。




图 4.28 降水温度相关系数图

2. 经过上一节的数据分析我们大致认为降水与温度负相关程度越高，极端天气灾害的发生频率越高。我们计算并分析了极端天气回归周期，中国极端天气回归周期图如下图所示。从图中我们能够看出除了新疆地区外的其他地区炎热与干旱复合极端事件的可能性都有显著变化。回归周期的值明显减少，发生的可能越来越大，这意味着在未来我们面对复合极端天气时间的可能性越来越高。




图 4.29 高温干旱回归周期图

3. 通过对高维高斯分布的归因分析后我们得到了上图。从图片中我们能够看出西北地区和青海湖地区降水的增加是导致局地复合极端天气回归周期增加的主要原因。气温的下降导致湖北省、湖南省、江西省复合极端天气时间的回归周期明显增加，而在中国其他地区，特别是东北三省、贵州省、云南省、四川省、甘肃省等地区，气候变暖导致复合极端天气时间的回归周期缩短。与此同时也能得出降水与温度的相关性是导致广东省、江西省、湖南省等部分地区复合极端天气时间的回归周期缩短、回归次数增加且是导致湖北、河南、安徽、江苏四省和内蒙古自治区等地方复合极端天气时间的回归周期延长不可忽视的原因之一。总而言之，高温环境影响因素呈明显的增加趋势，通过归因方法可以将这一趋势分解为三个驱动因素的贡献。三个因子中，温度的影响最大，其次是降水和降水-温度的共同作用。贡献的空间分布与各驱动因素的空间分布相似，保证了贡献的大小与驱动因素的强

度密切相关。再次验证了模型有效性。

4.8 模型四：DEM 降尺度插值法

4.8.1 模型构建

首先借助 DEM（数字高程模型）回归插值技术，深入剖析了各类极端天气事件平均气候条件的空间分布格局，并进一步探索了地理位置、海拔高度、地形倾斜角度及其方向（通过倾斜方向的正弦值 X 和余弦值 Y 两个分量来量化）等地理要素之间的复杂多线性关系。随后，采用多元线性回归分析方法，将极端天气事件作为目标变量，而前述地理要素则作为预测因子，构建了一组回归诊断模型。这些模型旨在揭示并量化不同地理要素对极端天气事件发生频率或强度的影响程度。[2]

回归公式为：

$$\omega = \ln \left(\frac{P}{1-P} \right) = \beta_0 + \beta_1 x \quad (4.45)$$

鉴于 SRTM DEM 数据仅涵盖地形的高度信息4.30，为了同步获得地形倾斜角度及其方位角的精确数据，我们采用了不规则三角网（TIN）分析方法。该方法基于 DEM 数据中每个高程点及其相邻的两个网格点，构建一个三角形的平面片，以模拟局部地形。通过这些三角形平面片，我们可以计算出每个点处的地形倾斜角度，即三角形平面与水平面之间的夹角，同时确定方位角，即该点法线在水平面上的投影方向与特定参考方向（如正北）之间的夹角。为了高效执行这一计算过程，我们利用了 ArcGIS 10.0 软件平台中的 TIN 工具。该工具能够自动从 DEM 数据中提取所需的高程信息，并应用上述算法生成倾斜角度和方位角的分布图。图4.30（a）展示了原始的高度数据，而4.30（b）则直观地呈现了通过 TIN 分析得到的倾斜角度及方位角的计算结果，两者共同为我们提供了关于地形特征更全面、细致的描述。





图 4.30 通过 TIN 法求出的坡度 (a) 与方位角坡向 (b) 分布

4.8.2 模型求解

首先，我们依托 DEM 数据，结合经度、纬度、海拔高度、坡度及方向等多元化地理要素，对各类极端气候事件的平均气候条件进行了详尽的多线性回归分析。这一分析旨在深入探讨各地理要素如何塑造极端气候条件的空间分布格局，并进一步挖掘极端事件分布背后的驱动机制。此举不仅深化了我们对极端气候现象的理解，也为后续基于 DEM 的高精度气候状况实验分析奠定了坚实的理论基础。

值得注意的是，鉴于中国北部地区特有的白天零度以下温度及暴雨频发区域（如图4.31a 和图4.31b 所示），这些特定的极端事件指标并未纳入此次多线性回归分析的地理要素范畴之内，以确保分析结果的聚焦性和准确性。

此外，鉴于气象站点数据在空间分布上的不均衡性，为了提升分析结果的代表性和广泛性，我们在探索极端气候事件与地形数据之间关联性之前，特将所有极端事件指标进行了空间插值处理，将其统一映射至分辨率为 $0.5^\circ \times 0.5^\circ$ 的标准化地理网格之上。这一步骤有效消除了数据分布不均带来的偏差，确保了分析过程及结论的可靠性和科学性。






图 4.31 1990-2020 年华北地区多年平均气候

4.9 总结

通过以上建模分析，可以得到地形-气候相互作用如下：

1、海拔 (Elevation)：海拔高度可能会影响气温和降水的分布。通常情况下，随着海拔的升高，气温会降低，可能导致降水形式从雨变为雪。然而，由于模型的解释能力有限，我们不能确定海拔在模型中的具体作用。

2、气温 (Temperature)：气温对极端降水事件的形成可能有直接影响。气温较高的地区可能会有更多的能量驱动水汽上升，从而增加降水的可能性。但是，模型的低 R-squared 值表明，可能还有其他未考虑的因素在起作用。

3、坡度 (Slope)：地形的坡度可能会影响降水的分布。坡度较大的地区可能会改变风向和风速，从而影响降水的模式。然而，同样由于模型的解释能力有限，我们无法准确评估坡度对极端降水的具体影响。

5 问题三：脆弱性评估的多模型构建与求解

5.1 问题分析与预处理

5.1.1 数据集选择

1、降水量数据集 (中国大陆 0.25° 逐日降水数据集,1961-2022 年), 提取其中 1990-2020 年降雨量数据。

2、土地利用/土地覆被数据集 (中国 0.5° 土地利用和覆盖变化数据集, 1900-2019 年), 提取其中 1990-2020 年数据。

3、气温数据集 (中国大陆 0.1° 近地表气温数据集, 1979-2018 年), 提取其中 1990-2020 年气温数据。

4、中国数字高程图 (1km), 提取全国范围内地形数据, 结合海拔、坡度等特征。

5、人口密度数据集 (中国大陆 1km 逐年历史人口空间分布公里网格数据集, 1990-2015 年)。

6、GDP 数据集 (中国大陆 1km 逐年历史 GDP 空间分布公里网格数据集, 1990-2015 年), 提取 1990-2015 年 GDP 数据

5.1.2 数据分析

问题三的目标是对 2025 2035 年间中国境内应对暴雨灾害能力最为脆弱的地区进行预测。为了解决这一问题首先我们需要量化暴雨成灾的临界条件, 找到质变点。其次考虑, 对于暴雨成灾这一事件发生的影响因子, 并分析降雨、地形和土地利用这些影响因子对于暴雨成灾事件的影响权重。为了预测 2025 2035 年的数据, 我们还需要分别预测降雨、地形和土地利用/土地覆被的未来数据。在此过程中降雨数据具有强异变性和不可控性因此我们采用了长短期记忆模型对其进行预测, 而土地利用/土地覆被变化相对平滑因此我们采用了逻辑回归模型对其进行预测。对于地形这一相对稳定的影响因子我们保持了其现有数据, 不需要对其进行预测。




图 5.32 问题三模型一流程图

在上一模型基础上,我们还分析了我国的暴雨灾害分布情况,利用历史灾害数据及指标体系,构建出了我国暴雨灾害 AHP-频率比分析评估方法。通过该评估方法我们能够比较不同地区之间的风险水平,新疆、甘肃等地区发生暴雨灾害事件的概率较高。其原因是新疆、甘肃等地区相对落后,基础设施建设程度不如发达地区。分析完地区暴雨灾害分布情况后,我们引入了随机森林算法对 2025 年至 2035 年进行预测。




图 5.33 AHP-频率比方法处理流程图

5.2 模型假设

在构建预测或分析模型之前，我们基于以下核心假设来设定模型框架：

1、数据准确性假设：我们假定所收集到的数据集，包括但不限于降水记录、土地利用数据和地形信息，能够全面且准确地代表中国当前的自然环境特征。

2、主要影响因素假设：我们认定暴雨灾害的严重程度主要由降雨的强度和持续时间、地形特征以及土地利用状况等因素决定，而其他可能存在的因素（例如地质条件）虽然存在影响，但相较于前述因素，其影响可视为次要。

3、气候稳定性假设：我们预测未来 10 至 15 年内，现有的气候变化趋势将保持相对稳定，不会出现突然的、重大的气候变化事件，这有助于我们基于当前的气候数据进行合理的预测。

4、土地利用可预测性假设：我们假设土地利用的变化主要受人为活动和政策导向的驱动，因此，通过深入分析历史数据和当前政策走向，我们可以较为准确地预测未来土地利用的变化趋势。

5、社会经济影响力假设：我们认识到社会经济因素，如地区生产总值（GDP）和人口密度，对于提升区域应对暴雨灾害的能力具有至关重要的作用，并假设这些因素在模型中应当被充分考虑。

6、区域独立性假设：为了简化模型复杂度，我们假设各区域在暴雨灾害中的相互影响较为有限，特别是忽略上游地区防洪措施对下游地区的直接影响，从而允许我们更专注于单个或特定区域的独立分析。

5.3 模型构建与分析

5.3.1 模型一：多维动态脆弱性评估模型构建与分析

多维动态脆弱性评估模型包含三个主要模块分别为：暴雨成灾临界条件模块、降雨量预测模块、逻辑回归预测模块。首先我们通过模型确定暴雨成灾临界条件，分析了降雨量、地形和土地利用/土地覆被类型对于暴雨成灾的影响权重因子。后通过降雨量预测模块预测 2025 年至 2035 年这十年间的降雨量，通过逻辑回归模型预测了 2025 年至 2035 年土地利用/土地覆被的权重比例。再综合以上三个模型预测了在 2025 年至 2035 年中国应对暴雨灾害能力最为脆弱的地区。

1. 暴雨成灾临界条件模块在这个模块中我们使用了机器学习方法（如随机森林）来确定暴雨成灾的临界条件。模型的输入包括降雨特征（强度和持续时间）、地形特征和土地利用类型，输出为成灾概率。

首先我们将降雨进行连续性采样，将降雨转化为一个综合考量了时间和单日降雨量的指标 RAI（Rainstorm Assessment Index）暴雨评估指数，引入了消化排水系数 C 对地区排水能力进行描述。C 是一个综合性方程影响因子包含了地形和土地利用因子等。

$$RAI(r_t, C(STI, SDI), t) = (\sum_t r_t - C(STI, SDI)) \cdot t \quad (5.46)$$

r_t 是在 t 时间点的降雨量， t 为持续降雨周期时间。

为了预测暴雨成灾的概率我们引入了随机森林模型通过构建多个决策树，多颗决策树共同训练，共同对结果进行聚合。提高了对于暴雨成灾事件的预测成功率，并支持对于多元数据的共同影响因子进行分析。

$$Pr(RAI, STI, SDI, T) = \frac{1}{N} \sum_N MOD(RAI, STI, SDI, T) \quad (5.47)$$

其中 $Pr(RAI, STI, SDI, T)$ 表示发生暴雨极端天气的概率， N 代表随机森林中决策树的数量， $MOD(\cdot)$ 表示单颗决策树模型所预测得到的结果。

2. 降雨量预测模块使用问题一中的长短期记忆网络来对降雨量进行预测。模型的输入包括现有降雨量、地形特征和土地利用/土地覆被率，输出为未来某一时间的降雨量预测值。长短期记忆网络是一种循环神经网络，它通过遗忘门、输入门、输出门控制信息的流入与流出，以此得到了处理长期时序数据的能力。

3. 逻辑回归预测模型我们使用了逻辑回归预测模型来对土地利用/土地覆盖数据进行预测，逻辑回归模型对多重共线性非常敏感。我们将某一个土地覆被类型是否在某一个区域存在的比例设置为权重，并计算了这个权重 P 。

$$\omega = \ln \left(\frac{P}{1-P} \right) = \beta_0 + \beta_1 x \quad (5.48)$$

其中 $\frac{P}{1-P}$ 是覆盖的权重比，表示在特定条件下土地利用/土地覆被发生改变的比例与没有该特定条件下结果发生的几率之比。

利用逻辑回归预测模型进行回归分析。以每一种土地利用/土地覆被的比重为被解释变量，以导致土地利用/土地覆被变化的驱动因素为解释变量，计算在整个地图空间之中的每一种土地利用/土地覆被的权重比，分析每一种土地利用/土地覆被与驱动因素之间的关系。计算公式为

$$\ln \left(\frac{P}{1-P} \right) = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \beta_3 X_3 + \dots + \beta_n X_n \quad (5.49)$$

由上一个式子进行变换可以得到权重 P 的计算公式即为：

$$P_i = \frac{e^{(\beta_0 + \beta_1 X_1 + \beta_2 X_2 + \beta_3 X_3 + \dots + \beta_n X_n)}}{1 + e^{(\beta_0 + \beta_1 X_1 + \beta_2 X_2 + \beta_3 X_3 + \dots + \beta_n X_n)}} \quad (5.50)$$

其中 X_i 为各种影响因子， β_i 为第 i 个事件的影响因子权重。

模型准确率评估，为了评估逻辑回归模型对于土地利用/土地覆被的比重的预测效果我们引入了 Kappa 指数方程进行评估。Kappa 模型是一种用于评估模型性能的统计指标，在多类别的分类任务之中可以分析出结果与实际结果的一致性。公式如下所示：

$$K = \frac{P_o - P_e}{1 - P_e} \quad (5.51)$$

其中 P_o 是模型预测出的结果与数据集结果一致的比重， P_e 是通过随机数数据集得到的结果与数据集结果一致的比重。K 值结果处于-1 到 1 之间值越高说明模型的预测准确率越高。

5.3.2 模型二：基于 XGBoost 的暴雨灾害预测

XGBoost 算法基于决策树算法，使用于大规模数据集和多元复杂影响因子。它通过逐步加入新的决策树来提高现有模型效率，每棵决策树都将对之前决策树的错误进行反向补偿。XGBoost 算法大致分为三个阶段，第一阶段数据集标签生成阶段：在这个阶段中需要对数据进行差错处理、特征识别。第二阶段机器学习，在这个阶段包含了三部分分别是目标函数、参数定义及交叉检查。目标函数用来拟合机器学习的最终目标，面对不同任务时需要选择不同的目标函数。参数的选择主要包含了学习速度、树的深度、正则化项等。交叉验证是 XGBoost 一种常用的模型性能评估方法，能够有效抑制过拟合，并提高模型在未训练数据集上的工作效率。

5.4 模型求解




图 5.34 暴雨极端天气脆弱度得分图

通过对于上节中的模型进行求解后我们得到了地形对暴雨极端天气的脆弱度得分图，从图中我们能够得出新疆、甘肃等西南省份对于暴雨极端天气的脆弱度最高，最容易收到暴雨极端天气的影响。山东、浙江、辽宁等省对于暴雨极端天气的脆弱度最低，抵抗暴雨

极端天气的能力最强。

整体脆弱度得分对比图




图 5.35 历年暴雨极端天气脆弱度得分图

再通过时间预测模型进行分析我们得到了 2025 年至 2035 年每一年的地形对暴雨极端天气的脆弱度得分图。通过观察 11 年的脆弱度得分图变化能够看出，在总体上全国的平均暴雨极端天气脆弱度得分在降低，这表明全国应对极端天气水平在逐步升高。

5.4.1 模型三：随机森林分类器

1、模型建立基于模型二相同的方法，模型的表达式为：

$$Y = B_0 + \sum_{i=1}^{64} B_i \cdot X_i \quad (5.52)$$

其中：Y 表示降水量， B_0 是常熟项， X_1 代表地形， X_2 代表坡度， X_3 代表耕地覆盖面积， X_4 代表森林覆盖面积， X_5 代表草地覆盖面积， X_6 代表灌木丛覆盖面积， X_5 代表湿地覆盖面积。

构建模型的流程如下：

(1)、数据准备

读取降水量数据：使用 `xarray` 从 `NetCDF` 文件中读取降水量数据，并按年计算平均降水量。读取地形数据：使用 `gdal` 从 `TIFF` 文件中读取地形数据，处理负值并计算坡度。读取土地覆盖数据：循环读取每年的五种土地覆盖类型（耕地、森林、草地、灌木丛、湿地）的数据，并将其整合到数据框中。

(2) . 数据清理

处理缺失值：在构建数据框时，确保去除任何 `NaN` 值。特征标准化：使用 `StandardScaler` 对地形、坡度和土地覆盖面积进行标准化处理，以消除量纲的影响。

(3) . 建立模型

构建特征矩阵：将标准化后的特征（地形、坡度和土地覆盖类型）与降水量作为响应变量。添加常数项：使用 `sm.add_constant` 添加截距项。拟合模型：使用 `statsmodels` 中的 `OLS` 方法拟合线性回归模型。

(4) . 结果分析

模型摘要：通过 `model.summary()` 输出模型的统计信息，包括系数、标准误差、p 值等。系数解释：根据系数的符号和大小，分析每个特征对降水量的影响。

(5) . 可视化

特征分布：绘制特征的分布直方图，查看数据的分布情况。回归系数条形图：绘制回归系数的条形图，直观展示各特征的影响程度。实际值与预测值散点图：绘制实际降水量与预测降水量的散点图，并添加参考线 ($y=x$)，帮助判断模型的预测效果。

(6) . 模型诊断

自相关检验：检查 `Durbin-Watson` 统计量，以判断残差是否存在自相关。正态性检验：使用 `Omnibus` 和 `Jarque-Bera` 测试评估残差的正态性

使用 `lstm` 求取降雨量、土地覆盖面积、温度预测结果：

2、模型结果

OLS Regression Results

Dep. Variable:

y

R-squared:

0.134

Model:

OLS

Adj. R-squared:

0.134

Method:

Least Squares

F-statistic:

1.106e+04

Date:

Wed, 25 Sep 2024

Prob (F-statistic):

0.00

Time:

04:53:59

Log-Likelihood:

-8.8508e+05

No. Observations:

501301

AIC:

1.770e+06

Df Residuals:

501293

BIC:

1.770e+06

Df Model:

7

Covariance Type:

nonrobust

coef

std err

t

P>|t|

[0.025

0.975]

const

1.6140

0.002

807.980

0.000

1.610

1.618

Elevation

-0.0278

0.003

-10.159

0.000

-0.033

-0.022

Slope

-0.0929

0.002

-38.349

0.000

-0.098

-0.088

cropland

-0.2328

0.002

-109.172

0.000

-0.237

-0.229

forest

-0.1436

0.002

-60.537

0.000

-0.148

-0.139

grass

-0.3190

0.002

-140.744

0.000

-0.323

-0.315

shrub

-0.1734

0.002

-75.365

0.000

-0.178

-0.169

wetland

0.0316

0.002

12.678

0.000

0.027

0.036

Omnibus:

192642.364

Durbin-Watson:

0.140

Prob(Omnibus):

0.000

Jarque-Bera (JB):

1528525.369

Skew:

1.645

Prob(JB):

0.00

Kurtosis:

10.897

Cond. No.

2.42

图 5.36 运行结果




图 5.37 暴雨预测混淆矩阵




图 5.38 回归系数柱状图





图 5.39 回归系数分布图

根据 OLS 回归结果，以下是一些主要的分析点：

- (1) 模型解释能力：R-squared 为 0.134，表示模型只能解释约 13.4% 的降水量变异，这表明还有很多其他因素未被纳入模型。
- (2) 显著性：所有变量的 p 值均小于 0.001，表明它们在统计上显著影响降水量。
- (3) 系数分析：Elevation 和 Slope：两者均呈负相关，意味着海拔和坡度越高，降水量越少。
- (4) 土地覆盖类型：耕地（cropland）和草地（grass）对降水量的负面影响最大，可能是因为这些区域的蒸发量较高。湿地（wetland）的系数为正，表明其有助于增加降水量，可能是由于其水分保持能力。






图 5.40 降水量预测

从上图中能够看出随着时间变化，各地区对于降雨量小幅度增加，中国部分地区，特别是南方地区，可能会经历更多的降雨。其中以浙江、江苏、海南等沿海省份降雨增加率最高。华北、西北等地随降雨量减少可能会经历干旱问题。




图 5.41 温度预测

从图中我们能够看出在总体层面，全国气温会逐年小幅度升高，其中新疆地区变化并不明显且气温明显偏低。与南方相比北方和西北地区的升温幅度更大。高温极端天气事件发生概率增高，预计将会出现更多热浪。




图 5.42 植被覆盖面积预测

通过上方 10 年的植被覆盖面积预测，可以看出灌木的覆盖面积将会明显减少，森林的覆盖面积将会逐年增加，这可能与退耕还林，碳中和政策相关。更多的森林也给予了我国更多的碳消化容量。

3、模型评估

Durbin-Watson 值为 0.140，远低于 2，提示可能存在自相关问题，可能影响模型的可靠性。Omnibus 和 Jarque-Bera 测试显示数据偏态和峰度较高，可能不满足正态分布假设。总体而言，模型揭示了一些影响降水量的因素，但考虑到模型解释能力较低，建议进一步探索其他潜在变量和改进模型。

6 问题四：土地利用变化的特征与结构分析

6.1 问题分析

6.2

中国的自然地理特征通过“三级阶梯”的地形结构得到了清晰的表现：第一阶梯为青藏高原及其周边高山地区，地形高耸、气候寒冷，主要由冰川、高原和高山草甸组成；第二阶梯包括内蒙古高原、黄土高原和四川盆地等地区，气候干燥，适合草原、林地及部分农业发展；第三阶梯则是东部的平原和丘陵，人口稠密、经济发达，是中国农业和城市化发展最为集中的区域。

除了地形特征，气候条件中的“800mm 等降水量线”是中国南北方的重要气候分界线。它大致沿着“秦岭—淮河”一线延伸，成为农业、生态和经济活动的重要分界标志。在 800mm 等降水量线以南，降水充足，水热条件适宜，广泛分布着水稻等农作物，林地和湿地资源丰富。而在该线以北，气候相对干燥，适合小麦、玉米等旱地作物，草地和灌木丛分布较为广泛。

在人文地理特征方面，胡焕庸线（连接黑龙江黑河到云南腾冲的地理线）明确划分了中国东部和西部的经济、人口密度分布格局。胡焕庸线以东，占全国不到 40% 的土地，集中了约 90% 的人口和 GDP 总量，是中国社会经济活动最密集的区域；而胡焕庸线以西，地广人稀，主要为高原、山地和草原地区，经济发展水平相对滞后。

在这样的自然地理和人文地理条件下，中国的土地利用和土地覆被呈现出明显的区域特征。东部的平原和丘陵地区，由于降水充足、气候适宜，适合农业和城市化发展，土地主要用于耕地、城市用地和林地。西部和北部地区，则因高原、沙漠、草地的广泛分布，以及相对干旱的气候条件，主要用于林地、草地和自然保护区的建设。

土地利用变化的关键驱动力包括：

自然地理要素：气候（如降水、温度）、地形（如海拔、坡度）等条件直接影响土地利用类型的分布和变化。人文地理要素：人口密度、经济活动强度（GDP）、城市化水平等人类活动显著改变土地利用格局，如耕地向城市用地的转换、林地的开垦等。

因此，研究土地利用的变化需要结合自然地理和人文地理的双重因素，通过数学模型系统分析土地利用的时空演变规律。

6.3 数据分析及预处理

6.3.1 数据集选择

1、降水量数据集 (中国大陆 0.25° 逐日降水数据集,1961-2022 年), 提取其中 1990-2020 年降雨量数据。

2、土地利用/土地覆被数据集 (中国 0.5° 土地利用和覆盖变化数据集, 1900-2019 年),

提取其中 1990-2020 年数据。

3、气温数据集 (中国大陆 0.1° 近地表气温数据集, 1979-2018 年), 提取其中 1990-2020 年气温数据。

4、中国数字高程图 (1km), 提取全国范围内地形数据, 结合海拔、坡度等特征。

5、人口密度数据集 (中国大陆 1km 逐年历史人口空间分布公里网格数据集, 1990-2015 年)。

6、GDP 数据集 (中国大陆 1km 逐年历史 GDP 空间分布公里网格数据集, 1990-2015 年), 提取 1990-2015 年 GDP 数据

6.3.2 数据分析

在土地利用变化分析中, 数据是构建模型和分析结果的基础。为了对中国土地利用的时空变化进行综合分析, 我们需要整合多维度、多时间段的数据, 并进行适当的预处理。下面我将详细描述需要的数据及其预处理方法:

1. 土地利用/土地覆被类型数据

土地利用/土地覆被类型数据是本次分析的核心数据, 数据集 1 中记录了中国从 1990 年到 2020 年间, 不同区域土地利用类型的动态变化。主要包括以下五种类型:

耕地: 用于种植农作物的土地, 广泛分布于东部平原和中部丘陵地区。林地: 包括自然林和人工林, 主要分布在东北、华南和西南的山区。草地: 主要分布在内蒙古高原和青藏高原, 用于放牧。灌木: 多见于干旱半干旱地区, 植被相对较低。湿地: 主要分布在东部沿海和长江中下游平原, 是重要的生态系统之一。

这些土地利用数据通常以栅格或矢量形式提供, 并构建年度的土地利用转换矩阵, 用于识别各类土地利用类型之间的转换关系和动态变化。

时间尺度: 对 1990-2020 年间的土地利用数据进行逐年分析, 确保时序的连贯性。空间尺度: 对土地利用数据进行统计分析。转换矩阵构建: 构建每两年之间的土地利用转换矩阵, 分析各类土地类型的转换概率。

2. 自然地理数据

为了更好地分析自然因素对土地利用变化的影响, 我们选择了涵盖气候和地形特征的自然地理数据。这些数据为理解土地利用类型的空间分布和时空动态变化提供了关键依据。

降水量作为最主要的气候因素, 能够显著影响土地的湿润程度。数据集 3 记录了降水量数据, 在分析水资源丰富地区, 耕地、林地和湿地等土地利用类型的空间分布和变化趋势。通常情况下, 降水量较高的地区, 农业、湿地以及林地的分布比例较高, 而在降水较少的干旱和半干旱地区, 则更适合草地和灌木丛的分布, 降雨量分布如下图。




图 6.43 降雨量分布

温度是影响植被生长的另一关键因素。在不同海拔、纬度及地形条件下，温度变化会直接影响土地的利用方式。通过记录全国的年平均温度和极端温度，我们能够推断哪些区域适合农作物种植，哪些区域更适合森林和草地的生长。尤其是在寒冷的高海拔地区，温度的变化对植被类型的分布起着至关重要的作用，年平均气温分布如下图。




图 6.44 年平均气温

地形特征对土地利用类型的约束作用也不容忽视。首先，海拔高度直接决定了土地的可利用性。三级阶梯的地形特征，使得低海拔的东部平原适合农业和城市化发展，而中部的丘陵和高海拔的西部则主要被用于草地和林地。坡度则进一步限制了土地开发的可能性。坡度较小的平坦区域更适合农业发展，而坡度较大的地区则常常被保留为林地或草地，以避免土地流失和自然灾害的发生。坡向影响光照和水分条件，因此对植被的生长产生间接影响。向阳坡地通常较为干燥，适合灌木生长，而背阳的坡地则更适合湿润环境下的植被。

通过整合这些自然地理数据，我们能够进一步量化自然因素对土地利用变化的影响，从而为后续的模型构建提供有力支持。在数据预处理阶段，我们需要将这些数据标准化，确保它们的时间和空间分辨率与土地利用数据一致，以便能够进行统一的分析。

3. 社会经济数据

社会经济数据是分析土地利用变化的重要维度之一。人类的经济活动和人口分布直接影响着土地的利用方式和类型分布。在分析土地利用变化时，人口密度和 GDP 这两个核心变量反映了人类活动对自然环境的干预程度。因此，通过对这两个变量的详细分析，我们可以更好地理解土地利用变化的驱动因素。

4. 人口密度的影响

人口密度作为衡量人类活动强度的直接指标，在土地利用分析中至关重要。人口稠密的地区对土地的利用往往更加密集，尤其在城市化进程中，耕地和林地大多被改造成建筑用地和工业用地。同时，由于人口密度的差异，土地的开发和利用在区域间呈现出显著的空间异质性，我们通过分析人口密度（数据集 5）得到人口分布数据，其中：

东部地区：人口密度高，城市化进程快。典型如长江三角洲和珠江三角洲，这些地区耕地和林地逐渐减少，被城市用地和工业用地替代。城市化率的上升伴随着土地的集约开发，农业用地减少，生态用地也受到压力。

西部地区：地广人稀，人口密度低。这里的土地利用主要集中在农业和林业，土地开发强度低。西部山区和高原地区，如新疆、青海、西藏，仍然保留了大面积的天然草地和林地，未受大规模开发的影响。

从时间维度上看，随着时间的推移，人口密度的增加进一步加剧了土地利用的变化。随着农村人口向城市迁移，东部和中部的城市化加速，城市用地不断扩展，农业用地尤其是耕地呈现下降趋势。这一变化可以通过转换矩阵中的“耕地到城市用地”的变化概率反映出来。

5. GDP 的影响

GDP 作为反映经济活动水平的关键变量，与土地利用密切相关。经济发展推动了土地利用的转型，高 GDP 区域往往伴随着更高的城市化率和工业化进程，从而改变了土地类型的分布，我们通过数据集 6 分析得到 GDP 分布数据，其中：

高 GDP 地区：北京、上海、广州等城市，其土地利用主要表现为耕地转为城市用地、工业用地。高 GDP 区域不仅对土地的需求量大，且对土地的使用效率要求也更高。这些地区的土地利用类型转换频繁，城市扩展的同时，农业用地和自然生态用地减少显著。

低 GDP 地区：以西部为例，如甘肃、宁夏等地区，其经济发展相对滞后，城市化率低，土地利用仍然以传统农业为主，土地转换较少。低 GDP 区域的人类活动强度较低，土地利用保持相对稳定。

GDP 在时间维度上的变化也极大影响了土地利用类型的转化。在过去的 30 年中，东部地区的 GDP 持续增长，推动了大量土地从农业向城市和工业用地的转变。与此同时，中部地区（如湖南、湖北、安徽等省份）在经济改革中也表现出较为显著的 GDP 增长，这直接推动了土地利用的转型。尤其是在国家政策的支持下，中部地区的城市化进程加快，农村土地的大规模开发正在进行中。

6.4 模型构建

1. 转换矩阵

为了更加清晰地展示土地利用类型的转换情况，我们构建了土地利用转换矩阵。该矩阵展示了每年不同土地类型之间的转换概率，揭示了土地利用类型如何在自然和人类活动

的驱动下发生变化。土地利用转换矩阵通过统计每年土地类型之间的变化关系得出。具体来说，我们对五种土地类型（耕地、林地、草地、灌木丛、湿地）之间的转化关系进行量化，得到每种土地类型在次年转化为其他类型的概率。

为了进一步描述不同类型土地之间的转换关系，构建的土地利用转换矩阵，表示不同时间段内各个土地类型之间的转换概率。转换矩阵的定义如下：

$$P = \begin{bmatrix} p_{11} & p_{12} & \cdots & p_{1n} \\ p_{21} & p_{22} & \cdots & p_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ p_{n1} & p_{n2} & \cdots & p_{nn} \end{bmatrix}$$

其中， p_{ij} 表示土地类型 i 转换为 j 的概率。该转换矩阵通过历史数据的分析得出，并作为未来土地利用变化的预测工具。

以下以是 1995 年至 1996 年的给类型土地的转移矩阵为例。矩阵的每一行代表该类型土地在年初的状态，每一列代表这些土地在年末的状态。因此，通过分析该矩阵，可以观察到某一类型的土地在一年内向其他类型土地的转移情况。

2. 矩阵分析

矩阵行表示土地利用的初始类型（年初的土地利用状态），列表示土地利用的最终类型（年末的土地利用状态），对角线上的数字代表某一类型土地在一年内没有发生转移，即保持了原有的利用类型，非对角线的数字代表从某种土地利用类型转移到另一种土地利用类型的数量。

从这组数据可以看出，耕地（cropland）、林地（forest）、草地（grass）、灌木丛（shrub）和湿地（wetland）在这一年内都保持了相对稳定的状态。例如，耕地在年初有 796 块保持不变，仅有极少数转化为林地和草地。具体来看，有 2 块耕地转化为了林地，1 块耕地转化为草地。林地方面，536 块林地在一年内未发生变化，只有 1 块林地转化为草地。草地也保持了大部分的稳定性，其中 2179 块草地没有发生变化，而有 5 块草地转化为耕地，22 块草地转化为林地。灌木丛在这一年内也大体保持不变，仅有 10 块转化为林地。湿地则几乎没有变化，只有 3 块湿地保持稳定，且未转化为其他类型的土地。

6.5 模型一：基于 XGBoost 的土地利用变化模型

在本问题中，我们通过建立一个基于 XGBoost 的土地利用变化模型，来分析和预测土地利用变化的特征与结构。该模型结合了自然地理特征（如气候、地形）和人文地理特征（如人口密度、GDP）作为自变量，土地利用类型作为因变量。通过模型，我们可以揭示土地利用变化的规律，分析气候、地形和经济活动如何影响土地利用的转换。

1.XGBoost 模型

XGBoost 是一种基于梯度提升的决策树模型，适用于处理高维和非线性数据。我们使

用 XGBoost 模型来预测未来的土地利用变化。模型的数学表达如下：

$$\hat{y} = \sum_{k=1}^K f_k(x), \quad f_k \in \mathcal{F}$$

其中， y 是预测值， $f_k(x)$ 是第 k 棵树的预测， $\mathcal{F}$ 是所有回归树的空间。目标是最小化损失函数：

$$L(\phi) = \sum_{i=1}^n l(y_i, \hat{y}_i) + \sum_{k=1}^K \Omega(f_k)$$

其中， $l(y_i, \hat{y}_i)$ 是误差损失， $\Omega(f_k)$ 是正则化项，用于控制模型复杂度，避免过拟合。

2. 模型变量与公式

(1) 模型的输入变量（自变量）

$P_{precip}(x, y, t)$ ：在时间 t 时，位置 (x, y) 的年降水量（mm）。 $T_{avg}(x, y, t)$ ：在时间 t 时，位置 (x, y) 的年平均温度（℃）。 $Alt(x, y)$ ：位置 (x, y) 的海拔（m）。 $Slope(x, y)$ ：位置 (x, y) 的坡度。 $Pop(x, y, t)$ ：在时间 t 时，位置 (x, y) 的人口密度（人/km²）。 $GDP(x, y, t)$ ：在时间 t 时，位置 (x, y) 的 GDP（万元）。

(2) 模型的输出变量（因变量）

$L(x, y, t)$ ：在时间 t 时，位置 (x, y) 的土地利用类型。具体分为：耕地、林地、草地、灌木丛、湿地等 5 种类型，用 0 到 4 表示。模型的核心目标是通过自变量来预测土地利用类型的变化。

(3) 基本公式

在模型中，假设土地利用类型 $L(x, y, t)$ 在 t 时刻主要受到以下因素的影响：气候（年降水量、年均温）、地形（海拔、坡度）、人口密度以及 GDP。因此，土地利用类型可以表示为自变量的非线性函数：

$$L(x, y, t) = f(P_{precip}(x, y, t), T_{avg}(x, y, t), Alt(x, y), Slope(x, y), Pop(x, y, t), GDP(x, y, t))$$

由于土地利用变化不仅与单一年度的数据有关，还与其历史变化存在一定关联，因此我们引入滞后项：

$$L(x, y, t) = f(P_{precip}(x, y, t), T_{avg}(x, y, t), Alt(x, y), Slope(x, y), Pop(x, y, t-1), GDP(x, y, t-1), L(x, y, t-1))$$

其中： $L(x, y, t-1)$ ：位置 (x, y) 在时间 $t-1$ 时的土地利用类型，是当前土地利用类型的影响因素。我们使用 XGBoost 模型来拟合这个非线性关系，其中每个决策树学习输入特征与土地利用类型之间的复杂交互。

(4) 土地利用结构冲突

LUSC 是通过三个子指标 (复杂性、脆弱性、破碎性) 来衡量土地利用结构的冲突。各个部分通常通过具体的生态、环境、社会等因素来量化。不同土地利用类型之间, 由于资源、空间或功能上的竞争与不兼容, 导致的矛盾或利益冲突。随着城市化、工业化和农业发展, 土地资源日益紧张, 不同用地类型 (如农业用地、居住用地、工业用地、生态保护区等) 之间的需求往往相互冲突, 造成土地利用的矛盾和不平衡。

$$LUSC = C + V + F$$

(5) 模型参数优化

树的最大深度决定每棵树的复杂性。较深的树可以捕捉数据中的复杂非线性特征, 但同时也可能导致过拟合, 特别是当数据噪声较大或数据量较小时。模型的复杂度随深度呈指数级增长, 最大深度为 d 的树最多可以划分出 2^d 个叶子节点。

在二叉树中, 树的深度 d 与叶子节点 n 之间的关系为 $n = 2^d$, 每个叶子节点对应一个分割规则, 复杂的模型会使用更多的规则来划分特征空间。因此, 当深度增加时, 模型的表达能力增强, 但也更容易在训练数据上过拟合, 从而在测试数据上表现较差。

考虑到数据规模以及地理和经济特征之间的复杂性, 我们将树的最大深度设置为 8。这个深度可以捕捉土地利用类型和气候、地形、人口等多维特征之间的复杂关系。

$$textmax_depth = 8$$

学习率是控制模型每棵树对最终预测影响的关键参数。学习率 越小, 模型的更新步长越小, 这样可以更稳健地更新模型, 但需要更多的迭代次数才能达到最佳效果。较高的学习率可能会导致模型在训练初期快速收敛, 但容易跳过全局最优点。

$$F_t(x) = F_{t-1}(x) + \eta \cdot h_t(x)$$

其中 $F_t(x)$ 是第 t 轮更新后的模型, $h_t(x)$ 是当前树的输出, η 是控制每次更新步长的参数。通过降低 η , 可以控制每次更新的步长, 避免模型过度修正。

我们选择较小的学习率 $\eta = 0.05$, 通过增加树的数量 (迭代次数) 来让模型在更长时间内学习数据中的细节, 避免过拟合。

$$\eta = 0.05$$

数据采样率控制每棵树在训练时使用的样本比例。通过随机忽略部分数据, 可以增加模型的泛化能力, 减少模型对特定训练数据的依赖, 从而提高在测试数据上的表现。

假设模型有 N 个样本, 设置子采样率为 s , 则每棵树仅使用 $s \cdot N$ 个样本进行训练, 这相当于对模型施加了一个正则化限制, 降低了过拟合风险。

0.85 的采样率能够平衡数据利用率和防止过拟合。通过引入随机性，模型可以避免过度依赖某些噪声数据，提升泛化能力。

$$\text{subsample} = 0.85$$

特征采样率决定了每棵树在训练时使用的特征数量比例。特征采样和数据采样类似，通过随机选择部分特征进行训练，可以避免模型过度依赖某些特征，从而增强模型的鲁棒性。

对于 M 个特征，如果我们设置特征采样率为 c ，则每棵树使用 $c \cdot M$ 个特征。这确保每棵树不会依赖于全部特征，增加了模型的随机性和多样性。

我们选择了 0.8 的特征采样率，这意味着每棵树仅使用 80% 的特征进行训练。这样的设置可以有效避免模型过拟合到某些特定的强相关特征，从而提升模型的泛化能力。

$$\text{colsample_bytree} = 0.8$$

树的数量是决定模型整体复杂度和拟合能力的关键参数。在较低学习率下，较多的树可以确保模型有足够的表达能力。为了在保证模型稳定性的同时提高拟合效果，我们设置了 1000 棵树，配合较小的学习率使模型充分学习。

$$\text{n_estimators} = 1000$$

(6) 模型验证

评估指标是用于衡量模型在训练过程中的表现。对于多分类问题，使用 `mlogloss`（多分类对数损失）作为评估指标，可以更好地衡量预测概率与实际类别之间的差异。

`mlogloss` 的计算公式为：

$$\text{mlogloss} = -\frac{1}{N} \sum_{i=1}^N \sum_{k=1}^K y_{ik} \log(\hat{p}_{ik})$$

其中 y_{ik} 是样本 i 的实际标签， $\hat{p}_{ik}$ 是模型预测样本 i 属于类别 k 的概率。通过最小化 `mlogloss`，我们可以确保模型不仅输出正确的类别，还能输出更准确的类别概率。

$$\text{eval_metric} = \text{mlogloss}$$

(6) 模型评估

通过计算 XGBoost 模型的 AUC 值并绘制 ROC 曲线，如下图显示，在评估驱动程序和测试组件后，模型的 AUC 值分别为 1.00 和 0.75。

6.5.1 模型求解

(7) 惩罚系数

γ 控制分裂 w 节点时的最小损失减少量。如果某次分裂导致的损失减少量低于 γ ，则分裂不会发生。通过引入 γ 可以减少不必要的分裂，增强模型的泛化能力。

在每个节点分裂时，如果分裂带来的增益低于 γ ，则该分裂被取消。分裂增益公式为：

$$\text{Gain} = \frac{1}{2} \left[\frac{(\sum g)^2}{H + \lambda} \right] - \gamma$$

其中 g 是梯度， H 是二阶导数， λ 是正则化参数。较大的 γ 可以避免过多的分裂，减少过拟合。

$$\text{gamma} = 0.2$$

3. 模型评估概述我们将数据集划分为训练集、验证集和测试集，分别占 70%、15%、15%。训练集用于训练模型，验证集用于调整超参数，测试集用于评估模型的泛化能力。在模型评估过程中，我们使用了以下关键指标：

精确率 (Precision)：表示模型预测为正类的样本中有多少是真正的正类。

$$\text{Precision} = \frac{TP}{TP + FP}$$

召回率 (Recall)：表示实际为正类的样本中有多少被正确地预测为正类。

$$\text{Recall} = \frac{TP}{TP + FN}$$

F1 分数：精确率和召回率的调和平均数，用于衡量模型分类的平衡性。

$$F1 = 2 \cdot \frac{\text{Precision} \cdot \text{Recall}}{\text{Precision} + \text{Recall}}$$

R^2 值 (决定系数)：在回归模型中， R^2 衡量模型解释自变量对因变量变异的比例。 R^2 值越接近 1，说明模型对数据的拟合越好，其中有如下关系：

$$R^2 = 1 - \frac{\sum (y_i - \hat{y}_i)^2}{\sum (y_i - \bar{y})^2}$$

4. 模型结果与分析

(1) 特征重要性分析

在本次土地利用变化预测任务中，我们将数据集划分为训练集、验证集和测试集，分别占 70%、15% 和 15%。通过使用 XGBoost 模型，我们对自然地理特征（如降水量、海拔）与社会经济因素（如人口密度、GDP）进行了土地利用类型变化的分析与预测。以下是模型在不同指标下的评估结果。

为了更直观地理解不同特征对土地利用变化的影响，我们引入了 SHAP (SHapley Additive exPlanations) 值来解释 XGBoost 模型中的特征重要性。通过 SHAP 值，深入分析每

个特征对模型输出的贡献大小。以下是主要的 SHAP 分析结果展示,SHAP Summary Plot: 展示了每个特征对模型输出的整体影响。红色表示高特征值, 蓝色表示低特征值。




图 6.45 SHAP Summary Plot

该图展示了所有特征对模型预测的总体贡献, 图中的每个点代表一个数据点的 SHAP 值, 横轴表示 SHAP 值, 纵轴表示不同的特征。点的颜色从蓝色 (低值) 到红色 (高值), 展示了特征值的分布情况, 从图中可以看到, 降水量 (QW)、海拔 (DEM) 和 GDP 是对土地利用变化影响最大的特征。SHAP Dependence Plot 依赖性图显示了单个特征 (如降水量) 对 SHAP 值的影响, 并揭示了它与其他变量 (如海拔) 之间的相互关系。




图 6.46 SHAP Dependence Plot

该图展示了土地利用类型与某个重要特征（例如降水量 QW）的依赖关系。每个点代表一个数据样本，横轴是特征值（如降水量），纵轴是该特征对预测的影响（SHAP 值），从图中可以看到，降水量较小的区域对预测的影响是正向的，而随着降水量增加，SHAP 值逐渐转为负向，这意味着在降水量高的地区，土地类型可能更倾向于湿地、林地等类型。SHAP Force Plot 针对个别样本的 SHAP 分析，展示了模型如何通过各个特征影响最终预测结果。




图 6.47 SHAP Force Plot

SHAP 力图是一种交互式图表，它展示了一个特定样本中的所有特征如何共同影响模型预测。红色部分表示使预测值增大的特征，蓝色部分表示使预测值减小的特征，力图中

的每个条块代表一个特征的 SHAP 值，它们共同作用，推动预测值远离基线值，在本题中，我们可以看到海拔（DEM）、GDP 等因素都在推动预测值增加，而降水量（QW）和人口密度（PD）等特征的影响则推动预测值降低。SHAP Decision Plot 该决策图展示了多个样本在特定特征值范围内对模型输出的影响轨迹，帮助理解特征在不同数据点的影响趋势。




图 6.48 SHAP Decision Plot

此图展示了模型中每个特征对预测结果的影响。横轴表示模型的输出值（即模型对某个土地利用类型的预测概率），纵轴表示各个特征，颜色表示特征值的大小，红色表示高值，蓝色表示低值。我们可以看到，降雨量（标注为“QW”）和海拔（“DEM”）的高值和低值对模型输出的影响差异较大。。

(2) ROC 曲线与 AUC 值

ROC 曲线（Receiver Operating Characteristic Curve）用于评估模型的分类性能，表示不同阈值下假阳性率和真阳性率之间的权衡。通过分析 ROC 曲线，可以清楚地了解模型在区分不同土地利用类型时的能力。

AUC 值（Area Under the Curve）反映了 ROC 曲线下的面积，用于评估模型的整体分类能力。AUC 值范围为 0 到 1，越接近 1，模型的分类效果越好。在我们的模型中，经过验证集和测试集的评估，ROC 曲线和 AUC 值表现如下：

5. 误差分析

模型的预测效果虽然在整体上表现较好，但对某些特定土地类型的预测仍存在误差。例如，草地与灌木丛之间存在较大的特征重叠，导致模型在分类时常常出现混淆。为了进

一步改进模型性能，可以考虑引入更多特征或使用更复杂的模型结构来增强分类的准确性。

此外，湿地的样本数量较少，导致模型在处理湿地时可能存在过拟合或分类偏差的现象。需要通过引入更多的湿地样本提升该类的分类效果。

6. 结论

6.1 协方差矩阵分析

我们通过分析不同土地利用类型的协方差矩阵，进一步了解它们之间的相互关系以及转换的可能性。下图表示了每种土地利用类型与其他类型之间的相关性程度。




图 6.49 协方差矩阵

耕地与林地的负相关性：耕地与林地之间的相关性为-0.25，说明在某些区域，耕地的增加往往伴随着林地的减少，反映了城市化和农业开发对林地的侵占现象。这种趋势在高人口密度、经济活动集中的地区更加显著。草地与其他类型土地的负相关性：草地与其他土地类型的相关性也呈负值，特别是与耕地（-0.24）和林地（-0.23）的负相关性较强。这表明随着农业开发和生态恢复的推进，草地在某些地区逐渐转变为耕地或林地。灌木丛与林地的负相关性：灌木丛与林地的负相关性为-0.24，表明随着灌木丛区域的减少，林地可能得到了扩展。这种变化通常发生在生态恢复区域，植被得到了改善。湿地的独立性：湿

地与其他土地类型的相关性较弱，特别是与耕地、草地、林地的相关性均接近-0.24。由于湿地面积较小且较为稳定，湿地的变化主要受到水资源管理和气候因素的影响，而非人类活动的直接开发。

通过模型分析和协方差矩阵的结果，我们对中国土地利用变化的特征与结构有了更为深入的理解。自然与人文地理因素共同推动了土地利用类型的演变，其中自然地理因素如降水量、海拔和温度对土地类型的变化起到了至关重要的作用，特别是在“800mm 等降水量线”附近。降水量的波动直接影响了耕地、林地和湿地的面积转换，表现为降水量增加时林地与湿地面积的扩展，而耕地面积相对减少。而在人文地理层面，人口密度和 GDP 是土地开发与集约化的重要驱动力，特别是在东部人口稠密、经济发达的区域，耕地、城市用地等类型的变化较为显著，显示了集约化开发和城市化进程的持续推动。

从土地利用转换的趋势上来看，根据转换矩阵和协方差矩阵的分析，耕地和林地的转换尤为显著，尤其在降水充沛的区域，林地的恢复趋势得到了明显的体现。这也验证了中国近年来在部分区域通过生态恢复工程，积极推进植被恢复的政策效应。此外，草地与灌木丛之间的相互转换也表明了生态系统在高海拔和荒漠化地区逐步恢复的迹象，草地和林地在这些区域逐渐占据主导地位。

在模型的预测与评估方面，XGBoost 模型显示出较好的土地利用变化预测效果，特别是对耕地、林地和湿地的分类较为精准。通过 ROC 曲线和 AUC 值的分析，模型在测试集上的表现优异，展示了良好的分类能力。然而，草地和灌木丛的分类则存在一定的难度，主要是由于这些类型的特征在某些区域可能存在较大的交叠性。为了进一步提高分类精度，可以考虑引入更多的特征，如土壤类型、植被覆盖指数等，或通过增加数据样本来提升模型的泛化能力。

6.2 总结

从 20 世纪 80 年代到 21 世纪初，全球气候变暖趋势不断加剧，极端气候事件的频发为生态环境保护和社会经济的可持续发展带来了巨大挑战。极端气候事件往往具有低发生率、高突发性和强破坏力的特征。近年来，这些事件的频率和强度在全球范围内逐渐上升，中国也不例外。例如，2021 年 7 月河南省的极端降雨引发了严重的洪涝和山体滑坡灾害，影响了数千万人的生活和财产安全。而在 2022 年，由于高温干旱，湖南、广西、江西等地发生了大规模森林火灾，占全国火灾总数的 71%。这些事件不仅威胁了当地的社会经济，也对中国的生态系统，特别是植被生长和碳循环产生了显著影响。

在中国的宏观自然和人文地理背景下，土地利用和覆被的变化主要反映了自然与人为因素的相互作用。中国的“三级阶梯”地形、南北分界的“800mm 等降水量线”构成了土地利用分布的自然地理框架，而“胡焕庸线”则清晰地将中国划分为人口密集、经济发达的东部和人口稀疏、相对落后的西部。这种地理分布格局不仅在自然条件上表现为土地类型的差异，也深受经济发展和人口分布的影响。因此，研究土地利用变化时，必须同时考

考虑自然因素和人类活动的双重影响。

为了量化这些复杂的影响并揭示土地利用变化的动态模式，我们使用 XGBoost 模型对多年来的土地利用数据进行了分析。模型结果表明，降水量、海拔、人口密度、GDP 等关键因素在土地利用变化中起着重要作用，尤其是在耕地、林地和草地之间的转换过程中，气候和经济因素的作用尤为显著。通过土地利用转换矩阵的分析，我们还发现了不同土地类型之间的转化规律，揭示了生态恢复与城市化进程中的动态变化模式。

参考文献

- [1] 陈述彭. 地理系统与地理信息系统 [J]. 地理学报, 1991, 46(1): 1-7. <https://doi.org/10.11821/xb199101001>
- [2] 彭书时, 朴世龙, 于家烁, 刘永稳, 汪涛, 朱高峰, 董金玮, 缪驰远. 地理系统模型研究进展[J]. 地理科学进展, 2018, 37(1): 109-120. <https://doi.org/10.18306/dlkxjz.2018.01.012>
- [3] Mark Graham and Taylor Shelton. Geography and the future of big data, big data and the future of geography. *Dialogues in Human geography*, 3(3):255 - 261, 2013.
- [4] 薛港. 2001-2020 年中国植被净初级生产力时空变化及其影响因素分析. Master' s thesis, 东北林业大学, 2023.
- [5] Peuquet, D. J. (1988). Representations of Geographic Space: Toward a Conceptual Synthesis. *Annals of the Association of American Geographers*, 78(3), 375-394. <https://doi.org/https://doi.org/10.1111/j.1467-8306.1988.tb00214.x>
- [6] 胡焕庸. 中国人口之分布——附统计表与密度图 [J]. 地理学报, 1935, 2(2): 33-74 <https://doi.org/10.11821/xb193502002>
- [7] Graham, M., & Shelton, T. (2013). Geography and the future of big data, big data and the future of geography. *Dialogues in Human Geography*, 3(3), 255-261. <https://doi.org/10.1177/2043820613513121>
- [8] 闫国年, 周成虎, 林琿, 陈旻, 乐松山, 温永宁. 地理综合研究方法的发展与思考[J]. 科学通报, 2021, 66(20): 2542-2554.

7 附录 1

表 7.6 海拔、气温、坡度回归系数结果及分析

Year	Mean_Precipitation	Std_Precipitation	Max_Precipitation
1990	266.78082	234.24863	6495.4893
1991	251.9454	230.82516	8428.56
1992	240.33833	227.05429	5915.6606
1993	264.03284	247.29861	6632.7217
1994	257.6894	248.88737	6149.443
1995	250.55457	239.99664	8082.2505
1996	257.53552	233.64365	7536.9478
1997	244.74129	266.49982	6577.66
1998	285.12802	260.9356	8771.02
1999	248.7574	247.73064	6653.749
2000	249.4315	238.71068	6847.7183
2001	244.41054	247.22665	6298.1104
2002	267.69177	265.07654	7135.041
2003	259.9223	211.34865	6660.908
2004	244.35655	214.29066	7771.3384
2005	256.13678	224.76495	4901.999
2006	241.70479	235.2693	4475.0503
2007	248.71863	218.58191	6588.6987
2008	265.1314	244.50143	5703.523
2009	235.60226	198.66295	4353.498
2010	279.20053	246.80647	6499.9297
2011	228.17725	189.26463	4934.9897
2012	276.80972	252.5715	6896.9614
2013	266.68707	223.97356	5860.56
2014	259.47736	239.06404	6613.888
2015	273.74158	273.57483	7790.68
2016	299.14838	277.1783	6621.3403
2017	269.47815	243.55193	7138.7485
2018	276.62497	220.4475	5233.6797

Year	Mean_Precipitation	Std_Precipitation	Max_Precipitation
2019	264.9937	225.23471	5341.9795
2020	285.12454	251.47856	5818.149

表 7.7 长短时记忆网络未来降雨量预测结果

Year	Forecast_Mean_Precipitation
2021	279.61132
2022	274.18283
2023	275.93445
2024	275.97775
2025	278.81726

表 7.8 长短时记忆网络历史降雨量预测结果

Year	Forecast_Mean_Precipitation	True_Value
1995	259.3015	250.55457
1996	256.49637	257.53552
1997	257.19406	244.74129
1998	260.0108	285.12802
1999	259.21426	248.7574
2000	259.5204	249.4315
2001	260.95044	244.41054
2002	259.9758	267.69177
2003	262.5198	259.9223
2004	256.10556	244.35655
2005	257.24734	256.13678
2006	258.36673	241.70479
2007	259.89862	248.71863
2008	255.77443	265.1314
2009	254.15204	235.60226
2010	255.1686	279.20053
2011	255.22229	228.17725
2012	257.2141	276.80972
2013	258.9986	266.68707
2014	257.91037	259.47736
2015	263.7575	273.74158
2016	260.5738	299.14838
2017	271.44904	269.47815
2018	271.3931	276.62497
2019	273.9359	264.9937
2020	277.6378	285.12454

表 7.9 长短时记忆网络损失函数结果

训练次数	loss
1	0.2653374969959259
2	0.23419228196144104
3	0.2031790167093277
4	0.17166098952293396
5	0.14474985003471375
6	0.11490637063980103
7	0.09031865745782852
8	0.06530464440584183
9	0.052701644599437714
10	0.047546807676553726
11	0.053700849413871765
12	0.06219187751412392
13	0.06295447796583176
14	0.056444719433784485
15	0.05123768001794815
16	0.047135625034570694
17	0.04740291088819504
18	0.04930249601602554
19	0.05047249794006348
20	0.05098961293697357
21	0.050833821296691895
22	0.04999071732163429
23	0.04895579442381859
24	0.04790792614221573
25	0.047189224511384964
26	0.04748908057808876
27	0.047727420926094055
28	0.04827456921339035
29	0.04827147349715233
30	0.047988634556531906

训练次数	loss
31	0.04760105535387993
32	0.04771783947944641
33	0.047345519065856934
34	0.0473591648042202
35	0.04742598533630371
36	0.0475032813847065
37	0.047394972294569016
38	0.047302376478910446
39	0.047194819897413254
40	0.04737835004925728
41	0.04756760969758034
42	0.04734508693218231
43	0.047158293426036835
44	0.04710487276315689
45	0.04712681844830513
46	0.04784926399588585
47	0.04733094200491905
48	0.047182846814394
49	0.04721757397055626
50	0.047153666615486145
51	0.047115422785282135
52	0.047105684876441956
53	0.04709526151418686
54	0.04703706130385399
55	0.04694549739360809
56	0.047099143266677856
57	0.04693325608968735
58	0.04692142829298973
59	0.04695822671055794
60	0.04686511680483818
61	0.04691377282142639
62	0.04716216027736664

训练次数	loss
63	0.046939559280872345
64	0.046724025160074234
65	0.04696838557720184
66	0.0470140166580677
67	0.047092005610466
68	0.0473293773829937
69	0.04708629101514816
70	0.04694772884249687
71	0.04677634313702583
72	0.046822309494018555
73	0.04667562618851662
74	0.046981681138277054
75	0.04716687276959419
76	0.0465385727584362
77	0.04666223004460335
78	0.046886902302503586
79	0.04725528135895729
80	0.04717542976140976
81	0.04751422256231308
82	0.047267407178878784
83	0.047040343284606934
84	0.046469852328300476
85	0.04655797779560089
86	0.04668017849326134
87	0.04687587171792984
88	0.04691462963819504
89	0.04672230780124664
90	0.04644835367798805
91	0.0465877428650856
92	0.04655885323882103
93	0.04671647027134895
94	0.04688086360692978

训练次数	loss
95	0.04663188010454178
96	0.0463780015707016
97	0.046768803149461746
98	0.047180961817502975
99	0.04708048701286316
100	0.04663350060582161

```
1 问题一 数据预处理
2 if __name__ == "__main__":
3     orignPath = r'E:\mathmod\4\cloud\datayuan'
4     outputPath = r'E:\mathmod\4\cloud\data'
5     filenames = os.listdir(r'E:\mathmod\4\cloud\datayuan')
6     for pathname in filenames:
7         if pathname[-1] != 'f':
8             continue;
9         filePath = orignPath + '\\' + pathname # tif文件路径
10        print(filePath)
11        dataset = gdal.Open(filePath) # 打开 tif
12
13
14        geo_information = dataset.GetGeoTransform()
15        col = dataset.RasterXSize
16        row = dataset.RasterYSize
17        band = dataset.RasterCount
18        dem = dataset.GetRasterBand(1).ReadAsArray()
19
20        df = pd.DataFrame(dem)
21        outFilePath = outputPath + '\\' + pathname[:-4] + '.csv'
22        df.to_csv(outFilePath, index=False)
```



```

1  问题一 优势植被计算
2  using namespace std;
3
4  vector<vector<double>> OpenFile(string fileName) {
5      ifstream file (fileName);
6      vector<vector<string>> data;
7
8      string line ;
9      while (getline( file , line )) {
10         vector<string> row;
11         size_t pos = 0;
12         string token;
13         while ((pos = line.find (",") ) != string::npos) {
14             token = line.substr(0, pos);
15             row.push_back(token);
16             line.erase(0, pos + 1);
17         }
18         row.push_back(line);
19         data.push_back(row);
20     }
21
22     vector<vector<double>> ret;
23     for (int i = 0; i < data.size(); i++) {
24         vector<double> ret1;
25         for (int j = 0; j < data[i].size(); j++) {
26             double ret11 = stod(data[i][j]);
27             ret1.push_back(ret11);
28         }
29         ret.push_back(ret1);
30     }
31     return ret;
32 }
33
34

```

```

35 int main() {
36     vector<vector<double>> ret1 = OpenFile("E:\\mathmod\\4\\cloud\\zhibeidata\\
        cropland-2019.csv");
37     vector<vector<double>> ret2 = OpenFile("E:\\mathmod\\4\\cloud\\zhibeidata\\forest
        -2019.csv");
38     vector<vector<double>> ret3 = OpenFile("E:\\mathmod\\4\\cloud\\zhibeidata\\grass
        -2019.csv");
39     vector<vector<double>> ret4 = OpenFile("E:\\mathmod\\4\\cloud\\zhibeidata\\shrub
        -2019.csv");
40     vector<vector<double>> ret5 = OpenFile("E:\\mathmod\\4\\cloud\\zhibeidata\\
        wetland-2019.csv");
41
42     for (int i = 0; i < ret1.size(); i++) {
43         for (int j = 0; j < ret1[i].size(); j++) {
44             int count = 1;
45             if ((fabs(ret1[i][j] - 0) <= 1e-6) && (fabs(ret2[i][j] - 0) <= 1e-6) && (
                fabs(ret3[i][j] - 0) <= 1e-6) &&
46                 (fabs(ret4[i][j] - 0) <= 1e-6) && (fabs(ret5[i][j] - 0) <= 1e-6)) {
47                 ret1[i][j] = 0;
48                 continue;
49             }
50             if (ret1[i][j] - ret2[i][j] < 1e-6) {
51                 count = 2;
52                 ret1[i][j] = ret2[i][j] ;
53             }
54             if (ret1[i][j] - ret3[i][j] < 1e-6) {
55                 count = 3;
56                 ret1[i][j] = ret3[i][j] ;
57             }
58             if (ret1[i][j] - ret4[i][j] < 1e-6) {
59                 count = 4;
60                 ret1[i][j] = ret4[i][j] ;
61             }
62             if (ret1[i][j] - ret5[i][j] < 1e-6) {

```

```
63         count = 5;
64         ret1[i][j] = ret5[i][j] ;
65     }
66     ret1[i][j] = count;
67 }
68 }
69 ofstream file ;
70 file .open("output2019.csv", ios::out);
71 for (int i = 0; i < ret1.size(); i++) {
72     for (int j = 0; j < ret1[i].size(); j++) {
73         file << ret1[i][j] << " ";
74     }
75     file << endl;
76 }
77 return 0;
78 }
```

```
1 问题一 植被覆盖总权重计算
2 data = "136.474,16.325;136.474,55.325;72.474,55.325;72.474,16.325"
3 arr = data.split(';')
4 arr_len = len(arr)
5
6 temp = []
7 for i in range(0,arr_len):
8     temp.append([float(x) for x in arr[i].split(',') ])
9 s = temp[0][1] * (temp[arr_len-1][0]-temp[1][0])
10
11 for i in range(1,arr_len):
12     s += temp[i][1] * (temp[i-1][0] - temp[(i+1)%arr_len][0])
13 print(round(math.fabs(s/2)*9101160000.085981,6))
```

```

1  问题一 五大植被指数计算
2  #include <iostream>
3  #include <fstream>
4  #include <vector>
5  #include <string>
6  using namespace std;
7
8  double Totalarea = 4186;
9
10 vector<vector<double>> OpenFile(string fileName) {
11     ifstream file (fileName);
12     vector<vector<string>> data;
13
14     string line ;
15     while (getline( file , line )) {
16         vector<string> row;
17         size_t pos = 0;
18         string token;
19         while ((pos = line .find (",") ) != string ::npos) {
20             token = line .substr(0, pos);
21             row.push_back(token);
22             line .erase(0, pos + 1);
23         }
24         row.push_back(line);
25         data.push_back(row);
26     }
27
28     vector<vector<double>> ret;
29     for (int i = 0; i < data.size(); i++) {
30         vector<double> ret1;
31         for (int j = 0; j < data[i].size(); j++) {
32             double ret11 = stod(data[i][j]);
33             ret1.push_back(ret11);
34         }

```

```

35     ret.push_back(ret1);
36 }
37 return ret;
38 }
39
40
41 double k(double dataa, double datab) {
42     double ret = 10 * ((datab - dataa) / dataa);
43     return ret;
44 }
45
46
47 double LC(double data, double data11, double data21, double data31, double data41,
48     double data51) {
49     double ret = 5 * (data / (data11 + data21 + data31 + data41 + data51));
50     return ret;
51 }
52
53 double Q(double dataa, double datab) {
54     double ret = 10 * ((datab - dataa) / Totalarea);
55     return ret;
56 }
57
58
59 double subtractpath(vector<vector<double>> data1, vector<vector<double>> data2) {
60     double ret = 0;
61     // printf ("data1 = %d, %d\n", data1.size(), data1[0].size());
62     for (int i = 0; i < data1.size(); i++) {
63         for (int j = 0; j < data1[i].size(); j++) {
64             if ((data1[i][j] - data2[i][j]) < 0) {
65                 continue;
66             }
67             ret = ret + data1[i][j] - data2[i][j];

```

```

68         // printf ("ret = %lf\n", ret);
69     }
70 }
71 return ret;
72 }
73
74
75 double LUD(double Xab, double data1) {
76     double ret = 10 * ((Xab / data1));
77     return ret;
78 }
79
80
81 double LUC(double jab, double data1) {
82     double ret = 10 * ((jab / data1));
83     return ret;
84 }
85
86
87 int main() {
88     vector<double> cropland = {};
89     vector<double> grass = {};
90     vector<double> shrub = {};
91     vector<double> wetland = {};
92     printf ("cropland K 1990–2000 = ");
93     printf ("%lf\n", k(cropland[0], cropland[9]));
94     printf ("cropland K 2000–2010 = ");
95     printf ("%lf\n", k(cropland[10], cropland[19]));
96     printf ("cropland K 2010–2020 = ");
97     printf ("%lf\n", k(cropland[20], cropland[29]));
98
99     printf ("forest K 1990–2000 = ");
100    printf ("%lf\n", k(forest [0], forest [9]) );
101    printf ("forest K 2000–2010 = ");

```

```

102     printf ("%lf\n", k(forest [10], forest [19]));
103     printf (" forest K 2010–2020 = ");
104     printf ("%lf\n", k(forest [20], forest [29]));
105
106     printf ("grass K 1990–2000 = ");
107     printf ("%lf\n", k(grass[0], grass[9]));
108     printf ("grass K 2000–2010 = ");
109     printf ("%lf\n", k(grass[10], grass[19]));
110     printf ("grass K 2010–2020 = ");
111     printf ("%lf\n", k(grass[20], grass[29]));
112
113     printf ("shrub K 1990–2000 = ");
114     printf ("%lf\n", k(shrub[0], shrub[9]));
115     printf ("shrub K 2000–2010 = ");
116     printf ("%lf\n", k(shrub[10], shrub[19]));
117     printf ("shrub K 2010–2020 = ");
118     printf ("%lf\n", k(shrub[20], shrub[29]));
119
120     printf ("wetland K 1990–2000 = ");
121     printf ("%lf\n", k(wetland[0], wetland[9]));
122     printf ("wetland K 2000–2010 = ");
123     printf ("%lf\n", k(wetland[10], wetland[19]));
124     printf ("wetland K 2010–2020 = ");
125     printf ("%lf\n", k(wetland[20], wetland[29]));
126
127     double sumcat = 0;
128     printf ("LC 1990–2000 = ");
129     vector<vector<double>> ret11 = OpenFile("E:\\mathmod\\4\\cloud\\zhibeidata\\
        cropland–1990.csv");
130     // printf ("ret11.size = %d\n", ret11.size());
131     vector<vector<double>> ret12 = OpenFile("E:\\mathmod\\4\\cloud\\zhibeidata\\
        cropland–1999.csv");
132     // printf ("ret11.size = %d\n", ret12.size());
133     vector<vector<double>> ret21 = OpenFile("E:\\mathmod\\4\\cloud\\zhibeidata\\forest

```



```

-1990.csv");
134 // printf ("ret11.size = %d\n", ret21.size() );
135 vector<vector<double>> ret22 = OpenFile("E:\\mathmod\\4\\cloud\\zhibeidata\\forest
-1999.csv");
136 // printf ("ret11.size = %d\n", ret22.size() );
137 vector<vector<double>> ret31 = OpenFile("E:\\mathmod\\4\\cloud\\zhibeidata\\grass
-1990.csv");
138 // printf ("ret11.size = %d\n", ret31.size() );
139 vector<vector<double>> ret32 = OpenFile("E:\\mathmod\\4\\cloud\\zhibeidata\\grass
-1999.csv");
140 // printf ("ret11.size = %d\n", ret32.size() );
141 vector<vector<double>> ret41 = OpenFile("E:\\mathmod\\4\\cloud\\zhibeidata\\shrub
-1990.csv");
142 // printf ("ret11.size = %d\n", ret41.size() );
143 vector<vector<double>> ret42 = OpenFile("E:\\mathmod\\4\\cloud\\zhibeidata\\shrub
-1999.csv");
144 // printf ("ret11.size = %d\n", ret42.size() );
145 vector<vector<double>> ret51 = OpenFile("E:\\mathmod\\4\\cloud\\zhibeidata\\
wetland-1990.csv");
146 // printf ("ret11.size = %d\n", ret51.size() );
147 vector<vector<double>> ret52 = OpenFile("E:\\mathmod\\4\\cloud\\zhibeidata\\
wetland-1999.csv");
148 // printf ("ret11.size = %d\n", ret52.size() );
149 sumcat = subtractpath(ret11, ret12) + subtractpath(ret21, ret22) + subtractpath(
ret31, ret32) + subtractpath(ret41, ret42) + subtractpath(ret51, ret52);
150 // printf ("sumcat=%lf\n", subtractpath(ret11, ret12));
151 printf ("%lf\n", LC(sumcat,cropland[0], forest [0], grass[0], shrub[0], wetland[0]))
;
152
153 printf ("LC 2020-2010 = ");
154 ret11 = OpenFile("E:\\mathmod\\4\\cloud\\zhibeidata\\cropland-2000.csv");
155 // printf ("ret11.size = %d\n", ret11.size() );
156 ret12 = OpenFile("E:\\mathmod\\4\\cloud\\zhibeidata\\cropland-2009.csv");
157 // printf ("ret11.size = %d\n", ret12.size() );

```

```

158 ret21 = OpenFile("E:\\mathmod\\4\\cloud\\zhibeidata\\forest-2000.csv");
159 // printf ("ret11.size = %d\\n", ret21.size());
160 ret22 = OpenFile("E:\\mathmod\\4\\cloud\\zhibeidata\\forest-2009.csv");
161 // printf ("ret11.size = %d\\n", ret22.size());
162 ret31 = OpenFile("E:\\mathmod\\4\\cloud\\zhibeidata\\grass-2000.csv");
163 // printf ("ret11.size = %d\\n", ret31.size());
164 ret32 = OpenFile("E:\\mathmod\\4\\cloud\\zhibeidata\\grass-2009.csv");
165 // printf ("ret11.size = %d\\n", ret32.size());
166 ret41 = OpenFile("E:\\mathmod\\4\\cloud\\zhibeidata\\shrub-2000.csv");
167 // printf ("ret11.size = %d\\n", ret41.size());
168 ret42 = OpenFile("E:\\mathmod\\4\\cloud\\zhibeidata\\shrub-2009.csv");
169 // printf ("ret11.size = %d\\n", ret42.size());
170 ret51 = OpenFile("E:\\mathmod\\4\\cloud\\zhibeidata\\wetland-2000.csv");
171 // printf ("ret11.size = %d\\n", ret51.size());
172 ret52 = OpenFile("E:\\mathmod\\4\\cloud\\zhibeidata\\wetland-2009.csv");
173 // printf ("ret11.size = %d\\n", ret52.size());
174 sumcat = subtractpath(ret11, ret12) + subtractpath(ret21, ret22) + subtractpath(
    ret31, ret32) + subtractpath(ret41, ret42) + subtractpath(ret51, ret52);
175 // printf ("sumcat=%f\\n", subtractpath(ret11, ret12));
176 printf ("%f\\n", LC(sumcat, cropland[10], forest[10], grass[10], shrub[10], wetland
    [10]));
177 printf ("LC 2020-2010 = ");
178 ret11 = OpenFile("E:\\mathmod\\4\\cloud\\zhibeidata\\cropland-2010.csv");
179 // printf ("ret11.size = %d\\n", ret11.size());
180 ret12 = OpenFile("E:\\mathmod\\4\\cloud\\zhibeidata\\cropland-2019.csv");
181 // printf ("ret11.size = %d\\n", ret12.size());
182 ret21 = OpenFile("E:\\mathmod\\4\\cloud\\zhibeidata\\forest-2010.csv");
183 // printf ("ret11.size = %d\\n", ret21.size());
184 ret22 = OpenFile("E:\\mathmod\\4\\cloud\\zhibeidata\\forest-2019.csv");
185 // printf ("ret11.size = %d\\n", ret22.size());
186 ret31 = OpenFile("E:\\mathmod\\4\\cloud\\zhibeidata\\grass-2010.csv");
187 // printf ("ret11.size = %d\\n", ret31.size());
188 ret32 = OpenFile("E:\\mathmod\\4\\cloud\\zhibeidata\\grass-2019.csv");
189 // printf ("ret11.size = %d\\n", ret32.size());

```

```

190  ret41 = OpenFile("E:\\mathmod\\4\\cloud\\zhibeidata\\shrub-2010.csv");
191  // printf ("ret11.size = %d\\n", ret41.size() );
192  ret42 = OpenFile("E:\\mathmod\\4\\cloud\\zhibeidata\\shrub-2019.csv");
193  // printf ("ret11.size = %d\\n", ret42.size() );
194  ret51 = OpenFile("E:\\mathmod\\4\\cloud\\zhibeidata\\wetland-2010.csv");
195  // printf ("ret11.size = %d\\n", ret51.size() );
196  ret52 = OpenFile("E:\\mathmod\\4\\cloud\\zhibeidata\\wetland-2019.csv");
197  // printf ("ret11.size = %d\\n", ret52.size() );
198  sumcat = subtractpath(ret11, ret12) + subtractpath(ret21, ret22) + subtractpath(
      ret31, ret32) + subtractpath(ret41, ret42) + subtractpath(ret51, ret52);
199  // printf ("sumcat=%f\\n", subtractpath(ret11, ret12));
200  printf ("%f\\n", LC(sumcat, cropland[20], forest[20], grass[20], shrub[20], wetland
      [20]));
201
202  printf ("cropland Q 1990-2000 = ");
203  printf ("%f\\n", Q(cropland[0], cropland[9]));
204  printf ("cropland Q 2000-2010 = ");
205  printf ("%f\\n", Q(cropland[10], cropland[19]));
206  printf ("cropland Q 2010-2020 = ");
207  printf ("%f\\n", Q(cropland[20], cropland[29]));
208
209  printf ("forest Q 1990-2000 = ");
210  printf ("%f\\n", Q(forest [0], forest [9]) );
211  printf ("forest Q 2000-2010 = ");
212  printf ("%f\\n", Q(forest [10], forest [19]) );
213  printf ("forest Q 2010-2020 = ");
214  printf ("%f\\n", Q(forest [20], forest [29]) );
215
216  printf ("grass Q 1990-2000 = ");
217  printf ("%f\\n", Q(grass[0], grass[9]));
218  printf ("grass Q 2000-2010 = ");
219  printf ("%f\\n", Q(grass[10], grass[19]));
220  printf ("grass Q 2010-2020 = ");
221  printf ("%f\\n", Q(grass[20], grass[29]));

```

```

222
223     printf ("shrub Q 1990–2000 = ");
224     printf ("%lf\n", Q(shrub[0], shrub[9]));
225     printf ("shrub Q 2000–2010 = ");
226     printf ("%lf\n", Q(shrub[10], shrub[19]));
227     printf ("shrub Q 2010–2020 = ");
228     printf ("%lf\n", Q(shrub[20], shrub[29]));
229
230     printf ("wetland Q 1990–2000 = ");
231     printf ("%lf\n", Q(wetland[0], wetland[9]));
232     printf ("wetland Q 2000–2010 = ");
233     printf ("%lf\n", Q(wetland[10], wetland[19]));
234     printf ("wetland Q 2010–2020 = ");
235     printf ("%lf\n", Q(wetland[20], wetland[29]));
236
237     printf ("cropland LUD 1990–2000 = ");
238     ret11 = OpenFile("E:\\mathmod\\4\\cloud\\zhibeidata\\cropland–1990.csv");
239     ret12 = OpenFile("E:\\mathmod\\4\\cloud\\zhibeidata\\cropland–1999.csv");
240     double Xab = subtractpath(ret12, ret11);
241     printf ("%lf\n", LUD(Xab, cropland[0]));
242     printf ("Xab = %lf, cropland[0] = %lf\n", Xab, cropland[0]);
243     printf ("cropland LUD 2000–2010 = ");
244     ret11 = OpenFile("E:\\mathmod\\4\\cloud\\zhibeidata\\cropland–2010.csv");
245     ret12 = OpenFile("E:\\mathmod\\4\\cloud\\zhibeidata\\cropland–2009.csv");
246     Xab = subtractpath(ret12, ret11);
247     printf ("%lf\n", LUD(Xab, cropland[10]));
248     printf ("cropland LUD 2010–2020 = ");
249     ret11 = OpenFile("E:\\mathmod\\4\\cloud\\zhibeidata\\cropland–2010.csv");
250     ret12 = OpenFile("E:\\mathmod\\4\\cloud\\zhibeidata\\cropland–2009.csv");
251     Xab = subtractpath(ret12, ret11);
252     printf ("%lf\n", LUD(Xab, cropland[20]));
253
254     printf ("forest LUD 1990–2000 = ");
255     ret11 = OpenFile("E:\\mathmod\\4\\cloud\\zhibeidata\\forest–1990.csv");

```

```

256 ret12 = OpenFile("E:\\mathmod\\4\\cloud\\zhibeidata\\forest-1999.csv");
257 Xab = subtractpath(ret12, ret11);
258 printf ("%lf\\n", LUD(Xab, forest[0]));
259 printf (" forest LUD 2000-2010 = ");
260 ret11 = OpenFile("E:\\mathmod\\4\\cloud\\zhibeidata\\forest-2010.csv");
261 ret12 = OpenFile("E:\\mathmod\\4\\cloud\\zhibeidata\\forest-2009.csv");
262 Xab = subtractpath(ret12, ret11);
263 printf ("%lf\\n", LUD(Xab, forest[10]));
264 printf (" forest LUD 2010-2020 = ");
265 ret11 = OpenFile("E:\\mathmod\\4\\cloud\\zhibeidata\\forest-2010.csv");
266 ret12 = OpenFile("E:\\mathmod\\4\\cloud\\zhibeidata\\forest-2009.csv");
267 Xab = subtractpath(ret12, ret11);
268 printf ("%lf\\n", LUD(Xab, forest[20]));
269
270 printf ("grass LUD 1990-2000 = ");
271 ret11 = OpenFile("E:\\mathmod\\4\\cloud\\zhibeidata\\grass-1990.csv");
272 ret12 = OpenFile("E:\\mathmod\\4\\cloud\\zhibeidata\\grass-1999.csv");
273 Xab = subtractpath(ret12, ret11);
274 printf ("%lf\\n", LUD(Xab, grass[0]));
275 printf ("grass LUD 2000-2010 = ");
276 ret11 = OpenFile("E:\\mathmod\\4\\cloud\\zhibeidata\\grass-2010.csv");
277 ret12 = OpenFile("E:\\mathmod\\4\\cloud\\zhibeidata\\grass-2009.csv");
278 Xab = subtractpath(ret12, ret11);
279 printf ("%lf\\n", LUD(Xab, grass[10]));
280 printf ("grass LUD 2010-2020 = ");
281 ret11 = OpenFile("E:\\mathmod\\4\\cloud\\zhibeidata\\grass-2010.csv");
282 ret12 = OpenFile("E:\\mathmod\\4\\cloud\\zhibeidata\\grass-2009.csv");
283 Xab = subtractpath(ret12, ret11);
284 printf ("%lf\\n", LUD(Xab, grass[20]));
285
286 printf ("shrub LUD 1990-2000 = ");
287 ret11 = OpenFile("E:\\mathmod\\4\\cloud\\zhibeidata\\shrub-1990.csv");
288 ret12 = OpenFile("E:\\mathmod\\4\\cloud\\zhibeidata\\shrub-1999.csv");
289 Xab = subtractpath(ret12, ret11);

```

```

290     printf ("%lf\n", LUD(Xab, shrub[0]));
291     printf ("shrub LUD 2000-2010 = ");
292     ret11 = OpenFile("E:\\mathmod\\4\\cloud\\zhibeidata\\shrub-2010.csv");
293     ret12 = OpenFile("E:\\mathmod\\4\\cloud\\zhibeidata\\shrub-2009.csv");
294     Xab = subtractpath(ret12, ret11);
295     printf ("%lf\n", LUD(Xab, shrub[10]));
296     printf ("shrub LUD 2010-2020 = ");
297     ret11 = OpenFile("E:\\mathmod\\4\\cloud\\zhibeidata\\shrub-2010.csv");
298     ret12 = OpenFile("E:\\mathmod\\4\\cloud\\zhibeidata\\shrub-2009.csv");
299     Xab = subtractpath(ret12, ret11);
300     printf ("%lf\n", LUD(Xab, shrub[20]));
301
302     printf ("wetland LUD 1990-2000 = ");
303     ret11 = OpenFile("E:\\mathmod\\4\\cloud\\zhibeidata\\wetland-1990.csv");
304     ret12 = OpenFile("E:\\mathmod\\4\\cloud\\zhibeidata\\wetland-1999.csv");
305     Xab = subtractpath(ret12, ret11);
306     printf ("%lf\n", LUD(Xab, wetland[0]));
307     printf ("wetland LUD 2000-2010 = ");
308     ret11 = OpenFile("E:\\mathmod\\4\\cloud\\zhibeidata\\wetland-2010.csv");
309     ret12 = OpenFile("E:\\mathmod\\4\\cloud\\zhibeidata\\wetland-2009.csv");
310     Xab = subtractpath(ret12, ret11);
311     printf ("%lf\n", LUD(Xab, wetland[10]));
312     printf ("wetland LUD 2010-2020 = ");
313     ret11 = OpenFile("E:\\mathmod\\4\\cloud\\zhibeidata\\wetland-2010.csv");
314     ret12 = OpenFile("E:\\mathmod\\4\\cloud\\zhibeidata\\wetland-2009.csv");
315     Xab = subtractpath(ret12, ret11);
316     printf ("%lf\n", LUD(Xab, wetland[20]));
317
318     printf ("cropland LUC 1990-2000 = ");
319     ret11 = OpenFile("E:\\mathmod\\4\\cloud\\zhibeidata\\cropland-1990.csv");
320     ret12 = OpenFile("E:\\mathmod\\4\\cloud\\zhibeidata\\cropland-1999.csv");
321     double jab = subtractpath(ret11, ret12);
322     // printf ("cropland-1990-cropland-1999jab = %lf\n", jab);
323     printf ("%lf\n", LUC(jab, cropland[0]));

```

```

324     printf ("cropland LUC 2000–2010 = ");
325     ret11 = OpenFile("E:\\mathmod\\4\\cloud\\zhibeidata\\cropland–2010.csv");
326     ret12 = OpenFile("E:\\mathmod\\4\\cloud\\zhibeidata\\cropland–2009.csv");
327     jab = subtractpath(ret11, ret12);
328     printf ("%lf\\n", LUC(jab, cropland[10]));
329     printf ("cropland LUC 2010–2020 = ");
330     ret11 = OpenFile("E:\\mathmod\\4\\cloud\\zhibeidata\\cropland–2010.csv");
331     ret12 = OpenFile("E:\\mathmod\\4\\cloud\\zhibeidata\\cropland–2009.csv");
332     jab = subtractpath(ret11, ret12);
333     printf ("%lf\\n", LUC(jab, cropland[20]));
334
335     printf (" forest LUC 1990–2000 = ");
336     ret11 = OpenFile("E:\\mathmod\\4\\cloud\\zhibeidata\\ forest –1990.csv");
337     ret12 = OpenFile("E:\\mathmod\\4\\cloud\\zhibeidata\\ forest –1999.csv");
338     jab = subtractpath(ret11, ret12);
339     printf ("%lf\\n", LUC(jab, forest [0]) );
340     printf (" forest LUC 2000–2010 = ");
341     ret11 = OpenFile("E:\\mathmod\\4\\cloud\\zhibeidata\\ forest –2010.csv");
342     ret12 = OpenFile("E:\\mathmod\\4\\cloud\\zhibeidata\\ forest –2009.csv");
343     jab = subtractpath(ret11, ret12);
344     printf ("%lf\\n", LUC(jab, forest [10]) );
345     printf (" forest LUC 2010–2020 = ");
346     ret11 = OpenFile("E:\\mathmod\\4\\cloud\\zhibeidata\\ forest –2010.csv");
347     ret12 = OpenFile("E:\\mathmod\\4\\cloud\\zhibeidata\\ forest –2009.csv");
348     jab = subtractpath(ret11, ret12);
349     printf ("%lf\\n", LUC(jab, forest [20]) );
350
351     printf ("grass LUC 1990–2000 = ");
352     ret11 = OpenFile("E:\\mathmod\\4\\cloud\\zhibeidata\\grass–1990.csv");
353     ret12 = OpenFile("E:\\mathmod\\4\\cloud\\zhibeidata\\grass–1999.csv");
354     jab = subtractpath(ret11, ret12);
355     printf ("%lf\\n", LUC(jab, grass[0]));
356     printf ("grass LUC 2000–2010 = ");
357     ret11 = OpenFile("E:\\mathmod\\4\\cloud\\zhibeidata\\grass–2010.csv");

```

```

358 ret12 = OpenFile("E:\\mathmod\\4\\cloud\\zhibeidata\\grass-2009.csv");
359 jab = subtractpath(ret11, ret12);
360 printf ("%lf\\n", LUC(jab, grass[10]));
361 printf ("grass LUC 2010-2020 = ");
362 ret11 = OpenFile("E:\\mathmod\\4\\cloud\\zhibeidata\\grass-2010.csv");
363 ret12 = OpenFile("E:\\mathmod\\4\\cloud\\zhibeidata\\grass-2009.csv");
364 jab = subtractpath(ret11, ret12);
365 printf ("%lf\\n", LUC(jab, grass[20]));
366
367 printf ("shrub LUC 1990-2000 = ");
368 ret11 = OpenFile("E:\\mathmod\\4\\cloud\\zhibeidata\\shrub-1990.csv");
369 ret12 = OpenFile("E:\\mathmod\\4\\cloud\\zhibeidata\\shrub-1999.csv");
370 jab = subtractpath(ret11, ret12);
371 printf ("%lf\\n", LUC(jab, shrub[0]));
372 printf ("shrub LUC 2000-2010 = ");
373 ret11 = OpenFile("E:\\mathmod\\4\\cloud\\zhibeidata\\shrub-2010.csv");
374 ret12 = OpenFile("E:\\mathmod\\4\\cloud\\zhibeidata\\shrub-2009.csv");
375 jab = subtractpath(ret11, ret12);
376 printf ("%lf\\n", LUC(jab, shrub[10]));
377 printf ("shrub LUC 2010-2020 = ");
378 ret11 = OpenFile("E:\\mathmod\\4\\cloud\\zhibeidata\\shrub-2010.csv");
379 ret12 = OpenFile("E:\\mathmod\\4\\cloud\\zhibeidata\\shrub-2009.csv");
380 jab = subtractpath(ret11, ret12);
381 printf ("%lf\\n", LUC(jab, shrub[20]));
382
383 printf ("wetland LUC 1990-2000 = ");
384 ret11 = OpenFile("E:\\mathmod\\4\\cloud\\zhibeidata\\wetland-1990.csv");
385 ret12 = OpenFile("E:\\mathmod\\4\\cloud\\zhibeidata\\wetland-1999.csv");
386 jab = subtractpath(ret11, ret12);
387 printf ("%lf\\n", LUC(jab, wetland[0]));
388 printf ("wetland LUC 2000-2010 = ");
389 ret11 = OpenFile("E:\\mathmod\\4\\cloud\\zhibeidata\\wetland-2010.csv");
390 ret12 = OpenFile("E:\\mathmod\\4\\cloud\\zhibeidata\\wetland-2009.csv");
391 jab = subtractpath(ret11, ret12);

```

```
392     printf ("%lf\n", LUC(jab, wetland[10]));
393     printf ("wetland LUC 2010–2020 = ");
394     ret11 = OpenFile("E:\\mathmod\\4\\cloud\\zhibeidata\\wetland–2010.csv");
395     ret12 = OpenFile("E:\\mathmod\\4\\cloud\\zhibeidata\\wetland–2009.csv");
396     jab = subtractpath(ret11, ret12);
397     printf ("%lf\n", LUC(jab, wetland[20]));
398
399     return 0;
400 }
```

```
1 问题一 csv图片转化为色彩图
2
3 def csv_to_custom_colored_tiff(csv_file, tiff_file ):
4
5     data = pd.read_csv(csv_file, delim_whitespace=True, header=None)
6
7     matrix = data.to_numpy()
8
9     color_map = {
10         0: (255, 255, 255), # 白色
11         1: (243, 116, 84), # 田地/
12         2: (65, 121, 178), # 深林/
13         3: (156, 213, 227), # 草/
14         4: (215, 59, 58), # 灌木/
15         5: (243, 248, 194) # 湿地/
16     }
17
18     colored_image = np.zeros((matrix.shape[0], matrix.shape[1], 3), dtype=np.uint8)
19
20     for key, color in color_map.items():
21         colored_image[matrix == key] = color
22
23     image = Image.fromarray(colored_image)
24     image.save( tiff_file )
25
26
27 csv_file = 'output1990.csv' # 替换为你的CSV文件路径
28 tiff_file = 'output1990.tif' # 输出TIFF文件路径
29 csv_to_custom_colored_tiff(csv_file, tiff_file )
```

```
1 问题二方法一 Theil-Sen Median 斜率估计法
2 def mann_kendall_test(x):
3     n = len(x)
4     s = 0
5     for i in range(n - 1):
6         for j in range(i + 1, n):
7             s += np.sign(x[j] - x[i])
8
9     var_s = (n * (n - 1) * (2 * n + 5)) / 18
10
11     if s > 0:
12         z = (s - 1) / np.sqrt(var_s)
13     elif s < 0:
14         z = (s + 1) / np.sqrt(var_s)
15     else:
16         z = 0
17
18     p_value = 2 * (1 - norm.cdf(abs(z)))
19
20     if p_value < alpha:
21         if z > 0:
22             trend = 'increasing'
23         elif z < 0:
24             trend = 'decreasing'
25         else:
26             trend = 'no trend'
27     else:
28         trend = 'no trend'
29     return trend, p_value
```

问题二方法一 归因分析

```
class Attribution_Analysis :
```

```
    def __init__( self , channel, label , user_id):
```

```
        self .AD_data = pd.DataFrame(np.array([channel, label, user_id]).T, columns=[  
            channel, 'label ', 'user_id'])
```

```
    def _RR_cul(self):
```

```
        self .RR=[]
```

```
        for chn1, chn2 in self .channel_comb:
```

```
            rr_value = float ( self .AD_count[(self.AD_count['channel']==chn1)&(self.  
                AD_count['label']==1)][ 'trans_rate ']) / float ( self .AD_count[(self.  
                AD_count['channel']==chn2)&(self.AD_count['label']==1)][ 'trans_rate '])  
            self .RR.append(rr_value)
```

```
    def _RD_cul(self):
```

```
        self .RD = []
```

```
        for chn1, chn2 in self .channel_comb:
```

```
            rd_value = float ( self .AD_count[(self.AD_count['channel']==chn1)&(self.  
                AD_count['label']==1)][ 'trans_rate ']) - float ( self .AD_count[(self.  
                AD_count['channel']==chn2)&(self.AD_count['label']==1)][ 'trans_rate '])  
            self .RD.append(rd_value)
```

```
    def _OR_cul(self):
```

```
        self .OR = []
```

```
        for chn1, chn2 in self .channel_comb:
```

```
            numerator = float ( self .AD_count[(self.AD_count['channel']==chn1)&(self.  
                AD_count['label']==1)][ 'user_count'])/ float ( self .AD_count[(self.  
                AD_count['channel']==chn2)&(self.AD_count['label']==1)][ 'user_count'])  
            denominator = float ( self .AD_count[(self.AD_count['channel']==chn1)&(self.  
                AD_count['label']==0)][ 'user_count'])/ float ( self .AD_count[(self.  
                AD_count['channel']==chn2)&(self.AD_count['label']==0)][ 'user_count'])
```

```
            or_value = numerator/denominator
```

```
            self .OR.append(or_value)
```

```

26
27 def _AP_cul(self):
28     self.AP = []
29     for i in range(len(self.channel_comb)):
30         chn1 = self.channel_comb[i][0]
31         chn2 = self.channel_comb[i][1]
32         ap_value = (self.OR[i]-1)/self.OR[i]
33         self.AP.append(ap_value)
34
35 def _PAF_cul(self):
36     self.PAF = []
37     for i in range(len(self.channel_comb)):
38         chn1 = self.channel_comb[i][0]
39         chn2 = self.channel_comb[i][1]
40         pop = float ( self.AD_count[(self.AD_count['channel']==chn1)&(self.
            AD_count['label']==1)][ 'total_count ']) / self.AD_count['user_count'].sum
            ()
41         paf_value = (pop*(self.OR[i]-1))/(pop*(self.OR[i]-1)+1)
42         self.PAF.append(paf_value)
43
44
45 def attribution_analysis ( self ):
46     self.AD_count = self.AD_data.groupby(['channel', 'label ']) .count().reset_index
        ()
47     self.AD_count.rename(columns={'user_id':'user_count'}, inplace = True)
48     self.AD_count['total_count'] = self.AD_count.groupby("channel")["user_count
        "].transform('sum')
49     self.AD_count['trans_rate'] = self.AD_count['user_count']/self.AD_count['
        total_count']
50
51
52     self.channel = np.unique(self.AD_count['channel'])
53     self.channel_comb = []
54     for chn1 in self.channel:

```

```
55         for chn2 in self.channel:
56             if chn1 != chn2:
57                 self.channel_comb.append([chn1, chn2])
58
59     self._RR_cul()
60     self._RD_cul()
61     self._OR_cul()
62     self._AP_cul()
63     self._PAF_cul()
```